

Conceitos Iniciais de Inferência Estatística

População, Amostra, Parâmetros, Estatísticas e Planos Amostrais

Notas de Aula

Prof. Eduardo Bezerra

Sumário

1	Visão Geral da Inferência Estatística	2
1.1	Estimação de parâmetros	3
1.2	Teste de hipóteses	3
1.3	Ajuste ou seleção de modelo	4
2	População e amostra	5
3	Parâmetros versus estatísticas	6
4	Amostras i.i.d.	7
5	Planos amostrais	9
5.1	Amostragem aleatória simples (AAS)	9
5.1.1	Exemplo Trabalho	10
5.2	Amostragem aleatória sistemática	11
5.2.1	Exemplo Trabalho	12
5.3	Amostragem aleatória estratificada	12
5.3.1	Exemplo Trabalho	13
5.4	Amostragem por conglomerados	13
5.4.1	Exemplo Trabalho	14
5.5	Comparação entre os planos amostrais	15
6	Próximos assuntos	16

Introdução

Ao final da leitura, você deve ser capaz de:

- Distinguir população de amostra, e parâmetro de estatística.
- Explicar por que uma estatística é uma variável aleatória, enquanto um parâmetro é um valor numérico (ainda que desconhecido).
- Reconhecer os principais planos amostrais (aleatória simples, sistemática, estratificada e por conglomerados) e a diferença entre amostragem com e sem reposição.
- Explicar o que significa uma amostra ser i.i.d. e por que essa hipótese é relevante para os resultados assintóticos.

Estas notas estão organizadas em cinco partes.

- A Seção 1 discute o objetivo da Inferência Estatística e seus principais problemas.
- A Seção 2 distingue população de amostra.
- A Seção 3 apresenta os conceitos de parâmetro, estatística, estimador e estimativa.
- A Seção 4 apresenta o conceito de amostras i.i.d.
- A Seção 5 descreve os principais planos amostrais.

1 Visão Geral da Inferência Estatística

Definição

O objetivo da Inferência Estatística é produzir afirmações sobre dada *característica* dos elementos de uma população, com base nos dados contidos em uma ou mais amostras dessa população.

A característica sob estudo pode ser representada por uma variável aleatória, que possui uma determinada distribuição de probabilidades com determinado conjunto de parâmetros. Seguem alguns exemplos:

1. A altura dos indivíduos de uma determinada população é uma característica que pode ser modelada por meio da distribuição normal com média $\mu = 1,65$ m e variância $\sigma^2 = 0,01$ m² (ou seja, desvio-padrão $\sigma = 0,10$ m = 10 cm).
2. O tempo de atendimento em um quiosque pode ser modelado por uma distribuição exponencial. Se parametrizarmos por taxa λ , então a média é $1/\lambda$ (por exemplo, média 5 minutos implica $\lambda = 1/5$ por minuto).
3. A quantidade de defeitos em cada peça produzida em um processo industrial segue uma distribuição de Poisson, com média igual a $\lambda = 0,8$.

Cada um dos exemplos acima pressupõe que foi feito um estudo para (1) identificar a distribuição de probabilidades (normal, exponencial, Poisson, etc.) mais adequada para o problema em questão e (2) identificar a combinação de parâmetros mais adequada para aquela distribuição. Quando a função de massa (caso discreto) ou de densidade (caso contínuo) da variável aleatória é conhecida, o problema de fazer afirmações sobre a população fica substancialmente simplificado. Ocorre que muitas vezes não sabemos nada sobre a variável, ou essa informação é parcial: no caso das alturas, por exemplo, podemos presumir uma distribuição normal, mas em geral desconhecemos os parâmetros que a caracterizam.

Em geral, pode acontecer de:

- termos uma ideia de qual deve ser a distribuição de probabilidades adequada, mas desconhecemos os valores dos parâmetros dessa distribuição;
- conhecermos os valores dos parâmetros, mas desconhecemos a distribuição de probabilidades;
- não conhecermos nem a distribuição de probabilidades, nem os respectivos valores dos parâmetros.

Em qualquer caso, o uso de uma amostra pode revelar informações sobre o comportamento da variável sob estudo na população.

As técnicas da Inferência Estatística voltadas a esse objetivo podem ser divididas em três grandes famílias: **estimação de parâmetros**, **teste de hipóteses** e **ajuste ou seleção de modelo**.

1.1 Estimação de parâmetros

Na estimação de parâmetros, o objetivo é construir, a partir de uma amostra, um valor plausível para algum parâmetro populacional desconhecido. Em termos práticos, usaremos os dados observados para produzir uma aproximação numérica para uma característica da população, como uma média, uma proporção ou uma variância.

Exemplo Trabalhado

Considere uma rede de ensino com 100 escolas, e suponha que o interesse esteja no número médio de horas semanais que os estudantes dedicam aos estudos fora da escola. Como não é viável observar todos os estudantes da rede, selecionamos uma amostra e calculamos a média amostral $\bar{x}$.

Nesse caso, a pergunta inferencial é: *qual é a média populacional de horas de estudo?* A média amostral funciona como estimativa da média populacional μ . O foco principal aqui não é verificar uma alegação específica, mas produzir um bom palpite numérico para o valor desconhecido do parâmetro.

1.2 Teste de hipóteses

No teste de hipóteses, o objetivo é verificar alguma alegação sobre um parâmetro populacional com base nos dados observados. Em vez de perguntar apenas “qual parece ser o valor do parâmetro?”, perguntamos se a amostra oferece evidência suficiente a favor ou contra uma afirmação previamente formulada.

Exemplo Trabalhado

Considere a mesma rede de ensino e a mesma variável: número de horas semanais dedicadas aos estudos fora da escola. Suponha agora que a secretaria de educação afirme que os estudantes da rede estudam, em média, pelo menos 8 horas por semana fora da escola.

Depois de coletar uma amostra, podemos usar os dados para avaliar se essa alegação é compatível com a evidência observada. Nesse caso, a pergunta inferencial já não é simplesmente “qual é a média?”, mas sim *os dados fornecem evidência de que a média populacional é de pelo menos 8 horas por semana?* Esse é um problema típico de teste de hipóteses.

1.3 Ajuste ou seleção de modelo

No ajuste ou seleção de modelo, o objetivo é identificar ou comparar distribuições de probabilidade candidatas a descrever o fenômeno sob estudo. Aqui, o interesse principal deixa de ser um parâmetro isolado e passa a ser a forma probabilística mais adequada para representar os dados.

Exemplo Trabalhado

Considere novamente a rede de ensino, mas suponha agora que a variável de interesse seja o *número de faltas por estudante em um mês*. Após coletar uma amostra, um pesquisador pode querer decidir se essa contagem é mais bem descrita por uma distribuição de Poisson ou por uma binomial negativa.

Nesse caso, a pergunta inferencial é: *qual modelo probabilístico descreve melhor os dados observados?* O problema já não consiste em estimar apenas uma média ou testar uma alegação pontual, mas em escolher uma família de distribuições apropriada para representar o mecanismo gerador dos dados.

Pergunta 1

Para cada situação abaixo, identifique se o problema é de **estimação de parâmetros**, **teste de hipóteses** ou **ajuste/seleção de modelo**, e justifique em uma frase:


- (a) Um engenheiro coleta 50 medições do tempo de resposta de um servidor, modelado por uma distribuição exponencial, e obtém $\bar{x} = 120$ ms. Ele usa $\hat{\lambda} = 1/\bar{x}$ para estimar a taxa λ .
- (b) Uma fabricante afirma que seus chips têm taxa de defeitos inferior a 2%. Um laboratório independente testa 200 chips e quer verificar essa alegação.
- (c) Um pesquisador quer descobrir qual distribuição de probabilidades melhor descreve o número de acessos por minuto a um servidor web.

2 População e amostra

Definições

- **População** (*population*) é a totalidade de elementos ou resultados (scores, pessoas, medidas, etc.) que estão sob discussão e dos quais se deseja inferir alguma informação. Na Estatística, o termo tem significado mais amplo que no discurso comum: pode denotar coleções de objetos, eventos, procedimentos ou observações (por exemplo, quantidades de colesterol medidas no sangue de um grupo de indivíduos, visitas ao médico ou operações cirúrgicas).
- **Amostra** (*sample*) é uma coleção de n observações obtidas de uma população segundo algum mecanismo de amostragem. Em uma formulação probabilística, uma amostra aleatória de tamanho n é representada pelo vetor $(X_1, \dots, X_n)$. Depois de observada a amostra, seus valores são representados por $(x_1, \dots, x_n)$.

População (N elementos)



A amostra é um subconjunto de n elementos extraído da população de N elementos (caso sem reposição); os pontos em destaque na população correspondem aos elementos selecionados para a amostra.

Exemplo: estaturas de uma escola

Considere uma escola de 5.000 alunos. Se quisermos fazer um estudo das estaturas (por exemplo, qual a estatura média?), podemos colher uma amostra de, digamos, 40 alunos e estudar o comportamento da variável estatura apenas nesses alunos. A variável a ser estudada poderia ser inteligência, número de irmãos, número de cáries, notas em história ou renda familiar, dentre outras.

Pergunta 2

Uma empresa fabrica 200.000 parafusos por dia e quer estimar o número médio de defeitos por parafuso na produção. Suponha que cada parafuso pode apresentar zero, um ou mais defeitos (por exemplo, defeitos de rosca, de comprimento ou de acabamento).

- Identifique a população e descreva o que seria uma amostra nesse contexto.
- Por que seria inviável (ou até destrutivo) analisar a população inteira?
- A variável “quantidade de defeitos por parafuso” é um exemplo de qual tipo de dado (quantitativo discreto, quantitativo contínuo ou qualitativo)? Justifique brevemente.

3 Parâmetros versus estatísticas

Definições

- Um **parâmetro** é uma medida usada para descrever uma característica de uma população. É uma medida numérica, normalmente não observável, que descreve uma característica de uma população.
- Uma **estatística amostral** (ou simplesmente **estatística**) é alguma função computada a partir de uma amostra. Uma estatística é uma variável aleatória para a qual cada um de seus valores é resultante de alguma computação realizada sobre uma amostra aleatória retirada da população.

Um parâmetro está para uma população assim como uma estatística está para uma amostra.

Considere a porcentagem de eleitores de uma população que preferem um determinado candidato: essa porcentagem é um exemplo de parâmetro populacional. Como é, na maioria dos casos, impraticável perguntar a todos os eleitores da população quais são suas preferências, uma amostra de eleitores pode ser consultada e uma estatística (a porcentagem amostral que preferiu cada candidato) pode ser computada como estimativa do parâmetro populacional. Da mesma forma, em testes de produtos fabricados, em vez de testar destrutivamente todos os produtos, apenas uma amostra é testada, permitindo estimar a proporção de produtos que atende às especificações mínimas.

Repare que enquanto um parâmetro é um valor numérico, uma estatística é uma variável aleatória. Para entender isso, considere o experimento aleatório de produzir uma amostra aleatória de tamanho n a partir de uma população. Podemos interpretar cada amostra (isto é, cada resultado da realização do experimento aleatório) como um elemento do espaço amostral correspondente a todas as possíveis amostras de tamanho n dessa população. Como, por definição, cada valor de uma estatística é uma função dos valores contidos na amostra aleatória correspondente, faz sentido dizer que uma estatística é uma variável aleatória.

A tabela abaixo resume a correspondência entre os principais parâmetros populacionais e as estatísticas amostrais usadas para estimá-los (em todos os casos, n é o tamanho da amostra e k é a quantidade de indivíduos na amostra que possuem uma característica de interesse):

Quantidade	Parâmetro populacional	Valor observado da estatística
Média	μ	$\bar{x} = \frac{1}{n}(x_1 + x_2 + \cdots + x_n)$
Variância	σ^2	$s^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$
Desvio-padrão	σ	$s = \sqrt{s^2}$
Proporção	p	$\hat{p} = k/n$

Repare que os valores de cada uma das estatísticas acima são computados sobre amostras aleatórias de tamanho fixo n : cada uma dessas estatísticas é, de fato, uma função que mapeia elementos de $\mathbb{R}^n$ em $\mathbb{R}$.

Para enfatizar a natureza aleatória de uma estatística, usaremos letra maiúscula quando nos referirmos à estatística **antes** de a amostra ser observada (por exemplo, $\bar{X}_n$, S^2 , $\hat{P}$) e letra minúscula quando nos referirmos ao **valor calculado** sobre uma amostra específica já observada (por exemplo, $\bar{x}$, s^2 , $\hat{p}$, como na tabela acima). Assim, $E[\bar{X}_n]$ e $\text{Var}(\bar{X}_n)$ dizem respeito ao comportamento probabilístico de $\bar{X}_n$ ao longo de diferentes amostras, assunto que será formalizado na próxima nota por meio do conceito de **distribuição amostral**. Já $\bar{x}_n$ denota um número fixo, resultado de uma amostra particular já coletada.

Pergunta 3

Em uma pesquisa eleitoral, 600 eleitores foram consultados e 312 disseram preferir o candidato A.

- (a) Calcule a proporção amostral $\hat{p}$.
- (b) O valor que você calculou é um **parâmetro** ou uma **estatística**? Justifique.
- (c) Por que dizemos que uma estatística é uma *variável aleatória*, enquanto um parâmetro é apenas um *valor numérico* (ainda que desconhecido)? Dê uma explicação com suas próprias palavras.

4 Amostras i.i.d.

Muitos resultados fundamentais da Inferência Estatística são formulados supondo que as observações de uma amostra sejam **independentes e identicamente distribuídas**, ou simplesmente **i.i.d.** Essa hipótese aparecerá novamente quando estudarmos a Lei dos Grandes Números e o Teorema do Limite Central nas próximas notas.

Considere uma amostra aleatória representada por

$$X_1, X_2, \dots, X_n.$$

Dizer que essas variáveis aleatórias são i.i.d. significa exigir simultaneamente duas propriedades:

- **independentes**: conhecer o valor de uma observação não fornece informação sobre os valores das demais; mais precisamente, observar uma delas não altera a distribuição de probabilidades das outras;
- **identicamente distribuídas**: todas as observações possuem a mesma distribuição de probabilidades. Se X_i tem função de distribuição F , então $X_1, \dots, X_n$ têm essa mesma função F .

Intuitivamente, a condição de serem identicamente distribuídas expressa a ideia de que todas as observações são produzidas pelo mesmo mecanismo probabilístico. A condição de independência, por sua vez, significa que uma observação não carrega informação sobre o resultado das demais.

Um primeiro exemplo de amostra i.i.d. é dado por lançamentos sucessivos de uma moeda. Considere $X_i = 1$ se o i -ésimo lançamento resultar em cara e $X_i = 0$ caso contrário. Se a probabilidade de cara permanece constante em todos os lançamentos e o resultado de um lançamento não influencia os demais, então

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p).$$

Outro exemplo é o de sorteios com reposição em uma população finita. Suponha que um elemento seja sorteado aleatoriamente, sua característica X seja registrada e o elemento seja devolvido à população antes do próximo sorteio. Como a população disponível é a mesma em todos os sorteios e cada sorteio é independente dos anteriores, as observações resultantes são i.i.d.

As duas partes da hipótese i.i.d. são distintas. Uma amostra pode deixar de ser i.i.d. porque as observações são dependentes, porque não possuem a mesma distribuição, ou pelas duas razões simultaneamente. Por exemplo, suponha que a temperatura de uma cidade seja registrada a cada hora. A temperatura às 14h tende a estar relacionada à temperatura às 13h. Assim, observações consecutivas não podem, em geral, ser consideradas independentes, ainda que suas distribuições marginais possam ser semelhantes.

Em outro cenário, as observações podem até ser independentes, mas não identicamente distribuídas. Suponha que sejam sorteadas, independentemente, 50 observações de uma população com média μ_1 e outras 50 de uma população diferente com média μ_2 . Mesmo que todos os sorteios sejam independentes, se as duas populações possuem distribuições diferentes, a amostra resultante, com 100 observações, não é identicamente distribuída.

Também pode haver dependência dentro de grupos. Considere uma pesquisa realizada com vários alunos de uma mesma escola. Mesmo que os alunos sejam pessoas distintas, suas respostas podem estar associadas porque compartilham professores, infraestrutura e contexto socioeconômico. Esse tipo de dependência aparecerá novamente quando estudarmos **amostragem por conglomerados**.

Observar valores numericamente diferentes não significa que as observações deixaram de ser identicamente distribuídas. Duas variáveis aleatórias podem assumir valores muito diferentes e, ainda assim, possuir exatamente a mesma distribuição de probabilidades. Da mesma forma, o fato de duas observações terem valores parecidos não implica que sejam dependentes.

A propriedade i.i.d. diz respeito ao mecanismo probabilístico que gera as observações, e não à aparência dos valores observados em uma amostra particular.

Pergunta 4

Para cada situação abaixo, avalie se é razoável considerar as observações i.i.d. Caso não seja, indique qual condição pode estar sendo violada: **independência**, **distribuição idêntica** ou ambas.

- (a) Uma moeda com probabilidade fixa de cara é lançada 100 vezes, de modo que um lançamento não influencia os demais.
- (b) A temperatura de uma cidade é registrada a cada cinco minutos durante um dia.
- (c) São selecionados aleatoriamente 50 homens e 50 mulheres de duas populações cujas distribuições de altura são diferentes, sendo todas as seleções realizadas independentemente.
- (d) São entrevistados 30 alunos de cada uma de cinco escolas selecionadas para uma pesquisa sobre hábitos de estudo.
- (e) Explique, com suas palavras, por que “independentes” e “identicamente distribuídas” são duas condições diferentes.

5 Planos amostrais

Dada uma população finita de tamanho N , pode-se mostrar que a quantidade de amostras de tamanho n que podem ser formadas a partir dessa população é

$$\binom{N}{n} = \frac{N!}{n!(N-n)!}$$

no caso em que a amostragem é *sem reposição* e em que a *ordem dos elementos na amostra não importa*.

Plano amostral

Um plano amostral é uma forma de produzir amostras a partir de uma população. Existem inúmeros planos amostrais; entre os mais usados estão:

- Amostragem aleatória simples
- Amostragem aleatória sistemática
- Amostragem aleatória estratificada
- Amostragem por conglomerados

A amostragem aleatória simples é a referência natural para compreender os demais planos: apresentamo-la primeiro e, em seguida, discutimos a sistemática, a estratificada e a amostragem por conglomerados como alternativas com vantagens e riscos específicos.

Pergunta 5

Uma escola tem $N = 1.200$ alunos e você quer selecionar uma amostra de $n = 60$.

(a) Calcule (ou estime usando logaritmos/calculadora) $\log_{10} \binom{1200}{60}$ para ter uma ideia da magnitude do número de amostras possíveis. O que esse número implica sobre a viabilidade de examinar todas as amostras?

(b) Por que a aleatorização no processo de seleção da amostra é fundamental para que as conclusões da inferência sejam válidas?

(c) Se você simplesmente pedisse aos primeiros 60 alunos que chegassem à escola na segunda-feira de manhã para participar do estudo, que tipo de problema isso introduziria?

5.1 Amostragem aleatória simples (AAS)

Na AAS *sem reposição* de tamanho n , cada uma das $\binom{N}{n}$ amostras possíveis de tamanho n tem a mesma probabilidade de ser selecionada. Essa equiprobabilidade entre amostras é a definição mais precisa de AAS. Como consequência dela, cada elemento da população tem a mesma probabilidade n/N de ser incluído na amostra. A recíproca, porém, não vale: existem planos amostrais nos quais todos os elementos têm a mesma probabilidade de inclusão sem que todas as amostras de tamanho n sejam igualmente prováveis (alguns esquemas de amostragem sistemática são um exemplo). Por isso é importante caracterizar a AAS pela equiprobabilidade das *amostras*, e não apenas dos *elementos*.

Uma AAS pode ser recolhida *com reposição* ou *sem reposição*:

- Quando a amostra é recolhida **com reposição**, cada elemento eventualmente selecionado pode ser selecionado novamente.
- Quando a amostra é recolhida **sem reposição**, os sorteios não são independentes, o que afeta principalmente o cálculo da variância e do erro padrão dos estimadores.

No caso sem reposição, a população efetiva diminui a cada sorteio, mas a probabilidade final de inclusão de um elemento continua sendo $\Pr(\text{inclusão}) = n/N$. Uma forma de ver isso é pelo complemento:

$$\Pr(\text{não inclusão}) = \frac{N-1}{N} \cdot \frac{N-2}{N-1} \cdots \frac{N-n}{N-n+1} = \frac{N-n}{N},$$

logo

$$\Pr(\text{inclusão}) = 1 - \frac{N-n}{N} = \frac{n}{N}.$$

No caso com reposição, em cada sorteio a probabilidade de seleção continua sendo $1/N$. Em n sorteios com reposição, a probabilidade de o elemento aparecer pelo menos uma vez é:

$$\Pr(\text{inclusão ao menos uma vez}) = 1 - \left(1 - \frac{1}{N}\right)^n,$$

que, em geral, é diferente de n/N .

Em estudos estatísticos aplicados com população finita, a escolha mais comum é a AAS sem reposição, pois ela evita selecionar a mesma unidade mais de uma vez sem necessidade e, em geral, produz estimativas mais eficientes, isto é, com menor variabilidade para um mesmo tamanho amostral. Assim, em contextos de coleta sobre populações finitas, como pessoas, escolas ou empresas, costuma-se preferir a amostragem sem reposição.

Por outro lado, a amostragem com reposição pode ser útil em modelagem teórica e em simulações, já que os sorteios independentes simplificam a análise. Além disso, quando a fração amostral é pequena, isto é, quando $n/N \leq 5\%$, a diferença prática entre os regimes com e sem reposição costuma ser pequena em muitas fórmulas. Já quando a fração amostral não é pequena, torna-se importante tratar explicitamente o caso sem reposição, inclusive com correção para população finita quando necessário. Em resumo, em pesquisa aplicada normalmente usa-se AAS sem reposição, enquanto a versão com reposição aparece com mais frequência em contextos teóricos, em simulação, ou em desenhos amostrais nos quais repetir unidades faz sentido.

5.1.1 Exemplo Trabalhado

Considere uma população com $N = 8$ estudantes, identificados por $\{A, B, C, D, E, F, G, H\}$. Desejamos selecionar uma amostra de tamanho $n = 3$ por AAS sem reposição. Suponha que o sorteio produza, nessa ordem, os nomes F , B e H .

Nesse caso, a amostra observada é $\{F, B, H\}$. O ponto central é que o sorteio recai diretamente sobre unidades individuais da população, e cada subconjunto de três estudantes tem a mesma probabilidade de ser selecionado. Se o plano fosse com reposição, poderíamos obter repetições, como F , B e F , o que mostra concretamente a diferença entre os dois regimes.

Exemplo comparativo: pesquisa com estudantes

Considere uma rede de ensino com 100 escolas, cada uma contendo aproximadamente 500 estudantes. O objetivo é estimar o número médio de horas semanais que os estudantes dedicam aos estudos fora da escola.

Sob AAS, poderíamos sortear diretamente estudantes de toda a rede, independentemente da escola em que estudam. Esse plano distribui a seleção por toda a população, mas pode exigir que os pesquisadores visitem muitas escolas diferentes para localizar os estudantes sorteados.

Como vimos anteriormente, muitos resultados da Inferência Estatística são formulados supondo observações i.i.d. Na AAS com reposição, essa hipótese surge naturalmente, pois cada sorteio é independente dos anteriores e todos seguem a mesma distribuição sobre a população.

Na AAS sem reposição, por outro lado, os sorteios não são independentes, pois a seleção de um elemento altera as possibilidades dos sorteios seguintes. Ainda assim, quando a fração amostral n/N é pequena, essa dependência tende a ser fraca, e tratar as observações como aproximadamente i.i.d. costuma ser uma aproximação útil.

Pergunta 6

Uma urna contém $N = 1.000$ nomes. Você realiza $n = 50$ sorteios.

- (a) Supondo *sem reposição*, qual é a probabilidade de inclusão de um elemento específico? Mostre o cálculo usando a fórmula do complemento apresentada no texto.
- (b) Supondo *com reposição*, qual é a probabilidade de um elemento específico ser incluído *ao menos uma vez*? Calcule numericamente e compare com o resultado do item (a).
- (c) A fração amostral n/N nesse caso é pequena o suficiente (i.e., $\leq 5\%$) para que a diferença entre os dois regimes seja desprezível na prática? Justifique.
- (d) Em qual dos seguintes contextos faria mais sentido usar AAS com reposição:
(i) pesquisa de opinião com eleitores, (ii) simulação computacional de um processo estocástico, (iii) controle de qualidade em linha de produção?

5.2 Amostragem aleatória sistemática

Os itens ou indivíduos da população são ordenados de alguma forma (alfabeticamente ou por meio de algum outro método). Um ponto de partida aleatório é sorteado, e então cada k -ésimo membro da população é selecionado para a amostra. A varredura sobre a lista ordenada é realizada de forma circular.

Do ponto de vista da hipótese i.i.d., a amostragem sistemática requer cuidado. Em geral, as observações selecionadas não devem ser tratadas automaticamente como independentes, pois a escolha de cada unidade decorre de uma regra fixa aplicada a uma lista ordenada, e não de sorteios independentes sucessivos. Se a lista não tiver estrutura relevante para a variável estudada, a amostragem sistemática pode se comportar de maneira semelhante à AAS em muitos contextos práticos.

Por outro lado, se a ordenação da lista estiver associada à variável de interesse, ou se houver algum tipo de periodicidade na população, esse plano pode introduzir vies ou padrões de dependência que não aparecem em uma AAS. Por isso, ao usar amostragem

sistemática, é importante examinar como a lista foi organizada antes de aplicar fórmulas inferenciais que pressupõem observações i.i.d.

5.2.1 Exemplo Trabalhado

Considere os mesmos 8 estudantes, agora dispostos em uma lista ordenada nas posições 1 a 8: A, B, C, D, E, F, G, H . Queremos selecionar uma amostra sistemática de tamanho $n = 4$. Como $N/n = 8/4 = 2$, usamos intervalo $k = 2$. Se o ponto de partida aleatório sorteado for a posição 2, então as posições selecionadas serão 2, 4, 6 e 8.

Logo, a amostra obtida é $\{B, D, F, H\}$. Esse exemplo mostra que apenas o ponto inicial é sorteado; depois disso, as demais unidades são determinadas pela regra fixa de seleção de cada k -ésimo elemento.

Exemplo comparativo: pesquisa com estudantes

Considere a mesma rede de ensino com 100 escolas, cada uma contendo aproximadamente 500 estudantes, e o mesmo objetivo de estimar o número médio de horas semanais dedicadas aos estudos fora da escola.

Se tivermos uma lista ordenada de todos os estudantes da rede, poderíamos escolher aleatoriamente um ponto inicial e, em seguida, selecionar cada k -ésimo estudante dessa lista. Em comparação com a AAS, esse plano pode ser mais simples de executar quando há uma listagem organizada, mas sua qualidade depende de a ordenação não introduzir padrões relevantes para a variável estudada.

Pergunta 7

Uma lista com $N = 500$ funcionários está ordenada alfabeticamente. Você quer uma amostra sistemática de tamanho $n = 25$.

- (a) Qual deve ser o intervalo de seleção k ?
- (b) Se o ponto de partida sorteado for o funcionário de número 7, quais são os três primeiros funcionários selecionados (informe seus números na lista)?
- (c) Cite uma situação concreta em que a amostragem sistemática poderia introduzir *viés* nos resultados.

5.3 Amostragem aleatória estratificada

A população é inicialmente dividida em subgrupos (estratos) e uma subamostra é selecionada a partir de cada estrato da população. O objetivo é garantir representação dos estratos relevantes e, frequentemente, aumentar a precisão das estimativas. A quantidade de elementos selecionados em cada estrato pode ser *proporcional* ao tamanho do estrato na população (caso mais comum, e o que exploraremos no exercício a seguir) ou seguir outro critério de alocação (por exemplo, super-representar estratos menores ou mais heterogêneos, quando isso melhora a precisão das estimativas).

Do ponto de vista probabilístico, a amostra estratificada completa não é, em geral, i.i.d. no sentido estrito, porque as observações são extraídas de subpopulações diferentes e, portanto, não são necessariamente identicamente distribuídas quando vistas em conjunto. Em compensação, dentro de cada estrato, é comum selecionar uma AAS, de modo que a aleatorização ocorra separadamente em cada subgrupo.

Essa distinção é importante para a inferência. Em vez de ignorar os estratos e analisar a amostra como se todos os dados viessem de uma única população homogênea, a análise

correta deve respeitar a estrutura estratificada, inclusive na combinação das subamostras e, quando necessário, no uso de pesos. É justamente essa organização por estratos que pode aumentar a precisão das estimativas quando os grupos diferem entre si de maneira relevante.

5.3.1 Exemplo Trabalhado

Considere uma população de 8 estudantes divididos em dois estratos: Curso de Engenharia $\{A, B, C, D, E\}$ e Curso de Computação $\{F, G, H\}$. Desejamos uma amostra de tamanho total $n = 4$, com alocação proporcional simples. Como o primeiro estrato contém $5/8$ da população e o segundo contém $3/8$, uma alocação proporcional natural é selecionar 3 estudantes de Engenharia e 1 de Computação.

Suponha que, no estrato de Engenharia, sejam sorteados B, C e E , e que, no estrato de Computação, seja sorteado H . A amostra final é então $\{B, C, E, H\}$. O mecanismo importante aqui é que o sorteio não ocorre sobre a população inteira de uma vez, mas separadamente dentro de cada estrato, e a amostra total resulta da reunião dessas subamostras.

Exemplo comparativo: pesquisa com estudantes

Considere novamente a rede de ensino com 100 escolas e o objetivo de estimar o número médio de horas semanais dedicadas aos estudos fora da escola. Suponha agora que as escolas estejam divididas em três estratos relevantes para a pesquisa: urbanas, periurbanas e rurais.

Em uma amostragem estratificada, poderíamos selecionar estudantes dentro de cada estrato, preservando a presença desses grupos na amostra final. Em comparação com a AAS, esse plano ajuda a garantir representação de subgrupos importantes e pode aumentar a precisão das estimativas quando os estratos diferem entre si.

Pergunta 8

Uma universidade tem três cursos: Engenharia (400 alunos), Medicina (200 alunos) e Ciência da Computação (100 alunos). Você quer realizar uma *amostragem estratificada proporcional* de tamanho total $n = 70$.

- (a) Quantos alunos devem ser selecionados de *cada curso*? Mostre o cálculo.
- (b) Por que a amostragem estratificada pode ser *preferível à AAS* quando os cursos apresentam perfis distintos em relação à variável estudada e queremos garantir representação de todos eles?
- (c) O que poderia acontecer com as conclusões do estudo se o estrato de Ciência da Computação fosse completamente ignorado na amostragem?

5.4 Amostragem por conglomerados

Na *amostragem por conglomerados* (*cluster sampling*), a população é inicialmente dividida em grupos naturais de unidades, chamados *conglomerados*. Em vez de selecionar diretamente indivíduos espalhados por toda a população, sorteiam-se alguns desses conglomerados e as observações são coletadas a partir deles.

Exemplos naturais de conglomerados incluem escolas em uma rede de ensino, turmas dentro de uma universidade, bairros de uma cidade, hospitais de uma região ou domicílios

dentro de setores censitários. Esse plano é especialmente útil quando existe uma organização natural da população em grupos e seria caro ou logisticamente difícil realizar uma amostragem aleatória simples envolvendo unidades distribuídas por toda a população.

Há duas formas comuns de realizar esse tipo de amostragem. No plano em um estágio, alguns conglomerados são selecionados aleatoriamente e todos os elementos pertencentes aos conglomerados sorteados são incluídos na amostra. No plano em dois estágios, alguns conglomerados são selecionados aleatoriamente e, em seguida, uma subamostra de elementos é selecionada dentro de cada conglomerado sorteado.

Exemplo comparativo: pesquisa com estudantes

Considere uma rede de ensino com 100 escolas, cada uma contendo aproximadamente 500 estudantes. O objetivo é estimar o número médio de horas semanais que os estudantes dedicam aos estudos fora da escola.

Uma AAS de estudantes poderia exigir que os pesquisadores visitassem dezenas ou até centenas de escolas diferentes. Uma alternativa seria sortear aleatoriamente 10 escolas e entrevistar todos os estudantes dessas escolas. Nesse caso, as escolas são os conglomerados, e temos uma amostragem por conglomerados em um estágio.

Outra possibilidade seria sortear as mesmas 10 escolas e, dentro de cada uma, selecionar aleatoriamente 50 estudantes. Teríamos então uma amostragem por conglomerados em dois estágios.

Em desenhos mais complexos, podem existir ainda mais estágios. Por exemplo, pode-se selecionar primeiro municípios, depois escolas dentro dos municípios e, finalmente, alunos dentro das escolas.

5.4.1 Exemplo Trabalhado

Um estágio. Considere uma população de 8 estudantes distribuídos em 4 conglomerados, cada um com 2 estudantes: Sala 1 $\{A, B\}$, Sala 2 $\{C, D\}$, Sala 3 $\{E, F\}$ e Sala 4 $\{G, H\}$. Em uma amostragem por conglomerados em um estágio, podemos sortear aleatoriamente 2 salas. Suponha que sejam selecionadas as Salas 2 e 4.

Nesse caso, a amostra observada é $\{C, D, G, H\}$, pois todos os elementos dos conglomerados sorteados entram na amostra.

Dois estágios. Considere agora o mesmo conjunto de salas, mas suponha que, após sortear as Salas 2 e 4, selecionemos apenas um estudante dentro de cada sala sorteada. Se, por exemplo, forem escolhidos D na Sala 2 e G na Sala 4, então a amostra observada será $\{D, G\}$.

O que este exemplo mostra. Esse contraste ajuda a visualizar que, em amostragem por conglomerados, o primeiro sorteio recai sobre grupos, e não diretamente sobre indivíduos espalhados por toda a população. Em um estágio, todos os elementos dos conglomerados sorteados entram na amostra; em dois estágios, ainda há um sorteio adicional dentro de cada conglomerado selecionado.

Pergunta 9

Uma cidade possui 80 escolas públicas, distribuídas por diferentes bairros. Um pesquisador deseja estimar o tempo médio diário que os alunos do ensino médio passam utilizando redes sociais.

Para reduzir os custos de deslocamento, ele sorteia aleatoriamente 8 escolas e entrevista todos os alunos do ensino médio dessas escolas.

(a) Qual é a população de interesse?

(b) Quais são os conglomerados?

(c) Esse plano corresponde a uma amostragem por conglomerados em um ou dois estágios? Justifique.

(d) Por que esse plano pode ser operacionalmente mais barato do que realizar uma AAS diretamente entre todos os alunos da cidade?

(e) Explique por que as respostas de dois alunos pertencentes à mesma escola podem não ser estatisticamente independentes.

(f) Suponha agora que o pesquisador sorteie 8 escolas e, dentro de cada escola sorteada, selecione aleatoriamente 30 alunos. Como passa a ser classificado o plano amostral?

5.5 Comparação entre os planos amostrais

Os quatro planos apresentados diferem no modo como a amostra é selecionada, nas vantagens operacionais que oferecem e no tipo de cuidado inferencial que exigem. Na AAS, o sorteio recai diretamente sobre unidades individuais da população e, por isso, esse plano costuma servir como referência conceitual básica. Na amostragem sistemática, também se selecionam unidades individuais, mas a escolha passa a depender de uma lista ordenada e de uma regra fixa após o sorteio do ponto inicial.

Na amostragem estratificada, a população é dividida em estratos e uma subamostra é selecionada dentro de cada um deles. Esse plano é especialmente útil quando se deseja garantir representação de subgrupos relevantes e, em muitos casos, aumentar a precisão das estimativas. Já na amostragem por conglomerados, a população é dividida em grupos naturais, mas selecionam-se apenas alguns desses grupos. Sua principal vantagem costuma ser operacional: concentrar a coleta em menos locais pode reduzir custos e tempo de trabalho de campo.

Esses planos também diferem quanto à relação com a hipótese i.i.d. Na AAS com reposição, a hipótese surge naturalmente; sem reposição, ela deixa de valer estritamente, embora muitas vezes seja uma boa aproximação quando a fração amostral é pequena. Na amostragem sistemática, a hipótese i.i.d. pode falhar se a ordenação da lista introduzir padrões ou periodicidade. Na amostragem estratificada, a amostra completa não é, em geral, identicamente distribuída quando vista em conjunto, pois as observações vêm de estratos distintos. Na amostragem por conglomerados, por sua vez, a principal dificuldade está na possível dependência entre unidades do mesmo conglomerado.

Uma forma simples de resumir as diferenças é a seguinte: na AAS, sorteamos unidades espalhadas pela população; na sistemática, sorteamos um ponto inicial e depois seguimos uma regra fixa; na estratificada, sorteamos unidades em todos os grupos relevantes; na amostragem por conglomerados, sorteamos alguns grupos e estudamos seus elementos. Em aplicações concretas, a escolha entre esses planos depende do equilíbrio entre representatividade, custo operacional e adequação das hipóteses probabilísticas usadas na

análise.

6 Próximos assuntos

Uma estatística calculada a partir de uma amostra, como a média $\bar{X}_n$, não assume necessariamente o mesmo valor em todas as amostras possíveis. Amostras diferentes produzem estimativas diferentes.

Na próxima nota, estudaremos como representar e quantificar essa *variabilidade amostral* por meio da distribuição amostral de uma estatística. Esse estudo nos conduzirá à Lei dos Grandes Números, ao Teorema do Limite Central e, posteriormente, à construção de intervalos de confiança.