

Conceitos Iniciais de Inferência Estatística

População, Amostra, Parâmetros, Estatísticas e Planos Amostrais

Notas de Aula

Prof. Eduardo Bezerra

Sumário

1	População e amostra	2
2	Parâmetros versus estatísticas	3
3	Objetivo da Inferência Estatística	5
4	Amostras i.i.d.	6
5	Planos amostrais	7
5.1	Amostragem aleatória simples (AAS)	8
5.2	Amostragem aleatória sistemática	9
5.3	Amostragem aleatória estratificada	10

Objetivos

Ao final da leitura, você deve ser capaz de:

Conceitos iniciais

- Distinguir população de amostra, e parâmetro de estatística.
- Explicar por que uma estatística é uma variável aleatória, enquanto um parâmetro é um valor numérico (ainda que desconhecido).
- Reconhecer os principais planos amostrais (aleatória simples, sistemática, estratificada) e a diferença entre amostragem com e sem reposição.
- Explicar o que significa uma amostra ser i.i.d. e por que essa hipótese é relevante para os resultados assintóticos.


Roteiro de leitura

Estas notas estão organizadas em cinco partes. A Seção 1 distingue população de amostra. A Seção 2 apresenta os conceitos de parâmetro, estatística, estimador e estimativa. A Seção 3 discute o objetivo da Inferência Estatística e seus principais problemas. A Seção 4 apresenta a hipótese de amostras i.i.d. Por fim, a Seção 5 descreve os principais planos amostrais.

1 População e amostra

Definições

- **População** (*population*) é a totalidade de elementos ou resultados (escores, pessoas, medidas, etc.) que estão sob discussão e dos quais se deseja inferir alguma informação. Na Estatística, o termo tem significado mais amplo que no discurso comum: pode denotar coleções de objetos, eventos, procedimentos ou observações (por exemplo, quantidades de colesterol medidas no sangue de um grupo de indivíduos, visitas ao médico ou operações cirúrgicas).
- **Amostra** (*sample*) é uma coleção de n observações obtidas de uma população segundo um mecanismo de amostragem. Em amostragem **sem reposição**, a amostra pode ser vista como um subconjunto de n elementos distintos da população; em amostragem **com reposição**, um mesmo elemento pode aparecer mais de uma vez, e a amostra deixa de ser, estritamente, um subconjunto. Em uma formulação probabilística, quando o interesse recai sobre um modelo gerador de dados, uma amostra aleatória de tamanho n é representada pelo vetor $(X_1, \dots, X_n)$. Depois de observada a amostra, seus valores são representados por $(x_1, \dots, x_n)$.

População (N elementos)

A amostra é um subconjunto de n elementos extraído da população de N elementos (caso sem reposição); os pontos em destaque na população correspondem aos elementos selecionados para a amostra.

Exemplo: estaturas de uma escola

Considere uma escola de 5.000 alunos. Se quisermos fazer um estudo das estaturas (por exemplo, qual a estatura média?), podemos colher uma amostra de, digamos, 40 alunos e estudar o comportamento da variável estatura apenas nesses alunos. A variável a ser estudada poderia ser inteligência, número de irmãos, número de cáries, notas em história ou renda familiar, dentre outras.

Pergunta 1

Uma empresa fabrica 200.000 parafusos por dia e quer estimar o número médio de defeitos por parafuso na produção. Suponha que cada parafuso pode apresentar zero, um ou mais defeitos (por exemplo, defeitos de rosca, de comprimento ou de acabamento).

- (a) Identifique a **população** e descreva o que seria uma **amostra** nesse contexto.
- (b) Por que seria inviável (ou até destrutivo) analisar a população inteira?
- (c) A variável “quantidade de defeitos por parafuso” é um exemplo de qual tipo de dado (quantitativo discreto, quantitativo contínuo ou qualitativo)? Justifique brevemente.

2 Parâmetros versus estatísticas

Definições

- Um **parâmetro** é uma medida usada para descrever uma característica de uma população. É uma medida numérica, normalmente não observável, que descreve uma característica de uma população.
- Uma **estatística amostral** (ou simplesmente **estatística**) é alguma função computada a partir de uma amostra. Uma estatística é uma variável aleatória para a qual cada um de seus valores é resultante de alguma computação realizada sobre uma amostra aleatória retirada da população.

Um parâmetro está para uma população assim como uma estatística está para uma amostra.

Considere a porcentagem de eleitores de uma população que preferem um determinado candidato: essa porcentagem é um exemplo de parâmetro populacional. Como é, na maioria dos casos, impraticável perguntar a todos os eleitores da população quais são suas preferências, uma amostra de eleitores pode ser consultada e uma estatística (a porcentagem amostral que preferiu cada candidato) pode ser computada como estimativa do parâmetro populacional. Da mesma forma, em testes de produtos fabricados, em vez de testar destrutivamente todos os produtos, apenas uma amostra é testada, permitindo estimar a proporção de produtos que atende às especificações mínimas.

Estatística como variável aleatória

Repare que enquanto um parâmetro é um valor numérico, uma estatística é uma variável aleatória. Para entender isso, considere o experimento aleatório de produzir uma amostra aleatória de tamanho n a partir de uma população. Podemos interpretar cada amostra (isto é, cada resultado da realização do experimento aleatório) como um elemento do espaço amostral correspondente a todas as possíveis amostras de tamanho n dessa população. Como, por definição, cada valor de uma estatística é uma função dos valores contidos na amostra aleatória correspondente, faz sentido dizer que uma estatística é uma variável aleatória.

A tabela abaixo resume a correspondência entre os principais parâmetros populacionais e as estatísticas amostrais usadas para estimá-los (em todos os casos, n é o tamanho da amostra e k é a quantidade de indivíduos na amostra que possuem uma característica de interesse):

Quantidade	Parâmetro populacional	Valor observado da estatística
Média	μ	$\bar{x} = \frac{1}{n}(x_1 + x_2 + \cdots + x_n)$
Variância	σ^2	$s^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$
Desvio-padrão	σ	$s = \sqrt{s^2}$
Proporção	p	$\hat{p} = k/n$

Repare que os valores de cada uma das estatísticas acima são computados sobre amostras aleatórias de tamanho fixo n : cada uma dessas estatísticas é, de fato, uma função que mapeia elementos de $\mathbb{R}^n$ em $\mathbb{R}$.

Convenção de notação

Para enfatizar a natureza aleatória de uma estatística, usaremos letra maiúscula quando nos referirmos à estatística **antes** de a amostra ser observada (por exemplo, $\bar{X}_n$, S^2 , $\hat{P}$) e letra minúscula quando nos referirmos ao **valor calculado** sobre uma amostra específica já observada (por exemplo, $\bar{x}$, s^2 , $\hat{p}$, como na tabela acima). Assim, $E[\bar{X}_n]$ e $\text{Var}(\bar{X}_n)$ dizem respeito ao comportamento probabilístico de $\bar{X}_n$ ao longo de diferentes amostras, assunto que será formalizado na próxima nota por meio do conceito de **distribuição amostral**. Já $\bar{x}_n$ denota um número fixo, resultado de uma amostra particular já coletada.

Pergunta 2

Em uma pesquisa eleitoral, 600 eleitores foram consultados e 312 disseram preferir o candidato A.

- (a) Calcule a proporção amostral $\hat{p}$.
- (b) O valor que você calculou é um **parâmetro** ou uma **estatística**? Justifique.
- (c) Por que dizemos que uma estatística é uma *variável aleatória*, enquanto um parâmetro é apenas um *valor numérico* (ainda que desconhecido)? Dê uma explicação com suas próprias palavras.

3 Objetivo da Inferência Estatística

Definição

O objetivo da Inferência Estatística é produzir afirmações sobre dada **característica** dos elementos de uma população, com base nos dados contidos em uma ou mais amostras dessa população.

A característica sob estudo pode ser representada por uma variável aleatória, que possui uma determinada distribuição de probabilidades com determinado conjunto de parâmetros. Seguem alguns exemplos:

1. A altura dos indivíduos de uma determinada população é uma característica que pode ser modelada por meio da distribuição normal com média $\mu = 1,65$ m e variância $\sigma^2 = 0,01$ m² (ou seja, desvio-padrão $\sigma = 0,10$ m = 10 cm).
2. O tempo de atendimento em um quiosque pode ser modelado por uma distribuição exponencial. Se parametrizarmos por **taxa** λ , então a média é $1/\lambda$ (por exemplo, média 5 minutos implica $\lambda = 1/5$ por minuto).
3. A quantidade de defeitos em cada peça produzida em um processo industrial segue uma distribuição de Poisson, com média igual a $\lambda = 0,8$.

Cada um dos exemplos acima pressupõe que foi feito um estudo para (1) identificar a distribuição de probabilidades (normal, exponencial, Poisson, etc.) mais adequada para o problema em questão e (2) identificar a combinação de parâmetros mais adequada para aquela distribuição. Quando a função de massa (caso discreto) ou de densidade (caso contínuo) da variável aleatória é conhecida, o problema de fazer afirmações sobre a população fica substancialmente simplificado. Ocorre que muitas vezes não sabemos nada sobre a variável, ou essa informação é parcial: no caso das alturas, por exemplo, podemos presumir uma distribuição normal, mas em geral desconhecemos os parâmetros que a caracterizam.

Em geral, pode acontecer de:

- termos uma ideia de qual deve ser a distribuição de probabilidades adequada, mas desconhecemos os valores dos parâmetros dessa distribuição;
- conhecermos os valores dos parâmetros, mas desconhecemos a distribuição de probabilidades;

- não conhecermos nem a distribuição de probabilidades, nem os respectivos valores dos parâmetros.

Em qualquer caso, o uso de uma amostra pode revelar informações sobre o comportamento da variável sob estudo na população.

As técnicas da Inferência Estatística voltadas a esse objetivo podem ser divididas em três grandes famílias:

Estimação de parâmetros

Conjunto de técnicas para **construir uma estimativa** para um parâmetro de uma população por meio de observações de uma amostra.

Teste de hipóteses

Conjunto de técnicas para **verificar alguma alegação** acerca do parâmetro de uma população por meio de observações de uma ou mais amostras.

Ajuste ou seleção de modelo

Conjunto de técnicas para **identificar ou comparar distribuições de probabilidade** candidatas a descrever o fenômeno sob estudo, com base nos dados observados. Por exemplo, decidir se uma variável é mais bem descrita por uma distribuição de Poisson ou por uma binomial negativa.

Pergunta 3

Para cada situação abaixo, identifique se o problema é de **estimação de parâmetros**, **teste de hipóteses** ou **ajuste/seleção de modelo**, e justifique em uma frase:

- (a) Um engenheiro coleta 50 medições do tempo de resposta de um servidor, modelado por uma distribuição exponencial, e obtém $\bar{x} = 120$ ms. Ele usa $\hat{\lambda} = 1/\bar{x}$ para estimar a taxa λ .
- (b) Uma fabricante afirma que seus chips têm taxa de defeitos inferior a 2%. Um laboratório independente testa 200 chips e quer verificar essa alegação.
- (c) Um pesquisador quer descobrir qual distribuição de probabilidades melhor descreve o número de acessos por minuto a um servidor web.

4 Amostras i.i.d.

Em muitos resultados da Inferência Estatística, especialmente na Lei dos Grandes Números e no Teorema do Limite Central, assume-se que as observações da amostra são i.i.d. Esses resultados serão estudados nas próximas notas.

- **independentes**: conhecer o valor de uma observação não altera a distribuição das demais;
- **identicamente distribuídas**: todas as observações seguem a mesma distribuição de probabilidades.

Intuitivamente, a parte “i.d.” garante que estamos observando o mesmo fenômeno estatístico ao longo da amostra, enquanto a parte “independente” simplifica o cálculo de variâncias e sustenta resultados assintóticos clássicos.

Amostragem com ou sem reposição e a hipótese i.i.d.

Em amostragem aleatória simples **com reposição**, as hipóteses de independência e de distribuição idêntica são naturais. Em amostragem aleatória simples **sem reposição**, há dependência entre sorteios; ainda assim, quando a fração amostral é pequena (n/N pequeno), tratar a amostra como aproximadamente i.i.d. costuma ser uma aproximação útil.

Pergunta 4

Considere uma amostra de tamanho n usada para inferir um parâmetro populacional.

- (a) Explique, com suas palavras, o que significa dizer que as observações são i.i.d.
- (b) Dê um exemplo de situação em que a hipótese de independência pode falhar na prática.

5 Planos amostrais

Dada uma população finita de tamanho N , pode-se mostrar que a quantidade de amostras de tamanho n que podem ser formadas a partir dessa população é

$$\binom{N}{n} = \frac{N!}{n!(N-n)!}$$

no caso em que a amostragem é **sem reposição** e em que a **ordem dos elementos na amostra não importa**.

Plano amostral

Um **plano amostral** é uma forma de produzir amostras a partir de uma população. Existem inúmeros planos amostrais; entre os mais usados estão:

- Amostragem aleatória simples
- Amostragem aleatória sistemática
- Amostragem aleatória estratificada

A amostragem aleatória simples é a referência natural para compreender os demais planos: apresentamo-la primeiro e, em seguida, a sistemática e a estratificada como alternativas com vantagens e riscos específicos.

Pergunta 5

Uma escola tem $N = 1.200$ alunos e você quer selecionar uma amostra de $n = 60$.

(a) Calcule (ou estime usando logaritmos/calculadora) $\log_{10} \binom{1200}{60}$ para ter uma ideia da magnitude do número de amostras possíveis. O que esse número implica sobre a viabilidade de examinar todas as amostras?

(b) Por que a **aleatorização** no processo de seleção da amostra é fundamental para que as conclusões da inferência sejam válidas?

(c) Se você simplesmente pedisse aos primeiros 60 alunos que chegassem à escola na segunda-feira de manhã para participar do estudo, que tipo de problema isso introduziria?

5.1 Amostragem aleatória simples (AAS)

Na AAS **sem reposição** de tamanho n , cada uma das $\binom{N}{n}$ amostras possíveis de tamanho n tem a **mesma probabilidade** de ser selecionada. Essa equiprobabilidade entre amostras é a definição mais precisa de AAS. Como consequência dela, cada elemento da população tem a mesma probabilidade n/N de ser incluído na amostra. A recíproca, porém, não vale: existem planos amostrais nos quais todos os elementos têm a mesma probabilidade de inclusão sem que todas as amostras de tamanho n sejam igualmente prováveis (alguns esquemas de amostragem sistemática são um exemplo). Por isso é importante caracterizar a AAS pela equiprobabilidade das *amostras*, e não apenas dos *elementos*.

Uma AAS pode ser recolhida *com reposição* ou *sem reposição*:

- Quando a amostra é recolhida **com reposição**, cada elemento eventualmente selecionado pode ser selecionado novamente.
- Quando a amostra é recolhida **sem reposição**, os sorteios não são independentes, o que afeta principalmente o cálculo da variância e do erro padrão dos estimadores.

Probabilidade de inclusão em AAS

Sem reposição. A população efetiva diminui a cada sorteio, mas a probabilidade final de inclusão é $P(\text{inclusão}) = n/N$. Uma forma de ver isso é pelo complemento:

$$\Pr(\text{não inclusão}) = \frac{N-1}{N} \cdot \frac{N-2}{N-1} \cdots \frac{N-n}{N-n+1} = \frac{N-n}{N},$$

logo

$$\Pr(\text{inclusão}) = 1 - \frac{N-n}{N} = \frac{n}{N}.$$

Com reposição. Em cada sorteio, a probabilidade de seleção continua sendo $1/N$. Em n sorteios com reposição, a probabilidade de o elemento aparecer pelo menos uma vez é:

$$\Pr(\text{inclusão ao menos uma vez}) = 1 - \left(1 - \frac{1}{N}\right)^n,$$

que, em geral, é diferente de n/N .

Dúvida frequente: AAS com ou sem reposição?

Em estudos estatísticos aplicados com população finita, a escolha mais comum é **AAS sem reposição**. Por quê?

- Evita selecionar a mesma unidade mais de uma vez sem necessidade.
- Em geral, produz estimativas mais eficientes (menor variabilidade) para o mesmo tamanho amostral.

Quando considerar cada caso:

1. **Coleta em população finita** (pessoas, escolas, empresas): preferir **sem reposição**.
2. **Modelagem teórica e simulações: com reposição** pode ser útil por simplificar a análise (sorteios independentes).
3. **Fração amostral pequena** ($n/N \leq 5\%$): a diferença prática entre com e sem reposição costuma ser pequena em muitas fórmulas.
4. **Fração amostral não pequena**: é importante tratar o caso sem reposição explicitamente (incluindo correção para população finita quando necessário).

Resumo prático: para pesquisa aplicada, normalmente usa-se AAS sem reposição; com reposição é mais comum em contextos teóricos, simulação, ou quando repetir unidades faz sentido no desenho amostral.

Pergunta 6

Uma urna contém $N = 1.000$ nomes. Você realiza $n = 50$ sorteios.

- (a) Supondo **sem reposição**, qual é a probabilidade de inclusão de um elemento específico? Mostre o cálculo usando a fórmula do complemento apresentada no texto.
- (b) Supondo **com reposição**, qual é a probabilidade de um elemento específico ser incluído *ao menos uma vez*? Calcule numericamente e compare com o resultado do item (a).
- (c) A fração amostral n/N nesse caso é pequena o suficiente (i.e., $\leq 5\%$) para que a diferença entre os dois regimes seja desprezível na prática? Justifique.
- (d) Em qual dos seguintes contextos faria mais sentido usar AAS **com** reposição: (i) pesquisa de opinião com eleitores, (ii) simulação computacional de um processo estocástico, (iii) controle de qualidade em linha de produção?

5.2 Amostragem aleatória sistemática

Os itens ou indivíduos da população são ordenados de alguma forma (alfabeticamente ou por meio de algum outro método). Um ponto de partida aleatório é sorteado, e então cada k -ésimo membro da população é selecionado para a amostra. A varredura sobre a lista ordenada é realizada de forma circular.

Pergunta 7

Uma lista com $N = 500$ funcionários está ordenada alfabeticamente. Você quer uma amostra sistemática de tamanho $n = 25$.

- (a) Qual deve ser o intervalo de seleção k ?
- (b) Se o ponto de partida sorteado for o funcionário de número 7, quais são os **três primeiros** funcionários selecionados (informe seus números na lista)?
- (c) Cite uma situação concreta em que a amostragem sistemática poderia introduzir **viés** nos resultados.

5.3 Amostragem aleatória estratificada

A população é inicialmente dividida em subgrupos (estratos) e uma subamostra é selecionada a partir de cada estrato da população. O objetivo é garantir representação dos estratos relevantes e, frequentemente, aumentar a precisão das estimativas. A quantidade de elementos selecionados em cada estrato pode ser **proporcional** ao tamanho do estrato na população (caso mais comum, e o que exploraremos no exercício a seguir) ou seguir outro critério de alocação (por exemplo, super-representar estratos menores ou mais heterogêneos, quando isso melhora a precisão das estimativas).

Pergunta 8

Uma universidade tem três cursos: Engenharia (400 alunos), Medicina (200 alunos) e Ciência da Computação (100 alunos). Você quer realizar uma **amostragem estratificada proporcional** de tamanho total $n = 70$.

- (a) Quantos alunos devem ser selecionados de **cada curso**? Mostre o cálculo.
- (b) Por que a amostragem estratificada pode ser **preferível à AAS** quando os cursos apresentam perfis distintos em relação à variável estudada e queremos garantir representação de todos eles?
- (c) O que poderia acontecer com as conclusões do estudo se o estrato de Ciência da Computação fosse completamente ignorado na amostragem?

Próximo passo

Uma estatística calculada a partir de uma amostra, como a média $\bar{X}_n$, não assume necessariamente o mesmo valor em todas as amostras possíveis. Amostras diferentes produzem estimativas diferentes.

Na próxima nota, estudaremos como representar e quantificar essa **variabilidade amostral** por meio da distribuição amostral de uma estatística. Esse estudo nos conduzirá à Lei dos Grandes Números, ao Teorema do Limite Central e, posteriormente, à construção de intervalos de confiança.