

Distribuições Amostrais e Resultados Assintóticos

Lei dos Grandes Números, Teorema do Limite Central e Regra Empírica

Nota de Aula 02

Prof. Eduardo Bezerra

Sumário

Na nota de aula anterior, distinguimos população, amostra, parâmetro, estatística, estimador e estimativa. Vimos também que uma estatística, antes da observação dos dados, é uma variável aleatória.

Nesta nota, estudaremos como essa estatística varia entre diferentes amostras. Para isso, introduziremos o conceito de **distribuição amostral** e analisaremos, em particular, o comportamento da média amostral $\bar{X}_n$.

Objetivos

Ao final da leitura, você deve ser capaz de:

Distribuições amostrais

- Distinguir *distribuição da amostra* (*sample distribution*) de *distribuição amostral* (*sampling distribution*).
- Descrever o experimento mental que gera a distribuição amostral de uma estatística e diferenciar suas versões teórica e empírica.
- Calcular a esperança, a variância e o erro padrão da distribuição amostral da média amostral.

Lei dos Grandes Números (LLN) ★

- Enunciar a LLN e interpretar seu significado em termos de convergência em probabilidade.
- Diferenciar o papel da LLN (convergência para o alvo) do papel do TLC (forma e escala das flutuações em torno do alvo).
- Esboçar a demonstração de uma versão da LLN a partir da desigualdade de Chebyshev.

Teorema do Limite Central (TLC) ★

- Enunciar o TLC (na forma padronizada) e diferenciar as propriedades *exatas* (média e variância de $\bar{X}_n$) da *aproximação de forma* que o teorema fornece.
- Reconhecer as condições sob as quais a aproximação normal é razoável e as situações em que ela pode falhar.

Regra 68-95-99,7

- Aplicar a regra empírica para interpretar a dispersão de dados aproximadamente normais, tanto para observações individuais quanto para médias amostrais.
- Calcular e interpretar escores-z.

Estas notas estão organizadas em quatro partes. A Seção 1 apresenta o conceito de distribuição amostral, distingue *sample distribution* de *sampling distribution* e estuda a distribuição amostral da média. A Seção 2 apresenta a Lei dos Grandes Números, que formaliza a concentração da média amostral em torno de μ . A Seção 3 apresenta o Teorema do Limite Central, descreve a forma e a escala das flutuações de $\bar{X}_n$ e mostra como interpretar a aproximação normal por meio da regra empírica e da padronização. Por fim, a Seção 4 sintetiza os principais resultados e estabelece a transição para a estimação intervalar.

1 Distribuições Amostrais

1.1 Conceito e construção da distribuição amostral

Usaremos letras maiúsculas para representar variáveis aleatórias e estatísticas antes da observação da amostra, como X_i e $\bar{X}_n$. Letras minúsculas representarão os valores efetivamente observados, como x_i e $\bar{x}_n$. Assim, $\bar{X}_n$ é um estimador, enquanto $\bar{x}_n$ é a estimativa numérica obtida em uma amostra particular.

Considere uma população com parâmetro de interesse θ e uma estatística T calculada sobre amostras de tamanho n . A *distribuição amostral* (*sampling distribution*) de T é a distribuição dos valores de T quando consideramos todas as possíveis amostras de tamanho n extraídas dessa população.

Para tornar isso concreto, imagine o seguinte experimento mental: extraia uma amostra de tamanho n , calcule T , registre o valor, e repita esse mecanismo de amostragem de forma independente, indefinidamente. O histograma dos valores registrados converge para a distribuição amostral de T . Cada valor individual de T varia de amostra para amostra porque cada amostra é diferente, e é exatamente essa variabilidade que a distribuição amostral descreve.

De forma mais geral (e válida também para populações contínuas, nas quais “todas as amostras possíveis” não é uma enumeração concreta) a distribuição amostral de T é a distribuição de probabilidade induzida em T pelo mecanismo de geração da amostra. A descrição por repetições, apresentada acima, funciona como uma boa intuição operacional para esse conceito mais geral.

Existem duas formas de obter (ou aproximar) essa distribuição:

- A *versão teórica* é derivada analiticamente a partir do mecanismo probabilístico que gera a amostra e da função que define a estatística. Em alguns casos, resulta em uma expressão fechada para a distribuição amostral, como veremos no caso da média amostral.
- A *versão empírica* aproxima a teórica por simulação: geram-se muitas amostras de tamanho n , calcula-se T em cada uma, e o histograma resultante serve como aproximação.

Pergunta 1

- (a) O texto descreve um experimento mental para construir a distribuição amostral de uma estatística T qualquer. Descreva como você aplicaria esse mesmo experimento para construir a distribuição amostral da mediana de tempos de atendimento em uma fila. O que mudaria em relação ao experimento descrito no texto?
- (b) O texto afirma que o histograma das repetições “converge” para a distribuição amostral de T . O que impede que esse histograma seja exato após um número finito de repetições? Em que sentido a versão empírica é sempre uma aproximação?
- (c) Por que o valor de T muda a cada repetição do experimento, se a população é sempre a mesma?
- (d) Qual a diferença entre a versão teórica e a versão empírica da distribuição amostral? Em qual situação a versão empírica seria preferível?

1.2 Distinção importante: *sample* vs. *sampling distribution*

Os termos em inglês são próximos e frequentemente confundidos, mas referem-se a objetos completamente diferentes. A ideia principal é a seguinte:

- a *sample distribution* (*distribuição da amostra*) descreve os valores observados em uma única amostra específica;
- já a *sampling distribution* (*distribuição amostral*) descreve os valores assumidos por uma estatística ao longo de muitas amostras diferentes.

Mais precisamente, a distribuição da amostra é a distribuição empírica induzida pelos n valores observados: histograma, frequências relativas, função de distribuição empírica etc. Ela atribui massa $1/n$ a cada ocorrência; consequentemente, cada valor distinto recebe massa igual à sua frequência relativa na amostra. Já a distribuição amostral é um objeto probabilístico: ela descreve como uma estatística varia quando o mecanismo de amostragem é repetido. Esses dois objetos não devem ser confundidos nem pensados como se um “gerasse” o outro a partir de uma única amostra observada: ambos estão ligados ao mesmo contexto de amostragem, mas respondem a perguntas diferentes. Em resumo, a cadeia correta é: **dados da amostra $\rightarrow$ distribuição empírica da amostra**; em paralelo, **mecanismo de amostragem + estatística escolhida $\rightarrow$ distribuição amostral da estatística**. Por exemplo, se medimos a altura de 40 alunos e calculamos a média $\bar{x}$, o histograma das 40 alturas observadas é a *distribuição da amostra*. Se repetirmos esse mesmo processo de amostragem, obtendo muitas novas amostras de 40 alunos da mesma população, e construirmos um histograma das médias obtidas, estaremos aproximando a *distribuição amostral* de $\bar{X}_n$.

A Figura ?? ilustra essa diferença: à esquerda, o histograma dos valores individuais de uma amostra (a *sample distribution*); à direita, o histograma das médias calculadas em muitas repetições do mesmo mecanismo de amostragem, na mesma população-alvo (a *sampling distribution*). Note como o segundo é mais concentrado e mais próximo de um formato de sino, um comportamento que será formalizado pelo TLC na Seção ??.

Ao ler a figura, o ponto central não é o desenho exato das barras, mas sim o contraste entre variabilidade dos dados individuais e variabilidade de uma estatística calculada repetidamente.




Figura 1: Contraste entre distribuição da amostra e distribuição amostral. À esquerda, aparecem os 50 tempos de atendimento observados em uma única amostra; à direita, aparecem as 100 médias obtidas em 100 repetições independentes do mesmo procedimento de amostragem.

Pergunta 2

Um pesquisador coletou o tempo de atendimento (em minutos) de 50 clientes em uma agência bancária e registrou os 50 valores. Em seguida, ele repetiu esse mesmo procedimento de coleta (50 clientes) mais 99 vezes, sempre na mesma população-alvo de clientes (por exemplo, sorteando 50 atendimentos diferentes ao longo do tempo, na mesma rede de agências e sob as mesmas condições de atendimento) obtendo ao todo 100 amostras independentes de tamanho 50.

- (a) O histograma dos 50 tempos da primeira coleta é um exemplo de *sample distribution* ou *sampling distribution*? Justifique.
- (b) O pesquisador calculou a média $\bar{x}$ de cada uma das 100 amostras e construiu um histograma dessas 100 médias. Esse histograma é um exemplo de qual dos dois conceitos? Justifique.
- (c) O histograma do item (b), construído a partir das 100 médias já observadas, é uma distribuição empírica (i.e., um objeto fixo, calculado a partir de números já conhecidos) que aproxima a distribuição amostral teórica de $\bar{X}_n$, um objeto probabilístico definido antes da observação de qualquer amostra. Explique essa diferença com suas próprias palavras, e o que ela implica sobre a natureza de $\bar{X}_n$ como variável aleatória.

1.3 Distribuição amostral da média

Quando a estatística de interesse é a média amostral, denotada como variável aleatória por

$$\bar{X}_n = \frac{1}{n}(X_1 + X_2 + \cdots + X_n),$$

com valor observado $\bar{x}_n = \frac{1}{n}(x_1 + x_2 + \cdots + x_n)$ calculado sobre uma amostra específica, a distribuição dos valores que $\bar{X}_n$ pode assumir ao longo de muitas amostras de tamanho n é chamada de *distribuição amostral da média amostral*.

Algumas propriedades dessa distribuição podem ser derivadas diretamente das propriedades da esperança e da variância, sem nenhuma hipótese sobre a forma da distribuição populacional; basta que as observações sejam i.i.d. com média μ e variância σ^2 finita:

$$E[\bar{X}_n] = \mu \quad \text{e} \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

A primeira igualdade diz que $\bar{X}_n$ é um estimador *não-viesado* de μ : em média, ao longo de muitas amostras, o estimador acerta o alvo. A segunda diz que a variabilidade de $\bar{X}_n$ em torno de μ *diminui com n*: quanto maior a amostra, mais concentrada é a distribuição amostral em torno do parâmetro verdadeiro.

A quantidade

$$\sigma_{\bar{X}_n} = \frac{\sigma}{\sqrt{n}}$$

é chamada de *erro padrão* (*standard error*) da média e mede a precisão típica do estimador: para reduzir o erro padrão à metade, é necessário quadruplicar o tamanho da amostra.

A distribuição amostral da média é central para a inferência estatística porque conecta três ideias fundamentais:

1. **Variabilidade amostral:** amostras diferentes produzem médias diferentes; a distribuição amostral quantifica esse fenômeno.
2. **Precisão de estimativas:** o erro padrão indica o quanto $\bar{X}_n$ pode se afastar de μ em uma amostra típica.
3. **Comportamento assintótico:** o Teorema do Limite Central (Seção ??) descreve a *forma* dessa distribuição conforme n cresce, completando o quadro.

As fórmulas

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \quad \text{e} \quad \sigma_{\bar{X}_n} = \frac{\sigma}{\sqrt{n}}$$

valem diretamente para observações i.i.d., como em amostragem com reposição ou em um modelo probabilístico de população conceitualmente infinita.

Como contraste importante, em uma AAS sem reposição de uma população finita de tamanho N , os sorteios deixam de ser independentes. Nesse caso, saímos do regime i.i.d. usado como referência ao longo desta nota, e a variância da média passa a incluir a *correção para população finita*. Se adotarmos σ^2 como a variância da população finita segundo a convenção usual do curso, obtemos:

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \frac{N - n}{N - 1}.$$

Quando a fração amostral n/N é pequena, o fator $(N - n)/(N - 1)$ fica próximo de 1, e a fórmula i.i.d. σ^2/n fornece uma boa aproximação. Nas seções seguintes, voltaremos ao caso i.i.d. para apresentar a LLN e o TLC em sua forma clássica.

Pergunta 3

Uma população tem média $\mu = 80$ e desvio-padrão $\sigma = 20$.

- (a) Calcule o erro padrão da média amostral para $n = 16$, $n = 100$ e $n = 400$.
- (b) Com base nos valores calculados, o que acontece com a concentração da distribuição amostral de $\bar{X}_n$ em torno de μ conforme n aumenta?
- (c) Um colega afirma: “Se coletarmos uma amostra grande o suficiente, $\bar{x}$ será exatamente igual a μ .” Essa afirmação está correta? Justifique com base nas propriedades apresentadas no texto.

Pergunta 4

- (a) O texto afirma que $\bar{X}_n$ é um estimador não-viesado de μ . O que essa afirmação significa em termos do experimento mental de extrair muitas amostras e calcular $\bar{x}$ em cada uma?
- (b) Não-viés é uma propriedade de uma única amostra ou do comportamento do estimador ao longo de muitas amostras? Justifique.
- (c) O texto lista três razões pelas quais a distribuição amostral da média é central para a inferência estatística. Reescreva cada uma delas com suas próprias palavras, sem usar os termos técnicos do texto.

1.4 Exemplo integrador: média amostral no dado justo

Se X é uniforme discreta entre $a = 1$ e $b = 6$, com $k = b - a + 1 = 6$ valores igualmente prováveis:

$$\mu = E[X] = \frac{a+b}{2} = 3,5,$$
$$\sigma^2 = \text{Var}[X] = \frac{k^2 - 1}{12} = \frac{36 - 1}{12} = \frac{35}{12} \approx 2,9167.$$

Esses valores são parâmetros populacionais. A partir deles, podemos determinar exatamente a média, a variância e o erro padrão da distribuição amostral de $\bar{X}_n$. Nas seções seguintes, usaremos esse exemplo para ilustrar a LLN e o TLC.

Pergunta 5

No experimento do dado justo, considere $X \in \{1, 2, 3, 4, 5, 6\}$.

- (a) Quais são os valores teóricos de μ e σ^2 ? Use as fórmulas apresentadas no texto.
- (b) Para $n = 36$, qual é o valor teórico de $\text{Var}(\bar{X}_n)$?
- (c) Uma simulação com muitas repetições produziu média das médias amostrais igual a 3,48. Sabendo que $E[\bar{X}_n] = 3,5$, esse resultado está próximo do esperado? Explique o que a esperança e a variância de $\bar{X}_n$ dizem sobre o centro e a concentração de sua distribuição.

2 Lei dos Grandes Números (LLN)

2.1 Enunciado e interpretação

A Lei dos Grandes Números (LLN, do inglês *Law of Large Numbers*) afirma que a média amostral converge para a média populacional à medida que o tamanho da amostra cresce. Usaremos a sigla LLN ao longo do texto. Nesta seção, consideramos $X_1, \dots, X_n$ i.i.d. com $\mu = E[X_i]$ finita.

É importante não confundir as hipóteses dos dois resultados. O TLC clássico (Seção ??) exige variância populacional finita. Já a LLN, em suas versões mais gerais, exige apenas que a média μ seja finita; *não* é necessário que a variância também o seja. Nesta seção, no entanto, apresentaremos uma demonstração que usa a desigualdade de Chebyshev e que, por isso, assume adicionalmente variância finita: trata-se de uma versão particular da LLN, mais simples de demonstrar, mas não a forma mais geral do resultado.

Essa escolha é também didática: a versão com variância finita conversa diretamente com as propriedades da média amostral estudadas na seção anterior e prepara o terreno para o TLC, que também será apresentado sob hipótese de variância finita.

Formalmente (LLN fraca, sob variância finita), para $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - \mu| < \varepsilon) = 1.$$

Essa expressão diz que a probabilidade de a média amostral ficar arbitrariamente próxima de μ tende a 1 quando n aumenta.

Uma formulação equivalente e comum da LLN é: a média amostral $\bar{X}_n$ de variáveis aleatórias i.i.d. converge em probabilidade para μ conforme n cresce.

2.2 Exemplo: o dado de 6 lados revisitado

Considere novamente o dado justo apresentado na Seção ??, com $E[X] = 3,5$. Pela LLN, à medida que aumentamos o número de lançamentos, a média amostral $\bar{X}_n$ tende a se aproximar de 3,5. A Figura ?? ilustra esse comportamento: à medida que n cresce (eixo em escala logarítmica), a média amostral oscila cada vez menos em torno de $\mu = 3,5$. O aspecto importante aqui é a redução gradual das oscilações, não o valor exato de cada ponto da trajetória simulada.




Figura 2: Trajetória ilustrativa da média amostral $\bar{X}_n$ em lançamentos sucessivos de um dado justo. Conforme o tamanho da amostra cresce, a média amostral oscila menos e se aproxima de $\mu = 3,5$.

2.3 Esboço de demonstração (Chebyshev)

A desigualdade de Chebyshev para uma variável aleatória com média μ e variância finita σ^2 é:

$$\Pr(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Aplicando esse resultado à média amostral, obtemos a derivação abaixo.

Passo 1: aplicar Chebyshev a $\bar{X}_n$.

$$\Pr(|\bar{X}_n - \mu_{\bar{X}_n}| \geq \varepsilon) \leq \frac{\sigma_{\bar{X}_n}^2}{\varepsilon^2}.$$

Passo 2: usar $\mu_{\bar{X}_n} = \mu$ e $\sigma_{\bar{X}_n}^2 = \sigma^2/n$ (pela independência das observações):

$$\Pr(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

Passo 3: tomar o complementar.

$$\Pr(|\bar{X}_n - \mu| < \varepsilon) \geq 1 - \frac{\sigma^2}{n\varepsilon^2}.$$

Passo 4: tomar o limite quando $n \rightarrow \infty$. O termo $\sigma^2/(n\varepsilon^2)$ tende a 0, logo o limite inferior tende a 1, concluindo:

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - \mu| < \varepsilon) = 1.$$

Este esboço prova a convergência em probabilidade no caso com variância finita, que é a forma mais usada na prática introdutória. Contudo, como observado anteriormente na discussão sobre as hipóteses da LLN e do TLC, essa não é a única versão possível da LLN.

Pergunta 6

Considere a expressão

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - \mu| < \varepsilon) = 1.$$

- (a) Explique, com suas palavras, o significado dessa expressão.
- (b) Por que essa afirmação não significa que, para um único n finito, $\bar{X}_n = \mu$ com probabilidade 1?

Pergunta 7

No esboço com Chebyshev, usa-se:

$$\Pr(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

- (a) Identifique as hipóteses principais necessárias para essa desigualdade ser aplicada no contexto da média amostral.
- (b) O que acontece com o limite superior quando n aumenta? Interprete esse resultado em termos da precisão de $\bar{X}_n$.

3 Teorema do Limite Central (TLC)

3.1 Retomada das propriedades exatas

Como vimos na Seção ??, para observações i.i.d. com média μ e variância finita σ^2 :

$$E[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Essas propriedades são exatas para qualquer tamanho amostral n . O TLC acrescentará uma informação diferente: a forma aproximada da distribuição de $\bar{X}_n$ quando n é grande.

Em outras palavras, a LLN e as fórmulas exatas de média e variância dizem para onde $\bar{X}_n$ vai e quão concentrada ela fica; o TLC acrescenta como a distribuição dessa flutuação se organiza em torno de μ quando n cresce.

3.2 Enunciado do TLC

Considere amostras aleatórias i.i.d. retiradas de uma população com média μ e variância finita σ^2 .

Teorema do Limite Central

Sob as hipóteses acima, a versão **padronizada** de $\bar{X}_n$ converge em distribuição para a normal padrão:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty).$$

Essa é a afirmação assintótica formal do TLC. Na prática, para n grande (porém finito), ela justifica a **aproximação**

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

que combina a forma normal fornecida pelo TLC com os valores exatos de média e variância vistos acima.

É importante não confundir as duas afirmações acima. A convergência formal ocorre para a variável *padronizada* $(\bar{X}_n - \mu)/(\sigma/\sqrt{n})$, cuja distribuição-limite (a normal padrão) *não depende* de n . Já $\bar{X}_n$ propriamente dita tem variância $\sigma^2/n \rightarrow 0$ conforme n cresce e, portanto, *não* converge em distribuição para uma normal não degenerada: ela se concentra cada vez mais em torno de um único ponto, μ (esse é, aliás, o conteúdo da LLN, Seção ??). A escrita $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$ deve ser lida como uma aproximação prática, útil para n fixo e grande, e não como um resultado de convergência.

Em outras palavras, o TLC afirma algo sobre a *forma* da distribuição de $\bar{X}_n$ (que ela se torna aproximadamente normal para n grande) enquanto as propriedades de média e variância apresentadas acima já valiam exatamente para qualquer n .

Uma forma curta de resumir a subseção é a seguinte: a normalidade aproximada vem do TLC; o centro μ e a variância σ^2/n vêm de resultados exatos já conhecidos.

A Figura ?? ilustra apenas o efeito da variância: as três curvas mostram a aproximação normal de $\bar{X}_n$ (já assumindo que o TLC se aplica) para tamanhos amostrais crescentes. A média μ permanece a mesma em todas elas; o que muda é exclusivamente a dispersão, que diminui com σ^2/n conforme n cresce. A figura não ilustra a aproximação progressiva da *forma* da distribuição de $\bar{X}_n$ à normalidade; essa aproximação de forma seria mais bem visualizada partindo de uma população não normal e comparando histogramas de $\bar{X}_n$ simulados para diferentes valores de n . Portanto, ela deve ser lida como uma figura sobre contração da distribuição, e não como evidência visual direta do TLC.

Pergunta 8

Sobre o enunciado do TLC e as propriedades da distribuição amostral de $\bar{X}_n$:

- Qual resultado descreve uma *aproximação de forma de distribuição* e quais descrevem *momentos exatos* (média e variância) de $\bar{X}_n$?
- Explique, em uma frase, por que não há contradição entre “aproximação normal” e “igualdades exatas para média e variância”.
- Em termos práticos, por que separar essas ideias ajuda a interpretar resultados de simulação?




Figura 3: Efeito do tamanho amostral sobre a dispersão de $\bar{X}_n$ sob a aproximação normal do TLC. As três curvas têm o mesmo centro μ ; apenas a variância σ^2/n diminui quando n cresce.

3.3 Quando a aproximação normal é razoável?

- A aproximação normal não exige que a população original seja normal, mas sua qualidade depende da forma dessa população e do tamanho amostral disponível; sob as hipóteses do TLC, ela tende a melhorar quando n cresce.
- Populações muito assimétricas ou com caudas pesadas demandam amostras maiores para boa aproximação.
- Em populações aproximadamente simétricas, a aproximação costuma funcionar com tamanhos menores.

Uma regra prática comum é dizer que, em muitos cenários, $n > 30$ já produz boa aproximação. Essa, porém, é uma heurística grosseira. Ela pode falhar em distribuições com forte assimetria ou caudas pesadas, sobretudo quando valores extremos permanecem relevantes mesmo em amostras de tamanho moderado.

3.4 Limite importante das hipóteses

O TLC clássico apresentado aqui depende de variância populacional finita ($\sigma^2 < \infty$). Quando a distribuição tem caudas muito pesadas, essa hipótese pode falhar, e a aproximação normal para $\bar{X}_n$ pode deixar de ser adequada mesmo com amostras grandes.

“Variância infinita” não significa valores infinitos observados na amostra; significa que eventos extremos têm peso suficiente para impedir a estabilização do segundo momento.

Pergunta 9

Com base na seção sobre o limite importante das hipóteses:

- (a) Qual hipótese do TLC clássico pode falhar em distribuições com caudas muito pesadas?
- (b) Se essa hipótese falhar, qual consequência o texto aponta para a aproximação normal de $\bar{X}_n$?
- (c) Explique, em uma frase, por que “variância infinita” não significa observar valores infinitos na amostra.

Pergunta 10

Considere duas populações: A (aproximadamente simétrica) e B (fortemente assimétrica).

- (a) Em qual delas você esperaria precisar de maior tamanho amostral para obter boa aproximação normal da distribuição de $\bar{X}_n$? Justifique com base no texto.
- (b) A regra prática “ $n > 30$ ” pode falhar em qual situação e por quê?
- (c) Reescreva, com suas palavras, a ideia central do texto para explicar por que distribuições fortemente assimétricas tendem a exigir amostras maiores para boa aproximação normal.

3.5 Erro padrão e efeito do tamanho amostral

Como já vimos na Seção ??, o erro padrão da média, $\sigma_{\bar{X}_n} = \sigma/\sqrt{n}$, decresce com $\sqrt{n}$: para reduzir a variabilidade de $\bar{X}_n$ à metade, é necessário quadruplicar o tamanho da amostra. O exercício abaixo retoma esse cálculo em um novo contexto numérico.

Pergunta 11

Uma população tem desvio-padrão $\sigma = 12$.

- (a) Calcule $\sigma_{\bar{X}_n}$ para $n = 9$, $n = 36$ e $n = 144$.
- (b) O que acontece com a variabilidade de $\bar{X}_n$ quando quadruplicamos n ?
- (c) Se o objetivo é reduzir o erro padrão pela metade, como o tamanho amostral deve ser alterado?

Além da concentração, vale retomar a ideia discutida anteriormente nesta seção: quando o TLC fornece uma boa aproximação, aumentar n tende não só a estreitar o histograma de $\bar{X}_n$, mas também a torná-lo mais próximo de uma curva em forma de sino.

Pergunta 12

Um grupo simulou a distribuição amostral de $\bar{X}_n$ para $n = 5$ e para $n = 100$.

- (a) Em qual caso você espera histograma mais “concentrado”? Justifique com a fórmula de $\sigma_{\bar{X}_n}$.
- (b) Em qual caso a forma do histograma deve parecer mais próxima de uma curva em forma de sino? Justifique com base no TLC.
- (c) Descreva o que você esperaria observar visualmente ao comparar os dois histogramas lado a lado: o que mudaria na largura, na simetria e no formato geral de cada um?

3.6 Relação entre LLN e TLC

- A LLN afirma que a média amostral se concentra em torno de μ : $\bar{X}_n \rightarrow \mu$ em probabilidade.
- O TLC descreve a *escala* e a *forma* das flutuações remanescentes em torno de μ : o erro típico é da ordem de $\sigma/\sqrt{n}$ e, após padronização, tem distribuição aproximadamente normal.
- À medida que n cresce, o centro da distribuição de $\bar{X}_n$ permanece em μ , pois $E[\bar{X}_n] = \mu$ para todo n . O que muda é sua dispersão: a LLN garante que $\bar{X}_n$ se concentra em torno de μ , enquanto o TLC descreve como as flutuações remanescentes, quando reescaladas por $\sqrt{n}/\sigma$, se aproximam de uma normal padrão. Em suma:

$$\bar{X}_n - \mu \approx \frac{\sigma}{\sqrt{n}} Z, \quad Z \sim \mathcal{N}(0, 1).$$

Uma dúvida comum quando se estudam o TLC e a LLN é a seguinte: *se o TLC também fala de $\bar{X}_n$, por que estudar a LLN separadamente?* A resposta curta é que LLN e TLC tratam de aspectos diferentes da média amostral.

- A LLN responde para onde $\bar{X}_n$ vai:

$$\bar{X}_n \xrightarrow{P} \mu.$$

Isto é, a média amostral se aproxima do parâmetro populacional.

- O TLC responde como $\bar{X}_n$ oscila em torno de μ para n grande:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Isto é, ele descreve a forma aproximada da distribuição do erro de estimação.

Sob hipóteses usuais (i.i.d. e variância finita), o TLC é mais forte e implica a mensagem central da LLN. Ainda assim, didaticamente é útil separar os dois resultados: a LLN fixa a ideia de convergência para o alvo; o TLC quantifica a flutuação ao redor do alvo.

Pergunta 13

Um colega afirma: “A LLN diz que, para n grande, a distribuição de $\bar{X}_n$ é normal.”

- (a) A afirmação está correta? Justifique.
- (b) Reescreva a frase separando claramente o papel da LLN e o papel do TLC.

Mesmo sem boa simetria populacional, a distinção entre os dois resultados continua a mesma: a LLN fala da aproximação de $\bar{X}_n$ a μ , enquanto a aproximação normal do TLC pode exigir tamanhos amostrais maiores para se tornar confiável.

Pergunta 14

Considere uma variável com média finita, porém com distribuição bastante assimétrica.

- (a) O que a LLN ainda garante sobre $\bar{X}_n$?
- (b) Que cuidado metodológico você teria ao usar aproximação normal para tamanhos amostrais moderados?

3.7 Interpretação prática da normal: regra 68-95-99,7

3.7.1 Ideia central

Para uma variável $X \sim \mathcal{N}(\mu, \sigma^2)$, uma grande fração dos valores fica concentrada em torno da média. As áreas são aproximadamente:

- 68,27% dos dados estão no intervalo $[\mu - \sigma, \mu + \sigma]$;
- 95,45% dos dados estão no intervalo $[\mu - 2\sigma, \mu + 2\sigma]$;
- 99,73% dos dados estão no intervalo $[\mu - 3\sigma, \mu + 3\sigma]$.

Na normal padrão, para a qual $\mu = 0$ e $\sigma = 1$, esses intervalos correspondem a $[-1, 1]$, $[-2, 2]$ e $[-3, 3]$.

Na prática, esses valores costumam ser arredondados para 68%-95%-99,7%, dando origem à chamada regra empírica. A Figura ?? resume visualmente essas três faixas e ajuda a conectar a linguagem de “estar a 1, 2 ou 3 desvios-padrão da média” com áreas sob a curva normal.

Pergunta 15

A regra 68-95-99,7 é apresentada com percentuais arredondados.

- (a) Quais são os valores aproximados mais precisos listados no texto para os intervalos de 1σ , 2σ e 3σ ?
- (b) Em uma frase, explique por que ainda usamos os valores arredondados na prática.




Figura 4: Áreas centrais da normal padrão correspondentes aos intervalos de 1, 2 e 3 desvios-padrão em torno da média.

3.7.2 Interpretação

Quanto mais distante da média, menor tende a ser a densidade da distribuição normal e menor é a probabilidade associada a pequenos intervalos naquela região. Por isso, valores muito afastados de μ são relativamente raros quando a distribuição é normal.

Em distribuições exatamente normais, os percentuais acima são aproximações numéricas muito precisas das áreas exatas. Em dados apenas aproximadamente normais, a regra funciona como guia rápido, não como garantia exata. Por exemplo, se uma variável aproximadamente normal tem média 100 e desvio-padrão 10, esperaríamos que a maior parte das observações ficasse entre 80 e 120, e apenas uma fração pequena ultrapassasse 130 ou caísse abaixo de 70. Em aplicações práticas, essa regra é útil para análise de dispersão, detecção inicial de outliers e interpretação rápida de variabilidade.

3.7.3 Dois usos da regra: observações individuais e médias amostrais

A regra 68-95-99,7 pode ser aplicada em dois contextos que é importante não confundir:

1. **Observações individuais:** quando a própria população é (aproximadamente) normal, $X \sim \mathcal{N}(\mu, \sigma^2)$, e a regra descreve a dispersão dos valores individuais de X em torno de μ :

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0,9545.$$

2. **Médias amostrais:** quando, pelo TLC, $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$ para n grande, e a regra descreve a dispersão de $\bar{X}_n$ em torno de μ , usando o erro padrão $\sigma/\sqrt{n}$ no lugar de σ :

$$P\left(\mu - 2\frac{\sigma}{\sqrt{n}} \leq \bar{X}_n \leq \mu + 2\frac{\sigma}{\sqrt{n}}\right) \approx 0,9545.$$

Essa distinção prepara diretamente a construção de intervalos de confiança para μ , assunto das próximas notas de aula: a mesma lógica (delimitar um intervalo em torno do centro usando múltiplos do erro padrão) será retomada e formalizada.

3.7.4 Ligação com padronização

Se $X \sim \mathcal{N}(\mu, \sigma^2)$, a variável padronizada

$$Z = \frac{X - \mu}{\sigma}$$

segue normal padrão $\mathcal{N}(0, 1)$. Assim, os percentuais acima são áreas sob a curva normal padrão entre -1 e 1 , -2 e 2 , e -3 e 3 .

Para uma observação específica x , o valor

$$z = \frac{x - \mu}{\sigma}$$

é chamado de **escore-z**: ele indica quantos desvios-padrão x está acima ($z > 0$) ou abaixo ($z < 0$) da média. Adotaremos a seguinte convenção para classificar observações:

- $|z| \leq 2$ indica observação usual;
- $2 < |z| \leq 3$, incomum;
- $|z| > 3$, rara.

É importante notar que essa classificação é *convencional*, não um corte probabilístico exato: para um valor não inteiro, como $z = 1,2$, a regra 68-95-99,7 (que se refere especificamente aos intervalos $[-1, 1]$, $[-2, 2]$ e $[-3, 3]$) não fornece diretamente a proporção de valores mais extremos que ele; isso exigiria a tabela da normal padrão.

Pergunta 16

Com base no texto, interprete os valores de escore-z abaixo:

- (a) $z = 1,2$
- (b) $z = 2,4$
- (c) $z = 3,1$

Para cada caso, classifique qualitativamente a observação como “usual”, “incomum” ou “rara”, usando a convenção apresentada, e discuta por que essa classificação não substitui um cálculo exato via tabela da normal.

4 Resumo

A tabela abaixo sintetiza os principais resultados estudados:

Resultado	Enunciado
Esperança de $\bar{X}_n$	$E[\bar{X}_n] = \mu$ (exato, para qualquer n)
Variância de $\bar{X}_n$ / erro padrão	$\text{Var}(\bar{X}_n) = \sigma^2/n$, $\sigma_{\bar{X}_n} = \sigma/\sqrt{n}$ (exato, para qualquer n , sob observações i.i.d.)
Teorema do Limite Central	$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$ (convergência formal); na prática, $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$ para n grande (aproximação de forma)
Lei dos Grandes Números (LLN)	$\bar{X}_n \xrightarrow{P} \mu$ conforme n cresce (concentração da média amostral em torno do alvo)
Regra 68-95-99,7	$\approx 68\%, 95\%, 99,7\%$ dos valores em $\mu \pm 1\sigma$, $\mu \pm 2\sigma$, $\mu \pm 3\sigma$ (sob normalidade); aplica-se a X individual com σ , ou a $\bar{X}_n$ com $\sigma/\sqrt{n}$

Toda a discussão deste texto parte da distinção entre população e amostra, e entre parâmetro e estatística, apresentada nas notas de aula anteriores. A distribuição amostral descreve como uma estatística varia de amostra para amostra. A LLN garante que a média amostral converge para o parâmetro populacional; o TLC descreve a forma dessa variação em torno do parâmetro, aproximando-a por uma normal; e a regra 68-95-99,7 traduz essa forma normal em faixas de valores fáceis de interpretar. Juntas, essas ideias fornecem a base necessária para construir intervalos de confiança, assunto tratado nas próximas notas de aula.

O TLC permite construir afirmações probabilísticas sobre a distância entre $\bar{X}_n$ e μ . A regra 68-95-99,7 fornece uma leitura rápida com ± 2 desvios-padrão; para obter a versão mais precisa associada a 95%, usamos o quantil 1,96 da normal padrão. Assim, sob a aproximação normal,

$$\Pr\left(-1,96 \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq 1,96\right) \approx 0,95.$$

Na próxima nota, reorganizaremos desigualdades desse tipo para construir intervalos de confiança para parâmetros populacionais desconhecidos.