

Estimação Intervalar

Nota de Aula 03

Prof. Eduardo Bezerra

Sumário

1	Introdução à Estimação Intervalar	2
2	Estimação Intervalar para Amostras Grandes	4
2.1	IC para a média populacional μ	5
2.1.1	Procedimento prático	6
2.2	IC para a proporção populacional p	6
2.3	Confiabilidade versus precisão	7
2.4	Determinação do tamanho da amostra	8
2.4.1	Caso 1: parâmetro de interesse é μ	8
2.4.2	Caso 2: parâmetro de interesse é p	8
2.5	Exercícios de fixação	10
2.5.1	Situações-problema com média populacional	10
2.5.2	Situações-problema com proporção populacional	11
2.5.3	Questões de comparação e interpretação	12
2.6	Apêndice: derivação dos intervalos de confiança	13
2.6.1	IC para a média em amostras grandes	13
2.6.2	IC para a proporção em amostras grandes	13
2.6.3	Derivação da fórmula de tamanho amostral	14
3	Estimação Intervalar para Amostras Pequenas	15
3.1	A distribuição t de Student	15
3.1.1	Uma ponte geométrica: média e resíduos	16
3.1.2	Da geometria à distribuição qui-quadrado	18
3.1.3	Da qui-quadrado à distribuição t	19
3.1.4	Principais características	21
3.1.5	Funções do <code>scipy.stats</code> relacionadas à distribuição t	22
3.1.6	Exemplos de cálculo com a distribuição t	22
3.2	Verificação da suposição de normalidade	23
3.3	Intervalo de confiança para μ com distribuição t	23
3.3.1	Procedimento de cálculo	24
3.3.2	Exemplos	24
3.4	Exercícios de fixação	26
3.4.1	Aquecimento: distribuição t e valores críticos	26
3.4.2	Construção de ICs: situações-problema	27
3.4.3	Verificação de suposições e diagnóstico	29
3.4.4	Comparação: distribuição z versus t	29
3.4.5	Questões conceituais e de interpretação	30
4	Resumo	31

Objetivos

Ao final da leitura, você deve ser capaz de:

Conceitos fundamentais

- Distinguir estimativa pontual de intervalo de confiança e explicar por que a estimação intervalar é mais informativa.
- Interpretar corretamente o nível de confiança de um intervalo.

Amostras grandes ★

- Construir intervalos de confiança para a média μ e a proporção p usando a aproximação normal.
- Verificar a condição de aplicabilidade da aproximação normal para proporções.
- Determinar o tamanho amostral mínimo para garantir margem de erro e nível de confiança definidos.

Amostras pequenas ★

- Descrever as principais características da distribuição t de Student e sua relação com a distribuição normal.
- Construir intervalos de confiança para a média usando a distribuição t quando n é pequeno e σ é desconhecido.
- Identificar quando o uso da distribuição t é adequado e verificar a suposição de normalidade da população.

Estas notas estão organizadas em três partes. A Seção 1 apresenta os fundamentos da estimação intervalar: intervalos de confiança, margem de erro e nível de confiança. A Seção 2 trata de intervalos de confiança para amostras grandes, usando a aproximação pelo Teorema Central do Limite, e inclui o planejamento do tamanho amostral. A Seção 3 aborda amostras pequenas, introduzindo a distribuição t de Student para o caso em que σ é desconhecido e n é reduzido. Os objetivos marcados com ★ são os mais centrais.

1 Introdução à Estimação Intervalar

Suponha que estejamos interessados em estudar um parâmetro populacional θ . Uma *estimativa pontual* é um único valor calculado a partir da amostra e usado como aproximação para θ . Contudo, estimativas obtidas de amostras diferentes variam, e o valor observado em uma amostra não revela, por si só, a magnitude de seu erro em relação ao parâmetro. A estimação intervalar acrescenta essa dimensão de incerteza ao construir um *intervalo de confiança*, isto é, uma faixa de valores plausíveis para o parâmetro baseada nos dados amostrais.

Uma abordagem mais apropriada é construir um *intervalo de confiança*: em vez de um único número, reporta-se uma faixa de valores plausíveis para o parâmetro. Por exemplo, uma informação muito mais útil do que a estimativa pontual de 161 cm seria poder afirmar que *a altura média das mulheres da comunidade acadêmica está entre 1,56 m e 1,67 m*,

com 95% de confiança. O intervalo comunica simultaneamente a estimativa e a incerteza associada a ela.

Um *intervalo de confiança*, ou *estimativa intervalar*, para um parâmetro populacional θ é um par de números $[L, U]$, ambos calculados a partir dos dados amostrais, tal que o procedimento de construção tem probabilidade $(1 - \alpha)$ de produzir intervalos que contenham o verdadeiro valor de θ .

Essa probabilidade de cobertura pode ser exata ou aproximada. Por exemplo, o intervalo baseado em t tem cobertura exata sob amostragem i.i.d. de uma população normal; os intervalos baseados no TLC e o intervalo normal de Wald têm cobertura aproximadamente igual ao nível nominal quando suas condições de aproximação são razoáveis.

Na prática, os intervalos de confiança estudados neste texto são *simétricos em torno da estimativa pontual*: somamos e subtraímos uma mesma quantidade E (a margem de erro) ao valor central. No caso em que o estimador é $\hat{p}$:

$$[\hat{p} - E, \hat{p} + E]$$

No caso em que o estimador é $\bar{x}$:

$$[\bar{x} - E, \bar{x} + E]$$

O valor E , que corresponde à metade do comprimento do intervalo, é denominado *margem de erro*. Ele não é o erro efetivo $|\hat{\theta} - \theta|$, que permanece desconhecido porque o próprio parâmetro é desconhecido. A margem de erro é uma quantidade calculada pelo procedimento para atingir a cobertura desejada, exatamente ou por aproximação conforme o método: um E muito pequeno geraria um intervalo estreito que raramente capturaria o parâmetro; um E grande capturaria o parâmetro com muita frequência, mas seria tão largo que pouco informaria.

Um intervalo de confiança está sempre associado a um *nível de confiança* (*confidence level*), que corresponde ao quão confiável é a informação de que o parâmetro populacional de interesse se encontra dentro do intervalo computado.

O nível de confiança é a probabilidade de que o procedimento de construção de intervalos produza um intervalo que contenha o verdadeiro valor do parâmetro populacional. Por exemplo, com nível de 95%, se fosse possível construir 100 intervalos de confiança para um determinado parâmetro θ a partir de 100 amostras diferentes, aproximadamente 95 desses intervalos conteriam o valor de θ .

Uma interpretação frequente, mas incorreta, é:


“Há 95% de probabilidade de que o parâmetro esteja dentro do intervalo calculado”.

Isso está errado porque o parâmetro populacional é *fixo* (não aleatório). O que é aleatório é o intervalo, pois depende da amostra.

Interpretação correta:

“Se repetirmos o procedimento muitas vezes, cerca de 95% dos intervalos construídos conterão o verdadeiro valor do parâmetro”.

A figura abaixo ilustra esse conceito. Cada linha horizontal representa um intervalo de confiança construído a partir de uma amostra diferente. A linha vertical tracejada indica o verdadeiro valor do parâmetro θ . Os intervalos em cinza capturam θ ; o intervalo em vermelho, não.



Uma realização ilustrativa com 13 intervalos construídos a partir de 13 amostras distintas.

Nela, 12 capturam θ (cinza) e 1 não captura (vermelho). A proporção observada, $12/13 \approx 92\%$, não é a cobertura do procedimento: em um número finito de repetições ela pode diferir do nível nominal de 95%.

Pergunta 1

O texto apresenta intervalos de confiança nas formas $[\hat{p} - E, \hat{p} + E]$ e $[\bar{x} - E, \bar{x} + E]$.

- (a) O que representa o termo E ?
- (b) Por que conhecer apenas a estimativa pontual pode ser insuficiente em inferência estatística?

Pergunta 2

Uma turma interpretou “nível de confiança de 95%” como: “há 95% de probabilidade de o parâmetro estar dentro do intervalo já calculado”. Usando a explicação do texto, reescreva essa interpretação de forma correta.

2 Estimação Intervalar para Amostras Grandes

Com amostras i.i.d. e variância populacional finita, podemos construir intervalos de confiança para a média sem conhecer a forma exata da distribuição da população, desde que n seja suficientemente grande. O ingrediente central é o *Teorema Central do Limite (TLC)*: formalmente, a média amostral *padronizada* converge em distribuição para a normal padrão. Na prática, para um n grande e fixo, isso justifica a aproximação


$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Portanto, não é a população original que se torna normal, nem $\bar{X}_n$ que converge para uma normal não degenerada quando $n \rightarrow \infty$: a distribuição de $\bar{X}_n$ fica simultaneamente mais concentrada em torno de μ e, para cada n grande, aproximadamente normal em sua forma. Essa aproximação permite usar probabilidades da normal padrão para determinar margens de erro; por isso, os procedimentos desta seção são chamados de *assintóticos*.

Para a média, a regra prática $n > 30$ costuma funcionar bem quando a distribuição subjacente é aproximadamente simétrica e sem caudas muito pesadas. O valor 30 não é especial matematicamente; é apenas uma regra prática. Em distribuições muito assimétricas ou de cauda pesada, como a log-normal ou a Pareto, a aproximação normal pode exigir n consideravelmente maior; não existe um limiar universal. Para a proporção, além de n grande, é importante verificar se há quantidade suficiente de sucessos e falhas na amostra (ver Seção 2.2).

2.1 IC para a média populacional μ

Sob observações i.i.d., variância populacional finita e tamanho amostral para o qual a aproximação normal seja razoável, a média amostral padronizada $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$ é aproximadamente normal padrão. Isso nos permite capturar uma fração $(1 - \alpha)$ da distribuição de $\bar{X}$ usando os pontos críticos $\pm z_{\alpha/2}$ da normal padrão, os valores que deixam exatamente $\alpha/2$ de área em cada cauda. A figura abaixo ilustra essa região central para um nível de confiança de 95% ($\alpha = 0,05$, $z_{\alpha/2} = 1,96$).



A área central (azul) corresponde a $(1 - \alpha)$ da distribuição; as caudas (vermelho) correspondem a $\alpha/2$ cada. Para 95% de confiança: $z_{\alpha/2} = 1,96$.

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

A estrutura da fórmula tem uma leitura intuitiva direta: partimos da estimativa pontual $\bar{x}$ e adicionamos/subtraímos uma margem de erro $E = z_{\alpha/2} \cdot \sigma/\sqrt{n}$. Essa margem cresce com $z_{\alpha/2}$ (maior confiança exige intervalo mais largo), cresce com σ (populações mais dispersas geram estimativas mais incertas) e diminui com $\sqrt{n}$ (amostras maiores reduzem o erro).

Se σ é desconhecido, o que é o caso mais comum na prática, e n é grande, uma aproximação usual substitui σ pelo desvio padrão amostral s :

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

Essa substituição é assintoticamente válida porque, para n grande, s converge para σ e a diferença tende a ter efeito desprezível sobre o intervalo. Quando n é pequeno,

a estatística apropriada usa a distribuição t de Student; mesmo em amostras grandes, t continua sendo a referência teórica quando σ é desconhecido, embora seus valores críticos sejam muito próximos dos de z .

2.1.1 Procedimento prático

1. *Calcular $\bar{x}$* : a média amostral é a estimativa pontual de μ e o centro do intervalo.
2. *Calcular o erro-padrão* ($\sigma/\sqrt{n}$ se σ é conhecido, ou $s/\sqrt{n}$ se σ é desconhecido): o erro-padrão mede a dispersão típica de $\bar{x}$ em torno de μ .
3. *Obter $z_{\alpha/2}$ na distribuição normal padrão*: para os níveis de confiança mais comuns, os valores são $z_{0,025} = 1,960$ (95%), $z_{0,05} = 1,645$ (90%) e $z_{0,005} = 2,576$ (99%).
4. *Calcular os limites*: $\bar{x} - z_{\alpha/2} \cdot \text{EP}$ (limite inferior) e $\bar{x} + z_{\alpha/2} \cdot \text{EP}$ (limite superior).

Pergunta 3

No caso de IC para μ com amostra grande:

- (a) Qual fórmula é usada quando σ é conhecido?
- (b) O que muda na fórmula quando σ é desconhecido?

2.2 IC para a proporção populacional p

A lógica é a mesma do IC para a média: sob observações i.i.d. Bernoulli, a proporção amostral $\hat{P}$ pode ser aproximada por uma normal quando a amostra contém sucessos e falhas em quantidade suficiente. O erro-padrão de $\hat{P}$ é $\sqrt{p(1-p)/n}$, que reflete o fato de que proporções extremas (próximas de 0 ou 1) são inerentemente menos variáveis do que proporções intermediárias, e que amostras maiores reduzem a incerteza. Como p é desconhecido, estimamos esse erro-padrão substituindo p por $\hat{p}$, obtendo o *intervalo normal de Wald*:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

A heurística mais comum requer pelo menos 10 sucessos e 10 falhas na amostra, ou seja, $n\hat{p} \geq 10$ e $n(1-\hat{p}) \geq 10$. Ela não garante cobertura nominal exata, mas costuma tornar a aproximação normal razoável. Alguns textos adotam o limiar mais conservador de 15 em cada categoria; outros aceitam 5. Para contagens pequenas ou proporções muito próximas de 0 ou 1, o intervalo de Wilson ou métodos exatos são preferíveis ao intervalo de Wald.

Pergunta 4

Para cada situação abaixo, verifique se a condição de aplicabilidade do IC para proporção é satisfeita. Justifique calculando o número de sucessos e falhas na amostra.

- (a) $n = 80, \hat{p} = 0,08$
- (b) $n = 200, \hat{p} = 0,15$
- (c) $n = 50, \hat{p} = 0,50$


2.3 Confiabilidade versus precisão

Para um tamanho amostral fixo, existe um *trade-off* inevitável entre confiabilidade e precisão. O mecanismo é direto: aumentar o nível de confiança significa exigir que o intervalo capture o parâmetro com maior frequência ao longo de repetidas amostragens. Para isso, precisamos usar um valor crítico $z_{\alpha/2}$ maior, o que por sua vez aumenta a margem de erro $E = z_{\alpha/2} \cdot \sigma/\sqrt{n}$ e alarga o intervalo. Ou seja: *pagar* por mais confiança significa *abrir mão* de precisão.

- Maior nível de confiança $\Rightarrow z_{\alpha/2}$ maior $\Rightarrow E$ maior $\Rightarrow$ intervalo mais largo.
- Menor nível de confiança $\Rightarrow z_{\alpha/2}$ menor $\Rightarrow E$ menor $\Rightarrow$ intervalo mais estreito.

A única forma de aumentar a confiabilidade *sem* perder precisão é aumentar o tamanho amostral n , pois n aparece no denominador do erro-padrão, e é o que a próxima seção explora.

A figura abaixo torna visual esse trade-off: os dois intervalos foram construídos a partir da mesma amostra ($\bar{x} = 50, \sigma/\sqrt{n} = 2$), diferindo apenas no nível de confiança.



Mesma amostra, dois níveis de confiança. O IC de 99% é mais largo (mais confiável, menos preciso); o IC de 90% é mais estreito (mais preciso, menos confiável).

Pergunta 5

Mantendo n fixo, o que acontece com a largura do intervalo quando:

- (a) aumentamos o nível de confiança?
- (b) reduzimos o nível de confiança?

Em síntese, toda a construção de intervalos de confiança se resume a *controlar a margem de erro E*: intervalos estreitos oferecem mais precisão e menos confiança; intervalos largos oferecem mais confiança e menos precisão.

2.4 Determinação do tamanho da amostra

O objetivo aqui é planejar o estudo antes da coleta, definindo um tamanho amostral mínimo que garanta um nível de confiança $(1 - \alpha)$ e uma margem de erro máxima E .

Determinar o tamanho da amostra significa responder à pergunta: *quantos dados preciso coletar para garantir um erro máximo aceitável?* Maior precisão, isto é, menor E , exige amostras maiores; maior confiança também exige amostras maiores.

2.4.1 Caso 1: parâmetro de interesse é μ

$$n = \left\lceil \frac{\sigma^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

Se σ for desconhecido, usa-se uma estimativa obtida em estudo piloto (s):

$$n = \left\lceil \frac{s^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

Essa é uma aproximação de planejamento: o valor de s do piloto é aleatório e, se o IC final usar t , o valor crítico também depende do tamanho amostral final. Na prática, a fórmula com z fornece um ponto de partida; quando o tamanho calculado é pequeno, é prudente revisar o planejamento com um valor crítico t apropriado ou adotar uma escolha conservadora.

2.4.2 Caso 2: parâmetro de interesse é p

Usando a aproximação normal para a proporção amostral:

$$n = \left\lceil \frac{z_{\alpha/2}^2 p(1-p)}{E^2} \right\rceil$$

Se houver amostra piloto, substitui-se p por $\hat{p}_{\text{pil}}$. Sem piloto, usa-se a aproximação conservadora $p(1-p) \leq 1/4$:

$$n = \left\lceil \frac{z_{\alpha/2}^2}{4E^2} \right\rceil$$

O produto $p(1-p)$ é máximo em $p = 0,5$, onde vale $1/4$. Ao usar $1/4$, garantimos que o tamanho amostral seja suficiente para qualquer valor de p . Quando o p real está próximo de 0 ou 1, essa escolha conservadora *superdimensiona* a amostra.

Pergunta 6

Calcule $p(1-p)$ para os valores $p = 0,50$, $p = 0,30$ e $p = 0,10$. Com base nos resultados:

- (a) Para qual valor de p o produto é maior?
- (b) O que isso implica sobre o tamanho amostral calculado com a fórmula conservadora quando o p real é próximo de 0 ou 1?

Exemplos de planejamento amostral. *Média com estudo piloto.*

Dados: $s^2 = 16$, $E = 0,5$, 95% de confiança ($z_{0,025} = 1,96$).

$$n = \left\lceil \frac{16 \cdot (1,96)^2}{(0,5)^2} \right\rceil = 245$$

Proporção com estimativa prévia.

Dados: $p \approx 0,60$, $E = 0,03$, 95% de confiança.

$$n = \left\lceil \frac{(1,96)^2(0,6)(0,4)}{(0,03)^2} \right\rceil \approx 1024$$

Proporção: abordagem conservadora versus estimativa prévia.

Foi reportado IC 95% para proporção de obesidade entre 22% e 24% (margem $E = 0,01$).

Abordagem conservadora (p desconhecido):

$$n = \left\lceil \frac{(1,96)^2}{4(0,01)^2} \right\rceil = 9604$$

Abordagem com $\hat{p} = 0,23$:

$$n = \left\lceil \frac{(1,96)^2(0,23)(0,77)}{(0,01)^2} \right\rceil = 6829$$

Usar a estimativa $\hat{p} = 0,23$ reduz o tamanho amostral necessário de 9.604 para 6.829, uma economia de cerca de 29%.

Média com σ conhecido.

Deseja-se erro máximo de R\$ 500, com 95% de confiança e $\sigma = 6250$:

$$n = \left\lceil \frac{(6250)^2(1,96)^2}{(500)^2} \right\rceil = 601$$

Se a margem de erro for relaxada para R\$ 1000:

$$n = \left\lceil \frac{(6250)^2(1,96)^2}{(1000)^2} \right\rceil = 151$$

Dobrar E reduz o tamanho amostral por um fator de aproximadamente 4 (de 601 para 151).

Pergunta 7

No caso de tamanho amostral para estimar μ , use a expressão

$$n = \left\lceil \frac{\sigma^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

para justificar, em uma frase, por que dobrar a margem de erro E reduz aproximadamente o tamanho amostral por um fator 4.

2.5 Exercícios de fixação

2.5.1 Situações-problema com média populacional

Exercício 1: Tempo de atendimento em uma clínica. Uma clínica deseja estimar o tempo médio de atendimento de seus pacientes. Uma amostra aleatória de $n = 64$ atendimentos produziu média amostral $\bar{x} = 38$ minutos. Suponha que o desvio-padrão populacional seja conhecido e igual a $\sigma = 12$ minutos.

- (a) Construa um IC de 95% para o tempo médio de atendimento.
- (b) Interprete o intervalo no contexto do problema.
- (c) Qual seria o efeito de aumentar o nível de confiança para 99%?

Solução do Exercício 1. Para 95% de confiança, $\alpha = 0,05$ e precisamos de $z_{0,025}$. Em Python:

```
from scipy.stats import norm
norm.ppf(0.975) # -> 1.96
```

A sigla *ppf* significa *percent point function* e corresponde à inversa da CDF. Usamos 0.975 porque a área central desejada é 0,95; cada cauda recebe 0,025; logo o ponto crítico à direita tem 0,975 de área acumulada à esquerda.

O erro-padrão é:

$$\frac{\sigma}{\sqrt{n}} = \frac{12}{\sqrt{64}} = \frac{12}{8} = 1,5$$

A margem de erro é:

$$E = 1,96 \cdot 1,5 = 2,94$$

O intervalo de confiança é $38 \pm 2,94$, ou seja, (35,06; 40,94).

Interpretação: com 95% de confiança, o procedimento produz um intervalo que sugere que o tempo médio de atendimento está entre aproximadamente 35,1 e 40,9 minutos.

Se o nível de confiança aumentar para 99%, o valor crítico aumenta, a margem de erro fica maior e o intervalo se torna mais largo.

Exercício 2: Peso médio de embalagens. Uma indústria quer verificar o peso médio de um produto embalado automaticamente. Foi coletada uma amostra com $n = 100$ embalagens, obtendo-se $\bar{x} = 502$ g e desvio-padrão amostral $s = 8$ g.

- (a) Construa um IC de 95% para o peso médio populacional.
- (b) Explique por que, nesse caso, é aceitável usar s no lugar de σ .
- (c) O intervalo é compatível com a meta nominal de 500 g?

Exercício 3: Salário médio de estagiários. Uma universidade deseja estimar a bolsa média mensal recebida por seus estagiários. Uma amostra de $n = 49$ alunos apresentou média $\bar{x} = \text{R\$ } 1.420$ e desvio-padrão populacional conhecido $\sigma = 210$.

- (a) Construa um IC de 90% para a bolsa média.
- (b) Compare conceitualmente esse intervalo com o que seria obtido para 95% de confiança.
- (c) Qual dos dois é mais estreito e por quê?

2.5.2 Situações-problema com proporção populacional

Exercício 4: Aprovação de uma política institucional. Uma instituição entrevistou $n = 200$ alunos sobre uma nova política acadêmica. Desses, 136 declararam ser favoráveis à proposta.

- (a) Calcule $\hat{p}$.
- (b) Verifique se a condição de aplicabilidade da aproximação normal é satisfeita.
- (c) Construa um IC de 95% para a proporção populacional de alunos favoráveis.
- (d) Interprete o resultado em linguagem não técnica.

Solução do Exercício 4. A proporção amostral é $\hat{p} = 136/200 = 0,68$.

Verificação da condição:

$$n\hat{p} = 200 \cdot 0,68 = 136 \geq 10 \quad n(1 - \hat{p}) = 200 \cdot 0,32 = 64 \geq 10$$

A aproximação normal é adequada.

Para $z_{0,025} \approx 1,96$, o erro-padrão é:

$$\sqrt{\frac{(0,68)(0,32)}{200}} = \sqrt{0,001088} \approx 0,033$$

A margem de erro é $E = 1,96 \cdot 0,033 \approx 0,065$. O intervalo de confiança é $(0,615; 0,745)$, ou seja, aproximadamente $(61,5\%; 74,5\%)$.

Interpretação: com 95% de confiança, o procedimento indica que a proporção de alunos favoráveis à proposta está entre cerca de 61,5% e 74,5%.

Exercício 5: Uso de bicicleta para ir ao campus. Em uma pesquisa com $n = 120$ estudantes, 18 afirmaram ir ao campus de bicicleta com frequência.

- (a) Calcule a proporção amostral.
- (b) Verifique se a condição de pelo menos 10 sucessos e 10 falhas é satisfeita.
- (c) Construa um IC de 90% para a proporção populacional.
- (d) Seria adequado usar o mesmo procedimento com $n = 30$ mantendo a mesma proporção amostral?

Exercício 6: Intenção de voto. Uma chapa deseja estimar sua proporção de apoio entre os alunos. Em uma amostra de $n = 500$ estudantes, 260 declararam intenção de voto nessa chapa.

- (a) Construa um IC de 95% para a proporção populacional de apoio.
- (b) Calcule a margem de erro desse intervalo.
- (c) Como a margem de erro mudaria se a amostra tivesse tamanho $n = 1000$, mantendo a mesma proporção amostral?

2.5.3 Questões de comparação e interpretação

Exercício 7: Comparando dois intervalos para a média. Duas equipes calcularam ICs para a mesma variável:

- Equipe A: $\bar{x} \pm 1,96 \cdot \frac{10}{\sqrt{100}}$
- Equipe B: $\bar{x} \pm 2,58 \cdot \frac{10}{\sqrt{100}}$

- (a) Qual equipe usou maior nível de confiança?
- (b) Qual intervalo é mais largo?
- (c) Por que isso acontece?

Solução do Exercício 7. A Equipe B usou maior nível de confiança, porque utilizou um valor crítico maior: 1,96 é típico de 95% de confiança, e 2,58 é típico de 99% de confiança.

Como o erro-padrão é o mesmo nos dois casos ($10/\sqrt{100} = 1$), as margens de erro são 1,96 (Equipe A) e 2,58 (Equipe B). Portanto, o intervalo da Equipe B é mais largo. *Quanto maior o nível de confiança, maior é o valor crítico, maior é a margem de erro e mais largo fica o intervalo.*

Exercício 8: Planejamento de pesquisa. Uma equipe quer estimar a proporção de alunos que pretendem fazer intercâmbio, com margem de erro máxima de 4 pontos percentuais e 95% de confiança.

- (a) Calcule o tamanho amostral conservador.
- (b) Explique por que a escolha conservadora usa $p(1 - p) = 1/4$.
- (c) O que aconteceria com o tamanho amostral se houvesse estudo piloto indicando $p \approx 0,20$?

2.6 Apêndice: derivação dos intervalos de confiança

2.6.1 IC para a média em amostras grandes

Passo 1: Distribuição da média amostral. Se $X_1, \dots, X_n$ são i.i.d. com média μ e variância σ^2 , então, para n grande, o TLC implica:

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Passo 2: Padronização.

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1)$$

Passo 3: Região central da normal padrão.

Para nível de confiança $(1 - \alpha)$, escolhemos $z_{\alpha/2}$ tal que $\Pr(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$.

Passo 4: Isolamento de μ .

$$\Pr\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Portanto, o intervalo de confiança de nível $(1 - \alpha)$ para μ é:

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Quando σ é desconhecido, em amostras grandes substituímos σ por s .

2.6.2 IC para a proporção em amostras grandes

Passo 1: Distribuição da proporção amostral. Para n grande: $\hat{P} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$.

Passo 2: Padronização.

$$Z = \frac{\hat{P} - p}{\sqrt{p(1-p)/n}} \approx \mathcal{N}(0, 1)$$

Passos 3 e 4: Região central e isolamento de p . Para nível $(1 - \alpha)$, escolhemos $z_{\alpha/2}$ tal que:

$$\Pr\left(-z_{\alpha/2} \leq \frac{\hat{P} - p}{\sqrt{p(1-p)/n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

Multiplicando os três membros por $\sqrt{p(1-p)/n}$ e reorganizando para isolar p , obteríamos uma expressão alternativa (como o intervalo de Wilson), mais precisa do que a aproximação normal, porém mais complexa:

$$p \approx \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

O problema é que o erro-padrão depende do próprio p , que é desconhecido. Isolar p algebricamente seria possível (e resulta no chamado *intervalo de Wilson*), mas conduz a uma expressão mais complexa.

Passo 5: Substituição prática. Para amostras grandes, $\hat{p}$ é próximo de p ; logo, substituímos p por $\hat{p}$ dentro do erro-padrão:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

2.6.3 Derivação da fórmula de tamanho amostral

A ideia é simples: partimos da fórmula da margem de erro e a invertemos para encontrar o n necessário.

Passo 1: Margem de erro do IC. Para amostras grandes, a margem de erro do IC para μ é:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Essa expressão relaciona quatro quantidades: E , $z_{\alpha/2}$, σ e n . Se fixarmos os três primeiros, podemos determinar o quarto.

Passo 2: Impor o erro máximo desejado. No planejamento, escolhemos previamente o maior erro que toleramos e o nível de confiança. Queremos, portanto, encontrar o menor n tal que:

$$z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \leq E$$

Tomamos a igualdade para obter o n mínimo exato.

Passo 3: Isolar n . Da igualdade $z_{\alpha/2} \cdot \sigma / \sqrt{n} = E$, multiplicamos ambos os lados por $\sqrt{n}$ e dividimos por E :

$$\sqrt{n} = \frac{z_{\alpha/2} \sigma}{E}$$

Elevando ao quadrado:

$$n = \frac{\sigma^2 z_{\alpha/2}^2}{E^2}$$

Passo 4: Substituir σ por s e arredondar. Quando σ é desconhecido, usamos s de um estudo piloto. Como n deve ser inteiro e precisamos garantir que a margem não seja ultrapassada, arredondamos *para cima*:

$$n = \left\lceil \frac{s^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

Essa expressão revela três relações fundamentais de planejamento: (i) exigir maior confiança aumenta $z_{\alpha/2}$ e, portanto, n ; (ii) maior variabilidade na população (maior s) exige amostras maiores; (iii) reduzir a margem de erro E pela metade *quadruplica* o tamanho amostral necessário, pois E aparece ao quadrado no denominador, um custo que cresce rapidamente.

Qual intervalo de confiança usar? Ao resolver um problema, siga este roteiro:

1. Qual é o parâmetro de interesse?
 - Média (μ) ou proporção (p)?
2. O desvio padrão populacional σ é conhecido?
3. A população é aproximadamente normal, ou a amostra é grande o suficiente para uma aproximação assintótica razoável?
 - A normalidade é especialmente importante para amostras pequenas.
 - A regra $n > 30$ é apenas uma heurística; assimetria intensa e caudas pesadas podem exigir amostras maiores.

Regra geral:

- Se σ é conhecido, use o valor crítico z ; para amostras pequenas, a normalidade populacional ainda é necessária para a validade exata.
- Se σ é desconhecido, use o valor crítico t com $n - 1$ graus de liberdade. Para amostras grandes, t e z são numericamente próximos, e o uso de z com s é uma aproximação comum.

3 Estimação Intervalar para Amostras Pequenas

Quando o tamanho da amostra é pequeno, a construção de intervalos de confiança exige mais cuidado porque a aproximação assintótica pode ser fraca. Para a média μ , quando a população é aproximadamente normal e σ é desconhecido, a *distribuição t de Student* é a ferramenta clássica.

O limiar $n = 30$ é uma heurística para julgar a qualidade de aproximações normais, não uma fronteira entre z e t . Na prática, *sempre que σ for desconhecido*, independentemente de n , o uso da distribuição t é teoricamente mais adequado.

3.1 A distribuição t de Student

A distribuição t de Student foi proposta em um artigo publicado em 1908 por William Gosset. Por questões de confidencialidade com sua empresa, Gosset usou o pseudônimo *Student* nessa publicação. Seu trabalho surgiu da necessidade de realizar inferências estatísticas confiáveis a partir de *amostras pequenas*.

Para entender por que uma nova distribuição é necessária, considere uma amostra aleatória i.i.d.

$$X_1, X_2, \dots, X_n$$

retirada de uma população normal com média μ e desvio padrão σ . Se σ fosse conhecido, poderíamos padronizar a média amostral usando

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

que segue uma distribuição normal padrão.

Na prática, porém, σ geralmente é desconhecido. A solução natural é estimá-lo pelo desvio padrão amostral S , obtendo

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Essa substituição parece pequena, mas tem uma consequência importante: enquanto σ é um parâmetro fixo, S depende da amostra e, portanto, também é uma variável aleatória. A distribuição t de Student surge justamente para descrever essa nova estatística.

Antes de observar os dados, tanto a média quanto a variância amostral são variáveis aleatórias:

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Para compreender a distribuição de S e sua relação com $\bar{X}$, é útil examinar geometricamente como uma amostra pode ser decomposta em uma parte associada à média e outra associada aos desvios em torno dessa média.

3.1.1 Uma ponte geométrica: média e resíduos

Considere inicialmente uma amostra de tamanho 3. Podemos representar

$$\mathbf{X} = (X_1, X_2, X_3)$$

como um ponto aleatório em um espaço tridimensional: cada nova amostra produz, em geral, uma posição diferente nesse espaço.

A reta diagonal

$$\mathcal{D} = \{(a, a, a) : a \in \mathbb{R}\}$$

reúne todos os vetores cujas três coordenadas são iguais. A projeção ortogonal de $\mathbf{X}$ sobre essa reta é o ponto da diagonal mais próximo de $\mathbf{X}$. Esse ponto é

$$P = (\bar{X}, \bar{X}, \bar{X}).$$

Assim, a posição de P ao longo da diagonal contém exatamente a informação sobre a média amostral.

A diferença entre o ponto observado $\mathbf{X}$ e sua projeção P é o *vetor de resíduos*:

$$\mathbf{R} = \mathbf{X} - P = (X_1 - \bar{X}, X_2 - \bar{X}, X_3 - \bar{X}).$$

Temos, portanto, a decomposição

$$\mathbf{X} = (\bar{X}, \bar{X}, \bar{X}) + \mathbf{R}.$$

Equivalentemente, escrevendo $\mathbf{1} = (1, 1, 1)$,

$$\mathbf{X} = \bar{X} \mathbf{1} + \mathbf{R}.$$

A primeira parcela descreve a componente da amostra associada à média; a segunda descreve como as observações se desviam dessa média.

A Figura 1 ilustra essa decomposição.

Todo ponto do plano verde tem a mesma média $\bar{X}$. Portanto, mover-se dentro desse plano modifica apenas os desvios das observações em relação à média.

Isso ocorre porque as coordenadas do vetor de resíduos satisfazem necessariamente

$$(X_1 - \bar{X}) + (X_2 - \bar{X}) + (X_3 - \bar{X}) = 0.$$

Consequentemente, os três resíduos não podem variar livremente. Se conhecermos dois deles, o terceiro fica automaticamente determinado. Há, portanto, apenas dois modos independentes de variar em torno da média. Dizemos que os resíduos possuem $2 = 3 - 1$ *graus de liberdade*.

Geometricamente, o plano de média constante que passa por P pode ser escrito como

$$H_{\bar{X}} = \{(x_1, x_2, x_3) : x_1 + x_2 + x_3 = 3\bar{X}\}.$$

Ele é ortogonal à diagonal $\mathcal{D}$, cuja direção é $(1, 1, 1)$.




Figura 1: Representação para $n = 3$. A reta azul contém as amostras com observações todas iguais. O ponto azul é a projeção $(\bar{X}, \bar{X}, \bar{X})$ da amostra sobre essa reta; o plano verde contém os vetores com a mesma média, e o segmento vermelho é o vetor de resíduos.

Os próprios vetores de resíduos pertencem ao plano que passa pela origem

$$H_0 = \{(r_1, r_2, r_3) : r_1 + r_2 + r_3 = 0\}.$$

O plano $H_{\bar{X}}$ é simplesmente uma versão deslocada desse espaço residual:

$$H_{\bar{X}} = P + H_0.$$

Assim, H_0 possui dimensão 2. Essa é a interpretação geométrica da existência de dois graus de liberdade no caso $n = 3$.

Além disso, o comprimento do vetor de resíduos mede quão distante a amostra está da situação em que todas as observações seriam iguais à média. Sua distância quadrática é

$$\|\mathbf{R}\|^2 = \sum_{i=1}^3 (X_i - \bar{X})^2 = (3 - 1)S^2.$$

No caso geral, para uma amostra de tamanho n ,

$$\mathbf{X} = \bar{X} \mathbf{1} + \mathbf{R},$$

em que

$$\mathbf{R} = (X_1 - \bar{X}, \dots, X_n - \bar{X})$$

satisfaz

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Há n resíduos, mas uma restrição entre eles. Portanto, apenas $n - 1$ podem variar independentemente. Esse é o significado dos $n - 1$ graus de liberdade associados à variância amostral.

O vetor $\mathbf{X}$ é aleatório, assim como $\bar{X}$, sua projeção P , o vetor $\mathbf{R}$ e o plano $H_{\bar{X}}$. Já a direção da média e o espaço residual H_0 são estruturas fixas. De uma amostra para outra, o plano de média constante se desloca paralelamente a si mesmo ao longo da direção da média. A figura representa apenas uma realização possível dessas quantidades aleatórias.

3.1.2 Da geometria à distribuição qui-quadrado

A geometria anterior separou a informação contida na amostra em duas partes:

- uma componente associada à média amostral;
- uma componente residual, associada à dispersão em torno da média.

Sob a hipótese de que a população é normal, essa decomposição possui propriedades probabilísticas particularmente convenientes.

Como $X_1, \dots, X_n$ são independentes e normalmente distribuídas com média μ e variância σ^2 , as variáveis

$$\frac{X_1 - \mu}{\sigma}, \dots, \frac{X_n - \mu}{\sigma}$$

são normais padrão independentes.

Geometricamente, o vetor formado por essas variáveis tem uma distribuição que não privilegia nenhuma direção do espaço: sua distribuição é *esfericamente simétrica*.

Podemos decompor esse vetor padronizado em uma coordenada na direção da média e $n - 1$ coordenadas ortogonais dentro do espaço residual.

A coordenada correspondente à direção da média é

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

e

$$Z \sim \mathcal{N}(0, 1).$$

Dentro do espaço residual, podemos escolher $n - 1$ eixos ortogonais. Denotemos por

$$Y_1, \dots, Y_{n-1}$$

as coordenadas padronizadas do vetor residual nesses novos eixos. Sob normalidade, essas coordenadas são normais padrão independentes.

Por definição, a soma dos quadrados de ν variáveis normais padrão independentes segue uma distribuição qui-quadrado com ν graus de liberdade. Portanto,

$$U = Y_1^2 + \dots + Y_{n-1}^2 \sim \chi_{n-1}^2.$$

A soma desses quadrados é justamente o comprimento quadrático padronizado do vetor residual. Assim,

$$U = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2},$$

e, consequentemente,

$$\boxed{\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2}.$$

A variável U não representa uma nova medida de dispersão. Ela é simplesmente uma versão adimensional da variância amostral:

$$\frac{U}{n-1} = \frac{S^2}{\sigma^2}.$$

Essa razão compara a variabilidade observada na amostra com a variabilidade populacional.

Há ainda uma propriedade fundamental da população normal. A componente de $\mathbf{X}$ na direção da média,

$$\overline{\mathbf{X}}\mathbf{1} = (\overline{X}, \dots, \overline{X}),$$

e o vetor residual $\mathbf{R}$ são independentes.

Como Z depende apenas da componente associada à média e U depende apenas do vetor residual, segue que

$$Z \text{ e } U$$

são independentes.

É importante distinguir duas ideias: a decomposição geométrica garante que as duas componentes são *ortogonais*; a conclusão de que elas são também *independentes* depende adicionalmente da hipótese de normalidade.

3.1.3 Da qui-quadrado à distribuição t

Agora podemos retornar ao problema que motivou esta seção: queremos padronizar $\overline{X}$, mas não conhecemos σ .

Temos

$$Z = \frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \sim \mathcal{N}(0, 1)$$

e

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

com Z e U independentes.

Considere então a razão

$$T = \frac{Z}{\sqrt{U/(n-1)}}.$$

Substituindo as expressões de Z e U :

$$T = \frac{\frac{\sqrt{n}(\overline{X} - \mu)}{\sigma}}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}}.$$

Como

$$\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}} = \frac{S}{\sigma},$$

obtemos

$$T = \frac{\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}}{S/\sigma} = \frac{\sqrt{n}(\bar{X} - \mu)}{S} = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

O ponto crucial é que o parâmetro desconhecido σ *desaparece da expressão*. Por definição, se

$$Z \sim \mathcal{N}(0, 1), \quad U \sim \chi^2_\nu,$$

e Z e U são independentes, então

$$\frac{Z}{\sqrt{U/\nu}}$$

segue uma distribuição t de Student com ν graus de liberdade. Como, neste caso, $\nu = n - 1$, concluímos que

$$\boxed{T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}}.$$

Portanto, a distribuição t não é uma correção arbitrária criada apenas porque a amostra é pequena. Ela surge exatamente quando substituímos o desvio padrão populacional desconhecido σ pelo desvio padrão amostral aleatório S na padronização da média.

Essa substituição também explica por que a distribuição t possui caudas mais pesadas do que a normal padrão. Se σ fosse conhecido, o denominador

$$\frac{\sigma}{\sqrt{n}}$$

seria fixo. Quando usamos

$$\frac{S}{\sqrt{n}},$$

o denominador varia de uma amostra para outra.

Em algumas amostras, S será menor que σ . Nesses casos, o denominador torna-se relativamente pequeno e T pode assumir valores grandes em módulo. Valores extremos de T ocorrem, portanto, com maior frequência do que valores extremos de uma normal padrão. É isso que produz as caudas mais pesadas da distribuição t .

Quando n é pequeno, S pode apresentar variabilidade considerável, e essa diferença é importante. À medida que n aumenta,

$$\frac{S^2}{\sigma^2}$$

tende a se concentrar próximo de 1. O denominador de T torna-se então cada vez menos variável, e a distribuição t se aproxima da normal padrão.

Depois que a amostra é observada, as realizações das variáveis aleatórias $\bar{X}$ e S são denotadas por $\bar{x}$ e s . São esses valores observados que utilizamos nos cálculos numéricos.

Compare, portanto, as duas estatísticas:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}, \quad T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

As fórmulas são muito semelhantes, mas existe uma diferença fundamental: em Z , o denominador envolve o parâmetro fixo σ ; em T , ele envolve a variável aleatória S . Essa incerteza adicional é incorporada pela distribuição t .


3.1.4 Principais características

- A forma da distribuição t depende do parâmetro $\nu = n - 1$, denominado *número de graus de liberdade*. Os n resíduos satisfazem a restrição $\sum_{i=1}^n (X_i - \bar{X}) = 0$, de modo que apenas $n - 1$ deles podem variar independentemente.
- A distribuição t é simétrica em torno de 0, assim como a distribuição normal padrão.
- Para poucos graus de liberdade, a distribuição t apresenta caudas mais pesadas do que a normal padrão. Isso reflete a incerteza adicional introduzida pela estimação de σ por meio de S .
- À medida que os graus de liberdade aumentam, S torna-se uma estimativa cada vez mais estável de σ e a diferença entre as distribuições t e normal padrão diminui rapidamente.
- Com algumas dezenas de graus de liberdade, os valores críticos da distribuição t já são bastante próximos dos correspondentes valores críticos da normal padrão para os níveis de confiança usuais.
- No limite,

$$t_\nu \longrightarrow \mathcal{N}(0, 1) \quad \text{quando} \quad \nu \rightarrow \infty.$$

- Em aplicações, quando σ é desconhecido, é preferível utilizar a distribuição t independentemente do tamanho da amostra. Para amostras grandes, a diferença numérica em relação ao uso da normal padrão costuma ser pequena.

A figura abaixo mostra as curvas da distribuição t para diferentes valores de ν , sobrepostas à curva da normal padrão. Note como as caudas da distribuição t são progressivamente mais pesadas para valores menores de ν , convergindo para a normal conforme ν cresce.



Distribuições t para $\nu = 2, 5$ e 15 comparadas à normal padrão (tracejado azul). Quanto menor ν , mais pesadas são as caudas. Para $\nu \geq 30$, as curvas tornam-se praticamente indistinguíveis.

Pergunta 8

Compare as estatísticas Z e T :

- (a) Qual é a diferença entre suas fórmulas?
- (b) Por que essa diferença faz com que T siga uma distribuição com caudas mais pesadas do que a normal padrão?
- (c) Na interpretação geométrica, por que há $n - 1$ graus de liberdade para os resíduos e por que a quantidade $U = (n - 1)S^2/\sigma^2$ segue uma qui-quadrado sob normalidade?

3.1.5 Funções do `scipy.stats` relacionadas à distribuição t

Felizmente, não precisamos calcular diretamente com a expressão matemática da função de densidade da distribuição t . A biblioteca `scipy.stats` oferece funções que encapsulam esses cálculos. Os exemplos abaixo pressupõem:

```
from scipy.stats import t
```

Função `t.ppf(q, df)`. Retorna a inversa da CDF (*percent point function*): dado um valor de probabilidade acumulada q , retorna o ponto x tal que $\Pr(T \leq x) = q$. É a função central para obter valores críticos. Por exemplo, `t.ppf(0.975, df=9)` retorna $\approx 2,262$, que é o valor crítico bicaudal de 95% com 9 graus de liberdade, ou seja, 97,5% da área está à esquerda de 2,262.

Função `t.cdf(x, df)`. Retorna a probabilidade acumulada $\Pr(T \leq x)$, ou seja, a área sob a curva à esquerda do ponto x . Útil para calcular probabilidades a partir de valores observados.

Função `t.pdf(x, df)`. Retorna a altura da curva da distribuição (função de densidade) no ponto x . Menos usada em aplicações práticas, mas útil para construção de gráficos.

3.1.6 Exemplos de cálculo com a distribuição t

Exemplo 1: Percentis da t com 5 graus de liberdade. Encontre os percentis 2,5 e 97,5 da distribuição t com 5 graus de liberdade.

```
t.ppf(0.025, 5) # -> aproximadamente -2.571
t.ppf(0.975, 5) # -> aproximadamente 2.571
```

Exemplo 2: Probabilidade de cauda. Uma amostra de tamanho 10 é colhida de uma população normal com $\mu = 4$. Qual é $\Pr(T > 1,833)$, em que $T = (\bar{X} - 4)/(S/\sqrt{10})$? Por definição, $T \sim t_9$ (9 graus de liberdade).

```
1 - t.cdf(1.833, 9) # -> aproximadamente 0.05
```

Portanto $\Pr(T > 1,833) \approx 0,05$.

Exemplo 3: Ponto crítico. Encontre o valor para t_{12} que delimita à sua direita uma área de 0,025.

```
t.ppf(0.975, 12) # -> aproximadamente 2.179
```

3.2 Verificação da suposição de normalidade

A validade exata do IC com distribuição t depende de que a população seja *normal*. Em aplicações, o procedimento costuma ser razoavelmente robusto a desvios moderados de normalidade, especialmente quando n não é muito pequeno. O que deve ser evitado são situações de assimetria intensa ou presença de outliers extremos, que podem distorcer tanto $\bar{x}$ quanto s de forma apreciável. As principais ferramentas para esse diagnóstico são:

- *Q-Q plot (gráfico quantil-quantil)*: compara os quantis observados da amostra com os quantis teóricos da distribuição normal. Se os pontos se alinham aproximadamente sobre uma reta, a suposição de normalidade é plausível. Desvios sistemáticos na forma de S ou de pontos isolados nos extremos são sinais de alerta. Em Python: `scipy.stats.probplot(dados, plot=plt)`.
- *Teste de Shapiro-Wilk*: teste formal de normalidade, especialmente adequado para amostras pequenas. Em Python: `scipy.stats.shapiro(dados)`. O resultado inclui uma estatística W (próxima de 1 quando os dados são normais) e um p-valor; p-valores pequenos (convencionalmente $< 0,05$) indicam evidência contra a normalidade.

Nem um Q-Q plot aproximadamente linear nem um p-valor grande no teste de Shapiro-Wilk provam que a população é normal. Eles apenas indicam que os dados observados não fornecem evidência forte contra essa suposição; a decisão também deve considerar o contexto e o mecanismo gerador dos dados.

Para amostras muito pequenas ($n < 10$), mesmo esses diagnósticos têm poder limitado. Nesses casos, o conhecimento do processo gerador dos dados, isto é, o contexto do problema, tende a ser mais informativo do que os testes formais.

3.3 Intervalo de confiança para μ com distribuição t

Para amostras pequenas, o IC para μ é construído de forma análoga ao caso com n grande: partimos da estimativa pontual $\bar{x}$ e somamos/subtraímos uma margem de erro. A diferença é que substituímos o z -score da normal padrão pelo t -score, que é o ponto crítico da distribuição t com $(n-1)$ graus de liberdade correspondente ao nível de confiança desejado:

$$\bar{x} \pm t_{n-1, \alpha/2} \times \frac{s}{\sqrt{n}}$$

O valor $t_{n-1, \alpha/2}$ é o ponto que delimita uma área de $\alpha/2$ na cauda direita da distribuição t_{n-1} . Como a distribuição t tem caudas mais pesadas do que a normal padrão, sempre vale $t_{n-1, \alpha/2} > z_{\alpha/2}$ para qualquer n finito. Isso significa que o IC com distribuição t é *mais largo* do que o IC com z correspondente, e é esse alargamento que reflete honestamente a incerteza adicional devida ao uso de s no lugar de σ .

3.3.1 Procedimento de cálculo

Para construir um IC de nível $(1 - \alpha)$ para μ , com σ desconhecido e população aproximadamente normal:

1. Calcular a média da amostra: $\bar{x} = (X_1 + \cdots + X_n)/n$.
2. Calcular o desvio padrão da amostra: $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2}$.
3. Determinar $t_{n-1, \alpha/2}$, o valor que delimita área $\alpha/2$ na cauda direita da distribuição t .
4. Computar os extremos do IC: $\bar{x} \pm t_{n-1, \alpha/2} \cdot s/\sqrt{n}$.

Pergunta 9

Para cada situação abaixo, identifique o valor crítico $t_{n-1, \alpha/2}$ a ser usado na construção do IC:

- (a) $n = 10$, nível de confiança 95%
- (b) $n = 25$, nível de confiança 90%
- (c) $n = 5$, nível de confiança 99%

3.3.2 Exemplos

Exemplo: resistência de soldaduras. Um técnico em metalurgia fabrica 5 juntas soldadas usando um novo processo e mede a resistência à deformação de cada uma. Os cinco valores (em ksi) são:

56,3 65,4 58,7 70,1 63,9

Suponha que a população seja aproximadamente normal. Determine um IC de 95% para a resistência média.

Para 95% de confiança e $\nu = 5 - 1 = 4$ graus de liberdade, o valor crítico é $t_{4, 0,025} \approx 2,776$. A distribuição t_4 tem 95% de sua área entre $-2,776$ e $+2,776$.

A média e o desvio padrão da amostra são $\bar{x} = 62,88$ e $s = 5,484$. Portanto:

$$\bar{x} - 2,776 \cdot \frac{s}{\sqrt{n}} < \mu < \bar{x} + 2,776 \cdot \frac{s}{\sqrt{n}}$$

$$62,88 - 6,81 < \mu < 62,88 + 6,81$$

O IC de 95% é (56,07; 69,69).

Em Python:

```
import numpy as np
from scipy.stats import t

dados = [56.3, 65.4, 58.7, 70.1, 63.9]
n = len(dados)
media = np.mean(dados)
```

```
s = np.std(dados, ddof=1)          # ddof=1 para desvio padrao amostral
t_critico = t.ppf(0.975, df=n-1)    # bicaudal 95%
margem = t_critico * s / np.sqrt(n)
print(media - margem, media + margem) # -> (56.07, 69.69)
```

Nota: use sempre $ddof=1$ para que a fórmula do desvio padrão amostral s seja aplicada (divisor $n - 1$), e não a do desvio padrão populacional σ (divisor n).

Exemplo: amostra de 25 elementos. Uma amostra de 25 elementos tem média $\bar{x} = 150$ e desvio padrão $s = 10$. Determine um IC de 90% para a média populacional.

Como σ é desconhecido, usamos a distribuição t com $\nu = n - 1 = 24$ graus de liberdade. Para $(1 - \alpha) = 0,9$, temos $\alpha/2 = 0,05$.

```
t_critico = t.ppf(0.95, df=24)    # -> 1.7109
```

Construindo o intervalo:

$$150 \pm 1,7109 \times \frac{10}{\sqrt{25}} = 150 \pm 3,42$$

O IC de 90% é (146,58; 153,42).

Pergunta 10

No Exemplo 1 (soldagem), suponha que os dados fossem $n = 5$ observações de uma distribuição claramente assimétrica (por exemplo, com um valor muito discrepante). O procedimento de IC com distribuição t ainda seria adequado? O que você faria antes de aplicá-lo?

Pergunta 11

Um pesquisador afirma: “Como minha amostra tem $n = 40$, posso usar z em vez de t ”. Avalie essa afirmação. Em que sentido ela está correta? Em que sentido poderia ser melhorada?

Síntese: z ou t ?

Situação	Distribuição usada	Valor crítico
n grande, σ conhecido	Normal padrão	$z_{\alpha/2}$
n grande, σ desconhecido	Normal padrão (aprox.)	$z_{\alpha/2}$ com s
n pequeno, σ desconhecido, pop. normal	t de Student	$t_{n-1, \alpha/2}$

Alerta conceitual: quando σ é desconhecido e usamos s em seu lugar, a estatística correta deixa de seguir a distribuição normal e passa a seguir a distribuição t de Student. Portanto, do ponto de vista teórico, o mais adequado é usar sempre t nesse caso.

Por que então usamos z para n grande? Porque, à medida que n cresce, os valores críticos da distribuição t se aproximam rapidamente dos da normal padrão, tornando a diferença praticamente desprezível na prática.

Recomendação prática: sempre que σ for desconhecido, prefira a distribuição t . Para amostras grandes, usar z com s é uma aproximação comum e geralmente adequada.

3.4 Exercícios de fixação

Os exercícios abaixo cobrem os principais aspectos da estimação intervalar para amostras pequenas: uso da distribuição t , interpretação de graus de liberdade, verificação das suposições e comparação com o caso de amostras grandes.

3.4.1 Aquecimento: distribuição t e valores críticos

Exercício 1: Identificação do valor crítico. Para cada situação abaixo, identifique: (i) o número de graus de liberdade; (ii) o valor crítico $t_{n-1, \alpha/2}$ a usar; (iii) se o valor crítico é maior ou menor do que o correspondente $z_{\alpha/2}$ da normal padrão.

- (a) $n = 8$, nível de confiança 95%.
- (b) $n = 15$, nível de confiança 90%.
- (c) $n = 25$, nível de confiança 99%.
- (d) $n = 30$, nível de confiança 95%.

Solução do Exercício 1. Para cada caso, os graus de liberdade são $\nu = n - 1$ e o valor crítico é obtido por `t.ppf(1 - alpha/2, df=nu)`.

```
from scipy.stats import t, norm

casos = [(8, 0.05), (15, 0.10), (25, 0.01), (30, 0.05)]
for n, alpha in casos:
    nu = n - 1
    t_crit = t.ppf(1 - alpha/2, df=nu)
    z_crit = norm.ppf(1 - alpha/2)
    print(f"n={n}, gl={nu}, t={t_crit:.3f}, z={z_crit:.3f}")
```

n	Graus de liberdade	Nível	$t_{n-1, \alpha/2}$	$z_{\alpha/2}$
8	7	95%	2,365	1,960
15	14	90%	1,761	1,645
25	24	99%	2,797	2,576
30	29	95%	2,045	1,960

Em todos os casos, $t_{n-1, \alpha/2} > z_{\alpha/2}$. A diferença diminui conforme n aumenta, refletindo a convergência da distribuição t para a normal padrão. Para $n = 30$, os valores já são bastante próximos.

Exercício 2: Efeito dos graus de liberdade na largura do IC. Um pesquisador obteve $\bar{x} = 50$ e $s = 8$ em duas situações distintas: (A) $n = 5$ e (B) $n = 20$. Em ambos os casos, deseja construir um IC de 95% para μ .

- (a) Calcule os valores críticos $t_{n-1, 0,025}$ para cada caso.
- (b) Calcule os erros-padrão $s/\sqrt{n}$ para cada caso.

- (c) Calcule as margens de erro e os intervalos de confiança.
- (d) Compare as larguras dos dois intervalos. O que explica a diferença?

Solução do Exercício 2.

```
import numpy as np
from scipy.stats import t

xbar, s = 50, 8
for n in [5, 20]:
    t_crit = t.ppf(0.975, df=n-1)
    ep = s / np.sqrt(n)
    E = t_crit * ep
    print(f"n={n}: t={t_crit:.3f}, EP={ep:.3f}, E={E:.3f}, IC=({xbar-E:.2f}; {xbar+E:.2f})")
```

n	$t_{n-1, 0,025}$	$s/\sqrt{n}$	Margem E	IC (95%)	Largura
5	2,776	3,578	9,934	(40,07; 59,93)	19,87
20	2,093	1,789	3,745	(46,26; 53,75)	7,49

O IC com $n = 5$ é mais de *2,6 vezes mais largo* do que o IC com $n = 20$. Isso ocorre por dois motivos combinados: o valor crítico t é maior (caudas mais pesadas com poucos graus de liberdade) e o erro-padrão é maior (divisor $\sqrt{n}$ menor). Ambos os fatores alargam o intervalo ao mesmo tempo.

3.4.2 Construção de ICs: situações-problema

Exercício 3: Teor de vitamina C em laranjas. Um nutricionista colheu uma amostra de 10 laranjas de um mesmo lote e mediu o teor de vitamina C (em mg por 100 g de suco) de cada uma. Os resultados foram:

52,1 48,7 55,3 50,6 49,2 53,8 47,9 51,4 54,0 50,1

Suponha que o teor de vitamina C nesse lote siga distribuição aproximadamente normal.

- (a) Calcule a média amostral $\bar{x}$ e o desvio padrão amostral s .
- (b) Determine o valor crítico $t_{9, 0,025}$ para um IC de 95%.
- (c) Construa o IC de 95% para o teor médio de vitamina C no lote.
- (d) Interprete o intervalo no contexto do problema.

Solução do Exercício 3.

```
import numpy as np
from scipy.stats import t

dados = [52.1, 48.7, 55.3, 50.6, 49.2, 53.8, 47.9, 51.4, 54.0,
         50.1]
n = len(dados)
xbar = np.mean(dados)          # -> 51.31
s = np.std(dados, ddof=1)      # -> 2.365
t_crit = t.ppf(0.975, df=9)    # -> 2.262
E = t_crit * s / np.sqrt(n)    # -> 1.691
print(f"IC 95%: ({xbar-E:.2f}; {xbar+E:.2f})") # -> (49.62;
         53.00)
```

Os resultados são: $\bar{x} = 51,31$ mg, $s = 2,365$ mg, $t_{9,0,025} = 2,262$, margem de erro $E = 1,69$ mg.

O IC de 95% para o teor médio é (49,62; 53,00) mg por 100 g.

Interpretação: com 95% de confiança, o procedimento indica que o teor médio de vitamina C nesse lote está entre aproximadamente 49,6 mg e 53,0 mg por 100 g de suco.

Exercício 4: Tempo de resposta de um sistema. Um engenheiro de software mediu o tempo de resposta (em milissegundos) de um sistema sob teste em 12 requisições aleatórias:

142 138 155 149 160 137 152 145 158 143 151 147

Suponha que os tempos de resposta seguem distribuição aproximadamente normal.

- Construa um IC de 99% para o tempo médio de resposta.
- O valor de 160 ms pertence ao IC? Explique o que essa comparação indica sobre a compatibilidade do valor com os dados, sem tratá-la como um teste formal da exigência unilateral " $\mu < 160$ ".
- O que mudaria no IC se o nível de confiança fosse reduzido para 90%?

Exercício 5: Consumo de combustível. Um fabricante de automóveis testou um novo modelo em 8 percursos padronizados e obteve os seguintes consumos (em km/L):

13,2 12,8 14,1 13,5 12,6 13,9 14,3 13,0

- Verifique graficamente (ou pelo teste de Shapiro-Wilk) se a suposição de normalidade é razoável.
- Construa um IC de 95% para o consumo médio do modelo.
- O fabricante anuncia que o consumo médio é de 14 km/L. O IC é consistente com essa afirmação? O que você diria ao fabricante?

3.4.3 Verificação de suposições e diagnóstico

Exercício 6: Quando usar (ou não usar) a distribuição t . Para cada situação abaixo, indique se o IC com distribuição t é adequado, justificando sua resposta.

- (a) $n = 12$, σ desconhecido, histograma da amostra aproximadamente simétrico e sem outliers.
- (b) $n = 8$, σ desconhecido, amostra com um valor claramente discrepante (outlier extremo).
- (c) $n = 25$, σ desconhecido, Q-Q plot com pontos alinhados ao longo da reta de referência.
- (d) $n = 6$, σ desconhecido, teste de Shapiro-Wilk com p-valor = 0,02.
- (e) $n = 50$, σ desconhecido, distribuição da população claramente assimétrica.

Exercício 7: Impacto de um outlier. Considere os dados do Exercício 3 (teor de vitamina C), mas suponha que o valor 47,9 fosse substituído por 18,0 (erro de medição).

- (a) Recalcule $\bar{x}$ e s com o valor modificado.
- (b) Construa o IC de 95% com o novo conjunto de dados.
- (c) Compare com o IC original. O que o outlier faz com a largura e com a posição do intervalo?
- (d) O uso da distribuição t ainda seria adequado nesse caso? O que você recomendaria fazer antes de prosseguir?

3.4.4 Comparação: distribuição z versus t

Exercício 8: Erro de usar z em amostra pequena. Um analista tem $n = 10$, $\bar{x} = 80$ e $s = 6$. Ele decide (incorretamente) usar $z_{0,025} = 1,960$ em vez de $t_{9,0,025}$ para construir um IC de 95%.

- (a) Calcule o IC usando z (abordagem incorreta).
- (b) Calcule o IC usando t (abordagem correta).
- (c) Qual é a diferença nas margens de erro? Em termos relativos, quanto o IC com z subestima a margem correta?
- (d) Descreva a consequência prática de subestimar a margem de erro: o que acontece com a cobertura real do intervalo?

Solução do Exercício 8.

```

from scipy.stats import t, norm
import numpy as np

n, xbar, s = 10, 80, 6
ep = s / np.sqrt(n)          # -> 1.897

z = norm.ppf(0.975)          # -> 1.960
t9 = t.ppf(0.975, df=9)      # -> 2.262

E_z = z * ep                 # -> 3.718
E_t = t9 * ep                # -> 4.291

```

<i>Abordagem</i>	<i>Valor crítico</i>	<i>Margem E</i>	<i>IC</i>
Com z (incorreta)	1,960	3,718	(76,28; 83,72)
Com t_9 (correta)	2,262	4,291	(75,71; 84,29)

A margem de erro com z é $\approx 13\%$ menor do que a margem correta. Isso significa que o IC com z é *mais estreito do que deveria*: sua cobertura real é inferior a 95%, o intervalo falha em capturar o parâmetro mais frequentemente do que o nível de confiança nominal garante.

3.4.5 Questões conceituais e de interpretação

Exercício 9: Interpretação do IC com distribuição t . Um pesquisador construiu o seguinte IC de 95% para a duração média (em dias) de uma determinada fase de um processo industrial, com base em $n = 8$ observações:

$$IC_{95\%}(\mu) = (12,3; 18,7) \text{ dias}$$

Avalie cada afirmação abaixo, indicando se está *correta* ou *incorreta*, e justificando sua resposta.

- “Há 95% de probabilidade de que a duração média verdadeira esteja entre 12,3 e 18,7 dias”.
- “Se o procedimento fosse repetido muitas vezes com amostras de tamanho 8, aproximadamente 95% dos intervalos construídos conteriam o verdadeiro valor de μ ”.
- “A estimativa pontual para μ é de 15,5 dias”.
- “A margem de erro desse IC é de 3,2 dias”.
- “Com 99% de confiança, o IC seria mais estreito do que esse”.

Exercício 10: Planejamento com amostra pequena. Um laboratório deseja estimar a concentração média de um reagente em lotes de produção. Com base em um estudo piloto de 6 lotes, obteve-se $s = 4,2$ mg/L. O laboratório quer um IC de 95% com margem de erro de no máximo 3 mg/L.

- Usando a fórmula de tamanho amostral para μ com $z_{0,025} = 1,96$, calcule o n necessário.
- Mantendo a estimativa piloto s fixa, discuta: uma versão do planejamento que use um valor crítico t tende a exigir um n maior ou menor do que a fórmula com z ? Por quê? Comente também por que essa comparação ainda é aproximada.
- Se o laboratório coletar exatamente o n calculado no item (a), o IC resultante terá margem de erro exatamente igual a 3 mg/L? Justifique.

4 Resumo

A tabela abaixo sintetiza os principais intervalos de confiança estudados:

<i>Parâmetro</i>	<i>Fórmula do IC</i>	<i>Condições</i>
Média μ (σ conhecido)	$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$	Obs. i.i.d.; pop. normal, ou n grande com variância finita
Média μ (σ desconhecido, aproximação z)	$\bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$	Obs. i.i.d.; n grande e aproximação normal razoável
Proporção p (amostra grande)	$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	$n\hat{p} \geq 10$ e $n(1-\hat{p}) \geq 10$
Média μ (σ desconhecido, distribuição t)	$\bar{x} \pm t_{n-1, \alpha/2} \cdot \frac{s}{\sqrt{n}}$	Pop. aprox. normal; resultado exato sob normalidade

Intervalos de confiança são preferíveis a estimativas pontuais porque quantificam a incerteza da estimação. O nível de confiança não é a probabilidade de um intervalo já calculado conter o parâmetro, mas sim a taxa de cobertura do procedimento ao longo de repetições amostrais. Quanto maior o tamanho amostral, menor a margem de erro e mais precisa a estimativa.