

Estimação Intervalar

Nota de Aula 03

Prof. Eduardo Bezerra

Sumário

1	Introdução à Estimação Intervalar	3
2	Estimação Intervalar para Amostras Grandes	5
2.1	IC para a média populacional μ	6
2.1.1	Procedimento prático	6
2.2	IC para a proporção populacional p	7
2.3	Confiabilidade versus precisão	7
2.4	Determinação do tamanho da amostra	8
2.4.1	Caso 1: parâmetro de interesse é μ	8
2.4.2	Caso 2: parâmetro de interesse é p	9
2.5	Exercícios de fixação	9
2.5.1	Situações-problema com média populacional	9
2.5.2	Situações-problema com proporção populacional	10
2.5.3	Questões de comparação e interpretação	11
2.6	Apêndice: derivação dos intervalos de confiança	12
2.6.1	IC para a média em amostras grandes	12
2.6.2	IC para a proporção em amostras grandes	13
2.6.3	Derivação da fórmula de tamanho amostral	13
3	Estimação Intervalar para Amostras Pequenas	14
3.1	A distribuição t de Student	15
3.1.1	Principais características	15
3.1.2	Funções do <code>scipy.stats</code> relacionadas à distribuição t	16
3.1.3	Exemplos de cálculo com a distribuição t	17
3.2	Verificação da suposição de normalidade	17
3.3	Intervalo de confiança para μ com distribuição t	18
3.3.1	Procedimento de cálculo	18
3.3.2	Exemplos	19
3.4	Exercícios de fixação	20
3.4.1	Aquecimento: distribuição t e valores críticos	20
3.4.2	Construção de ICs: situações-problema	22
3.4.3	Verificação de suposições e diagnóstico	23
3.4.4	Comparação: distribuição z versus t	24
3.4.5	Questões conceituais e de interpretação	24
4	Resumo	25

A	Fundamentos geométricos e probabilísticos da distribuição t	26
A.0.1	Uma ponte geométrica: média e resíduos	26
A.0.2	Da geometria à distribuição qui-quadrado	32
A.0.3	Da qui-quadrado à distribuição t	36

Objetivos

Ao final da leitura, você deve ser capaz de:

Conceitos fundamentais

- Distinguir estimativa pontual de intervalo de confiança e explicar por que a estimação intervalar é mais informativa.
- Interpretar corretamente o nível de confiança de um intervalo.

Amostras grandes ★

- Construir intervalos de confiança para a média μ e a proporção p usando a aproximação normal.
- Verificar a condição de aplicabilidade da aproximação normal para proporções.
- Determinar o tamanho amostral mínimo para garantir margem de erro e nível de confiança definidos.

Amostras pequenas ★

- Descrever as principais características da distribuição t de Student e sua relação com a distribuição normal.
- Construir intervalos de confiança para a média usando a distribuição t quando n é pequeno e σ é desconhecido.
- Identificar quando o uso da distribuição t é adequado e verificar a suposição de normalidade da população.

Estas notas estão organizadas em três partes. A Seção 1 apresenta os fundamentos da estimação intervalar: intervalos de confiança, margem de erro e nível de confiança. A Seção 2 trata de intervalos de confiança para amostras grandes, usando a aproximação pelo Teorema Central do Limite, e inclui o planejamento do tamanho amostral. A Seção 3 aborda amostras pequenas, introduzindo a distribuição t de Student para o caso em que σ é desconhecido e n é reduzido. Os objetivos marcados com ★ são os mais centrais.

1 Introdução à Estimação Intervalar

Suponha que estejamos interessados em estudar um parâmetro populacional θ . Uma *estimativa pontual* é um único valor calculado a partir da amostra e usado como aproximação para θ . Contudo, estimativas obtidas de amostras diferentes variam, e o valor observado em uma amostra não revela, por si só, a magnitude de seu erro em relação ao parâmetro. A estimação intervalar acrescenta essa dimensão de incerteza ao construir um *intervalo de confiança*, isto é, uma faixa de valores plausíveis para o parâmetro baseada nos dados amostrais.

Uma abordagem mais apropriada é construir um *intervalo de confiança*: em vez de um único número, reporta-se uma faixa de valores plausíveis para o parâmetro. Por exemplo, uma informação muito mais útil do que a estimativa pontual de 161 cm seria poder afirmar que *a altura média das mulheres da comunidade acadêmica está entre 1,56 m e 1,67 m*,

com 95% de confiança. O intervalo comunica simultaneamente a estimativa e a incerteza associada a ela.

Um *intervalo de confiança*, ou *estimativa intervalar*, para um parâmetro populacional θ é um par de números $[L, U]$, ambos calculados a partir dos dados amostrais, tal que o procedimento de construção tem probabilidade $(1 - \alpha)$ de produzir intervalos que contenham o verdadeiro valor de θ .

Na prática, os intervalos de confiança estudados neste texto são *simétricos em torno da estimativa pontual*: somamos e subtraímos uma mesma quantidade E (a margem de erro) ao valor central. No caso em que o estimador é $\hat{p}$:

$$[\hat{p} - E, \hat{p} + E]$$

No caso em que o estimador é $\bar{x}$:

$$[\bar{x} - E, \bar{x} + E]$$

O valor E , que corresponde à metade do comprimento do intervalo, é denominado *margem de erro*. A margem de erro é uma quantidade calculada pelo procedimento para atingir a cobertura desejada, exatamente ou por aproximação conforme o método: um E muito pequeno geraria um intervalo estreito que raramente capturaria o parâmetro; um E grande capturaria o parâmetro com muita frequência, mas seria tão largo que pouco informaria.

Um intervalo de confiança está sempre associado a um *nível de confiança* (*confidence level*), que corresponde ao quão confiável é a informação de que o parâmetro populacional de interesse se encontra dentro do intervalo computado.

O nível de confiança é a probabilidade de que o procedimento de construção de intervalos produza um intervalo que contenha o verdadeiro valor do parâmetro populacional. Por exemplo, com nível de 95%, se fosse possível construir 100 intervalos de confiança para um determinado parâmetro θ a partir de 100 amostras diferentes, aproximadamente 95 desses intervalos conteriam o valor de θ .

Uma interpretação frequente, mas incorreta, é:


“Há 95% de probabilidade de que o parâmetro esteja dentro do intervalo calculado”.

Isso está errado porque o parâmetro populacional é *fixo* (não aleatório). O que é aleatório é o intervalo, pois depende da amostra.

Interpretação correta:

“Se repetirmos o procedimento muitas vezes, cerca de 95% dos intervalos construídos conterão o verdadeiro valor do parâmetro”.

A figura abaixo ilustra esse conceito. Cada linha horizontal representa um intervalo de confiança construído a partir de uma amostra diferente. A linha vertical tracejada indica o verdadeiro valor do parâmetro θ . Os intervalos em cinza capturam θ ; o intervalo em vermelho, não.



Uma realização ilustrativa com 13 intervalos construídos a partir de 13 amostras distintas.

Nela, 12 capturam θ (cinza) e 1 não captura (vermelho). A proporção observada, $12/13 \approx 92\%$, não é a cobertura do procedimento: em um número finito de repetições ela pode diferir do nível nominal de 95%.

Pergunta 1

O texto apresenta intervalos de confiança nas formas $[\hat{p} - E, \hat{p} + E]$ e $[\bar{x} - E, \bar{x} + E]$.

- O que representa o termo E ?
- Por que conhecer apenas a estimativa pontual pode ser insuficiente em inferência estatística?

Pergunta 2

Uma turma interpretou “nível de confiança de 95%” como: “há 95% de probabilidade de o parâmetro estar dentro do intervalo já calculado”. Usando a explicação do texto, reescreva essa interpretação de forma correta.

2 Estimação Intervalar para Amostras Grandes

Com amostras i.i.d. e variância populacional finita, podemos construir intervalos de confiança para a média sem conhecer a forma exata da distribuição da população, desde que n seja suficientemente grande. O ingrediente central é o *Teorema Central do Limite (TLC)*: formalmente, a média amostral *padronizada* converge em distribuição para a normal padrão. Na prática, para um n grande e fixo, isso justifica a aproximação


$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Conforme $n \rightarrow \infty$, a distribuição de $\bar{X}_n$ fica mais concentrada em torno de μ e, para cada n grande, aproximadamente normal em sua forma. Essa aproximação permite usar probabilidades da normal padrão para determinar margens de erro.

Para parâmetros que são média, a regra prática $n > 30$ costuma funcionar bem quando a distribuição subjacente é aproximadamente simétrica e sem caudas muito pesadas. O valor 30 não é especial matematicamente; é apenas uma regra prática. Em distribuições muito assimétricas ou de cauda pesada, como a log-normal ou a Pareto, a aproximação normal pode exigir n consideravelmente maior; não existe um limiar universal. Para a proporção, além de n grande, é importante verificar se há quantidade suficiente de sucessos e falhas na amostra (ver Seção 2.2).

2.1 IC para a média populacional μ

Sob observações i.i.d., variância populacional finita e tamanho amostral para o qual a aproximação normal seja razoável, a média amostral padronizada $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$ é aproximadamente normal padrão. Isso nos permite capturar uma fração $(1 - \alpha)$ da distribuição de $\bar{X}$ usando os pontos críticos $\pm z_{\alpha/2}$ da normal padrão, os valores que deixam exatamente $\alpha/2$ de área em cada cauda. A figura abaixo ilustra essa região central para um nível de confiança de 95% ($\alpha = 0,05$, $z_{\alpha/2} = 1,96$).



A área central (azul) corresponde a $(1 - \alpha)$ da distribuição; as caudas (vermelho) correspondem a $\alpha/2$ cada. Para 95% de confiança: $z_{\alpha/2} = 1,96$.

Se σ é desconhecido, o que é o caso mais comum na prática, e n é grande, uma aproximação usual substitui σ pelo desvio padrão amostral s :

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

A estrutura da fórmula acima tem uma leitura intuitiva direta: partimos da estimativa pontual $\bar{x}$ e adicionamos/subtraímos uma margem de erro $E = z_{\alpha/2} \cdot \sigma/\sqrt{n}$. Essa margem cresce com $z_{\alpha/2}$ (maior confiança exige intervalo mais largo), cresce com σ (populações mais dispersas geram estimativas mais incertas) e diminui com $\sqrt{n}$ (amostras maiores reduzem o erro).

2.1.1 Procedimento prático

1. *Calcular $\bar{x}$* : a média amostral é a estimativa pontual de μ e o centro do intervalo.
2. *Calcular o erro-padrão* ($\sigma/\sqrt{n}$ se σ é conhecido, ou $s/\sqrt{n}$ se σ é desconhecido): o erro-padrão mede a dispersão típica de $\bar{x}$ em torno de μ .

3. *Obter $z_{\alpha/2}$ na distribuição normal padrão:* para os níveis de confiança mais comuns, os valores são $z_{0,025} = 1,960$ (95%), $z_{0,05} = 1,645$ (90%) e $z_{0,005} = 2,576$ (99%).
4. *Calcular os limites:* $\bar{x} - z_{\alpha/2} \cdot \text{EP}$ (limite inferior) e $\bar{x} + z_{\alpha/2} \cdot \text{EP}$ (limite superior).

Pergunta 3

No caso de IC para μ com amostra grande:

- (a) Qual fórmula é usada quando σ é conhecido?
- (b) O que muda na fórmula quando σ é desconhecido?

2.2 IC para a proporção populacional p

A lógica é a mesma do IC para a média: sob observações i.i.d. Bernoulli, a proporção amostral $\hat{P}$ pode ser aproximada por uma normal quando a amostra contém sucessos e falhas em quantidade suficiente. O erro-padrão de $\hat{P}$ é $\sqrt{p(1-p)/n}$, que reflete o fato de que proporções extremas (próximas de 0 ou 1) são inerentemente menos variáveis do que proporções intermediárias, e que amostras maiores reduzem a incerteza. Como p é desconhecido, estimamos esse erro-padrão substituindo p por $\hat{p}$, obtendo o denominado *intervalo normal de Wald*:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

A heurística mais comum requer pelo menos 10 sucessos e 10 falhas na amostra, ou seja, $n\hat{p} \geq 10$ e $n(1-\hat{p}) \geq 10$. Ela não garante cobertura nominal exata, mas costuma tornar a aproximação normal razoável. Alguns textos adotam o limiar mais conservador de 15 em cada categoria; outros aceitam 5. Para contagens pequenas ou proporções muito próximas de 0 ou 1, o intervalo de Wilson ou métodos exatos são preferíveis ao intervalo de Wald.

Pergunta 4

Para cada situação abaixo, verifique se a condição de aplicabilidade do IC para proporção é satisfeita. Justifique calculando o número de sucessos e falhas na amostra.

- (a) $n = 80$, $\hat{p} = 0,08$
- (b) $n = 200$, $\hat{p} = 0,15$
- (c) $n = 50$, $\hat{p} = 0,50$


2.3 Confiabilidade versus precisão

Para um tamanho amostral fixo, existe um *trade-off* inevitável entre confiabilidade e precisão. O mecanismo é direto: aumentar o nível de confiança significa exigir que o intervalo capture o parâmetro com maior frequência ao longo de repetidas amostragens. Para isso, precisamos usar um valor crítico $z_{\alpha/2}$ maior, o que por sua vez aumenta a margem de erro $E = z_{\alpha/2} \cdot \sigma/\sqrt{n}$ e alarga o intervalo. Ou seja: *pagar* por mais confiança significa *abrir mão* de precisão.

- Maior nível de confiança $\Rightarrow z_{\alpha/2}$ maior $\Rightarrow E$ maior $\Rightarrow$ intervalo mais largo.
- Menor nível de confiança $\Rightarrow z_{\alpha/2}$ menor $\Rightarrow E$ menor $\Rightarrow$ intervalo mais estreito.

A única forma de aumentar a confiabilidade *sem* perder precisão é aumentar o tamanho amostral n , pois n aparece no denominador do erro-padrão, e é o que a próxima seção explora.

A figura abaixo torna visual esse trade-off: os dois intervalos foram construídos a partir da mesma amostra ($\bar{x} = 50$, $\sigma/\sqrt{n} = 2$), diferindo apenas no nível de confiança.



Mesma amostra, dois níveis de confiança. O IC de 99% é mais largo (mais confiável, menos preciso); o IC de 90% é mais estreito (mais preciso, menos confiável).

Pergunta 5

Mantendo n fixo, o que acontece com a largura do intervalo quando:

- aumentamos o nível de confiança?
- reduzimos o nível de confiança?

Em síntese, toda a construção de intervalos de confiança se resume a *controlar a margem de erro E* : intervalos estreitos oferecem mais precisão e menos confiança; intervalos largos oferecem mais confiança e menos precisão.

2.4 Determinação do tamanho da amostra

O objetivo aqui é planejar o estudo antes da coleta, definindo um tamanho amostral mínimo que garanta um nível de confiança $(1 - \alpha)$ e uma margem de erro máxima E .

Determinar o tamanho da amostra significa responder à pergunta: *quantos dados preciso coletar para garantir um erro máximo aceitável?* Maior precisão, isto é, menor E , exige amostras maiores; maior confiança também exige amostras maiores.

2.4.1 Caso 1: parâmetro de interesse é μ

$$n = \left\lceil \frac{\sigma^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

Se σ for desconhecido, usa-se uma estimativa obtida em estudo piloto (s):

$$n = \left\lceil \frac{s^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

2.4.2 Caso 2: parâmetro de interesse é p

Usando a aproximação normal para a proporção amostral:

$$n = \left\lceil \frac{z_{\alpha/2}^2 p(1-p)}{E^2} \right\rceil$$

Se houver amostra piloto, substitui-se p por $\hat{p}_{\text{pil}}$. Sem piloto, usa-se a aproximação conservadora $p(1-p) \leq 1/4$:

$$n = \left\lceil \frac{z_{\alpha/2}^2}{4E^2} \right\rceil$$

O produto $p(1-p)$ é máximo em $p = 0,5$, onde vale $1/4$. Ao usar $1/4$, garantimos que o tamanho amostral seja suficiente para qualquer valor de p . Quando o p real está próximo de 0 ou 1, essa escolha conservadora *superdimensiona* a amostra.

Pergunta 6

Calcule $p(1-p)$ para os valores $p = 0,50$, $p = 0,30$ e $p = 0,10$. Com base nos resultados:

- (a) Para qual valor de p o produto é maior?
- (b) O que isso implica sobre o tamanho amostral calculado com a fórmula conservadora quando o p real é próximo de 0 ou 1?

2.5 Exercícios de fixação

2.5.1 Situações-problema com média populacional

Exercício 1: Tempo de atendimento em uma clínica. Uma clínica deseja estimar o tempo médio de atendimento de seus pacientes. Uma amostra aleatória de $n = 64$ atendimentos produziu média amostral $\bar{x} = 38$ minutos. Suponha que o desvio-padrão populacional seja conhecido e igual a $\sigma = 12$ minutos.

- (a) Construa um IC de 95% para o tempo médio de atendimento.
- (b) Interprete o intervalo no contexto do problema.
- (c) Qual seria o efeito de aumentar o nível de confiança para 99%?

Solução do Exercício 1. Para 95% de confiança, $\alpha = 0,05$ e precisamos de $z_{0,025}$. Em Python:

```
from scipy.stats import norm
norm.ppf(0.975) # -> 1.96
```

A sigla `ppf` significa *percent point function* e corresponde à inversa da CDF. Usamos 0.975 porque a área central desejada é 0,95; cada cauda recebe 0,025; logo o ponto crítico à direita tem 0,975 de área acumulada à esquerda.

O erro-padrão é:

$$\frac{\sigma}{\sqrt{n}} = \frac{12}{\sqrt{64}} = \frac{12}{8} = 1,5$$

A margem de erro é:

$$E = 1,96 \cdot 1,5 = 2,94$$

O intervalo de confiança é $38 \pm 2,94$, ou seja, $(35,06; 40,94)$.

Interpretação: com 95% de confiança, o procedimento produz um intervalo que sugere que o tempo médio de atendimento está entre aproximadamente 35,1 e 40,9 minutos.

Se o nível de confiança aumentar para 99%, o valor crítico aumenta, a margem de erro fica maior e o intervalo se torna mais largo.

Exercício 2: Peso médio de embalagens. Uma indústria quer verificar o peso médio de um produto embalado automaticamente. Foi coletada uma amostra com $n = 100$ embalagens, obtendo-se $\bar{x} = 502$ g e desvio-padrão amostral $s = 8$ g.

- (a) Construa um IC de 95% para o peso médio populacional.
- (b) Explique por que, nesse caso, é aceitável usar s no lugar de σ .
- (c) O intervalo é compatível com a meta nominal de 500 g?

Exercício 3: Salário médio de estagiários. Uma universidade deseja estimar a bolsa média mensal recebida por seus estagiários. Uma amostra de $n = 49$ alunos apresentou média $\bar{x} = \text{R\$ } 1.420$ e desvio-padrão populacional conhecido $\sigma = 210$.

- (a) Construa um IC de 90% para a bolsa média.
- (b) Compare conceitualmente esse intervalo com o que seria obtido para 95% de confiança.
- (c) Qual dos dois é mais estreito e por quê?

2.5.2 Situações-problema com proporção populacional

Exercício 4: Aprovação de uma política institucional. Uma instituição entrevistou $n = 200$ alunos sobre uma nova política acadêmica. Desses, 136 declararam ser favoráveis à proposta.

- (a) Calcule $\hat{p}$.
- (b) Verifique se a condição de aplicabilidade da aproximação normal é satisfeita.
- (c) Construa um IC de 95% para a proporção populacional de alunos favoráveis.
- (d) Interprete o resultado em linguagem não técnica.

Solução do Exercício 4. A proporção amostral é $\hat{p} = 136/200 = 0,68$.

Verificação da condição:

$$n\hat{p} = 200 \cdot 0,68 = 136 \geq 10 \quad n(1 - \hat{p}) = 200 \cdot 0,32 = 64 \geq 10$$

A aproximação normal é adequada.

Para $z_{0,025} \approx 1,96$, o erro-padrão é:

$$\sqrt{\frac{(0,68)(0,32)}{200}} = \sqrt{0,001088} \approx 0,033$$

A margem de erro é $E = 1,96 \cdot 0,033 \approx 0,065$. O intervalo de confiança é $(0,615; 0,745)$, ou seja, aproximadamente $(61,5\%; 74,5\%)$.

Interpretação: com 95% de confiança, o procedimento indica que a proporção de alunos favoráveis à proposta está entre cerca de 61,5% e 74,5%.

Exercício 5: Uso de bicicleta para ir ao campus. Em uma pesquisa com $n = 120$ estudantes, 18 afirmaram ir ao campus de bicicleta com frequência.

- Calcule a proporção amostral.
- Verifique se a condição de pelo menos 10 sucessos e 10 falhas é satisfeita.
- Construa um IC de 90% para a proporção populacional.
- Seria adequado usar o mesmo procedimento com $n = 30$ mantendo a mesma proporção amostral?

Exercício 6: Intenção de voto. Uma chapa deseja estimar sua proporção de apoio entre os alunos. Em uma amostra de $n = 500$ estudantes, 260 declararam intenção de voto nessa chapa.

- Construa um IC de 95% para a proporção populacional de apoio.
- Calcule a margem de erro desse intervalo.
- Como a margem de erro mudaria se a amostra tivesse tamanho $n = 1000$, mantendo a mesma proporção amostral?

2.5.3 Questões de comparação e interpretação

Exercício 7: Comparando dois intervalos para a média. Duas equipes calcularam ICs para a mesma variável:

- Equipe A: $\bar{x} \pm 1,96 \cdot \frac{10}{\sqrt{100}}$
- Equipe B: $\bar{x} \pm 2,58 \cdot \frac{10}{\sqrt{100}}$

- Qual equipe usou maior nível de confiança?
- Qual intervalo é mais largo?
- Por que isso acontece?

Solução do Exercício 7. A Equipe B usou maior nível de confiança, porque utilizou um valor crítico maior: 1,96 é típico de 95% de confiança, e 2,58 é típico de 99% de confiança.

Como o erro-padrão é o mesmo nos dois casos ($10/\sqrt{100} = 1$), as margens de erro são 1,96 (Equipe A) e 2,58 (Equipe B). Portanto, o intervalo da Equipe B é mais largo. *Quanto maior o nível de confiança, maior é o valor crítico, maior é a margem de erro e mais largo fica o intervalo.*

Exercício 8: Planejamento de pesquisa. Uma equipe quer estimar a proporção de alunos que pretendem fazer intercâmbio, com margem de erro máxima de 4 pontos percentuais e 95% de confiança.

- (a) Calcule o tamanho amostral conservador.
- (b) Explique por que a escolha conservadora usa $p(1 - p) = 1/4$.
- (c) O que aconteceria com o tamanho amostral se houvesse estudo piloto indicando $p \approx 0,20$?

2.6 Apêndice: derivação dos intervalos de confiança

2.6.1 IC para a média em amostras grandes

Passo 1: Distribuição da média amostral. Se $X_1, \dots, X_n$ são i.i.d. com média μ e variância σ^2 , então, para n grande, o TLC implica:

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Passo 2: Padronização.

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1)$$

Passo 3: Região central da normal padrão.

Para nível de confiança $(1 - \alpha)$, escolhemos $z_{\alpha/2}$ tal que $\Pr(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$.

Passo 4: Isolamento de μ .

$$\Pr\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Portanto, o intervalo de confiança de nível $(1 - \alpha)$ para μ é:

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Quando σ é desconhecido, em amostras grandes substituímos σ por s .

2.6.2 IC para a proporção em amostras grandes

Passo 1: Distribuição da proporção amostral. Para n grande: $\hat{P} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$.

Passo 2: Padronização.

$$Z = \frac{\hat{P} - p}{\sqrt{p(1-p)/n}} \approx \mathcal{N}(0, 1)$$

Passos 3 e 4: Região central e isolamento de p . Para nível $(1 - \alpha)$, escolhemos $z_{\alpha/2}$ tal que:

$$\Pr\left(-z_{\alpha/2} \leq \frac{\hat{P} - p}{\sqrt{p(1-p)/n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

Multiplicando os três membros por $\sqrt{p(1-p)/n}$ e reorganizando para isolar p , obteríamos uma expressão alternativa (como o intervalo de Wilson), mais precisa do que a aproximação normal, porém mais complexa:

$$p \approx \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

O problema é que o erro-padrão depende do próprio p , que é desconhecido. Isolar p algebricamente seria possível (e resulta no chamado *intervalo de Wilson*), mas conduz a uma expressão mais complexa.

Passo 5: Substituição prática. Para amostras grandes, $\hat{p}$ é próximo de p ; logo, substituímos p por $\hat{p}$ dentro do erro-padrão:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

2.6.3 Derivação da fórmula de tamanho amostral

A ideia é simples: partimos da fórmula da margem de erro e a invertemos para encontrar o n necessário.

Passo 1: Margem de erro do IC. Para amostras grandes, a margem de erro do IC para μ é:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Essa expressão relaciona quatro quantidades: E , $z_{\alpha/2}$, σ e n . Se fixarmos os três primeiros, podemos determinar o quarto.

Passo 2: Impor o erro máximo desejado. No planejamento, escolhemos previamente o maior erro que toleramos e o nível de confiança. Queremos, portanto, encontrar o menor n tal que:

$$z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \leq E$$

Tomamos a igualdade para obter o n mínimo exato.

Passo 3: Isolar n . Da igualdade $z_{\alpha/2} \cdot \sigma / \sqrt{n} = E$, multiplicamos ambos os lados por $\sqrt{n}$ e dividimos por E :

$$\sqrt{n} = \frac{z_{\alpha/2} \sigma}{E}$$

Elevando ao quadrado:

$$n = \frac{\sigma^2 z_{\alpha/2}^2}{E^2}$$

Passo 4: Substituir σ por s e arredondar. Quando σ é desconhecido, usamos s de um estudo piloto. Como n deve ser inteiro e precisamos garantir que a margem não seja ultrapassada, arredondamos *para cima*:

$$n = \left\lceil \frac{s^2 z_{\alpha/2}^2}{E^2} \right\rceil$$

Essa expressão revela três relações fundamentais de planejamento: (i) exigir maior confiança aumenta $z_{\alpha/2}$ e, portanto, n ; (ii) maior variabilidade na população (maior s) exige amostras maiores; (iii) reduzir a margem de erro E pela metade *quadruplica* o tamanho amostral necessário, pois E aparece ao quadrado no denominador, um custo que cresce rapidamente.

Qual intervalo de confiança usar? Ao resolver um problema, siga este roteiro:

1. *Qual é o parâmetro de interesse?*
 - Média (μ) ou proporção (p)?
2. *O desvio padrão populacional σ é conhecido?*
3. *A população é aproximadamente normal, ou a amostra é grande o suficiente para uma aproximação assintótica razoável?*
 - A normalidade é especialmente importante para amostras pequenas.
 - A regra $n > 30$ é apenas uma heurística; assimetria intensa e caudas pesadas podem exigir amostras maiores.

Regra geral:

- Se σ é conhecido, use o valor crítico z ; para amostras pequenas, a normalidade populacional ainda é necessária para a validade exata.
- Se σ é desconhecido, use o valor crítico t com $n - 1$ graus de liberdade. Para amostras grandes, t e z são numericamente próximos, e o uso de z com s é uma aproximação comum.

3 Estimação Intervalar para Amostras Pequenas

Quando o tamanho da amostra é pequeno, a construção de intervalos de confiança exige mais cuidado porque a aproximação assintótica pode ser fraca. Para a média μ , quando a população é aproximadamente normal e σ é desconhecido, a *distribuição t de Student* é a ferramenta clássica.

O limiar $n = 30$ é uma heurística para julgar a qualidade de aproximações normais, não uma fronteira entre z e t . Na prática, *sempre que σ for desconhecido*, independentemente de n , o uso da distribuição t é teoricamente mais adequado.

3.1 A distribuição t de Student

A distribuição t de Student foi proposta em um artigo publicado em 1908 por William Gosset. Por questões de confidencialidade com sua empresa, Gosset usou o pseudônimo *Student* nessa publicação. Seu trabalho surgiu da necessidade de realizar inferências estatísticas confiáveis a partir de *amostras pequenas*.

Para entender por que uma nova distribuição é necessária, considere uma amostra aleatória i.i.d.

$$X_1, X_2, \dots, X_n$$

retirada de uma população normal com média μ e desvio padrão σ . Se σ fosse conhecido, poderíamos padronizar a média amostral usando

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

que segue uma distribuição normal padrão. Na prática, porém, σ geralmente é desconhecido. A solução natural é estimá-lo pelo desvio padrão amostral S , obtendo

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Essa substituição parece pequena, mas tem uma consequência importante: enquanto σ é um parâmetro fixo, S depende da amostra e, portanto, também é uma variável aleatória. A estatística acima não segue mais a distribuição normal. A distribuição t de Student surge justamente para descrever essa nova estatística. Uma justificativa geométrica detalhada da expressão acima é apresentada no Apêndice A.


3.1.1 Principais características

- A forma da distribuição t depende do parâmetro $\nu = n - 1$, denominado *número de graus de liberdade*. Os n resíduos satisfazem a restrição $\sum_{i=1}^n (X_i - \bar{X}) = 0$, de modo que apenas $n - 1$ deles podem variar independentemente.
- A distribuição t é simétrica em torno de 0, assim como a distribuição normal padrão.
- Para poucos graus de liberdade, a distribuição t apresenta caudas mais pesadas do que a normal padrão. Isso reflete a incerteza adicional introduzida pela estimação de σ por meio de S .
- À medida que os graus de liberdade aumentam, S torna-se uma estimativa cada vez mais estável de σ e a diferença entre as distribuições t e normal padrão diminui rapidamente.
- Com algumas dezenas de graus de liberdade, os valores críticos da distribuição t já são bastante próximos dos correspondentes valores críticos da normal padrão para os níveis de confiança usuais.
- No limite,

$$t_\nu \longrightarrow \mathcal{N}(0, 1) \quad \text{quando} \quad \nu \rightarrow \infty.$$

- Em aplicações, quando σ é desconhecido, é preferível utilizar a distribuição t independentemente do tamanho da amostra. Para amostras grandes, a diferença numérica em relação ao uso da normal padrão costuma ser pequena.

A figura abaixo mostra as curvas da distribuição t para diferentes valores de ν , sobrepostas à curva da normal padrão. Note como as caudas da distribuição t são progressivamente mais pesadas para valores menores de ν , convergindo para a normal conforme ν cresce.



Distribuições t para $\nu = 2, 5$ e 15 comparadas à normal padrão (tracejado azul). Quanto menor ν , mais pesadas são as caudas. Para $\nu \geq 30$, as curvas tornam-se praticamente indistinguíveis.

Pergunta 7

Compare as estatísticas Z e T :

- Qual é a diferença entre suas fórmulas?
- Por que essa diferença faz com que T siga uma distribuição com caudas mais pesadas do que a normal padrão?
- Na interpretação geométrica, por que há $n - 1$ graus de liberdade para os resíduos e por que a quantidade $U = (n - 1)S^2/\sigma^2$ segue uma qui-quadrado sob normalidade?

3.1.2 Funções do `scipy.stats` relacionadas à distribuição t

Felizmente, não precisamos calcular diretamente com a expressão matemática da função de densidade da distribuição t . A biblioteca `scipy.stats` oferece funções que encapsulam esses cálculos. Os exemplos abaixo pressupõem:

```
from scipy.stats import t
```

Função `t.ppf(q, df)`. Retorna a inversa da CDF (*percent point function*): dado um valor de probabilidade acumulada q , retorna o ponto x tal que $\Pr(T \leq x) = q$. É a função central para obter valores críticos. Por exemplo, `t.ppf(0.975, df=9)` retorna $\approx 2,262$, que é o valor crítico bicaudal de 95% com 9 graus de liberdade, ou seja, 97,5% da área está à esquerda de 2,262.

Função `t.cdf(x, df)`. Retorna a probabilidade acumulada $\Pr(T \leq x)$, ou seja, a área sob a curva à esquerda do ponto x . Útil para calcular probabilidades a partir de valores observados.

Função `t.pdf(x, df)`. Retorna a altura da curva da distribuição (função de densidade) no ponto x . Menos usada em aplicações práticas, mas útil para construção de gráficos.

3.1.3 Exemplos de cálculo com a distribuição t

Exemplo 1: Percentis da t com 5 graus de liberdade. Encontre os percentis 2,5 e 97,5 da distribuição t com 5 graus de liberdade.

```
t.ppf(0.025, 5) # -> aproximadamente -2.571
t.ppf(0.975, 5) # -> aproximadamente 2.571
```

Exemplo 2: Probabilidade de cauda. Uma amostra de tamanho 10 é colhida de uma população normal com $\mu = 4$. Qual é $\Pr(T > 1,833)$, em que $T = (\bar{X} - 4)/(S/\sqrt{10})$? Por definição, $T \sim t_9$ (9 graus de liberdade).

```
1 - t.cdf(1.833, 9) # -> aproximadamente 0.05
```

Portanto $\Pr(T > 1,833) \approx 0,05$.

Exemplo 3: Ponto crítico. Encontre o valor para t_{12} que delimita à sua direita uma área de 0,025.

```
t.ppf(0.975, 12) # -> aproximadamente 2.179
```

3.2 Verificação da suposição de normalidade

A validade exata do IC com distribuição t depende de que a população seja *normal*. Em aplicações, o procedimento costuma ser razoavelmente robusto a desvios moderados de normalidade, especialmente quando n não é muito pequeno. O que deve ser evitado são situações de assimetria intensa ou presença de outliers extremos, que podem distorcer tanto $\bar{x}$ quanto s de forma apreciável. As principais ferramentas para esse diagnóstico são:

- *Q-Q plot (gráfico quantil-quantil):* compara os quantis observados da amostra com os quantis teóricos da distribuição normal. Se os pontos se alinham aproximadamente sobre uma reta, a suposição de normalidade é plausível. Desvios sistemáticos na forma de S ou de pontos isolados nos extremos são sinais de alerta. Em Python: `scipy.stats.probplot(dados, plot=plt)`.
- *Teste de Shapiro-Wilk:* teste formal de normalidade, especialmente adequado para amostras pequenas. Em Python: `scipy.stats.shapiro(dados)`. O resultado inclui uma estatística W (próxima de 1 quando os dados são normais) e um p-valor; p-valores pequenos (convencionalmente $< 0,05$) indicam evidência contra a normalidade.

Nem um Q-Q plot aproximadamente linear nem um p-valor grande no teste de Shapiro-Wilk provam que a população é normal. Eles apenas indicam que os dados observados não fornecem evidência forte contra essa suposição; a decisão também deve considerar o contexto e o mecanismo gerador dos dados.

Para amostras muito pequenas ($n < 10$), mesmo esses diagnósticos têm poder limitado. Nesses casos, o conhecimento do processo gerador dos dados, isto é, o contexto do problema, tende a ser mais informativo do que os testes formais.

3.3 Intervalo de confiança para μ com distribuição t

Para amostras pequenas, o IC para μ é construído de forma análoga ao caso com n grande: partimos da estimativa pontual $\bar{x}$ e somamos/subtraímos uma margem de erro. A diferença é que substituímos o z -score da normal padrão pelo t -score, que é o ponto crítico da distribuição t com $(n-1)$ graus de liberdade correspondente ao nível de confiança desejado:

$$\bar{x} \pm t_{n-1, \alpha/2} \times \frac{s}{\sqrt{n}}$$

O valor $t_{n-1, \alpha/2}$ é o ponto que delimita uma área de $\alpha/2$ na cauda direita da distribuição t_{n-1} . Como a distribuição t tem caudas mais pesadas do que a normal padrão, sempre vale $t_{n-1, \alpha/2} > z_{\alpha/2}$ para qualquer n finito. Isso significa que o IC com distribuição t é *mais largo* do que o IC com z correspondente, e é esse alargamento que reflete honestamente a incerteza adicional devida ao uso de s no lugar de σ .

3.3.1 Procedimento de cálculo

Para construir um IC de nível $(1 - \alpha)$ para μ , com σ desconhecido e população aproximadamente normal:

1. Calcular a média da amostra: $\bar{x} = (X_1 + \cdots + X_n)/n$.
2. Calcular o desvio padrão da amostra: $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2}$.
3. Determinar $t_{n-1, \alpha/2}$, o valor que delimita área $\alpha/2$ na cauda direita da distribuição t .
4. Computar os extremos do IC: $\bar{x} \pm t_{n-1, \alpha/2} \cdot s/\sqrt{n}$.

Pergunta 8

Para cada situação abaixo, identifique o valor crítico $t_{n-1, \alpha/2}$ a ser usado na construção do IC:

- (a) $n = 10$, nível de confiança 95%
- (b) $n = 25$, nível de confiança 90%
- (c) $n = 5$, nível de confiança 99%

3.3.2 Exemplos

Exemplo: resistência de soldaduras. Um técnico em metalurgia fabrica 5 juntas soldadas usando um novo processo e mede a resistência à deformação de cada uma. Os cinco valores (em ksi) são:

56,3 65,4 58,7 70,1 63,9

Suponha que a população seja aproximadamente normal. Determine um IC de 95% para a resistência média.

Para 95% de confiança e $\nu = 5 - 1 = 4$ graus de liberdade, o valor crítico é $t_{4,0,025} \approx 2,776$. A distribuição t_4 tem 95% de sua área entre $-2,776$ e $+2,776$.

A média e o desvio padrão da amostra são $\bar{x} = 62,88$ e $s = 5,484$. Portanto:

$$\bar{x} - 2,776 \cdot \frac{s}{\sqrt{n}} < \mu < \bar{x} + 2,776 \cdot \frac{s}{\sqrt{n}}$$

$$62,88 - 6,81 < \mu < 62,88 + 6,81$$

O IC de 95% é (56,07; 69,69).

Em Python:

```
import numpy as np
from scipy.stats import t

dados = [56.3, 65.4, 58.7, 70.1, 63.9]
n = len(dados)
media = np.mean(dados)
s = np.std(dados, ddof=1)          # ddof=1 para desvio padrao amostral
t_critico = t.ppf(0.975, df=n-1)  # bicaudal 95%
margem = t_critico * s / np.sqrt(n)
print(media - margem, media + margem) # -> (56.07, 69.69)
```

Nota: use sempre $ddof=1$ para que a fórmula do desvio padrão amostral s seja aplicada (divisor $n - 1$), e não a do desvio padrão populacional σ (divisor n).

Exemplo: amostra de 25 elementos. Uma amostra de 25 elementos tem média $\bar{x} = 150$ e desvio padrão $s = 10$. Determine um IC de 90% para a média populacional.

Como σ é desconhecido, usamos a distribuição t com $\nu = n - 1 = 24$ graus de liberdade. Para $(1 - \alpha) = 0,9$, temos $\alpha/2 = 0,05$.

```
t_critico = t.ppf(0.95, df=24) # -> 1.7109
```

Construindo o intervalo:

$$150 \pm 1,7109 \times \frac{10}{\sqrt{25}} = 150 \pm 3,42$$

O IC de 90% é (146,58; 153,42).

Pergunta 9

No Exemplo 1 (soldagem), suponha que os dados fossem $n = 5$ observações de uma distribuição claramente assimétrica (por exemplo, com um valor muito discrepante). O procedimento de IC com distribuição t ainda seria adequado? O que você faria antes de aplicá-lo?

Pergunta 10

Um pesquisador afirma: “Como minha amostra tem $n = 40$, posso usar z em vez de t ”. Avalie essa afirmação. Em que sentido ela está correta? Em que sentido poderia ser melhorada?

Síntese: z ou t ?

Situação	Distribuição usada	Valor crítico
n grande, σ conhecido	Normal padrão	$z_{\alpha/2}$
n grande, σ desconhecido	Normal padrão (aprox.)	$z_{\alpha/2}$ com s
n pequeno, σ desconhecido, pop. normal	t de Student	$t_{n-1, \alpha/2}$

Alerta conceitual: quando σ é desconhecido e usamos s em seu lugar, a estatística correta deixa de seguir a distribuição normal e passa a seguir a distribuição t de Student. Portanto, do ponto de vista teórico, o mais adequado é usar sempre t nesse caso.

Por que então usamos z para n grande? Porque, à medida que n cresce, os valores críticos da distribuição t se aproximam rapidamente dos da normal padrão, tornando a diferença praticamente desprezível na prática.

Recomendação prática: sempre que σ for desconhecido, prefira a distribuição t . Para amostras grandes, usar z com s é uma aproximação comum e geralmente adequada.

3.4 Exercícios de fixação

Os exercícios abaixo cobrem os principais aspectos da estimação intervalar para amostras pequenas: uso da distribuição t , interpretação de graus de liberdade, verificação das suposições e comparação com o caso de amostras grandes.

3.4.1 Aquecimento: distribuição t e valores críticos

Exercício 1: Identificação do valor crítico. Para cada situação abaixo, identifique: (i) o número de graus de liberdade; (ii) o valor crítico $t_{n-1, \alpha/2}$ a usar; (iii) se o valor crítico é maior ou menor do que o correspondente $z_{\alpha/2}$ da normal padrão.

- (a) $n = 8$, nível de confiança 95%.
- (b) $n = 15$, nível de confiança 90%.
- (c) $n = 25$, nível de confiança 99%.
- (d) $n = 30$, nível de confiança 95%.

Solução do Exercício 1. Para cada caso, a quantidade de graus de liberdade é $\nu = n - 1$, e o valor crítico é obtido por `t.ppf(1 - alpha/2, df=nu)`

```
from scipy.stats import t, norm

casos = [(8, 0.05), (15, 0.10), (25, 0.01), (30, 0.05)]
for n, alpha in casos:
```

```

nu = n - 1
t_crit = t.ppf(1 - alpha/2, df=nu)
z_crit = norm.ppf(1 - alpha/2)
print(f"n={n}, gl={nu}, t={t_crit:.3f}, z={z_crit:.3f}")

```

n	Graus de liberdade	Nível	$t_{n-1, \alpha/2}$	$z_{\alpha/2}$
8	7	95%	2,365	1,960
15	14	90%	1,761	1,645
25	24	99%	2,797	2,576
30	29	95%	2,045	1,960

Em todos os casos, $t_{n-1, \alpha/2} > z_{\alpha/2}$. A diferença diminui conforme n aumenta, refletindo a convergência da distribuição t para a normal padrão. Para $n = 30$, os valores já são bastante próximos.

Exercício 2: Efeito dos graus de liberdade na largura do IC. Um pesquisador obteve $\bar{x} = 50$ e $s = 8$ em duas situações distintas: (A) $n = 5$ e (B) $n = 20$. Em ambos os casos, deseja construir um IC de 95% para μ .

- Calcule os valores críticos $t_{n-1, 0,025}$ para cada caso.
- Calcule os erros-padrão $s/\sqrt{n}$ para cada caso.
- Calcule as margens de erro e os intervalos de confiança.
- Compare as larguras dos dois intervalos. O que explica a diferença?

Solução do Exercício 2.

```

import numpy as np
from scipy.stats import t

xbar, s = 50, 8
for n in [5, 20]:
    t_crit = t.ppf(0.975, df=n-1)
    ep = s / np.sqrt(n)
    E = t_crit * ep
    print(f"n={n}: t={t_crit:.3f}, EP={ep:.3f}, E={E:.3f}, IC=({xbar-E:.2f}; {xbar+E:.2f})")

```

n	$t_{n-1, 0,025}$	$s/\sqrt{n}$	Margem E	IC (95%)	Largura
5	2,776	3,578	9,934	(40,07; 59,93)	19,87
20	2,093	1,789	3,745	(46,26; 53,75)	7,49

O IC com $n = 5$ é mais de 2,6 vezes mais largo do que o IC com $n = 20$. Isso ocorre por dois motivos combinados: o valor crítico t é maior (caudas mais pesadas com poucos graus de liberdade) e o erro-padrão é maior (divisor $\sqrt{n}$ menor). Ambos os fatores alargam o intervalo ao mesmo tempo.

3.4.2 Construção de ICs: situações-problema

Exercício 3: Teor de vitamina C em laranjas. Um nutricionista colheu uma amostra de 10 laranjas de um mesmo lote e mediu o teor de vitamina C (em mg por 100 g de suco) de cada uma. Os resultados foram:

52,1 48,7 55,3 50,6 49,2 53,8 47,9 51,4 54,0 50,1

Suponha que o teor de vitamina C nesse lote siga distribuição aproximadamente normal.

- Calcule a média amostral $\bar{x}$ e o desvio padrão amostral s .
- Determine o valor crítico $t_{9,0,025}$ para um IC de 95%.
- Construa o IC de 95% para o teor médio de vitamina C no lote.
- Interprete o intervalo no contexto do problema.

Solução do Exercício 3.

```
import numpy as np
from scipy.stats import t

dados = [52.1, 48.7, 55.3, 50.6, 49.2, 53.8, 47.9, 51.4, 54.0,
         50.1]
n = len(dados)
xbar = np.mean(dados)          # -> 51.31
s = np.std(dados, ddof=1)      # -> 2.365
t_crit = t.ppf(0.975, df=9)    # -> 2.262
E = t_crit * s / np.sqrt(n)    # -> 1.691
print(f"IC 95%: ({xbar-E:.2f}; {xbar+E:.2f})") # -> (49.62;
         53.00)
```

Os resultados são: $\bar{x} = 51,31$ mg, $s = 2,365$ mg, $t_{9,0,025} = 2,262$, margem de erro $E = 1,69$ mg.

O IC de 95% para o teor médio é (49,62; 53,00) mg por 100 g.

Interpretação: com 95% de confiança, o procedimento indica que o teor médio de vitamina C nesse lote está entre aproximadamente 49,6 mg e 53,0 mg por 100 g de suco.

Exercício 4: Tempo de resposta de um sistema. Um engenheiro de software mediu o tempo de resposta (em milissegundos) de um sistema sob teste em 12 requisições aleatórias:

142 138 155 149 160 137 152 145 158 143 151 147

Suponha que os tempos de resposta seguem distribuição aproximadamente normal.

- Construa um IC de 99% para o tempo médio de resposta.
- O valor de 160 ms pertence ao IC? Explique o que essa comparação indica sobre a compatibilidade do valor com os dados, sem tratá-la como um teste formal da exigência unilateral " $\mu < 160$ ".
- O que mudaria no IC se o nível de confiança fosse reduzido para 90%?

Exercício 5: Consumo de combustível. Um fabricante de automóveis testou um novo modelo em 8 percursos padronizados e obteve os seguintes consumos (em km/L):

13,2 12,8 14,1 13,5 12,6 13,9 14,3 13,0

- (a) Verifique graficamente (ou pelo teste de Shapiro-Wilk) se a suposição de normalidade é razoável.
- (b) Construa um IC de 95% para o consumo médio do modelo.
- (c) O fabricante anuncia que o consumo médio é de 14 km/L. O IC é consistente com essa afirmação? O que você diria ao fabricante?

3.4.3 Verificação de suposições e diagnóstico

Exercício 6: Quando usar (ou não usar) a distribuição t . Para cada situação abaixo, indique se o IC com distribuição t é adequado, justificando sua resposta.

- (a) $n = 12$, σ desconhecido, histograma da amostra aproximadamente simétrico e sem outliers.
- (b) $n = 8$, σ desconhecido, amostra com um valor claramente discrepante (outlier extremo).
- (c) $n = 25$, σ desconhecido, Q-Q plot com pontos alinhados ao longo da reta de referência.
- (d) $n = 6$, σ desconhecido, teste de Shapiro-Wilk com p-valor = 0,02.
- (e) $n = 50$, σ desconhecido, distribuição da população claramente assimétrica.

Exercício 7: Impacto de um outlier. Considere os dados do Exercício 3 (teor de vitamina C), mas suponha que o valor 47,9 fosse substituído por 18,0 (erro de medição).

- (a) Recalcule $\bar{x}$ e s com o valor modificado.
- (b) Construa o IC de 95% com o novo conjunto de dados.
- (c) Compare com o IC original. O que o outlier faz com a largura e com a posição do intervalo?
- (d) O uso da distribuição t ainda seria adequado nesse caso? O que você recomendaria fazer antes de prosseguir?

3.4.4 Comparação: distribuição z versus t

Exercício 8: Erro de usar z em amostra pequena. Um analista tem $n = 10$, $\bar{x} = 80$ e $s = 6$. Ele decide (incorretamente) usar $z_{0,025} = 1,960$ em vez de $t_{9,0,025}$ para construir um IC de 95%.

- Calcule o IC usando z (abordagem incorreta).
- Calcule o IC usando t (abordagem correta).
- Qual é a diferença nas margens de erro? Em termos relativos, quanto o IC com z subestima a margem correta?
- Descreva a consequência prática de subestimar a margem de erro: o que acontece com a cobertura real do intervalo?

Solução do Exercício 8.

```
from scipy.stats import t, norm
import numpy as np

n, xbar, s = 10, 80, 6
ep = s / np.sqrt(n)          # -> 1.897

z = norm.ppf(0.975)          # -> 1.960
t9 = t.ppf(0.975, df=9)      # -> 2.262

E_z = z * ep                 # -> 3.718
E_t = t9 * ep                 # -> 4.291
```

Abordagem	Valor crítico	Margem E	IC
Com z (incorreta)	1,960	3,718	(76,28; 83,72)
Com t_9 (correta)	2,262	4,291	(75,71; 84,29)

A margem de erro com z é $\approx 13\%$ menor do que a margem correta. Isso significa que o IC com z é *mais estreito do que deveria*: sua cobertura real é inferior a 95%, o intervalo falha em capturar o parâmetro mais frequentemente do que o nível de confiança nominal garante.

3.4.5 Questões conceituais e de interpretação

Exercício 9: Interpretação do IC com distribuição t . Um pesquisador construiu o seguinte IC de 95% para a duração média (em dias) de uma determinada fase de um processo industrial, com base em $n = 8$ observações:

$$IC_{95\%}(\mu) = (12,3; 18,7) \text{ dias}$$

Avalie cada afirmação abaixo, indicando se está *correta* ou *incorreta*, e justificando sua resposta.

- (a) “Há 95% de probabilidade de que a duração média verdadeira esteja entre 12,3 e 18,7 dias”.
- (b) “Se o procedimento fosse repetido muitas vezes com amostras de tamanho 8, aproximadamente 95% dos intervalos construídos conteriam o verdadeiro valor de μ ”.
- (c) “A estimativa pontual para μ é de 15,5 dias”.
- (d) “A margem de erro desse IC é de 3,2 dias”.
- (e) “Com 99% de confiança, o IC seria mais estreito do que esse”.

Exercício 10: Planejamento com amostra pequena. Um laboratório deseja estimar a concentração média de um reagente em lotes de produção. Com base em um estudo piloto de 6 lotes, obteve-se $s = 4,2$ mg/L. O laboratório quer um IC de 95% com margem de erro de no máximo 3 mg/L.

- (a) Usando a fórmula de tamanho amostral para μ com $z_{0,025} = 1,96$, calcule o n necessário.
- (b) Mantendo a estimativa piloto s fixa, discuta: uma versão do planejamento que use um valor crítico t tende a exigir um n maior ou menor do que a fórmula com z ? Por quê? Comente também por que essa comparação ainda é aproximada.
- (c) Se o laboratório coletar exatamente o n calculado no item (a), o IC resultante terá margem de erro exatamente igual a 3 mg/L? Justifique.

4 Resumo

A tabela abaixo sintetiza os principais intervalos de confiança estudados:

<i>Parâmetro</i>	<i>Fórmula do IC</i>	<i>Condições</i>
Média μ (σ conhecido)	$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$	Obs. i.i.d.; pop. normal, ou n grande com variância finita
Média μ (σ desconhecido, aproximação z)	$\bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$	Obs. i.i.d.; n grande e aproximação normal razoável
Proporção p (amostra grande)	$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	$n\hat{p} \geq 10$ e $n(1-\hat{p}) \geq 10$
Média μ (σ desconhecido, distribuição t)	$\bar{x} \pm t_{n-1, \alpha/2} \cdot \frac{s}{\sqrt{n}}$	Pop. aprox. normal; resultado exato sob normalidade

Intervalos de confiança são preferíveis a estimativas pontuais porque quantificam a incerteza da estimação. O nível de confiança não é a probabilidade de um intervalo já calculado conter o parâmetro, mas sim a taxa de cobertura do procedimento ao longo de repetições amostrais. Quanto maior o tamanho amostral, menor a margem de erro e mais precisa a estimativa.

A Fundamentos geométricos e probabilísticos da distribuição t

Antes de observar os dados, tanto a média quanto a variância amostral são variáveis aleatórias:

$$\bar{X} = \frac{X_1 + X_2 + \cdots + X_n}{n} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Para compreender por que o desvio padrão amostral S varia de uma amostra para outra e como essa variabilidade se relaciona com $\bar{X}$, é útil examinar geometricamente como uma amostra pode ser decomposta em uma parte associada à média e outra associada aos desvios em torno dessa média.

A.0.1 Uma ponte geométrica: média e resíduos

Considere inicialmente uma amostra de tamanho 3. Podemos representar

$$\mathbf{X} = (X_1, X_2, X_3)$$

como um vetor aleatório em um espaço tridimensional. Geometricamente, esse vetor pode ser visualizado como uma seta que parte da origem e termina no ponto (X_1, X_2, X_3) . Como os valores observados mudam de uma amostra para outra, em geral também mudam a direção e o comprimento desse vetor.

Por exemplo, suponha que uma amostra observada seja

$$\mathbf{X} = (2, 5, 8).$$

A média dessa amostra é

$$\bar{X} = \frac{2 + 5 + 8}{3} = 5.$$

A ideia central desta seção é perceber que esse ponto pode ser separado em duas partes: uma que representa apenas a média da amostra e outra que representa como as observações se afastam dessa média.

Considere a reta diagonal

$$\mathcal{D} = \{(a, a, a) : a \in \mathbb{R}\}.$$

Ela reúne todos os pontos cujas três coordenadas são iguais, como

$$(0, 0, 0), \quad (1, 1, 1), \quad (5, 5, 5).$$

A projeção ortogonal de $\mathbf{X}$ sobre essa reta é o ponto de $\mathcal{D}$ mais próximo de $\mathbf{X}$. Esse ponto é

$$P = (\bar{X}, \bar{X}, \bar{X}).$$

No exemplo,

$$P = (5, 5, 5).$$

Assim, a posição de P ao longo da diagonal contém exatamente a informação sobre a média amostral. Se duas amostras possuem a mesma média, suas projeções sobre $\mathcal{D}$ coincidem.

A diferença entre o ponto observado $\mathbf{X}$ e sua projeção P é o *vetor de resíduos*:

$$\mathbf{R} = \mathbf{X} - P = (X_1 - \bar{X}, X_2 - \bar{X}, X_3 - \bar{X}).$$

No exemplo,

$$\mathbf{R} = (2, 5, 8) - (5, 5, 5) = (-3, 0, 3).$$

Portanto,

$$(2, 5, 8) = (5, 5, 5) + (-3, 0, 3).$$

É exatamente isso que queremos dizer quando afirmamos que a amostra foi *decomposta*: escrevemos o vetor original como a soma de dois vetores com interpretações diferentes.

Em geral,

$$\mathbf{X} = (\bar{X}, \bar{X}, \bar{X}) + \mathbf{R}$$

ou, escrevendo $\mathbf{1} = (1, 1, 1)$,

$$\mathbf{X} = \bar{X} \mathbf{1} + \mathbf{R}.$$

A primeira parcela, denotada por $\bar{X} \mathbf{1}$, representa a parte da amostra associada à sua *localização média* (ver Eq. 1).

$$\bar{X} \mathbf{1} = (\bar{X}, \bar{X}, \bar{X}) \quad (1)$$

A segunda parcela, denominada *vetor residual*, e denotada por $\mathbf{R}$, representa como cada observação se desvia dessa média (veja a Eq. 2).

$$\mathbf{R} = (X_1 - \bar{X}, X_2 - \bar{X}, X_3 - \bar{X}) \quad (2)$$

Podemos resumir essa ideia como

$$\text{amostra} = \text{componente associada à média} + \text{componente residual}.$$

A Figura 1 ilustra geometricamente essa separação.

Há uma propriedade importante nessa decomposição. O vetor residual é perpendicular à direção da diagonal. De fato, a diagonal tem direção

$$\mathbf{1} = (1, 1, 1),$$

e o produto interno entre $\mathbf{1}$ e $\mathbf{R}$ é

$$\mathbf{1}^\top \mathbf{R} = (X_1 - \bar{X}) + (X_2 - \bar{X}) + (X_3 - \bar{X}).$$

Como

$$X_1 + X_2 + X_3 = 3\bar{X},$$

temos




Figura 1: Representação para $n = 3$. A reta azul contém as amostras com observações todas iguais. O ponto azul é a projeção $(\bar{X}, \bar{X}, \bar{X})$ da amostra sobre essa reta; o plano verde contém os vetores com a mesma média, e o segmento vermelho é o vetor de resíduos.

$$\mathbf{1}^\top \mathbf{R} = 0.$$

Portanto, as duas parcelas da decomposição são ortogonais: a componente associada à média aponta ao longo da diagonal, enquanto o vetor residual aponta em uma direção perpendicular a ela.

A Figura 2 apresenta uma versão simplificada dessa geometria. O vetor amostral $\mathbf{X}$ pode ser visto como o resultado da soma de dois vetores: sua projeção P sobre a diagonal $\mathcal{D}$, que representa a componente associada à média amostral, e o vetor residual $\mathbf{R}$, que representa o afastamento da amostra em relação a essa diagonal. Como $\mathbf{R}$ é perpendicular a $\mathcal{D}$, a decomposição

$$\mathbf{X} = P + \mathbf{R}$$

separa geometricamente duas informações distintas contidas na amostra: sua localização média e sua dispersão em torno dessa média.




Figura 2: Visualização esquemática da decomposição da amostra. O vetor amostral $\mathbf{X}$ pode ser escrito como a soma de sua projeção $P = (\bar{X}, \bar{X}, \bar{X})$ sobre a diagonal $\mathcal{D}$ e do vetor residual $\mathbf{R} = \mathbf{X} - P$, perpendicular à diagonal.

Essa ortogonalidade permite interpretar cada amostra como contendo dois tipos distintos de informação:

- a posição ao longo da diagonal informa a média amostral;
- o afastamento em relação à diagonal informa a dispersão das observações em torno dessa média.

Para entender onde aparecem os graus de liberdade, observe novamente o vetor de resíduos:

$$\mathbf{R} = (R_1, R_2, R_3) = (X_1 - \bar{X}, X_2 - \bar{X}, X_3 - \bar{X}).$$

Seus componentes satisfazem necessariamente

$$R_1 + R_2 + R_3 = 0.$$

Isso significa que os três resíduos não podem ser escolhidos livremente. No caso $n = 3$, embora $\mathbf{R}$ tenha três componentes, apenas duas podem variar independentemente. Por exemplo, considere que $R_1 = -3$ e $R_2 = 0$. Então o terceiro resíduo é obrigatoriamente $R_3 = 3$.

Depois que dois resíduos são conhecidos, o terceiro já está determinado. Portanto, apesar de termos três resíduos, existem apenas dois valores que podem variar independentemente. Dizemos que os resíduos possuem

$$2 = 3 - 1$$

graus de liberdade.

A mesma conclusão aparece geometricamente. Todo ponto com uma determinada média $\bar{X}$ satisfaz

$$x_1 + x_2 + x_3 = 3\bar{X}.$$

Assim, os pontos com essa mesma média formam o plano

$$H_{\bar{X}} = \{(x_1, x_2, x_3) : x_1 + x_2 + x_3 = 3\bar{X}\}.$$

Esse plano é perpendicular à diagonal $\mathcal{D}$. Mover-se dentro dele altera os valores individuais x_1, x_2, x_3 , mas mantém a média dos valores x_1, x_2 e x_3 permanece constante. Por exemplo, os pontos

$$(2, 5, 8), \quad (4, 5, 6), \quad (3, 3, 9)$$

possuem todos média igual a 5 e, portanto, pertencem ao mesmo plano

$$x_1 + x_2 + x_3 = 15.$$

Eles ocupam posições diferentes no plano porque possuem diferentes padrões de dispersão em torno da mesma média.

Os próprios vetores de resíduos pertencem ao plano paralelo que passa pela origem:

$$H_0 = \{(r_1, r_2, r_3) : r_1 + r_2 + r_3 = 0\}.$$

O plano $H_{\bar{X}}$ é simplesmente esse espaço residual deslocado até o ponto

$$P = (\bar{X}, \bar{X}, \bar{X}) :$$

$$H_{\bar{X}} = P + H_0.$$

Como H_0 é um plano em $\mathbb{R}^3$, ele possui dimensão 2. Essa é a interpretação geométrica dos dois graus de liberdade: depois que uma dimensão do espaço é usada para representar a média, restam duas direções independentes nas quais as observações podem variar sem alterar essa média.

Antes de seguir adiante, é importante distinguir quais objetos são fixos e quais são aleatórios. O vetor $\mathbf{X}$ é aleatório; conseqüentemente, $\bar{X}$, o ponto P , o vetor $\mathbf{R}$ e o plano $H_{\bar{X}}$ também dependem da amostra e são aleatórios. Já a direção $\mathbf{1}$ e o espaço residual

$$H_0 = \left\{ (r_1, \dots, r_n) : \sum_{i=1}^n r_i = 0 \right\}$$

são estruturas geométricas fixas.

De uma amostra para outra, a projeção P muda de posição ao longo da direção da média e o plano de média constante se desloca paralelamente a si mesmo. A Figura 1 representa apenas uma realização possível desse processo aleatório.

A dispersão das observações também possui uma interpretação geométrica direta. A norma $\|\mathbf{R}\|$ é exatamente a distância euclidiana entre o ponto amostral $\mathbf{X}$ e sua projeção P sobre a diagonal $\mathcal{D}$. No exemplo,

$$\mathbf{R} = (-3, 0, 3),$$

portanto,

$$\|\mathbf{R}\|^2 = (-3)^2 + 0^2 + 3^2 = 18.$$

Em geral, para $n = 3$,

$$\|\mathbf{R}\|^2 = \sum_{i=1}^3 (X_i - \bar{X})^2.$$

Essa quantidade é a *soma dos quadrados dos resíduos*. Ela mede quão distante a amostra está da diagonal $\mathcal{D}$, formada pelos pontos em que todas as observações têm o mesmo valor, sem ainda realizar qualquer normalização.

Assim:

- se todas as observações forem iguais, então $\mathbf{X}$ está sobre a diagonal e $\mathbf{R} = \mathbf{0}$;
- quanto mais as observações diferirem entre si, mais distante $\mathbf{X}$ estará da diagonal e maior será $\|\mathbf{R}\|^2$.

Por exemplo,

$$(5, 5, 5)$$

possui média 5 e está exatamente sobre a diagonal, enquanto

$$(2, 5, 8)$$

possui a mesma média, mas está afastado dela. A diferença entre essas duas amostras não está em sua média, mas em sua dispersão.

No caso geral, para uma amostra de tamanho n ,

$$\mathbf{X} = (X_1, \dots, X_n) \in \mathbb{R}^n$$

e podemos escrever

$$\mathbf{X} = \bar{X} \mathbf{1} + \mathbf{R},$$

em que

$$\mathbf{1} = (1, \dots, 1)$$

e

$$\mathbf{R} = (X_1 - \bar{X}, \dots, X_n - \bar{X}).$$

A componente $\bar{X} \mathbf{1}$ pertence à reta gerada por $\mathbf{1}$ e contém a informação sobre a média. O vetor residual pertence ao espaço perpendicular a essa reta e satisfaz

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

Há n resíduos, mas uma restrição linear entre eles. Consequentemente, apenas $n - 1$ resíduos podem variar independentemente. Geometricamente, o espaço residual possui dimensão $n - 1$.

Temos, portanto, a decomposição dimensional abaixo, na qual uma dimensão está associada à média e $n - 1$ dimensões estão associadas aos resíduos.

$$n = 1 + (n - 1)$$

A soma quadrática residual é

$$Q = \|\mathbf{R}\|^2 = \sum_{i=1}^n (X_i - \bar{X})^2.$$

Como a variação residual ocorre em um espaço de dimensão $n - 1$, a soma quadrática

$$Q = \sum_{i=1}^n (X_i - \bar{X})^2$$

está associada a $n - 1$ graus de liberdade. Essa observação explica a presença de $n - 1$ no denominador da definição usual da variância amostral:

$$S^2 = \frac{Q}{n - 1} = \frac{1}{n - 1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

O denominador $n - 1$ não aparece de forma arbitrária. Geometricamente, ele corresponde ao número de graus de liberdade associados aos resíduos, isto é, ao número de direções independentes nas quais os desvios em torno da média podem variar. Probabilisticamente, essa mesma normalização faz com que

$$E[S^2] = \sigma^2,$$

de modo que S^2 seja um estimador não viesado da variância populacional. Como

$$Q = \|\mathbf{R}\|^2 = \sum_{i=1}^n (X_i - \bar{X})^2$$

e

$$S^2 = \frac{Q}{n-1},$$

temos

$$\boxed{\|\mathbf{R}\|^2 = (n-1)S^2.}$$

Chegamos, portanto, a uma interpretação geométrica da variância amostral: ela está diretamente relacionada ao comprimento quadrático do vetor residual, isto é, ao afastamento da amostra em relação à direção associada à média.

A geometria também mostrou que esse vetor residual pertence a um espaço de dimensão $n-1$. Falta agora responder a uma questão probabilística: *como varia o comprimento desse vetor de uma amostra para outra?*

Sob a hipótese de normalidade, essa pergunta terá uma resposta particularmente simples. Veremos que o comprimento quadrático padronizado do vetor residual,

$$\frac{\|\mathbf{R}\|^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2},$$

segue uma distribuição qui-quadrado com $n-1$ graus de liberdade.

A.0.2 Da geometria à distribuição qui-quadrado

Na subseção anterior, vimos que o vetor amostral pode ser escrito como

$$\mathbf{X} = \bar{X} \mathbf{1} + \mathbf{R},$$

separando a informação da amostra em duas partes ortogonais:

- uma componente na direção de $\mathbf{1} = (1, \dots, 1)$, associada à média amostral;
- uma componente residual $\mathbf{R}$, pertencente a um espaço de dimensão $n-1$ e associada à dispersão em torno da média.

A geometria, por si só, já explicou por que existem $n-1$ graus de liberdade residuais. Agora acrescentaremos a hipótese de normalidade para descobrir a distribuição probabilística do comprimento desse vetor residual.

Suponha que

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2).$$

Padronizando cada observação em relação aos parâmetros populacionais, obtemos

$$W_i = \frac{X_i - \mu}{\sigma}, \quad i = 1, \dots, n.$$

Como as observações são independentes e normais,

$$W_1, \dots, W_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1).$$

Podemos reunir essas variáveis em um único vetor:

$$\mathbf{W} = \frac{\mathbf{X} - \mu \mathbf{1}}{\sigma} = (W_1, \dots, W_n).$$

A função densidade de $\mathbf{W}$ possui uma propriedade especial: seu valor em um ponto $\mathbf{w}$ depende apenas da distância $\|\mathbf{w}\|$ desse ponto à origem, e não de sua direção.

A Figura 3 ilustra essa propriedade no caso bidimensional. As curvas de nível da distribuição são círculos centrados na origem, de modo que a função densidade assume o mesmo valor em todos os pontos situados a uma mesma distância da origem. Como a orientação dos eixos não altera essas curvas de nível, podemos rotacionar o sistema de coordenadas sem modificar a forma da distribuição. Essa invariância é o que permite escolher um novo eixo u_1 alinhado à direção associada à média e um eixo ortogonal u_2 em uma direção residual.




Figura 3: Ilustração bidimensional da simetria esférica da normal multivariada padrão. As curvas de nível são círculos centrados na origem, mostrando que o valor da função densidade depende apenas da distância à origem. Por isso, uma rotação do sistema de coordenadas não altera a forma da distribuição. Essa invariância permite escolher um novo sistema ortonormal de eixos: um eixo u_1 na direção associada à média e um eixo ortogonal u_2 em uma direção residual.

Como a distribuição de $\mathbf{W}$ é esfericamente simétrica, podemos escolher um novo sistema de coordenadas ortonormal sem alterar a forma da distribuição. Escolhemos um dos eixos na direção

$$\frac{\mathbf{1}}{\sqrt{n}},$$

associada à média amostral, e os outros $n - 1$ eixos dentro do espaço residual

$$H_0 = \left\{ \mathbf{r} \in \mathbb{R}^n : \sum_{i=1}^n r_i = 0 \right\},$$

que é ortogonal a essa direção.

A coordenada de $\mathbf{W}$ no primeiro eixo é

$$\frac{\mathbf{1}^\top}{\sqrt{n}} \mathbf{W} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma}.$$

Como $\sum_{i=1}^n X_i = n\bar{X}$, obtemos

$$\frac{\mathbf{1}^\top}{\sqrt{n}} \mathbf{W} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}.$$

Denotando essa coordenada por Z ,

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

e, como esperado,

$$Z \sim \mathcal{N}(0, 1).$$

Portanto, a estatística Z possui uma interpretação geométrica precisa: ela é a coordenada padronizada do vetor amostral na direção associada à média.

Consideremos agora a componente residual. Como o espaço residual tem dimensão $n - 1$, podemos escolher nele $n - 1$ eixos ortonormais. Denotemos por

$$Y_1, \dots, Y_{n-1}$$

as coordenadas da componente residual padronizada nesses eixos.

Como passamos do sistema original de coordenadas para outro sistema ortonormal, apenas realizamos uma rotação ou reflexão do vetor normal multivariado padrão. A distribuição permanece a mesma. Consequentemente,

$$Y_1, \dots, Y_{n-1} \stackrel{\text{ind.}}{\sim} \mathcal{N}(0, 1),$$

e essas coordenadas também são independentes de Z .

Esse é o ponto em que a hipótese de normalidade se torna essencial. A geometria garante a *ortogonalidade* entre a direção da média e o espaço residual; no caso normal, essa ortogonalidade se traduz também em *independência probabilística* das respectivas coordenadas.

Considere agora o comprimento quadrático da componente residual padronizada. Em coordenadas ortonormais, ele é

$$Y_1^2 + \dots + Y_{n-1}^2.$$

Por definição, a soma dos quadrados de ν variáveis normais padrão independentes segue uma distribuição qui-quadrado com ν graus de liberdade. Portanto,

$$U = Y_1^2 + \cdots + Y_{n-1}^2 \sim \chi_{n-1}^2.$$

Mas uma mudança para eixos ortonormais não altera comprimentos. Logo, essa soma de quadrados é também o comprimento quadrático do vetor residual original depois de dividido por σ :

$$U = \frac{\|\mathbf{R}\|^2}{\sigma^2}.$$

Na subseção anterior, definimos

$$Q = \|\mathbf{R}\|^2 = \sum_{i=1}^n (X_i - \bar{X})^2$$

e, usando os $n - 1$ graus de liberdade residuais,

$$S^2 = \frac{Q}{n - 1}.$$

Portanto,

$$Q = (n - 1)S^2,$$

e podemos escrever

$$U = \frac{Q}{\sigma^2} = \frac{(n - 1)S^2}{\sigma^2}.$$

Concluimos que

$$\frac{(n - 1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Observe a sequência lógica: os $n - 1$ graus de liberdade não surgiram da distribuição qui-quadrado. Eles já haviam sido obtidos geometricamente, como a dimensão do espaço residual. A normalidade acrescentou uma nova informação: nesse espaço de dimensão $n - 1$, as coordenadas padronizadas podem ser representadas por $n - 1$ normais padrão independentes; por isso, seu comprimento quadrático segue uma χ_{n-1}^2 .

A variável U é, portanto, o comprimento quadrático padronizado do vetor residual. Dividindo-a pelos graus de liberdade,

$$\frac{U}{n - 1} = \frac{S^2}{\sigma^2}.$$

Essa razão indica quão grande é a dispersão observada na amostra em relação à variabilidade populacional σ^2 .

Finalmente, como Z é a coordenada na direção da média e U depende apenas das coordenadas do espaço residual, temos, sob normalidade,

$$Z \text{ e } U \text{ são independentes.}$$

Essa independência será o ingrediente decisivo para obter a distribuição t de Student.

A.0.3 Da qui-quadrado à distribuição t

Podemos agora retornar ao problema que motivou toda essa construção.

Se o desvio padrão populacional σ fosse conhecido, a média amostral poderia ser padronizada por

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Na prática, porém, σ geralmente é desconhecido. Precisamos substituí-lo pelo desvio padrão amostral S .

A subseção anterior caracterizou probabilisticamente a variabilidade de S^2 por meio da relação

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Dividindo por $n-1$,

$$\frac{U}{n-1} = \frac{S^2}{\sigma^2}.$$

Tomando a raiz quadrada,

$$\boxed{\sqrt{\frac{U}{n-1}} = \frac{S}{\sigma}}.$$

Assim, a razão S/σ mede quanto o desvio padrão observado na amostra difere do desvio padrão verdadeiro da população.

Temos, portanto, duas variáveis aleatórias:

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim \mathcal{N}(0, 1)$$

e

$$U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

que, como vimos, são independentes.

Considere agora

$$T = \frac{Z}{\sqrt{U/(n-1)}}.$$

Substituindo as expressões anteriores,

$$T = \frac{\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}}{S/\sigma}.$$

O parâmetro σ aparece tanto no numerador quanto no denominador e, portanto, se cancela:

$$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S}.$$

Equivalentemente,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Esse cancelamento é o ponto central da construção: obtivemos uma estatística cuja distribuição pode ser conhecida mesmo sem conhecermos o parâmetro populacional σ .

A distribuição t de Student é definida precisamente a partir dessa situação. Se

$$Z \sim \mathcal{N}(0, 1), \quad U \sim \chi_\nu^2,$$

e Z e U são independentes, então

$$\frac{Z}{\sqrt{U/\nu}}$$

segue uma distribuição t de Student com ν graus de liberdade.

No nosso problema,

$$\nu = n - 1.$$

Logo,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Assim, a distribuição t não é uma correção arbitrária introduzida simplesmente porque a amostra é pequena. Ela surge como consequência de três fatos:

1. a componente da amostra associada à média produz uma variável $Z \sim \mathcal{N}(0, 1)$;
2. a componente residual possui $n - 1$ graus de liberdade e, sob normalidade, seu comprimento quadrático padronizado satisfaz

$$U \sim \chi_{n-1}^2;$$

3. essas duas quantidades são independentes.

A combinação

$$\frac{Z}{\sqrt{U/(n-1)}}$$

elimina o σ desconhecido e produz exatamente a distribuição t_{n-1} .

Essa construção também explica por que a distribuição t possui caudas mais pesadas do que a normal padrão.

Se σ fosse conhecido, usaríamos

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}},$$

cujo denominador é fixo.

Quando σ é desconhecido, usamos

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}},$$

e agora o denominador também varia de uma amostra para outra.

Como S varia de uma amostra para outra, em algumas amostras teremos $S < \sigma$ e, em outras, $S > \sigma$. Quando ocorre $S < \sigma$,

$$\frac{S}{\sigma} < 1,$$

ou, equivalentemente,

$$\sqrt{\frac{U}{n-1}} < 1.$$

Dividir Z por um valor menor que 1 aumenta seu módulo. Assim, valores grandes de $|T|$ ocorrem com maior frequência do que valores igualmente grandes de $|Z|$. Essa variabilidade adicional do denominador é o que produz as caudas mais pesadas da distribuição t .

Para amostras pequenas, temos poucos graus de liberdade residuais e S^2 pode variar consideravelmente de uma amostra para outra. À medida que n aumenta, porém,

$$\frac{U}{n-1} = \frac{S^2}{\sigma^2}$$

torna-se cada vez mais concentrado em torno de 1. Consequentemente,

$$\sqrt{\frac{U}{n-1}} = \frac{S}{\sigma}$$

fica cada vez mais próximo de 1, e

$$T = \frac{Z}{\sqrt{U/(n-1)}}$$

fica cada vez mais próximo de Z . Por isso,

$$t_{n-1} \longrightarrow \mathcal{N}(0, 1)$$

quando n cresce.

Depois que a amostra é observada, as variáveis aleatórias $\bar{X}$ e S assumem valores concretos, denotados por $\bar{x}$ e s . São esses valores observados que utilizamos nos cálculos numéricos.

Podemos, portanto, resumir a diferença entre as duas padronizações:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}, \quad T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Em Z , a escala σ é conhecida e fixa. Em T , ela é estimada por S , que varia de amostra para amostra. A distribuição t incorpora exatamente essa incerteza adicional.