

# Testes de Hipóteses

## Nota de Aula 04

Prof. Eduardo Bezerra

## Sumário

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Fundamentos do Teste de Hipóteses</b>                          | <b>3</b>  |
| 1.1      | Motivação . . . . .                                               | 3         |
| 1.2      | Hipóteses nula e alternativa . . . . .                            | 4         |
| 1.2.1    | Direção da hipótese alternativa . . . . .                         | 5         |
| 1.2.2    | A forma da hipótese nula . . . . .                                | 6         |
| 1.2.3    | Exemplos de formulação . . . . .                                  | 6         |
| 1.3      | A lógica do teste de hipóteses . . . . .                          | 7         |
| 1.4      | Etapas de um teste de hipóteses . . . . .                         | 9         |
| 1.5      | Estatística de teste . . . . .                                    | 10        |
| 1.6      | O $p$ -valor . . . . .                                            | 11        |
| 1.6.1    | Ilustração com o experimento da moeda . . . . .                   | 13        |
| 1.6.2    | A direção da hipótese alternativa e o $p$ -valor . . . . .        | 14        |
| 1.7      | Nível de significância e regra de decisão . . . . .               | 15        |
| 1.7.1    | Regra de decisão baseada no $p$ -valor . . . . .                  | 15        |
| 1.7.2    | Significância estatística e relevância prática . . . . .          | 16        |
| 1.7.3    | Conexão com intervalos de confiança . . . . .                     | 16        |
| 1.8      | Tipos de erro . . . . .                                           | 17        |
| 1.8.1    | Um exemplo: teste diagnóstico . . . . .                           | 18        |
| 1.8.2    | O compromisso entre os dois tipos de erro . . . . .               | 18        |
| 1.9      | Exercícios de fixação . . . . .                                   | 19        |
| 1.9.1    | Formulação de hipóteses . . . . .                                 | 19        |
| 1.9.2    | Interpretação do $p$ -valor e regra de decisão . . . . .          | 20        |
| 1.9.3    | Erros tipo I e tipo II . . . . .                                  | 20        |
| 1.9.4    | Etapas do teste de hipóteses . . . . .                            | 20        |
| <b>2</b> | <b>O <math>z</math>-Teste</b>                                     | <b>21</b> |
| 2.1      | Passos do $z$ -teste . . . . .                                    | 21        |
| 2.2      | Condições de aplicabilidade . . . . .                             | 21        |
| 2.3      | Exemplos . . . . .                                                | 22        |
| 2.3.1    | Exemplo 1: Acidentes de trabalho (unicaudal à esquerda) . . . . . | 22        |
| 2.3.2    | Exemplo 2: Índice de nicotina (unicaudal à esquerda) . . . . .    | 22        |
| 2.3.3    | Exemplo 3: Tempo de aprendizado (unicaudal à esquerda) . . . . .  | 23        |
| 2.3.4    | Exemplo 4: Peso de pinguins (bicaudal) . . . . .                  | 23        |
| 2.4      | Implementação em Python . . . . .                                 | 24        |
| 2.5      | Exercícios de fixação . . . . .                                   | 25        |
| 2.5.1    | Tempo de processamento de pedidos . . . . .                       | 25        |
| 2.5.2    | Consumo de energia elétrica . . . . .                             | 25        |
| 2.5.3    | Teor de cafeína em bebidas . . . . .                              | 25        |
| 2.5.4    | Condições de aplicabilidade . . . . .                             | 26        |

|          |                                                                        |           |
|----------|------------------------------------------------------------------------|-----------|
| <b>3</b> | <b>O <math>t</math>-Teste</b>                                          | <b>26</b> |
| 3.1      | $t$ -teste para uma amostra . . . . .                                  | 27        |
| 3.1.1    | Passos do $t$ -teste para uma amostra . . . . .                        | 27        |
| 3.1.2    | Condições de aplicabilidade . . . . .                                  | 28        |
| 3.2      | Exemplos . . . . .                                                     | 28        |
| 3.2.1    | Exemplo 1: Máquina de garrafas (retomada) . . . . .                    | 28        |
| 3.2.2    | Exemplo 2: Peso de recém-nascidos com SIDS (bicaudal) . . . . .        | 28        |
| 3.3      | $t$ -teste para amostras pareadas . . . . .                            | 29        |
| 3.3.1    | Hipóteses . . . . .                                                    | 29        |
| 3.3.2    | Exemplo: Eficiência de um programa de treinamento . . . . .            | 30        |
| 3.4      | $t$ -teste para duas amostras independentes . . . . .                  | 30        |
| 3.4.1    | Teste de Welch . . . . .                                               | 30        |
| 3.4.2    | Condições de aplicabilidade . . . . .                                  | 31        |
| 3.5      | Exemplos . . . . .                                                     | 31        |
| 3.5.1    | Exemplo 1: Níveis de colesterol em dois grupos . . . . .               | 31        |
| 3.5.2    | Exemplo 2: Desempenho por gênero em teste . . . . .                    | 32        |
| 3.6      | Resumo das funções <code>scipy.stats</code> para $t$ -testes . . . . . | 32        |
| 3.7      | Exercícios de fixação . . . . .                                        | 33        |
| 3.7.1    | Vida útil de baterias ( $t$ -teste para uma amostra) . . . . .         | 33        |
| 3.7.2    | Programa de emagrecimento ( $t$ -teste pareado) . . . . .              | 33        |
| 3.7.3    | Desempenho acadêmico ( $t$ -teste independente) . . . . .              | 34        |
| 3.7.4    | Escolha do tipo de $t$ -teste . . . . .                                | 34        |
| <b>4</b> | <b>Poder do Teste</b>                                                  | <b>34</b> |
| 4.1      | Definição . . . . .                                                    | 34        |
| 4.2      | Fatores que afetam o poder . . . . .                                   | 36        |
| 4.3      | Impacto da variabilidade no poder . . . . .                            | 36        |
| 4.3.1    | Simulação: poder vs. variabilidade em Python . . . . .                 | 36        |
| 4.4      | Relação entre poder, erro tipo I e tamanho amostral . . . . .          | 37        |
| 4.5      | Exercícios de fixação . . . . .                                        | 38        |
| 4.5.1    | Poder e tamanho amostral . . . . .                                     | 38        |
| 4.5.2    | Interpretação de resultado não significativo . . . . .                 | 38        |
| 4.5.3    | Trade-off entre erros tipo I e tipo II . . . . .                       | 38        |
| 4.5.4    | Fatores que afetam o poder: análise integrada . . . . .                | 39        |
| <b>5</b> | <b>Resumo</b>                                                          | <b>39</b> |
| <b>6</b> | <b>Diagnóstico e Consolidação Conceitual</b>                           | <b>39</b> |
| 6.1      | Quiz diagnóstico: erros clássicos . . . . .                            | 40        |
| 6.2      | Questões conceituais . . . . .                                         | 40        |

## Objetivos

Ao final da leitura, você deve ser capaz de:

### Fundamentos do teste de hipóteses

- Explicar o propósito de um teste de hipóteses e distingui-lo da estimação intervalar.
- Formular corretamente as hipóteses nula e alternativa para problemas uni e bicaudais.
- Interpretar o  $p$ -valor e aplicar a regra de decisão baseada no nível de significância  $\alpha$ .
- Identificar e distinguir os erros de tipo I e de tipo II, compreendendo suas consequências.

### $z$ -teste para a média ★

- Aplicar o  $z$ -teste quando o desvio padrão populacional  $\sigma$  é conhecido.
- Computar o  $z$ -escore e o  $p$ -valor para testes unilaterais e bilaterais.
- Verificar as condições de aplicabilidade do  $z$ -teste.

### $t$ -teste para a média ★

- Aplicar o  $t$ -teste para uma amostra quando  $\sigma$  é desconhecido.
- Distinguir o  $t$ -teste para uma amostra, para amostras pareadas e para duas amostras independentes.
- Computar o  $t$ -escore, os graus de liberdade e o  $p$ -valor correspondente.
- Verificar as condições de aplicabilidade do  $t$ -teste.

### Poder do teste

- Definir o poder de um teste e relacioná-lo ao erro tipo II.
- Identificar os fatores que influenciam o poder: tamanho da amostra, nível de significância, tamanho do efeito e variabilidade.

**Roteiro de leitura.** Estas notas estão organizadas em quatro partes. A Seção 1 apresenta os fundamentos do teste de hipóteses: motivação, definições, tipos de erro,  $p$ -valor e nível de significância. A Seção 2 trata do  $z$ -teste, aplicável quando  $\sigma$  é conhecido e as condições de normalidade ou de aproximação pelo TLC são atendidas. A Seção 3 apresenta o  $t$ -teste nas suas três variantes: uma amostra, amostras pareadas e duas amostras independentes. A Seção 4 discute o poder do teste e os fatores que o afetam. Os objetivos marcados com ★ são os mais centrais.

## 1 Fundamentos do Teste de Hipóteses

### 1.1 Motivação

Considere a seguinte situação.

**Situação-problema: máquina de preenchimento de garrafas.** Uma máquina está configurada para preencher cada garrafa com 500 ml de vinho. Sabe-se que o volume colocado nas garrafas apresenta variabilidade natural: mesmo quando a máquina está funcionando corretamente, diferentes garrafas não recebem exatamente o mesmo volume.

O fabricante suspeita de que a máquina esteja desregulada e, em média, preenchendo as garrafas com menos de 500 ml. Para investigar essa suspeita, ele seleciona uma amostra de 20 garrafas e mede o volume de cada uma:

|        |        |        |        |        |        |        |        |        |
|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 484,11 | 459,49 | 471,38 | 512,01 | 494,48 | 528,63 | 493,64 | 485,03 | 473,88 |
| 501,59 | 502,85 | 538,08 | 465,68 | 495,03 | 475,32 | 529,41 | 518,13 | 464,32 |
|        |        |        | 449,08 | 489,27 |        |        |        |        |

A média dessa amostra é

$$\bar{x} = 491,57 \text{ ml.}$$

À primeira vista, esse resultado parece apoiar a suspeita do fabricante: a média observada está abaixo de 500 ml. No entanto, essa comparação, isoladamente, não é suficiente para concluir que a máquina está desregulada.

A razão é que a média amostral varia de uma amostra para outra. Mesmo que a máquina esteja funcionando corretamente, diferentes conjuntos de 20 garrafas produziriam médias ligeiramente diferentes. Algumas dessas médias poderiam ficar abaixo de 500 ml simplesmente por efeito da variabilidade amostral.

Surge, portanto, a questão central:

**a diferença entre 491,57 ml e 500 ml é grande o suficiente para indicar uma mudança real, ou poderia ter ocorrido apenas por acaso?**

Responder a essa pergunta exige levar em conta não apenas a diferença entre a média observada e o valor de referência, mas também a variabilidade dos dados e o tamanho da amostra. Uma diferença de 8 ml pode representar uma evidência importante em um conjunto de dados pouco variável e uma evidência fraca em outro conjunto muito mais variável.

É justamente esse tipo de problema que motiva os *testes de hipóteses*. Eles fornecem um procedimento estatístico para avaliar se os dados observados são compatíveis com uma determinada afirmação sobre a população ou se apresentam uma discrepância suficientemente grande para colocar essa afirmação em dúvida.

No exemplo da máquina, precisamos formalizar duas possibilidades: uma que represente seu funcionamento de acordo com a referência adotada e outra que represente a redução do volume médio que o fabricante deseja detectar. Essas duas possibilidades serão expressas por meio das **hipóteses nula e alternativa**, apresentadas na próxima subseção.

## 1.2 Hipóteses nula e alternativa

Um teste de hipóteses começa pela formulação de duas afirmações sobre um parâmetro populacional. Essas afirmações representam, de forma precisa, as duas possibilidades que queremos confrontar com base nos dados.

**Hipótese nula.** A **hipótese nula**, denotada por  $H_0$ , representa a situação tomada como referência para o teste. Em muitos problemas, ela corresponde à ausência do efeito que se deseja detectar, à manutenção de uma condição conhecida ou a uma afirmação previamente estabelecida.

**Hipótese alternativa.** A **hipótese alternativa**, denotada por  $H_a$ , representa o efeito ou mudança que se deseja investigar. Ela descreve os valores do parâmetro que seriam compatíveis com a suspeita ou questão de interesse.

No exemplo da máquina de preenchimento, o fabricante deseja investigar se o volume médio está abaixo de 500 ml. Assim, podemos formular:

$$H_0 : \mu \geq 500 \quad \text{e} \quad H_a : \mu < 500.$$

Aqui,  $H_0$  representa a situação em que a média de preenchimento não está abaixo do valor de referência, enquanto  $H_a$  representa precisamente a redução que o fabricante deseja detectar.

A função dessas duas hipóteses é transformar uma pergunta formulada em linguagem corrente em uma afirmação estatística sobre um parâmetro populacional. Por exemplo, a pergunta

*“A máquina está preenchendo as garrafas com menos de 500 ml, em média?”*

é traduzida pela hipótese alternativa

$$H_a : \mu < 500.$$

Uma regra prática útil é, portanto, identificar primeiro o efeito que se deseja detectar. Esse efeito determina  $H_a$ . Em seguida,  $H_0$  é formulada como a situação complementar que será usada como referência no teste.

### 1.2.1 Direção da hipótese alternativa

A forma de  $H_a$  determina que tipo de afastamento em relação ao valor de referência será interpretado como evidência contra  $H_0$ .

Há três possibilidades principais.

- **Teste unilateral à esquerda:**  $H_a : \mu < \mu_0$ . É utilizado quando apenas valores menores do parâmetro são relevantes para a pergunta de interesse. No exemplo da máquina, a suspeita é de subpreenchimento.

- **Teste unilateral à direita:**

$$H_a : \mu > \mu_0.$$

É utilizado quando apenas valores maiores são relevantes, como ao investigar se um novo método aumentou o rendimento médio.

- **Teste bilateral:**

$$H_a : \mu \neq \mu_0.$$

É utilizado quando desvios em ambas as direções são relevantes. Por exemplo, em um processo de calibração, tanto valores acima quanto abaixo do valor nominal podem indicar um problema.

A direção da hipótese alternativa deve ser determinada pela pergunta de interesse *antes* de examinar os resultados da amostra. Escolher a direção do teste depois de observar os dados altera o procedimento originalmente planejado e pode levar a conclusões inadequadas.

### 1.2.2 A forma da hipótese nula

Como  $H_a$  descreve o efeito que se deseja detectar,  $H_0$  representa os valores restantes do parâmetro. Por essa razão, a hipótese nula contém a igualdade, podendo ser escrita com  $=$ ,  $\leq$  ou  $\geq$ .

As formas usuais são:

| Hipótese alternativa   | Hipótese nula correspondente |
|------------------------|------------------------------|
| $H_a : \mu < \mu_0$    | $H_0 : \mu \geq \mu_0$       |
| $H_a : \mu > \mu_0$    | $H_0 : \mu \leq \mu_0$       |
| $H_a : \mu \neq \mu_0$ | $H_0 : \mu = \mu_0$          |

A escolha entre igualdade e desigualdade na formulação de  $H_0$  não é apenas uma questão de notação. Ela deve refletir corretamente a pergunta que está sendo investigada.

Considere novamente a máquina de preenchimento. Como o fabricante deseja detectar apenas valores médios abaixo de 500 ml, a hipótese alternativa é

$$H_a : \mu < 500.$$

Logo, a hipótese nula correspondente é

$$H_0 : \mu \geq 500.$$

Valores médios iguais ou superiores a 500 ml não fornecem evidência para a suspeita específica de subpreenchimento e, portanto, pertencem à hipótese nula.

Em um problema diferente, suponha que o objetivo seja verificar se uma máquina deixou de produzir exatamente o valor nominal, independentemente da direção da mudança. Nesse caso:

$$H_0 : \mu = \mu_0, \quad H_a : \mu \neq \mu_0.$$

Portanto, a formulação das hipóteses deve sempre partir da pergunta que se deseja responder, e não de uma regra mecânica sobre qual símbolo usar.

### 1.2.3 Exemplos de formulação

**Exemplo 1 – Tempo médio de entrega.** Uma empresa afirma que seu tempo médio de entrega é, no máximo, 3 dias. Um cliente suspeita de que o tempo real seja maior.

$$H_0 : \mu \leq 3, \quad H_a : \mu > 3.$$

Trata-se de um teste unilateral à direita.

**Exemplo 2 – Colesterol médio.** Um pesquisador deseja verificar se uma intervenção altera o colesterol médio em relação ao valor histórico de 200 mg/dL, sem especificar previamente a direção da mudança.

$$H_0 : \mu = 200, \quad H_a : \mu \neq 200.$$

Trata-se de um teste bilateral.

**Exemplo 3 – Máquina de preenchimento.** O fabricante suspeita de que o volume médio esteja abaixo de 500 ml.

$$H_0 : \mu \geq 500, \quad H_a : \mu < 500.$$

Trata-se de um teste unilateral à esquerda.

**Exemplo 4 – Proporção de votantes.** Deseja-se investigar se mais de 30

$$H_0 : p \leq 0,30, \quad H_a : p > 0,30.$$

Trata-se de um teste unilateral à direita.

#### Pergunta 1

Formule as hipóteses nula e alternativa para cada situação abaixo e identifique se o teste é unilateral à esquerda, unilateral à direita ou bilateral.

- (a) Uma empresa afirma que o tempo médio de entrega de seus produtos é, no máximo, 3 dias. Um cliente suspeita de que o tempo real seja maior.
- (b) Um pesquisador quer verificar se uma nova dieta altera, para mais ou para menos, o colesterol médio de uma população, cujo valor histórico é de 200 mg/dL.
- (c) Uma fábrica deseja verificar se o diâmetro médio de seus parafusos permanece igual a 10 mm ou se sofreu alguma alteração.

Uma vez formuladas  $H_0$  e  $H_a$ , o próximo passo é compreender como os dados amostrais podem fornecer evidência contra  $H_0$ . Essa é a lógica central de um teste de hipóteses, discutida na próxima subseção.

## 1.3 A lógica do teste de hipóteses

A ideia central é avaliar o que seria razoável observar *caso*  $H_0$  fosse verdadeira.

Para isso, o teste de hipóteses adota  $H_0$  como hipótese de referência. Sob essa suposição e de acordo com o modelo probabilístico adotado, podemos determinar como uma estatística calculada a partir da amostra se comportaria em repetições do experimento. Essa estatística, denominada *estatística de teste*, será construída de modo que seus valores permitam medir a discrepância entre os dados observados e aquilo que seria esperado sob  $H_0$ .

Considere, por exemplo, uma hipótese nula da forma

$$H_0 : \mu = \mu_0.$$

Nesse caso,  $\mu_0$  fornece o valor de referência para a média populacional. A partir dele e das demais suposições do modelo, podemos obter a distribuição da estatística de teste sob  $H_0$ . Essa distribuição indica quais valores da estatística seriam mais usuais e quais seriam mais extremos se  $H_0$  fosse verdadeira.

Depois de coletar a amostra, calculamos o valor observado da estatística de teste e verificamos sua posição nessa distribuição. Se esse valor estiver em uma região usual, os dados são compatíveis com o comportamento esperado sob  $H_0$ . Se estiver em uma região extrema, os dados fornecem evidência contra  $H_0$ , pois um resultado como o observado seria pouco comum caso essa hipótese fosse verdadeira.

A pergunta central do teste pode, portanto, ser expressa como:

**“Se  $H_0$  fosse verdadeira, quão surpreendente seria observar um resultado como este?”**

O  $p$ -valor, apresentado em detalhe mais adiante, quantifica essa ideia. Em termos gerais, quanto menor o  $p$ -valor, mais extremo é o resultado observado em relação ao que seria esperado sob  $H_0$  e, portanto, maior é a evidência contra essa hipótese.

$$p\text{-valor pequeno} \implies \text{maior evidência contra } H_0.$$

É importante perceber que esse raciocínio é *condicional*: avaliamos os dados *supondo que  $H_0$  seja verdadeira*. O teste não calcula a probabilidade de  $H_0$  ser verdadeira. Em vez disso, investiga se aquilo que foi observado seria plausível sob essa hipótese.

Se os dados forem suficientemente incompatíveis com  $H_0$ , segundo um critério de decisão estabelecido previamente, rejeitamos  $H_0$ . Caso contrário, não a rejeitamos. Assim, o raciocínio pode ser resumido da seguinte forma:

1. tomamos  $H_0$  como hipótese de referência;
2. determinamos como a estatística de teste se comportaria se  $H_0$  fosse verdadeira;
3. calculamos o valor dessa estatística a partir da amostra observada;
4. avaliamos quão extremo é esse valor sob  $H_0$ ;
5. se o resultado for suficientemente extremo, rejeitamos  $H_0$ ; caso contrário, não a rejeitamos.

**A assimetria da conclusão.** A lógica do teste produz uma assimetria importante entre rejeitar e não rejeitar  $H_0$ .

Quando rejeitamos  $H_0$ , concluímos que os dados fornecem evidência estatística contra ela. Isso não equivale a uma demonstração lógica de que  $H_0$  seja falsa: mesmo quando  $H_0$  é verdadeira, resultados raros podem ocasionalmente ocorrer.

Quando não rejeitamos  $H_0$ , por outro lado, também não concluímos que ela seja verdadeira. A conclusão é apenas que os dados disponíveis não forneceram evidência suficiente para rejeitá-la. Isso pode ocorrer porque  $H_0$  é compatível com a situação estudada, mas também porque existe um efeito real que o estudo não conseguiu detectar, por exemplo, devido a uma amostra pequena, elevada variabilidade ou um efeito de pequena magnitude.

Por essa razão, utilizamos as expressões *rejeitar  $H_0$*  e *não rejeitar  $H_0$* , e não *aceitar  $H_0$* . A ausência de evidência suficiente contra uma hipótese não constitui, por si só, evidência de que ela seja verdadeira.

Essa distinção será retomada quando estudarmos os erros de tipo I e tipo II e o poder de um teste. Em particular, ela explica por que demonstrar que dois tratamentos são suficientemente semelhantes exige procedimentos específicos, como testes de equivalência ou de não inferioridade; simplesmente não rejeitar uma hipótese de ausência de diferença não é suficiente para estabelecer equivalência.

## 1.4 Etapas de um teste de hipóteses

A lógica discutida na subseção anterior pode ser organizada em uma sequência de etapas. Embora os detalhes dos cálculos dependam do parâmetro de interesse, do modelo probabilístico e do teste utilizado, a estrutura geral do procedimento permanece a mesma.

### 1. Formular as hipóteses $H_0$ e $H_a$ .

A pergunta de interesse é traduzida em duas afirmações sobre o parâmetro populacional. A hipótese alternativa  $H_a$  representa o efeito que se deseja detectar, enquanto  $H_0$  estabelece a situação que será tomada como referência para avaliar os dados.

A forma de  $H_a$  também determina a direção do teste: unilateral à esquerda, unilateral à direita ou bilateral.

### 2. Escolher e calcular a estatística de teste.

A partir da amostra, calcula-se uma estatística que mede a discrepância entre o que foi observado e o que seria esperado sob  $H_0$ . Essa discrepância é avaliada levando em conta a variabilidade amostral.

Diferentes problemas levam a diferentes estatísticas de teste. Por exemplo, nos testes para médias estudados nesta nota, utilizaremos estatísticas baseadas nas distribuições normal padrão ( $Z$ ) ou  $t$  de Student ( $T$ ).

### 3. Calcular o $p$ -valor.

O valor observado da estatística de teste é comparado com sua distribuição sob  $H_0$ . O  $p$ -valor quantifica quão extremo é o resultado observado nessa distribuição, considerando também valores ainda mais extremos na direção definida por  $H_a$ .

Quanto menor o  $p$ -valor, maior a evidência fornecida pelos dados contra  $H_0$ .

### 4. Comparar o $p$ -valor com o nível de significância $\alpha$ .

Antes de realizar o teste, estabelece-se um nível de significância  $\alpha$ , que determina o critério utilizado para decidir se a evidência contra  $H_0$  será considerada suficientemente forte.

A regra de decisão é

$$\begin{cases} p \leq \alpha & \implies \text{rejeitar } H_0, \\ p > \alpha & \implies \text{não rejeitar } H_0. \end{cases}$$

### 5. Interpretar a decisão no contexto do problema.

A conclusão não deve se limitar às expressões “rejeitamos  $H_0$ ” ou “não rejeitamos  $H_0$ ”. É necessário traduzi-la de volta para a pergunta que motivou o estudo.

No exemplo da máquina de preenchimento, por exemplo, rejeitar

$$H_0 : \mu \geq 500$$

em favor de

$$H_a : \mu < 500$$

significa concluir que os dados fornecem evidência estatística de que o volume médio de preenchimento está abaixo de 500 ml.

Se  $H_0$  não for rejeitada, a conclusão adequada é que os dados não fornecem evidência suficiente para afirmar que o volume médio está abaixo de 500 ml. Isso não significa concluir que a média seja necessariamente igual ou superior a 500 ml.

A Figura 1 resume esse encadeamento. Observe que as etapas não são independentes: a pergunta de interesse determina  $H_a$ ; a formulação das hipóteses e o modelo determinam qual estatística de teste é apropriada e qual é sua distribuição sob  $H_0$ ; e essa distribuição permite calcular o  $p$ -valor que será usado na decisão.




Figura 1: Etapas gerais de um teste de hipóteses. A decisão estatística resulta da comparação entre o  $p$ -valor e o nível de significância  $\alpha$ , mas o procedimento somente se completa quando essa decisão é interpretada no contexto do problema.

As próximas subseções examinam com mais detalhes os componentes centrais desse procedimento: a estatística de teste, o  $p$ -valor e o nível de significância.

## 1.5 Estatística de teste

Depois de formular  $H_0$  e  $H_a$ , precisamos transformar os dados da amostra em uma quantidade que permita avaliar quão discrepante é o resultado observado em relação ao que

seria esperado sob  $H_0$ . Essa quantidade é a **estatística de teste** (*test statistic*).

**Definição.** Uma estatística de teste é uma função dos dados amostrais cuja distribuição de probabilidade, sob  $H_0$ , é conhecida ou pode ser determinada. Depois que a amostra é observada, essa função assume um valor numérico, denominado *valor observado da estatística de teste*.

Nos testes para médias estudados nesta nota, a estatística de teste compara a diferença entre uma estimativa amostral e o valor especificado por  $H_0$  com a variabilidade esperada dessa estimativa. De forma esquemática,

$$\text{estatística de teste} = \frac{\text{diferença em relação ao valor de referência}}{\text{variabilidade esperada dessa diferença}}.$$

Por exemplo, ao testar uma hipótese sobre uma média populacional, a diferença

$$\bar{x} - \mu_0$$

indica quanto a média observada se afastou do valor de referência  $\mu_0$ . Entretanto, essa diferença não deve ser interpretada isoladamente. Um afastamento de 5 unidades pode ser grande quando a média amostral varia pouco entre amostras e pequeno quando essa variabilidade é elevada. A estatística de teste leva justamente essa variabilidade em consideração.

Nos  $z$ - e  $t$ -testes, esse afastamento é expresso em unidades de erro padrão. Assim, valores próximos de zero indicam que a estimativa amostral está próxima do valor especificado por  $H_0$ , enquanto valores mais afastados de zero indicam maior discrepância em relação a ele.

O que torna essa estatística útil para o teste é conhecermos sua distribuição sob  $H_0$ . Essa distribuição permite avaliar se o valor observado é comum ou extremo caso  $H_0$  seja verdadeira. É justamente essa comparação que será utilizada, na próxima subseção, para definir o  $p$ -valor.

Nesta nota, utilizaremos principalmente as seguintes estatísticas:

| Teste estatístico | Estatística de teste |
|-------------------|----------------------|
| $z$ -teste        | $Z$                  |
| $t$ -teste        | $T$                  |

As expressões específicas de  $Z$  e  $T$ , bem como as condições sob as quais suas distribuições são válidas, serão apresentadas nas seções dedicadas a cada teste.

## 1.6 O $p$ -valor

Na subseção anterior, vimos que a estatística de teste permite expressar a discrepância entre os dados observados e aquilo que seria esperado sob  $H_0$ . Restava agora quantificar quão extremo é o valor observado dessa estatística. Essa é a função do  **$p$ -valor** (*p-value*).

**Definição.** O  $p$ -valor é a probabilidade, *supondo que  $H_0$  seja verdadeira*, de obter um valor da estatística de teste tão extremo quanto o observado ou ainda mais extremo, na direção determinada pela hipótese alternativa  $H_a$ .

Em outras palavras, depois de calcular a estatística de teste, perguntamos:

**“Se  $H_0$  fosse verdadeira, com que frequência obteríamos um resultado tão extremo quanto este ou ainda mais extremo?”**

Um  $p$ -valor pequeno indica que o resultado observado ocupa uma região pouco provável da distribuição da estatística sob  $H_0$ . Por isso, fornece maior evidência contra  $H_0$ :

$$p\text{-valor pequeno} \implies \text{maior evidência contra } H_0.$$

Por outro lado, um  $p$ -valor grande indica que resultados tão extremos quanto o observado não são particularmente incomuns sob  $H_0$ . Nesse caso, os dados não fornecem forte evidência contra essa hipótese.

É importante observar que o  $p$ -valor não considera apenas a probabilidade de obter *exatamente* o valor observado. Ele inclui também resultados que seriam ainda mais extremos na direção especificada por  $H_a$ . Essa ideia é ilustrada, para um teste bilateral, na Figura 2.




Figura 2: Interpretação do  $p$ -valor em um teste bilateral. Sob  $H_0$ , as áreas sombreadas correspondem a valores da estatística de teste tão ou mais extremos que o valor observado, considerando afastamentos em ambas as direções.

**O que o  $p$ -valor não representa.** Uma interpretação particularmente importante, mas incorreta, é afirmar que

“o  $p$ -valor é a probabilidade de  $H_0$  ser verdadeira”.

O teste frequentista não atribui, por meio do  $p$ -valor, uma probabilidade à hipótese  $H_0$ . A probabilidade é calculada para possíveis resultados da estatística de teste *condicionalmente à suposição de que  $H_0$  seja verdadeira*.

Portanto, há uma diferença fundamental entre

$$\Pr(\text{dados tão ou mais extremos} \mid H_0)$$

e

$$\Pr(H_0 \mid \text{dados}).$$

O  $p$ -valor está relacionado à primeira quantidade, e não à segunda.

Assim, um  $p$ -valor pequeno não significa que “ $H_0$  tem pequena probabilidade de ser verdadeira”. Significa que um resultado tão extremo quanto o observado seria pouco provável segundo a distribuição da estatística de teste sob  $H_0$ .

Da mesma forma, um  $p$ -valor grande não demonstra que  $H_0$  seja verdadeira. Ele indica apenas que o resultado observado não é suficientemente incomum sob  $H_0$  para fornecer forte evidência contra ela.

### 1.6.1 Ilustração com o experimento da moeda

Considere uma moeda que será lançada 20 vezes. Queremos investigar se ela apresenta uma tendência a produzir mais caras do que uma moeda justa. As hipóteses são

$$H_0 : p = 0,5, \quad H_a : p > 0,5,$$

onde  $p$  representa a probabilidade de obter cara em um lançamento.

Suponha que tenham sido observadas 16 caras em 20 lançamentos. Se  $H_0$  for verdadeira, o número  $X$  de caras segue uma distribuição binomial:

$$X \sim B(20, 0,5).$$

Como  $H_a$  afirma que a probabilidade de cara é *maior* do que 0,5, resultados com números maiores de caras são ainda mais extremos na direção de  $H_a$ . Portanto, o  $p$ -valor não é apenas a probabilidade de observar exatamente 16 caras, mas a probabilidade de observar *16 ou mais*:

$$p\text{-valor} = \Pr(X \geq 16 \mid p = 0,5).$$

Calculando essa probabilidade,

$$p\text{-valor} = \sum_{k=16}^{20} \binom{20}{k} (0,5)^k (0,5)^{20-k} \approx 0,0059.$$

Isso significa que, se a moeda fosse justa, a probabilidade de obter 16 ou mais caras em 20 lançamentos seria de aproximadamente 0,59%. Trata-se, portanto, de um resultado bastante extremo sob  $H_0$  e que fornece forte evidência contra a hipótese de que a moeda seja justa.

```
from scipy.stats import binom

n = 20
p_h0 = 0.5
k_obs = 16

p_valor = binom.sf(k_obs - 1, n, p_h0) # P(X >= 16)

print(f"p-valor = {p_valor:.4f}")      # -> 0.0059
```

Observe que ainda não precisamos estabelecer, neste ponto, se esse  $p$ -valor é “pequeno o suficiente” para rejeitar formalmente  $H_0$ . Para isso, será necessário compará-lo com um critério previamente estabelecido, o nível de significância  $\alpha$ , apresentado na próxima subseção.

### 1.6.2 A direção da hipótese alternativa e o $p$ -valor

O conjunto de valores considerados “tão ou mais extremos” depende da hipótese alternativa. É  $H_a$  que determina em qual direção da distribuição devemos procurar resultados que forneçam evidência contra  $H_0$ .

Para ilustrar, considere uma estatística de teste  $Z$  que, sob  $H_0$ , segue a distribuição normal padrão,

$$Z \sim \mathcal{N}(0, 1),$$

e seja  $z_{\text{obs}}$  o valor observado.

- Se  $H_a : \mu > \mu_0$ , valores grandes e positivos fornecem evidência contra  $H_0$ . O teste é unilateral à direita e  $p\text{-valor} = \Pr(Z \geq z_{\text{obs}})$ .

- Se

$$H_a : \mu < \mu_0,$$

valores grandes em magnitude na direção negativa fornecem evidência contra  $H_0$ . O teste é unilateral à esquerda e

$$p\text{-valor} = \Pr(Z \leq z_{\text{obs}}).$$

- Se

$$H_a : \mu \neq \mu_0,$$

afastamentos em ambas as direções fornecem evidência contra  $H_0$ . Para a distribuição normal padrão, que é simétrica,

$$p\text{-valor} = 2 \Pr(Z \geq |z_{\text{obs}}|).$$

A Figura 3 ilustra essas três situações. Em cada caso, a área sombreada representa os valores da estatística considerados tão ou mais extremos que um valor observado hipotético.




Figura 3: Cálculo do  $p$ -valor conforme a direção de  $H_a$ . A área sombreada representa valores da estatística de teste tão ou mais extremos que o valor observado, na direção relevante para a hipótese alternativa.

Portanto, não existe uma única “cauda do  $p$ -valor” escolhida depois de observar os dados. A região relevante é determinada pela hipótese alternativa, que deve ter sido formulada antes da análise da amostra.

## 1.7 Nível de significância e regra de decisão

O  $p$ -valor mede quão extremo é o resultado observado sob a suposição de que  $H_0$  seja verdadeira. Para transformar essa medida de evidência em uma regra de decisão, é necessário estabelecer previamente um critério que determine quando um resultado será considerado suficientemente incompatível com  $H_0$ .

Esse critério é o **nível de significância**, denotado por  $\alpha$ .

**Definição.** O nível de significância  $\alpha$  é o limite estabelecido para a probabilidade de rejeitar  $H_0$  quando ela é verdadeira. Em outras palavras, ele controla a probabilidade de cometer um **erro de tipo I**.

Valores frequentemente utilizados são

$$\alpha = 0,05 \quad \text{e} \quad \alpha = 0,01,$$

embora a escolha adequada dependa das consequências de uma rejeição incorreta de  $H_0$  no contexto do problema.

O valor de  $\alpha$  deve ser definido *antes* de observar os resultados da análise. Caso contrário, seria possível ajustar o critério de decisão aos dados obtidos, comprometendo a interpretação probabilística do procedimento.

### 1.7.1 Regra de decisão baseada no $p$ -valor

Uma vez fixado  $\alpha$ , a decisão é obtida comparando o  $p$ -valor com esse nível:

|                                                 |
|-------------------------------------------------|
| $p \leq \alpha \implies \text{rejeitar } H_0,$  |
| $p > \alpha \implies \text{não rejeitar } H_0.$ |

A lógica dessa regra decorre diretamente da interpretação do  $p$ -valor.

Se

$$p \leq \alpha,$$

o resultado observado é suficientemente extremo, segundo o critério estabelecido, para que rejeitemos  $H_0$ .

Se

$$p > \alpha,$$

o resultado não é suficientemente extremo para justificar sua rejeição.

Quando  $p \leq \alpha$ , dizemos que o resultado é **estatisticamente significativo ao nível  $\alpha$** .

É importante perceber que o valor de  $\alpha$  não mede a intensidade da evidência encontrada nos dados. Essa informação está contida no próprio  $p$ -valor. O nível  $\alpha$  funciona como um limiar de decisão previamente estabelecido.

Por exemplo, se

$$p = 0,003,$$

então  $H_0$  seria rejeitada tanto para  $\alpha = 0,05$  quanto para  $\alpha = 0,01$ . O valor 0,003, entretanto, contém mais informação sobre a evidência observada do que simplesmente classificá-la como “significativa”.

**Rejeitar não significa provar.** A decisão produzida por um teste deve ser interpretada de acordo com a lógica discutida anteriormente.

Ao rejeitar  $H_0$ , concluímos que os dados fornecem evidência estatística contra ela. Não concluímos que  $H_0$  seja impossível ou que  $H_a$  tenha sido demonstrada com certeza.

Da mesma forma, quando  $H_0$  não é rejeitada, a conclusão adequada é que os dados não forneceram evidência suficiente contra ela. Não rejeitar  $H_0$  não equivale a aceitá-la como verdadeira.

Por essa razão, utilizamos sempre as expressões

$$\text{rejeitar } H_0 \quad \text{ou} \quad \text{não rejeitar } H_0,$$

e evitamos a expressão *aceitar*  $H_0$ .

### 1.7.2 Significância estatística e relevância prática

A comparação entre  $p$  e  $\alpha$  responde a uma pergunta estatística: os dados fornecem evidência suficiente contra  $H_0$  segundo o critério adotado?

Ela não responde, entretanto, a outra pergunta igualmente importante:

#### A magnitude do efeito observado é relevante na prática?

Essas duas questões não são equivalentes.

Um efeito muito pequeno pode ser detectado estatisticamente quando a amostra é suficientemente grande. Isso ocorre porque o aumento do tamanho amostral reduz o erro padrão, tornando o teste capaz de detectar discrepâncias cada vez menores em relação a  $H_0$ .

Considere, por exemplo, um novo tratamento que reduza a pressão arterial, em média, apenas 0,3 mmHg a mais do que o tratamento convencional. Com uma amostra de dezenas de milhares de pacientes, essa diferença pode produzir um  $p$ -valor muito pequeno e ser estatisticamente significativa. Ainda assim, uma redução de 0,3 mmHg pode não ter relevância clínica.

Portanto,

$$\text{significância estatística} \not\Rightarrow \text{relevância prática.}$$

A interpretação de um resultado deve considerar, além do  $p$ -valor, a magnitude do efeito observado, sua incerteza e o contexto do problema.

### 1.7.3 Conexão com intervalos de confiança

Testes de hipóteses e intervalos de confiança são duas formas relacionadas de realizar inferência sobre um parâmetro populacional.

Considere um teste bilateral da forma

$$H_0 : \mu = \mu_0, \quad H_a : \mu \neq \mu_0,$$

realizado ao nível de significância  $\alpha$ .

Se construirmos, com o mesmo modelo e sob as mesmas condições, um intervalo de confiança bilateral de nível  $1 - \alpha$ , então as duas abordagens fornecem decisões equivalentes:

|                              |        |                 |        |                      |
|------------------------------|--------|-----------------|--------|----------------------|
| $\mu_0 \notin IC_{1-\alpha}$ | $\iff$ | $p \leq \alpha$ | $\iff$ | rejeitar $H_0$ ,     |
| $\mu_0 \in IC_{1-\alpha}$    | $\iff$ | $p > \alpha$    | $\iff$ | não rejeitar $H_0$ . |

Essa equivalência fornece outra maneira de interpretar o teste: rejeitamos  $H_0$  quando o valor proposto para o parâmetro está fora do conjunto de valores compatíveis com os dados representado pelo intervalo de confiança correspondente.

Para testes unilaterais, a equivalência exige o intervalo de confiança *unilateral* correspondente. Em geral, um intervalo bilateral de nível  $1 - \alpha$  não produz a mesma regra de decisão de um teste unilateral de nível  $\alpha$ .

## 1.8 Tipos de erro

Como a decisão de um teste de hipóteses é tomada a partir de uma amostra, ela está sujeita à variabilidade amostral. Mesmo quando o procedimento é corretamente especificado e todas as suas condições são satisfeitas, ainda existe a possibilidade de a decisão não corresponder ao verdadeiro estado da população.

Há dois tipos fundamentais de erro.

**Erro de tipo I.** O erro de tipo I ocorre quando rejeitamos  $H_0$  mesmo que ela seja verdadeira:

$$H_0 \text{ verdadeira} \quad \text{e} \quad \text{rejeitamos } H_0.$$

Esse erro pode ser interpretado como um *falso positivo*: o teste indica evidência de um efeito que, de fato, não existe nos termos definidos por  $H_a$ .

O nível de significância  $\alpha$  é escolhido justamente para controlar a probabilidade desse erro. Em um teste de nível  $\alpha$ ,

$$\Pr(\text{rejeitar } H_0 \mid H_0 \text{ verdadeira}) \leq \alpha.$$

Em muitos testes usuais, essa probabilidade é igual a  $\alpha$  no valor de fronteira de  $H_0$ .

**Erro de tipo II.** O erro de tipo II ocorre quando não rejeitamos  $H_0$  mesmo que ela seja falsa:

$$H_0 \text{ falsa} \quad \text{e} \quad \text{não rejeitamos } H_0.$$

Esse erro pode ser interpretado como uma *falha de detecção*: existe um efeito compatível com  $H_a$ , mas os dados observados não fornecem evidência suficiente para que o teste o detecte.

A probabilidade de erro de tipo II é usualmente denotada por  $\beta$ . Para um valor específico  $\theta$  do parâmetro sob  $H_a$ ,

$$\beta(\theta) = \Pr_{\theta}(\text{não rejeitar } H_0), \quad \theta \in H_a.$$

Assim, ao contrário de  $\alpha$ ,  $\beta$  não é, em geral, um único número determinado apenas pelo teste: seu valor depende do verdadeiro valor do parâmetro sob  $H_a$ . Quanto mais distante a situação real estiver da fronteira de  $H_0$ , em geral mais fácil será detectar o efeito e menor será  $\beta$ .

A tabela a seguir resume as quatro combinações possíveis entre a decisão do teste e o verdadeiro estado de  $H_0$ :

|                    | $H_0$ verdadeira | $H_0$ falsa                 |
|--------------------|------------------|-----------------------------|
| Não rejeitar $H_0$ | Decisão correta  | Erro de tipo II ( $\beta$ ) |
| Rejeitar $H_0$     | Erro de tipo I   | Decisão correta             |

Quando  $H_0$  é falsa, a probabilidade de rejeitá-la corretamente é chamada de **poder do teste**:

$$\text{poder} = 1 - \beta.$$

Esse conceito será estudado em detalhe mais adiante.

### 1.8.1 Um exemplo: teste diagnóstico

Considere, para fins de analogia, um teste em que definimos

$$H_0 : \text{“o paciente é saudável”}$$

e

$$H_a : \text{“o paciente está doente”}.$$

Nesse contexto:

- um **erro de tipo I** ocorre quando concluímos que há evidência de doença em uma pessoa que está saudável;
- um **erro de tipo II** ocorre quando não detectamos a doença em uma pessoa que está de fato doente.

A analogia ajuda a visualizar os dois erros, mas sua gravidade não é determinada pela teoria estatística. Ela depende das consequências concretas de cada decisão.

### 1.8.2 O compromisso entre os dois tipos de erro

Para um tamanho de amostra e um modelo fixados, tornar o critério de rejeição mais rigoroso reduz a probabilidade de erro de tipo I, mas tende a aumentar a probabilidade de erro de tipo II.

Por exemplo, reduzir o nível de significância de

$$\alpha = 0,05$$

para

$$\alpha = 0,01$$

faz com que sejam necessárias evidências mais fortes para rejeitar  $H_0$ . Com isso, falsos positivos tornam-se menos prováveis, mas efeitos reais também podem se tornar mais difíceis de detectar.

Assim, existe um compromisso entre os dois tipos de erro:

$$\alpha \downarrow \implies \beta \uparrow$$

quando os demais elementos do problema são mantidos fixos.

Esse compromisso não significa, porém, que seja impossível melhorar simultaneamente o comportamento do teste. Uma das estratégias mais importantes é aumentar o tamanho da amostra. Mantendo  $\alpha$  fixado, uma amostra maior reduz o erro padrão e tende a aumentar a capacidade do teste de detectar efeitos reais. Em consequência,  $\beta$  diminui e o poder  $1 - \beta$  aumenta.

Portanto, aumentar o tamanho amostral permite, em geral, reduzir a probabilidade de erro de tipo II sem elevar a probabilidade de erro de tipo I estabelecida pelo nível de significância.

**Qual erro é mais grave?** Não existe uma resposta universal. A importância relativa dos erros de tipo I e tipo II depende das consequências associadas a cada decisão.

Em um teste diagnóstico, por exemplo, um falso positivo pode levar a exames adicionais, ansiedade ou tratamentos desnecessários. Um falso negativo pode atrasar o diagnóstico de uma doença real. Qual desses erros merece maior controle depende, entre outros fatores, da gravidade da doença, da segurança do tratamento e dos custos associados a cada decisão.

A escolha de  $\alpha$  e o planejamento do tamanho amostral devem, portanto, considerar não apenas convenções estatísticas, mas também as consequências práticas dos erros que o teste pode produzir.

### Pergunta 2

Considere novamente a situação em que

$$H_0 : \text{“o paciente é saudável”} \quad \text{e} \quad H_a : \text{“o paciente está doente”}.$$

- (a) O que representa um erro de tipo I nesse contexto? Quais podem ser suas consequências práticas?
- (b) O que representa um erro de tipo II? Quais podem ser suas consequências práticas?
- (c) A informação fornecida é suficiente para decidir qual dos dois erros é mais grave? Que informações adicionais seriam necessárias?
- (d) Se reduzirmos  $\alpha$  mantendo o tamanho da amostra fixo, o que tende a acontecer com  $\beta$ ? Explique.

## 1.9 Exercícios de fixação

### 1.9.1 Formulação de hipóteses

Para cada situação abaixo, formule as hipóteses  $H_0$  e  $H_a$ , identifique se o teste é unicaudal (à esquerda ou à direita) ou bicaudal, e justifique sua escolha.

- (a) Uma empresa afirma que o tempo médio de entrega é de no máximo 3 dias. Um cliente desconfia que o tempo real é maior.
- (b) Um pesquisador quer verificar se uma nova dieta altera (para mais ou para menos) o colesterol médio de uma população, sabendo que o valor histórico é 200 mg/dL.
- (c) Uma fábrica de parafusos afirma que o diâmetro médio de produção é exatamente 10 mm. O controle de qualidade suspeita que algo mudou.
- (d) Um laboratório afirma que sua vacina reduz a duração média de um resfriado comum abaixo de 7 dias. Você deseja verificar essa afirmação.

### 1.9.2 Interpretação do $p$ -valor e regra de decisão

Classifique cada afirmação abaixo como verdadeira ou falsa e justifique:

- (a) “Se  $p = 0,03$ , há 3% de probabilidade de que  $H_0$  seja verdadeira”.
- (b) “Se não rejeitamos  $H_0$ , então  $H_0$  foi provada verdadeira”.
- (c) “Quanto menor o  $p$ -valor, maior a magnitude do efeito observado”.
- (d) “Fixar  $\alpha = 0,01$  sempre leva a conclusões mais confiáveis do que  $\alpha = 0,05$ ”.
- (e) “Um resultado estatisticamente não significativo implica que não há diferença entre os grupos”.

### 1.9.3 Erros tipo I e tipo II

Um sistema automatizado de detecção de fraudes em transações bancárias analisa cada operação e decide: bloquear (suspeita de fraude) ou liberar. Defina  $H_0$ : “a transação é legítima”.

- (a) Descreva o que é um erro tipo I nesse contexto e quais são suas consequências para o cliente e para o banco.
- (b) Descreva o que é um erro tipo II e quais são suas consequências.
- (c) Um banco decide reduzir drasticamente  $\alpha$  para evitar bloqueios indevidos. O que provavelmente acontece com  $\beta$ ? Como isso afeta a segurança do sistema?
- (d) Qual estratégia, além de ajustar  $\alpha$ , o banco poderia adotar para reduzir simultaneamente os dois tipos de erro?

### 1.9.4 Etapas do teste de hipóteses

Uma indústria alimentícia afirma que suas embalagens de 500 g têm peso médio igual ao valor declarado. Sabe-se que o peso segue distribuição normal. Um fiscal coleta uma amostra de 25 embalagens e obtém  $\bar{x} = 496$  g e  $s = 8$  g.

- (a) Identifique as cinco etapas do teste de hipóteses para esse problema.
- (b) Formule  $H_0$  e  $H_a$  para verificar se o peso médio é diferente de 500 g.
- (c) Qual informação ainda é necessária para concluir o teste? Que teste seria adequado aqui:  $z$ -teste ou  $t$ -teste? Por quê?

## 2 O $z$ -Teste

O  $z$ -teste é utilizado para testar afirmações acerca da média de uma população quando o desvio padrão populacional  $\sigma$  é *conhecido*. A estatística de teste é denominada  $z$ -score e é definida por:

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Na expressão acima:  $\mu_0$  é o valor da média populacional sob  $H_0$ ;  $\sigma$  é o desvio padrão populacional (conhecido);  $n$  é o tamanho da amostra; e  $\bar{x}$  é a média amostral. O  $z$ -score indica quantos *erros padrão* existem entre a média amostral e a suposta média da população. Quanto maior o valor absoluto do  $z$ -score, menos provável é a amostra presumindo que  $H_0$  seja verdadeira.

**Interpretação do  $z$ -score.** O  $z$ -score mede:

quantos erros padrão a média amostral está distante de  $\mu_0$

- $z \approx 0$  dados compatíveis com  $H_0$
- $|z|$  grande dados improváveis sob  $H_0$

### 2.1 Passos do $z$ -teste

1. **Declarar as hipóteses:**

- $H_0$ :  $\mu = \mu_0$
- $H_a$ :  $\mu \neq \mu_0$  (bicaudal), ou  $\mu > \mu_0$  (unicaudal à direita), ou  $\mu < \mu_0$  (unicaudal à esquerda)

2. **Computar o  $z$ -score** a partir da amostra usando a fórmula acima.

3. **Encontrar o  $p$ -valor** associado ao  $z$ -score:

- $H_a$ :  $\mu > \mu_0 \rightarrow p = \Pr(Z > z_{\text{obs}})$
- $H_a$ :  $\mu < \mu_0 \rightarrow p = \Pr(Z < z_{\text{obs}})$
- $H_a$ :  $\mu \neq \mu_0 \rightarrow p = 2 \Pr(Z > |z_{\text{obs}}|)$

4. **Interpretar o resultado:** rejeitar  $H_0$  se  $p \leq \alpha$ ; caso contrário, não rejeitar  $H_0$ .

### 2.2 Condições de aplicabilidade

Para que o  $z$ -teste seja válido, devem ser verificadas as seguintes condições:

- O valor de  $\sigma$  é conhecido (não estimado a partir dos dados da amostra).
- A população é aproximadamente normal, *ou* o tamanho da amostra é suficientemente grande para que o Teorema Central do Limite garanta a normalidade da distribuição amostral da média. Na prática,  $n \geq 30$  é frequentemente usado como regra heurística, mas o limiar adequado depende da forma da distribuição populacional: distribuições muito assimétricas ou com caudas pesadas podem requerer

amostras maiores. Para amostras pequenas com  $\sigma$  conhecido, a normalidade da população deve ser verificada com base em conhecimento prévio ou análise exploratória.

- As observações representam unidades selecionadas aleatoriamente e podem ser tratadas como independentes. Em uma AAS sem reposição de população finita, a independência não é literal; a aproximação i.i.d. costuma ser razoável quando a fração amostral é pequena. Caso contrário, é preciso considerar a correção para população finita.

## 2.3 Exemplos

### 2.3.1 Exemplo 1: Acidentes de trabalho (unicaudal à esquerda)

(Fonte: Morettin & Bussab, *Estatística Básica*, 5ª ed., p. 334.)

A média de horas perdidas com acidentes de trabalho tem sido de 60 h/homem/ano, com desvio padrão  $\sigma = 20$  h. Após um programa de prevenção, amostrou-se 9 indústrias, obtendo média de 50 h. Há evidência de melhoria ao nível de 5%?

**Solução**

(1) **Hipóteses:**  $H_0: \mu = 60$ ;  $H_a: \mu < 60$ .

(2) **Estatística de teste:**

$$Z = \frac{50 - 60}{20/\sqrt{9}} = \frac{-10}{6,67} \approx -1,5$$

(3) **p-valor:**  $p = \Pr(Z < -1,5) \approx 0,067$

(4) **Conclusão:** Como  $p = 0,067 > 0,05 = \alpha$ , não rejeitamos  $H_0$ . Não há evidência suficiente para afirmar que o programa de prevenção reduziu o número de horas perdidas. O resultado está próximo do limiar de significância, mas não constitui evidência suficiente ao nível adotado.

```
from scipy.stats import norm
import numpy as np

alpha = 0.05
z_score = (50 - 60) / (20 / np.sqrt(9))    # -> -1.5
p_value = norm.cdf(z_score)                # -> 0.0668
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

### 2.3.2 Exemplo 2: Índice de nicotina (unicaudal à esquerda)

(Fonte: Morettin & Bussab, *Estatística Básica*, 5ª ed., p. 334.)

Um fabricante de cigarros anuncia que o índice médio de nicotina está abaixo de 23 mg. Um laboratório realiza 6 análises: 27, 24, 21, 25, 26, 22. Sabe-se que  $\sigma^2 = 4,86 \text{ mg}^2$ . Os dados fornecem evidência estatística que sustente a afirmação do fabricante ao nível de 10%?

**Solução**

(1) **Hipóteses:**  $H_0: \mu \geq 23$ ;  $H_a: \mu < 23$ . Para o cálculo, usamos o valor de fronteira  $\mu_0 = 23$ .

(2) **Estatística de teste:**  $\bar{x} = 24,17$ ,  $\sigma = \sqrt{4,86} \approx 2,20$ ,

$$Z = \frac{24,17 - 23}{2,20/\sqrt{6}} \approx 1,302$$

(3) **p-valor:** Para  $H_a: \mu < 23$  (unicaudal à esquerda):  $p = \Pr(Z < 1,302) \approx 0,904$ .

(4) **Conclusão:** Como  $p \gg \alpha = 0,10$ , não rejeitamos  $H_0$ . Os dados não sustentam a alegação do fabricante: a média amostral (24,17 mg) é *maior* do que 23 mg, apontando na direção oposta à hipótese alternativa. A decisão formal não prova que  $\mu \geq 23$ , mas tampouco oferece evidência para afirmar que  $\mu < 23$ .

```
import numpy as np
from scipy.stats import norm

amostra = [27, 24, 21, 25, 26, 22]
mu0, sigma = 23, np.sqrt(4.86)
x_bar = np.mean(amostra)
z_score = (x_bar - mu0) / (sigma / np.sqrt(len(amostra)))
p_value = norm.cdf(z_score) # unicaudal a esquerda
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

### 2.3.3 Exemplo 3: Tempo de aprendizado (unicaudal à esquerda)

(Fonte: Morettin & Bussab, 5ª ed., p. 334.)

O tempo de aprendizado de uma máquina segue  $\mathcal{N}(25, 100)$ . Uma nova técnica foi testada em 16 operários: tempo médio de 20,5 h. A técnica é melhor ao nível de 5%?

(1) **Hipóteses:**  $H_0: \mu = 25$ ;  $H_a: \mu < 25$ .

(2) **Estatística de teste:**

$$Z = \frac{20,5 - 25}{10/\sqrt{16}} = \frac{-4,5}{2,5} = -1,8$$

(3) **p-valor:**  $p = \Pr(Z < -1,8) \approx 0,036$

(4) **Conclusão:** Como  $p = 0,036 < 0,05 = \alpha$ , rejeitamos  $H_0$ . Há evidência para afirmar que a nova técnica reduziu o tempo médio de aprendizado.

### 2.3.4 Exemplo 4: Peso de pinguins (bicaudal)

O peso médio de pinguins-rei em uma região da Antártica era 15,4 kg. Em uma amostra de 35 pinguins deste ano, o peso médio é 14,6 kg. Com  $\sigma = 2,5$  kg, há evidência de que o peso médio mudou ( $\alpha = 0,05$ )?

(1) **Hipóteses:**  $H_0: \mu = 15,4$ ;  $H_a: \mu \neq 15,4$  (bicaudal).

(2) **Estatística de teste:**

$$Z = \frac{14,6 - 15,4}{2,5/\sqrt{35}} \approx -1,893$$

(3) **p-valor:**  $p = 2 \Pr(Z < -1,893) \approx 0,0584$

(4) **Conclusão:** Como  $p = 0,058 > 0,05 = \alpha$ , não rejeitamos  $H_0$ . Não há evidência suficiente para afirmar que o peso médio dos pinguins mudou.

```
import numpy as np
from scipy.stats import norm

z_score = (14.6 - 15.4) / (2.5 / np.sqrt(35))
p_value = 2 * norm.cdf(z_score) # bicaudal
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

## 2.4 Implementação em Python

A função utilitária a seguir encapsula o  $z$ -teste para uma amostra, permitindo testes uni e bilaterais:

```
from scipy.stats import norm
import numpy as np

def z_test_1sample(sample, mu0, sigma, alternative='two-sided',
    alpha=0.05):
    sample = np.array(sample)
    n = len(sample)
    mean = np.mean(sample)
    se = sigma / np.sqrt(n) # erro padrao
    z_stat = (mean - mu0) / se # estatistica de teste

    if alternative == 'two-sided':
        p_value = 2 * norm.sf(abs(z_stat))
    elif alternative == 'less':
        p_value = norm.cdf(z_stat)
    elif alternative == 'greater':
        p_value = 1 - norm.cdf(z_stat)

    decision = "Rejeita H0" if p_value < alpha else "Nao rejeita H0"
    print(f"z = {z_stat:.4f}, p-valor = {p_value:.4f}")
    print(f"Decisao ao nivel {alpha}: {decision}")
    return z_stat, p_value, decision
```

### Pergunta 3

Um pesquisador quer testar se a média de uma população mudou de um valor de referência  $\mu_0 = 100$ . Ele dispõe de  $\sigma = 15$  e coleta uma amostra com  $n = 36$  e  $\bar{x} = 95$ .

- (a) Formule as hipóteses para um teste bicaudal.
- (b) Calcule o  $z$ -escore.
- (c) Calcule o  $p$ -valor e conclua ao nível de significância  $\alpha = 0,05$ .

## 2.5 Exercícios de fixação

### 2.5.1 Tempo de processamento de pedidos

Uma empresa afirma que o tempo médio de processamento de pedidos é de 5 dias. Um auditor coletou uma amostra de  $n = 36$  pedidos e obteve  $\bar{x} = 5,8$  dias. Sabe-se que  $\sigma = 1,5$  dias.

- (a) Formule as hipóteses para verificar se o tempo médio é *maior* do que o alegado.
- (b) Calcule o  $z$ -escore.
- (c) Calcule o  $p$ -valor e conclua ao nível  $\alpha = 0,05$ .
- (d) Repita a análise para  $\alpha = 0,01$ . A conclusão muda?

### 2.5.2 Consumo de energia elétrica

O consumo médio mensal de energia elétrica residencial em uma cidade é historicamente de  $\mu_0 = 220$  kWh, com desvio padrão populacional  $\sigma = 40$  kWh. Após uma campanha de conscientização, uma amostra de  $n = 64$  residências registrou consumo médio de  $\bar{x} = 208$  kWh.

- (a) Formule as hipóteses adequadas para verificar se a campanha reduziu o consumo.
- (b) Calcule o  $z$ -escore e o  $p$ -valor.
- (c) Conclua ao nível  $\alpha = 0,05$ .
- (d) A que conclusão você chegaria se o tamanho da amostra fosse  $n = 16$ , mantendo os demais valores? Discuta o efeito do tamanho amostral.

### 2.5.3 Teor de cafeína em bebidas

Um fabricante declara que suas latas de refrigerante contêm em média  $\mu_0 = 35$  mg de cafeína por 100 ml, com desvio padrão  $\sigma = 3$  mg. Um laboratório independente analisa 50 latas e obtém  $\bar{x} = 36,2$  mg.

- (a) Formule as hipóteses para um teste bicaudal.
- (b) Calcule o  $z$ -escore e o  $p$ -valor.
- (c) Conclua ao nível  $\alpha = 0,05$  e interprete o resultado no contexto do problema.
- (d) O resultado seria diferente para um teste unicaudal à direita? Justifique, recalculando o  $p$ -valor.

### 2.5.4 Condições de aplicabilidade

Para cada situação abaixo, indique se o  $z$ -teste é aplicável e justifique com base nas condições de validade do teste:

- (a)  $n = 8$ , população com distribuição desconhecida,  $\sigma$  conhecido.
- (b)  $n = 50$ , população normal,  $\sigma$  desconhecido.
- (c)  $n = 100$ ,  $\sigma$  conhecido, mas os dados apresentam forte dependência temporal.
- (d)  $n = 40$ , população assimétrica,  $\sigma$  conhecido.

## 3 O $t$ -Teste

Na prática, o desvio padrão populacional  $\sigma$  raramente é conhecido. Nesse caso, o procedimento padrão para inferir sobre médias usa o  **$t$ -score**, em um procedimento conhecido como  **$t$ -teste**. Para amostras grandes, a distribuição  $t$  se aproxima da normal padrão, mas o uso da distribuição  $t$  preserva a incerteza introduzida por estimar  $\sigma$  com os próprios dados.

**Por que mudar de  $z$  para  $t$ ?** No  $z$ -teste, assumimos que  $\sigma$  é conhecido.

Na prática, isso raramente acontece. Em vez disso, estimamos  $\sigma$  pelo desvio padrão amostral  $s$ , calculado a partir dos próprios dados. Essa estimativa introduz uma fonte adicional de incerteza, afinal,  $s$  também varia de amostra para amostra.

Essa incerteza adicional é capturada pela **distribuição  $t$  de Student**, que possui caudas mais pesadas do que a normal padrão. Intuitivamente, caudas mais pesadas significam que valores extremos são mais prováveis, o que é coerente com a maior variabilidade introduzida por estimar  $\sigma$ .

**Ideia-chave:** o  $t$ -teste é uma versão do  $z$ -teste que incorpora a incerteza adicional de se estimar  $\sigma$  a partir da amostra. À medida que  $n$  cresce,  $s$  converge para  $\sigma$  e a distribuição  $t$  se aproxima da normal padrão.

Há três tipos de  $t$ -teste, conforme descrito na tabela abaixo:

| Tipo                                   | Situação                                                             | $H_0$           |
|----------------------------------------|----------------------------------------------------------------------|-----------------|
| $t$ -teste para uma amostra            | Comparar a média amostral com um valor de referência $\mu_0$         | $\mu = \mu_0$   |
| $t$ -teste para amostras pareadas      | Comparar médias de duas situações relacionadas (ex.: antes e depois) | $\mu_d = 0$     |
| $t$ -teste para amostras independentes | Comparar médias de dois grupos distintos                             | $\mu_1 = \mu_2$ |

Antes de detalhar os diferentes tipos de  $t$ -teste, vale a pena organizar a decisão sobre *qual teste usar* em cada situação. A Figura 4 resume esse processo.




Figura 4: Fluxograma simplificado para escolha do teste de hipóteses ao comparar médias.

### 3.1 $t$ -teste para uma amostra

O  $t$ -teste para uma amostra verifica se a média de uma população é igual a um valor de referência  $\mu_0$ , quando  $\sigma$  é desconhecido. A estatística de teste é o  $t$ -escore:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

onde  $s$  é o desvio padrão *amostral* (calculado com divisor  $n-1$ ). Sob  $H_0$  e com a população aproximadamente normal, essa estatística segue a distribuição  $t$  de Student com  $\nu = n-1$  graus de liberdade.

#### 3.1.1 Passos do $t$ -teste para uma amostra

1. **Declarar as hipóteses:**  $H_0: \mu = \mu_0$  vs.  $H_a$  (uni ou bicaudal).
2. **Computar o  $t$ -escore** com  $s$  da amostra.
3. **Encontrar o  $p$ -valor** na distribuição  $t_{n-1}$ :
  - $H_a: \mu < \mu_0 \rightarrow p = \Pr(T_{n-1} < t_{\text{obs}})$
  - $H_a: \mu > \mu_0 \rightarrow p = \Pr(T_{n-1} > t_{\text{obs}})$
  - $H_a: \mu \neq \mu_0 \rightarrow p = 2 \Pr(T_{n-1} > |t_{\text{obs}}|)$

4. **Interpretar:** rejeitar  $H_0$  se  $p \leq \alpha$ ; caso contrário, não rejeitar  $H_0$ .

### 3.1.2 Condições de aplicabilidade

- As observações representam unidades selecionadas aleatoriamente e podem ser tratadas como independentes.
- Para amostras grandes, o Teorema Central do Limite torna a distribuição da média aproximadamente normal; a qualidade dessa aproximação depende da assimetria e das caudas da população. Para amostras pequenas, a normalidade da população (ou, na prática, a ausência de assimetrias severas e de outliers extremos) é importante para a validade do teste.

## 3.2 Exemplos

### 3.2.1 Exemplo 1: Máquina de garrafas (retomada)

Voltando ao exemplo motivador:  $n = 20$  garrafas,  $\bar{x} = 491,57$  ml.  $H_0: \mu = 500$ ;  $H_a: \mu < 500$ .  $\sigma$  é desconhecido: usamos o  $t$ -teste.

```
import numpy as np
from scipy import stats

volumes = np.array([484.11, 459.49, 471.38, 512.01, 494.48,
                    528.63, 493.64, 485.03, 473.88, 501.59,
                    502.85, 538.08, 465.68, 495.03, 475.32,
                    529.41, 518.13, 464.32, 449.08, 489.27])

mu0 = 500
t_stat, p_bilateral = stats.ttest_1samp(volumes, popmean=mu0)

# Ajuste para unicaudal a esquerda
p_one = p_bilateral / 2 if t_stat < 0 else 1 - p_bilateral / 2
print(f"t = {t_stat:.4f}, p (unicaudal) = {p_one:.4f}")
```

**Resultados:**  $\bar{x} = 491,57$ ,  $s = 25,11$ ,  $t \approx -1,520$ ,  $p \approx 0,072$ .

**Conclusão:** Como  $p = 0,072 > 0,05$ , não rejeitamos  $H_0$ . Apesar da média amostral estar abaixo de 500 ml, a variabilidade é grande o suficiente para que essa diferença não seja estatisticamente significativa ao nível de 5%. O fabricante não tem evidência suficiente para afirmar que a máquina está desregulada. O resultado está próximo do limiar de significância, o que pode motivar uma investigação mais aprofundada, possivelmente com uma amostra maior.

### 3.2.2 Exemplo 2: Peso de recém-nascidos com SIDS (bicaudal)

Uma amostra de  $n = 10$  pesos (em gramas) de recém-nascidos com SIDS:

2998, 3740, 2031, 2804, 2454, 2780, 2203, 3803, 3948, 2144

Queremos testar, ao nível  $\alpha = 10\%$ , se bebês com SIDS possuem peso médio diferente da população geral, que é  $\mu_0 = 3300$  g.

(1) **Hipóteses:**  $H_0: \mu = 3300$ ;  $H_a: \mu \neq 3300$  (bicaudal).

(2) **Estatística de teste:**  $\bar{x} = 2890,5$  g,  $s = 720,0$  g,

$$t = \frac{2890,5 - 3300}{720,0/\sqrt{10}} = -1,80$$

A estatística segue  $t_9$  (9 graus de liberdade).

(3) **p-valor:**  $p = 2 \Pr(T_9 < -1,80) \approx 0,105$ .

(4) **Conclusão:** Como  $p = 0,105 > 0,10 = \alpha$ , não rejeitamos  $H_0$ . Não há evidência estatística suficiente para afirmar que o peso médio de recém-nascidos com SIDS difere da média geral.

```
import numpy as np
from scipy.stats import t

amostra = np.array([2998, 3740, 2031, 2804, 2454,
                    2780, 2203, 3803, 3948, 2144])
n, mu_0 = 10, 3300
x_bar = np.mean(amostra)          # 2890.5
s = np.std(amostra, ddof=1)       # 720.0
t_score = (x_bar - mu_0) / (s / np.sqrt(n))    # -1.80
pvalue = 2 * t.cdf(t_score, df=n-1)
print(f"t = {t_score:.4f}, p = {pvalue:.4f}")
```

### 3.3 t-teste para amostras pareadas

O  $t$ -teste para amostras pareadas é aplicado quando há uma correspondência um-a-um entre os elementos das duas amostras. Os casos mais comuns são:

- Medições antes e depois de uma intervenção no mesmo indivíduo.
- Dois tratamentos aplicados ao mesmo objeto, em ordens diferentes.

A ideia é reduzir o problema às diferenças individuais. Neste exemplo, adotaremos  $d_i = \text{Depois}_i - \text{Antes}_i$ , de modo que uma melhora corresponda a  $d_i > 0$ , e então aplicaremos o  $t$ -teste para uma amostra sobre essas diferenças:

$$t = \frac{\bar{d} - \mu_{d_0}}{s_d / \sqrt{n}}$$

onde  $\bar{d}$  é a média das diferenças,  $s_d$  é o desvio padrão das diferenças e  $\mu_{d_0}$  é o valor de referência (usualmente 0, testando se a intervenção teve efeito).

#### 3.3.1 Hipóteses

- $H_0$ :  $\mu_d = 0$  (a intervenção não teve efeito médio)
- $H_a$ :  $\mu_d \neq 0$ , ou  $\mu_d > 0$ , ou  $\mu_d < 0$

Além do pareamento correto, as diferenças  $d_i$  devem corresponder a pares independentes entre si. Para amostras pequenas, sua distribuição deve ser aproximadamente normal ou não apresentar assimetrias severas e outliers extremos.

### 3.3.2 Exemplo: Eficiência de um programa de treinamento

Um programa de treinamento cognitivo foi avaliado em 8 indivíduos. Os escores (em pontos) foram registrados antes e depois do programa:

| Indivíduo           | 1  | 2  | 3  | 4  | 5  | 6  | 7  | 8  |
|---------------------|----|----|----|----|----|----|----|----|
| Antes               | 72 | 65 | 80 | 70 | 75 | 68 | 77 | 60 |
| Depois              | 78 | 70 | 85 | 68 | 80 | 74 | 82 | 67 |
| Diferença ( $d_i$ ) | 6  | 5  | 5  | -2 | 5  | 6  | 5  | 7  |

$H_0: \mu_d = 0$ ;  $H_a: \mu_d > 0$ . Testamos se o programa melhorou os escores ao nível  $\alpha = 5\%$ .

```
import numpy as np
from scipy import stats

antes = np.array([72, 65, 80, 70, 75, 68, 77, 60])
depois = np.array([78, 70, 85, 68, 80, 74, 82, 67])

# t-teste pareado: diferencas depois - antes
t_stat, p_bilateral = stats.ttest_rel(depois, antes)

# Unicaudal: Ha: diferenca > 0 (depois > antes)
p_one = p_bilateral / 2 if t_stat > 0 else 1 - p_bilateral / 2
print(f"t = {t_stat:.4f}, p (unicaudal) = {p_one:.4f}")
```

**Nota:** `ttest_rel(depois, antes)` calcula as diferenças `depois - antes`, exatamente como a tabela. Como esperamos que “depois > antes” (melhora), as diferenças tendem a ser positivas e usamos o teste unicaudal à direita.

## 3.4 t-teste para duas amostras independentes

O *t*-teste para duas amostras independentes compara as médias de dois grupos distintos, sem qualquer correspondência entre os elementos. A hipótese nula é  $H_0: \mu_1 = \mu_2$ , ou equivalentemente,  $H_0: \mu_1 - \mu_2 = 0$ .

### 3.4.1 Teste de Welch

A variante mais robusta é o **teste de Welch**, que não supõe igualdade das variâncias populacionais. A estatística de teste é:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

Os graus de liberdade são calculados pela fórmula de Welch–Satterthwaite:

$$\nu = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

**Atenção: Welch vs.  $t$ -teste padrão.** O  $t$ -teste padrão (`equal_var=True`) pode ser ligeiramente mais potente quando a suposição de igualdade de variâncias é válida, mas perde confiabilidade se ela for violada. O teste de Welch (`equal_var=False`) é mais robusto e deve ser a opção padrão quando houver dúvida sobre a igualdade das variâncias, especialmente com tamanhos amostrais diferentes.

### 3.4.2 Condições de aplicabilidade

- As observações são independentes dentro de cada grupo e entre os grupos.
- Para amostras pequenas, ambas as populações são aproximadamente normais ou não apresentam assimetrias severas e outliers extremos. Para amostras grandes, a aproximação pela distribuição  $t$  tende a ser robusta a desvios moderados de normalidade.

Como decidir entre os testes.

- **Pareado:** mesmas unidades medidas duas vezes (antes/depois)
- **Independente:** grupos distintos (ex.: tratamento vs controle)

**Regra simples:** existe correspondência 1:1 entre observações? use pareado.

## 3.5 Exemplos

### 3.5.1 Exemplo 1: Níveis de colesterol em dois grupos

Dois grupos de indivíduos foram avaliados quanto ao nível de colesterol (mg/dL). Grupo A ( $n_1 = 20$ ) e Grupo B ( $n_2 = 20$ ). Há diferença estatisticamente significativa entre as médias ao nível  $\alpha = 5\%$ ?

**(1) Hipóteses:**  $H_0: \mu_1 = \mu_2$ ;  $H_a: \mu_1 \neq \mu_2$  (bicaudal).

**Estatísticas amostrais:**  $\bar{x}_1 = 245,05$ ,  $s_1 = 36,64$  (Grupo A);  $\bar{x}_2 = 210,30$ ,  $s_2 = 48,34$  (Grupo B).

**Estatística de teste:**

$$t = \frac{245,05 - 210,30}{\sqrt{36,64^2/20 + 48,34^2/20}} = \frac{34,75}{13,563} \approx 2,562$$

Graus de liberdade (Welch):  $\nu \approx 35,4$ .

**$p$ -valor:**  $p \approx 0,015$ .

**Conclusão:** Como  $p = 0,015 < 0,05 = \alpha$ , rejeitamos  $H_0$ . Há evidência de diferença estatisticamente significativa nos níveis de colesterol entre os dois grupos.

```
import numpy as np
from scipy import stats

grupo_a = np.array([233, 291, 312, 250, 246, 197, 268, 224, 239,
                    239,
                    254, 276, 234, 181, 248, 252, 202, 218, 212,
                    325])
grupo_b = np.array([344, 185, 263, 246, 224, 212, 188, 250, 148,
                    169,
```

```

                226, 175, 242, 252, 153, 183, 137, 202, 194,
                213])

t_stat, p_value = stats.ttest_ind(grupo_a, grupo_b, equal_var=
    False)
print(f"t = {t_stat:.4f}, p = {p_value:.4f}")

```

### 3.5.2 Exemplo 2: Desempenho por gênero em teste

Foram registradas as notas de 20 estudantes em um teste. Há diferença significativa entre alunas e alunos ao nível  $\alpha = 5\%$ ?

```

import pandas as pd
from scipy import stats

data = {
    "Score": [95, 100, 78, 68, 100, 95, 98, 79, 98, 95,
              90, 95, 98, 86, 100, 100, 78, 89, 89, 94],
    "Gender": [2, 1, 2, 2, 1, 2, 2, 2, 2, 1,
               1, 1, 1, 2, 1, 1, 2, 2, 2, 2] # 1=Feminino, 2=Masculino
}
df = pd.DataFrame(data)
fem = df[df["Gender"]==1]["Score"]
masc = df[df["Gender"]==2]["Score"]
t_stat, p = stats.ttest_ind(fem, masc, equal_var=False)
print(f"Media feminino: {fem.mean():.2f}, masculino: {masc.mean():.2f}")
print(f"t = {t_stat:.4f}, p = {p:.4f}")

```

O  $p$ -valor é menor que 0,05, indicando evidência de diferença entre as médias dos grupos observados. Nesta amostra, a média das alunas é maior; como os grupos não foram formados por um experimento aleatorizado, o teste não permite atribuir essa diferença ao gênero nem estabelecer causalidade.

## 3.6 Resumo das funções `scipy.stats` para $t$ -testes

| Função                                        | Tipo de $t$ -teste            | Hipótese nula   |
|-----------------------------------------------|-------------------------------|-----------------|
| <code>ttest_1samp(a, popmean)</code>          | Uma amostra                   | $\mu = \mu_0$   |
| <code>ttest_rel(a, b)</code>                  | Amostras pareadas             | $\mu_d = 0$     |
| <code>ttest_ind(a, b)</code>                  | Duas amostras independentes   | $\mu_1 = \mu_2$ |
| <code>ttest_ind(a, b, equal_var=False)</code> | Welch (variâncias diferentes) | $\mu_1 = \mu_2$ |

**$p$ -valor bilateral.** Todas as funções `scipy.stats` acima retornam o  $p$ -valor **bilateral**. Para testes unicaudais, é necessário ajustar manualmente:

```

# Para Ha: mu < mu0 (unicaudal a esquerda)
t_stat, p = stats.ttest_1samp(data, mu0)
p_one_sided = p / 2 if t_stat < 0 else 1 - (p / 2)

```

**Síntese:  $z$ -teste vs.  $t$ -teste.**

| Situação                                      | Teste                  | Estatística                                                        |
|-----------------------------------------------|------------------------|--------------------------------------------------------------------|
| $\sigma$ conhecido, $n$ grande ou pop. normal | $z$ -teste             | $Z = \frac{(\bar{x} - \mu_0)}{(\sigma/\sqrt{n})}$                  |
| $\sigma$ desconhecido, uma amostra            | $t$ -teste (1 amostra) | $t = \frac{(\bar{x} - \mu_0)}{(s/\sqrt{n})}$                       |
| $\sigma$ desconhecido, amostras pareadas      | $t$ -teste pareado     | $t = \frac{\bar{d}}{(s_d/\sqrt{n})}$                               |
| $\sigma$ desconhecido, amostras independentes | $t$ -teste Welch       | $t = \frac{(\bar{x}_1 - \bar{x}_2)}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$ |

**Pergunta 4**

Para cada situação abaixo, indique qual tipo de  $t$ -teste seria mais adequado e justifique:

- (a) Um pesquisador mede a pressão arterial de 15 pacientes antes e depois de administrar um medicamento.
- (b) Dois grupos de estudantes diferentes (grupo de estudo online vs. presencial) fazem o mesmo teste. O pesquisador quer comparar as médias.
- (c) Com  $\sigma$  populacional desconhecido, uma empresa quer verificar se o tempo médio de atendimento telefônico é igual a 5 minutos.

**3.7 Exercícios de fixação****3.7.1 Vida útil de baterias ( $t$ -teste para uma amostra)**

Um fabricante afirma que a vida útil média de suas baterias é de 200 horas. Uma amostra de  $n = 12$  baterias produziu  $\bar{x} = 195$  horas e  $s = 10$  horas.

- (a) Formule as hipóteses para verificar se a vida útil é *menor* do que o afirmado.
- (b) Calcule o  $t$ -score e os graus de liberdade.
- (c) Calcule o  $p$ -valor e conclua ao nível  $\alpha = 0,05$ .
- (d) Que condição sobre a distribuição dos dados é necessária para a validade deste teste, dado o tamanho da amostra?

**3.7.2 Programa de emagrecimento ( $t$ -teste pareado)**

Um nutricionista quer verificar se uma dieta reduziu o peso corporal de 10 pacientes. Os pesos (em kg) antes e depois do programa são:

|        |    |    |    |    |    |    |    |    |    |    |
|--------|----|----|----|----|----|----|----|----|----|----|
| Antes  | 85 | 92 | 78 | 95 | 88 | 76 | 90 | 83 | 97 | 80 |
| Depois | 82 | 89 | 75 | 91 | 84 | 74 | 86 | 80 | 93 | 77 |

- (a) Por que o  $t$ -teste pareado é mais adequado do que o  $t$ -teste para amostras independentes neste caso?
- (b) Calcule as diferenças  $d_i$ , a média  $\bar{d}$  e o desvio padrão  $s_d$ .
- (c) Realize o teste ao nível  $\alpha = 5\%$  e conclua.
- (d) Implemente o teste em Python usando `scipy.stats.ttest_rel`.

### 3.7.3 Desempenho acadêmico ( $t$ -teste independente)

Uma escola quer comparar o desempenho de turmas do turno da manhã e da tarde em uma prova. Os dados são: turno da manhã ( $n_1 = 20$ ,  $\bar{x}_1 = 74$ ,  $s_1 = 8$ ) e turno da tarde ( $n_2 = 25$ ,  $\bar{x}_2 = 70$ ,  $s_2 = 10$ ).

- (a) Formule as hipóteses para um teste bicaudal.
- (b) Aplique o teste de Welch e calcule o  $p$ -valor.
- (c) Conclua ao nível  $\alpha = 5\%$  e interprete.
- (d) Qual suposição adicional seria necessária para usar o  $t$ -teste padrão com `equal_var=True`?

### 3.7.4 Escolha do tipo de $t$ -teste

Para cada situação abaixo, identifique o tipo de  $t$ -teste mais adequado (uma amostra, pareado ou Welch) e justifique sua escolha:

- (a) Um pesquisador mede a pressão arterial de 15 pacientes antes e depois de administrar um medicamento.
- (b) Dois grupos de estudantes distintos (online vs. presencial) fazem o mesmo exame e o pesquisador quer comparar as notas médias.
- (c) Uma empresa quer verificar se o tempo médio de atendimento telefônico é diferente de 5 minutos, com base em uma amostra de 30 ligações.
- (d) O mesmo conjunto de 20 ratos recebe dois tratamentos diferentes (A e B) em momentos distintos e os pesquisadores registram a resposta imunológica em cada caso.

## 4 Poder do Teste

### 4.1 Definição

**Definição.** O *poder de um teste estatístico (power)* é a probabilidade de rejeitar corretamente a hipótese nula  $H_0$  quando ela é de fato falsa:

$$\text{Poder} = 1 - \beta$$

onde  $\beta = \Pr(\text{erro tipo II}) = \Pr(\text{não rejeitar } H_0 \mid H_0 \text{ falsa})$ .

Em termos práticos, o poder mede a capacidade do teste de detectar um efeito real quando ele existe.

Um teste com *baixo poder* pode falhar em detectar diferenças reais, levando a falsas conclusões de que “nada mudou”, o chamado erro tipo II. Por exemplo, imagine que uma nova medicação é genuinamente mais eficaz do que o placebo: um teste com baixo poder pode não detectar essa eficácia, levando à conclusão incorreta de que o medicamento não funciona.

**Ideia central.** Um resultado não significativo pode ocorrer por dois motivos completamente distintos:

- **O efeito não existe:**  $H_0$  é de fato verdadeira.
- **O efeito existe, mas o teste não teve poder suficiente para detectá-lo.**

**Mensagem importante:** “não rejeitar  $H_0$ ” não significa que não há efeito. Pode significar apenas que a amostra foi pequena demais para revelá-lo.

Para compreender intuitivamente os conceitos de erro tipo I, erro tipo II e poder do teste, é útil visualizar as distribuições da estatística sob  $H_0$  e sob  $H_a$ . A Figura 5 ilustra essa ideia.

- A curva azul representa a distribuição da estatística de teste assumindo que  $H_0$  é verdadeira.
- A curva vermelha representa a distribuição quando existe um efeito real ( $H_a$ ).
- O ponto  $c$  define a região crítica: valores à direita levam à rejeição de  $H_0$ .
- A área  $\alpha$  corresponde à região sob  $H_0$  à direita de  $c$  (área hachurada). Trata-se do erro tipo I.
- A área  $\beta$  corresponde à região sob  $H_a$  à esquerda de  $c$  (área cinza). Trata-se do erro tipo II.
- A área  $1 - \beta$  corresponde à região sob  $H_a$  à direita de  $c$  (área verde). Trata-se do poder do teste.

**Importante:** as regiões  $\alpha$  e  $1 - \beta$  ocupam o mesmo intervalo no eixo  $x$  (à direita de  $c$ ), mas são calculadas sob distribuições diferentes ( $H_0$  e  $H_a$ , respectivamente). Portanto, não devem ser interpretadas como a mesma área.

**Atenção: Cuidado: regiões no mesmo intervalo não são a mesma coisa.** As regiões  $\alpha$  e  $1 - \beta$  ocupam o mesmo intervalo no eixo  $x$  (à direita de  $c$ ), mas correspondem a probabilidades diferentes, pois são calculadas sob distribuições distintas:

- $\alpha$  é calculado sob a distribuição de  $H_0$
- $1 - \beta$  é calculado sob a distribuição de  $H_a$

**Conclusão:** mesmo intervalo no eixo horizontal não implica mesma probabilidade.




Figura 5: Distribuições da estatística de teste sob  $H_0$  e sob  $H_a$ . A região  $\alpha$  representa o erro tipo I, a região  $\beta$  representa o erro tipo II, e a região  $1 - \beta$  representa o poder do teste.

## 4.2 Fatores que afetam o poder

O poder de um teste aumenta quando a diferença entre as médias é grande em relação à variabilidade dos dados, e quando a amostra é grande. Formalmente, os quatro fatores principais são:

1. **Tamanho da amostra  $n$ :** quanto maior a amostra, menor o erro padrão, mais fácil é distinguir a média real de  $\mu_0$  e, portanto, maior o poder.
2. **Nível de significância  $\alpha$ :** um  $\alpha$  maior (ex.: 0,10 em vez de 0,05) aumenta o poder, mas também eleva a probabilidade de erro tipo I. Alterar  $\alpha$  raramente é a estratégia mais adequada para aumentar o poder.
3. **Tamanho do efeito:** efeitos maiores (diferença entre a média real e  $\mu_0$ , relativa à variabilidade) são mais fáceis de detectar e aumentam o poder.
4. **Variabilidade dos dados:** menor variabilidade (desvio padrão menor) resulta em maior poder, pois o sinal fica mais claro em relação ao ruído.

## 4.3 Impacto da variabilidade no poder

A Figura 6 ilustra o efeito da variabilidade sobre o poder do teste. Em ambos os cenários, a diferença entre as médias dos grupos A e B é a mesma ( $\mu_A = 100$ ,  $\mu_B = 110$ ). O que muda é o desvio padrão.

### 4.3.1 Simulação: poder vs. variabilidade em Python

```
import numpy as np
from scipy.stats import ttest_ind

np.random.seed(42)
n = 30
mean_a, mean_b = 100, 110

# Cenário 1: baixa variabilidade
```




Figura 6: Mesma diferença de médias ( $\Delta = 10$ ) em dois cenários de variabilidade. Com baixa variabilidade (esq.), os grupos se sobrepõem pouco, o teste tem alto poder. Com alta variabilidade (dir.), a sobreposição é grande e o teste tem dificuldade em distinguir os grupos.

```
std_low = 5
grupo_a_low = np.random.normal(mean_a, std_low, n)
grupo_b_low = np.random.normal(mean_b, std_low, n)
t_low, p_low = ttest_ind(grupo_a_low, grupo_b_low)
print(f"Baixa variabilidade: p = {p_low:.4f}")

# Cenário 2: alta variabilidade
std_high = 20
grupo_a_high = np.random.normal(mean_a, std_high, n)
grupo_b_high = np.random.normal(mean_b, std_high, n)
t_high, p_high = ttest_ind(grupo_a_high, grupo_b_high)
print(f"Alta variabilidade: p = {p_high:.4f}")
```

**Resultado esperado:** o cenário de baixa variabilidade produz  $p$ -valor muito pequeno (rejeita  $H_0$ ), enquanto o de alta variabilidade pode não rejeitar  $H_0$ , mesmo a diferença de médias sendo a mesma. Isso ilustra que **alta variabilidade dificulta a detecção de efeitos reais**.

## 4.4 Relação entre poder, erro tipo I e tamanho amostral

Síntese: poder do teste.

| Para aumentar o poder... | Efeito colateral                   |
|--------------------------|------------------------------------|
| Aumentar $n$             | Custo mais alto de coleta          |
| Aumentar $\alpha$        | Maior probabilidade de erro tipo I |
| Reduzir a variabilidade  | Nem sempre controlável             |
| Estudar efeitos maiores  | Pode não ser o objetivo            |

**Recomendação:** o aumento do tamanho amostral é a estratégia mais eficaz e controlável para aumentar o poder sem comprometer a taxa de erro tipo I.

**Pergunta 5**

Um pesquisador aplica um  $t$ -teste e obtém  $p = 0,12$  com  $n = 15$ . Ele conclui que “não há diferença entre os grupos”.

- (a) Essa conclusão é necessariamente correta? Que erro pode estar ocorrendo?
- (b) Que medidas o pesquisador poderia tomar para aumentar o poder do teste?

**4.5 Exercícios de fixação****4.5.1 Poder e tamanho amostral**

Um pesquisador aplica um  $t$ -teste com  $n = 10$  e obtém  $p = 0,09$  para  $\alpha = 0,05$ .

- (a) Qual é a decisão do pesquisador? Que tipo de erro ele pode estar cometendo?
- (b) Se o pesquisador repetir o estudo com  $n = 40$ , mantendo os demais parâmetros, o que provavelmente acontecerá com o  $p$ -valor e o poder do teste? Justifique.
- (c) O pesquisador decide aumentar  $\alpha$  para 0,10. Isso resolve o problema do poder? Quais são os riscos dessa estratégia?

**4.5.2 Interpretação de resultado não significativo**

Um ensaio clínico compara um novo medicamento com placebo em  $n = 20$  pacientes por grupo e obtém  $p = 0,15$  com  $\alpha = 0,05$ .

- (a) A conclusão “o medicamento não tem efeito” é válida? Explique.
- (b) O que significa dizer que o teste tem baixo poder nesse contexto?
- (c) Que informação adicional (além do  $p$ -valor) seria útil para avaliar se o efeito do medicamento é clinicamente relevante?
- (d) Proponha duas estratégias para aumentar o poder em um novo ensaio.

**4.5.3 Trade-off entre erros tipo I e tipo II**

Considere dois cenários de uso de testes de hipóteses:

- Cenário A: triagem de segurança em aviação, em que  $H_0$ : “passageiro não é ameaça”.
- Cenário B: aprovação de um medicamento contra gripe comum, em que  $H_0$ : “o medicamento não é eficaz”.

- (a) Para cada cenário, identifique qual erro (tipo I ou tipo II) é mais grave e justifique.
- (b) Como a escolha de  $\alpha$  deveria diferir entre os dois cenários? Explique o impacto sobre  $\beta$ .
- (c) Em qual cenário é mais importante garantir alto poder? Por quê?

#### 4.5.4 Fatores que afetam o poder: análise integrada

Um pesquisador deseja detectar uma diferença de 5 pontos na média de um escore cognitivo entre dois grupos, sabendo que o desvio padrão típico é  $\sigma = 15$ .

- Sem calcular formalmente, argumente por que um estudo com  $n = 10$  por grupo terá dificuldade em detectar essa diferença.
- O que acontece com o poder se o pesquisador usar  $n = 100$  por grupo? E se o desvio padrão for  $\sigma = 5$ ?
- Se a diferença real entre os grupos fosse de 15 pontos (em vez de 5), como isso afetaria o poder para um mesmo  $n$ ?
- Implemente em Python uma simulação com 1000 repetições para estimar o poder do teste para  $n \in \{10, 30, 100\}$ , assumindo  $\sigma = 15$  e diferença real de 5 pontos.

## 5 Resumo

A tabela abaixo sintetiza os principais testes de hipóteses estudados:

| Teste              | Quando usar                                   | Estatística                                                      | Distribuição        |
|--------------------|-----------------------------------------------|------------------------------------------------------------------|---------------------|
| $z$ -teste         | $\sigma$ conhecido, $n$ grande ou pop. normal | $Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$                    | $\mathcal{N}(0, 1)$ |
| $t$ -teste (1 am.) | $\sigma$ desconhecido, uma amostra            | $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$                         | $t_{n-1}$           |
| $t$ -teste pareado | Duas amostras pareadas                        | $t = \frac{\bar{d}}{s_d/\sqrt{n}}$                               | $t_{n-1}$           |
| $t$ -teste Welch   | Duas amostras independentes                   | $t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$ | $t_\nu$             |

**Mensagem central.** O teste de hipóteses é um procedimento formal para avaliar evidências amostrais contra uma afirmação sobre um parâmetro populacional. A regra de decisão é sempre baseada na comparação do  $p$ -valor com o nível de significância  $\alpha$  previamente definido. A escolha do teste adequado depende do que é conhecido sobre a população ( $\sigma$ ), da estrutura do delineamento (uma ou duas amostras, pareadas ou independentes) e do tamanho amostral. O poder do teste (i.e., a capacidade de detectar efeitos reais) aumenta principalmente com o tamanho da amostra. Lembre-se também que significância estatística e relevância prática são conceitos distintos: um efeito pode ser estatisticamente detectável, mas irrelevante na prática, ou relevante na prática, mas difícil de detectar com uma amostra pequena.

## 6 Diagnóstico e Consolidação Conceitual

Esta seção tem como objetivo identificar e corrigir erros conceituais comuns, além de estimular uma compreensão mais profunda dos conceitos abordados.

## 6.1 Quiz diagnóstico: erros clássicos

Para cada afirmação abaixo, indique se ela é *verdadeira* ou *falsa* e justifique brevemente sua resposta.

1. “Se o  $p$ -valor é 0,03, então há 3% de probabilidade de que a hipótese nula seja verdadeira”.
2. “Se não rejeitamos  $H_0$ , então ela deve ser verdadeira”.
3. “Quanto menor o  $p$ -valor, maior é a magnitude do efeito observado”.
4. “Em geral, aumentar o tamanho da amostra tende a diminuir o  $p$ -valor quando existe um efeito real, pois reduz o erro padrão e aumenta a evidência estatística. Contudo, isso não é garantido para qualquer amostra específica”.
5. “Fixar  $\alpha = 0,01$  sempre leva a conclusões mais confiáveis do que  $\alpha = 0,05$ ”.
6. “Se um resultado não é estatisticamente significativo, então não há diferença entre os grupos”.
7. “Quando  $\sigma$  é desconhecido, o  $t$ -teste é o procedimento padrão para a média; para amostras grandes, seus resultados se aproximam dos do  $z$ -teste.”

## 6.2 Questões conceituais

Explique cada questão abaixo como se estivesse ensinando a um colega que nunca estudou estatística. Evite fórmulas sempre que possível e priorize intuição e exemplos. Se você consegue responder essas perguntas de forma clara, sem recorrer a fórmulas, então você provavelmente desenvolveu uma compreensão sólida dos conceitos fundamentais de teste de hipóteses.

1. Explique, em termos simples, o que significa rejeitar  $H_0$ . O que exatamente estamos afirmando (e o que não estamos afirmando)?
2. Explique por que o  $p$ -valor não é a probabilidade de a hipótese nula ser verdadeira.
3. Explique a diferença entre erro tipo I e erro tipo II usando um exemplo do mundo real (por exemplo, um teste médico ou sistema de detecção de fraude).
4. Explique por que um resultado pode não ser estatisticamente significativo mesmo quando existe uma diferença real entre os grupos.
5. Explique por que aumentar o tamanho da amostra aumenta o poder do teste.
6. Explique a diferença entre testes unicaudais e bicaudais. Em que situações cada um deve ser usado?
7. Um resultado é estatisticamente significativo com  $p = 0,001$ . Isso necessariamente significa que o efeito é relevante na prática? Justifique com um exemplo.