Testes de Hipóteses

Notas de Aula

Prof. Eduardo Bezerra

Sumário

1 Fundamentos do Teste de Hipóteses **4**
1.1 Motivação . . . 4
1.2 Definição e etapas . . . 4
1.3 A lógica do teste de hipóteses . . . 6
1.4 Hipóteses nula e alternativa . . . 7
1.4.1 Exemplos de formulação . . . 8
1.5 Estatística de teste . . . 9
1.6 O p-valor . . . 10
1.6.1 Cálculo do p-valor conforme a hipótese alternativa . . . 10
1.7 Nível de significância e regra de decisão . . . 11
1.8 Tipos de erro . . . 13
1.9 Exercícios de fixação . . . 14

2 O z-Teste **15**
2.1 Passos do z-teste . . . 16
2.2 Condições de aplicabilidade . . . 16
2.3 Exemplos . . . 17
2.3.1 Exemplo 1: Acidentes de trabalho (unicaudal à esquerda) . . . 17
2.3.2 Exemplo 2: Índice de nicotina (unicaudal à esquerda) . . . 17
2.3.3 Exemplo 3: Tempo de aprendizado (unicaudal à esquerda) . . . 18
2.3.4 Exemplo 4: Peso de pinguins (bicaudal) . . . 18
2.4 Implementação em Python . . . 19
2.5 Exercícios de fixação . . . 20

3 O t-Teste **21**
3.1 t-teste para uma amostra . . . 22
3.1.1 Passos do t-teste para uma amostra . . . 22
3.1.2 Condições de aplicabilidade . . . 23
3.2 Exemplos . . . 23
3.2.1 Exemplo 1: Máquina de garrafas (retomada) . . . 23
3.2.2 Exemplo 2: Peso de recém-nascidos com SIDS (bicaudal) . . . 23
3.3 t-teste para amostras pareadas . . . 24
3.3.1 Hipóteses . . . 24
3.4 t-teste para duas amostras independentes . . . 25
3.4.1 Teste de Welch . . . 25
3.4.2 Condições de aplicabilidade . . . 26
3.5 Exemplos . . . 26
3.5.1 Exemplo 1: Níveis de colesterol em dois grupos . . . 26
3.5.2 Exemplo 2: Desempenho por gênero em teste . . . 27

3.6 Resumo das funções `scipy.stats` para t-testes 27
3.7 Exercícios de fixação 28

4 Poder do Teste **30**
4.1 Definição 30
4.2 Fatores que afetam o poder 31
4.3 Impacto da variabilidade no poder 32
4.4 Relação entre poder, erro tipo I e tamanho amostral 33
4.5 Exercícios de fixação 33

5 Resumo **34**

6 Diagnóstico e Consolidação Conceitual **35**
6.1 Quiz diagnóstico: erros clássicos 35
6.2 Questões conceituais 35

Objetivos

Ao final da leitura, você deve ser capaz de:

Fundamentos do teste de hipóteses

- Explicar o propósito de um teste de hipóteses e distingui-lo da estimação intervalar.
- Formular corretamente as hipóteses nula e alternativa para problemas uni e bicaudais.
- Interpretar o p-valor e aplicar a regra de decisão baseada no nível de significância α.
- Identificar e distinguir os erros de tipo I e de tipo II, compreendendo suas consequências.

z-teste para a média $\star$

- Aplicar o z-teste quando o desvio padrão populacional σ é conhecido.
- Computar o z-escore e o p-valor para testes unilaterais e bilaterais.
- Verificar as condições de aplicabilidade do z-teste.

t-teste para a média $\star$

- Aplicar o t-teste para uma amostra quando σ é desconhecido.
- Distinguir o t-teste para uma amostra, para amostras pareadas e para duas amostras independentes.
- Computar o t-escore, os graus de liberdade e o p-valor correspondente.
- Verificar as condições de aplicabilidade do t-teste.

Poder do teste

- Definir o poder de um teste e relacioná-lo ao erro tipo II.
- Identificar os fatores que influenciam o poder: tamanho da amostra, nível de significância, tamanho do efeito e variabilidade.

Roteiro de leitura

Estas notas estão organizadas em quatro partes. A Seção 1 apresenta os fundamentos do teste de hipóteses: motivação, definições, tipos de erro, p-valor e nível de significância. A Seção 2 trata do z-teste, aplicável quando σ é conhecido e a amostra é grande. A Seção 3 apresenta o t-teste nas suas três variantes: uma amostra, amostras pareadas e duas amostras independentes. A Seção 4 discute o poder do teste e os fatores que o afetam. Os objetivos marcados com $\star$ são os mais centrais.

1 Fundamentos do Teste de Hipóteses

1.1 Motivação

Para motivar o uso do teste de hipóteses, considere a seguinte situação:

Situação-problema: máquina de preenchimento de garrafas

Uma máquina de preenchimento de garrafas está configurada para preencher cada garrafa com 500 ml de vinho. Sabe-se que o volume preenchido segue uma distribuição normal com variância desconhecida. O fabricante suspeita de que a máquina está preenchendo as garrafas com valores a menor, por estar desregulada.
Ele coleta uma amostra de 20 garrafas e mede o volume de cada uma:

484,11	459,49	471,38	512,01	494,48	528,63	493,64	485,03
473,88	501,59	502,85	538,08	465,68	495,03	475,32	529,41
		518,13	464,32	449,08	489,27		

O fabricante calcula a média amostral: $\overline{x} = 491{,}57$ ml. Com base nesse valor, que evidência ele tem para justificar ou refutar sua suspeita?

A intuição natural seria dizer: "a média amostral está abaixo de 500 ml, logo a máquina está desregulada". Mas essa conclusão ignora a variabilidade amostral. Mesmo que a máquina esteja perfeita ($\mu = 500$ ml), uma amostra de 20 garrafas pode perfeitamente ter média 491,57 ml apenas por acaso. O **teste de hipóteses** é o procedimento formal para quantificar essa incerteza e decidir, com base em evidência amostral, se o desvio observado é plausível sob a hipótese de que "nada mudou" ou se ele é improvável o suficiente para justificar a conclusão de que "algo de fato mudou".

Ideia central do teste de hipóteses

Um teste de hipóteses responde à seguinte pergunta:

"O que observamos é compatível com o acaso ou indica um efeito real?"

- Assumimos inicialmente que nada mudou (H_0)
- Calculamos quão improvável é a amostra sob essa hipótese
- Se for improvável o suficiente, rejeitamos H_0

Resumo: rejeitamos H_0 quando os dados seriam muito raros se H_0 fosse verdadeira.

1.2 Definição e etapas

Definição

Um **teste de hipóteses** (*hypothesis test*), também chamado de **teste de significância**, é um procedimento para verificar uma afirmação sobre o valor de algum parâmetro populacional. Essa verificação é realizada usando *evidência* obtida a partir dos dados de uma (ou mais) amostras da população.

O procedimento padrão de um teste de hipóteses é composto de quatro etapas:

1. **Formular as hipóteses nula e alternativa.**
2. **Computar a estatística de teste** (*test statistic*) a partir dos dados da amostra.
3. **Computar o p-valor** (*p-value*) associado à estatística de teste.
4. **Interpretar e declarar o resultado**: rejeitar ou não rejeitar a hipótese nula, comparando o p-valor com o nível de significância α.

A Figura 1 resume o encadeamento lógico de um teste de hipóteses. Ao longo das próximas subseções, detalharemos cada uma dessas etapas separadamente.

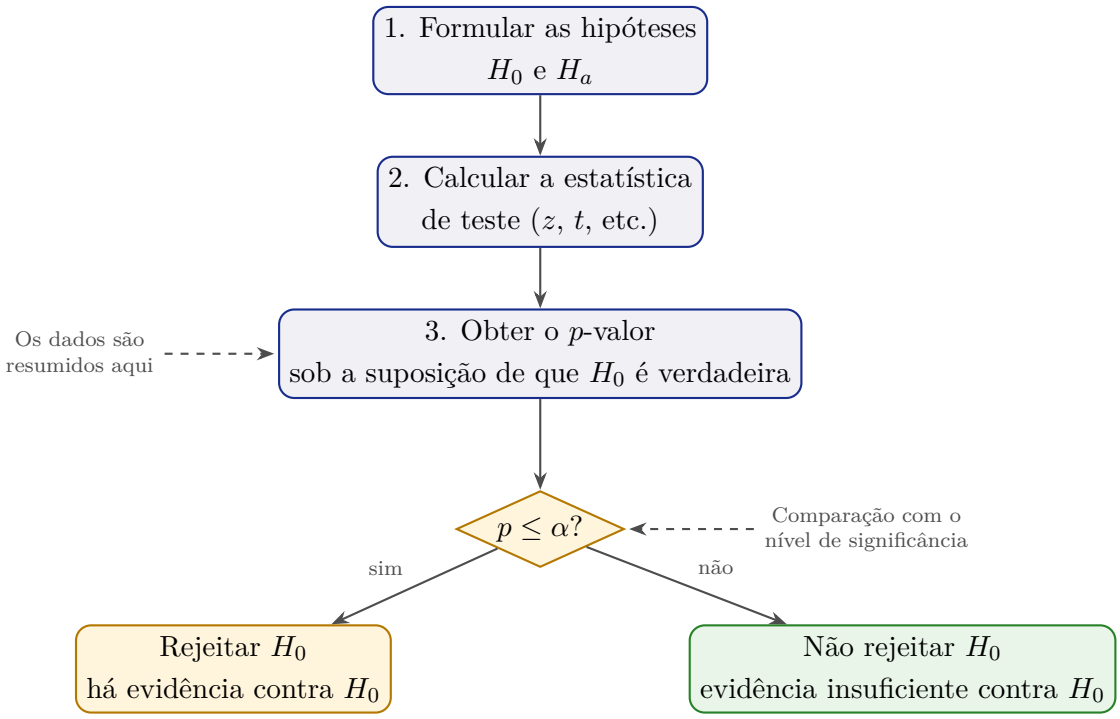

Figura 1: Fluxo geral de um teste de hipóteses. O procedimento começa com a formulação de H_0 e H_a, passa pelo cálculo da estatística de teste e do p-valor, e termina com a decisão baseada na comparação entre p e o nível de significância α.

Mapa mental do teste de hipóteses

Ao conduzir um teste, percorra mentalmente as etapas a seguir. Se você consegue responder a cada pergunta, está no caminho certo.

1. **O que quero detectar?** $\rightarrow$ define H_a
2. **Qual é o status quo?** $\rightarrow$ define H_0
3. **Que teste é adequado?** $\rightarrow$ z, t, etc. (depende do que é conhecido e do delineamento)
4. **Calcule a estatística de teste** a partir dos dados
5. **Calcule o p-valor** (observe a direção de H_a)
6. **Compare com** α e tome a decisão
7. **Interprete no contexto do problema** (não apenas "rejeitar" ou "não rejeitar")

Pergunta-guia: os dados observados seriam surpreendentes se H_0 fosse verdadeira?

1.3 A lógica do teste de hipóteses

Antes de aprofundar nas definições formais, vale tornar explícita a estrutura lógica do procedimento, pois é ela que justifica todas as regras de decisão.

A lógica do teste (ponto central)

O teste de hipóteses segue um raciocínio indireto:

1. Assumimos que H_0 é verdadeira, mesmo que suspeitemos o contrário.
2. Calculamos quão compatíveis os dados são com essa suposição, via p-valor.
3. Se os dados forem muito improváveis sob H_0, concluímos que a suposição é implausível e a rejeitamos.

Atenção: ao rejeitar H_0, não provamos que H_a é verdadeira, apenas mostramos que H_0 é implausível à luz dos dados. E ao não rejeitar H_0, não a provamos verdadeira, apenas constatamos que os dados são compatíveis com ela.

Assimetria fundamental da inferência frequentista

O teste estatístico sempre coleta evidências *contra* H_0, nunca diretamente *a favor* de H_a. Por isso:

- Evidência forte $\Rightarrow$ rejeitamos H_0 (com um nível de confiança controlado por α)
- Evidência fraca $\Rightarrow$ *não rejeitamos* H_0, mas não podemos concluir que ela é verdadeira

Essa assimetria é fundamental: um teste nunca "confirma" o status quo, apenas falha ou não em derrubá-lo.

1.4 Hipóteses nula e alternativa

A primeira e mais crítica etapa do teste de hipóteses é a formulação das hipóteses.

Definições

- A **hipótese nula** (*null hypothesis*), denotada por H_0, é uma afirmação que representa o "estado atual das coisas" (*status quo*). Ela é sempre declarada com um símbolo que envolve igualdade: $=$, $\leq$ ou $\geq$.
- A **hipótese alternativa** (*alternative hypothesis*), denotada por H_a, afirma que H_0 é falsa. Ela é sempre declarada com um símbolo de desigualdade estrita: $\neq$, $>$ ou $<$.

No teste de hipóteses, buscamos **evidência nos dados da amostra contra** H_0, como modo de dar suporte a H_a.

A tabela a seguir resume as correspondências usuais entre os símbolos da hipótese nula e da alternativa:

H_0	H_a
$=$	$\neq$, $>$ ou $<$
$\geq$	$<$
$\leq$	$>$

Regra prática

- H_0 sempre representa o **status quo**
- H_a representa o **efeito que queremos detectar**

Dica: escreva primeiro o que você suspeita (efeito) isso define H_a depois construa H_0 como complemento.

1.4.1 Exemplos de formulação

Antes dos exemplos, é importante esclarecer uma dúvida comum: por que H_0 às vezes usa $=$ e outras vezes usa $\geq$ ou $\leq$?

Quando usar $=$, $\geq$ ou $\leq$ em H_0

A escolha do símbolo em H_0 deve refletir com precisão a afirmação que representa o *status quo*:

- Use $=$ quando o status quo é um valor nominal fixo e pontual; por exemplo, "a máquina foi calibrada para encher exatamente 500 ml" ou "o peso médio histórico era 77 kg". Aqui, a referência é um número específico, não uma faixa.
- Use $\geq$ ou $\leq$ quando o status quo é uma afirmação de intervalo; por exemplo, "a média salarial é pelo menos K" ou "no máximo 30% dos eleitores votaram". Nesse caso, o status quo abrange uma faixa de valores.

Na prática, o cálculo não muda. Em ambos os casos, a estatística de teste é calculada usando o valor limite de H_0 (o ponto de igualdade), pois esse é o ponto mais desfavorável à rejeição, e portanto o mais conservador. O impacto é apenas na precisão conceitual da formulação.

Exemplo 1 – Média salarial. Um pesquisador quer verificar se a média salarial está *abaixo* de um valor de referência K. O status quo é a afirmação de que "a média é pelo menos K", uma cota inferior, não um valor pontual. Portanto, H_0 usa $\geq$.

- H_0: $\mu \geq K$ (a média é pelo menos K; status quo como afirmação de intervalo)
- H_a: $\mu < K$ (teste unicaudal à esquerda)

Exemplo 2 – Peso corporal. Nos anos 1970, a média do peso corporal de homens de 20 a 29 anos era $\mu_0 = 77$ kg. Queremos verificar se essa média *mudou* atualmente, para mais ou para menos. O status quo é um valor histórico pontual e fixo. Portanto, H_0 usa $=$.

- H_0: $\mu = 77$ (valor histórico pontual, status quo como valor fixo)
- H_a: $\mu \neq 77$ (teste *bicaudal*)

Exemplo 3 – Máquina de garrafas. O fabricante suspeita que a máquina está preenchendo *menos* do que 500 ml. O status quo é que a máquina funciona bem, ou seja, preenche *ao menos* 500 ml, uma cota inferior. Embora valores acima de 500 ml também sejam compatíveis com o bom funcionamento, a suspeita é apenas de subdosagem. Portanto, H_0 usa $\geq$.

- H_0: $\mu \geq 500$ ml (a máquina preenche ao menos 500 ml, status quo como afirmação de intervalo)
- H_a: $\mu < 500$ ml (teste *unicaudal à esquerda*)

Erro comum neste exemplo

É tentador escrever $H_0 : \mu = 500\,\text{ml}$, raciocínio que parte do valor de calibração da máquina. Essa formulação é operacionalmente equivalente para o cálculo da estatística de teste, mas é conceitualmente imprecisa: ela sugere que o bom funcionamento corresponde *exatamente* a 500 ml, quando na verdade qualquer valor $\geq 500\,\text{ml}$ seria aceitável. A formulação com $\geq$ é mais rigorosa e coerente com a suspeita unilateral do fabricante.

Exemplo 4 – Proporção de votantes. A afirmação a ser contestada é "no máximo 30% dos eleitores votaram". O status quo é essa cota superior, não um valor pontual. Portanto, H_0 usa $\leq$.

- H_0: $p \leq 0{,}30$ (a proporção é no máximo 30%, status quo como afirmação de intervalo)
- H_a: $p > 0{,}30$ (teste *unicaudal à direita*)

Pergunta 1

Formule as hipóteses nula e alternativa para cada situação abaixo:
(a) Uma empresa afirma que o tempo médio de entrega de seus produtos é, no máximo, 3 dias. Um cliente desconfia que o tempo real é maior.
(b) Um pesquisador quer verificar se uma nova dieta altera (para mais ou para menos) o colesterol médio de uma população, sabendo que o valor histórico é de 200 mg/dL.
(c) Uma fábrica de parafusos quer garantir que o diâmetro médio de sua produção seja exatamente 10 mm. O controle de qualidade suspeita que algo mudou.

1.5 Estatística de teste

Definição

Uma **estatística de teste** (*test statistic*) é uma variável aleatória cujos valores são computados a partir dos dados da amostra, e que é usada para determinar o resultado do teste (rejeitar ou não rejeitar H_0). Em geral, quando a amostra apresenta forte evidência contra H_0, o valor absoluto da estatística de teste tende a ser grande em relação à sua distribuição sob H_0.

Neste texto, estudamos os testes e respectivas estatísticas apresentados na tabela abaixo:

Teste estatístico	Estatística utilizada
z-teste	Z
t-teste	T
ANOVA	F
Qui-quadrado	χ^2

1.6 O p-valor

Definição

O p-**valor** (*p-value*) é a probabilidade de se obter o valor observado (ou um valor ainda mais extremo, na direção definida por H_a) para a estatística de teste, *presumindo que H_0 seja verdadeira.*
Valores menores do p-valor fornecem evidência mais forte contra H_0:

$$p\text{-valor pequeno} \Rightarrow \text{evidência forte contra } H_0$$

A Figura 2, para um teste bicaudal, ilustra graficamente onde o p-valor se encontra na distribuição da estatística de teste sob H_0: ele corresponde à área nas regiões mais extremas do que o valor observado.

Figura 2: Distribuição da estatística de teste sob H_0 (bicaudal). As regiões em vermelho correspondem a valores raros (p-valor), isto é, resultados que seriam pouco prováveis caso H_0 fosse verdadeira. Se H_0 for verdadeira, valores nessas regiões são improváveis.

Interpretação incorreta do p-valor

Uma interpretação comum (mas incorreta) é:

> "O p-valor é a probabilidade de H_0 ser verdadeira."

Isso está errado.

Interpretação correta:

> "O p-valor é a probabilidade de observar dados tão extremos quanto os obtidos, *assumindo que H_0 é verdadeira.*"

Ou seja, o p-valor não fala diretamente sobre a probabilidade de H_0, mas sobre a compatibilidade dos dados com H_0. Um p-valor pequeno não diz "H_0 é falsa", mas sim "os dados seriam muito raros se H_0 fosse verdadeira".

1.6.1 Cálculo do p-valor conforme a hipótese alternativa

O modo de calcular o p-valor depende da direção da hipótese alternativa. Dado um valor observado z_{obs} da estatística de teste $Z \sim \mathcal{N}(0,1)$:

- $H_a\colon \mu > \mu_0$ (unicaudal à direita): $\quad p = \Pr(Z > z_{\text{obs}})$

- $H_a\colon \mu < \mu_0$ (unicaudal à esquerda): $p = \Pr(Z < z_{\text{obs}})$
- $H_a\colon \mu \neq \mu_0$ (bicaudal): $p = 2\,\Pr(Z > |z_{\text{obs}}|)$

Ilustração com o experimento da moeda

Uma pessoa afirma que uma moeda é viciada, tendendo a cair mais em cara. Para investigar isso, a moeda é lançada 20 vezes e observamos 16 caras.

- H_0: a moeda é justa, $P(\text{cara}) = 0{,}5$
- H_a: a moeda é viciada para mais caras, $P(\text{cara}) > 0{,}5$

O p-valor é a probabilidade de se observar 16 ou mais caras em 20 lançamentos, supondo que a moeda seja justa. Usando a distribuição binomial $B(20; 0{,}5)$:

$$p = \Pr(X \geq 16) \approx 0{,}0059$$

Como $p = 0{,}0059 < 0{,}05 = \alpha$, rejeitamos H_0. Há evidência estatística de que a moeda é viciada.

```
from scipy.stats import binom
n, p_h0, k_obs = 20, 0.5, 16
p_valor = binom.sf(k_obs - 1, n, p_h0)    # P(X >= 16)
print(f"p-valor = {p_valor:.4f}")           # -> 0.0059
```

A forma de calcular o p-valor depende diretamente da hipótese alternativa. A Figura 3 ilustra como essa escolha determina a região da distribuição considerada no cálculo do p-valor.

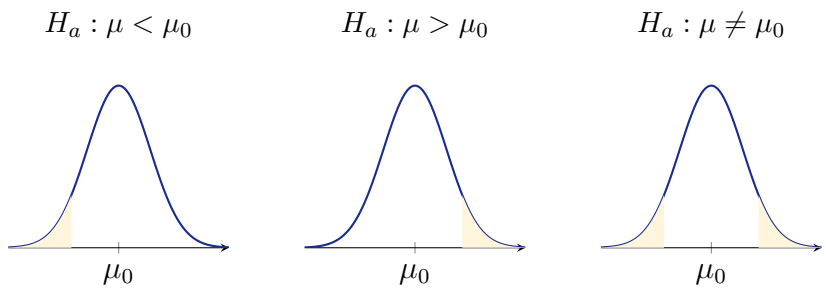

Figura 3: Regiões de rejeição para testes unicaudais (à esquerda e à direita) e bicaudal. A área sombreada indica valores da estatística de teste que levam à rejeição de H_0.

1.7 Nível de significância e regra de decisão

Definição

O **nível de significância** α é a probabilidade de rejeitar H_0 quando ela é verdadeira, considerando o procedimento de teste sob repetição do experimento. Equivalentemente, é a probabilidade máxima aceitável de cometer um erro de tipo I. Ele é fixado pelo pesquisador *antes* da coleta dos dados.

A regra de decisão é:

$$\text{Rejeitar } H_0 \text{ se } p \leq \alpha \qquad \text{Não rejeitar } H_0 \text{ se } p > \alpha$$

Atenção à linguagem

Em estatística, a terminologia correta é sempre **rejeitar** ou **não rejeitar** H_0 — nunca "aceitar" H_0. Não rejeitar H_0 significa apenas que os dados não fornecem evidência suficiente contra ela; não significa que H_0 foi provada verdadeira.

As convenções mais comuns para interpretação da força da evidência em função do p-valor são:

p-valor	Interpretação
$p > 0{,}10$	Evidência não significativa contra H_0
$0{,}05 < p \leq 0{,}10$	Evidência marginalmente significativa
$0{,}01 < p \leq 0{,}05$	Evidência significativa
$p \leq 0{,}01$	Evidência altamente significativa

Significância estatística $\neq$ relevância prática

Um resultado pode ser *estatisticamente significativo* e, ainda assim, irrelevante na prática. Com amostras suficientemente grandes, diferenças minúsculas (sem nenhum impacto real) podem produzir p-valores muito pequenos.
Exemplo: suponha que um novo medicamento reduza a pressão arterial em, em média, 0,3 mmHg a mais do que o tratamento padrão. Com $n = 50.000$ pacientes, essa diferença pode ser altamente significativa ($p \ll 0{,}01$), mas clinicamente irrelevante.
Conclusão: sempre interprete o resultado estatístico junto com o *tamanho do efeito* e o contexto do problema. O p-valor responde "os dados são consistentes com H_0?", mas não responde "a diferença importa?".

Nível de significância não é nível de confiança

O nível de significância α e o nível de confiança $(1-\alpha)$ são valores complementares. Por exemplo, para $\alpha = 0{,}05$, o nível de confiança é 95%. As seguintes afirmações são equivalentes:

- Se o p-valor for menor do que α, o resultado é *estatisticamente significativo*.
- Se o p-valor for menor do que α, o intervalo de confiança correspondente *não conterá* o valor presumido por H_0.

Conexão com intervalos de confiança

Testes de hipóteses e intervalos de confiança são duas faces do mesmo conceito:

- Se μ_0 estiver fora do intervalo de confiança $(1 - \alpha)$, rejeitamos H_0
- Se μ_0 estiver dentro do intervalo, não rejeitamos H_0

Isso permite interpretar testes de hipóteses geometricamente.

1.8 Tipos de erro

Ao tomar uma decisão com base em uma amostra, dois tipos de erro são possíveis:

Definições

- **Erro tipo I** (*falso positivo*): ocorre quando o pesquisador **rejeita** H_0 sendo ela **verdadeira**. A probabilidade desse erro é α.
- **Erro tipo II** (*falso negativo*): ocorre quando o pesquisador **não rejeita** H_0 sendo ela **falsa**. A probabilidade desse erro é β.

A tabela a seguir sintetiza os quatro resultados possíveis de um teste de hipóteses:

	H_0 **é verdadeira**	H_0 **é falsa**
Não rejeitar H_0	Decisão correta	Erro tipo II (β)
Rejeitar H_0	Erro tipo I (α)	Decisão correta (poder $= 1 - \beta$)

Intuição prática

- Erro tipo I (α): **alarme falso**
- Erro tipo II (β): **falha em detectar um problema real**

Exemplo: teste médico

- Tipo I: diagnosticar doença em pessoa saudável
- Tipo II: deixar de diagnosticar uma pessoa doente

Reduzindo os erros

Os erros tipo I e tipo II nunca podem ser completamente eliminados. Contudo, o pesquisador pode reduzir sua probabilidade aumentando o tamanho da amostra: quanto maior a amostra, menor a chance de que ela difira substancialmente da população. Há ainda um trade-off: reduzir α (exigir mais evidência para rejeitar H_0) tende a aumentar β, e vice-versa.

Pergunta 2

Um médico aplica um teste diagnóstico para uma doença rara. Defina H_0: "o paciente é saudável".
(a) O que é um erro tipo I nesse contexto? Quais são suas consequências práticas?
(b) O que é um erro tipo II? Quais são suas consequências práticas?
(c) Qual dos dois erros seria mais grave nesse cenário? Justifique.

1.9 Exercícios de fixação

Exercício 1: Formulação de hipóteses

Para cada situação abaixo, formule as hipóteses H_0 e H_a, identifique se o teste é unicaudal (à esquerda ou à direita) ou bicaudal, e justifique sua escolha.

(a) Uma empresa afirma que o tempo médio de entrega é de no máximo 3 dias. Um cliente desconfia que o tempo real é maior.

(b) Um pesquisador quer verificar se uma nova dieta altera (para mais ou para menos) o colesterol médio de uma população, sabendo que o valor histórico é 200 mg/dL.

(c) Uma fábrica de parafusos afirma que o diâmetro médio de produção é exatamente 10 mm. O controle de qualidade suspeita que algo mudou.

(d) Um laboratório afirma que sua vacina reduz a duração média de um resfriado comum abaixo de 7 dias. Você deseja verificar essa afirmação.

Exercício 2: Interpretação do p-valor e regra de decisão

Classifique cada afirmação abaixo como **verdadeira** ou **falsa** e justifique:

(a) "Se $p = 0{,}03$, há 3% de probabilidade de que H_0 seja verdadeira."

(b) "Se não rejeitamos H_0, então H_0 foi provada verdadeira."

(c) "Quanto menor o p-valor, maior a magnitude do efeito observado."

(d) "Fixar $\alpha = 0{,}01$ sempre leva a conclusões mais confiáveis do que $\alpha = 0{,}05$."

(e) "Um resultado estatisticamente não significativo implica que não há diferença entre os grupos."

Exercício 3: Erros tipo I e tipo II

Um sistema automatizado de detecção de fraudes em transações bancárias analisa cada operação e decide: bloquear (suspeita de fraude) ou liberar. Defina H_0: "a transação é legítima".

(a) Descreva o que é um erro tipo I nesse contexto e quais são suas consequências para o cliente e para o banco.

(b) Descreva o que é um erro tipo II e quais são suas consequências.

(c) Um banco decide reduzir drasticamente α para evitar bloqueios indevidos. O que provavelmente acontece com β? Como isso afeta a segurança do sistema?

(d) Qual estratégia, além de ajustar α, o banco poderia adotar para reduzir simultaneamente os dois tipos de erro?

Exercício 4: Etapas do teste de hipóteses

Uma indústria alimentícia afirma que suas embalagens de 500 g têm peso médio igual ao valor declarado. Sabe-se que o peso segue distribuição normal. Um fiscal coleta uma amostra de 25 embalagens e obtém $\overline{x} = 496$ g e $s = 8$ g.

(a) Identifique as quatro etapas do teste de hipóteses para esse problema.

(b) Formule H_0 e H_a para verificar se o peso médio é diferente de 500 g.

(c) Qual informação ainda é necessária para concluir o teste? Que teste seria adequado aqui: z-teste ou t-teste? Por quê?

2 O z-Teste

O **z-teste** é utilizado para testar afirmações acerca da média de uma população quando o desvio padrão populacional σ é *conhecido*. A estatística de teste é denominada z-escore e é definida por:

$$Z = \frac{\overline{x} - \mu_0}{\sigma/\sqrt{n}}$$

Na expressão acima: μ_0 é o valor da média populacional sob H_0; σ é o desvio padrão populacional (conhecido); n é o tamanho da amostra; e $\overline{x}$ é a média amostral. O z-escore indica quantos *erros padrão* existem entre a média amostral e a suposta média da população. Quanto maior o valor absoluto do z-escore, menos provável é a amostra presumindo que H_0 seja verdadeira.

Interpretação do z-escore

O z-escore mede:

quantos erros padrão a média amostral está distante de μ_0

- $z \approx 0$ dados compatíveis com H_0
- $|z|$ grande dados improváveis sob H_0

2.1 Passos do z-teste

1. **Declarar as hipóteses:**
   - H_0: $\mu = \mu_0$
   - H_a: $\mu \neq \mu_0$ (bicaudal), ou $\mu > \mu_0$ (unicaudal à direita), ou $\mu < \mu_0$ (unicaudal à esquerda)
2. **Computar o z-escore** a partir da amostra usando a fórmula acima.
3. **Encontrar o p-valor** associado ao z-escore:
   - $H_a : \mu > \mu_0 \to p = \Pr(Z > z_{\text{obs}})$
   - $H_a : \mu < \mu_0 \to p = \Pr(Z < z_{\text{obs}})$
   - $H_a : \mu \neq \mu_0 \to p = 2\ \Pr(Z > |z_{\text{obs}}|)$
4. **Interpretar o resultado:** rejeitar H_0 se $p \leq \alpha$; caso contrário, não rejeitar H_0.

2.2 Condições de aplicabilidade

Para que o z-teste seja válido, devem ser verificadas as seguintes condições:

- O valor de σ é conhecido (não estimado a partir dos dados da amostra).
- A população é aproximadamente normal, *ou* o tamanho da amostra é suficientemente grande para que o Teorema Central do Limite garanta a normalidade da distribuição amostral da média. Na prática, $n \geq 30$ é frequentemente usado como regra heurística, mas o limiar adequado depende da forma da distribuição populacional: distribuições muito assimétricas ou com caudas pesadas podem requerer amostras maiores. Para amostras pequenas com σ conhecido, a normalidade da população deve ser verificada com base em conhecimento prévio ou análise exploratória.
- A amostra é uma amostra aleatória simples da população.
- Os dados são **IID** (independentes e identicamente distribuídos).

2.3 Exemplos

2.3.1 Exemplo 1: Acidentes de trabalho (unicaudal à esquerda)

(Fonte: Morettin & Bussab, Estatística Básica, 5ł ed., p. 334.)

A média de horas perdidas com acidentes de trabalho tem sido de 60 h/homem/ano, com desvio padrão $\sigma = 20$ h. Após um programa de prevenção, amostrou-se 9 indústrias, obtendo média de 50 h. Há evidência de melhoria ao nível de 5%?

Solução

(1) Hipóteses: $H_0 : \mu = 60$; $H_a : \mu < 60$.

(2) Estatística de teste:

$$Z = \frac{50 - 60}{20/\sqrt{9}} = \frac{-10}{6{,}67} \approx -1{,}5$$

(3) p**-valor:** $p = \Pr(Z < -1{,}5) \approx 0{,}067$

(4) Conclusão: Como $p = 0{,}067 > 0{,}05 = \alpha$, não rejeitamos H_0. Não há evidência suficiente para afirmar que o programa de prevenção reduziu o número de horas perdidas. O resultado está próximo do limiar de significância, mas não constitui evidência suficiente ao nível adotado.

```
from scipy.stats import norm
import numpy as np

alpha = 0.05
z_score = (50 - 60) / (20 / np.sqrt(9))    # -> -1.5
p_value = norm.cdf(z_score)                 # -> 0.0668
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

2.3.2 Exemplo 2: Índice de nicotina (unicaudal à esquerda)

(Fonte: Morettin & Bussab, Estatística Básica, 5ł ed., p. 334.)

Um fabricante de cigarros anuncia que o índice médio de nicotina está abaixo de 23 mg. Um laboratório realiza 6 análises: 27, 24, 21, 25, 26, 22. Sabe-se que $\sigma^2 = 4{,}86\,\text{mg}^2$. Os dados fornecem evidência estatística que sustente a afirmação do fabricante ao nível de 10%?

Solução

(1) Hipóteses: $H_0 : \mu = 23$; $H_a : \mu < 23$.

(2) Estatística de teste: $\overline{x} = 24{,}17$, $\sigma = \sqrt{4{,}86} \approx 2{,}20$,

$$Z = \frac{24{,}17 - 23}{2{,}20/\sqrt{6}} \approx 1{,}302$$

(3) p**-valor:** Para $H_a : \mu < 23$ (unicaudal à esquerda): $p = \Pr(Z < 1{,}302) \approx 0{,}904$.

(4) Conclusão: Como $p \gg \alpha = 0{,}10$, não rejeitamos H_0. Os dados não fornecem qualquer suporte para a alegação do fabricante, pelo contrário: a média amostral (24,17 mg) é *maior* do que 23 mg, apontando exatamente na direção oposta à da hipótese alternativa. Note que não rejeitar H_0 não equivale a confirmar que a afirmação do fabricante é verdadeira; significa apenas que os dados são insuficientes para refutá-la.

```
import numpy as np
from scipy.stats import norm

amostra = [27, 24, 21, 25, 26, 22]
mu0, sigma = 23, np.sqrt(4.86)
x_bar = np.mean(amostra)
z_score = (x_bar - mu0) / (sigma / np.sqrt(len(amostra)))
p_value = norm.cdf(z_score)   # unicaudal a esquerda
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

2.3.3 Exemplo 3: Tempo de aprendizado (unicaudal à esquerda)

(Fonte: Morettin & Bussab, 5ł ed., p. 334.)

O tempo de aprendizado de uma máquina segue $\mathcal{N}(25, 100)$. Uma nova técnica foi testada em 16 operários: tempo médio de 20,5 h. A técnica é melhor ao nível de 5%?

(1) Hipóteses: $H_0 : \mu = 25$; $H_a : \mu < 25$.

(2) Estatística de teste:

$$Z = \frac{20{,}5 - 25}{10/\sqrt{16}} = \frac{-4{,}5}{2{,}5} = -1{,}8$$

(3) p**-valor:** $p = \Pr(Z < -1{,}8) \approx 0{,}036$

(4) Conclusão: Como $p = 0{,}036 < 0{,}05 = \alpha$, rejeitamos H_0. Há evidência para afirmar que a nova técnica reduziu o tempo médio de aprendizado.

2.3.4 Exemplo 4: Peso de pinguins (bicaudal)

O peso médio de pinguins-rei em uma região da Antártica era 15,4 kg. Em uma amostra de 35 pinguins deste ano, o peso médio é 14,6 kg. Com $\sigma = 2{,}5$ kg, há evidência de que o peso médio mudou ($\alpha = 0{,}05$)?

(1) Hipóteses: $H_0 : \mu = 15{,}4$; $H_a : \mu \neq 15{,}4$ (bicaudal).

(2) Estatística de teste:

$$Z = \frac{14{,}6 - 15{,}4}{2{,}5/\sqrt{35}} \approx -1{,}893$$

(3) p**-valor:** $p = 2\ \Pr(Z < -1{,}893) \approx 0{,}0584$

(4) Conclusão: Como $p = 0{,}058 > 0{,}05 = \alpha$, não rejeitamos H_0. Não há evidência suficiente para afirmar que o peso médio dos pinguins mudou.

```
import numpy as np
from scipy.stats import norm

z_score = (14.6 - 15.4) / (2.5 / np.sqrt(35))
p_value = 2 * norm.cdf(z_score)   # bicaudal
print(f"z = {z_score:.4f}, p = {p_value:.4f}")
```

2.4 Implementação em Python

A função utilitária a seguir encapsula o z-teste para uma amostra, permitindo testes uni e bilaterais:

```
from scipy.stats import norm
import numpy as np

def z_test_1sample(sample, mu0, sigma, alternative='two-sided',
   alpha=0.05):
    sample = np.array(sample)
    n = len(sample)
    mean = np.mean(sample)
    se = sigma / np.sqrt(n)          # erro padrao
    z_stat = (mean - mu0) / se       # estatistica de teste

    if alternative == 'two-sided':
        p_value = 2 * norm.sf(abs(z_stat))
    elif alternative == 'less':
        p_value = norm.cdf(z_stat)
    elif alternative == 'greater':
        p_value = 1 - norm.cdf(z_stat)

    decision = "Rejeita H0" if p_value < alpha else "Nao rejeita
        H0"
    print(f"z = {z_stat:.4f}, p-valor = {p_value:.4f}")
    print(f"Decisao ao nivel {alpha}: {decision}")
    return z_stat, p_value, decision
```

Pergunta 3

Um pesquisador quer testar se a média de uma população mudou de um valor de referência $\mu_0 = 100$. Ele dispõe de $\sigma = 15$ e coleta uma amostra com $n = 36$ e $\overline{x} = 95$.

(a) Formule as hipóteses para um teste bicaudal.

(b) Calcule o z-escore.

(c) Calcule o p-valor e conclua ao nível de significância $\alpha = 0{,}05$.

2.5 Exercícios de fixação

Exercício 5: Tempo de processamento de pedidos

Uma empresa afirma que o tempo médio de processamento de pedidos é de 5 dias. Um auditor coletou uma amostra de $n = 36$ pedidos e obteve $\overline{x} = 5{,}8$ dias. Sabe-se que $\sigma = 1{,}5$ dias.

(a) Formule as hipóteses para verificar se o tempo médio é *maior* do que o alegado.

(b) Calcule o z-escore.

(c) Calcule o p-valor e conclua ao nível $\alpha = 0{,}05$.

(d) Repita a análise para $\alpha = 0{,}01$. A conclusão muda?

Exercício 6: Consumo de energia elétrica

O consumo médio mensal de energia elétrica residencial em uma cidade é historicamente de $\mu_0 = 220\,\text{kWh}$, com desvio padrão populacional $\sigma = 40\,\text{kWh}$. Após uma campanha de conscientização, uma amostra de $n = 64$ residências registrou consumo médio de $\overline{x} = 208\,\text{kWh}$.

(a) Formule as hipóteses adequadas para verificar se a campanha reduziu o consumo.

(b) Calcule o z-escore e o p-valor.

(c) Conclua ao nível $\alpha = 0{,}05$.

(d) A que conclusão você chegaria se o tamanho da amostra fosse $n = 16$, mantendo os demais valores? Discuta o efeito do tamanho amostral.

Exercício 7: Teor de cafeína em bebidas

Um fabricante declara que suas latas de refrigerante contêm em média $\mu_0 = 35\,\text{mg}$ de cafeína por $100\,\text{ml}$, com desvio padrão $\sigma = 3\,\text{mg}$. Um laboratório independente analisa 50 latas e obtém $\overline{x} = 36{,}2\,\text{mg}$.

(a) Formule as hipóteses para um teste bicaudal.

(b) Calcule o z-escore e o p-valor.

(c) Conclua ao nível $\alpha = 0{,}05$ e interprete o resultado no contexto do problema.

(d) O resultado seria diferente para um teste unicaudal à direita? Justifique, recalculando o p-valor.

Exercício 8: Condições de aplicabilidade

Para cada situação abaixo, indique se o z-teste é aplicável e justifique com base nas condições de validade do teste:

(a) $n = 8$, população com distribuição desconhecida, σ conhecido.

(b) $n = 50$, população normal, σ desconhecido.

(c) $n = 100$, σ conhecido, mas os dados apresentam forte dependência temporal.

(d) $n = 40$, população assimétrica, σ conhecido.

3 O t-Teste

Na prática, o desvio padrão populacional σ raramente é conhecido. Quando ele é desconhecido, não se pode usar o z-escore como estatística de teste. Nesse caso, deve-se usar o **t-escore**, em um procedimento conhecido como **t-teste**.

Por que mudar de z para t?

No z-teste, assumimos que σ é conhecido.
Na prática, isso raramente acontece. Em vez disso, estimamos σ pelo desvio padrão amostral s, calculado a partir dos próprios dados. Essa estimativa introduz uma fonte adicional de incerteza, afinal, s também varia de amostra para amostra.

Essa incerteza adicional é capturada pela **distribuição t de Student**, que possui caudas mais pesadas do que a normal padrão. Intuitivamente, caudas mais pesadas significam que valores extremos são mais prováveis, o que é coerente com a maior variabilidade introduzida por estimar σ.

Ideia-chave: o t-teste é uma versão do z-teste que incorpora a incerteza adicional de se estimar σ a partir da amostra. À medida que n cresce, s converge para σ e a distribuição t se aproxima da normal padrão.

Há três tipos de t-teste, conforme descrito na tabela abaixo:

Tipo	**Situação**	H_0
t-teste para uma amostra	Comparar a média amostral com um valor de referência μ_0	$\mu = \mu_0$
t-teste para amostras pareadas	Comparar médias de duas situações relacionadas (ex.: antes e depois)	$\mu_d = 0$
t-teste para amostras independentes	Comparar médias de dois grupos distintos	$\mu_1 = \mu_2$

Antes de detalhar os diferentes tipos de t-teste, vale a pena organizar a decisão sobre *qual teste usar* em cada situação. A Figura 4 resume esse processo.

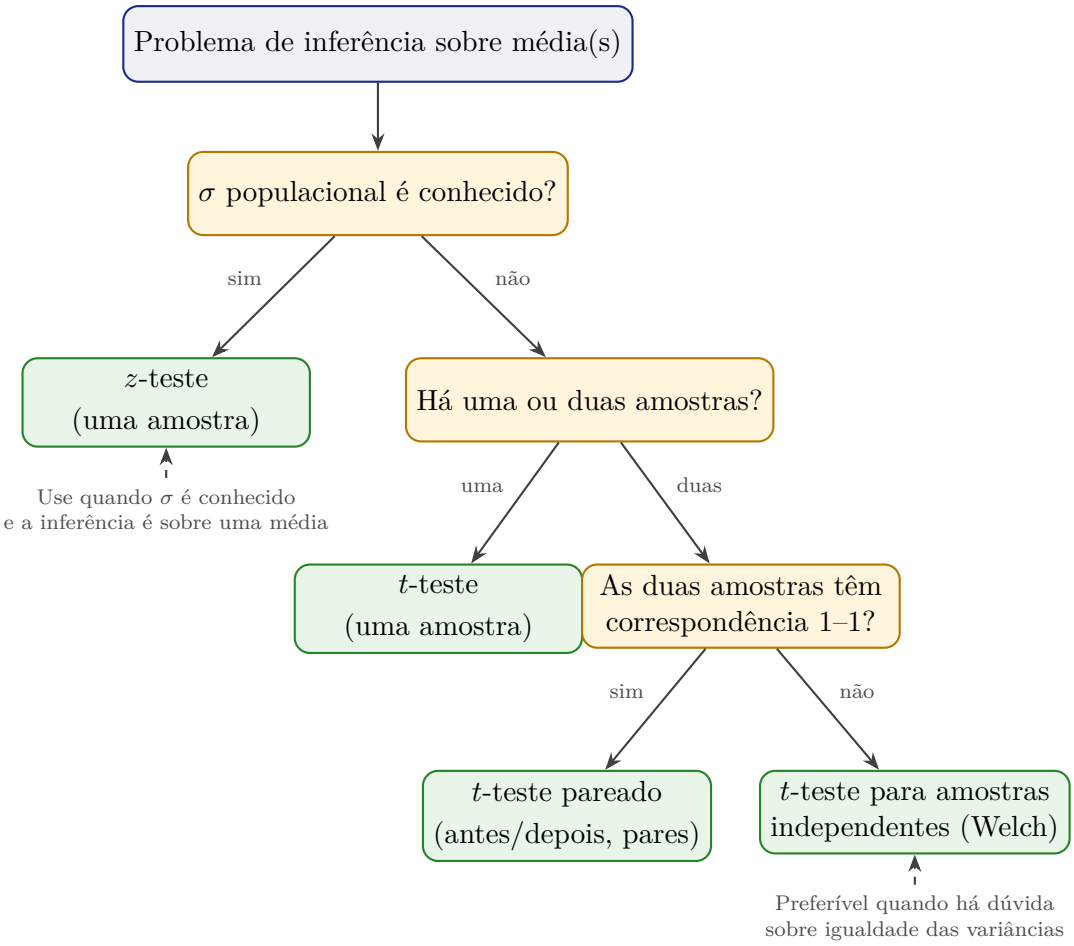

Figura 4: Fluxograma simplificado para escolha do teste de hipóteses ao comparar médias.

3.1 t-teste para uma amostra

O t-teste para uma amostra verifica se a média de uma população é igual a um valor de referência μ_0, quando σ é desconhecido. A estatística de teste é o t-escore:

$$t = \frac{\overline{x} - \mu_0}{s/\sqrt{n}}$$

onde s é o desvio padrão *amostral* (calculado com divisor $n-1$). Sob H_0 e com a população aproximadamente normal, essa estatística segue a distribuição t de Student com $\nu = n-1$ graus de liberdade.

3.1.1 Passos do t-teste para uma amostra

1. **Declarar as hipóteses:** $H_0 \colon \mu = \mu_0$ vs. H_a (uni ou bicaudal).
2. **Computar o t-escore** com s da amostra.
3. **Encontrar o p-valor** na distribuição t_{n-1}:
   - $H_a \colon \mu < \mu_0 \to p = \Pr(T_{n-1} < t_{\text{obs}})$
   - $H_a \colon \mu > \mu_0 \to p = \Pr(T_{n-1} > t_{\text{obs}})$
   - $H_a \colon \mu \neq \mu_0 \to p = 2\ \Pr(T_{n-1} > |t_{\text{obs}}|)$

4. **Interpretar:** rejeitar H_0 se $p \leq \alpha$; caso contrário, não rejeitar H_0.

3.1.2 Condições de aplicabilidade

- A amostra foi obtida por amostragem aleatória simples.
- Para amostras grandes ($n \geq 30$), o Teorema Central do Limite garante a aproximação normal da distribuição da média amostral, tornando o teste robusto a desvios de normalidade. Para amostras pequenas, a normalidade da população (ou ausência de assimetrias severas e outliers extremos) é importante para a validade do teste.

3.2 Exemplos

3.2.1 Exemplo 1: Máquina de garrafas (retomada)

Voltando ao exemplo motivador: $n = 20$ garrafas, $\overline{x} = 491{,}57\,\text{ml}$. $H_0 : \mu = 500$; $H_a : \mu < 500$. σ é *desconhecido*: usamos o t-teste.

```
import numpy as np
from scipy import stats

volumes = np.array([484.11, 459.49, 471.38, 512.01, 494.48,
                    528.63, 493.64, 485.03, 473.88, 501.59,
                    502.85, 538.08, 465.68, 495.03, 475.32,
                    529.41, 518.13, 464.32, 449.08, 489.27])
mu0 = 500
t_stat, p_bilateral = stats.ttest_1samp(volumes, popmean=mu0)

# Ajuste para unicaudal a esquerda
p_one = p_bilateral / 2 if t_stat < 0 else 1 - p_bilateral / 2
print(f"t = {t_stat:.4f}, p (unicaudal) = {p_one:.4f}")
```

Resultados: $\overline{x} = 491{,}57$, $s = 25{,}11$, $t \approx -1{,}520$, $p \approx 0{,}072$.

Conclusão: Como $p = 0{,}072 > 0{,}05$, não rejeitamos H_0. Apesar da média amostral estar abaixo de 500 ml, a variabilidade é grande o suficiente para que essa diferença não seja estatisticamente significativa ao nível de 5%. O fabricante não tem evidência suficiente para afirmar que a máquina está desregulada. O resultado está próximo do limiar de significância, o que pode motivar uma investigação mais aprofundada, possivelmente com uma amostra maior.

3.2.2 Exemplo 2: Peso de recém-nascidos com SIDS (bicaudal)

Uma amostra de $n = 10$ pesos (em gramas) de recém-nascidos com SIDS:

$$2998,\ 3740,\ 2031,\ 2804,\ 2454,\ 2780,\ 2203,\ 3803,\ 3948,\ 2144$$

Queremos testar, ao nível $\alpha = 10\%$, se bebês com SIDS possuem peso médio diferente do da população geral, que é $\mu_0 = 3300\,\text{g}$.

(1) Hipóteses: $H_0 : \mu = 3300$; $\quad H_a : \mu \neq 3300$ (bicaudal).

(2) Estatística de teste: $\overline{x} = 2890{,}5\,\text{g}$, $s = 720{,}0\,\text{g}$,

$$t = \frac{2890{,}5 - 3300}{720{,}0/\sqrt{10}} = -1{,}80$$

A estatística segue t_9 (9 graus de liberdade).

(3) p-valor: $p = 2\ \Pr(T_9 < -1{,}80) \approx 0{,}105$.

(4) Conclusão: Como $p = 0{,}105 > 0{,}10 = \alpha$, não rejeitamos H_0. Não há evidência estatística suficiente para afirmar que o peso médio de recém-nascidos com SIDS difere da média geral.

```
import numpy as np
from scipy.stats import t

amostra = np.array([2998, 3740, 2031, 2804, 2454,
                    2780, 2203, 3803, 3948, 2144])
n, mu_0 = 10, 3300
x_bar = np.mean(amostra)        # 2890.5
s = np.std(amostra, ddof=1)     # 720.0
t_score = (x_bar - mu_0) / (s / np.sqrt(n))   # -1.80
pvalue = 2 * t.cdf(t_score, df=n-1)
print(f"t = {t_score:.4f}, p = {pvalue:.4f}")
```

3.3 t-teste para amostras pareadas

O t-teste para amostras pareadas é aplicado quando há uma correspondência um-a-um entre os elementos das duas amostras. Os casos mais comuns são:

- Medições antes e depois de uma intervenção no mesmo indivíduo.
- Dois tratamentos aplicados ao mesmo objeto, em ordens diferentes.

A ideia é reduzir o problema às diferenças individuais $d_i = x_{1i} - x_{2i}$, e então aplicar o t-teste para uma amostra sobre essas diferenças:

$$t = \frac{\overline{d} - \mu_{d_0}}{s_d/\sqrt{n}}$$

onde $\overline{d}$ é a média das diferenças, s_d é o desvio padrão das diferenças e μ_{d_0} é o valor de referência (usualmente 0, testando se a intervenção teve efeito).

3.3.1 Hipóteses

- H_0: $\mu_d = 0$ (a intervenção não teve efeito médio)
- H_a: $\mu_d \neq 0$, ou $\mu_d > 0$, ou $\mu_d < 0$

Exemplo: Eficiência de um programa de treinamento

Um programa de treinamento cognitivo foi avaliado em 8 indivíduos. Os escores (em pontos) foram registrados antes e depois do programa:

Indivíduo	1	2	3	4	5	6	7	8
Antes	72	65	80	70	75	68	77	60
Depois	78	70	85	68	80	74	82	67
Diferença (d_i)	6	5	5	-2	5	6	5	7

$H_0 : \mu_d = 0$; $H_a : \mu_d > 0$. Testamos se o programa melhorou os escores ao nível $\alpha = 5\%$.

```
import numpy as np
from scipy import stats

antes  = np.array([72, 65, 80, 70, 75, 68, 77, 60])
depois = np.array([78, 70, 85, 68, 80, 74, 82, 67])

# t-teste pareado (equivale a t-teste das diferencas)
t_stat, p_bilateral = stats.ttest_rel(antes, depois)

# Unicaudal: Ha: diferenca < 0 (antes < depois)
p_one = p_bilateral / 2 if t_stat < 0 else 1 - p_bilateral
   / 2
print(f"t = {t_stat:.4f}, p (unicaudal) = {p_one:.4f}")
```

Nota: `ttest_rel(antes, depois)` calcula as diferenças `antes - depois`. Como esperamos que "depois > antes" (melhora), as diferenças tendem a ser negativas, e usamos o teste unicaudal à esquerda.

3.4 t-teste para duas amostras independentes

O t-teste para duas amostras independentes compara as médias de dois grupos distintos, sem qualquer correspondência entre os elementos. A hipótese nula é $H_0 : \mu_1 = \mu_2$, ou equivalentemente, $H_0 : \mu_1 - \mu_2 = 0$.

3.4.1 Teste de Welch

A variante mais robusta é o **teste de Welch**, que não supõe igualdade das variâncias populacionais. A estatística de teste é:

$$t = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

Os graus de liberdade são calculados pela fórmula de Welch–Satterthwaite:

$$\nu = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\dfrac{(s_1^2/n_1)^2}{n_1 - 1} + \dfrac{(s_2^2/n_2)^2}{n_2 - 1}}$$

Welch vs. t-teste padrão

O t-teste padrão (`equal_var=True`) é mais potente quando a suposição de igualdade de variâncias é válida, mas menos confiável se violada. O teste de Welch (`equal_var=False`) é mais robusto e é preferível sempre que houver dúvida sobre a igualdade das variâncias, ou quando as amostras têm tamanhos diferentes.

3.4.2 Condições de aplicabilidade

- Ambas as amostras são aproximadamente normalmente distribuídas.
- As amostras são independentes entre si.

Como decidir entre os testes

- **Pareado:** mesmas unidades medidas duas vezes (antes/depois)
- **Independente:** grupos distintos (ex.: tratamento vs controle)

Regra simples: existe correspondência 11 entre observações? use pareado.

3.5 Exemplos

3.5.1 Exemplo 1: Níveis de colesterol em dois grupos

Dois grupos de indivíduos foram avaliados quanto ao nível de colesterol (mg/dL). Grupo A ($n_1 = 20$) e Grupo B ($n_2 = 20$). Há diferença estatisticamente significativa entre as médias ao nível $\alpha = 5\%$?

(1) Hipóteses: $H_0 \colon \mu_1 = \mu_2$; $H_a \colon \mu_1 \neq \mu_2$ (bicaudal).

Estatísticas amostrais: $\overline{x}_1 = 245{,}05$, $s_1 = 36{,}64$ (Grupo A); $\overline{x}_2 = 210{,}30$, $s_2 = 48{,}34$ (Grupo B).

Estatística de teste:

$$t = \frac{245{,}05 - 210{,}30}{\sqrt{36{,}64^2/20 + 48{,}34^2/20}} = \frac{34{,}75}{13{,}563} \approx 2{,}562$$

Graus de liberdade (Welch): $\nu \approx 35{,}4$.

p-valor: $p \approx 0{,}015$.

Conclusão: Como $p = 0{,}015 < 0{,}05 = \alpha$, rejeitamos H_0. Há evidência de diferença estatisticamente significativa nos níveis de colesterol entre os dois grupos.

```
import numpy as np
from scipy import stats

grupo_a = np.array([233, 291, 312, 250, 246, 197, 268, 224, 239,
    239,
                    254, 276, 234, 181, 248, 252, 202, 218, 212,
                        325])
grupo_b = np.array([344, 185, 263, 246, 224, 212, 188, 250, 148,
    169,
                    226, 175, 242, 252, 153, 183, 137, 202, 194,
                        213])
```

```
t_stat, p_value = stats.ttest_ind(grupo_a, grupo_b, equal_var=
    False)
print(f"t = {t_stat:.4f}, p = {p_value:.4f}")
```

3.5.2 Exemplo 2: Desempenho por gênero em teste

Foram registradas as notas de 20 estudantes em um teste. Há diferença significativa entre alunas e alunos ao nível $\alpha = 5\%$?

```
import pandas as pd
from scipy import stats

data = {
    "Score": [95,100,78,68,100,95,98,79,98,95,
              90,95,98,86,100,100,78,89,89,94],
    "Gender": [2,1,2,2,1,2,2,2,2,1,
               1,1,1,2,1,1,2,2,2,2]    # 1=Feminino, 2=Masculino
}
df = pd.DataFrame(data)
fem = df[df["Gender"]==1]["Score"]
masc = df[df["Gender"]==2]["Score"]
t_stat, p = stats.ttest_ind(fem, masc, equal_var=False)
print(f"Media feminino: {fem.mean():.2f}, masculino: {masc.mean
    ():.2f}")
print(f"t = {t_stat:.4f}, p = {p:.4f}")
```

O p-valor é menor que 0,05, indicando que a diferença é estatisticamente significativa. As alunas apresentaram desempenho médio significativamente superior.

3.6 Resumo das funções `scipy.stats` para t-testes

Função	Tipo de t-teste	Hipótese nula
`ttest_1samp(a, popmean)`	Uma amostra	$\mu = \mu_0$
`ttest_rel(a, b)`	Amostras pareadas	$\mu_d = 0$
`ttest_ind(a, b)`	Duas amostras independentes	$\mu_1 = \mu_2$
`ttest_ind(a, b, equal_var=False)`	Welch (variâncias diferentes)	$\mu_1 = \mu_2$

Atenção ao p-valor bilateral

Todas as funções `scipy.stats` acima retornam o p-valor **bilateral**. Para testes unicaudais, é necessário ajustar manualmente:

```
# Para Ha: mu < mu0 (unicaudal a esquerda)
t_stat, p = stats.ttest_1samp(data, mu0)
p_one_sided = p / 2 if t_stat < 0 else 1 - (p / 2)
```

Síntese: z-teste vs. t-teste

Situação	Teste	Estatística
σ conhecido, n grande ou pop. normal	z-teste	$Z = \frac{(\overline{x}-\mu_0)}{(\sigma/\sqrt{n})}$
σ desconhecido, uma amostra	t-teste (1 amostra)	$t = \frac{(\overline{x}-\mu_0)}{(s/\sqrt{n})}$
σ desconhecido, amostras pareadas	t-teste pareado	$t = \frac{\overline{d}}{(s_d/\sqrt{n})}$
σ desconhecido, amostras independentes	t-teste Welch	$t = \frac{(\overline{x}_1-\overline{x}_2)}{\sqrt{s_1^2/n_1+s_2^2/n_2}}$

Pergunta 4

Para cada situação abaixo, indique qual tipo de t-teste seria mais adequado e justifique:
(a) Um pesquisador mede a pressão arterial de 15 pacientes antes e depois de administrar um medicamento.
(b) Dois grupos de estudantes diferentes (grupo de estudo online vs. presencial) fazem o mesmo teste. O pesquisador quer comparar as médias.
(c) Uma empresa quer verificar se o tempo médio de atendimento telefônico é igual a 5 minutos.

3.7 Exercícios de fixação

Exercício 9: Vida útil de baterias (t-teste para uma amostra)

Um fabricante afirma que a vida útil média de suas baterias é de 200 horas. Uma amostra de $n = 12$ baterias produziu $\overline{x} = 195$ horas e $s = 10$ horas.

(a) Formule as hipóteses para verificar se a vida útil é *menor* do que o afirmado.

(b) Calcule o t-escore e os graus de liberdade.

(c) Calcule o p-valor e conclua ao nível $\alpha = 0{,}05$.

(d) Que condição sobre a distribuição dos dados é necessária para a validade deste teste, dado o tamanho da amostra?

Exercício 10: Programa de emagrecimento (t-teste pareado)

Um nutricionista quer verificar se uma dieta reduziu o peso corporal de 10 pacientes. Os pesos (em kg) antes e depois do programa são:

Antes	85	92	78	95	88	76	90	83	97	80
Depois	82	89	75	91	84	74	86	80	93	77

(a) Por que o t-teste pareado é mais adequado do que o t-teste para amostras independentes neste caso?

(b) Calcule as diferenças d_i, a média $\overline{d}$ e o desvio padrão s_d.

(c) Realize o teste ao nível $\alpha = 5\%$ e conclua.

(d) Implemente o teste em Python usando `scipy.stats.ttest_rel`.

Exercício 11: Desempenho acadêmico (t-teste independente)

Uma escola quer comparar o desempenho de turmas do turno da manhã e da tarde em uma prova. Os dados são: turno da manhã ($n_1 = 20$, $\overline{x}_1 = 74$, $s_1 = 8$) e turno da tarde ($n_2 = 25$, $\overline{x}_2 = 70$, $s_2 = 10$).

(a) Formule as hipóteses para um teste bicaudal.

(b) Aplique o teste de Welch e calcule o p-valor.

(c) Conclua ao nível $\alpha = 5\%$ e interprete.

(d) Qual suposição adicional seria necessária para usar o t-teste padrão com `equal_var=True`?

Exercício 12: Escolha do tipo de t-teste

Para cada situação abaixo, identifique o tipo de t-teste mais adequado (uma amostra, pareado ou Welch) e justifique sua escolha:

(a) Um pesquisador mede a pressão arterial de 15 pacientes antes e depois de administrar um medicamento.

(b) Dois grupos de estudantes distintos (online vs. presencial) fazem o mesmo exame e o pesquisador quer comparar as notas médias.

(c) Uma empresa quer verificar se o tempo médio de atendimento telefônico é diferente de 5 minutos, com base em uma amostra de 30 ligações.

(d) O mesmo conjunto de 20 ratos recebe dois tratamentos diferentes (A e B) em momentos distintos e os pesquisadores registram a resposta imunológica em cada caso.

4 Poder do Teste

4.1 Definição

Definição

O **poder de um teste estatístico** (*power*) é a probabilidade de rejeitar corretamente a hipótese nula H_0 quando ela é de fato falsa:

$$\text{Poder} = 1 - \beta$$

onde $\beta = \Pr(\text{erro tipo II}) = \Pr(\text{não rejeitar } H_0 \mid H_0 \text{ falsa})$.
Em termos práticos, o poder mede a capacidade do teste de detectar um efeito real quando ele existe.

Um teste com *baixo poder* pode falhar em detectar diferenças reais, levando a falsas conclusões de que "nada mudou", o chamado erro tipo II. Por exemplo, imagine que uma nova medicação é genuinamente mais eficaz do que o placebo: um teste com baixo poder pode não detectar essa eficácia, levando à conclusão incorreta de que o medicamento não funciona.

Ideia central

Um resultado não significativo pode ocorrer por dois motivos completamente distintos:

- **O efeito não existe:** H_0 é de fato verdadeira.
- **O efeito existe, mas o teste não teve poder suficiente para detectá-lo.**

Mensagem importante: "não rejeitar H_0" não significa que não há efeito. Pode significar apenas que a amostra foi pequena demais para revelá-lo.

Para compreender intuitivamente os conceitos de erro tipo I, erro tipo II e poder do teste, é útil visualizar as distribuições da estatística sob H_0 e sob H_a. A Figura 5 ilustra essa ideia.

- A curva azul representa a distribuição da estatística de teste assumindo que H_0 é verdadeira.
- A curva vermelha representa a distribuição quando existe um efeito real (H_a).
- O ponto c define a região crítica: valores à direita levam à rejeição de H_0.
- A área α corresponde à região sob H_0 à direita de c (área hachurada). Trata-se do erro tipo I.
- A área β corresponde à região sob H_a à esquerda de c (área cinza). Trata-se do erro tipo II.
- A área $1 - \beta$ corresponde à região sob H_a à direita de c (área verde). Trata-se do poder do teste.

Importante: as regiões α e $1-\beta$ ocupam o mesmo intervalo no eixo x (à direita de c), mas são calculadas sob distribuições diferentes (H_0 e H_a, respectivamente). Portanto, não devem ser interpretadas como a mesma área.

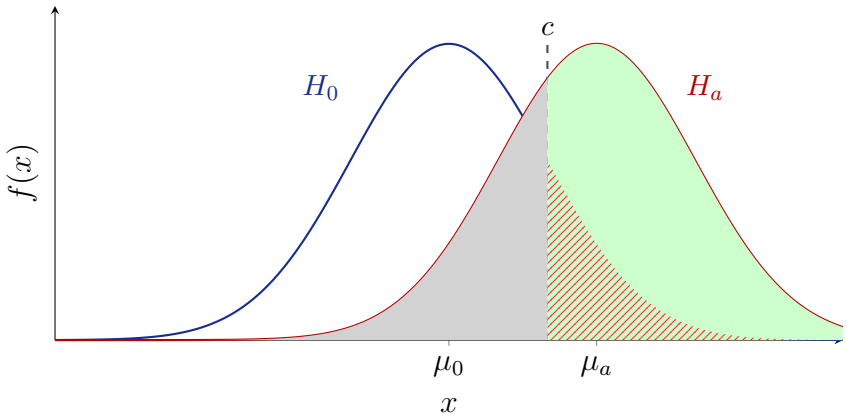

Figura 5: Distribuições da estatística de teste sob H_0 e sob H_a. A região α representa o erro tipo I, a região β representa o erro tipo II, e a região $1-\beta$ representa o poder do teste.

Cuidado: regiões no mesmo intervalo não são a mesma coisa

As regiões α e $1-\beta$ ocupam o mesmo intervalo no eixo x (à direita de c), mas correspondem a probabilidades diferentes, pois são calculadas sob distribuições distintas:

- α é calculado sob a distribuição de H_0
- $1-\beta$ é calculado sob a distribuição de H_a

Conclusão: mesmo intervalo no eixo horizontal não implica mesma probabilidade.

4.2 Fatores que afetam o poder

O poder de um teste aumenta quando a diferença entre as médias é grande em relação à variabilidade dos dados, e quando a amostra é grande. Formalmente, os quatro fatores principais são:

1. **Tamanho da amostra** n: quanto maior a amostra, menor o erro padrão, mais fácil é distinguir a média real de μ_0 e, portanto, maior o poder.
2. **Nível de significância** α: um α maior (ex.: 0,10 em vez de 0,05) aumenta o poder, mas também eleva a probabilidade de erro tipo I. Alterar α raramente é a estratégia mais adequada para aumentar o poder.
3. **Tamanho do efeito**: efeitos maiores (diferença entre a média real e μ_0, relativa à variabilidade) são mais fáceis de detectar e aumentam o poder.
4. **Variabilidade dos dados**: menor variabilidade (desvio padrão menor) resulta em maior poder, pois o sinal fica mais claro em relação ao ruído.

4.3 Impacto da variabilidade no poder

A Figura 6 ilustra o efeito da variabilidade sobre o poder do teste. Em ambos os cenários, a diferença entre as médias dos grupos A e B é a mesma ($\mu_A = 100$, $\mu_B = 110$). O que muda é o desvio padrão.

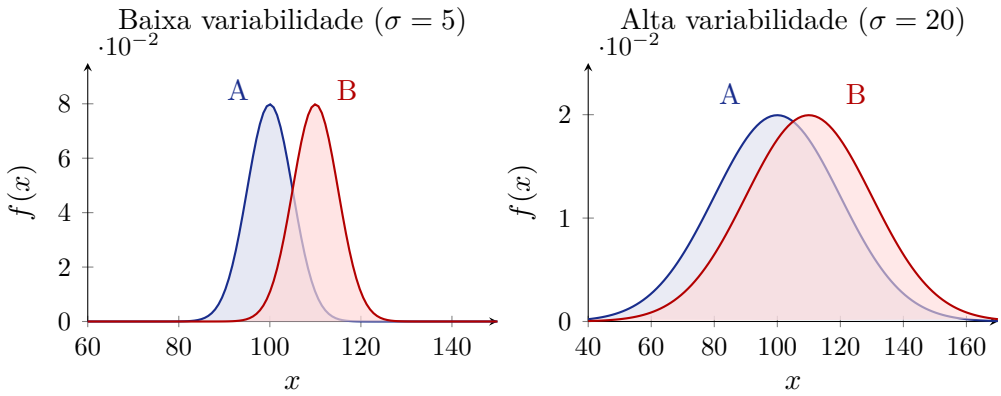

Figura 6: Mesma diferença de médias ($\Delta = 10$) em dois cenários de variabilidade. Com baixa variabilidade (esq.), os grupos se sobrepõem pouco, o teste tem alto poder. Com alta variabilidade (dir.), a sobreposição é grande e o teste tem dificuldade em distinguir os grupos.

Simulação: poder vs. variabilidade em Python

```
import numpy as np
from scipy.stats import ttest_ind

np.random.seed(42)
n = 30
mean_a, mean_b = 100, 110

# Cenario 1: baixa variabilidade
std_low = 5
grupo_a_low = np.random.normal(mean_a, std_low, n)
grupo_b_low = np.random.normal(mean_b, std_low, n)
t_low, p_low = ttest_ind(grupo_a_low, grupo_b_low)
print(f"Baixa variabilidade: p = {p_low:.4f}")

# Cenario 2: alta variabilidade
std_high = 20
grupo_a_high = np.random.normal(mean_a, std_high, n)
grupo_b_high = np.random.normal(mean_b, std_high, n)
t_high, p_high = ttest_ind(grupo_a_high, grupo_b_high)
print(f"Alta variabilidade:  p = {p_high:.4f}")
```

Resultado esperado: o cenário de baixa variabilidade produz p-valor muito pequeno (rejeita H_0), enquanto o de alta variabilidade pode não rejeitar H_0, mesmo a diferença de médias sendo a mesma. Isso ilustra que **alta variabilidade dificulta a detecção de efeitos reais**.

4.4 Relação entre poder, erro tipo I e tamanho amostral

Síntese: poder do teste

Para aumentar o poder...	Efeito colateral
Aumentar n	Custo mais alto de coleta
Aumentar α	Maior probabilidade de erro tipo I
Reduzir a variabilidade	Nem sempre controlável
Estudar efeitos maiores	Pode não ser o objetivo

Recomendação: o aumento do tamanho amostral é a estratégia mais eficaz e controlável para aumentar o poder sem comprometer a taxa de erro tipo I.

Pergunta 5

Um pesquisador aplica um t-teste e obtém $p = 0{,}12$ com $n = 15$. Ele conclui que "não há diferença entre os grupos".
(a) Essa conclusão é necessariamente correta? Que erro pode estar ocorrendo?
(b) Que medidas o pesquisador poderia tomar para aumentar o poder do teste?

4.5 Exercícios de fixação

Exercício 13: Poder e tamanho amostral

Um pesquisador aplica um t-teste com $n = 10$ e obtém $p = 0{,}09$ para $\alpha = 0{,}05$.

(a) Qual é a decisão do pesquisador? Que tipo de erro ele pode estar cometendo?

(b) Se o pesquisador repetir o estudo com $n = 40$, mantendo os demais parâmetros, o que provavelmente acontecerá com o p-valor e o poder do teste? Justifique.

(c) O pesquisador decide aumentar α para 0,10. Isso resolve o problema do poder? Quais são os riscos dessa estratégia?

Exercício 14: Interpretação de resultado não significativo

Um ensaio clínico compara um novo medicamento com placebo em $n = 20$ pacientes por grupo e obtém $p = 0{,}15$ com $\alpha = 0{,}05$.

(a) A conclusão "o medicamento não tem efeito" é válida? Explique.

(b) O que significa dizer que o teste tem baixo poder nesse contexto?

(c) Que informação adicional (além do p-valor) seria útil para avaliar se o efeito do medicamento é clinicamente relevante?

(d) Proponha duas estratégias para aumentar o poder em um novo ensaio.

Exercício 15: Trade-off entre erros tipo I e tipo II

Considere dois cenários de uso de testes de hipóteses:
Cenário A: triagem de segurança em aviação, em que H_0: "passageiro não é ameaça".
Cenário B: aprovação de um medicamento contra gripe comum, em que H_0: "o medicamento não é eficaz".

(a) Para cada cenário, identifique qual erro (tipo I ou tipo II) é mais grave e justifique.

(b) Como a escolha de α deveria diferir entre os dois cenários? Explique o impacto sobre β.

(c) Em qual cenário é mais importante garantir alto poder? Por quê?

Exercício 16: Fatores que afetam o poder: análise integrada

Um pesquisador deseja detectar uma diferença de 5 pontos na média de um escore cognitivo entre dois grupos, sabendo que o desvio padrão típico é $\sigma = 15$.

(a) Sem calcular formalmente, argumente por que um estudo com $n = 10$ por grupo terá dificuldade em detectar essa diferença.

(b) O que acontece com o poder se o pesquisador usar $n = 100$ por grupo? E se o desvio padrão for $\sigma = 5$?

(c) Se a diferença real entre os grupos fosse de 15 pontos (em vez de 5), como isso afetaria o poder para um mesmo n?

(d) Implemente em Python uma simulação com 1000 repetições para estimar o poder do teste para $n \in \{10, 30, 100\}$, assumindo $\sigma = 15$ e diferença real de 5 pontos.

5 Resumo

A tabela abaixo sintetiza os principais testes de hipóteses estudados:

Teste	**Quando usar**	**Estatística**	**Distribuição**
z-teste	σ conhecido, n grande ou pop. normal	$Z = \dfrac{\overline{x} - \mu_0}{\sigma/\sqrt{n}}$	$\mathcal{N}(0,1)$
t-teste (1 am.)	σ desconhecido, uma amostra	$t = \dfrac{\overline{x} - \mu_0}{s/\sqrt{n}}$	t_{n-1}
t-teste pareado	Duas amostras pareadas	$t = \dfrac{\overline{d}}{s_d/\sqrt{n}}$	t_{n-1}
t-teste Welch	Duas amostras independentes	$t = \dfrac{\overline{x}_1 - \overline{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	t_ν

Mensagem central

O teste de hipóteses é um procedimento formal para avaliar evidências amostrais contra uma afirmação sobre um parâmetro populacional. A regra de decisão é sempre baseada na comparação do p-valor com o nível de significância α previamente definido. A escolha do teste adequado depende do que é conhecido sobre a população (σ), da estrutura do delineamento (uma ou duas amostras, pareadas ou independentes) e do tamanho amostral. O poder do teste (i.e., a capacidade de detectar efeitos reais) aumenta principalmente com o tamanho da amostra. Lembre-se também que significância estatística e relevância prática são conceitos distintos: um efeito pode ser estatisticamente detectável, mas irrelevante na prática, ou relevante na prática, mas difícil de detectar com uma amostra pequena.

6 Diagnóstico e Consolidação Conceitual

Esta seção tem como objetivo identificar e corrigir erros conceituais comuns, além de estimular uma compreensão mais profunda dos conceitos abordados.

6.1 Quiz diagnóstico: erros clássicos

Para cada afirmação abaixo, indique se ela é *verdadeira* ou *falsa* e justifique brevemente sua resposta.

1. "Se o p-valor é 0,03, então há 3% de probabilidade de que a hipótese nula seja verdadeira."
2. "Se não rejeitamos H_0, então ela deve ser verdadeira."
3. "Quanto menor o p-valor, maior é a magnitude do efeito observado."
4. "Em geral, aumentar o tamanho da amostra tende a diminuir o p-valor quando existe um efeito real, pois reduz o erro padrão e aumenta a evidência estatística. Contudo, isso não é garantido para qualquer amostra específica."
5. "Fixar $\alpha = 0{,}01$ sempre leva a conclusões mais confiáveis do que $\alpha = 0{,}05$."
6. "Se um resultado não é estatisticamente significativo, então não há diferença entre os grupos."
7. "O teste t sempre deve ser usado quando σ é desconhecido, independentemente do tamanho da amostra."

6.2 Questões conceituais

Explique cada questão abaixo como se estivesse ensinando a um colega que nunca estudou estatística. Evite fórmulas sempre que possível e priorize intuição e exemplos. Se você consegue responder essas perguntas de forma clara, sem recorrer a fórmulas, então você provavelmente desenvolveu uma compreensão sólida dos conceitos fundamentais de teste de hipóteses.

1. Explique, em termos simples, o que significa rejeitar H_0. O que exatamente estamos afirmando (e o que não estamos afirmando)?

2. Explique por que o p-valor não é a probabilidade de a hipótese nula ser verdadeira.

3. Explique a diferença entre erro tipo I e erro tipo II usando um exemplo do mundo real (por exemplo, um teste médico ou sistema de detecção de fraude).

4. Explique por que um resultado pode não ser estatisticamente significativo mesmo quando existe uma diferença real entre os grupos.

5. Explique por que aumentar o tamanho da amostra aumenta o poder do teste.

6. Explique a diferença entre testes unicaudais e bicaudais. Em que situações cada um deve ser usado?

7. Um resultado é estatisticamente significativo com $p = 0{,}001$. Isso necessariamente significa que o efeito é relevante na prática? Justifique com um exemplo.