CEFET/RJ

Centro Federal de Educação Tecnológica Celso Suckow da Fonseca

Bacharelado em Ciência da Computação

GCC1625 – Inferencia Estatística

Testes Qui-quadrado

Nota de Aula

Prof. Eduardo Bezerra

Escola de Informática e Computação

CEFET/RJ

27 de outubro de 2026

Sumário

1 Fundamentos dos Testes Qui-Quadrado 2

2 A Estatística χ^2 e a Distribuição χ^2 9

3 Tamanho do Efeito: Coeficiente Phi e V de Cramér 15

4 Leitura Descritiva dos Resíduos 19

5 Exemplos Resolvidos 22

6 Resumo 24

7 Exercícios de Fixação 25

A Fundamentos probabilísticos e graus de liberdade 27

B Equivalência com o z-teste para Duas Proporções 29

C Correção de Continuidade de Yates (tabelas 2×2) 30

D Análise de Resíduos Padronizados Ajustados 30

Objetivos

Ao final do estudo do conteúdo principal, você deve ser capaz de:

- Distinguir os testes de aderência, independência e homogeneidade e formular suas hipóteses.
- Organizar contagens, calcular frequências esperadas e compreender a estatística de Pearson.
- Determinar os graus de liberdade nos casos básicos e interpretar o p-valor.
- Verificar as condições de aplicabilidade e reconhecer situações que exigem outra abordagem, como Fisher em tabelas 2×2.
- Aplicar os testes em Python e comunicar conclusões contextualizadas.
- Distinguir significância estatística e tamanho do efeito, utilizando ϕ ou V de Cramér nas tabelas de contingência.
- Interpretar descritivamente os sinais dos resíduos para localizar padrões de associação.

O conteúdo principal prioriza a realização e a interpretação de uma análise completa. Os apêndices oferecem aprofundamento: fundamentos probabilísticos e graus de liberdade (Apêndice A); conexão com o teste de duas proporções (Apêndice B); correção de Yates (Apêndice C); e análise detalhada de resíduos (Apêndice D). Os exercícios desses apêndices são complementares.

1 Fundamentos dos Testes Qui-Quadrado

Nos testes estudados anteriormente, analisamos questões envolvendo médias e proporções. Agora, ampliaremos a análise para situações em que os dados são organizados em *categorias* e o interesse está na distribuição das observações entre essas categorias.

Considere, por exemplo, uma pesquisa sobre preferência por animais de estimação. Cada participante informa se prefere cachorro ou gato. Nesse caso, não faz sentido calcular a média das respostas: precisamos contar quantas pessoas escolheram cada alternativa. Se também registrarmos outra característica dos participantes, como sexo, poderemos investigar uma pergunta adicional: a distribuição das preferências é a mesma entre os grupos?

Questões desse tipo aparecem em diversos contextos:

- As preferências por quatro cores de carros se distribuem igualmente entre as cores?
- Há associação entre hábito de fumar e nível de atividade física?
- A distribuição das formas de pagamento é a mesma em diferentes filiais de uma loja?

Os *testes qui-quadrado* (χ^2) permitem investigar essas questões a partir de *contagens de observações*. A ideia comum é comparar as frequências efetivamente observadas com aquelas que esperaríamos encontrar caso uma hipótese nula fosse verdadeira.

Uma diferença entre observado e esperado é natural em dados amostrais. O teste avalia se a discrepância encontrada é compatível com a variabilidade amostral prevista sob H_0 ou se fornece evidência contra essa hipótese.

Para desenvolver essa ideia, começaremos com uma pergunta sobre duas variáveis categóricas. Antes de formular o teste, precisamos organizar os dados de uma maneira que permita visualizar sua distribuição conjunta.

1.1 Tabela de Contingência: Organizando a Pergunta

Suponha que uma pesquisa registre, para cada uma de 100 pessoas, as variáveis `sexo`, com as categorias Masculino e Feminino, e `animal de estimação preferido`, com as categorias Cachorro e Gato. Neste exemplo, cada participante pertence a uma categoria de cada variável e contribui com uma única observação.

Queremos investigar se a preferência por animal está associada ao sexo dos participantes. Contar apenas o total de pessoas que preferem cachorro ou gato não basta: precisamos saber como essas preferências se distribuem *dentro de cada grupo*.

Para isso, organizamos as contagens em uma *tabela de contingência*, também chamada de *tabulação cruzada*. As linhas representam as categorias de uma variável; as colunas, as categorias da outra. Cada célula contém o número de observações que pertencem simultaneamente à categoria da linha e à categoria da coluna.

Considere a seguinte tabela:

	Cachorro	**Gato**	**Total**
Masculino	42	10	52
Feminino	9	39	48
Total	51	49	100

Por exemplo, a contagem 42 indica que 42 participantes pertencem ao grupo Masculino *e* preferem cachorro. A contagem 39 indica que 39 participantes pertencem ao grupo Feminino *e* preferem gato.

A coluna à direita contém os *totais marginais por linha*: 52 participantes no grupo Masculino e 48 no grupo Feminino. A linha inferior contém os *totais marginais por coluna*: 51 participantes preferem cachorro e 49 preferem gato. O total geral é $N = 100$.

Dizemos que essa tabela tem dimensão 2×2, pois há duas categorias em cada variável. A linha e a coluna de totais não entram nessa contagem.

A tabela permite uma primeira análise descritiva. Para comparar os grupos, porém, convém calcular proporções dentro de cada linha, pois seus tamanhos podem ser diferentes. A proporção de preferência por cachorro é:

$$\frac{42}{52} \approx 0{,}808 \quad \text{no grupo Masculino,} \qquad \frac{9}{48} \approx 0{,}188 \quad \text{no grupo Feminino.}$$

Assim, aproximadamente 81% do primeiro grupo e 19% do segundo preferem cachorro. Na amostra, as distribuições de preferência são bastante diferentes.

Essa descrição ainda não responde à pergunta inferencial: o padrão observado fornece evidência de associação na população? Para formular essa pergunta com precisão, precisamos definir o que significaria *não haver associação*.

1.2 Independência Estatística: o Cenário de Referência

Duas variáveis são *estatisticamente independentes* quando conhecer a categoria de uma delas não altera as probabilidades das categorias da outra.

No exemplo, independência significaria que conhecer o sexo de uma pessoa não altera a probabilidade de ela preferir cachorro ou gato. A distribuição das preferências seria, portanto, a mesma nos dois grupos da população.

Em termos de eventos, se A representa "pertencer a um grupo" e B representa "preferir cachorro", a independência implica:

$$\Pr(B \mid A) = \Pr(B),$$

desde que $\Pr(A) > 0$. Equivalentemente,

$$\Pr(A \cap B) = \Pr(A)\Pr(B).$$

A primeira expressão destaca a interpretação: a probabilidade de preferir cachorro entre as pessoas do grupo é igual à probabilidade de preferir cachorro na população. A segunda expressa a mesma ideia por meio da probabilidade conjunta.

Essa definição fornece o cenário de referência para o *teste qui-quadrado de independência*:

- H_0: as duas variáveis são independentes na população;
- H_a: as duas variáveis estão associadas na população.

Se H_0 for verdadeira, a distribuição das preferências será a mesma nos dois grupos da população. Isso não significa, porém, que as proporções observadas em uma amostra serão exatamente iguais. A seleção aleatória dos participantes introduz variabilidade amostral: mesmo quando não há associação na população, uma amostra pode apresentar uma proporção de preferência por cachorro um pouco maior em um grupo do que no outro. Se repetíssemos a pesquisa com novas amostras, obteríamos outras contagens e, consequentemente, outras diferenças entre as proporções. Portanto, a simples presença de uma diferença na amostra não basta para rejeitar a hipótese de independência. Precisamos avaliar se a discrepância observada é compatível com as flutuações amostrais esperadas sob H_0 ou se é suficientemente grande para fornecer evidência contra essa hipótese.

Na tabela apresentada, 51 das 100 pessoas entrevistadas preferem cachorro, o que corresponde a 51% da amostra. Se sexo e preferência forem independentes na população, a probabilidade de preferir cachorro será a mesma nos dois grupos. Como não conhecemos essa probabilidade populacional, usamos a proporção geral observada na amostra, 51%, como uma estimativa comum aos grupos. Aplicando essa proporção às 52 pessoas do grupo Masculino, esperaríamos encontrar $52 \times 0{,}51 = 26{,}52$ pessoas com preferência por cachorro; entre as 48 pessoas do grupo Feminino, esperaríamos $48 \times 0{,}51 = 24{,}48$. Esses valores não descrevem o que foi efetivamente observado, mas estabelecem uma referência para a comparação: como as contagens se distribuiriam se não houvesse associação entre as variáveis? Embora sejam expressos em número de pessoas, os valores esperados podem ser

fracionários, pois representam médias teóricas, e não contagens efetivamente realizadas. Na próxima seção, formalizaremos esse raciocínio por meio das *frequências esperadas* e veremos como compará-las com as frequências observadas.

O teste compara essas frequências esperadas com as observadas e avalia a discrepância global. A pergunta é:

Se as variáveis fossem independentes na população, quão compatível seria a discrepância observada com a variabilidade amostral?

É importante separar duas conclusões. A tabela descreve um padrão na amostra; o teste avalia a evidência de associação na população, sob as condições de sua aplicação. Mesmo quando há evidência de associação, isso não demonstra que uma variável causa a outra. Por esse motivo, usaremos expressões como "há associação entre as variáveis", evitando atribuir uma relação causal apenas com base no teste.

Pergunta 1

Na tabela sexo × animal preferido, as proporções de preferência por cachorro são diferentes entre os dois grupos.
(a) Essa diferença amostral, por si só, permite concluir que as variáveis estão associadas na população?
(b) Se as variáveis fossem independentes na população, as proporções observadas em uma amostra precisariam ser exatamente iguais? Explique.
(c) Qual é o papel do teste estatístico nessa análise?

1.3 Três Perguntas, Três Modalidades de Teste

Até aqui, usamos o qui-quadrado para motivar uma investigação de associação entre duas variáveis. A mesma ideia de comparar frequências observadas e esperadas também permite responder a outras perguntas.

Distinguiremos três modalidades: *aderência*, *independência* e *homogeneidade*. Para escolher entre elas, identifique a pergunta de pesquisa e a forma como os dados foram coletados.

1.3.1 Teste de Aderência: uma Variável e uma Distribuição de Referência

No teste de aderência, observamos uma única variável categórica e investigamos se suas probabilidades populacionais correspondem a uma distribuição de referência especificada sob H_0. Considere, por exemplo, uma pesquisa em que cada participante indica sua preferência entre quatro cores de carros: Vermelho, Azul, Preto e Branco. A variável observada é a cor preferida, e sua distribuição descreve como as preferências se repartem entre essas quatro categorias. Se queremos verificar se as quatro cores são igualmente preferidas na população, a distribuição de referência é a *uniforme*: sob H_0, cada cor tem probabilidade $1/4 = 0{,}25$ de ser escolhida. Na amostra, entretanto, as contagens de preferência por cada cor podem ser diferentes, mesmo que essa hipótese seja verdadeira. O teste de aderência avalia se as diferenças entre as contagens observadas e aquelas esperadas sob a distribuição uniforme são compatíveis com a variabilidade amostral ou fornecem evidência de que as preferências não se distribuem igualmente na população. Como há apenas uma variável, organizamos os dados em uma lista de cores e suas respectivas contagens, sem precisar cruzar duas variáveis em uma tabela de contingência. Nesse caso:

- H_0: a proporção populacional de preferência por cada cor é 0,25;
- H_a: pelo menos uma dessas proporções difere de 0,25.

De modo geral, para m categorias e probabilidades de referência $p_{10}, \ldots, p_{m0}$:

$$H_0 : \ p_i = p_{i0} \text{ para todo } i, \qquad H_a : \ p_i \neq p_{i0} \text{ para pelo menos um } i.$$

A distribuição uniforme é apenas uma das possíveis distribuições de referência: o teste de aderência também permite avaliar hipóteses que atribuem probabilidades diferentes às categorias. Considere, por exemplo, uma investigação sobre os tipos sanguíneos A, B, AB e O em determinada população. Se dispomos de proporções de referência para esses tipos, podemos usá-las para formular H_0 e calcular as contagens esperadas em uma amostra. Nesse caso, não estamos perguntando se os quatro tipos são igualmente frequentes, mas se a distribuição na população investigada corresponde às proporções especificadas. A escolha da distribuição de referência deve, portanto, expressar a hipótese que desejamos avaliar, e não resultar de uma exigência de igualdade entre as categorias.

Em qualquer desses exemplos, as hipóteses dizem respeito às *probabilidades populacionais*, enquanto os dados disponíveis são contagens obtidas em uma amostra. Essa distinção é importante porque uma hipótese sobre a população não determina exatamente o resultado de cada amostragem. Mesmo que as quatro cores sejam igualmente preferidas na população, por exemplo, uma amostra de 100 pessoas não precisa apresentar exatamente 25 escolhas de cada cor. Essas são as contagens esperadas sob H_0, mas as contagens observadas podem oscilar em torno delas. O teste de aderência considera conjuntamente os desvios de todas as categorias e avalia se a discrepância global é compatível com a variabilidade amostral prevista pela distribuição de referência. Assim, a decisão não depende da simples existência de diferenças entre observado e esperado, mas de quão expressivas são essas diferenças no cenário descrito por H_0.

1.3.2 Teste de Independência: duas Variáveis em uma Amostra

No teste de aderência, comparamos a distribuição de uma variável com probabilidades de referência previamente especificadas. No teste de independência, a pergunta é diferente: queremos investigar se duas variáveis categóricas estão associadas na população. Para isso, selecionamos uma amostra e registramos ambas as variáveis em cada unidade amostral. O interesse está em verificar se a distribuição de uma variável permanece a mesma entre as categorias da outra ou se conhecer uma característica altera as probabilidades da outra.

A pesquisa sobre sexo e animal preferido ilustra essa situação. Cada participante fornece duas informações, que são cruzadas em uma tabela de contingência. Se as variáveis forem independentes na população, a proporção de preferência por cachorro será a mesma nos grupos Masculino e Feminino, assim como a proporção de preferência por gato. Se houver associação, essas distribuições serão diferentes: conhecer o grupo ao qual uma pessoa pertence modificará a probabilidade de ela preferir cada animal. Isso não significa que a preferência de uma pessoa possa ser determinada com certeza a partir de seu grupo, mas que as probabilidades de preferência variam entre os grupos.

As hipóteses expressam essas duas possibilidades:

- H_0: as duas variáveis são estatisticamente independentes na população; no exemplo, a distribuição das preferências por animal é a mesma nos dois grupos.

- H_a: as duas variáveis estão associadas na população; no exemplo, a distribuição das preferências por animal difere entre os grupos.

Diferentemente do exemplo de aderência com quatro cores igualmente preferidas, aqui não especificamos previamente qual deve ser a proporção de preferência por cada animal. A hipótese de independência não exige que cachorro e gato sejam igualmente preferidos: ela permite, por exemplo, que cachorro seja mais popular, desde que a distribuição das preferências seja a mesma nos dois grupos. Para construir o cenário esperado sob H_0, usamos as proporções marginais da própria amostra. Na tabela apresentada anteriormente, a proporção geral de 51% de preferência por cachorro é aplicada aos dois grupos para obter as respectivas frequências esperadas. O teste compara essas frequências com as observadas e avalia se a discrepância global fornece evidência contra a independência.

A mesma lógica se aplica a tabelas com mais categorias. Poderíamos selecionar uma amostra de estudantes e registrar, para cada um, o hábito de fumar e o nível de atividade física. Sob H_0, a distribuição dos níveis de atividade física seria a mesma em todas as categorias de hábito de fumar. Sob H_a, pelo menos uma dessas distribuições seria diferente. A rejeição de H_0 forneceria evidência de associação entre as variáveis, mas não indicaria, por si só, quais combinações de categorias apresentam os desvios mais expressivos nem demonstraria uma relação causal entre tabagismo e atividade física.

1.3.3 Teste de Homogeneidade: uma Distribuição Comparada entre Populações

No teste de independência, partimos de uma amostra e investigamos a relação entre duas variáveis registradas em cada unidade amostral. No teste de homogeneidade, partimos de duas ou mais populações ou grupos que desejamos comparar. Selecionamos uma amostra de cada população, de forma independente, e registramos a mesma variável categórica em todas elas. A pergunta é se as probabilidades das categorias dessa variável são iguais entre as populações, isto é, se a variável apresenta a mesma distribuição nos diferentes grupos.

Considere uma rede de supermercados que deseja comparar as formas de pagamento utilizadas pelos clientes de três filiais. Para isso, seleciona, separadamente, uma amostra de clientes de cada filial e registra se cada cliente pagou com Dinheiro, Cartão ou PIX. Cada filial define uma população de interesse, e a variável observada em todas elas é a forma de pagamento. As contagens podem ser organizadas em uma tabela de contingência, com uma linha para cada filial e uma coluna para cada forma de pagamento. Essa organização permite comparar como os clientes de cada filial se distribuem entre as três categorias.

Nesse exemplo, dizer que as distribuições são homogêneas significa que cada forma de pagamento tem a mesma proporção de utilização nas três populações. Suponha, por exemplo, que essas proporções sejam 20% para Dinheiro, 50% para Cartão e 30% para PIX em todas as filiais. As distribuições seriam homogêneas, embora as três formas de pagamento não fossem igualmente utilizadas. Portanto, a igualdade investigada ocorre *entre as filiais, para cada categoria*, e não entre as categorias de pagamento dentro de uma filial.

Para expressar essa comparação de forma geral, sejam r o número de populações e c o número de categorias da variável. Denotamos por p_{ij} a probabilidade de uma observação pertencer à categoria j na população i. No exemplo, p_{ij} é a proporção populacional de clientes da filial i que utilizam a forma de pagamento j. As hipóteses são:

- H_0: $p_{1j} = p_{2j} = \cdots = p_{rj}$ para toda categoria j; a distribuição da variável é a mesma em todas as populações.
- H_a: para pelo menos uma categoria, a probabilidade difere entre pelo menos duas populações; portanto, as distribuições não são todas iguais.

Sob H_0, não precisamos conhecer previamente as proporções comuns às populações. Nós as estimamos reunindo as contagens das amostras: a proporção total de clientes que utilizaram PIX, por exemplo, serve como estimativa da probabilidade comum de utilização de PIX nas filiais. Aplicamos essa proporção ao tamanho da amostra de cada filial para calcular a respectiva frequência esperada. Assim, se as amostras tiverem tamanhos diferentes, suas contagens esperadas também poderão ser diferentes, mesmo sob a hipótese de homogeneidade. O que deve ser comum são as proporções populacionais, não os números absolutos de clientes.

As proporções observadas nas amostras, por sua vez, dificilmente serão exatamente iguais, mesmo quando H_0 for verdadeira, pois cada amostra está sujeita à variabilidade amostral. O teste de homogeneidade compara as contagens observadas com as esperadas sob a hipótese de uma distribuição comum e avalia a discrepância global. Se rejeitarmos H_0, teremos evidência de que a distribuição das formas de pagamento não é a mesma em todas as filiais. Essa conclusão não significa que todas as filiais diferem entre si nem que todas as formas de pagamento apresentam proporções diferentes; identificar onde estão as diferenças exige examinar o padrão observado e, quando necessário, realizar análises complementares.

1.3.4 Como Distinguir Independência e Homogeneidade

Os testes de independência e homogeneidade utilizam tabelas de contingência e compartilham a mesma estatística de Pearson, a mesma fórmula de frequências esperadas e o mesmo cálculo de graus de liberdade. A diferença está na pergunta e no desenho amostral:

- **Independência**: uma amostra é selecionada de uma população, e duas variáveis são registradas em cada unidade.
- **Homogeneidade**: amostras são selecionadas separadamente de diferentes populações ou grupos, e uma mesma variável é registrada em cada amostra.

Por isso, olhar apenas para os números de uma tabela pode não ser suficiente para nomear o teste. É preciso conhecer a origem dos dados e o objetivo da investigação.

Também precisamos distinguir duas ideias que usam a palavra “independência”:

- **Independência entre variáveis**: é a hipótese investigada no teste de independência.
- **Independência das observações**: é uma condição para a aplicação dos testes apresentados nestas notas. Refere-se à forma como as unidades amostrais foram observadas.

Por exemplo, registrar duas variáveis em cada pessoa não viola a independência das observações. O problema surge quando tratamos como independentes registros que são relacionados, como várias respostas da mesma pessoa ao longo do tempo. Dados pareados, repetidos ou agrupados podem exigir outros procedimentos.

Pergunta 2

Para cada situação, identifique a modalidade de teste qui-quadrado, formule H_0 e H_a e indique qual aspecto da coleta ou da pergunta orientou sua escolha.
(a) Um pesquisador seleciona uma amostra de pacientes e verifica se a distribuição dos tipos sanguíneos corresponde a proporções populacionais conhecidas.
(b) Uma empresa seleciona, separadamente, uma amostra aleatória de funcionários de cada um de três departamentos. Em cada amostra, registra o nível de satisfação e compara sua distribuição entre os departamentos.
(c) Em uma única amostra de estudantes universitários, registram-se o curso e a preferência por modalidade de aula (presencial ou remota). O objetivo é investigar se há associação entre essas variáveis.

As três modalidades partem, portanto, de uma mesma estrutura: formular uma hipótese sobre probabilidades populacionais, obter as frequências esperadas sob essa hipótese e compará-las com as frequências observadas. Na próxima seção, veremos como construir essa comparação e resumi-la na estatística χ^2.

2 A Estatística χ^2 e a Distribuição χ^2

Na seção anterior, distinguimos três perguntas que podem ser investigadas por testes qui-quadrado: se uma distribuição corresponde a probabilidades de referência, se duas variáveis estão associadas e se uma distribuição é a mesma em diferentes populações. Apesar das diferenças de interpretação, os três testes compartilham uma ideia: comparar as frequências observadas com as frequências esperadas sob a hipótese nula.

Para transformar essa ideia em um procedimento de teste, precisamos responder a três perguntas. Primeiro, como calcular as frequências esperadas em cada situação? Segundo, como resumir as diferenças entre observado e esperado em um único número? Por fim, como avaliar se o valor obtido é compatível com a variabilidade amostral prevista sob H_0? Nesta seção, desenvolveremos essas etapas, retomando a tabela sexo × animal preferido como exemplo.

2.1 Frequências Observadas e Frequências Esperadas

O ponto de partida da análise é distinguir os dados que efetivamente obtivemos do cenário de referência construído sob H_0. Chamamos de *frequências observadas* as contagens registradas na amostra e de *frequências esperadas* os valores calculados segundo a hipótese nula. Em uma tabela de contingência, representaremos essas quantidades por O_{ij} e E_{ij}, respectivamente, sendo i o índice da linha e j o índice da coluna.

Na tabela da Seção 1.1, por exemplo, a frequência observada na célula Masculino/-Cachorro é $O_{11} = 42$. Esse número informa quantos participantes da amostra pertencem simultaneamente às duas categorias. A frequência esperada nessa mesma célula responde a outra pergunta: quantas observações atribuiríamos a essa combinação no cenário em que sexo e preferência fossem independentes?

A maneira de construir esse cenário depende da hipótese investigada. Nos testes de independência e homogeneidade, estimamos as probabilidades comuns a partir das margens da tabela. No teste de aderência com probabilidades previamente especificadas, usamos diretamente a distribuição de referência declarada em H_0.

2.1.1 Frequências Esperadas nos Testes de Independência e Homogeneidade

Retomemos o teste de independência. Na amostra de 100 pessoas, 51 preferem cachorro, de modo que a proporção geral dessa preferência é $51/100 = 0{,}51$. Sob H_0, a probabilidade de preferir cachorro é a mesma nos dois grupos. Usamos, então, a proporção geral da amostra como estimativa dessa probabilidade comum e a aplicamos ao tamanho de cada grupo.

Pergunta 3

Na tabela sexo × animal preferido, há 52 pessoas no grupo Masculino e 51 pessoas que preferem cachorro, em uma amostra de 100 pessoas.
Se usarmos a proporção geral de preferência por cachorro como referência comum aos grupos, quantas das 52 pessoas do grupo Masculino esperaríamos encontrar nessa categoria? Explique seu raciocínio antes de consultar a fórmula a seguir.

Aplicando a proporção 0,51 às 52 pessoas do grupo Masculino, obtemos $52 \times 0{,}51 = 26{,}52$. Esse raciocínio se generaliza para qualquer célula: multiplicamos o total da linha pela proporção correspondente à coluna. Assim, a frequência esperada na célula (i, j) é:

$$E_{ij} = (\text{total da linha } i) \times \frac{(\text{total da coluna } j)}{N} = \frac{(\text{total da linha } i) \times (\text{total da coluna } j)}{N}.$$

A fórmula expressa a hipótese de independência por meio das proporções marginais observadas. Sob essa hipótese, a probabilidade conjunta de pertencer à linha i e à coluna j é o produto das respectivas probabilidades marginais. Como essas probabilidades populacionais são desconhecidas, nós as estimamos pelas proporções da amostra e multiplicamos o resultado por N para obter a contagem esperada.

Para a tabela da Seção 1.1, os cálculos são:

$$E_{11} = \frac{52 \times 51}{100} = 26{,}52, \qquad E_{12} = \frac{52 \times 49}{100} = 25{,}48,$$
$$E_{21} = \frac{48 \times 51}{100} = 24{,}48, \qquad E_{22} = \frac{48 \times 49}{100} = 23{,}52.$$

Podemos organizar esses resultados na mesma disposição da tabela observada:

	Cachorro	**Gato**	**Total**
Masculino	26,52	25,48	52
Feminino	24,48	23,52	48
Total	51	49	100

Observe que a tabela esperada preserva os totais marginais da tabela observada. O que muda é a distribuição das contagens pelas células: em cada linha, 51% do total corresponde à preferência por cachorro e 49% à preferência por gato. Desse modo, a tabela esperada representa um cenário sem associação, construído a partir das estimativas marginais fornecidas pela amostra.

As frequências esperadas podem ser fracionárias, embora as contagens observadas sejam inteiras. Isso ocorre porque uma frequência esperada não representa um número de

pessoas efetivamente contado, mas um valor de referência obtido a partir de probabilidades. Não devemos arredondar esses valores para inteiros antes de calcular a estatística, pois isso alteraria desnecessariamente a comparação.

No teste de homogeneidade, usamos a mesma fórmula, mas sua interpretação acompanha o desenho da pesquisa. Se as linhas representam filiais e as colunas representam formas de pagamento, a proporção total de utilização de cada forma de pagamento estima a probabilidade comum às filiais sob H_0. Multiplicando essa proporção pelo tamanho da amostra de cada filial, obtemos a frequência esperada em cada célula.

2.1.2 Frequências Esperadas no Teste de Aderência

No teste de aderência com probabilidades previamente especificadas, não precisamos estimar a distribuição de referência pelas margens de uma tabela. As probabilidades de cada categoria já fazem parte de H_0. Para obter a frequência esperada, basta multiplicar o tamanho da amostra pela probabilidade atribuída à categoria:

$$E_i = Np_{i0},$$

onde p_{i0} é a probabilidade da categoria i segundo a hipótese nula. Como há apenas uma variável categórica, usamos um único índice para identificar as categorias.

Considere novamente a preferência por quatro cores de carros. Se H_0 afirma que a distribuição é uniforme, cada cor tem probabilidade 0,25. Em uma amostra de 300 compradores, a frequência esperada de cada cor será:

$$E_i = 300 \times 0{,}25 = 75.$$

Se a distribuição de referência atribuir probabilidades diferentes às categorias, as frequências esperadas também serão diferentes. O princípio permanece o mesmo: traduzir as probabilidades propostas por H_0 em contagens de referência para uma amostra de tamanho N. Uma vez calculadas essas contagens, podemos compará-las com as observadas.

2.2 A Estatística χ^2: Resumindo as Discrepâncias

A comparação entre observado e esperado produz um desvio em cada célula ou categoria. Alguns desvios são positivos, indicando mais observações do que o esperado; outros são negativos, indicando menos observações. Para avaliar a tabela como um todo, precisamos combinar essas diferenças em uma única medida.

Somar diretamente os desvios $O_{ij} - E_{ij}$ não resolve o problema: como as frequências observadas e esperadas têm o mesmo total, os desvios positivos e negativos se cancelam. Além disso, uma diferença de determinada magnitude não tem o mesmo significado em todas as escalas. Um desvio de 10 observações é proporcionalmente muito maior diante de uma frequência esperada de 5 do que diante de uma frequência esperada de 500.

A estatística qui-quadrado de Pearson combina essas duas ideias. Ela eleva cada desvio ao quadrado, evitando o cancelamento entre sinais, e divide o resultado pela frequência esperada, levando em conta a escala de referência da célula. Em seguida, soma as contribuições:

$$\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Cada termo da soma é não negativo. Se todas as frequências observadas coincidirem com as esperadas, a estatística será zero. Quanto maiores forem os desvios em relação às respectivas frequências esperadas, maior será o valor da estatística. Para o mesmo desvio absoluto de 10 observações, por exemplo, a contribuição será $10^2/5 = 20$ quando $E = 5$, mas apenas $10^2/500 = 0{,}2$ quando $E = 500$.

No teste de aderência, a construção é a mesma, mas a soma percorre as m categorias de uma única variável:

$$\chi^2 = \sum_{i=1}^{m} \frac{(O_i - E_i)^2}{E_i}.$$

Para a tabela sexo × animal preferido, usamos as quatro frequências esperadas calculadas anteriormente:

$$\begin{aligned}\chi^2 &= \frac{(42 - 26{,}52)^2}{26{,}52} + \frac{(10 - 25{,}48)^2}{25{,}48} \\ &\quad + \frac{(9 - 24{,}48)^2}{24{,}48} + \frac{(39 - 23{,}52)^2}{23{,}52} \\ &\approx 38{,}42.\end{aligned}$$

Esse valor resume a discrepância entre a tabela observada e o cenário de independência. Entretanto, ele ainda não determina a decisão do teste. Para avaliar se 38,42 é um valor incomum sob H_0, precisamos conhecer a distribuição de referência da estatística. Antes disso, identificaremos uma característica que determina qual distribuição usar: os graus de liberdade.

Pergunta 4

A estatística qui-quadrado soma termos da forma:

$$\frac{(O - E)^2}{E}.$$

(a) Por que a soma simples dos desvios $O - E$ não seria uma medida adequada da discrepância global?
(b) Duas células apresentam o mesmo desvio absoluto, mas frequências esperadas diferentes. Elas necessariamente contribuem com o mesmo valor para χ^2? Explique.
(c) Uma estatística χ^2 igual a zero significa que a hipótese nula foi provada verdadeira? Justifique.

2.3 Graus de Liberdade

As contagens de uma tabela não podem variar de forma completamente livre quando precisam respeitar determinados totais. Os *graus de liberdade* expressam o número de variações independentes que permanecem após considerar essas restrições. Esse número é importante porque a distribuição de referência da estatística qui-quadrado depende dele.

Para visualizar a ideia, considere uma tabela 2×2 com os totais marginais da pesquisa sobre animal preferido. Se escolhermos a contagem da célula Masculino/Cachorro, as demais serão determinadas pelos totais. Chamando essa contagem de a, a célula Masculino/Gato deverá conter $52 - a$ observações, pois a primeira linha soma 52. A célula Feminino/Cachorro deverá conter $51 - a$, pois a primeira coluna soma 51. Por fim, a

última célula será determinada pelo total da segunda linha. Assim, respeitados os valores possíveis das contagens, há apenas uma escolha livre.

Em uma tabela com r linhas e c colunas, essa ideia se generaliza para:

$$k = (r-1)(c-1).$$

Essa é a fórmula dos graus de liberdade para os testes de independência e homogeneidade. Para a tabela 2×2 do exemplo:

$$k = (2-1)(2-1) = 1.$$

No teste de aderência com m categorias e probabilidades previamente especificadas, a restrição básica é o total amostral N. Conhecidas as contagens de $m-1$ categorias, a última fica determinada pela diferença entre N e a soma das anteriores. Por isso:

$$k = m - 1.$$

No exemplo das quatro cores, temos $k = 4 - 1 = 3$ graus de liberdade.

Essas fórmulas mostram por que o número de células ou categorias não corresponde diretamente ao número de graus de liberdade: é preciso considerar as restrições envolvidas. No teste de aderência, se parâmetros da distribuição de referência forem estimados a partir da própria amostra, também será necessário considerar esse ajuste. A discussão desse caso e a contagem geral das restrições em tabelas de contingência estão no Apêndice A.

2.4 A Distribuição Qui-Quadrado: uma Referência para a Estatística

Se repetíssemos a coleta de dados sob H_0, obteríamos novas frequências observadas e, consequentemente, novos valores da estatística χ^2. Mesmo sem associação ou sem afastamento da distribuição de referência, a estatística geralmente não seria zero, pois as contagens estão sujeitas à variabilidade amostral. Precisamos, portanto, de uma distribuição que descreva os valores que essa estatística pode assumir sob a hipótese nula.

Sob H_0 e quando as condições da aproximação são adequadas, a distribuição amostral da estatística de Pearson é aproximadamente uma *distribuição qui-quadrado* com os graus de liberdade correspondentes ao problema. Representamos essa distribuição por χ^2_k, sendo k o número de graus de liberdade. A justificativa probabilística dessa aproximação está no Apêndice A; aqui, usaremos suas propriedades para interpretar o resultado do teste.

É importante distinguir os dois usos da notação. A *estatística* χ^2 é a quantidade calculada a partir das frequências observadas e esperadas. A *distribuição* χ^2_k é a referência probabilística usada para avaliar esse resultado sob H_0. No exemplo sexo $\times$ animal preferido, calculamos uma estatística de aproximadamente 38,42 e a comparamos com a distribuição χ^2_1, pois a tabela tem um grau de liberdade.

A distribuição qui-quadrado assume apenas valores não negativos, assim como a estatística de Pearson. Sua forma depende de k: para poucos graus de liberdade, apresenta forte assimetria à direita; à medida que k aumenta, torna-se menos assimétrica e se desloca para valores maiores. Por isso, não podemos interpretar um valor da estatística sem considerar seus graus de liberdade: o que é incomum em uma distribuição pode ser relativamente frequente em outra.

A Figura 1 apresenta algumas dessas distribuições. O eixo vertical representa densidade, e as probabilidades correspondem a áreas sob cada curva. Para o teste, estaremos interessados na área associada a valores da estatística pelo menos tão grandes quanto o observado.

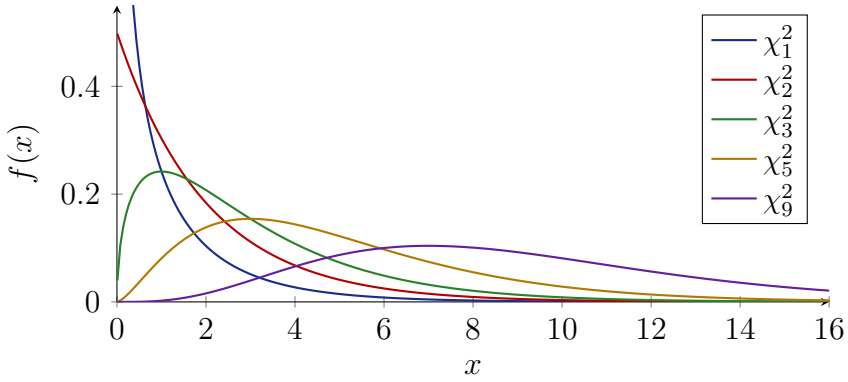


Figura 1: Densidades da distribuição χ^2 para diferentes graus de liberdade. Para $k = 1$ e $k = 2$, as curvas são decrescentes; para $k > 2$, o pico ocorre em $k - 2$. A distribuição com um grau de liberdade cresce sem limite quando x se aproxima de zero pela direita, de modo que parte dessa curva fica fora da escala vertical apresentada.

2.5 Cálculo e Interpretação do p-valor

Agora dispomos dos elementos necessários para avaliar o resultado: a estatística observada resume a discrepância dos dados em relação a H_0, e a distribuição χ^2_k fornece uma referência para a variabilidade dessa estatística sob a hipótese nula. O p-valor conecta essas duas informações.

No teste qui-quadrado de Pearson, tanto excessos quanto faltas de observações em relação ao esperado podem aumentar a estatística, pois os desvios são elevados ao quadrado. Assim, a evidência contra H_0 se concentra em valores grandes de χ^2. O p-valor é a probabilidade, sob H_0, de obter uma estatística tão grande quanto a observada ou maior:

$$p\text{-valor} = \Pr\big(X \geq \chi^2_{\text{obs}}\big), \qquad X \sim \chi^2_k.$$

Como usamos a aproximação qui-quadrado para a distribuição da estatística, esse também é um cálculo aproximado do p-valor do teste. Geometricamente, ele corresponde à área à direita de χ^2_{obs} sob a curva de referência. Quanto menor essa área, menos frequentes seriam discrepâncias pelo menos tão grandes quanto a observada no cenário descrito por H_0.

Dizemos, por isso, que a região de rejeição do teste de Pearson fica na cauda direita. Isso não significa que o teste procure apenas aumentos nas frequências: desvios positivos e negativos são considerados. A cauda direita é usada porque ambos os tipos de desvio aumentam a medida global de discrepância.

A Figura 2 ilustra esse cálculo para uma distribuição com três graus de liberdade. O valor assinalado é apenas ilustrativo e não corresponde à tabela sexo × animal preferido, que tem um grau de liberdade.

Para tomar a decisão, comparamos o p-valor com o nível de significância α, definido previamente. Se $p \leq \alpha$, rejeitamos H_0: a discrepância observada é suficientemente grande, segundo esse critério, para fornecer evidência contra a hipótese nula. A interpretação depende da modalidade do teste: evidência de afastamento da distribuição de referência, de associação entre variáveis ou de diferenças entre distribuições populacionais.

No exemplo sexo × animal preferido, a estatística $\chi^2_{\text{obs}} \approx 38{,}42$, comparada com uma distribuição de um grau de liberdade, produz um p-valor menor que 0,001. Assim, ao nível $\alpha = 0{,}05$, rejeitamos a hipótese de independência e concluímos que os dados

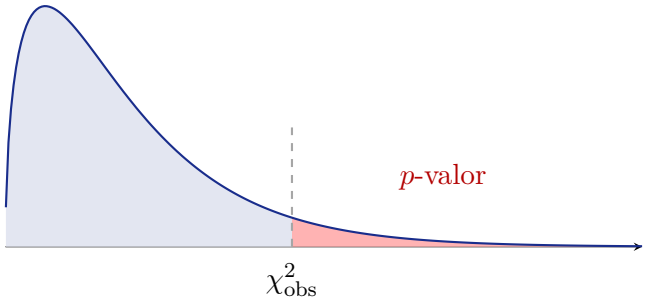


Figura 2: Ilustração do p-valor na distribuição χ^2_3. A região vermelha representa a área à direita da estatística observada; a cauda continua além do limite horizontal exibido.

fornecem evidência de associação entre as variáveis na população, desde que as condições de aplicação do teste estejam satisfeitas.

Se $p > \alpha$, não rejeitamos H_0. Nesse caso, os dados não fornecem evidência suficiente contra a hipótese nula no nível de significância adotado. Isso não demonstra que H_0 seja verdadeira: uma amostra pode não oferecer informação suficiente para distinguir a hipótese nula de outras possibilidades. Por essa razão, devemos evitar afirmações como "aceitamos H_0" ou "provamos que as variáveis são independentes".

Por fim, o p-valor não é a probabilidade de H_0 ser verdadeira nem uma medida da força da associação. Ele avalia a compatibilidade dos dados com o cenário nulo por meio da estatística escolhida. Nas próximas seções, discutiremos as condições necessárias para essa avaliação e as medidas que complementam o teste na interpretação da magnitude da associação.

3 Tamanho do Efeito: Coeficiente Phi e V de Cramér

O teste qui-quadrado permite avaliar se os dados fornecem evidência contra a hipótese de independência ou de homogeneidade. Entretanto, rejeitar H_0 não informa, por si só, a intensidade da associação encontrada. Duas pesquisas podem apresentar resultados estatisticamente significativos e, ainda assim, revelar associações de magnitudes muito diferentes. Para interpretar os resultados, precisamos distinguir duas perguntas: *há evidência de associação?* e *qual é a magnitude dessa associação?*

Essa distinção é importante porque a estatística χ^2 depende do tamanho amostral. Se multiplicarmos todas as contagens de uma tabela por dois, preservando suas proporções, as frequências esperadas também dobrarão e a estatística χ^2 será multiplicada por dois. Os graus de liberdade permanecerão iguais e o p-valor diminuirá, embora o padrão proporcional da tabela não tenha mudado. Assim, amostras grandes podem fornecer evidência estatística de associações pequenas, cuja relevância prática precisa ser examinada separadamente.

As medidas de *tamanho do efeito* complementam o teste ao quantificar a magnitude da associação. Nesta seção, apresentaremos o coeficiente phi para tabelas 2×2 e o V de Cramér para tabelas de contingência em geral. Essas medidas se aplicam à associação entre as dimensões da tabela; não devem ser usadas automaticamente como medidas de efeito para qualquer teste de aderência.

Pergunta 5

Suponha que dois estudos tenham encontrado associação estatisticamente significativa entre duas variáveis categóricas. No Estudo A, a amostra tem $N = 80$ e o p-valor é próximo de 0,04. No Estudo B, a amostra tem $N = 8000$ e o p-valor é menor que 0,001.
Podemos concluir que a associação no Estudo B é mais forte? Explique por que precisamos de outras informações para responder a essa pergunta.

3.1 Coeficiente Phi: Magnitude da Associação em Tabelas 2×2

Para uma tabela 2×2, uma maneira de reduzir a dependência da medida em relação ao tamanho amostral é dividir a estatística de Pearson por N. Se todas as contagens forem multiplicadas pelo mesmo fator, tanto χ^2 quanto N crescerão nessa proporção, preservando a razão χ^2/N. A raiz quadrada dessa razão fornece a medida que utilizaremos:

$$\phi = \sqrt{\frac{\chi^2}{N}}.$$

Nessa definição, χ^2 é a estatística de Pearson calculada *sem correção de continuidade de Yates*, e N é a soma das contagens da tabela. Essa escolha deve ser mantida mesmo quando o p-valor da análise for obtido por outro procedimento, como o teste exato de Fisher: a medida de associação e o procedimento de teste cumprem funções diferentes.

Para visualizar o cálculo, retomemos a tabela sexo × animal preferido. Com $\chi^2 \approx 38{,}42$ e $N = 100$, obtemos:

$$\phi = \sqrt{\frac{38{,}42}{100}} \approx 0{,}620.$$

Se duplicássemos todas as contagens, teríamos $\chi^2 \approx 76{,}84$ e $N = 200$, de modo que:

$$\phi = \sqrt{\frac{76{,}84}{200}} \approx 0{,}620.$$

O p-valor seria menor, mas a magnitude da associação medida por phi permaneceria igual, pois as proporções da tabela seriam as mesmas.

Aqui usamos ϕ como uma medida não negativa, com valores entre 0 e 1. O valor zero corresponde à ausência de associação na tabela, enquanto valores maiores indicam maior associação segundo essa medida. O valor 1 representa associação perfeita em uma tabela 2×2: conhecer a categoria de uma variável permite determinar a categoria da outra. Um valor calculado na amostra, entretanto, é uma estimativa e está sujeito à variabilidade amostral; não descreve com certeza a associação populacional.

Há também uma definição de phi como a correlação de Pearson entre duas variáveis binárias codificadas como 0 e 1. Nessa definição, o coeficiente pode ser positivo ou negativo, e trocar a codificação de uma das variáveis inverte seu sinal. A expressão $\sqrt{\chi^2/N}$ corresponde ao valor absoluto dessa correlação. Portanto, ela resume a magnitude da associação; para compreender quais categorias aparecem juntas com maior frequência, precisamos examinar as proporções e os desvios da tabela.

3.2 V de Cramér: Extensão para Outras Dimensões de Tabela

O coeficiente phi é apresentado principalmente para tabelas 2×2. Quando ambas as variáveis possuem mais de duas categorias, a razão χ^2/N pode ultrapassar 1, de modo que sua raiz deixa de fornecer uma medida limitada ao intervalo de 0 a 1. Para levar em conta a dimensão da tabela, usamos o *V de Cramér*:

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}},$$

onde r é o número de linhas, c é o número de colunas e $\min(r-1, c-1)$ indica o menor dos dois valores.

Assim como no cálculo de phi, usamos a estatística de Pearson sem correção de continuidade. O fator adicional no denominador normaliza a medida pela dimensão da tabela, mantendo V entre 0 e 1. Essa escala comum facilita sua apresentação, mas não elimina a necessidade de considerar as categorias, as proporções marginais e o contexto ao comparar resultados de tabelas diferentes.

Em uma tabela 2×2, temos $\min(r-1, c-1) = 1$. Nesse caso:

$$V = \sqrt{\frac{\chi^2}{N}} = \phi.$$

Portanto, podemos usar o V de Cramér também em tabelas 2×2: ele coincide com a versão não negativa de phi adotada nestas notas.

A igualdade numérica não se limita às tabelas 2×2. Em uma tabela 3×2, por exemplo, o fator de normalização também é 1. Por convenção, porém, usaremos o nome V de Cramér para apresentar a medida em tabelas de dimensões gerais. Essa distinção evita a impressão de que a expressão $\sqrt{\chi^2/N}$ necessariamente ultrapassa 1 em qualquer tabela maior que 2×2.

Pergunta 6

Considere as seguintes tabelas:

(a) Uma tabela 2×2 relacionando gênero e preferência por aula presencial ou remota.

(b) Uma tabela 3×2 relacionando faixa etária e preferência por aula presencial ou remota.

(c) Uma tabela 4×5 relacionando curso e principal dificuldade percebida na disciplina.

Para cada tabela, calcule o fator $\min(r-1, c-1)$ e escreva a expressão correspondente para o V de Cramér. Em quais casos ela coincide com $\sqrt{\chi^2/N}$? Por que isso não torna todas essas tabelas equivalentes do ponto de vista da interpretação?

3.3 Interpretação: da Medida Numérica ao Contexto

Após calcular phi ou V de Cramér, precisamos interpretar o resultado em relação à pergunta de pesquisa. Um valor maior representa maior associação segundo a medida, mas

não existe uma classificação universal capaz de determinar, apenas pelo número, se a associação é importante. Sua relevância depende do fenômeno estudado e das consequências práticas das diferenças entre os grupos.

Como referência inicial para phi em tabelas 2×2, são frequentemente utilizados os valores 0,10, 0,30 e 0,50, associados às convenções de efeito pequeno, moderado e grande. A tabela abaixo organiza essas referências em faixas. Elas funcionam como orientações descritivas, e não como limites que separam fenômenos qualitativamente distintos.

Valor de ϕ em tabelas 2×2	**Referência descritiva**
$0 \leq \phi < 0{,}10$	Abaixo da referência de efeito pequeno
$0{,}10 \leq \phi < 0{,}30$	Pequeno
$0{,}30 \leq \phi < 0{,}50$	Moderado
$0{,}50 \leq \phi \leq 1$	Grande

Essas referências também podem orientar a leitura do V quando $\min(r-1, c-1) = 1$, mas não devem ser transferidas automaticamente para tabelas de qualquer dimensão. Como a normalização de V depende do formato da tabela, a interpretação deve explicitar esse formato e recorrer, sempre que possível, a referências substantivas da área. Além disso, estar abaixo de 0,10 não demonstra ausência de associação nem garante irrelevância prática.

A Figura 3 representa as faixas de referência para phi em tabelas 2×2. A representação ajuda a localizar um resultado na escala, mas não deve sugerir mudanças abruptas de interpretação nas fronteiras: valores como 0,29 e 0,30 são muito próximos, apesar de pertencerem a faixas diferentes.



Figura 3: Faixas convencionais de referência para phi em tabelas 2×2. Os limites são orientações descritivas; não substituem a interpretação contextual nem devem ser aplicados automaticamente ao V de Cramér em qualquer dimensão de tabela.

No exemplo sexo × animal preferido, encontramos $\phi \approx 0{,}620$, que corresponde a uma associação grande segundo essas referências. Para dar significado a esse resultado, devemos relacioná-lo às proporções observadas: aproximadamente 81% do grupo Masculino e 19% do grupo Feminino preferem cachorro. A medida resume a magnitude da associação, enquanto as proporções mostram como ela se manifesta.

Também devemos evitar interpretar $V = 0{,}620$ como "62% de associação" ou "62% da preferência explicada pelo sexo". O V de Cramér é um índice de associação, não uma porcentagem de observações explicadas nem uma medida de efeito causal. Um relato adequado combina o resultado do teste, o valor da medida e uma descrição das diferenças relevantes no contexto.

3.4 Implementação em Python

Para calcular a medida em Python, precisamos obter a estatística de Pearson, somar as contagens da tabela e identificar suas dimensões. A função auxiliar abaixo reúne essas

operações e retorna o V de Cramér, que coincide com phi quando a tabela é 2×2. A entrada deve conter contagens de categorias válidas, com pelo menos duas linhas e duas colunas e sem margens de total zero.

O argumento `correction=False` aparece explicitamente na chamada a `chi2_contingency`, pois as definições de phi e V utilizadas nesta seção se baseiam na estatística sem correção de Yates. Para evitar misturar o cálculo da medida com outras escolhas de teste, a função mantém essa opção fixa. O p-valor retornado corresponde, portanto, ao teste de Pearson sem correção; se as condições dessa aproximação não forem adequadas, o procedimento para obter o p-valor deve ser escolhido separadamente.

```
import numpy as np
from scipy.stats import chi2_contingency

def phi_cramer(tabela):
    """Calcula V de Cramer; em tabelas 2x2, coincide com phi."""
    tabela = np.asarray(tabela, dtype=float)

    chi2, p, dof, expected = chi2_contingency(
        tabela, correction=False
    )

    n = tabela.sum()
    r, c = tabela.shape
    v = np.sqrt(chi2 / (n * min(r - 1, c - 1)))

    return chi2, p, v

tabela = np.array([[42, 10],
                   [9, 39]])

chi2_stat, p_val, v = phi_cramer(tabela)

print(f"chi2 = {chi2_stat:.2f}, p = {p_val:.4e}")
print(f"V de Cramer (= phi para 2x2) = {v:.3f}")
# V de Cramer (= phi para 2x2) = 0.620
```

A saída deve ser interpretada em conjunto com a tabela original e com a verificação das condições de aplicação. O p-valor informa a evidência contra a hipótese nula no procedimento adotado; o valor $V \approx 0{,}620$ resume a magnitude da associação amostral; e as proporções por grupo mostram a direção do padrão observado. Essas informações se complementam e, reunidas, permitem uma conclusão mais informativa do que a simples indicação de que o resultado foi estatisticamente significativo.

4 Leitura Descritiva dos Resíduos

O teste qui-quadrado e as medidas de tamanho do efeito respondem a perguntas complementares: o primeiro avalia a evidência contra a hipótese nula, enquanto as segundas resumem a magnitude da associação. Nenhum desses resultados, porém, descreve sozinho como a associação se manifesta nas categorias da tabela. Se o teste de independência rejeita H_0, sabemos que os dados fornecem evidência de associação, mas ainda precisamos

examinar quais combinações de categorias apresentam mais ou menos observações do que o esperado sob independência.

Essa investigação começa pela comparação que usamos para construir a estatística χ^2: a diferença entre a frequência observada e a frequência esperada em cada célula. Chamamos essa diferença de *resíduo bruto*:

$$d_{ij} = O_{ij} - E_{ij}.$$

Enquanto a estatística qui-quadrado eleva os desvios ao quadrado e os combina em uma medida global, o resíduo bruto preserva o sinal da diferença. Isso permite identificar a direção do desvio em cada combinação de categorias.

Um resíduo positivo indica que a contagem observada é maior que a esperada sob independência. Dizemos, nesse caso, que a combinação está *sobre-representada* em relação a esse cenário de referência. Um resíduo negativo indica uma contagem menor que a esperada, caracterizando *sub-representação*. Se o resíduo for zero, a contagem observada coincide com a esperada naquela célula. Essas expressões sempre dependem da comparação com E_{ij}: uma contagem elevada em termos absolutos não significa, necessariamente, sobre-representação.

4.1 Identificando o Padrão na Tabela

Retomemos a tabela sexo × animal preferido. Na célula Masculino/Cachorro, observamos 42 participantes, enquanto a frequência esperada sob independência é 26,52. O resíduo bruto é:

$$d_{11} = 42 - 26{,}52 = +15{,}48.$$

Portanto, essa combinação apresenta 15,48 observações a mais que o valor de referência calculado sob H_0. Na célula Masculino/Gato, ocorre o contrário:

$$d_{12} = 10 - 25{,}48 = -15{,}48.$$

Há menos participantes nessa combinação do que esperaríamos no cenário de independência.

Calculando os resíduos das quatro células, obtemos:

	Cachorro	**Gato**
Masculino	+15,48	−15,48
Feminino	−15,48	+15,48

Os sinais revelam um padrão: Masculino/Cachorro e Feminino/Gato estão sobre-representados, enquanto Masculino/Gato e Feminino/Cachorro estão sub-representados. Esse resultado é coerente com as proporções calculadas anteriormente: aproximadamente 81% do grupo Masculino e 19% do grupo Feminino preferem cachorro. As proporções descrevem a distribuição das respostas dentro dos grupos; os resíduos mostram como as contagens se afastam do cenário de independência.

Os desvios das células não são independentes entre si. Como a tabela esperada preserva os totais marginais observados, os resíduos brutos somam zero em cada linha e em cada coluna. Na primeira linha, por exemplo, o excesso de 15,48 na categoria Cachorro é

compensado pela falta de 15,48 na categoria Gato. Em uma tabela 2×2, essa restrição faz com que os quatro resíduos brutos tenham o mesmo valor absoluto, com sinais alternados. Por isso, não devemos interpretar as quatro células como quatro evidências independentes de associação.

4.2 O que Essa Leitura Permite Concluir

A leitura dos resíduos ajuda a transformar uma conclusão global em uma descrição do padrão amostral. Em vez de relatar apenas que "há evidência de associação entre sexo e animal preferido", podemos acrescentar que, na amostra, a preferência por cachorro é proporcionalmente mais frequente no grupo Masculino e a preferência por gato é proporcionalmente mais frequente no grupo Feminino. Essa descrição torna o resultado mais informativo, sem atribuir uma relação causal entre as variáveis.

Entretanto, o sinal de um resíduo não informa se aquela célula apresenta um desvio estatisticamente significativo. Mesmo sob independência, as contagens amostrais podem ficar acima ou abaixo dos valores esperados. Além disso, rejeitar a hipótese nula no teste global não significa que todas as células se afastem individualmente do cenário de referência. O teste considera a discrepância conjunta da tabela, e não uma decisão separada para cada combinação de categorias.

Também precisamos de cuidado ao comparar as magnitudes dos resíduos brutos. Uma diferença de 10 observações pode ter significados muito distintos quando a frequência esperada é 5 ou 500. Portanto, não devemos identificar automaticamente a célula com maior resíduo bruto em valor absoluto como a mais importante para a associação. A comparação entre células exige considerar suas escalas e a variabilidade dos desvios.

Quando o objetivo for aprofundar essa análise e realizar inferência por célula, utilizaremos os *resíduos padronizados ajustados*. Seu cálculo leva em conta as frequências esperadas e as proporções marginais. A interpretação inferencial também precisa considerar que examinar várias células envolve comparações múltiplas. A padronização, sua implementação e os procedimentos de ajuste são apresentados no Apêndice D.

No conteúdo principal, a leitura descritiva deve reunir três elementos: as proporções por grupo, os sinais dos resíduos e a comparação entre contagens observadas e esperadas. Esses elementos permitem explicar onde e em que direção o padrão de associação aparece na amostra, preservando a distinção entre descrição dos dados e inferência estatística.

Pergunta 7

Um teste qui-quadrado de independência aplicado a uma tabela 4×3 rejeitou H_0.
(a) Por que esse resultado não permite concluir que todas as combinações de categorias apresentam desvios individualmente significativos?
(b) Uma célula apresenta resíduo bruto positivo. O que podemos afirmar sobre sua contagem observada em relação à esperada? O sinal, por si só, permite afirmar que o desvio é significativo?
(c) Duas células apresentam resíduos brutos iguais a $+10$, mas suas frequências esperadas são 5 e 500. Por que não devemos interpretar esses desvios como igualmente expressivos?

5 Exemplos Resolvidos

Nos exemplos a seguir, adotamos $\alpha = 0{,}05$.

Um relatório completo deve conter: o tipo de teste aplicado; a estatística χ^2; os graus de liberdade; o p-valor; uma medida de tamanho do efeito; e uma interpretação substantiva no contexto do problema.

Por exemplo, uma conclusão pode ser redigida da seguinte forma: "Foi observada associação entre gênero e preferência por tipo de filme, $\chi^2(1) = 11{,}67$, $p = 0{,}001$, $\phi = 0{,}289$, indicando associação de magnitude pequena a moderada".

5.1 Exemplo 1: Preferência por Cores de Carros

Um estudo sobre preferência de cores de carros registrou, em uma amostra de 300 compradores: Vermelho (90), Azul (80), Preto (60), Branco (70). Deseja-se verificar se a distribuição é uniforme.

(1) Hipóteses: $H_0 : P_i = 0{,}25$ para todo i vs. H_a: alguma proporção difere.

(2) Condições: $E_i = 300 \times 0{,}25 = 75 \geq 5$. Satisfeitas.

(3) Estatística: $k = 3$.

$$\chi^2 = \frac{(90-75)^2}{75} + \frac{(80-75)^2}{75} + \frac{(60-75)^2}{75} + \frac{(70-75)^2}{75} = 3{,}00 + 0{,}33 + 3{,}00 + 0{,}33 = 6{,}67$$

(4) Conclusão: $p \approx 0{,}083 > 0{,}05$. Não rejeitamos H_0. Os dados não fornecem evidência suficiente de que a distribuição de preferências se afasta da uniformidade.

```
from scipy.stats import chisquare

chi2_stat, p_val = chisquare(f_obs=[90, 80, 60, 70],
                             f_exp=[75, 75, 75, 75])
print(f"chi2 = {chi2_stat:.4f}, p = {p_val:.4f}")
```

5.2 Exemplo 2: Análise Completa de Independência

Pesquisa com 140 pessoas investigou se há associação entre gênero e preferência por tipo de filme.

	Ação	**Comédia**	**Total**
Masculino	40	30	70
Feminino	20	50	70
Total	60	80	140

(1) Hipóteses: H_0: gênero e preferência por filme são independentes. H_a: há associação.

(2) Frequências esperadas: $E_{11} = 30$, $E_{12} = 40$, $E_{21} = 30$, $E_{22} = 40$. Todas ≥ 5.

(3) Estatística: $k = 1$.

$$\chi^2 = \frac{(40-30)^2}{30} + \frac{(30-40)^2}{40} + \frac{(20-30)^2}{30} + \frac{(50-40)^2}{40} = 3{,}33 + 2{,}50 + 3{,}33 + 2{,}50 = 11{,}67$$

(4) Conclusão: $p \approx 0{,}001$. Rejeitamos H_0.

(5) Tamanho do efeito: $\phi = V = \sqrt{11{,}67/140} \approx 0{,}289$ (efeito pequeno-a-moderado).

(6) Frase de conclusão: "Foi observada associação entre gênero e preferência por tipo de filme, $\chi^2(1) = 11{,}67$, $p = 0{,}001$, $\phi = 0{,}289$, indicando associação de magnitude pequena a moderada".

```
import numpy as np
from scipy.stats import chi2_contingency

tabela = np.array([[40, 30],
                   [20, 50]])

# correction=False para reproduzir o calculo manual
chi2_stat, p_val, dof, expected = chi2_contingency(tabela,
                                                   correction=
                                                      False)
n = tabela.sum()
r, c = tabela.shape
v = np.sqrt(chi2_stat / (n * min(r-1, c-1)))
print(f"chi2={chi2_stat:.2f}, p={p_val:.4f}, V={v:.3f}")
```

5.3 Exemplo 3: Formas de Pagamento

Uma rede de supermercados quer saber se o padrão de preferência por forma de pagamento (Dinheiro, Cartão, PIX) é o mesmo em três filiais. As linhas representam formas de pagamento e as colunas representam as filiais; a orientação poderia ser transposta sem alterar o resultado do teste.

	Loja A	**Loja B**	**Loja C**
Dinheiro	30	25	20
Cartão	45	40	35
PIX	25	35	45

(1) Hipóteses: H_0: a distribuição de formas de pagamento é a mesma nas três lojas. H_a: pelo menos uma loja difere.

(2) Frequências esperadas: $N = 300$; totais de linha: 75, 120, 105; colunas: 100, 100, 100.

$$E_{ij} = \frac{\text{total}_i \times 100}{300} \quad \Rightarrow \quad E_{\text{Din}} = 25{,}0; \quad E_{\text{Cart}} = 40{,}0; \quad E_{\text{PIX}} = 35{,}0$$

Todas as células têm $E_{ij} \geq 5$. Condições satisfeitas.

(3) Estatística: $k = (3-1)(3-1) = 4$.

$$\begin{aligned}\chi^2 = &\frac{(30-25)^2}{25} + \frac{(25-25)^2}{25} + \\ &\frac{(20-25)^2}{25} + \frac{(45-40)^2}{40} + \\ &\frac{(40-40)^2}{40} + \frac{(35-40)^2}{40} + \\ &\frac{(25-35)^2}{35} + \frac{(35-35)^2}{35} + \frac{(45-35)^2}{35} \\ &\approx 8{,}96\end{aligned}$$

(4) Conclusão: $p \approx 0{,}062 > 0{,}05$. Não rejeitamos H_0. Os dados não fornecem evidência suficiente de que a distribuição de formas de pagamento difere entre as lojas, embora o resultado seja próximo do limiar de significância.

(5) Tamanho do efeito:

$$V = \sqrt{\frac{8{,}96}{300 \times 2}} \approx 0{,}122 \quad \text{(efeito pequeno)}$$

Mesmo que o resultado fosse significativo, a magnitude da associação seria pequena, reforçando a importância de reportar sempre o tamanho do efeito.

5.4 Resumo das Funções Python Utilizadas

Função	Propósito	Módulo
`pd.crosstab(v1, v2)`	Montar tabela de contingência	`pandas`
`chisquare(f_obs, f_exp)`	Teste de aderência	`scipy.stats`
`chi2_contingency(tab)`	Teste de independência / homogeneidade	`scipy.stats`
`fisher_exact(tab)`	Teste exato de Fisher	`scipy.stats`
`chi2.ppf(1-a, df=k)`	Valor crítico de χ^2_k	`scipy.stats`

6 Resumo

Os testes qui-quadrado são o principal instrumento para análise inferencial de variáveis categóricas.

- O teste de aderência verifica ajuste a uma distribuição especificada sob H_0;

- o teste de independência detecta associação entre duas variáveis em uma amostra;
- o teste de homogeneidade verifica se a mesma distribuição ocorre em grupos distintos.

A rejeição de H_0 deve ser sempre complementada com: (i) uma medida de tamanho do efeito (ϕ ou V de Cramér); (ii) interpretação do padrão observado nas proporções e nos desvios por célula; a análise inferencial de resíduos é um aprofundamento do Apêndice D. Para amostras pequenas, substituir o χ^2 padrão preferencialmente pelo *teste exato de Fisher*, ou pela *correção de Yates* como alternativa conservadora.

A tabela a seguir sintetiza os principais conceitos e procedimentos apresentados:

Aspecto	**Detalhe**
Tipo de dados	Variáveis categóricas, representadas por contagens de frequência
Testes disponíveis	Aderência, independência, homogeneidade
Estatística	$\chi^2 = \sum(O_{ij} - E_{ij})^2/E_{ij}$
Freq. esperada (independência)	$E_{ij} = (\text{total}_i \times \text{total}_j)/N$
Freq. esperada (aderência)	$E_i = N \times p_i$
Graus de liberdade (tab. $r \times c$)	$(r-1)(c-1)$, pois há $r + c - 1$ restrições independentes
Graus de liberdade (aderência, m categ.)	$m-1$ (sem parâmetros estimados); $m-1-q$ com q parâmetros estimados
Tipo de teste	Unicaudal à direita (teste qui-quadrado de Pearson)
Condições	Obs. independentes; $E_{ij} \geq 5$ (regra geral)
Variantes	Fisher (preferível) ou Yates (E_{ij} pequenos, 2×2)
Não-paramétrico	Não exige normalidade da população
Equivalência (2×2, sem Yates)	$\chi^2 = z^2$ (bilateral para duas proporções)
Tamanho do efeito	ϕ ou V de Cramér: negligível / pequeno / moderado / grande
Análise post-hoc	Leitura descritiva; inferência por célula no Apêndice D

7 Exercícios de Fixação

7.1 Exercício 1: Identificação do tipo de teste

Para cada situação abaixo, identifique o tipo de teste qui-quadrado e formule H_0 e H_a.

(a) Um dado é lançado 120 vezes. Deseja-se verificar se o dado é honesto ($p_i = 1/6$ para cada face).

(b) Uma pesquisa com 400 eleitores de quatro cidades registra o partido preferido de cada um. Deseja-se saber se a distribuição de preferências é a mesma nas quatro cidades.

(c) Em 500 pacientes, registram-se o sexo e se o tratamento prescrito foi seguido. O pesquisador quer saber se há associação entre as duas variáveis.

(d) Uma empresa afirma que 50% dos clientes são da faixa A, 30% da faixa B e 20% da faixa C. Uma amostra de 200 clientes apresentou 95, 65 e 40 nas respectivas faixas.

7.2 Exercício 2: Cálculo manual e verificação em Python

Um estudo investiga a associação entre gênero e preferência por tipo de filme (tabela do Exemplo 2, Seção 5.2).

(a) Calcule as quatro frequências esperadas E_{ij}.

(b) Calcule χ^2, os graus de liberdade e o p-valor manualmente.

(c) Calcule ϕ e classifique o tamanho do efeito.

(d) Compare as frequências observadas e esperadas e descreva as combinações sobre-representadas e sub-representadas.

(e) Verifique todos os resultados com as funções Python correspondentes (usando `correction=False`).

7.3 Exercício 3: Condições de aplicabilidade e variantes

Para cada situação abaixo, identifique qual variante do teste aplicar e justifique:

(a) Tabela 2×2 com $N = 40$ e frequências esperadas mínimas de 3,2.

(b) Tabela 2×2 com $N = 15$ e uma célula com $E_{ij} = 0{,}8$.

(c) Tabela 4×3 com todas as frequências esperadas maiores que 10.

(d) Tabela 2×2 com $N = 200$ e frequências esperadas mínimas de 22.

7.4 Exercício 4: Tamanho do efeito e interpretação

Um pesquisador aplica o teste qui-quadrado em três estudos distintos:

Estudo	**Tabela**	N	χ^2	p-valor
A	2×2	50	5,20	0,023
B	2×2	500	5,20	0,023
C	2×2	50	18,80	$< 0{,}001$

(a) Calcule ϕ para os três estudos.

(b) Os estudos A e B têm o mesmo χ^2 e o mesmo p-valor, mas N diferente. Mantido o mesmo χ^2, o que acontece com ϕ quando N aumenta? O que isso revela sobre a diferença entre p-valor e tamanho do efeito?

(c) Os estudos A e B têm a mesma associação? Explique à luz dos valores de ϕ calculados no item anterior.

(d) Classifique o tamanho do efeito de cada estudo.

(e) Um colega afirma: "O estudo C tem associação maior porque o p-valor é menor". Essa afirmação está correta? Justifique.

7.5 Exercício 5: Hábitos de tabagismo e exercício físico

O conjunto `survey.csv` contém dados sobre hábito de fumar (`Smoke`: Never, Occasionally, Regularly, Heavy) e nível de exercício físico (`Exer`: Freq, None, Some) de estudantes.

(a) Construa a tabela de contingência com `pd.crosstab`.

(b) Verifique as condições de aplicabilidade inspecionando as frequências esperadas.

(c) Aplique o teste de independência ao nível $\alpha = 0{,}05$ e conclua.

(d) Calcule o V de Cramér e classifique o tamanho do efeito.

(e) Se H_0 for rejeitada, compare proporções e frequências observadas e esperadas para descrever o padrão de associação. A análise inferencial por célula é complementar (Apêndice D).

A Fundamentos probabilísticos e graus de liberdade

Este apêndice aprofunda a justificativa dos procedimentos do conteúdo principal.

A.1 Construção e propriedades da distribuição

A distribuição qui-quadrado com k graus de liberdade é a distribuição da soma dos quadrados de k variáveis normais padrão independentes:

$$X = \sum_{i=1}^{k} Z_i^2, \quad Z_i \sim N(0,1) \implies X \sim \chi^2_k$$

A variável χ^2_k assume apenas valores não-negativos. A distribuição é assimétrica à direita, e sua forma varia substancialmente com k. Quando k é grande, a distribuição χ^2_k torna-se menos assimétrica e pode ser aproximada por uma normal com média k e variância $2k$:

$$\frac{X - k}{\sqrt{2k}} \approx N(0,1) \quad \text{para } k \text{ grande.}$$

A.2 Contagem das restrições e parâmetros estimados

A fórmula $k = m - 1$ vale quando as probabilidades p_i sob H_0 são especificadas *antes* de olhar os dados, isto é, não são estimadas a partir da própria amostra. Se algum parâmetro da distribuição esperada for estimado usando a amostra (por exemplo, estimar a média de uma distribuição de Poisson a partir dos dados e então testar aderência a essa Poisson), os graus de liberdade devem ser reduzidos pelo número de parâmetros estimados:

$$k = m - 1 - q,$$

onde q é o número de parâmetros estimados a partir dos dados. Esse ajuste é importante para evitar que a regra $m - 1$ seja aplicada de forma absoluta.

A origem da expressão $(r-1)(c-1)$ está nas restrições impostas pelos totais marginais. A demonstração correta é a seguinte:

Fixados os totais marginais de uma tabela $r \times c$, nem todas as rc células podem variar livremente.

- Os r totais de linha e os c totais de coluna impõem, juntos, $r + c$ restrições sobre as células.
- Entretanto, uma dessas restrições é redundante: a soma dos totais de linha é sempre igual à soma dos totais de coluna (ambas iguais a N). Portanto, há apenas $r+c-1$ restrições independentes.
- O número de células efetivamente livres é então:

$$rc - (r + c - 1) = rc - r - c + 1 = (r - 1)(c - 1).$$

Equivalentemente: preenchidos os valores das primeiras $(r - 1)$ linhas e das primeiras $(c - 1)$ colunas, todos os demais ficam determinados pelos totais marginais. Logo, só há $(r - 1)(c - 1)$ valores de escolha livre.

A justificativa análoga para o teste de aderência é simples: com m categorias e total N fixo, basta especificar $m - 1$ frequências; a última fica determinada. Assim, $k = m - 1$ (quando nenhum parâmetro adicional é estimado).

A.3 Por que surge a distribuição qui-quadrado?

Sob H_0, as contagens apresentam flutuações amostrais. Em amostras grandes, o vetor dessas flutuações, adequadamente escalado, admite uma aproximação normal multivariada. Entretanto, as contagens não são independentes: no modelo multinomial, seu total é fixo; no teste de independência, as frequências esperadas também são estimadas a partir das margens.

Não é correto tratar cada resíduo de Pearson $(O_{ij} - E_{ij})/\sqrt{E_{ij}}$ como uma normal padrão independente. Por exemplo, em aderência com probabilidades conhecidas, $\mathrm{Var}(O_i) = Np_i(1 - p_i)$, enquanto $E_i = Np_i$; assim, a variância do resíduo de Pearson é $1 - p_i$, e não 1.

A justificativa assintótica considera conjuntamente os resíduos e suas covariâncias. No espaço de contrastes compatível com a hipótese nula, a estatística de Pearson pode ser representada, no limite, como uma soma de quadrados de componentes normais padrão independentes. A dimensão desse espaço determina os graus de liberdade: $m - 1$ na aderência com probabilidades previamente especificadas e $(r-1)(c-1)$ na independência.

Portanto, a conclusão sobre a distribuição da soma não exige que cada resíduo original seja uma normal padrão independente. Essa é uma explicação conceitual do resultado assintótico, e não sua demonstração formal. Frequências esperadas pequenas podem comprometer a aproximação; os critérios usuais são regras práticas.

B Equivalência com o z-teste para Duas Proporções

Existe uma conexão algébrica exata entre o teste qui-quadrado de independência e o z-teste bilateral para diferença de duas proporções, quando aplicados a uma tabela 2×2.

Para tornar essa conexão concreta: em uma tabela 2×2, uma das variáveis define dois grupos (por exemplo, Masculino e Feminino) e a outra variável define uma resposta binária (por exemplo, prefere Cachorro ou prefere Gato). Comparar a tabela inteira é equivalente a comparar duas proporções: a proporção de preferência por cachorro no grupo Masculino e a proporção correspondente no grupo Feminino. O teste qui-quadrado e o z-teste bilateral capturam exatamente a mesma informação, apenas por caminhos diferentes.

Sejam $\hat{p}_1$ e $\hat{p}_2$ as proporções observadas em dois grupos de tamanhos n_1 e n_2, e $\hat{p} = (n_1\hat{p}_1 + n_2\hat{p}_2)/(n_1 + n_2)$ a proporção combinada. A estatística z do teste bilateral para $H_0 : p_1 = p_2$ satisfaz:

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\dfrac{1}{n_1} + \dfrac{1}{n_2}\right)}} \qquad \Longrightarrow \qquad \chi^2 = z^2$$

Os dois testes são algebricamente equivalentes: conduzem exatamente ao mesmo p-valor bilateral.

Essa equivalência vale para o teste qui-quadrado de Pearson *sem* a correção de continuidade de Yates, combinado com o z-teste bilateral usando a proporção combinada sob H_0. Se a correção de Yates for aplicada, a igualdade $\chi^2 = z^2$ deixa de valer exatamente.

Essa equivalência explica por que ambos os testes estão disponíveis para analisar tabelas 2×2. A vantagem do z-teste é a possibilidade de formular hipóteses unilaterais; a vantagem do χ^2 é a generalização natural para tabelas maiores.

Para verificar essa equivalência no exemplo de sexo e animal preferido, consideremos as proporções observadas.

As proporções de preferência por cachorro são $\hat{p}_1 = 42/52 \approx 0{,}808$ (Masculino) e $\hat{p}_2 = 9/48 \approx 0{,}188$ (Feminino), com proporção combinada $\hat{p} = 51/100 = 0{,}51$. Calculando:

$$z = \frac{0{,}808 - 0{,}188}{\sqrt{0{,}51 \times 0{,}49 \times \left(\frac{1}{52} + \frac{1}{48}\right)}} \approx 6{,}200 \qquad \Longrightarrow \qquad z^2 \approx 38{,}44 \approx \chi^2$$

A pequena diferença em relação a $\chi^2 = 38{,}41$ é devida ao arredondamento.

B.1 Exercício Complementar: Equivalência χ^2 – z-teste

Em uma pesquisa, 180 homens e 120 mulheres responderam se preferem trabalho presencial ou remoto. Entre os homens, 108 preferiram presencial; entre as mulheres, 60.

(a) Monte a tabela de contingência 2×2.

(b) Aplique o teste χ^2 de independência sem correção de Yates e registre χ^2 e p.

(c) Aplique o z-teste bilateral para diferença de duas proporções e registre z e p.

(d) Verifique numericamente que $\chi^2 = z^2$. Por que a equivalência exige que o teste χ^2 seja aplicado sem a correção de Yates?

(e) Calcule ϕ e classifique o tamanho do efeito.

C Correção de Continuidade de Yates (tabelas 2×2)

Para tabelas 2×2 com frequências esperadas reduzidas, aplica-se a *correção de continuidade de Yates*, que reduz cada desvio absoluto em 0,5 antes de elevar ao quadrado:

$$\chi^2_{\text{Yates}} = \sum_{i,j} \frac{\left(\max\{0,\ |O_{ij} - E_{ij}| - 0{,}5\}\right)^2}{E_{ij}}$$

O termo $\max\{0, \cdot\}$ evita que a correção produza um desvio negativo quando $|O_{ij} - E_{ij}| < 0{,}5$; nesses casos raros, a contribuição da célula é simplesmente anulada. Essa correção torna o teste mais conservador (reduz a taxa de falsos positivos). Contudo, ela pode ser excessivamente conservadora em alguns cenários, e muitos autores preferem o **teste exato de Fisher** como alternativa mais limpa em amostras pequenas.

A função `chi2_contingency` aplica a correção de Yates automaticamente para tabelas 2×2 quando o argumento padrão `correction=True` está ativo. Para desativar: `chi2_contingency(tabela, correction=False)`.

Nos exemplos destas notas que reproduzem cálculos manuais e verificam a equivalência $\chi^2 = z^2$, usamos `correction=False` para manter consistência. A correção de Yates é ilustrada apenas quando explicitamente mencionada.

Pergunta 8

A função `chi2_contingency` do `scipy` aplica automaticamente a correção de Yates em tabelas 2×2 quando `correction=True`.

(a) Por que isso pode gerar resultados ligeiramente diferentes dos cálculos manuais feitos sem correção?

(b) Em quais situações faz sentido usar `correction=False`?

(c) Por que a equivalência $\chi^2 = z^2$ para duas proporções deixa de valer quando a correção de Yates é aplicada?

D Análise de Resíduos Padronizados Ajustados

D.1 Motivação

Quando a ANOVA rejeita H_0, aplicamos o teste de Tukey para identificar *quais* pares de grupos diferem. O teste qui-quadrado enfrenta um problema análogo: ao rejeitar H_0 em uma tabela maior que 2×2, sabemos que existe associação, mas não sabemos quais células são responsáveis por ela.

A análise de resíduos padronizados ajustados é o procedimento post-hoc que responde a essa questão. A analogia com o teste de Tukey não é perfeita: Tukey compara médias entre pares de grupos, enquanto os resíduos ajustados examinam células individuais da tabela. A lógica pedagógica, porém, é semelhante: primeiro testamos a existência de alguma diferença global; depois investigamos onde essa diferença se manifesta.

Pergunta 9

Suponha que, em uma tabela curso × modalidade de aula, a célula "Computação × Remota" tenha muito mais observações do que o esperado sob independência. O que isso sugere sobre a relação entre esse curso e essa modalidade?
E por que essa informação *não* aparece diretamente no p-valor global do teste qui-quadrado?

Pergunta 10

Um teste qui-quadrado aplicado a uma tabela 4×3 rejeitou H_0 com $p < 0{,}001$.

(a) O que exatamente essa rejeição permite concluir?

(b) O que ela **não** permite concluir diretamente?

(c) Por que, em tabelas maiores que 2×2, é necessário algum procedimento pós-teste para interpretar a associação?

D.2 Três Tipos de Resíduo

Antes de apresentar o resíduo que usaremos, convém distinguir três formas diferentes de medir o desvio de uma célula:

1. **Resíduo bruto** $O_{ij} - E_{ij}$: mostra apenas a diferença em contagens, sem levar em conta a escala esperada.
2. **Resíduo padronizado simples** $(O_{ij} - E_{ij})/\sqrt{E_{ij}}$: divide a diferença por $\sqrt{E_{ij}}$, tornando-a mais comparável entre células com diferentes frequências esperadas.
3. **Resíduo padronizado ajustado** (de Haberman): vai além do anterior, corrigindo também o efeito dos totais marginais da linha e da coluna. Sob H_0, esse resíduo se aproxima melhor de $N(0, 1)$, permitindo comparações e testes de significância célula a célula.

O resíduo que utilizaremos para a análise post-hoc é sempre o ajustado.

D.3 Resíduos Padronizados Ajustados

O *resíduo padronizado ajustado* (ou resíduo de Haberman) da célula (i, j) é:

$$r_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij} \times \left(1 - \frac{\text{total}_i}{N}\right) \times \left(1 - \frac{\text{total}_j}{N}\right)}}$$

onde total_i é o total da linha i e total_j é o total da coluna j. Sob H_0, cada r_{ij} segue aproximadamente a distribuição $N(0,1)$.

O denominador corrige a variância de $O_{ij} - E_{ij}$ levando em conta as proporções marginais, tornando r_{ij} mais próximo de $N(0,1)$ do que o resíduo bruto ou o resíduo padronizado simples.

Os limiares abaixo são nominais para uma célula isolada; para examinar várias células, ajuste as comparações conforme discutido adiante. Sob condições assintóticas adequadas:

- $|r_{ij}| > 1{,}96$: célula com desvio significativo ao nível $\alpha = 0{,}05$.
- $|r_{ij}| > 2{,}58$: célula com desvio significativo ao nível $\alpha = 0{,}01$.
- $r_{ij} > 0$: mais observações do que o esperado (sobre-representação).
- $r_{ij} < 0$: menos observações do que o esperado (sub-representação).

Pergunta 11

Após aplicar um teste qui-quadrado, foram obtidos os seguintes resíduos padronizados ajustados para algumas células de uma tabela:

Célula	Resíduo ajustado	Interpretação inicial
A	$+3{,}10$	?
B	$-2{,}45$	?
C	$+0{,}80$	?
D	$-4{,}20$	?

Para cada célula, indique:

(a) se há mais ou menos observações do que o esperado sob H_0;

(b) se o desvio é relevante ao nível aproximado de 5%, usando o critério $|r_{ij}| > 1{,}96$;

(c) qual célula parece contribuir mais fortemente para a associação global.

Para tabelas grandes, as $r \times c$ comparações simultâneas inflacionam a taxa de erros tipo I. Recomenda-se aplicar a correção de Bonferroni, usando como limiar $\Phi^{-1}(1 - \alpha/(2rc))$ em vez de $\Phi^{-1}(1 - \alpha/2)$, onde Φ é a função de distribuição normal padrão. Para $\alpha = 0{,}05$ e uma tabela 3×4 (12 células), o limiar corrigido seria $\Phi^{-1}(1 - 0{,}05/24) \approx 2{,}87$.

D.4 Implementação em Python

```
import numpy as np
from scipy.stats import chi2_contingency

def residuos_padronizados(tabela):
    """Calcula os residuos padronizados ajustados (Haberman)."""
    tabela = np.array(tabela, dtype=float)
```

```
    _, _, _, E = chi2_contingency(tabela, correction=False)
    N = tabela.sum()
    totais_linha = tabela.sum(axis=1, keepdims=True)
    totais_col   = tabela.sum(axis=0, keepdims=True)
    denom = np.sqrt(E * (1 - totais_linha/N) * (1 - totais_col/N
       ))
    return (tabela - E) / denom

tabela = np.array([[42, 10],
                   [ 9, 39]])
r = residuos_padronizados(tabela)
print("Residuos padronizados ajustados:")
print(r.round(2))
# |r_ij| > 1.96: celula com desvio significativo (alpha = 0.05)
```

D.5 Exemplo: Resíduos para Sexo e Animal Preferido

Para a tabela da Seção 1.1, com $N = 100$, totais de linha (52, 48) e totais de coluna (51, 49):

r_{11} (Masculino, Cachorro):

$$r_{11} = \frac{42 - 26{,}52}{\sqrt{26{,}52 \times (1 - 0{,}52) \times (1 - 0{,}51)}} = \frac{15{,}48}{\sqrt{26{,}52 \times 0{,}48 \times 0{,}49}} \approx +6{,}20$$

Para uma tabela 2×2, todos os resíduos têm o mesmo valor absoluto: $|r_{ij}| \approx 6{,}20 \gg 2{,}58$. Todas as células têm desvio altamente significativo:

- (Masculino, Cachorro) e (Feminino, Gato): sobre-representados ($r > 0$).
- (Masculino, Gato) e (Feminino, Cachorro): sub-representados ($r < 0$).

Resultado coerente com a forte associação detectada ($V = 0{,}62$, efeito grande).

Em tabelas 2×2, a análise dos resíduos costuma acrescentar pouca informação além do que já se vê nas proporções, pois existe apenas uma célula livre. Ainda assim, ela é útil para mostrar a conexão entre resíduos, estatística χ^2 e comparação de proporções, e para manter consistência de procedimento com tabelas maiores.

D.6 Complemento ao exemplo de preferência por filmes

(6) Resíduos padronizados ajustados: Com $E_{ij} \in \{30, 40\}$ e totais de linha iguais a 70:

$$r_{11} = \frac{40 - 30}{\sqrt{30 \times (1 - 0{,}50) \times (1 - 0{,}43)}} \approx +3{,}42$$

Todos os quatro resíduos têm $|r_{ij}| \approx 3{,}42 > 1{,}96$: homens preferem ação (sobre-representado) e comédia (sub-representado); o oposto para mulheres.

D.7 Exemplo Complementar: Tarefas Domésticas

O conjunto registra, para 13 tipos de tarefas domésticas, a frequência de execução pela esposa (*Wife*), marido (*Husband*), de forma alternada ou em conjunto. Pergunta: há associação entre tipo de tarefa e executor?

Tabela 13×4; $k = (13-1)(4-1) = 36$. Resultado: $\chi^2 = 1944{,}46$, $p \approx 0$. Rejeitamos H_0.

Tamanho do efeito: Com $N = 1744$ e $\min(r-1, c-1) = 3$:

$$V = \sqrt{\frac{1944{,}46}{1744 \times 3}} = \sqrt{\frac{1944{,}46}{5232}} \approx 0{,}61$$

Efeito grande segundo as diretrizes de Cohen.

Resíduos mais expressivos: *Repairs* × Husband ($r \gg 0$: reparos quase exclusivos do marido), *Holidays* × Jointly ($r \gg 0$: férias planejadas em conjunto muito além do esperado), *Laundry* × Wife ($r \gg 0$: lavanderia fortemente associada à esposa).

```
import pandas as pd
from scipy.stats import chi2_contingency
import numpy as np

data = {
    "Wife":        [156,124,77,82,53,32,33,12,10,13, 8,  0, 0],
    "Alternating": [ 14, 20,11,36,11,24,23,46,51,13, 1,  3, 1],
    "Husband":     [  2,  5, 7,15, 1, 4, 9,23,75,21,53,160, 6],
    "Jointly":     [  4,  4,13, 7,57,53,55,15, 3,66,77,  2,153]
}
tasks = ["Laundry","Main_meal","Dinner","Breakfast","Tidying",
         "Dishes","Shopping","Official","Driving","Finances",
         "Insurance","Repairs","Holidays"]

df = pd.DataFrame(data, index=tasks)
chi2_stat, p_val, dof, expected = chi2_contingency(df,
                                                   correction=
                                                      False)
n = df.values.sum()
r, c = df.shape
v = np.sqrt(chi2_stat / (n * min(r-1, c-1)))
print(f"chi2={chi2_stat:.2f}, p~0, N={n}, V={v:.3f}")

tot_l = df.values.sum(axis=1, keepdims=True)
tot_c = df.values.sum(axis=0, keepdims=True)
denom = np.sqrt(expected * (1 - tot_l/n) * (1 - tot_c/n))
res = pd.DataFrame((df.values - expected)/denom,
                   index=tasks, columns=df.columns)
print(res.abs().stack().nlargest(5))
```

D.8 Exercício Complementar: Interpretação de tabela de resíduos

Os resultados abaixo são ilustrativos para exercitar a leitura de resíduos e a correção por comparações múltiplas; não se destinam a reconstruir uma tabela de contagens.

Após aplicar o teste qui-quadrado de independência a dados sobre canal bancário preferido (App, Agência, Internet) e faixa etária (Jovem, Adulto, Sênior), obteve-se $\chi^2 = 42{,}3$, $p < 0{,}001$, $V = 0{,}31$ ($N = 220$). Os resíduos padronizados ajustados foram:

	App	**Agência**	**Internet**
Jovem	$+4{,}8$	$-3{,}1$	$+1{,}2$
Adulto	$+0{,}3$	$+0{,}9$	$-1{,}0$
Sênior	$-4{,}1$	$+2{,}7$	$-0{,}6$

(a) Quais células apresentam desvios significativos ao nível $\alpha = 0{,}05$? E ao nível $\alpha = 0{,}01$?

(b) Para cada célula significativa, indique sobre-representação ou sub-representação.

(c) Elabore uma interpretação prática: qual faixa etária prefere cada canal?

(d) Aplique a correção de Bonferroni (9 células, $\alpha = 0{,}05$) e reavalie quais células permanecem significativas.

(e) O $V = 0{,}31$ indica efeito moderado. Esse resultado é coerente com o padrão observado nos resíduos? Justifique.