Bootstrapping: Inferência Não-Paramétrica por Reamostragem

Nota de Aula 07

Prof. Eduardo Bezerra

Conteúdo

Objetivos e Orientações para a Leitura **3**

1 Métodos Paramétricos e Não-Paramétricos **3**
1.1 Distribuição Amostral e Erro Padrão 3
1.2 O que Muda em uma Abordagem Não-Paramétrica 4

2 Bootstrapping: Fundamentos **5**
2.1 A Distribuição Empírica como Aproximação da Distribuição Populacional . 5
2.2 Reamostragem com Reposição 6
2.3 Dos Sorteios à Distribuição Bootstrap 6
2.4 Tamanho da Amostra e Número de Reamostras 7
2.5 Condições e Limitações 8

3 Aplicações do Bootstrapping **8**
3.1 Estimativa do Erro Padrão 8
3.2 Estimativa de Viés 9
3.3 Intervalos de Confiança pelo Método dos Percentis 11
3.4 Construção Manual e Uso de SciPy 12

4 Realização de Testes de Hipóteses **13**
4.1 Teste para a Média de uma População 13
4.1.1 A Estatística Observada 13
4.1.2 Construindo uma Distribuição Empírica Compatível com a Hipótese Nula 14
4.2 Da Reamostragem sob H_0 ao Valor-p 14
4.2.1 Identificando Resultados pelo Menos Tão Extremos 15
4.2.2 Decisão e Interpretação 15
4.3 Extensão para a Diferença entre Médias de Duas Populações 16
4.3.1 A Estatística de Welch 16
4.3.2 Centralização dos Dois Grupos 16
4.3.3 Reamostragem e Cálculo do Valor-p 17
4.4 Condições de Aplicação e Limites da Interpretação 18

5 Exemplos Computacionais e Interpretação **18**
5.1 Média de uma Distribuição Assimétrica 18
5.2 Mediana: um Exemplo Autocontido 19
5.3 Aplicação Complementar: Mediana do Atributo dis em Boston 20

5.4 Uma Função para Testar Diferenças de Médias 20
5.5 Aplicação Complementar: Curtidas em Publicações Pagas 22

6 Resumo **22**

7 Exercícios de Fixação **23**

A Contagem de Reamostras e Probabilidades **25**

B Outros Intervalos Bootstrap **26**

C Respostas Comentadas para Autoverificação **26**

D Orientações para os Exercícios **27**

Objetivos e Orientações para a Leitura

Ao final da leitura, você deverá ser capaz de explicar como a reamostragem aproxima a variabilidade de uma estatística; distinguir a distribuição dos dados da distribuição das estatísticas bootstrap; estimar erro padrão e viés; construir e interpretar um intervalo de confiança percentil; e explicar por que um teste de hipóteses requer um cenário de reamostragem compatível com a hipótese nula.

O conteúdo principal acompanha esse percurso. A Seção 1 apresenta o problema inferencial; a Seção 2 constrói o mecanismo de reamostragem; a Seção 3 desenvolve erro padrão, viés e intervalos; e a Seção 4 introduz testes de hipóteses. A Seção 5 retoma as ideias em exemplos computacionais e a Seção 7 propõe sua aplicação a outras situações. Os apêndices reúnem aprofundamentos e respostas comentadas para autoverificação.

Faça uma primeira leitura acompanhando os exemplos numéricos antes de executar os programas. Ao chegar a uma pergunta, registre sua resposta e só depois consulte o Apêndice C. Nos códigos, procure antecipar o significado de cada vetor e de cada saída: saber executar um programa não basta para interpretar a inferência. Leve para a aula as dúvidas e as diferenças entre sua justificativa inicial e a resposta comentada.

Os exemplos centrais são autocontidos e usam dados explícitos ou simulados. Os estudos com os arquivos Boston e Facebook são aplicações complementares e exigem os CSVs indicados; os demais exemplos podem ser executados sem esses arquivos. Utilizamos Python com NumPy, SciPy e Matplotlib; Pandas é necessário apenas nas aplicações com CSV.

1 Métodos Paramétricos e Não-Paramétricos

Uma estimativa calculada em uma amostra não costuma coincidir exatamente com o parâmetro populacional. Se selecionássemos outra amostra pelo mesmo procedimento, obteríamos, em geral, outra estimativa. A inferência estatística procura quantificar essa variabilidade para construir intervalos de confiança e avaliar hipóteses. O bootstrap oferece uma maneira computacional de realizar parte desse trabalho, especialmente quando a distribuição amostral da estatística é difícil de obter analiticamente.

Considere o tempo de resposta de um sistema. Podemos usar a média para resumir o tempo esperado ou a mediana para descrever o valor central, menos sensível a respostas excepcionalmente demoradas. Depois de calcular uma dessas estatísticas, surge uma pergunta: quanto seu valor mudaria se observássemos uma nova amostra de respostas? A questão envolve a distribuição da *estatística entre amostras*, e não apenas a dispersão dos tempos individuais.

1.1 Distribuição Amostral e Erro Padrão

A *distribuição amostral* de uma estatística descreve os valores que ela pode assumir quando repetimos a amostragem da mesma população, mantendo o tamanho da amostra e o plano de coleta. Não precisamos executar esse experimento inúmeras vezes para defini-la: trata-se do modelo probabilístico da variabilidade do estimador.

Para a média de n observações independentes e identicamente distribuídas, com variância populacional finita σ^2, conhecemos uma expressão para o desvio padrão dessa

distribuição:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

Esse desvio padrão recebe o nome de *erro padrão*. Quando σ é desconhecido, usamos frequentemente $s/\sqrt{n}$ como estimativa. A fórmula do erro padrão, nessas condições, não exige normalidade; outras etapas da inferência, como a escolha de uma distribuição de referência para um teste ou intervalo, podem exigir condições adicionais ou aproximações.

Para estatísticas como medianas e determinados quantis, a incerteza também pode ser estudada teoricamente, mas não há uma expressão simples e geral comparável a $s/\sqrt{n}$ que dispense informações sobre a distribuição populacional. Essa dificuldade motiva a reamostragem: em vez de derivar uma fórmula específica para cada estatística, podemos recalculá-la em amostras simuladas e observar sua variação.

1.2 O que Muda em uma Abordagem Não-Paramétrica

Em uma abordagem paramétrica, especificamos uma família de distribuições para representar os dados e realizamos a inferência a partir desse modelo. As condições variam conforme o procedimento: um intervalo t para uma média, um teste de Welch e uma ANOVA clássica não exigem exatamente as mesmas hipóteses. Independência das observações e adequação do desenho de coleta, por exemplo, são questões distintas da forma da distribuição.

Métodos não-paramétricos permitem realizar inferência sem restringir a população a uma família paramétrica específica, como a normal. Isso não significa ausência de condições. Nesta nota, estudaremos principalmente o *bootstrap não-paramétrico ordinário*, que reamostra observações individuais e pressupõe, no seu uso básico, dados independentes e identicamente distribuídos. Dados pareados, agrupados ou temporais exigem esquemas que preservem a estrutura relevante.

Uma amostra pequena ou assimétrica não determina automaticamente a escolha do método. Uma amostra pequena pode oferecer informação insuficiente tanto para uma aproximação paramétrica quanto para o bootstrap. Uma distribuição assimétrica, por sua vez, não impede toda inferência sobre médias: importam o tamanho da amostra, as caudas, a estatística e a precisão pretendida. A escolha deve começar pela pergunta de pesquisa e pelas condições de coleta.

Outros procedimentos não-paramétricos incluem Mann–Whitney, Wilcoxon e Kruskal–Wallis. Eles não devem ser vistos simplesmente como versões dos testes t e da ANOVA que dispensam normalidade: suas hipóteses e interpretações podem ser diferentes. Nosso foco será a reamostragem para uma estatística explicitamente escolhida, como média, mediana ou diferença de médias.

Pergunta 1

Um pesquisador dispõe de 20 tempos de resposta de um sistema e deseja estimar a mediana populacional e sua incerteza. Por que a dificuldade de obter um erro padrão simples pode motivar o bootstrap? Por que o fato de haver apenas 20 observações não garante que o método produzirá uma boa aproximação?

2 Bootstrapping: Fundamentos

Idealmente, observaríamos muitas amostras da população e calcularíamos a estatística em cada uma. Na prática, geralmente temos uma única amostra. O bootstrap substitui a população desconhecida por uma aproximação construída com essa amostra e simula novas amostragens a partir dela. O método não coleta informação nova sobre a população: explora repetidamente a informação já observada.

Para acompanhar o procedimento, usaremos uma amostra didática de cinco tempos de resposta, em milissegundos:

$$x = (4, 5, 4, 7, 2).$$

Sua média é $\bar{x} = 4{,}4$ e sua mediana é 4. O tamanho reduzido facilita acompanhar os sorteios; não deve ser entendido como recomendação de que cinco observações bastam para uma inferência confiável.

2.1 A Distribuição Empírica como Aproximação da Distribuição Populacional

Para estudar como uma estatística varia entre amostras, gostaríamos de selecionar repetidamente novas amostras da população e recalcular a estatística em cada uma. Entretanto, geralmente dispomos apenas dos dados já coletados e não conhecemos a distribuição populacional que permitiria simular essas novas amostras. O bootstrap contorna essa dificuldade usando uma distribuição construída a partir da própria amostra: a *distribuição empírica*.

Na situação estudada aqui, em que as observações recebem pesos iguais, a distribuição empírica atribui a cada valor distinto uma probabilidade igual à sua frequência relativa na amostra. Considere novamente os tempos $x = (4, 5, 4, 7, 2)$. O valor 4 aparece em duas das cinco observações e, portanto, recebe probabilidade $2/5$. Os valores 2, 5 e 7 aparecem uma vez cada e recebem probabilidade $1/5$ cada. Essa distribuição descreve as frequências efetivamente observadas, sem pressupor que os tempos sigam uma distribuição normal, exponencial ou outra família paramétrica.

Uma maneira equivalente de realizar sorteios dessa distribuição é selecionar, com a mesma probabilidade, uma das cinco posições da amostra e registrar o valor encontrado. Cada posição tem probabilidade $1/5$ de seleção, mas o valor 4 pode ser obtido por duas posições diferentes. Assim, sortear uniformemente entre as observações preserva as frequências relativas dos valores; sortear uniformemente apenas entre os quatro valores distintos produziria outra distribuição.

No bootstrap, usamos a distribuição empírica como uma aproximação da distribuição populacional desconhecida para gerar reamostras no computador. A analogia é a seguinte: assim como uma nova amostra da população produziria uma nova estimativa, uma reamostra da distribuição empírica produz uma nova estimativa bootstrap. Repetindo esse procedimento, procuramos aproximar a variabilidade que a estatística apresentaria se pudéssemos repetir a coleta original.

Essa aproximação utiliza apenas a informação disponível na amostra. No exemplo, a distribuição empírica permite sortear os valores 2, 4, 5 e 7, mas não inclui outros tempos que poderiam existir na população e não foram observados. Portanto, a qualidade da aproximação depende de quanto a amostra informa sobre as características populacionais relevantes para a estatística de interesse. Uma coleta adequada e uma amostra suficientemente informativa são fundamentais; repetir os sorteios muitas vezes não compensa

informação ausente nem garante que o bootstrap funcione bem para qualquer estatística.

2.2 Reamostragem com Reposição

Uma *reamostra bootstrap* é obtida sorteando n observações da amostra original, com reposição. Depois de cada sorteio, a observação continua disponível para o próximo. Por isso, uma observação pode aparecer várias vezes ou não aparecer em determinada reamostra. No bootstrap ordinário estudado aqui, cada reamostra tem o mesmo tamanho da amostra original, pois desejamos aproximar a variabilidade de uma estatística calculada em amostras de tamanho n.

Para os cinco tempos apresentados, três reamostras possíveis são as seguintes. Elas foram escolhidas apenas para ilustrar o mecanismo, e não constituem uma simulação suficiente para inferência.

Reamostra	**Média**	**Mediana**
$(4, 4, 7, 2, 5)$	4,4	4
$(7, 7, 5, 4, 7)$	6,0	7
$(2, 2, 4, 5, 4)$	3,4	4

A repetição não representa pessoas ou medições novas: representa os resultados de sorteios da distribuição empírica. É justamente a variação das frequências dos elementos entre reamostras que permite observar diferentes médias e medianas. Sem reposição, selecionar todas as n observações apenas mudaria sua ordem, deixando essas estatísticas inalteradas. A Listagem 1 implementa um único sorteio com reposição e calcula a média da reamostra obtida.

Listagem 1: Uma reamostra com reposição.

```
import numpy as np
rng = np.random.default_rng(42)
x = np.array([4, 5, 4, 7, 2])
reamostra = rng.choice(x, size=len(x), replace=True)
print("Reamostra:", reamostra)
print("Media:", reamostra.mean())
```

O objeto `rng` controla os sorteios. A semente 42 torna a execução reproduzível no mesmo ambiente computacional; ela não melhora a qualidade estatística do método. Em `choice`, `size` define quantos sorteios faremos e `replace=True` permite selecionar novamente uma observação já sorteada.

Pergunta 2

Para $x = (4, 5, 4, 7, 2)$: **(a)** qual é a probabilidade de sortear o valor 4 em uma extração? **(b)** a reamostra $(7, 7, 7, 7, 7)$ é possível? **(c)** por que embaralhar os cinco elementos sem reposição não permite estimar a variabilidade da média?

2.3 Dos Sorteios à Distribuição Bootstrap

Denotaremos por θ o parâmetro populacional de interesse e por $\hat{\theta} = T(x)$ a estimativa obtida na amostra original. O símbolo T identifica a regra de cálculo, como média ou

mediana. Para a reamostra de índice b, escreveremos $x^{*(b)}$ e calcularemos $\hat{\theta}^{*(b)} = T(x^{*(b)})$. O asterisco indica que a quantidade foi obtida por reamostragem, e não por uma nova coleta populacional.

O algoritmo consiste em calcular $\hat{\theta}$, sortear uma reamostra de tamanho n, recalcular a mesma estatística e repetir esse sorteio e cálculo B vezes. Ao final, teremos B números:

$$\hat{\theta}^{*(1)}, \hat{\theta}^{*(2)}, \ldots, \hat{\theta}^{*(B)}.$$

Esses números, e não todos os dados das reamostras misturados, formam a aproximação computacional da *distribuição bootstrap da estatística*. Seu desvio padrão será usado para estimar o erro padrão; sua média ajudará a estimar o viés; e seus quantis serão usados no intervalo percentil.

Distribuição	**O que ela descreve?**	**Como é obtida?**
Empírica dos dados	Valores individuais da variável	Observações da amostra original
Amostral da estatística	Estatística entre novas amostras da população	Modelo de repetição da coleta
Bootstrap da estatística	Estatística entre reamostras da distribuição empírica	Sorteios computacionais condicionados aos dados

Um histograma dos tempos individuais responde onde se concentram os tempos. Um histograma de médias bootstrap responde onde se concentram as médias obtidas por reamostragem. A diferença de objeto é fundamental: os dois histogramas têm interpretações e dispersões diferentes, embora ambos usem a unidade de tempo.

2.4 Tamanho da Amostra e Número de Reamostras

O tamanho n informa quantas observações originais dispomos; B informa quantas vezes repetimos o cálculo por simulação. Aumentar n por meio de uma coleta adequada pode acrescentar informação populacional. Aumentar B apenas torna mais precisa a aproximação computacional construída a partir dos mesmos dados.

A diferença entre duas execuções com sementes distintas é uma manifestação da *variabilidade de Monte Carlo*. Ao aumentar B, essa variação tende a diminuir: o erro padrão e os limites de intervalo calculados tornam-se mais estáveis. Entretanto, a distribuição bootstrap não deve se concentrar indefinidamente em um único ponto. Sua dispersão representa incerteza amostral, que não desaparece por repetirmos os sorteios no computador.

Usaremos frequentemente $B = 10\,000$ como escolha didática. Esse número não é uma garantia de precisão universal; probabilidades de cauda muito pequenas podem exigir mais simulações. O número de reamostras possíveis e a diferença entre sequências e multiconjuntos são discutidos no Apêndice A.

Pergunta 3

Dois estudantes usam a mesma amostra: um gera 20 reamostras e outro gera 10 000. Qual deles tende a obter resultados computacionalmente mais estáveis? O segundo passa a dispor de 10 000 novas amostras da população? Aumentar B resolve a ausência de valores extremos que não apareceram na amostra original?

2.5 Condições e Limitações

O bootstrap ordinário não corrige seleção tendenciosa, erros de medição ou dependência ignorada. Se respostas de uma mesma pessoa estão relacionadas, reamostrar cada resposta isoladamente pode destruir essa relação. Se duas medidas formam um par, devemos preservar o par. Para séries temporais ou observações em grupos, podem ser necessários métodos por blocos ou por conglomerados.

Mesmo com observações independentes, certas estatísticas exigem cuidado. Dados arredondados ou discretos podem gerar muitos empates e tornar a distribuição bootstrap de medianas ou quantis discreta, o que afeta a localização de seus percentis. Em outro problema, pode haver poucos dados perto da mediana ou do quantil de interesse; nesse caso, pequenas mudanças nas observações podem alterar bastante a estatística e prejudicar a qualidade da aproximação. Extremos amostrais também merecem atenção. Na reamostragem ordinária, nenhum valor maior que o máximo observado ou menor que o mínimo observado será sorteado. Aumentar B não elimina essas limitações. O método é uma ferramenta para aproximar a incerteza sob um esquema de coleta, e não uma autorização para ignorar esse esquema.

3 Aplicações do Bootstrapping

Depois de gerar as estatísticas bootstrap, precisamos decidir qual característica de sua distribuição responde à pergunta inferencial. Começaremos pelo erro padrão, que mede dispersão entre estimativas. Em seguida, estudaremos o viés, que envolve deslocamento médio, e os intervalos de confiança, que procuram expressar a incerteza por uma faixa de valores.

3.1 Estimativa do Erro Padrão

O erro padrão é o desvio padrão da distribuição amostral de um estimador. Ele descreve o quanto as estimativas variariam entre novas amostras obtidas pelo mesmo procedimento. No bootstrap, substituímos essa distribuição desconhecida pela distribuição das estatísticas reamostradas e calculamos o desvio padrão desses B números:

$$\widehat{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\left(\hat{\theta}^{*(b)} - \bar{\theta}^{*}\right)^2}, \qquad \bar{\theta}^{*} = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}^{*(b)}.$$

A média $\bar{\theta}^{*}$ é o centro das estatísticas bootstrap. Na fórmula, medimos o afastamento de cada estatística em relação a esse centro. Não estamos calculando o desvio padrão dos dados originais nem a média dos desvios padrão das reamostras. O vetor submetido ao cálculo contém uma estatística por reamostra.

Exemplo resolvido: ler um erro padrão

Suponha que as medianas de 10 000 reamostras de tempos tenham desvio padrão de 1,8 ms. Estimamos, então, um erro padrão da mediana de 1,8 ms. O número descreve a variabilidade das medianas entre amostras, aproximada pelo bootstrap; não significa que os tempos individuais tenham desvio padrão de 1,8 ms.

A Listagem 2 gera B reamostras em uma matriz e mostra como extrair, para cada uma delas, a média e a mediana antes de calcular seus erros padrão bootstrap.

Listagem 2: Erro padrão bootstrap da média e da mediana.

```
import numpy as np
rng = np.random.default_rng(42)
x = np.array([3, 5, 6, 8, 10])
B = 10000
reamostras = rng.choice(x, size=(B, len(x)), replace=True)
boot_medias = reamostras.mean(axis=1)
boot_medianas = np.median(reamostras, axis=1)
print("EP bootstrap da media:", boot_medias.std(ddof=1))
print("EP bootstrap da mediana:", boot_medianas.std(ddof=1))
print("EP classico da media:", x.std(ddof=1) / np.sqrt(len(x)))
```

A matriz `reamostras` tem uma reamostra por linha. O argumento `axis=1` manda calcular a estatística ao longo das colunas de cada linha. Assim, `boot_medias` e `boot_medianas` têm B elementos cada. O argumento `ddof=1` faz o desvio padrão usar denominador $B-1$. Para amostras ou valores de B muito grandes, armazenar toda a matriz pode ser custoso; uma implementação em laço ou em lotes permite controlar a memória.

A comparação com $s/\sqrt{n}$ exige uma ressalva. No limite de infinitas reamostras, o erro padrão bootstrap da média é:

$$SE_{\text{boot},\infty}(\bar{X}^*) = \sqrt{\frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}} = \sqrt{\frac{n-1}{n}}\frac{s}{\sqrt{n}}.$$

Isso ocorre porque a variância da distribuição empírica tem denominador n. Para n grande, a diferença é pequena; para $n = 5$, é perceptível. Na amostra do código, o limite bootstrap é aproximadamente 1,081, enquanto $s/\sqrt{n} \approx 1{,}208$. Aumentar B estabiliza o primeiro valor, sem obrigá-lo a coincidir com o segundo. A expressão exata vale para a média; não devemos transportá-la automaticamente para outras estatísticas.

Pergunta 4

Uma estudante calcula o desvio padrão dos dados originais e o chama de erro padrão bootstrap da mediana. O que está faltando em seu procedimento? Se as medianas bootstrap já foram calculadas, qual vetor deve entrar no cálculo do desvio padrão?

3.2 Estimativa de Viés

Além de variar, um estimador pode apresentar deslocamento sistemático. Seu *viés* é definido como a diferença entre sua esperança e o parâmetro estimado:

$$\text{Viés}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

A esperança se refere a novas amostras da população, não à média dos valores individuais da amostra. Um viés positivo indica que, em média, o estimador superestima o parâmetro; um viés negativo indica subestimação. Como não conhecemos a população nem θ, não podemos calcular diretamente esse viés em um problema real apenas observando uma amostra.

O bootstrap repete a comparação na população substituta. Para uma estatística definida como a aplicação da mesma regra à distribuição, o parâmetro dessa população empírica é $\hat{\theta}$. Já a média das estimativas reamostradas aproxima a esperança do estimador nesse cenário. Isso motiva:

$$\widehat{\text{Viés}}_{\text{boot}} = \bar{\theta}^* - \hat{\theta}.$$

Essa interpretação deve respeitar a definição do estimador e do parâmetro; não basta aplicar a expressão a qualquer procedimento sem verificar o que ele estima. O resultado é uma estimativa de viés construída com a distribuição empírica, e não uma observação direta do viés populacional.

Exemplo resolvido: viés e correção

Se $\hat{\theta} = 6{,}40$ e $\bar{\theta}^* = 6{,}52$, o viés estimado é $+0{,}12$. O bootstrap sugere uma tendência de superestimação nesse cenário. Uma correção possível é subtrair o viés estimado: $\hat{\theta}_{\text{corr}} = 6{,}40 - 0{,}12 = 6{,}28$. Não sabemos, porém, se 6,28 está mais perto do parâmetro verdadeiro nessa amostra. Uma correção pode reduzir viés e aumentar variabilidade; não há garantia automática de melhoria global.

Um exemplo instrutivo é o estimador da variância com denominador n:

$$v_n = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Sob observações independentes e identicamente distribuídas, com variância finita, sua esperança é $(n-1)\sigma^2/n$, de modo que ele subestima a variância em média. No mundo bootstrap, a variância da população substituta é o próprio v_n e a esperança de v_n^* é $(n-1)v_n/n$. Portanto, o viés bootstrap limite é $-v_n/n$. A Listagem 3 simula essa estimativa de viés e a compara tanto com seu limite bootstrap quanto com a variância corrigida por $n-1$.

Listagem 3: Estimativa do viés de uma variância com denominador n.

```
import numpy as np
rng = np.random.default_rng(42)
x = np.array([3, 5, 6, 8, 10])
B = 10000
v_obs = np.var(x, ddof=0)
reamostras = rng.choice(x, size=(B, len(x)), replace=True)
boot_var = np.var(reamostras, axis=1, ddof=0)
vies_boot = boot_var.mean() - v_obs
print("Variancia com denominador n:", v_obs)
print("Vies bootstrap estimado:", vies_boot)
print("Vies bootstrap limite:", -v_obs / len(x))
print("Estimativa corrigida:", v_obs - vies_boot)
print("Variancia com denominador n-1:", np.var(x, ddof=1))
```

Na amostra acima, $v_n = 5{,}84$ e o viés bootstrap limite é $-1{,}168$. A correção bootstrap de primeira ordem tende a 7,008, enquanto a correção analítica com denominador $n-1$ produz 7,3. Elas não precisam coincidir: a correção bootstrap é uma aproximação baseada no viés estimado na população substituta.

Para a média amostral, a esperança bootstrap coincide exatamente com a média original. Um pequeno viés estimado por um número finito de reamostras pode, nesse caso, ser apenas ruído de Monte Carlo. Essa é uma razão para não aplicar mecanicamente uma correção sempre que a simulação produzir um valor diferente de zero.

Pergunta 5

Um estimador tem viés bootstrap estimado próximo de zero e erro padrão estimado elevado. Podemos concluir que suas estimativas são precisas? Explique a diferença entre deslocamento médio e dispersão entre estimativas.

3.3 Intervalos de Confiança pelo Método dos Percentis

O erro padrão resume a dispersão por um número. Um intervalo de confiança procura expressar a incerteza por uma faixa de valores para o parâmetro. Uma maneira de construí-lo é usar diretamente quantis da distribuição bootstrap, conhecida como *método dos percentis*.

Depois de calcular B estatísticas bootstrap, examinamos seus valores ordenados. O percentil 2,5 marca a região abaixo da qual estão aproximadamente 2,5% dessas estimativas; o percentil 97,5 deixa aproximadamente 97,5% abaixo dele. Entre os dois limites estão aproximadamente 95% das estatísticas bootstrap. O método usa esses limites como um intervalo de confiança aproximado para o parâmetro.

Se q_p^* denota o quantil de ordem p da distribuição bootstrap da estatística, o intervalo bilateral de nível nominal $1-\alpha$ é:

$$IC_{1-\alpha}^{\text{percentil}} = [q_{\alpha/2}^*, q_{1-\alpha/2}^*].$$

Na notação q_p^*, p varia de 0 a 1. A função `np.percentile`, por sua vez, recebe percentuais de 0 a 100; para um intervalo de 95%, usamos os argumentos 2.5 e 97.5. Detalhes de interpolação podem produzir pequenas diferenças entre implementações, especialmente com poucos valores ou muitos empates.

Exemplo resolvido: intervalo para a mediana

Se os percentis 2,5 e 97,5 das medianas bootstrap são 3,82 e 5,14 ms, o intervalo percentil de nível nominal 95% é [3,82; 5,14] ms. O procedimento fornece uma faixa de incerteza para a mediana populacional, não uma faixa que conterá 95% dos tempos individuais.

O fato de 95% das estatísticas bootstrap estarem entre os limites não demonstra, sozinho, cobertura populacional de 95%. A interpretação frequentista se refere à repetição de toda a coleta e construção do intervalo: sob condições adequadas, esperamos que uma proporção próxima ao nível nominal dos intervalos contenha o parâmetro fixo. A cobertura é aproximada e pode ser ruim em amostras pequenas ou em situações nas quais o bootstrap não reproduz bem a incerteza do estimador.

O método percentil não exige que o intervalo seja simétrico em torno da estimativa. Assimetria, por si só, não o invalida. Entretanto, viés relevante, baixa qualidade da aproximação bootstrap e estatísticas pouco regulares podem prejudicar sua cobertura. Existem alternativas, como os métodos basic e BCa, apresentadas no Apêndice B; nenhum método resolve automaticamente todas as limitações dos dados.

Pergunta 6

Os percentis 2,5 e 97,5 das medianas bootstrap são 3,82 e 5,14 ms. **(a)** qual intervalo será relatado? **(b)** quais percentis devem ser usados para nível nominal 99%? **(c)** por que o intervalo não significa que 95% das observações individuais estejam entre seus limites?

3.4 Construção Manual e Uso de SciPy

Para tornar o cálculo explícito, simularemos uma amostra de uma distribuição exponencial com média 2. Conhecemos a média porque somos os autores da simulação, mas o procedimento inferencial utilizará apenas a amostra. Em uma aplicação real, a distribuição geradora não seria conhecida. A assimetria fornece um exemplo útil, sem implicar que um intervalo clássico para a média seja necessariamente inadequado. A Listagem 4 constrói o intervalo percentil manualmente e o compara a uma execução equivalente de `scipy.stats.bootstrap`.

Listagem 4: Intervalo percentil manual para a media.

```
import numpy as np
from scipy.stats import bootstrap
rng_dados = np.random.default_rng(42)
x = rng_dados.exponential(scale=2.0, size=50)
B = 10000
rng_manual = np.random.default_rng(123)
reamostras = rng_manual.choice(x, size=(B, len(x)), replace=True)
boot_medias = reamostras.mean(axis=1)
limites = np.percentile(boot_medias, [2.5, 97.5])
print("Media observada:", x.mean())
print("EP bootstrap:", boot_medias.std(ddof=1))
print("IC percentil manual:", limites)

# Mesmos dados, mesma estatistica e mesmo metodo de intervalo.
resultado = bootstrap(
    (x,), np.mean, confidence_level=0.95,
    n_resamples=B, method="percentile",
    rng=np.random.default_rng(456)
)
print("IC percentil SciPy:", resultado.confidence_interval)
print("EP SciPy:", resultado.standard_error)
```

A tupla `(x,)` é uma sequência contendo uma amostra; a vírgula é necessária para criar a tupla com um único elemento. A função pode receber várias amostras, o que será útil em comparações de grupos. Usamos `np.mean` nos dois cálculos: trocar por `np.median` mudaria o parâmetro estimado e impediria a comparação direta dos intervalos.

O método `percentile` é indicado explicitamente porque o padrão de `scipy.stats.bootstrap` é BCa. As sementes diferentes geram reamostras diferentes, de modo que os resultados devem ser próximos, não necessariamente idênticos. O argumento `rng` pressupõe uma versão recente de SciPy; em versões anteriores à adoção dessa interface, o controle do gerador pode exigir `random_state`. Consulte a documentação da versão instalada.

4 Realização de Testes de Hipóteses

Nas seções anteriores, reamostramos os dados para estimar a incerteza de uma estatística e construir intervalos de confiança. Em um teste de hipóteses, precisamos responder a uma pergunta adicional: como a estatística se comportaria *se a hipótese nula fosse verdadeira*? Essa pergunta exige construir um cenário de reamostragem compatível com H_0, em vez de usar automaticamente a distribuição empírica tal como ela aparece nos dados.

Considere, por exemplo, uma amostra cuja média observada seja 10 e a hipótese de que a média populacional seja 9. Se reamostrarmos diretamente os valores originais, as médias bootstrap oscilarão em torno de 10, pois essa é a média da distribuição empírica. Para avaliar a discrepância em relação à hipótese nula, precisamos de uma referência na qual a média seja 9. Veremos como construir essa referência por meio de um deslocamento dos dados.

Começaremos pelo teste para a média de uma população e, depois, ampliaremos o raciocínio para a diferença entre médias de duas populações. Nos dois casos, utilizaremos procedimentos bootstrap aproximados baseados em observações independentes e identicamente distribuídas dentro de cada amostra, com variâncias populacionais finitas e positivas. A qualidade da aproximação dependerá das características dos dados e do tamanho das amostras.

4.1 Teste para a Média de uma População

Suponha que uma amostra de n tempos de resposta de um sistema seja usada para investigar se o tempo médio populacional corresponde a um valor de referência μ_0. Para avaliar diferenças em qualquer direção, formulamos:

$$H_0 : \mu = \mu_0, \qquad H_a : \mu \neq \mu_0.$$

A hipótese nula se refere à média da população, não à média de cada amostra. Mesmo que H_0 seja verdadeira, a média observada $\bar{x}$ geralmente será diferente de μ_0 por causa da variabilidade amostral. O teste procura avaliar se a diferença encontrada é suficientemente expressiva para fornecer evidência contra essa hipótese.

4.1.1 A Estatística Observada

Uma diferença de determinada magnitude pode ser mais ou menos expressiva conforme a precisão da média amostral. Uma diferença de 1 ms, por exemplo, tem interpretações distintas quando o erro padrão estimado é 0,2 ms ou 5 ms. Por isso, em vez de considerar apenas $\bar{x} - \mu_0$, dividimos essa diferença por uma estimativa de seu erro padrão:

$$T_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}},$$

onde s é o desvio padrão amostral, calculado com denominador $n - 1$.

Essa estatística expressa a distância entre a média observada e o valor de referência em unidades de erro padrão. Valores positivos indicam uma média amostral acima de μ_0; valores negativos indicam uma média abaixo dele. Quanto maior o valor absoluto de T_{obs}, maior a discrepância padronizada em relação à hipótese nula. Chamamos a divisão por um erro padrão estimado de *studentização*.

A expressão é a mesma utilizada no teste t para uma média. A diferença, aqui, está na construção da distribuição de referência: em vez de obter o valor-p a partir de uma distribuição t, iremos aproximar a distribuição da estatística sob H_0 por reamostragem.

4.1.2 Construindo uma Distribuição Empírica Compatível com a Hipótese Nula

Para gerar reamostras de um cenário com média μ_0, deslocamos todos os valores originais pela mesma quantidade. Subtraímos a média observada e adicionamos o valor de referência:

$$x_i^0 = x_i - \bar{x} + \mu_0, \qquad i = 1, \ldots, n.$$

A média dos valores transformados é:

$$\frac{1}{n}\sum_{i=1}^{n} x_i^0 = \bar{x} - \bar{x} + \mu_0 = \mu_0.$$

Assim, a distribuição empírica dos dados transformados satisfaz a igualdade proposta por H_0. Como todos os valores foram deslocados pela mesma constante, as diferenças entre eles permanecem iguais: a transformação preserva a dispersão e a forma empírica da amostra.

Exemplo resolvido: centralização em um valor de referência

Considere a amostra $x = (8, 10, 12)$ e a hipótese $H_0 : \mu = 9$. A média observada é $\bar{x} = 10$, de modo que o deslocamento necessário é $\mu_0 - \bar{x} = -1$. Os dados transformados são, portanto, $x^0 = (7, 9, 11)$. Sua média é 9, enquanto o desvio padrão permanece igual ao da amostra original. Usaremos os valores transformados para gerar a distribuição de referência, mas calcularemos a estatística observada com os dados originais. O tamanho reduzido deste exemplo serve apenas para acompanhar a transformação.

Essa construção representa uma aproximação do cenário nulo porque não conhecemos a distribuição populacional. Usamos a forma e a dispersão observadas na amostra para construir uma distribuição empírica cuja média é o valor proposto por H_0. Não estamos descobrindo quais dados teriam sido coletados se a hipótese fosse verdadeira; estamos definindo uma referência computacional para avaliar a discrepância encontrada.

4.2 Da Reamostragem sob H_0 ao Valor-p

Depois de construir os dados centralizados, geramos B reamostras de tamanho n, com reposição, a partir de $x_1^0, \ldots, x_n^0$. Em cada reamostra, calculamos a média $\bar{x}^{*(b)}$, o desvio padrão $s^{*(b)}$ e a estatística:

$$T^{*(b)} = \frac{\bar{x}^{*(b)} - \mu_0}{s^{*(b)}/\sqrt{n}}, \qquad b = 1, \ldots, B.$$

O erro padrão é recalculado em cada repetição, pois queremos aplicar às reamostras a mesma regra usada nos dados originais. Os valores $T^{*(1)}, \ldots, T^{*(B)}$ aproximam a distribuição da estatística no cenário em que a média é μ_0.

Embora a distribuição empírica centralizada tenha média exatamente igual a μ_0, as médias das reamostras não precisam coincidir com esse valor. Elas variam porque cada reamostra contém uma combinação de observações sorteadas. Essa variação é justamente o que precisamos representar: mesmo sob a hipótese nula, novas amostras produziriam diferenças em relação a μ_0.

4.2.1 Identificando Resultados pelo Menos Tão Extremos

Para a alternativa bilateral, tanto uma média muito acima quanto uma média muito abaixo de μ_0 constituem evidência contra H_0. Por isso, consideramos pelo menos tão extremas quanto a observada as estatísticas simuladas cujo módulo seja maior ou igual a $|T_{\text{obs}}|$.

Se K é o número dessas estatísticas, podemos escrevê-lo como:

$$K = \sum_{b=1}^{B} \mathbf{1}\left\{|T^{*(b)}| \geq |T_{\text{obs}}|\right\}.$$

O símbolo $\mathbf{1}$ vale 1 quando a condição é satisfeita e 0 caso contrário. Assim, a soma conta quantas das B simulações produziram uma discrepância padronizada pelo menos tão grande quanto a encontrada nos dados originais.

A proporção K/B estima a probabilidade desses resultados no cenário nulo construído. Entretanto, se nenhum resultado simulado atender ao critério, essa proporção será zero. Isso não demonstra que resultados tão extremos sejam impossíveis: eles podem ser pouco frequentes e simplesmente não ter aparecido nas repetições realizadas. Para evitar relatar um valor-p igual a zero nessa situação, adotaremos a convenção:

$$\hat{p} = \frac{K+1}{B+1}.$$

Quando $K < B$, esse ajuste produz um valor ligeiramente maior que K/B. Com $B = 10\,000$ e nenhum resultado extremo, por exemplo, relataríamos aproximadamente 0,0001. A convenção não torna o teste exato: o resultado continua dependendo da qualidade da aproximação bootstrap e do número finito de simulações.

4.2.2 Decisão e Interpretação

O valor-p estimado descreve a frequência de resultados pelo menos tão extremos quanto o observado no cenário nulo simulado. Ele não é a probabilidade de H_0 ser verdadeira. Comparamos esse valor com o nível de significância α, definido previamente: se $\hat{p} \leq \alpha$, rejeitamos H_0; caso contrário, não a rejeitamos.

Exemplo resolvido: cálculo do valor-p

Em um teste bilateral com $B = 10\,000$, suponha que 620 estatísticas simuladas tenham módulo pelo menos tão grande quanto o observado. Obtemos:

$$\hat{p} = \frac{620+1}{10\,000+1} \approx 0{,}0621.$$

Ao nível $\alpha = 0{,}05$, não rejeitamos H_0. Os dados não forneceram evidência suficiente de que a média populacional difere de μ_0 nesse nível de significância. Isso não prova que a média seja exatamente igual ao valor de referência.

A direção da alternativa determina quais resultados devem ser contados como extremos. Se a pergunta for se a média é maior que μ_0, usamos a alternativa $H_a : \mu > \mu_0$ e contamos $T^{*(b)} \geq T_{\text{obs}}$. Se a pergunta for se a média é menor, usamos $H_a : \mu < \mu_0$ e contamos $T^{*(b)} \leq T_{\text{obs}}$. Em ambos os casos, construímos a referência na igualdade $\mu = \mu_0$, que é a fronteira da hipótese nula unilateral.

A escolha entre teste bilateral e unilateral deve decorrer da pergunta de pesquisa antes de examinar o resultado. Não devemos observar o sinal da diferença e, depois, selecionar a direção que produza o menor valor-p.

Pergunta 7

Uma amostra tem média observada de 10 ms, e deseja-se testar $H_0 : \mu = 9$ ms.
(a) Em torno de qual valor as médias bootstrap tenderiam a variar se reamostrássemos diretamente os dados originais?
(b) Qual transformação deve ser aplicada antes de gerar as reamostras para o teste?
(c) Por que a estatística observada deve ser calculada nos dados originais, e não nos dados centralizados?
(d) Em um teste bilateral, por que usamos o módulo das estatísticas na contagem de resultados extremos?

4.3 Extensão para a Diferença entre Médias de Duas Populações

O teste para duas populações segue a mesma lógica: calcular a discrepância observada, construir distribuições empíricas compatíveis com H_0 e usar reamostras para avaliar a discrepância. A diferença é que agora dispomos de dois grupos e precisamos representar a variabilidade de ambas as médias.

Sejam μ_A e μ_B as médias populacionais e suponha que as duas amostras sejam independentes. Para investigar uma diferença em qualquer direção, formulamos:

$$H_0 : \mu_A - \mu_B = 0, \qquad H_a : \mu_A - \mu_B \neq 0.$$

Não conhecemos o valor comum das médias sob H_0. A hipótese afirma apenas que elas são iguais, permitindo que as populações tenham variâncias e formas diferentes.

4.3.1 A Estatística de Welch

Assim como no teste para uma população, padronizamos a diferença observada por uma estimativa de seu erro padrão. Para duas amostras independentes, usamos:

$$T_{\text{obs}} = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{s_A^2/n_A + s_B^2/n_B}}.$$

Essa é a estatística de Welch. O denominador combina as contribuições dos dois grupos para a incerteza da diferença de médias. Não supomos variâncias populacionais iguais: cada variância é estimada separadamente e ponderada pelo respectivo tamanho amostral.

Uma diferença de médias pode produzir uma estatística pequena quando os dados são muito dispersos ou as amostras são pouco informativas. A mesma diferença pode produzir uma estatística maior quando o erro padrão é menor. Portanto, a studentização mantém a distinção entre magnitude da diferença e precisão de sua estimativa.

4.3.2 Centralização dos Dois Grupos

Para construir um cenário de igualdade de médias, deslocamos cada grupo para uma média comum m_0:

$$x_{Ai}^0 = x_{Ai} - \bar{x}_A + m_0, \qquad x_{Bj}^0 = x_{Bj} - \bar{x}_B + m_0.$$

Uma escolha conveniente para esse valor comum é a média combinada:

$$m_0 = \frac{n_A \bar{x}_A + n_B \bar{x}_B}{n_A + n_B}.$$

Após a transformação, as duas distribuições empíricas têm média m_0. Cada grupo, porém, preserva sua própria dispersão e forma, pois todos os seus valores foram deslocados pela mesma constante.

Exemplo resolvido: mesma média, dispersões diferentes

Considere $A = (4, 6, 8)$ e $B = (1, 2, 6)$, com médias 6 e 3. Como os grupos têm o mesmo tamanho, a média combinada é $m_0 = 4{,}5$. Subtraímos 1,5 dos valores de A e adicionamos 1,5 aos valores de B, obtendo:

$$A^0 = (2{,}5;\ 4{,}5;\ 6{,}5), \qquad B^0 = (2{,}5;\ 3{,}5;\ 7{,}5).$$

As duas médias passam a ser 4,5, mas os grupos continuam com distribuições empíricas diferentes. Suas variâncias amostrais permanecem, respectivamente, 4 e 7. A centralização impõe igualdade de médias sem exigir igualdade de dispersão.

A escolha específica de m_0 não altera a distribuição bootstrap da estatística de Welch neste procedimento. Se usássemos outro valor comum, apenas deslocaríamos os dois grupos pela mesma quantidade adicional. As diferenças entre as médias reamostradas e os desvios padrão permaneceriam iguais. A média combinada é, portanto, uma escolha conveniente para realizar a transformação, e não uma suposição de que os grupos compartilham toda a distribuição.

Também não reunimos os valores centralizados para sortear ambos os grupos de um único conjunto. Fazer isso usaria uma distribuição empírica comum para representar as duas populações, impondo igualdade de forma e variância, além da igualdade de médias. Como H_0 exige apenas que as médias sejam iguais, mantemos os grupos separados e preservamos as outras diferenças observadas.

4.3.3 Reamostragem e Cálculo do Valor-p

Em cada repetição, sorteamos uma reamostra de tamanho n_A do grupo A centralizado e outra de tamanho n_B do grupo B centralizado. Calculamos:

$$T^{*(b)} = \frac{\bar{x}_A^{*(b)} - \bar{x}_B^{*(b)}}{\sqrt{(s_A^{*(b)})^2/n_A + (s_B^{*(b)})^2/n_B}}.$$

As médias das distribuições usadas nos sorteios são iguais, mas as médias de cada par de reamostras geralmente diferem por variabilidade amostral. As estatísticas resultantes descrevem essas diferenças padronizadas no cenário nulo construído.

A partir daí, aplicamos o mesmo procedimento desenvolvido para uma população. Na alternativa bilateral, contamos as repetições com $|T^{*(b)}| \geq |T_{\text{obs}}|$ e calculamos $\hat{p} = (K+1)/(B+1)$. Para $H_a : \mu_A > \mu_B$, contamos $T^{*(b)} \geq T_{\text{obs}}$; para $H_a : \mu_A < \mu_B$, contamos $T^{*(b)} \leq T_{\text{obs}}$. A decisão é tomada pela comparação com α, e a conclusão deve se referir à diferença entre as médias populacionais.

Pergunta 8

Considere duas amostras independentes e a hipótese $H_0 : \mu_A = \mu_B$.
(a) Por que reamostrar diretamente os grupos originais não impõe, em geral, a igualdade de médias?
(b) Depois de centralizados, os grupos precisam ter a mesma variância? Explique.
(c) Por que reamostramos os grupos separadamente?
(d) O que muda em relação ao teste para a média de uma população e quais etapas permanecem iguais?

4.4 Condições de Aplicação e Limites da Interpretação

Os procedimentos apresentados usam distribuições empíricas centralizadas para aproximar cenários populacionais sob H_0. Não conhecemos essas populações e não podemos assegurar que a transformação reproduza todas as características relevantes para a distribuição da estatística. A aproximação tende a exigir maior cuidado quando as amostras são pequenas, as caudas são muito pesadas ou poucas observações dominam as estimativas.

A reamostragem de observações individuais também depende da estrutura da coleta. Medidas repetidas da mesma pessoa, pares de observações, agrupamentos e dependência temporal não devem ser tratados automaticamente como dados independentes. Nesses casos, o esquema de reamostragem precisa preservar as relações relevantes. Aumentar B não corrige uma estrutura de dependência ignorada.

A studentização exige um erro padrão estimado positivo. Se uma reamostra produzir desvio padrão zero no teste para uma população, ou um denominador nulo no teste para duas populações, a estatística não estará definida. Descartar silenciosamente essas repetições modificaria a distribuição simulada; a ocorrência deve motivar uma revisão da adequação do procedimento.

Por fim, o número finito de reamostras introduz variação computacional no valor-p estimado. Se o resultado estiver próximo de α, pode ser útil aumentar B e verificar sua estabilidade. Esse cuidado melhora a precisão da simulação, mas não elimina limitações da amostra ou da construção do cenário nulo. A conclusão deve reunir a estimativa da diferença, sua unidade, o valor-p e as condições sob as quais a análise foi realizada. Rejeitar H_0 fornece evidência contra a hipótese testada; não rejeitá-la não demonstra igualdade, e nenhum desses resultados, isoladamente, estabelece causalidade.

5 Exemplos Computacionais e Interpretação

Os exemplos seguintes retomam o percurso completo, da escolha da estatística à interpretação. Adotamos nível nominal de confiança de 95%, $\alpha = 0{,}05$ para os testes e $B = 10\,000$, salvo indicação diferente. Os exemplos simulados permitem execução imediata; as aplicações com CSV mantêm o vínculo com conjuntos de dados usados no curso, mas exigem discussão adicional sobre sua coleta.

5.1 Média de uma Distribuição Assimétrica

A Listagem 4 já constrói um intervalo para uma amostra exponencial. A Listagem 5 retoma suas variáveis e coloca lado a lado os dados e as médias bootstrap. Antes de

executar, procure prever qual histograma descreve tempos individuais e qual descreve a variabilidade de uma média calculada com 50 observações.

Listagem 5: Visualizacao dos dados e das medias bootstrap.

```
# Executar depois da Listagem de IC manual (x e boot_medias).
import matplotlib.pyplot as plt
fig, eixos = plt.subplots(1, 2, figsize=(10, 4))
eixos[0].hist(x, bins=15, edgecolor="black")
eixos[0].set(title="Dados originais", xlabel="Valor individual")
eixos[1].hist(boot_medias, bins=35, edgecolor="black")
eixos[1].axvline(limites[0], color="red", linestyle="--")
eixos[1].axvline(limites[1], color="red", linestyle="--")
eixos[1].set(title="Medias bootstrap", xlabel="Media reamostrada")
fig.tight_layout()
plt.show()
```

O histograma das médias tende a ser menos disperso que o dos valores individuais: uma média de 50 observações não varia como uma observação isolada. As linhas verticais delimitam o intervalo percentil, não uma região que deva conter 95% dos dados originais. Para investigar cobertura, seria necessário repetir a geração da amostra e a construção do intervalo, não apenas gerar mais reamostras da mesma amostra.

5.2 Mediana: um Exemplo Autocontido

Considere 30 tempos independentes de conclusão de uma tarefa, simulados por uma distribuição lognormal. A população simulada tem mediana e^2, mas deixaremos essa informação fora do cálculo do intervalo. O interesse é verificar como trocar a estatística, mantendo o mecanismo de reamostragem. A Listagem 6 estima a mediana, seu erro padrão bootstrap e um intervalo percentil para esses tempos simulados.

Listagem 6: Intervalo e erro padrao para uma mediana.

```
import numpy as np
from scipy.stats import bootstrap
rng = np.random.default_rng(2026)
tempos = rng.lognormal(mean=2.0, sigma=0.7, size=30)
res = bootstrap(
    (tempos,), np.median, method="percentile",
    confidence_level=0.95, n_resamples=10000,
    rng=np.random.default_rng(87)
)
print("Mediana observada:", np.median(tempos))
print("EP bootstrap:", res.standard_error)
print("IC percentil:", res.confidence_interval)
```

Relate a estimativa, o erro padrão, os limites e a unidade de medida. A presença ou ausência de e^2 em um único intervalo não valida ou invalida o método: uma propriedade de cobertura se refere a repetições de todo o procedimento. A simulação oferece um ambiente em que essa propriedade pode ser investigada, porque o parâmetro gerador é conhecido.

5.3 Aplicação Complementar: Mediana do Atributo dis em Boston

No conjunto Boston, o atributo `dis` registra uma medida de distância ponderada a cinco centros de emprego. Para usar as linhas como amostra de uma população mais ampla, precisamos explicitar qual população ou processo esses registros representam e avaliar a plausibilidade de independência entre unidades geográficas. A presença de 506 registros em um arquivo não assegura essas condições.

A Listagem 7 realiza uma análise exploratória sob um modelo de linhas independentes. Se houver dependência espacial ou se a população de interesse for exatamente o conjunto finito de registros sem plano de amostragem definido, a interpretação inferencial precisa ser revista. O código não resolve essa escolha de modelo.

Listagem 7: Aplicacao ao CSV Boston, quando disponivel.

```
import numpy as np
import pandas as pd
from scipy.stats import bootstrap
from pathlib import Path
caminho = Path("../data/Boston.csv")
if not caminho.exists():
    print("Disponibilize Boston.csv no caminho indicado.")
else:
    df = pd.read_csv(caminho)
    dis = pd.to_numeric(df["dis"], errors="coerce").dropna().to_numpy()
    print("Numero de valores validos:", len(dis))
    resultado = bootstrap(
        (dis,), np.median, method="percentile",
        confidence_level=0.95, n_resamples=10000,
        rng=np.random.default_rng(42)
    )
    print("Mediana:", np.median(dis))
    print("EP:", resultado.standard_error)
    print("IC:", resultado.confidence_interval)
```

5.4 Uma Função para Testar Diferenças de Médias

A Listagem 8 implementa o procedimento da Seção 4. Ela pode ser usada com duas amostras independentes e variâncias finitas, desde que o erro padrão estimado não seja zero. O programa verifica condições numéricas básicas, mas a independência e o desenho de coleta devem ser avaliados por quem conduz a análise.

Listagem 8: Bootstrap studentizado sob igualdade de medias.

```
import numpy as np
from scipy.stats import ttest_ind

def welch_t(a, b):
    ep = np.sqrt(a.var(ddof=1)/len(a) + b.var(ddof=1)/len(b))
    if not np.isfinite(ep) or ep <= 0:
        raise ValueError("Erro padrao zero ou invalido.")
    return (a.mean() - b.mean()) / ep
```

```
def teste_bootstrap(a, b, B=10000, alternativa="two-sided", seed=42):
    a = np.asarray(a, dtype=float)
    b = np.asarray(b, dtype=float)
    if (a.ndim != 1 or b.ndim != 1 or min(len(a), len(b)) < 2
            or not np.all(np.isfinite(a))
            or not np.all(np.isfinite(b))):
        raise ValueError("Forneca vetores finitos com ao menos 2 valores.")
    if alternativa not in ("two-sided", "greater", "less"):
        raise ValueError("Alternativa invalida.")
    if not isinstance(B, (int, np.integer)) or B < 1:
        raise ValueError("B deve ser inteiro positivo.")
    t_obs = welch_t(a, b)
    m0 = np.concatenate((a, b)).mean()
    a0 = a - a.mean() + m0
    b0 = b - b.mean() + m0
    rng = np.random.default_rng(seed)
    t_boot = np.empty(B)
    for i in range(B):
        aa = rng.choice(a0, size=len(a), replace=True)
        bb = rng.choice(b0, size=len(b), replace=True)
        t_boot[i] = welch_t(aa, bb)
    if alternativa == "two-sided":
        extremos = np.abs(t_boot) >= abs(t_obs)
    elif alternativa == "greater":
        extremos = t_boot >= t_obs
    else:
        extremos = t_boot <= t_obs
    k = np.count_nonzero(extremos)
    p = (k + 1)/(B + 1)
    return {"diferenca": a.mean()-b.mean(), "t": t_obs,
            "p": p, "extremos": k, "t_boot": t_boot}

# Dados simulados para executar sem arquivos externos.
rng = np.random.default_rng(2026)
a = rng.normal(loc=72, scale=12, size=40)
b = rng.normal(loc=68, scale=15, size=45)
res = teste_bootstrap(a, b, alternativa="two-sided")
print("Diferenca observada:", res["diferenca"])
print("T observado:", res["t"])
print("Extremos:", res["extremos"])
print("Valor-p bootstrap:", res["p"])
print("Welch classico:", ttest_ind(a, b, equal_var=False))
```

O vetor `t_boot` contém estatísticas sob o cenário nulo, e não diferenças brutas de médias. A saída do teste de Welch clássico usa outra aproximação de referência; por isso, seu valor-p não precisa coincidir exatamente com o bootstrap. Compare a decisão, a magnitude da diferença e as condições dos procedimentos. Uma divergência exige examinar os dados e a qualidade das aproximações, não escolher automaticamente o menor valor-p.

Se uma reamostra produzir erro padrão zero, a função interrompe com uma mensagem. Isso pode ocorrer em amostras pequenas ou muito discretas. Descartar silenciosamente

essas reamostras mudaria a distribuição simulada; é preferível reconhecer a limitação e reconsiderar o procedimento.

5.5 Aplicação Complementar: Curtidas em Publicações Pagas

O conjunto Facebook Metrics permite investigar se publicações identificadas como pagas apresentam média de curtidas maior que as não pagas. Denotando essas médias por μ_1 e μ_0, definimos previamente a alternativa $H_a : \mu_1 > \mu_0$ e usamos a fronteira nula $\mu_1 = \mu_0$ para construir a simulação.

As unidades são publicações, não usuários. A análise requer discutir dependência temporal, campanhas comuns, públicos compartilhados e possíveis confundidores. Mesmo com evidência de diferença nas médias, dados observacionais não demonstram que pagar a publicação cause aumento nas curtidas. A Listagem 9 lê o arquivo, trata valores ausentes e aplica o teste bootstrap unilateral definido anteriormente.

Listagem 9: Aplicacao ao Facebook Metrics, quando o CSV estiver disponivel.

```
# Executar depois da definicao de teste_bootstrap.
import pandas as pd
from pathlib import Path
caminho = Path("../data/dataset_Facebook.csv")
if not caminho.exists():
    print("Disponibilize dataset_Facebook.csv no caminho indicado.")
else:
    df = pd.read_csv(caminho, delimiter=";")
    dados = df[["Paid", "like"]].apply(pd.to_numeric, errors="coerce")
    dados = dados.dropna()
    dados = dados[dados["Paid"].isin([0, 1])]
    pagas = dados.loc[dados["Paid"] == 1, "like"].to_numpy()
    nao_pagas = dados.loc[dados["Paid"] == 0, "like"].to_numpy()
    print("Tamanhos validos:", len(pagas), len(nao_pagas))
    resultado = teste_bootstrap(
        pagas, nao_pagas, alternativa="greater", B=10000, seed=42
    )
    for nome in ("diferenca", "t", "extremos", "p"):
        print(nome, resultado[nome])
```

Não fixamos antecipadamente tamanhos ou resultados para essa aplicação: eles devem ser obtidos do arquivo efetivamente utilizado, após o tratamento explícito de ausências. No relatório, informe as médias, os tamanhos válidos, a diferença, a estatística, o valor-p e a decisão. Discuta também se a suposição de publicações independentes é defensável; caso não seja, reamostrar publicações isoladas não é suficiente.

6 Resumo

O bootstrap não-paramétrico usa a distribuição empírica como população substituta e sorteia reamostras para estudar a variação de uma estatística. Ele não transforma B reamostras em B novas coletas e não recupera informação ausente da amostra. A validade depende da relação entre a amostra, o desenho de coleta e a estatística escolhida.

As aplicações usam características diferentes das estatísticas reamostradas. Seu desvio padrão estima o erro padrão; a diferença entre sua média e a estimativa original pode esti-

mar viés; e seus quantis fornecem os limites do intervalo percentil. Para testar hipóteses, precisamos modificar o cenário de simulação de modo a representar H_0.

7 Exercícios de Fixação

Os exercícios combinam cálculo, programação e interpretação. Use sementes explícitas nos programas e registre os parâmetros das simulações. Quando o enunciado solicitar inferência, explique quais unidades são consideradas independentes e qual população ou processo está sendo representado. Respostas numéricas aproximadas e orientações estão no Apêndice D.

Exercício 1: Escolha e Condições de Uso

Para cada situação, discuta as vantagens e limitações do bootstrap, em vez de escolher apenas entre "paramétrico" e "não-paramétrico":

(a) Uma amostra aleatória de 200 salários é usada para construir um intervalo para a mediana. A distribuição é fortemente assimétrica.

(b) Uma amostra independente de 500 alturas aproximadamente normais é usada para construir um intervalo para a média. Compare a conveniência de uma fórmula clássica e da reamostragem.

(c) Quinze tempos de resposta apresentam valores extremos e o interesse é a mediana. Por que tamanho pequeno e valores extremos exigem cautela, em vez de garantir a adequação do método?

(d) Mil avaliações de 1 a 5 são usadas para estimar a média da codificação numérica. Discuta a interpretação dessa média e o que mudaria se várias avaliações pertencessem ao mesmo usuário.

Exercício 2: Reamostras e Erro Padrão

Considere $x = (1, 3, 5, 7, 9)$, com $n = 5$.

(a) Gere cinco reamostras com reposição e calcule a média de cada uma.

(b) Estime o erro padrão pelo desvio padrão dessas cinco médias. Por que o resultado é instável?

(c) Repita com $B = 10\,000$. Compare com $s/\sqrt{n}$ e com $\sqrt{(n-1)/n}\,s/\sqrt{n}$. Qual deles é o limite bootstrap?

(d) Explique por que repetir o cálculo com muitas reamostras não transforma esses cinco dados em uma amostra populacional grande.

(e) Como aprofundamento, calcule o número de sequências ordenadas e de multiconjuntos de índices possíveis. Por que os multiconjuntos não devem receber pesos iguais?

Exercício 3: Intervalo para a Mediana

Considere os 30 tempos abaixo, em milissegundos, tratados como observações independentes de um processo estável. Eles são dados didáticos, fornecidos integralmente para permitir reprodução sem arquivos externos. A Listagem 10 define o vetor que deve ser usado nos cálculos deste exercício.

Listagem 10: Dados do Exercicio 3.

```
tempos = np.array([
    4.2, 5.1, 6.0, 7.4, 5.8, 8.3, 4.9, 6.7, 7.1, 9.5,
    5.3, 6.4, 8.8, 7.9, 6.2, 10.1, 5.6, 7.0, 6.8, 8.1,
    4.7, 9.2, 7.6, 6.5, 5.9, 8.5, 7.3, 11.4, 6.1, 7.8
])
```

Calcule a mediana, o erro padrão bootstrap e um intervalo percentil de 95% com $B = 10\,000$. Compare a implementação manual com SciPy, mantendo a mesma estatística e o mesmo método. Interprete o intervalo sem confundi-lo com uma faixa para tempos individuais. Avalie também como o arredondamento dos tempos pode afetar os empates entre medianas reamostradas.

Exercício 4: Diferença de Medianas e Desenho da Coleta

Em uma primeira pesquisa, pessoas diferentes executam as tarefas A e B, formando duas amostras independentes. A Listagem 11 define os vetores a serem usados para estimar um intervalo percentil para mediana(A) − mediana(B), reamostrando cada grupo separadamente.

Listagem 11: Dados do Exercicio 4.

```
a = np.array([12, 15, 11, 18, 13, 16, 14, 22, 17, 12, 19, 15])
b = np.array([10, 11, 14, 9, 12, 13, 10, 15, 11, 12, 16, 10])
```

Em uma segunda pesquisa hipotética, cada pessoa executa ambas as tarefas, e cada posição dos vetores corresponde ao mesmo participante. Explique por que seria necessário reamostrar os índices dos pares conjuntamente. Distinga a diferença entre medianas da mediana das diferenças individuais: são parâmetros distintos. Se um intervalo bilateral adequado para a diferença excluir zero, discuta a evidência contra igualdade das medianas, lembrando que o procedimento tem cobertura aproximada.

Exercício 5: Viés da Variância

Use os 20 valores da Listagem 12 como amostra e estime o viés de $v_n = \sum(x_i - \bar{x})^2/n$ com $B = 5\,000$.

Listagem 12: Dados do Exercicio 5.

```
x = np.array([3, 5, 6, 8, 10, 4, 7, 9, 6, 5,
              11, 8, 7, 6, 12, 4, 9, 10, 5, 7])
```

Explique o sinal esperado do viés, calcule a correção bootstrap e compare com a variância com denominador $n - 1$. Compare também a estimativa por simulação com o viés bootstrap limite $-v_n/n$. As duas correções precisam coincidir? Um viés menor garante menor erro quadrático médio?

Exercício 6: Teste de Igualdade de Médias

Para duas amostras independentes, use os dados da Listagem 13, em pontos de uma prova. A pergunta foi definida antes da análise: as médias populacionais diferem em qualquer direção?

Listagem 13: Dados do Exercicio 6.

```
impresso = np.array([64, 72, 68, 81, 75, 69, 77, 83, 70, 74, 66, 79])
digital = np.array([60, 67, 71, 65, 73, 62, 76, 68, 64, 70, 66, 72])
```

Formule as hipóteses, calcule a diferença e a estatística de Welch, execute o teste bootstrap bilateral e compare com `ttest_ind(..., equal_var=False)`. Relate o valor-p e a decisão em $\alpha = 0{,}05$. Explique por que a comparação observacional entre grupos não prova efeito causal do material de estudo. Examine o que mudaria no esquema de reamostragem caso os alunos pertencessem a turmas com dependência interna.

Exercício 7: Interpretação Conjunta

Um analista obteve a estimativa original $\hat{\theta} = 14{,}30$, média das estatísticas bootstrap $\bar{\theta}^* = 14{,}47$, desvio padrão dessas estatísticas de 1,82 e percentis 2,5 e 97,5 iguais a 10,88 e 17,93.

(a) Informe o intervalo percentil, o erro padrão estimado, o viés estimado e a estimativa corrigida.

(b) O valor de referência 12 está incluído no intervalo? O que isso permite dizer, e o que não permite concluir, considerando a aproximação do procedimento?

(c) Em outro cenário, um intervalo bilateral de 95% adequado para o mesmo parâmetro exclui 12. Como interpretar esse resultado em relação à hipótese de que o parâmetro vale 12?

(d) Por que a interpretação via intervalo não garante valor-p numericamente idêntico ao teste bootstrap centralizado da Seção 4?

A Contagem de Reamostras e Probabilidades

Se cada uma das n posições originais pode ser escolhida em cada um dos n sorteios, existem n^n sequências ordenadas de índices. No bootstrap ordinário, todas essas sequências têm a mesma probabilidade n^{-n}. Para $n = 5$, são 3125 sequências.

Quando a estatística não depende da ordem, podemos agrupar sequências com as mesmas multiplicidades. O número de vetores de multiplicidades $(k_1, \ldots, k_n)$ com $k_i \geq 0$ e soma n é:

$$\binom{2n-1}{n-1}.$$

Para $n = 5$, há 126 multiconjuntos de índices. Se valores originais se repetem, alguns desses multiconjuntos ainda produzem os mesmos valores numéricos. Portanto, essa contagem não é necessariamente o número de conjuntos numéricos distintos.

Os multiconjuntos não são equiprováveis. Um vetor de multiplicidades tem probabilidade:

$$\Pr(k_1, \ldots, k_n) = \frac{n!}{k_1! \cdots k_n!} \left(\frac{1}{n}\right)^n .$$

Com dois índices originais, as sequências $(1,1)$, $(1,2)$, $(2,1)$ e $(2,2)$ têm probabilidade $1/4$ cada. Ignorando a ordem, o multiconjunto com um elemento de cada índice tem probabilidade $1/2$, enquanto os outros dois têm $1/4$. Dar peso $1/3$ a cada multiconjunto não reproduziria o mecanismo de sorteio. Na prática, simulamos sequências diretamente, podendo repetir reamostras entre as B realizações.

B Outros Intervalos Bootstrap

O método percentil usa diretamente os quantis da distribuição das estimativas bootstrap. O método *basic*, também chamado reverso, parte de uma aproximação para a distribuição do erro do estimador e reflete os quantis em torno da estimativa original:

$$IC_{1-\alpha}^{\text{basic}} = [2\hat{\theta} - q^*_{1-\alpha/2},\ 2\hat{\theta} - q^*_{\alpha/2}].$$

A reflexão pode mudar a localização do intervalo e, em certos problemas, produzir limites fora do espaço possível do parâmetro. É preciso avaliar a adequação da construção ao problema, em vez de escolher o método apenas pela largura do intervalo.

O método BCa ajusta as probabilidades dos quantis usando uma correção relacionada ao viés e um termo de aceleração, frequentemente estimado por jackknife. Seu objetivo é melhorar propriedades de cobertura sob condições de regularidade, mas não oferece garantia universal. Dados degenerados e estatísticas com muitos empates podem causar dificuldades. A derivação fica fora do escopo desta leitura; a documentação de SciPy descreve as opções implementadas.

C Respostas Comentadas para Autoverificação

Estas respostas se referem às perguntas distribuídas no texto. Consulte-as depois de formular sua própria justificativa. O objetivo é verificar o raciocínio, e não apenas reconhecer um número correto.

Pergunta 1. O bootstrap permite aproximar a variação da mediana recalculando-a em reamostras, sem uma fórmula simples para seu erro padrão. Com apenas 20 observações, a distribuição empírica pode representar mal regiões relevantes da população; a simulação repete essa limitação em vez de eliminá-la.

Pergunta 2. A probabilidade de sortear 4 é $2/5$, pois duas posições têm esse valor. Cinco sorteios do valor 7 são possíveis, com probabilidade $(1/5)^5$. Sem reposição, usar todas as posições preserva a mesma coleção e a mesma média, de modo que não gera sua distribuição bootstrap.

Pergunta 3. Dez mil reamostras tendem a estabilizar a aproximação computacional mais que 20, mas continuam condicionadas à mesma amostra. Valores que não aparecem nela não surgem pela simples reamostragem. A informação populacional original não é multiplicada por B.

Pergunta 4. É preciso gerar reamostras, calcular uma mediana em cada uma e obter o desvio padrão desse vetor de medianas. O desvio padrão dos dados mede dispersão individual; o erro padrão mede dispersão de estimativas.

Pergunta 5. Viés próximo de zero indica pouco deslocamento médio estimado, mas não garante precisão. Um estimador pode oscilar muito em torno do parâmetro. Viés e variância contribuem conjuntamente para o erro quadrático médio.

Pergunta 6. O intervalo é [3,82; 5,14] ms. Para 99%, usamos os percentis 0,5 e 99,5. Os números reamostrados são medianas, portanto o intervalo se refere ao parâmetro mediana e não a uma proporção dos tempos individuais.

Pergunta 7. Reamostrar os grupos originais mantém, em média, a diferença amostral observada, sem impor igualdade populacional. A centralização estabelece médias comuns e a reamostragem separada preserva formas e dispersões diferentes. A alternativa deve ser escolhida pela pergunta de pesquisa antes de observar o resultado, evitando selecionar a direção mais favorável após a análise.

D Orientações para os Exercícios

Exercício 1. Para salários e mediana, a reamostragem pode ser útil se a coleta for adequada; assimetria não é obstáculo automático. Para alturas e média, um intervalo clássico é simples e o bootstrap pode servir de comparação. Com 15 tempos, a amostra pode não representar bem caudas e a mediana pode ter distribuição bootstrap discreta. Na escala 1 a 5, a média depende da codificação e de sua interpretação; avaliações repetidas do mesmo usuário exigem preservar a dependência, por exemplo reamostrando usuários sob um modelo apropriado.

Exercício 2. A média original é 5, $s^2 = 10$ e $s/\sqrt{5} \approx 1{,}414$. O limite do erro padrão bootstrap é $\sqrt{8/5} \approx 1{,}265$. Há $5^5 = 3125$ sequências e $\binom{9}{4} = 126$ multiconjuntos de índices, com pesos distintos. As estimativas por cinco reamostras podem variar muito entre execuções.

Exercício 3. A mediana observada é 6,9 ms. Os limites e o erro padrão devem ser calculados; pequenas diferenças entre simulações são esperadas. Use `np.median` e `method="percentile"` na comparação. Um intervalo diz respeito à mediana populacional sob o modelo de coleta, e não à concentração de 95% dos tempos.

Exercício 4. As medianas observadas são 15 e 11,5, com diferença 3,5. Para grupos independentes, sorteie cada vetor separadamente e subtraia as medianas em cada repetição. Para pares, sorteie uma sequência de índices e use-a nos dois vetores. Não substitua diferença de medianas por mediana das diferenças sem mudar explicitamente o parâmetro.

Exercício 5. O viés bootstrap limite é negativo e vale $-v_n/20$. A correção de primeira ordem tende a $v_n(1+1/20)$ e a correção analítica é $20v_n/19$. Os resultados não coincidem exatamente e reduzir o viés não garante reduzir a variância ou o erro quadrático médio.

Exercício 6. A hipótese alternativa é bilateral. As médias observadas são aproximadamente 73,17 e 67,83, com diferença 5,33 pontos e estatística de Welch próxima de 2,40. Ao executar a função da Listagem 8 com $B = 10\,000$ e semente 42, obtemos $K = 283$ estatísticas extremas e valor-p bootstrap $284/10\,001 \approx 0{,}0284$; o teste de Welch clássico fornece aproximadamente 0,0256. Ambos rejeitam a igualdade em $\alpha = 0{,}05$, sob as condições adotadas. A interpretação causal exige mais que diferença de médias, e dependência por turma exige outro modelo ou esquema de reamostragem.

Exercício 7. O intervalo é [10,88; 17,93], o erro padrão estimado é 1,82, o viés estimado é +0,17 e a correção produz 14,13. O valor 12 pertence ao intervalo apresentado; isso indica que, por esse procedimento aproximado, os dados não fornecem evidência suficiente contra 12 no nível nominal correspondente, mas não confirma que o parâmetro seja igual a 12. Em outro cenário, sua exclusão por um intervalo bilateral adequado sugere evidência contra esse valor no nível nominal correspondente, respeitada a aproximação. Uma equivalência exata entre decisão por intervalo e teste requer procedimentos compatíveis por inversão; não se deve presumir identidade numérica entre métodos bootstrap distintos.

Referências

[1] Hesterberg, T. C. (2015). What Teachers Should Know About the Bootstrap: Resampling in the Undergraduate Statistics Curriculum. *The American Statistician*, 69(4), 371–386. `https://doi.org/10.1080/00031305.2015.1089789`.

[2] SciPy. *scipy.stats.bootstrap*: documentação de referência. `https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.bootstrap.html`. Consulte a versão correspondente ao ambiente utilizado.