

Bootstrapping: Inferência Não-Paramétrica por Reamostragem

Notas de Aula

Prof. Eduardo Bezerra

Conteúdo

1	Métodos Paramétricos e Não-Paramétricos	3
1.1	Distribuição amostral e pressuposições paramétricas	3
1.2	Métodos não-paramétricos	3
2	Bootstrapping: Fundamentos	5
2.1	Visão geral	5
2.2	Etapas do bootstrapping	5
2.3	Reamostragem com reposição	6
3	Aplicações do Bootstrapping	7
3.1	Estimativa de viés	7
3.2	Estimativa do erro padrão	9
3.3	Construção de intervalos de confiança	10
3.3.1	Principais métodos para IC via bootstrap	10
3.3.2	Implementação em Python	11
3.4	Realização de testes de hipóteses	12
4	Exemplos	13
4.1	Exemplo 1: IC para a média (distribuição assimétrica)	13
4.2	Exemplo 2: IC para a mediana (conjunto de dados Boston)	14
4.3	Exemplo 3: Teste de hipóteses – curtidas em publicações pagas vs. não pagas	16
4.4	Resumo das funções Python utilizadas	18
5	Resumo	18
6	Exercícios de Fixação	19

Objetivos

Ao final da leitura, você deve ser capaz de:

Métodos não-paramétricos e motivação

- Explicar o que são métodos estatísticos paramétricos e identificar suas pressuposições.
- Descrever quando e por que métodos não-paramétricos são preferíveis.
- Citar exemplos de métodos não-paramétricos e suas contrapartes paramétricas.

Fundamentos do Bootstrapping ★

- Descrever o princípio central do bootstrapping: usar a amostra como substituta da população.
- Explicar o que é reamostragem com reposição e por que ela é usada.
- Calcular o número total de reamostras possíveis para uma amostra de tamanho n .
- Distinguir a distribuição amostral verdadeira da distribuição bootstrap.

Aplicações do bootstrapping ★

- Estimar o viés de um estimador usando reamostras bootstrap.
- Estimar o erro padrão de uma estatística via bootstrap, sem recorrer a fórmulas analíticas.
- Construir intervalos de confiança bootstrap pelo método dos percentis.
- Realizar testes de hipóteses usando a distribuição bootstrap e calcular o valor- p empírico.

Implementação em Python

- Implementar a reamostragem com reposição usando `numpy.random.choice`.
- Construir intervalos de confiança bootstrap usando `numpy.percentile`.
- Usar `scipy.stats.bootstrap` para calcular intervalos de confiança de forma direta.

Roteiro de leitura

Estas notas estão organizadas em cinco partes. A Seção 1 apresenta a motivação para os métodos não-paramétricos e situa o bootstrapping nesse contexto. A Seção 2 descreve o princípio geral do bootstrapping e o mecanismo de reamostragem com reposição. A Seção 3 detalha as três principais aplicações: estimativa de viés, estimativa do erro padrão e construção de intervalos de confiança. A Seção 4 apresenta o uso do bootstrapping para testes de hipóteses. A Seção 5 traz exemplos completos com código Python. Os objetivos marcados com ★ são os mais centrais.

1 Métodos Paramétricos e Não-Paramétricos

1.1 Distribuição amostral e pressuposições paramétricas

Nas notas anteriores, estudamos procedimentos de inferência estatística (estimação por intervalos de confiança e testes de hipóteses) que dependem da distribuição amostral de alguma estatística. Recorde que a *distribuição amostral* de uma estatística é a distribuição dessa estatística, considerada como variável aleatória, quando derivada de amostras aleatórias de tamanho n extraídas de uma população. Ela pode ser interpretada como a distribuição da estatística para todas as amostras possíveis da mesma população.

Para o caso particular da média amostral $\bar{x}$, o Teorema Central do Limite (TCL) nos garante que o erro padrão pode ser estimado por:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Os procedimentos paramétricos (testes t , z , F , χ^2 , ANOVA, entre outros) exigem que certas pressuposições sobre a população sejam satisfeitas, tais como:

- a variância populacional é conhecida ou pode ser estimada adequadamente;
- a população é aproximadamente normal;
- as variâncias de diferentes grupos são aproximadamente iguais (homocedasticidade).

Pergunta 1

Considere os testes paramétricos estudados ao longo do curso (testes t , z , ANOVA).

- (a) Cite ao menos duas pressuposições que esses testes fazem sobre os dados ou sobre a população.
- (b) O que pode acontecer com os resultados de um teste paramétrico quando essas pressuposições são violadas?
- (c) Em quais situações práticas seria difícil garantir que essas pressuposições estão satisfeitas?

1.2 Métodos não-paramétricos

Quando as pressuposições dos métodos paramétricos não podem ser satisfeitas (seja porque a amostra é pequena, a distribuição é assimétrica, ou simplesmente porque não se conhece a forma da distribuição populacional), uma alternativa natural são os *métodos não-paramétricos*.

Definição

Métodos não-paramétricos são técnicas estatísticas que não assumem uma forma específica para a distribuição da população da qual os dados foram coletados. Em outras palavras, não exigem que os dados sigam uma distribuição pré-definida, como a distribuição normal.

Esses métodos são úteis quando: a amostra é pequena; os dados não atendem aos pressupostos dos métodos paramétricos (como normalidade ou homocedasticidade); ou quando se deseja realizar inferência com o mínimo de suposições sobre a população.

Alguns exemplos comuns de métodos não-paramétricos, junto com suas contrapartes paramétricas, são apresentados na tabela a seguir.

Situação	Método paramétrico	Alternativa não-paramétrica
Comparar duas amostras independentes	Teste t para duas amostras	Teste de Mann–Whitney
Comparar amostras pareadas	Teste t pareado	Teste de Wilcoxon
Comparar três ou mais grupos	ANOVA	Teste de Kruskal–Wallis
Estimar distribuições de probabilidade	–	Estimadores de densidade por kernel
Análise de sobrevivência	–	Método de Kaplan–Meier

Vantagens e desvantagens

Métodos não-paramétricos são, em geral, mais robustos a violações de pressupostos, pois não dependem de hipóteses sobre a distribuição da população. Por outro lado, quando as pressuposições paramétricas são de fato válidas, os métodos não-paramétricos podem ter menor poder estatístico do que seus equivalentes paramétricos, isto é, podem ser menos eficazes em detectar diferenças reais.

Pergunta 2

Para cada situação abaixo, indique se um método paramétrico ou não-paramétrico parece mais adequado, e justifique.

- Uma amostra de tamanho $n = 200$ de uma população normal com variância conhecida; deseja-se testar se a média é igual a um valor de referência.
- Uma amostra de tamanho $n = 12$ de tempos de execução de um algoritmo, com distribuição visivelmente assimétrica.
- Dados de salários de funcionários de uma empresa, em que a distribuição apresenta cauda longa à direita.
- Notas de uma turma de 80 alunos, com distribuição aproximadamente simétrica e sem evidência de outliers.

2 Bootstrapping: Fundamentos

2.1 Visão geral

Definição

Em Estatística, bootstrapping é o nome dado a uma técnica não-paramétrica que usa reamostragem aleatória com reposição para simular o processo de amostragem a partir de uma população. Esta técnica permite estimar a distribuição amostral de praticamente qualquer estatística usando métodos computacionais, sem depender de fórmulas analíticas derivadas de suposições sobre a distribuição dos dados.

O método de bootstrapping é frequentemente usado como alternativa às técnicas de inferência paramétrica quando as condições de aplicabilidade não podem ser satisfeitas, quando a inferência paramétrica é impossível, ou quando o cálculo analítico do erro padrão envolve fórmulas complexas.

As principais aplicações do bootstrapping são:

1. produzir intervalos de confiança para algum parâmetro populacional;
2. realizar testes de hipóteses.

Ideia central

O método de bootstrapping se baseia em uma ideia simples, mas poderosa: a amostra que temos contém informações sobre a população, e podemos aproveitar essa informação repetidamente ao gerar novas amostras simuladas a partir dela. Em vez de extrair muitas amostras da população (o que seria custoso na prática), usamos a única amostra disponível *no lugar da população* e geramos reamostras *in silico* (por computador).

2.2 Etapas do bootstrapping

As etapas gerais do bootstrapping para estimar a distribuição amostral de uma estatística T (por exemplo, média, mediana, proporção, desvio padrão) são descritas abaixo.

1. **Distribuição amostral verdadeira:** seria obtida tomando novas amostras da população, calculando T para cada uma delas e acumulando os valores. Porém, extrair muitas amostras da população é custoso na prática.
2. **A amostra como substituta da população:** em vez de novas amostras da população, o bootstrapping usa uma única amostra disponível como se fosse a própria população. Essa amostra é denominada *população estimada*.
3. **Geração de reamostras:** a partir da amostra original, geram-se B reamostras por amostragem com reposição. Para cada reamostra, o valor de T é calculado.
4. **Distribuição amostral bootstrap:** os B valores de T obtidos no passo anterior formam a distribuição bootstrap, que aproxima a distribuição amostral verdadeira da estatística.

O que se pode fazer com a distribuição bootstrap

A partir da distribuição amostral estimada, é possível:

- calcular características da estatística de interesse, como sua média, variância e assimetria;
- construir *intervalos de confiança* sem necessidade de suposições paramétricas;
- estimar o *viés* e o *erro padrão* do estimador;
- calcular *valores-p* para testes de hipóteses.

Pergunta 3

Explique, com suas palavras, o papel da amostra original no processo de bootstrapping.

- (a) O que representa a amostra original no contexto do método?
- (b) Por que as reamostras são geradas *a partir da amostra original* e não diretamente da população?
- (c) Qual seria o impacto de usar uma amostra original enviesada ou de tamanho muito pequeno?

2.3 Reamostragem com reposição

O passo fundamental do bootstrapping é a reamostragem com reposição (*sampling with replacement*). O termo “com reposição” significa que um elemento da amostra original pode ser selecionado zero ou mais vezes para fazer parte de uma reamostra. Cada reamostra gerada, denominada *amostra bootstrap*, deve ter o mesmo tamanho n da amostra original.

Para uma amostra original de tamanho n , o número total de reamostras distintas possíveis é dado por:

$$|C_n| = \binom{2n-1}{n-1}$$

Como exemplo, para $n = 5$:

$$|C_5| = \binom{9}{4} = \frac{9!}{4! \times 5!} = \frac{9 \times 8 \times 7 \times 6}{4!} = 126$$

Na prática, em vez de enumerar todas as reamostras possíveis, sorteia-se aleatoriamente um subconjunto de B reamostras. Quanto maior o número de reamostras B , mais precisa será a aproximação da distribuição amostral. Valores típicos de B variam entre 1 000 e 10 000.

Pergunta 4

Considere uma amostra original com $n = 4$ elementos: $\{2, 5, 8, 11\}$.

- (a) Qual é o número total de reamostras possíveis?
- (b) Dê dois exemplos de reamostras de tamanho 4 obtidas *com reposição* dessa amostra.
- (c) Por que uma reamostra pode conter o mesmo elemento mais de uma vez?
- (d) O que aconteceria com a qualidade da estimativa bootstrap se usássemos apenas $B = 10$ reamostras? E $B = 10\,000$?

Limitação importante

O método de bootstrapping é eficaz, mas sua qualidade depende diretamente da representatividade da amostra original. Se a amostra original for enviesada ou pequena demais para capturar adequadamente a variabilidade da população, os resultados bootstrap também serão enviesados ou imprecisos. O bootstrapping não é capaz de “criar” informação que não está presente nos dados originais.

A Listagem 1 ilustra como realizar a reamostragem com reposição em Python usando a função `numpy.random.choice`.

Listagem 1: Exemplo de reamostragem com reposição em Python.

```
import numpy as np

# Amostra original
amostra_original = np.array([4, 5, 4, 7, 2])
n = len(amostra_original)

# Gerar uma reamostra com reposicao de mesmo tamanho
reamostra = np.random.choice(amostra_original, size=n, replace=True)
print("Reamostra:", reamostra)
```

3 Aplicações do Bootstrapping

3.1 Estimativa de viés

O **viés** de um estimador mede o quanto, em média, ele tende a superestimar ou subestimar o verdadeiro parâmetro populacional θ :

$$\text{Viés}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

Como o valor verdadeiro θ é desconhecido, o bootstrapping permite estimar esse viés de forma empírica. Denote por $\hat{\theta}$ o valor da estatística calculado na amostra original, e por $\bar{\theta}^*$ a média das B estatísticas calculadas nas reamostras. A estimativa bootstrap do viés é:

$$\widehat{\text{Viés}}_{\text{boot}} = \bar{\theta}^* - \hat{\theta}$$

Se $\widehat{\text{Viés}}_{\text{boot}} > 0$, o estimador tende a superestimar o parâmetro; se $\widehat{\text{Viés}}_{\text{boot}} < 0$, tende a subestimá-lo. Com essa estimativa, é possível também *corrigir* o valor do estimador:

$$\hat{\theta}_{\text{corrigido}} = \hat{\theta} - \widehat{\text{Viés}}_{\text{boot}}$$

Uma das vantagens do bootstrapping para a estimativa de viés é que não depende de fórmulas teóricas, sendo especialmente útil em situações como: estatísticas não lineares (medianas, razões, coeficientes de regressão); amostras pequenas, onde a aproximação normal pode ser fraca; e modelos nos quais não existe expressão analítica para o viés do estimador.

Pergunta 5

Suponha que, ao aplicar o bootstrapping com $B = 1000$ reamostras sobre uma amostra original de tamanho $n = 30$, você obteve:

$$\hat{\theta} = 6,40 \quad \text{e} \quad \bar{\theta}^* = 6,52.$$

- Calcule a estimativa bootstrap do viés.
- O estimador tende a superestimar ou subestimar o parâmetro?
- Qual seria o valor corrigido do estimador?
- Por que um viés próximo de zero não implica necessariamente que o estimador é de boa qualidade?

A Listagem 2 exemplifica o cálculo do viés bootstrap em Python.

Listagem 2: Estimativa de viés via bootstrapping.

```
import numpy as np

# Amostra original e estatística observada
x = np.array([3, 5, 6, 8, 10])
theta_hat = np.mean(x)

# Reamostragem bootstrap
B = 1000
n = len(x)
boot_stats = np.array([
    np.mean(np.random.choice(x, size=n, replace=True))
    for _ in range(B)
])

# Estimativa de vies
vies_boot = np.mean(boot_stats) - theta_hat

print(f"Estimativa original: {theta_hat:.3f}")
print(f"Media das reamostras: {np.mean(boot_stats):.3f}")
print(f"Vies estimado via bootstrap: {vies_boot:.3f}")
print(f"Estimativa corrigida: {theta_hat - vies_boot:.3f}")
```


3.2 Estimativa do erro padrão

O *erro padrão* (EP) de um estimador mede a variabilidade desse estimador em torno do seu valor esperado, isto é, o quanto a estimativa mudaria se o experimento fosse repetido. Para a média amostral, a fórmula analítica é conhecida:

$$SE(\bar{x}) = \frac{\sigma}{\sqrt{n}}$$

Na prática, como σ é desconhecido, substitui-se pelo desvio padrão amostral s :

$$\widehat{SE}(\bar{x}) = \frac{s}{\sqrt{n}}$$

Entretanto, para muitas estatísticas, essa fórmula simplesmente não existe, é difícil de derivar, ou depende de suposições pouco realistas. O bootstrapping oferece uma alternativa empírica: dado um conjunto de B estimativas bootstrap $\hat{\theta}^{*(1)}, \hat{\theta}^{*(2)}, \dots, \hat{\theta}^{*(B)}$, o erro padrão é estimado como o desvio padrão dessas estimativas:

$$\widehat{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B \left(\hat{\theta}^{*(b)} - \bar{\theta}^* \right)^2}$$

Quanto maior o número de reamostras B , mais estável será essa estimativa.

Por que estimar o erro padrão via bootstrap?

O bootstrap permite estimar o erro padrão de *qualquer* estatística, mesmo aquelas para as quais não existe fórmula fechada, como a mediana, a variância, um coeficiente de regressão ou um quantil. Além disso, funciona mesmo em amostras pequenas ou distribuições assimétricas, substituindo deduções analíticas por simulações empíricas baseadas na própria amostra.

Pergunta 6

Considere duas situações: (i) estimar o erro padrão da média amostral; (ii) estimar o erro padrão da mediana amostral.

- Para qual das duas estatísticas existe uma fórmula analítica simples para o erro padrão?
- O que torna o erro padrão da mediana mais difícil de calcular analiticamente?
- Como o bootstrap resolve essa dificuldade?
- Se aumentarmos B de 500 para 5 000 reamostras, o que esperamos que aconteça com a estimativa do erro padrão?

A Listagem 3 mostra como estimar o erro padrão via bootstrapping e como compará-lo com o erro padrão teórico.

Listagem 3: Estimativa do erro padrão via bootstrapping.

```
import numpy as np
```

```
x = np.array([3, 5, 6, 8, 10])
B = 1000
n = len(x)

# Reamostras
boot_stats = np.array([
    np.mean(np.random.choice(x, size=n, replace=True))
    for _ in range(B)
])

# Erro padrao bootstrap
se_boot = np.sqrt(np.sum((boot_stats - np.mean(boot_stats))**2) / (
    B - 1))
print(f"Erro padrao estimado via bootstrap: {se_boot:.4f}")

# Comparacao com o erro padrao teorico
se_teorico = np.std(x, ddof=1) / np.sqrt(n)
print(f"Erro padrao teorico (formula classica): {se_teorico:.4f}")
```

O erro padrão estimado via bootstrap é, em geral, próximo ao erro padrão teórico, mas não depende de nenhuma suposição sobre a distribuição dos dados. Isso é especialmente útil quando a estatística de interesse é complexa ou quando a distribuição populacional é desconhecida.

3.3 Construção de intervalos de confiança

Uma das aplicações mais populares do bootstrapping é a construção de *intervalos de confiança* sem pressupor distribuições específicas para os dados. O procedimento geral envolve os seguintes passos.

Roteiro para construção de IC via bootstrapping

1. Defina a estatística de interesse $\hat{\theta}$ (por exemplo, média, mediana, desvio padrão, diferença entre médias).
2. Calcule $\hat{\theta}$ na amostra original. Esse é o estimador pontual.
3. Gere B reamostras com reposição e calcule $\hat{\theta}^{*(b)}$ em cada uma delas. Tipicamente $B = 1\,000$ ou $B = 10\,000$.
4. Obtenha a distribuição bootstrap $\hat{\theta}^{*(1)}, \hat{\theta}^{*(2)}, \dots, \hat{\theta}^{*(B)}$, que representa a distribuição empírica da estatística.
5. Construa o intervalo de confiança usando um dos métodos descritos a seguir.

3.3.1 Principais métodos para IC via bootstrap

Existem diferentes abordagens para construir o intervalo de confiança a partir da distribuição bootstrap. A tabela a seguir resume os três principais.

Método	Descrição	IC de 95%
Percentil	Usa diretamente os percentis da distribuição bootstrap	$[\hat{\theta}_{2,5\%}^*, \hat{\theta}_{97,5\%}^*]$
Basic (reverso)	Espelha a distribuição bootstrap em torno da estatística observada	$[2\hat{\theta}_{\text{obs}} - \hat{\theta}_{97,5\%}^*, 2\hat{\theta}_{\text{obs}} - \hat{\theta}_{2,5\%}^*]$
BCa	Corrige viés e assimetria (mais sofisticado)	Baseado em correções de aceleração e viés

O método dos percentis é o mais simples e intuitivo: ordena-se a distribuição bootstrap e utilizam-se os percentis $\alpha/2$ e $1 - \alpha/2$ como limites inferior e superior do intervalo. Para um IC de 95%, os percentis de 2,5% e 97,5% são usados.

Pergunta 7

Um pesquisador gerou $B = 10\,000$ reamostras e calculou a mediana em cada uma. Os resultados ordenados da distribuição bootstrap produziram os seguintes percentis:

$$\hat{\theta}_{2,5\%}^* = 3,82 \quad \text{e} \quad \hat{\theta}_{97,5\%}^* = 5,14.$$

- Qual é o IC de 95% pelo método dos percentis?
- Como você interpretaria esse intervalo em linguagem acessível?
- Se o pesquisador quisesse um IC de 99%, quais percentis deveria usar?
- Por que o método dos percentis pode ser inadequado quando a distribuição bootstrap é muito assimétrica?

3.3.2 Implementação em Python

A Listagem 4 implementa a construção de um IC de 95% para a média usando o método dos percentis.

Listagem 4: Construção de IC de 95% para a média via bootstrapping (método dos percentis).

```
import numpy as np

# Dados e estatística observada
np.random.seed(42)
amostra = np.random.exponential(scale=2.0, size=50)
media_obs = np.mean(amostra)

# Bootstrapping
B = 10000
boot_medias = np.array([
    np.mean(np.random.choice(amostra, size=len(amostra), replace=
        True))
    for _ in range(B)
```

```

])

# Intervalo de confiança (metodo dos percentis)
linf = np.percentile(boot_medias, 2.5)
lsup = np.percentile(boot_medias, 97.5)

print(f"Media observada: {media_obs:.3f}")
print(f"IC 95% (percentil): [{linf:.3f}, {lsup:.3f}]")

```

A biblioteca `scipy.stats` também oferece a função `bootstrap`, que permite computar intervalos de confiança de forma mais direta, conforme a Listagem 5.

Listagem 5: Construção de IC via `scipy.stats.bootstrap`.

```

from scipy.stats import bootstrap
import numpy as np

# Os dados devem ser fornecidos como uma sequencia (tupla)
dados = (amostra,)
resultado = bootstrap(dados, np.median, confidence_level=0.95,
                      n_resamples=10000)
print(resultado.confidence_interval)

```

3.4 Realização de testes de hipóteses

O bootstrapping pode também ser utilizado para realizar *testes de hipóteses*, especialmente quando as condições de aplicabilidade dos testes paramétricos não estão satisfeitas. A ideia central é simular a distribuição da estatística de interesse sob a hipótese nula por meio de reamostragem, e então comparar o valor observado com essa distribuição simulada.

Roteiro para testes de hipóteses via bootstrapping

1. Defina a estatística de interesse T (por exemplo, diferença de médias, razão de variâncias).
2. Estabeleça a hipótese nula H_0 . Exemplo: $H_0: \mu_A = \mu_B$.
3. Calcule a estatística observada T_{obs} nos dados originais.
4. Simule a distribuição nula por reamostragem:
 - combine os grupos, caso necessário, de modo a simular que os dados vêm de uma única população (sob H_0);
 - gere B reamostras com reposição e calcule a estatística T^* em cada uma.
5. Calcule o valor- p comparando T_{obs} com a distribuição de T^* :
 - Teste bilateral: $p = \frac{\#(|T^*| \geq |T_{\text{obs}}|)}{B}$
 - Teste unilateral ($T_{\text{obs}} > 0$): $p = \frac{\#(T^* \geq T_{\text{obs}})}{B}$
6. **Tome a decisão:** se $p \leq \alpha$, rejeitar H_0 .

Pergunta 8

Um pesquisador quer testar se dois grupos (A e B) têm médias iguais, usando bootstrapping com $B = 10\,000$ reamostras e $\alpha = 0,05$.

- Formule as hipóteses H_0 e H_a em termos das médias populacionais μ_A e μ_B .
- Por que, ao gerar as reamostras, os dados dos dois grupos são combinados?
- Se a estatística observada for $T_{\text{obs}} = 3,2$ e, das 10 000 reamostras, 620 produzirem $|T^*| \geq 3,2$, qual é o valor- p ? Qual é a decisão do teste?
- Em que circunstâncias esse teste bootstrap seria preferível ao teste t paramétrico?

4 Exemplos

Nos exemplos a seguir, adotamos $\alpha = 0,05$ e $B = 10\,000$ reamostras, salvo indicação em contrário.

4.1 Exemplo 1: IC para a média (distribuição assimétrica)

Situação-problema

Uma amostra de $n = 50$ observações foi extraída de uma distribuição exponencial com média 2. Como a distribuição exponencial é assimétrica, os procedimentos paramétricos baseados em normalidade podem ser imprecisos para amostras dessa dimensão. Deseja-se construir um IC de 95% para a média populacional *sem presumir normalidade*.

Solução

- Calcula-se a média da amostra original: $\hat{\theta}_{\text{obs}} = \bar{x}$.
- Geram-se $B = 10\,000$ reamostras com reposição de tamanho $n = 50$. Para cada reamostra, calcula-se a média.
- Obtém-se a distribuição bootstrap das médias: $\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}$.
- Pelo método dos percentis, o IC de 95% é $[\hat{\theta}_{2,5\%}^*, \hat{\theta}_{97,5\%}^*]$.

Interpretação: com 95% de confiança, a média populacional está contida no intervalo estimado, sem nenhuma suposição sobre a forma da distribuição dos dados.

Listagem 6: IC de 95% para a média via bootstrapping – distribuição assimétrica.

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)
amostra = np.random.exponential(scale=2.0, size=50)
```

```
media_obs = np.mean(amostra)
print(f"Media observada: {media_obs:.3f}")

B = 10000
boot_medias = [
    np.mean(np.random.choice(amostra, size=len(amostra), replace=
        True))
    for _ in range(B)
]
boot_medias = np.array(boot_medias)

linf = np.percentile(boot_medias, 2.5)
lsup = np.percentile(boot_medias, 97.5)
print(f"IC 95% (percentil): [{linf:.3f}, {lsup:.3f}]")

# Visualizacao
plt.hist(boot_medias, bins=40, color='skyblue', edgecolor='k',
    alpha=0.7)
plt.axvline(linf, color='red', linestyle='--', label='Limite
    inferior')
plt.axvline(lsup, color='red', linestyle='--', label='Limite
    superior')
plt.axvline(media_obs, color='black', label='Media observada')
plt.title('Distribuicao Bootstrap da Media')
plt.xlabel('Media')
plt.ylabel('Frequencia')
plt.legend()
plt.show()
```

4.2 Exemplo 2: IC para a mediana (conjunto de dados Boston)

Situação-problema

Considere o conjunto de dados Boston, que contém informações socioeconômicas de bairros da cidade de Boston. O atributo `dis` representa a distância ponderada a cinco centros de emprego na cidade.

Tarefa: construir um IC de 95% para a mediana populacional do atributo `dis`.

Por que bootstrapping? Os procedimentos paramétricos estudados no curso permitem construir intervalos de confiança apenas para médias e proporções populacionais. Para a mediana, não existe fórmula analítica simples para o erro padrão, tornando o bootstrapping a abordagem natural.

Solução

Os passos são análogos ao Exemplo 1, com a mediana no lugar da média.

1. Calcula-se a mediana da amostra original: $\hat{\theta}_{\text{obs}} = \text{mediana}(\text{dis})$.
2. Geram-se $B = 10\,000$ reamostras com reposição de tamanho $n = 506$ (tamanho da amostra original).
3. Para cada reamostra, calcula-se a mediana.
4. O IC de 95% é obtido pelos percentis 2,5% e 97,5% da distribuição bootstrap.
5. O erro padrão da mediana é estimado pelo desvio padrão dos B valores bootstrap.

Listagem 7: IC de 95% para a mediana via bootstrapping – conjunto de dados Boston.

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('../data/Boston.csv')
amostra_original = df['dis']

# Geracao das reamostras e computo da mediana
B = 10000
bootstrap_dist = [
    np.median(np.random.choice(amostra_original, len(
        amostra_original), replace=True))
    for _ in range(B)
]
bootstrap_dist = np.array(bootstrap_dist)

# Intervalo de confianca de 95%
linf = np.percentile(bootstrap_dist, 2.5)
lsup = np.percentile(bootstrap_dist, 97.5)
print(f"IC 95% para a mediana: ({linf:.2f}, {lsup:.2f})")

# Erro padrao da mediana
se_mediana = np.std(bootstrap_dist)
print(f"Erro padrao da mediana: {se_mediana:.4f}")

# Visualizacao
sns.histplot(bootstrap_dist, kde=True, color='blue', bins=30)
plt.title('Distribuicao Bootstrap da Mediana de dis')
plt.xlabel('Mediana')
plt.show()
```

Observe que a mesma tarefa pode ser realizada de forma mais direta com a função `scipy.stats.bootstrap`:

Listagem 8: IC para a mediana usando `scipy.stats.bootstrap`.

```
from scipy.stats import bootstrap
import numpy as np

dados = (amostra_original.values,)
resultado = bootstrap(dados, np.median, confidence_level=0.95,
                      n_resamples=10000)
print(resultado.confidence_interval)
```

4.3 Exemplo 3: Teste de hipóteses – curtidas em publicações pagas vs. não pagas

Situação-problema (Facebook Metrics)

O conjunto de dados *Facebook Metrics* contém informações sobre publicações de uma marca de cosméticos ao longo de 2014. Dois atributos de interesse são **like** (número de curtidas) e **Paid** (indicador de publicação paga).

Pergunta de pesquisa: publicações pagas recebem, em média, mais curtidas do que publicações não pagas?

Hipóteses: Sendo μ_1 a média de curtidas das publicações pagas e μ_0 a média das não pagas:

$$H_0 : \mu_1 - \mu_0 = 0 \quad \text{vs.} \quad H_a : \mu_1 - \mu_0 > 0$$

Procedimento:

1. Calculamos a diferença observada nas médias amostrais: $T_{\text{obs}} = \bar{x}_{\text{pago}} - \bar{x}_{\text{não pago}}$.
2. Combinamos os dados dos dois grupos (simulando H_0 : todos vêm da mesma população).
3. Geramos $B = 10\,000$ reamostras dos dados combinados, atribuindo aleatoriamente amostras de tamanho $n_1 = 139$ e $n_0 = 359$ a cada grupo.
4. Calculamos a diferença de médias T^* em cada reamostra.
5. O valor- p (unicaudal) é a proporção de reamostras com $T^* \geq T_{\text{obs}}$.

Listagem 9: Teste de hipóteses via bootstrapping – curtidas em publicações do Facebook.

```
import pandas as pd
import numpy as np
from sklearn.utils import resample

data = pd.read_csv('../data/dataset_Facebook.csv', delimiter=';')

# Separar os dados
unpaid_likes = data[data['Paid'] == 0]['like'].dropna()
paid_likes    = data[data['Paid'] == 1]['like'].dropna()
```



```
# Diferença observada
obs_dif = np.mean(paid_likes) - np.mean(unpaid_likes)
print(f"Diferença observada nas médias: {obs_dif:.2f}")

# Combinação dos grupos (sob  $H_0$ )
combined = np.concatenate((paid_likes, unpaid_likes))

# Reamostragem bootstrap sob  $H_0$ 
B = 10000
boot_difs = []
for i in range(B):
    np.random.seed(i)
    boot_paid = resample(combined, n_samples=len(paid_likes))
    boot_unpaid = resample(combined, n_samples=len(unpaid_likes))
    boot_difs.append(np.mean(boot_paid) - np.mean(boot_unpaid))

boot_difs = np.array(boot_difs)

# Valor-p (teste unicaudal)
p_value = np.mean(boot_difs >= obs_dif)
print(f"Valor-p (unicaudal): {p_value:.4f}")

if p_value < 0.05:
    print("Rejeitamos  $H_0$ : publicações pagas recebem mais curtidas.")
else:
    print("Não rejeitamos  $H_0$ .")
```

Resultado e interpretação

A diferença observada nas médias foi de aproximadamente 79,8 curtidas (publicações pagas – não pagas). Das 10 000 reamostras geradas sob H_0 , apenas 137 produziram uma diferença de médias igual ou superior a 79,8, resultando em $p \approx 0,014$. Como $p < \alpha = 0,05$, rejeitamos H_0 .

Conclusão: há evidência estatística de que publicações pagas estão associadas a uma quantidade significativamente maior de curtidas em comparação com publicações não pagas.

Pergunta 9

Com base no Exemplo 3:

- (a) Por que o teste foi aplicado de forma unicaudal e não bilateral?
- (b) O que significa combinar os dados dos dois grupos antes de gerar as reamostras?
- (c) Como o valor-p bootstrap de 0,014 deve ser interpretado?
- (d) Seria correto aplicar um teste t a esses dados? Quais pressuposições precisariam ser verificadas?

4.4 Resumo das funções Python utilizadas

Função	Propósito	Módulo
<code>np.random.choice(x, n, replace=True)</code>	Gera uma reamostra com reposição	<code>numpy</code>
<code>np.percentile(dist, q)</code>	Computa o percentil q da distribuição bootstrap	<code>numpy</code>
<code>np.std(dist)</code>	Estima o erro padrão como desvio padrão da distribuição bootstrap	<code>numpy</code>
<code>bootstrap(data, func, ...)</code>	IC bootstrap de forma direta	<code>scipy.stats</code>
<code>resample(data, n_samples=n)</code>	Reamostragem com reposição	<code>sklearn.utils</code>

5 Resumo

Mensagem central

O bootstrapping é uma técnica não-paramétrica que usa a própria amostra como substituta da população, gerando reamostras com reposição para aproximar a distribuição amostral de qualquer estatística. Não exige suposições sobre a distribuição da população, sendo especialmente útil quando os pressupostos dos métodos paramétricos não podem ser verificados. Suas principais aplicações são a estimativa de viés, a estimativa do erro padrão, a construção de intervalos de confiança e a realização de testes de hipóteses.

Síntese: Bootstrapping

Aspecto	Detalhe
Classe do método	Não-paramétrico
Mecanismo central	Reamostragem com reposição da amostra original
Tamanho das reamostras	Igual ao da amostra original (n)
Número de reamostras	Tipicamente $B = 1\,000$ a $10\,000$
Aplicação 1	Estimativa de viés: $\widehat{\text{Viés}} = \bar{\theta}^* - \hat{\theta}$
Aplicação 2	Estimativa do erro padrão: $\widehat{SE} = \text{DP}(\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)})$
Aplicação 3	IC pelo método dos percentis: $[\hat{\theta}_{\alpha/2}^*, \hat{\theta}_{1-\alpha/2}^*]$
Aplicação 4	Teste de hipóteses: valor- p empírico via distribuição nula simulada
Limitação principal	Qualidade depende da representatividade da amostra original

6 Exercícios de Fixação

Exercício 1: Quando usar bootstrapping

Para cada situação abaixo, indique se o bootstrapping seria uma abordagem adequada ou desnecessária, justificando com base nas características dos dados e nas condições de aplicabilidade dos métodos paramétricos.

- (a) Uma amostra de $n = 200$ salários de trabalhadores formais, com distribuição fortemente assimétrica; deseja-se construir um IC para a mediana salarial.
- (b) Uma amostra de $n = 500$ alturas de adultos, com distribuição aproximadamente normal; deseja-se um IC para a média.
- (c) Uma amostra de $n = 15$ tempos de resposta de um sistema computacional, com presença de outliers; deseja-se testar se a mediana difere de um valor de referência.
- (d) Uma amostra de $n = 1\,000$ avaliações de produtos em escala Likert (1 a 5); deseja-se estimar o erro padrão da média.

Exercício 2: Reamostragem com reposição

Considere a amostra original $\{1, 3, 5, 7, 9\}$ com $n = 5$.

- (a) Quantas reamostras distintas são possíveis?
- (b) Gere manualmente (ou usando Python) cinco reamostras de tamanho 5 com reposição.
- (c) Calcule a média de cada reamostra gerada.
- (d) Estime o erro padrão da média a partir dessas cinco reamostras e compare com o valor teórico $s/\sqrt{n}$.
- (e) Repita o procedimento com $B = 1\,000$ reamostras e compare novamente com o valor teórico. O que se observa?

Exercício 3: IC para a mediana

Um biólogo mediu o comprimento (em cm) de 30 peixes de uma espécie nativa de um rio. Os dados estão disponíveis no arquivo `bootstrap/peixes.csv`.

- (a) Calcule a mediana observada.
- (b) Usando $B = 10\,000$ reamostras, construa um IC de 95% para a mediana pelo método dos percentis.
- (c) Estime o erro padrão da mediana.
- (d) Interprete o intervalo de confiança em linguagem acessível ao biólogo.
- (e) Construa também o IC pelo método `scipy.stats.bootstrap` e verifique se os resultados são compatíveis.

Exercício 4: IC para a diferença de medianas

Um pesquisador deseja comparar os tempos de resolução de dois tipos de tarefas cognitivas (A e B) em experimentos de usabilidade. Os dados estão no arquivo `bootstrap/tarefas.csv`.

- (a) Calcule a diferença observada entre as medianas dos dois grupos.
- (b) Use bootstrapping para construir um IC de 95% para essa diferença.
- (c) Com base no intervalo obtido, o pesquisador pode afirmar que existe diferença entre os tipos de tarefa? Justifique.
- (d) Por que, nesse contexto, a mediana pode ser mais informativa do que a média?

Exercício 5: Estimativa de viés

Um estudante aplicou o bootstrapping para estimar o viés do estimador $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ (variância amostral com denominador n , e não $n - 1$) usando uma amostra de tamanho $n = 20$.

- (a) Explique por que esse estimador é teoricamente enviesado.
- (b) Usando Python e $B = 5\,000$ reamostras, estime o viés via bootstrapping.
- (c) Calcule a estimativa corrigida $\hat{\sigma}_{\text{corrigido}}^2$.
- (d) Compare o resultado com o estimador não-enviesado $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

Exercício 6: Teste de hipóteses bootstrap

Um professor quer testar se o desempenho médio em uma prova difere entre dois grupos de alunos: os que estudaram com material impresso e os que usaram apenas recursos digitais. Os dados estão no arquivo `bootstrap/desempenho.csv`.

- (a) Formule as hipóteses H_0 e H_a .
- (b) Calcule a diferença observada entre as médias dos dois grupos.
- (c) Realize o teste de hipóteses via bootstrapping com $B = 10\,000$ reamostras e $\alpha = 0,05$.
- (d) Calcule o valor- p e tome a decisão.
- (e) Compare o resultado com o teste t paramétrico. Os resultados são compatíveis?

Exercício 7: Interpretação de resultados bootstrap

Um analista obteve os seguintes resultados ao aplicar bootstrapping a um conjunto de dados com $n = 80$:

Quantidade	Valor
Estatística observada $\hat{\theta}$	14,30
Média das reamostras $\bar{\theta}^*$	14,47
Desvio padrão das reamostras	1,82
Percentil 2,5% da distribuição bootstrap	10,88
Percentil 97,5% da distribuição bootstrap	17,93

- (a) Qual é o IC de 95% pelo método dos percentis?
- (b) Qual é a estimativa do erro padrão de $\hat{\theta}$?
- (c) Qual é a estimativa bootstrap do viés? O estimador tende a superestimar ou subestimar o parâmetro?
- (d) Calcule a estimativa corrigida do viés.
- (e) Se o valor de referência para H_0 fosse $\theta_0 = 12$, e o IC não incluísse esse valor, o que isso implicaria para o teste de hipóteses?