Teste de Permutação

Nota de Aula 08

Prof. Eduardo Bezerra

Conteúdo

1 Introdução **2**
1.1 Quando usar o teste de permutação? . . . 3
1.2 Hipóteses e princípio central . . . 3
1.3 Qual hipótese está sendo testada? . . . 4
1.4 Quando usar o teste t de Welch? . . . 5

2 Geração da Distribuição Nula por Permutação **7**
2.1 Procedimento . . . 7
2.2 Exemplo ilustrativo . . . 7
2.3 Quantidade de redistribuições possíveis . . . 8

3 Distribuição Nula e Valor-p **9**

4 Procedimento de Aplicação **10**

5 Exemplos **11**
5.1 Exemplo 1: Teste de randomização para um programa de treinamento . . . 12
5.2 Exemplo 2: Teste de randomização bilateral para peso entre dietas . . . 14
5.3 Exemplo 3: Dados categóricos: diferença de proporções . . . 16
5.4 Exemplo 4: Diferença de médias com variâncias distintas . . . 17

6 Resumo **20**

7 Exercícios de Fixação **21**

Objetivos

Ao final da leitura, você deve ser capaz de:

Introdução

- Explicar quando e por que o teste de permutação é uma alternativa adequada aos testes paramétricos.
- Distinguir igualdade de distribuições, hipótese nula aguda em experimentos randomizados e igualdade de médias.
- Descrever o princípio central do teste: se H_0 é verdadeira, as etiquetas de grupo são intercambiáveis.

Geração da distribuição nula $\star$

- Descrever o procedimento passo a passo para gerar a distribuição nula por permutação.
- Calcular o número total de redistribuições possíveis dos rótulos para grupos de tamanhos n_1 e n_2.
- Explicar por que, na prática, utiliza-se um número B fixo de permutações em vez de enumerar todas.
- Calcular o valor-p empírico a partir da distribuição nula e interpretar o resultado.

Aplicação e implementação em Python $\star$

- Aplicar o procedimento completo do teste de permutação a dados reais ou simulados.
- Distinguir entre teste unicaudal e bilateral e identificar qual usar em cada contexto.
- Implementar o teste de permutação em Python usando `numpy`.
- Interpretar a distribuição nula e o valor-p no contexto do problema.
- Escolher, dados o alvo inferencial, o desenho e a variabilidade dos grupos, entre a permutação irrestrita, o teste t de Welch e a permutação da estatística studentizada, justificando a escolha.

Estas notas estão organizadas em cinco partes. A Seção 1 apresenta a motivação e os fundamentos do teste de permutação. A Seção 2 descreve o procedimento para gerar a distribuição nula por permutação e calcula o número de redistribuições possíveis dos rótulos. A Seção 3 apresenta a relação entre a distribuição nula e o valor-p. A Seção 4 detalha o procedimento completo de aplicação do teste. A Seção 5 traz exemplos com código Python. Os objetivos marcados com $\star$ são os mais centrais.

1 Introdução

Testes de hipótese para dois grupos procuram responder se a diferença observada em uma característica de interesse pode ser explicada pela variação compatível com a hipótese nula. Nesta seção, apresentamos a ideia que distingue o teste de permutação: em vez de recorrer a uma distribuição teórica para a estatística, construímos uma referência redistribuindo os rótulos que identificam os grupos. Para isso, precisamos explicitar quando tal redistribuição é justificável.

1.1 Quando usar o teste de permutação?

Em notas anteriores, estudamos abordagens paramétricas para comparar amostras: o z-teste, o t-teste e a ANOVA. Esses métodos usam modelos e aproximações cuja adequação deve ser avaliada em relação ao desenho da coleta, ao tamanho amostral e à forma dos dados.

O *teste de permutação* (*permutation test*) é uma alternativa não-paramétrica que constrói uma distribuição de referência redistribuindo os rótulos dos grupos. Em sua forma básica para duas amostras independentes, ele requer observações independentes e rótulos intercambiáveis sob a hipótese nula. Ele é especialmente útil quando:

- os tamanhos amostrais são pequenos e aproximações assintóticas são pouco confiáveis;
- uma hipótese nula de distribuição comum ou um esquema de alocação aleatória justifica a intercambiabilidade;
- se deseja usar uma estatística escolhida para a pergunta, como diferença de médias, medianas ou proporções.

O método não elimina a necessidade de examinar o desenho de coleta. Antes de permutar, é preciso identificar qual é a unidade que poderia ter recebido outro rótulo sob H_0. Em dados pareados, por exemplo, os dois valores do mesmo participante ou da mesma unidade devem permanecer juntos: podemos trocar os rótulos dentro de cada par ou inverter o sinal de cada diferença, mas não misturar livremente todos os valores. Em dados agrupados, como alunos de uma mesma turma, pacientes de um mesmo hospital ou pessoas da mesma família, as observações de um grupo tendem a ser correlacionadas; a permutação deve respeitar os agrupamentos ou ocorrer dentro dos blocos usados na alocação. Em séries temporais, embaralhar pontos isolados destrói a dependência entre instantes próximos e possíveis tendências; nesse caso, seriam necessários esquemas que preservem blocos temporais. Em suma, só são permitidas redistribuições que reproduzam a aleatorização do estudo ou a intercambiabilidade plausível sob a hipótese nula.

Pergunta 1

Considere duas situações:

(a) Uma amostra de $n_1 = 200$ e outra de $n_2 = 180$ observações, ambas com distribuição aproximadamente normal.

(b) Uma amostra de $n_1 = 8$ e outra de $n_2 = 7$ observações, sem evidência de normalidade.

Em qual das situações o teste de permutação seria mais recomendado em relação ao t-teste? Explique quais condições adicionais sobre o alvo da inferência ou o desenho seriam necessárias para justificar sua escolha.

1.2 Hipóteses e princípio central

Considere duas amostras independentes, em que cada observação está associada a um rótulo que identifica seu grupo. Dizemos que os rótulos são *intercambiáveis* sob uma

hipótese quando, mantendo fixos os valores observados e os tamanhos dos grupos, trocar os rótulos entre as observações não torna uma atribuição mais ou menos plausível do que outra. Em outras palavras, sob essa hipótese, qualquer redistribuição dos rótulos que preserve n_1 observações em um grupo e n_2 no outro é compatível com o mesmo mecanismo gerador dos dados.

Para a permutação irrestrita dos rótulos, uma hipótese nula suficiente é:

- H_0: os grupos têm a mesma distribuição populacional; equivalentemente, sob o modelo adotado, os rótulos são intercambiáveis.
- H_a: as distribuições populacionais diferem.

Uma diferença de médias, de medianas ou de proporções pode ser escolhida como estatística para detectar evidência contra essa hipótese. Entretanto, igualdade apenas de médias não implica, em geral, intercambiabilidade se os grupos puderem diferir em dispersão ou forma. Em experimentos com alocação aleatória, a intercambiabilidade decorre do próprio esquema de randomização sob a hipótese nula de nenhum efeito do tratamento.

O princípio central do teste é, portanto, comparar a divisão efetivamente observada com todas as divisões que seriam igualmente plausíveis sob H_0. Se a diferença observada for incomum entre essas redistribuições, ela será evidência contra a hipótese nula.

Essa argumentação sugere um procedimento natural para gerar a *distribuição nula por permutação*, que é o nome dado à distribuição de referência da estatística condicionalmente aos valores observados, supondo que H_0 é verdadeira. Quando todas as redistribuições são enumeradas, essa distribuição é exata; quando apenas parte delas é sorteada, obtemos uma aproximação de Monte Carlo.

Pergunta 2

Explique, com suas palavras, por que a intercambiabilidade dos rótulos é um argumento válido sob a hipótese nula de que as duas amostras provêm da mesma população.

1.3 Qual hipótese está sendo testada?

Antes de escolher uma estatística ou permutar os dados, é preciso responder duas perguntas: qual afirmação se deseja investigar e como os grupos foram formados? Essas respostas determinam o alvo da inferência, isto é, a propriedade da população ou o efeito causal sobre o qual será tomada uma decisão.

Use o seguinte roteiro:

1. Defina a variável-resposta e a pergunta substantiva. Queremos comparar toda a distribuição dos valores, avaliar o efeito de uma intervenção ou comparar apenas as médias?
2. Verifique o desenho. Os participantes foram alocados aleatoriamente ao tratamento e ao controle, ou os grupos já existiam antes da coleta?
3. Escolha uma hipótese e um procedimento que sejam compatíveis com a pergunta e com o desenho, como nos três casos a seguir.

Caso 1: igualdade de distribuições. Considere duas populações e seja Y a variável-resposta. Denotamos por F_1 e F_2 as funções de distribuição de Y nas populações 1 e 2, respectivamente. Assim, $F_1(t)$ é a probabilidade de uma observação do Grupo 1 ser menor ou igual a t. A hipótese

$$H_0 : F_1 = F_2$$

afirma que as populações têm a mesma distribuição: elas coincidem não só na média, mas também em dispersão, forma e caudas. Sob essa hipótese, em duas amostras independentes, os rótulos dos grupos são intercambiáveis. A permutação irrestrita dos rótulos fornece, então, um teste exato condicionalmente aos dados.

Caso 2: experimento randomizado. Suponha que o pesquisador sorteie cada participante para receber um tratamento ou um controle. A alocação aleatória faz com que, antes do tratamento, os grupos sejam comparáveis também em características não observadas, em média sobre as possíveis alocações. Por isso, se o protocolo for seguido, o desfecho for medido de modo comparável e não houver interferência relevante entre participantes, uma diferença sistemática após a intervenção pode ser atribuída causalmente ao tratamento.

O teste de randomização exato usa a *hipótese nula aguda*: cada participante teria exatamente o mesmo desfecho se recebesse o tratamento ou o controle. Sob essa hipótese, os valores observados permanecem fixos e apenas os rótulos sorteados podem mudar. Portanto, redistribuímos os rótulos de acordo com o mesmo esquema de alocação usado no experimento. Essa hipótese é mais forte do que afirmar que o efeito médio é zero.

Caso 3: igualdade apenas de médias. Se o interesse é apenas comparar as médias populacionais, escrevemos

$$H_0 : \mu_1 = \mu_2,$$

em que μ_1 e μ_2 são as médias de Y nas duas populações. Essa hipótese, isoladamente, não torna os rótulos intercambiáveis: os grupos podem ter a mesma média e variâncias, assimetrias ou caudas distintas. Nesse caso, o procedimento padrão é o teste t de Welch, cuja estatística é

$$T_W = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}.$$

Uma versão por permutação pode recalcular T_W em cada redistribuição. Ela é útil como aproximação sob condições assintóticas adequadas, mas não é um teste exato de $H_0 : \mu_1 = \mu_2$ quando as distribuições, ou apenas as variâncias, diferem. Portanto, "não-paramétrico" não significa "sem condições": a hipótese, o desenho e o esquema de permutação devem ser compatíveis.

1.4 Quando usar o teste t de Welch?

O Caso 3 mostrou que a permutação irrestrita não é, em geral, exata para $H_0 : \mu_1 = \mu_2$. Isso não basta para saber quando o teste t de Welch é a escolha apropriada: é preciso conhecer o que ele supõe e contra que alternativas deve ser comparado.

O procedimento. Para duas amostras independentes, o teste de Welch usa a estatística T_W do Caso 3. Sob $H_0 : \mu_1 = \mu_2$ e as condições abaixo, T_W é aproximadamente t de Student com ν graus de liberdade (aproximação de Welch–Satterthwaite):

$$\nu = \frac{\left(\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}\right)^2}{\dfrac{(s_1^2/n_1)^2}{n_1 - 1} + \dfrac{(s_2^2/n_2)^2}{n_2 - 1}}.$$

O valor-p bilateral é $\Pr(|t_\nu| \geq |T_W|)$.

Condições.

- As unidades são independentes, dentro de cada grupo e entre os grupos.
- O alvo da inferência é a comparação das médias, e não a distribuição inteira.
- As médias amostrais são aproximadamente normais: isso é razoável se as populações são aproximadamente normais ou se as amostras são grandes o bastante para o teorema central do limite. Com amostras pequenas e forte assimetria ou caudas pesadas, a aproximação t_ν deve ser vista com cautela.
- *Não* se exige igualdade de variâncias. É essa a vantagem do procedimento.

Welch e o teste t com variâncias iguais. O teste t usual (de Student) estima uma variância comum s_p^2 e supõe $\sigma_1^2 = \sigma_2^2$. Quando $n_1 = n_2$, as duas estatísticas coincidem numericamente; mudam apenas os graus de liberdade. Quando as variâncias são iguais, Welch perde muito pouco; quando são diferentes, especialmente com $n_1 \neq n_2$, Student pode errar o nível de significância, como mostra a simulação do Exemplo 5.4. Por isso o teste de Welch é a referência para duas médias independentes, e o teste de Student só se justifica quando a igualdade de variâncias decorre do desenho do estudo. Escolher entre os dois a partir de um teste prévio de igualdade de variâncias não é recomendável: como a escolha do teste final passa a depender dos dados, seu nível deixa de ser necessariamente o nominal; além disso, testes de variâncias são sensíveis a desvios de normalidade e têm pouco poder justamente em amostras pequenas.

Três pistas para o reconhecimento. Diante de um problema, responda nesta ordem:

1. **Qual é o alvo?** Distribuição inteira, efeito nulo para cada unidade (hipótese nula aguda) ou apenas as médias?
2. **Qual é o desenho?** Houve alocação aleatória que justifique permutar os rótulos? As unidades são independentes?
3. **Como são as variabilidades e os tamanhos?** Variâncias claramente distintas, sobretudo com tamanhos desiguais, afastam a permutação simples e favorecem Welch.

A Tabela 1, apresentada no procedimento de aplicação, resume as decisões.

Pergunta 3

Um colega propõe decidir entre o teste t de Student e o de Welch aplicando antes um teste de igualdade de variâncias. Por que é preferível usar Welch diretamente?

2 Geração da Distribuição Nula por Permutação

A intercambiabilidade dos rótulos fornece a justificativa conceitual do teste; falta transformá-la em um procedimento operacional. Nesta seção, partimos da divisão originalmente observada entre os grupos, redistribuímos os rótulos de modo compatível com H_0 e observamos como a estatística varia nessas atribuições hipotéticas. O resultado será a distribuição nula por permutação usada nas seções seguintes: exata quando todas as atribuições são enumeradas e aproximada quando apenas uma amostra delas é sorteada.

2.1 Procedimento

O procedimento a seguir se aplica quando a permutação irrestrita dos rótulos é justificada, isto é, sob igualdade de distribuições ou sob uma hipótese nula aguda em um experimento randomizado. As entradas são duas amostras de tamanhos n_1 e n_2.

1. **Calcule a estatística observada**: a estatística de interesse T_{obs} (por exemplo, diferença de médias $\bar{x}_1 - \bar{x}_2$, diferença de medianas, etc.) é calculada a partir das amostras originais.
2. **Agrupe as observações**: combine as observações das duas amostras em uma única amostra de tamanho $n_1 + n_2$.
3. **Permute aleatoriamente**: reorganize de forma aleatória a ordem dos dados agrupados.
4. **Recalcule a estatística**: divida a permutação nos grupos de tamanhos n_1 e n_2 e calcule a mesma estatística T escolhida no passo 1. Registre o resultado como $T^{(b)}$.
5. **Repita**: repita os passos 3 e 4 por B iterações, acumulando $T^{(1)}, T^{(2)}, \ldots, T^{(B)}$.
6. **Obtenha a distribuição nula**: se todas as redistribuições forem consideradas, esse conjunto será a distribuição nula exata condicional aos dados; se apenas B redistribuições forem sorteadas, será uma aproximação de Monte Carlo.

2.2 Exemplo ilustrativo

Antes de repetir o procedimento muitas vezes, é útil acompanhar uma única redistribuição de rótulos. Considere, portanto, um experimento em que nove participantes foram alocados aleatoriamente a uma nova interface (tratamento) ou à interface usual (controle). Quatro participantes receberam o tratamento e cinco permaneceram no controle. Após executar a mesma tarefa, registrou-se o tempo de conclusão, em minutos:

- Tratamento: $\{6,\ 19,\ 34,\ 15\}$
- Controle: $\{9,\ 21,\ 8,\ 53,\ 25\}$

Sob a hipótese nula de que a nova interface não altera o tempo de nenhum participante, os nove tempos permanecem fixos e os rótulos de tratamento e controle podem ser redistribuídos, sempre preservando quatro participantes no tratamento e cinco no controle.

Uma iteração do procedimento é a seguinte:

1. A média do tratamento é $\bar{x}_{\text{trat}} = 18{,}5$ e a do controle é $\bar{x}_{\text{cont}} = 23{,}2$. A diferença observada é $T_{\text{obs}} = \bar{x}_{\text{trat}} - \bar{x}_{\text{cont}} = -4{,}7$.

2. Agrupando as observações:

$$\{6,\ 19,\ 34,\ 15,\ 9,\ 21,\ 8,\ 53,\ 25\}$$

3. Uma possível permutação aleatória resulta em:

$$\{34,\ 21,\ 8,\ 25,\ 6,\ 19,\ 15,\ 9,\ 53\}$$

   Isso corresponde a uma nova atribuição dos rótulos: tratamento $R_{\text{trat}} = \{34, 21, 8, 25\}$ e controle $R_{\text{cont}} = \{6, 19, 15, 9, 53\}$.

4. A média do tratamento redistribuído é 22 e a do controle redistribuído é 20,4. A diferença é $d_1 = 22 - 20{,}4 = 1{,}6$.

Como há apenas $\binom{9}{4} = 126$ redistribuições distintas, neste exemplo podemos enumerá-las integralmente e obter a distribuição nula exata condicional aos dados. Em problemas com um número muito maior de redistribuições, sorteamos B delas, por exemplo $B = 10\,000$, para aproximar essa distribuição.

2.3 Quantidade de redistribuições possíveis

O exemplo anterior mostra uma única redistribuição. Para compreender quando é possível obter a distribuição nula exata e quando precisamos simulá-la, devemos contar quantas atribuições distintas dos rótulos preservam os tamanhos dos grupos.

Para grupos de tamanhos n_1 e n_2, existem $(n_1 + n_2)!$ permutações possíveis dos dados agrupados. Contudo, como a ordem dos elementos *dentro* de cada grupo não é relevante, o número de atribuições distintas dos rótulos é dado por:

$$\text{número de redistribuições} = \frac{(n_1 + n_2)!}{n_1!\, n_2!}$$

No exemplo acima, com $n_1 = 4$ e $n_2 = 5$:

$$\frac{9!}{4!\,5!} = \frac{9 \times 8 \times 7 \times 6}{4!} = 126$$

O número de redistribuições cresce rapidamente. Para grupos de mesmo tamanho, por exemplo, temos $\binom{10}{5} = 252$, $\binom{20}{10} = 184\,756$, $\binom{30}{15} = 155\,117\,520$ e $\binom{40}{20} = 137\,846\,528\,820$. Para conjuntos pequenos, podemos enumerar todas as redistribuições e obter um teste exato condicional aos dados; para conjuntos maiores, usamos um número fixo B de permutações aleatórias.

Quando sorteamos apenas B redistribuições em vez de enumerar todas, os resultados dependem parcialmente dos sorteios realizados. Se repetirmos a simulação com outra

semente, poderemos obter uma contagem K, um valor-p estimado ou um histograma ligeiramente diferentes. Essa variação causada pela simulação finita é chamada de *variabilidade de Monte Carlo*. Aumentar B tende a reduzi-la, mas não altera os dados observados nem corrige um desenho de coleta inadequado.

Pergunta 4

Considere duas amostras, uma de tamanho $n_1 = 5$ e outra de $n_2 = 6$.

(a) Qual é o número total de redistribuições possíveis dos rótulos?

(b) Neste caso, você enumeraria todas as redistribuições ou usaria uma simulação com B permutações? Justifique.

(c) Para um problema em que a enumeração completa não fosse viável, o que poderia variar ao repetir a simulação com outra semente? Como aumentar B afetaria essa variação?

3 Distribuição Nula e Valor-p

Depois de gerar a distribuição nula, ainda precisamos comparar a estatística observada com os valores que seriam esperados sob H_0. O valor-p resume essa comparação: ele quantifica quão frequente é obter, na distribuição nula, uma estatística tão extrema quanto a observada segundo o critério definido pela hipótese alternativa.

O valor-p do teste de permutação é definido da mesma forma que nos testes paramétricos: a probabilidade de obter o resultado observado da estatística de teste, ou um mais extremo segundo um critério definido previamente, supondo que a hipótese nula é verdadeira.

A diferença é que, no teste de permutação, a distribuição nula é obtida pelas redistribuições compatíveis com a hipótese nula ou pelo sorteio de uma parte delas. Quando todas as N redistribuições distintas são enumeradas, o valor-p condicional é a proporção K/N de estatísticas tão ou mais extremas que T_{obs}.

Quando usamos apenas B permutações aleatórias, K é uma contagem sujeita à variabilidade de Monte Carlo. Usaremos a convenção

$$\hat{p} = \frac{K+1}{B+1},$$

que inclui a atribuição observada entre as $B+1$ atribuições consideradas. Sob H_0, ela produz um valor-p Monte Carlo válido e evita relatar valor-p zero por causa de uma simulação finita; em relação ao valor-p exato, é levemente conservadora. Para uma estatística de diferença d e B permutações sorteadas, contamos K da seguinte forma:

- **Teste bilateral** (valores extremos nos dois sentidos):

$$K = \#\big(|d_b| \geq |T_{\text{obs}}|\big)$$

- **Teste unicaudal à direita** (valores grandes de d favorecem H_a):

$$K = \#\big(d_b \geq T_{\text{obs}}\big)$$

- **Teste unicaudal à esquerda** (valores pequenos de d favorecem H_a):

$$K = \#\big(d_b \leq T_{\text{obs}}\big)$$

Para um teste bilateral, a regra baseada em $|d_b| \geq |T_{\text{obs}}|$ é uma convenção natural quando a distribuição de permutação é aproximadamente simétrica. Com grupos de tamanhos diferentes e dados assimétricos, ela pode diferir da regra que dobra a menor probabilidade de cauda; o critério deve ser definido antes de examinar os dados.

Rejeita-se H_0 quando o valor-p apropriado ao esquema usado é menor ou igual a α. O valor-p não é a probabilidade de H_0 ser verdadeira.

Pergunta 5

Em um teste de permutação bilateral com $B = 10\,000$ permutações, a diferença de médias observada foi $T_{\text{obs}} = -46{,}67$. Das 10 000 permutações, 985 produziram $|d_b| \geq 46{,}67$.

(a) Qual é a estimativa Monte Carlo do valor-p usando $(K+1)/(B+1)$?

(b) Ao nível $\alpha = 0{,}05$, qual é a decisão do teste?

(c) Seria correto dizer que o valor-p representa a probabilidade de que H_0 seja verdadeira? Justifique.

4 Procedimento de Aplicação

As seções anteriores separaram os elementos do teste: justificativa da permutação, geração da distribuição nula e cálculo do valor-p. Agora os reunimos em uma sequência de aplicação. A ordem dos passos é importante: o alvo inferencial, o desenho, a estatística e a direção da alternativa devem ser definidos antes de examinar o resultado observado.

O procedimento completo do teste de permutação pode ser resumido nos seguintes passos:

1. **Defina o alvo inferencial**: explicite se a pergunta trata de igualdade de distribuições, de uma hipótese nula aguda em experimento randomizado ou apenas de igualdade de médias.

2. **Verifique o desenho**: assegure que as unidades sejam independentes e que a permutação irrestrita dos rótulos seja compatível com H_0. Para dados pareados ou agrupados, preserve essa estrutura. Para igualdade apenas de médias, os rótulos podem não ser intercambiáveis quando as variâncias diferem; nesse caso, use o teste t de Welch como referência principal (Subseção 1.4 e Tabela 1) e, se for útil, compare-o com a permutação da estatística studentizada. O Exemplo 5.4 ilustra ambos os procedimentos e mostra, por simulação, o custo de escolher mal.

3. **Defina a estatística de interesse** T (diferença de médias, de medianas, de proporções etc.) e formule as hipóteses antes de analisar os resultados, especificando se o teste é bilateral ou unicaudal.

4. **Calcule a estatística observada** T_{obs} a partir dos dados originais.

5. **Gere a distribuição nula** por permutação, somente quando o esquema escolhido for justificado:
   - combine os dados dos dois grupos;
   - permute aleatoriamente os dados combinados;
   - divida em dois grupos com os tamanhos originais n_1 e n_2;
   - calcule a estatística para essa redistribuição dos grupos;
   - repita B vezes (tipicamente $B = 10\,000$).
6. **Calcule o valor-p**: use K/N ao enumerar todas as redistribuições ou $(K+1)/(B+1)$ ao usar B permutações aleatórias.
7. **Tome a decisão**: rejeitar H_0 se $p \leq \alpha$.

A Tabela 1 sintetiza as escolhas de procedimento. A permutação studentizada não elimina as condições assintóticas: em amostras muito pequenas, ela também deve ser interpretada com cautela e comparada ao teste de Welch, não tratada como solução automática para não normalidade.

Tabela 1: Escolha do procedimento conforme o alvo, o desenho e a variabilidade.

Situação	**Procedimento**	**Validade**
Pergunta sobre a distribuição inteira ($F_1 = F_2$); unidades independentes	Permutação irrestrita, com estatística escolhida para a pergunta	Exata condicionalmente aos dados
Experimento randomizado; interesse em efeito nulo para cada unidade	Teste de randomização conforme a alocação	Exata para a hipótese nula aguda
Apenas médias; unidades independentes; médias aproximadamente normais; variâncias possivelmente distintas	Teste t de Welch	Aproximada; não exige variâncias iguais
Apenas médias; amostras pequenas ou muito assimétricas, em que a aproximação t_ν é duvidosa	Permutação da estatística studentizada, comparada ao Welch	Aproximada (assintótica); use com cautela em amostras muito pequenas
Apenas médias; variâncias e tamanhos comparáveis	Welch e permutação simples tendem a concordar	Escolha pouco consequente; declare a hipótese testada

5 Exemplos

Com o procedimento estabelecido, os exemplos seguintes mostram como a mesma mecânica de redistribuição assume interpretações diferentes conforme a hipótese e o desenho. Em todos eles, é necessário identificar as unidades, o alvo inferencial e o critério de extremos antes de interpretar o valor-p. Adotamos $\alpha = 0{,}05$ e $B = 10\,000$ permutações, salvo quando indicado de outro modo.

5.1 Exemplo 1: Teste de randomização para um programa de treinamento

Uma empresa deseja avaliar a efetividade de um novo programa de treinamento para melhorar a produtividade dos funcionários. Para isso, selecionou 60 funcionários e os alocou aleatoriamente, em grupos de 30, ao novo programa ou ao treinamento usual:

- Grupo de tratamento: funcionários que participaram do novo programa de treinamento.
- Grupo de controle: funcionários que receberam o treinamento usual.

Após um mês, a produtividade de cada funcionário foi medida por um escore padronizado (0 a 100). Nas amostras simuladas, as médias foram aproximadamente 49,4 para o controle e 54,1 para o grupo treinado.

Assim, a pergunta de pesquisa é se a diferença observada entre as médias é compatível com a alocação aleatória sob a hipótese de que o programa não afeta a produtividade de nenhum funcionário.

Hipóteses:

- H_0: para cada funcionário, a produtividade seria a mesma com o novo programa e com o treinamento usual.
- H_a: a hipótese nula aguda é falsa; o teste será unilateral porque a direção de interesse é aumento da produtividade média no grupo tratado.

Este é um teste de randomização unicaudal à direita: valores grandes de tratamento menos controle favorecem a direção de interesse. Sob a hipótese nula aguda e a alocação aleatória, os rótulos de grupo são intercambiáveis; se todas as atribuições previstas pelo desenho fossem enumeradas, a distribuição de referência e o valor-p seriam exatos para essa hipótese. Essa justificativa não requer igualdade de variâncias entre os grupos. Ela também não transforma o teste em um teste exato da hipótese mais fraca de igualdade apenas das médias.

A diferença observada entre as médias foi de $T_{\text{obs}} \approx 4{,}67$. Como o número de atribuições possíveis é grande, sorteamos 10 000 delas em vez de enumerá-las. Das permutações sorteadas, apenas 1 produz diferença de médias maior ou igual a 4,67. Pela convenção Monte Carlo, obtemos a estimativa $\hat{p} = (1 + 1)/(10\,000 + 1) \approx 0{,}0002$, que pode variar ligeiramente com outra semente.

Como $\hat{p} < \alpha = 0{,}05$, rejeitamos a hipótese nula aguda. Sob a alocação aleatória descrita, há evidência contra a ausência de efeito em todos os funcionários, e a diferença média observada favorece o grupo treinado. A inferência causal refere-se aos 60 funcionários do experimento; generalizá-la para uma população mais ampla exigiria um mecanismo de amostragem ou hipóteses adicionais.

A Listagem 1 mostra a implementação do teste unicaudal em Python.

Listagem 1: Teste de permutação unicaudal – programa de treinamento.

```
import numpy as np
import matplotlib.pyplot as plt
```

```python
def permutation_test_unilateral(treatment, control,
    num_permutations=10000):
    """Realiza um teste de permutacao unicaudal (tratamento >
        controle)."""
    observed_diff = np.mean(treatment) - np.mean(control)
    combined = np.concatenate([treatment, control])

    perm_diffs = np.empty(num_permutations)
    for i in range(num_permutations):
        permuted = np.random.permutation(combined)
        perm_treatment = permuted[:len(treatment)]
        perm_control = permuted[len(treatment):]
        perm_diffs[i] = np.mean(perm_treatment) - np.mean(
            perm_control)

    k = np.count_nonzero(perm_diffs >= observed_diff)
    p_value = (k + 1) / (num_permutations + 1)
    return observed_diff, perm_diffs, k, p_value

# Gerar dados simulados
np.random.seed(42)
treatment = np.random.normal(55, 5, 30)  # novo programa
control = np.random.normal(50, 5, 30)    # treinamento usual

observed_diff, perm_diffs, k, p_value = permutation_test_unilateral
    (
    treatment, control, num_permutations=10000)

print(f"Diferenca observada nas medias: {observed_diff:.2f}")
print(f"Permutacoes extremas: {k}")
print(f"P-valor (unilateral): {p_value:.4f}")
```

Pergunta 6

Com base no Exemplo 1:

(a) Por que o teste foi aplicado de forma unicaudal e não bilateral?

(b) O que significa a proporção de permutações cujo $d_b \geq T_{\text{obs}}$ ser muito pequena?

(c) Por que esse teste de randomização não exige igualdade de variâncias sob a hipótese nula aguda?

(d) A enumeração completa das atribuições teria o mesmo valor-p estimado por Monte Carlo? Explique.

(e) Qual seria a consequência de usar um teste bilateral em vez do unicaudal?

5.2 Exemplo 2: Teste de randomização bilateral para peso entre dietas

O conjunto de dados *ChickData* corresponde ao conjunto *chickwts* do R. Nele, filhotes recém-nascidos foram alocados aleatoriamente a seis rações; após seis semanas, seus pesos foram medidos. Consideraremos os dois grupos que receberam as rações *meatmeal* e *casein*, com 11 e 12 filhotes, respectivamente.

A pergunta substantiva é se os pesos seriam compatíveis com a alocação aleatória sob a hipótese de que, para cada filhote, as duas rações não alterariam seu peso. Usaremos a diferença de médias como estatística-resumo. Essa estatística é especialmente sensível a diferenças de localização: ela pode não detectar efeitos que alterem apenas a variância, a assimetria ou as caudas, mantendo médias semelhantes. Para investigar qualquer diferença distribucional, seria necessário escolher uma estatística adequada a esse objetivo, como a estatística de Kolmogorov–Smirnov ou uma distância de energia.

Hipóteses:

- H_0: para cada filhote, o peso seria o mesmo sob *meatmeal* e sob *casein*.
- H_a: essa hipótese nula aguda é falsa.

Este é um teste de randomização bilateral, pois valores positivos e negativos extremos da diferença de médias são evidência contra H_0. Sob a hipótese nula aguda, a permutação dos rótulos entre os 23 filhotes, preservando os tamanhos dos grupos, fornece uma referência exata condicional aos dados.

Como há $\binom{23}{11} = 1\,352\,078$ atribuições possíveis, a enumeração completa é possível em princípio, mas o código usa uma aproximação Monte Carlo. A alocação aleatória justifica a interpretação causal para a hipótese nula aguda; ela não torna o teste exato para a hipótese mais fraca de igualdade apenas das médias.

As médias amostrais são $\bar{x}_{meatmeal} \approx 276{,}91$ e $\bar{x}_{casein} \approx 323{,}58$. A diferença observada é $T_{\text{obs}} = -46{,}67$.

Com a semente usada no código, 964 das 10 000 permutações produzem $|d_b| \geq 46{,}67$, resultando em $\hat{p} = (964 + 1)/(10\,000 + 1) \approx 0{,}0965$.

Como $\hat{p} > \alpha = 0{,}05$, não rejeitamos a hipótese nula aguda. Com essa estatística, os dados não fornecem evidência suficiente de que as rações alterem o peso dos filhotes; isso não demonstra ausência de efeito ou igualdade das médias.

A Listagem 2 mostra a implementação do teste bilateral em Python, com a versão vetorizada usando NumPy.

Listagem 2: Teste de randomização bilateral – dietas de filhotes (*ChickData*).

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('../data/ChickData.csv')

grupo1 = df.loc[df['feed'] == 'meatmeal', 'weight'].values
grupo2 = df.loc[df['feed'] == 'casein', 'weight'].values

# Estatistica observada
```

```
observed_diff = np.mean(grupo1) - np.mean(grupo2)
print(f"Diferenca observada entre as medias: {observed_diff:.2f}")

# Teste de permutacao (versao vetorizada)
n_perm = 10000
combined = np.concatenate([grupo1, grupo2])
rng = np.random.default_rng(42)

idx = np.array([rng.permutation(len(combined)) for _ in range(
   n_perm)])
grupoA = combined[idx[:, :len(grupo1)]]
grupoB = combined[idx[:, len(grupo1):]]
diffs_perm = grupoA.mean(axis=1) - grupoB.mean(axis=1)

# p-valor bilateral
k = np.count_nonzero(np.abs(diffs_perm) >= abs(observed_diff))
p_val = (k + 1) / (n_perm + 1)
print(f"Permutacoes extremas: {k}")
print(f"p-valor (bilateral): {p_val:.4f}")

# Visualizacao
plt.hist(diffs_perm, bins=30, color='lightgray', edgecolor='black',
    density=True)
plt.axvline(observed_diff, color='red', linestyle='--',
            label=f'Obs. diff = {observed_diff:.2f}')
plt.axvline(-observed_diff, color='red', linestyle='--')
plt.title('Distribuicao de randomizacao da diferenca de medias')
plt.xlabel('Diferenca media (meatmeal - casein)')
plt.ylabel('Densidade')
plt.legend()
plt.show()

alpha = 0.05
if p_val <= alpha:
    print("Rejeitamos H0: evidencia contra a hipotese nula aguda.")
else:
    print("Nao rejeitamos H0: sem evidencia suficiente contra a
       hipotese nula aguda.")
```

Pergunta 7

Com base no Exemplo 2:

(a) Por que foi aplicado um teste bilateral e não unicaudal?

(b) A não rejeição de H_0 significa que as dietas não têm efeito? Justifique.

(c) Por que este resultado não deve ser interpretado como um teste exato de igualdade apenas das médias se as variâncias dos grupos puderem diferir?

(d) Que tipo de efeito essa estatística pode deixar de detectar? Que estatística poderia ser escolhida se o objetivo fosse detectar qualquer alteração na distribuição dos pesos?

(e) Se repetirmos o estudo com $n_1 = n_2 = 100$, preservando aproximadamente a mesma diferença e variabilidade, o que esperamos que aconteça tipicamente com o valor-p? Por que isso não é uma garantia para uma realização específica?

5.3 Exemplo 3: Dados categóricos: diferença de proporções

O teste de permutação também pode ser aplicado a dados categóricos. Um caso clássico é verificar se a proporção de sucessos difere entre dois grupos.

Uma empresa testou duas versões de uma campanha de marketing (Grupo A e Grupo B). Em cada grupo, registrou-se sucesso (1) ou fracasso (0) para $n = 50$ usuários por grupo.

A pergunta de pesquisa é se há evidência de que as taxas de sucesso diferem entre os dois grupos. Para uma variável binária, igualdade das proporções implica igualdade das distribuições Bernoulli; portanto, a permutação simples é compatível com essa hipótese, desde que as observações sejam independentes e os rótulos sejam intercambiáveis sob o desenho adotado.

Hipóteses:

- $H_0 : p_A = p_B$
- $H_a : p_A \neq p_B$

A diferença observada nas proporções de sucesso foi $T_{\text{obs}} \approx 0{,}28$ (28 pontos percentuais). Das 10 000 permutações, 60 produziram $|d_b| \geq 0{,}28$, resultando em $\hat{p} = (60 + 1)/(10\,000 + 1) \approx 0{,}0061$.

Como $\hat{p} < \alpha = 0{,}05$, rejeitamos H_0. Há evidência estatística de que as proporções de sucesso diferem entre os grupos A e B, sob as condições de independência e intercambiabilidade adotadas.

Listagem 3: Teste de permutação bilateral para diferença de proporções.

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)
```

```
group_A = np.random.binomial(n=1, p=0.30, size=50)  # 30% de
    sucesso
group_B = np.random.binomial(n=1, p=0.50, size=50)  # 50% de
    sucesso

# Estatistica observada: diferenca nas proporcoes de sucesso
obs_diff = np.mean(group_B) - np.mean(group_A)
print(f"Diferenca observada nas proporcoes: {obs_diff:.3f}")

# Teste de permutacao
combined = np.concatenate([group_A, group_B])
n_A = len(group_A)
n_permutations = 10000
perm_diffs = []

for _ in range(n_permutations):
    permuted = np.random.permutation(combined)
    perm_A = permuted[:n_A]
    perm_B = permuted[n_A:]
    diff = np.mean(perm_B) - np.mean(perm_A)
    perm_diffs.append(diff)

perm_diffs = np.array(perm_diffs)

# Valor-p bilateral por Monte Carlo
k = np.count_nonzero(np.abs(perm_diffs) >= np.abs(obs_diff))
p_value = (k + 1) / (n_permutations + 1)
print(f"Permutacoes extremas: {k}")
print(f"Valor-p (teste bilateral): {p_value:.4f}")
```

Pergunta 8

Com base no Exemplo 3:

(a) A estatística de teste usada aqui (diferença de proporções) é a mesma usada nos exemplos anteriores (diferença de médias)? Em que sentido elas se assemelham?

(b) Se a diferença observada fosse apenas de 5 pontos percentuais, o que esperaria acontecer com o valor-p?

(c) Como o teste de permutação se compara ao teste qui-quadrado de independência e ao teste exato de Fisher nesse tipo de problema?

5.4 Exemplo 4: Diferença de médias com variâncias distintas

Considere dois grupos independentes nos quais o interesse é exclusivamente comparar as médias de uma medida contínua. O Grupo 1 apresenta variabilidade menor do que o Grupo 2. Não há informação de que os grupos provenham da mesma distribuição, nem o desenho é um experimento randomizado com uma hipótese nula aguda. Portanto, a

permutação simples da diferença de médias não é um teste exato de $H_0 : \mu_1 = \mu_2$.

Neste cenário, adotamos o teste t de Welch como procedimento principal:

- $H_0 : \mu_1 = \mu_2$;
- $H_a : \mu_1 \neq \mu_2$.

Também podemos calcular uma referência por permutação para a estatística studentizada de Welch. Essa comparação ilustra uma aproximação por reamostragem, e não um teste exato sob igualdade apenas das médias. Com a semente do código, o teste de Welch produz $t \approx 2{,}37$ e $p \approx 0{,}0257$; a permutação studentizada produz $\hat{p} \approx 0{,}0178$. A simulação apresentada mais adiante (Listagem 5) mostra a consequência de usar, nesse cenário, a permutação não studentizada da diferença de médias; seu primeiro cenário reproduz os tamanhos e as variabilidades deste exemplo.

Listagem 4: Teste de Welch e permutação studentizada para médias com variâncias distintas.

```
import numpy as np
from scipy.stats import ttest_ind

rng = np.random.default_rng(2026)
grupo1 = rng.normal(loc=60, scale=4, size=40)
grupo2 = rng.normal(loc=50, scale=12, size=25)

# Procedimento principal para H0: medias populacionais iguais
t_welch, p_welch = ttest_ind(grupo1, grupo2, equal_var=False)
print(f"t de Welch: {t_welch:.3f}")
print(f"p-valor de Welch: {p_welch:.4f}")

def welch_statistic(x, y):
    se = np.sqrt(x.var(ddof=1) / len(x) + y.var(ddof=1) / len(y))
    return (x.mean() - y.mean()) / se

# Referencia por permutacao: aproximacao, nao teste exato para
   medias
observed_t = welch_statistic(grupo1, grupo2)
combined = np.concatenate([grupo1, grupo2])
n1 = len(grupo1)
n_perm = 10000
perm_t = np.empty(n_perm)

for b in range(n_perm):
    permuted = rng.permutation(combined)
    perm_t[b] = welch_statistic(permuted[:n1], permuted[n1:])

k = np.count_nonzero(np.abs(perm_t) >= abs(observed_t))
p_perm = (k + 1) / (n_perm + 1)
print(f"p-valor por permutacao studentizada: {p_perm:.4f}")
```

O que acontece se escolhermos mal? Para ver a consequência da escolha do procedimento, simulamos pares de amostras normais com médias *iguais* (isto é, $H_0 : \mu_1 = \mu_2$

verdadeira) e variâncias distintas, e registramos a fração de vezes em que cada método rejeita H_0 ao nível $\alpha = 0{,}05$. Se o método controla o erro tipo I, essa fração deve ficar próxima de 0,05. A Listagem 5 mostra o código, com $R = 2000$ réplicas e $B = 499$ permutações por réplica; o erro de simulação é de cerca de 0,005 para taxas próximas de 0,05.

Listagem 5: Simulação do erro tipo I: Welch, Student e permutações.

```
import numpy as np
from scipy.stats import ttest_ind

rng = np.random.default_rng(2026)

def dif_medias(x, y):
    return x.mean(axis=-1) - y.mean(axis=-1)

def t_welch(x, y):
    se = np.sqrt(x.var(axis=-1, ddof=1) / x.shape[-1]
                 + y.var(axis=-1, ddof=1) / y.shape[-1])
    return (x.mean(axis=-1) - y.mean(axis=-1)) / se

def p_perm(x, y, stat, B=499):
    comb = np.concatenate([x, y])
    n1 = len(x)
    idx = np.argsort(rng.random((B, len(comb))), axis=1)
    P = comb[idx]
    t_obs = stat(x, y)
    t_b = stat(P[:, :n1], P[:, n1:])
    k = np.count_nonzero(np.abs(t_b) >= abs(t_obs))
    return (k + 1) / (B + 1)

def simular(n1, s1, n2, s2, R=2000, alpha=0.05):
    rej = np.zeros(4)
    for _ in range(R):
        x = rng.normal(0, s1, n1)   # H0 verdadeira: medias iguais
        y = rng.normal(0, s2, n2)
        rej += [ttest_ind(x, y, equal_var=False).pvalue <= alpha,
                ttest_ind(x, y).pvalue <= alpha,
                p_perm(x, y, dif_medias) <= alpha,
                p_perm(x, y, t_welch) <= alpha]
    return rej / R

for n1, s1, n2, s2 in [(40, 4, 25, 12), (40, 12, 25, 4), (30, 8,
   30, 8)]:
    r = simular(n1, s1, n2, s2)
    print(f"n1={n1}, s1={s1}, n2={n2}, s2={s2}: "
          f"Welch={r[0]:.3f} Student={r[1]:.3f} "
          f"PermDif={r[2]:.3f} PermStud={r[3]:.3f}")
```

A Tabela 2 mostra três coisas:

- Com variâncias distintas e tamanhos desiguais, a permutação simples da diferença de médias se comporta como o teste de Student: rejeita uma H_0 verdadeira mais

Tabela 2: Taxa de rejeição de H_0 verdadeira ($\alpha = 0{,}05$) na simulação da Listagem 5.

Cenário	**Welch**	**Student**	**Perm. dif. médias**	**Perm. studentizada**
$n_1 = 40,\ s_1 = 4;\ n_2 = 25,\ s_2 = 12$ (grupo menor, maior variância)	0,048	**0,113**	**0,114**	0,054
$n_1 = 40,\ s_1 = 12;\ n_2 = 25,\ s_2 = 4$ (grupo maior, maior variância)	0,046	0,019	0,017	0,046
$n_1 = n_2 = 30,\ s_1 = s_2 = 8$ (variâncias iguais)	0,051	0,051	0,051	0,052

do que o dobro do nível nominal quando o grupo *menor* tem a maior variância e rejeita bem menos do que o nível quando o grupo *maior* tem a maior variância.

- Com variâncias e tamanhos iguais, as quatro abordagens coincidem na prática, e a escolha entre elas é pouco consequente.
- Welch e a permutação studentizada mantêm o nível próximo de 0,05 nos três cenários.

Esses resultados valem para populações normais; com amostras pequenas e forte assimetria, o desempenho de cada método deve ser verificado separadamente.

Pergunta 9

No Exemplo 4, por que o teste de Welch é o procedimento principal, enquanto a permutação da estatística studentizada deve ser interpretada como aproximação? Que informação adicional seria necessária para transformar o problema em um teste de randomização exato?

6 Resumo

O percurso da nota partiu da intercambiabilidade dos rótulos, construiu a distribuição nula por redistribuições e usou essa distribuição para calcular um valor-p. A escolha do procedimento, contudo, depende da pergunta: igualdade de distribuições, hipótese nula aguda em um experimento randomizado ou igualdade apenas de médias.

O teste de permutação é uma técnica não-paramétrica para comparar grupos, baseada na intercambiabilidade dos rótulos sob uma hipótese nula de distribuição comum ou sob o esquema de randomização de um experimento. Ele não dispensa independência das unidades nem permite ignorar pareamento, agrupamento ou dependência temporal. Sob igualdade apenas das médias, particularmente com variâncias distintas, a permutação simples não é em geral exata; o teste de Welch é a referência usual.

As escolhas principais estão sintetizadas a seguir.

Alvo	**Condição central**	**Procedimento**	**Validade**
Igualdade de distribuições	$F_1 = F_2$; unidades independentes	Permutação irrestrita de uma estatística escolhida	Exata condicionalmente aos dados
Efeito causal nulo	Alocação aleatória e hipótese nula aguda de nenhum efeito	Teste de randomização conforme o esquema de alocação	Exata para a hipótese nula aguda
Igualdade de médias	$\mu_1 = \mu_2$; unidades independentes; médias aproximadamente normais; variâncias podem diferir	Teste t de Welch	Aproximada (referência t_ν); não exige variâncias iguais
Igualdade de médias por reamostragem	Condições assintóticas adequadas	Permutação da estatística studentizada de Welch	Aproximada; não exata em geral
Dados pareados	Estrutura de pares preservada	Inversões de sinal ou permutações dentro dos pares	Depende da hipótese e do desenho
Valor-p por simulação	B redistribuições aleatórias	$\hat{p} = (K+1)/(B+1)$	Sujeito à variabilidade de Monte Carlo

7 Exercícios de Fixação

Os exercícios retomam cada etapa do raciocínio: formulação de hipóteses, identificação do desenho, construção da referência nula e interpretação da decisão. Ao resolvê-los, explicite sempre qual estrutura dos dados a permutação deve preservar e se o valor-p foi obtido por enumeração completa ou por simulação.

Exercício 1: Formulação de hipóteses

Para cada situação abaixo, (i) identifique as duas amostras, (ii) explicite se a pergunta é sobre distribuições, efeito causal ou apenas médias, (iii) formule as hipóteses, (iv) indique se o teste deve ser bilateral ou unicaudal e (v) indique qual procedimento seria justificável. Justifique.

(a) Um pesquisador quer saber se o novo método de ensino resulta em notas *maiores* do que o método tradicional, após alocar estudantes aleatoriamente aos métodos.

(b) Um farmacêutico quer verificar se um novo medicamento tem um tempo de ação *diferente* do medicamento padrão.

(c) Um ecologista quer saber se o comprimento médio de peixes capturados no rio A é *menor* do que no rio B.

Exercício 2: Cálculo do número de redistribuições

Para cada par de tamanhos amostrais abaixo, calcule o número de redistribuições possíveis dos rótulos e discuta se seria viável enumerar todas elas.

(a) $n_1 = 3$, $n_2 = 3$

(b) $n_1 = 5$, $n_2 = 5$

(c) $n_1 = 10$, $n_2 = 10$

(d) $n_1 = 20$, $n_2 = 20$

Exercício 3: Cálculo do valor *--p*

Em uma simulação de teste de permutação com $B = 10\,000$ permutações e diferença observada $T_{\text{obs}} = 8{,}3$, obteve-se a seguinte contagem de valores da estatística nas permutações:

Condição	Contagem
$d_b \geq 8{,}3$	187
$d_b \leq -8{,}3$	201
$\lvert d_b \rvert \geq 8{,}3$	388

(a) Qual é a estimativa Monte Carlo do valor-p para um teste unicaudal à direita, em que valores grandes da estatística favorecem H_a?

(b) Qual é a estimativa Monte Carlo do valor-p para o teste bilateral?

(c) Ao nível $\alpha = 0{,}05$, qual é a decisão em cada caso?

Exercício 4: Efetividade de dois algoritmos de ordenação

Um pesquisador mediu o tempo de execução (em milissegundos) dos algoritmos A e B nas mesmas 30 instâncias de entrada. Os dados estão no arquivo `data/permutation/algoritmos.csv`; valores com a mesma coluna `instancia` formam um par.

(a) Formule as hipóteses para a simetria da distribuição das diferenças pareadas $A - B$ em torno de zero e aplique um teste bilateral com $B = 10\,000$ inversões aleatórias de sinal.

(b) Calcule o valor-p e tome a decisão ao nível $\alpha = 0{,}05$, explicitando a condição de simetria usada para justificar as inversões.

(c) Visualize a distribuição nula e marque o valor observado.

(d) Compare o resultado com o de um t-teste pareado, que tem como alvo a média das diferenças. Os resultados são compatíveis? Discuta as hipóteses distintas dos dois procedimentos.

Exercício 5: Diferença de medianas

Em muitos contextos, a mediana é mais robusta do que a média como medida de tendência central. O arquivo `data/permutation/salarios.csv` contém salários de dois grupos independentes de trabalhadores, tratados neste exercício como intercambiáveis sob a hipótese de distribuições comuns.

(a) Aplique o teste de permutação usando a diferença de medianas como estatística de teste.

(b) Compare o resultado com o que seria obtido usando a diferença de médias.

(c) Em qual situação a diferença de medianas seria preferível à diferença de médias?

Exercício 6: Proporções em campanha de marketing

Um analista deseja comparar as taxas de conversão de duas campanhas de e-mail marketing (A e B). Os dados estão no arquivo `data/permutation/campanha.csv`, com uma coluna `grupo` (A ou B) e uma coluna `conversao` (0 ou 1). Antes do teste, discuta se os usuários podem ser considerados independentes e se a atribuição à campanha torna os rótulos intercambiáveis sob a hipótese nula.

(a) Formule as hipóteses e aplique o teste de permutação (bilateral) para a diferença de proporções.

(b) Calcule o valor-p e interprete o resultado no contexto do negócio.

(c) Qual seria a diferença entre usar o teste de permutação e o teste z para proporções?

Exercício 7: Interpretação de resultados

Um pesquisador aplicou um teste de permutação bilateral com $B = 10\,000$ e obteve os seguintes resultados:

Quantidade	**Valor**
Tamanho do grupo 1 (n_1)	15
Tamanho do grupo 2 (n_2)	18
Diferença observada T_{obs}	$-3{,}72$
Número de permutações com $\lvert d_b \rvert \geq 3{,}72$	823
Nível de significância α	0,05

(a) Qual é a estimativa Monte Carlo do valor-p usando $(K+1)/(B+1)$?

(b) Qual é a decisão do teste?

(c) O que significa, em linguagem cotidiana, o valor-p calculado?

(d) Se o pesquisador tivesse formulado previamente um teste unicaudal em que valores negativos da estatística favorecessem H_a, o valor-p seria maior ou menor? Por quê?

Exercício 8: Permutação simples ou Welch?

Uma empresa compara o gasto mensal (em reais) de clientes de dois planos. Os clientes foram observados em seus planos atuais; não houve alocação aleatória. As amostras são independentes:

	n	Média	Desvio-padrão
Plano 1	35	220	30
Plano 2	20	190	80

A pergunta é se o gasto médio difere entre os planos.

(a) Identifique o alvo inferencial e o desenho. A permutação irrestrita da diferença de médias é justificável aqui? Por quê?

(b) Qual procedimento você usaria como referência principal? Escreva a estatística, calcule seu valor com os dados da tabela e indique como obter a distribuição de referência.

(c) Consulte a Tabela 2. Que problema você esperaria de uma permutação simples da diferença de médias neste cenário? Por quê?

(d) Como você interpretaria uma permutação da estatística studentizada de Welch nesse contexto?

Exercício 9: Reconhecimento do procedimento

Para cada situação, (i) identifique o alvo inferencial (distribuição inteira, efeito nulo para cada unidade ou apenas médias), (ii) indique o procedimento mais adequado entre permutação irrestrita, teste de randomização, teste t de Welch e permutação studentizada, e (iii) justifique em poucas linhas.

(a) Uma equipe sorteou 24 usuários, 12 para cada versão de um botão de compra, e mediu o tempo para concluir a tarefa. Deseja saber se a nova versão alterou o tempo de algum usuário.

(b) Amostras independentes de 35 funcionários da empresa X (desvio-padrão de R$ 4,1 mil) e 20 da empresa Y (desvio-padrão de R$ 11,8 mil). Deseja-se saber se o salário médio difere entre as empresas.

(c) Duas turmas (18 e 22 alunos) fizeram a mesma prova. O professor quer saber se as distribuições de notas diferem, e não apenas as médias.

(d) Dois lotes de 150 peças cada, com diâmetros aproximadamente simétricos e desvios-padrão praticamente iguais. Deseja-se saber se o diâmetro médio difere entre os lotes.

(e) Dois grupos independentes de 9 e 8 observações, muito assimétricos e com valores extremos. O interesse é apenas comparar as médias.