Regressão Linear

Nota de Aula 09

Prof. Eduardo Bezerra

Conteúdo

1 Covariância e Correlação **3**
1.1 Variância e Covariância . . . 3
1.2 Coeficiente de Correlação de Pearson . . . 5
1.3 Diagrama de Dispersão . . . 6
1.4 O Quarteto de Anscombe . . . 6
1.5 Exemplo resolvido: Idade e Peso de Crianças . . . 6
1.6 Implementação em Python . . . 8

2 O Método dos Mínimos Quadrados (OLS) **9**
2.1 Ideia central . . . 10
2.2 Resíduos e a Função de Perda . . . 10
2.3 Derivação das Estimativas OLS . . . 12

3 Regressão Linear Simples **15**
3.1 Modelo Probabilístico . . . 16
3.2 Modelo Populacional e Reta Estimada . . . 17
3.3 Erros Aleatórios e Resíduos . . . 17
3.4 Suposições do Modelo . . . 18

4 Regressão Linear Múltipla **19**
4.1 O Modelo de Regressão Linear Múltipla . . . 19
4.2 Interpretação dos Coeficientes . . . 20
4.3 Estimação dos Coeficientes por OLS . . . 22
4.4 Formulação Matricial . . . 23
4.5 Da Construção do Modelo à Sua Avaliação . . . 24

5 Exemplos Completos **24**
5.1 Exemplo 1: Horas de Estudo e Nota Final . . . 24
5.2 Exemplo 2: Regressão Múltipla — Tempo de Entrega . . . 25

6 Resumo **26**

7 Exercícios de Fixação **29**
7.1 Exercício 1: Covariância e correlação . . . 29
7.2 Exercício 2: Derivação e cálculo das estimativas OLS . . . 29
7.3 Exercício 3: Qualidade do ajuste e decomposição da variância . . . 29
7.4 Exercício 4: Inferência: testes e intervalos . . . 30
7.5 Exercício 5: Diagnóstico: identificar violações . . . 30
7.6 Exercício 6: Regressão Múltipla: preço de imóveis . . . 30
7.7 Exercício 7: Projeto computacional: regressão com dados reais . . . 31

Objetivos

Ao final do estudo desta nota, você deverá ser capaz de:

Covariância e Correlação (Seção 1)

- Calcular e interpretar a covariância amostral entre duas variáveis quantitativas.
- Calcular o coeficiente de correlação de Pearson e explicar sua relação com a covariância e os desvios padrões amostrais.
- Interpretar a direção e a intensidade de uma associação linear, utilizando também diagramas de dispersão.
- Reconhecer as limitações da correlação, especialmente diante de relações não lineares, observações atípicas e interpretações causais.

Método dos Mínimos Quadrados (OLS) $\star$ (Seção 2)

- Explicar como a regressão linear permite representar a associação entre duas variáveis por meio de uma reta.
- Definir resíduos e formular a soma dos quadrados dos resíduos como função de perda.
- Derivar as estimativas OLS do intercepto e da inclinação na regressão simples, utilizando as equações normais.
- Relacionar a inclinação estimada à covariância, à variância e ao coeficiente de correlação de Pearson.

Regressão Linear Simples $\star$ (Seção 3)

- Formular o modelo probabilístico de regressão linear simples e interpretar seus parâmetros.
- Distinguir o modelo populacional da reta estimada a partir dos dados amostrais.
- Diferenciar erros aleatórios de resíduos.
- Explicar as suposições do modelo, sintetizadas pelo acrônimo LINE, e sua importância para a inferência estatística.

Regressão Linear Múltipla $\star$ (Seção 4)

- Estender o modelo de regressão simples para incorporar múltiplas variáveis explicativas.
- Interpretar os coeficientes parciais, distinguindo associações marginais de associações condicionadas aos demais preditores.
- Formular o problema de estimação OLS para múltiplos preditores e expressar o modelo na forma matricial.
- Reconhecer as condições para a obtenção de uma solução OLS única e compreender o problema da multicolinearidade.

Aplicações e Interpretação de Resultados (Seção 5)

- Aplicar os conceitos de correlação e regressão linear a conjuntos de dados, com apoio de ferramentas computacionais.
- Interpretar equações ajustadas, valores previstos e coeficientes de regressão no contexto de problemas concretos.
- Interpretar resultados de avaliação e inferência apresentados nos exemplos, incluindo R^2, R^2 ajustado, testes de significância e medidas de incerteza.

A nota está organizada de modo a construir progressivamente os conceitos de regressão linear. Inicialmente, a Seção 1 apresenta a covariância e a correlação como instrumentos para investigar associações entre variáveis quantitativas. A Seção 2 introduz o método dos mínimos quadrados e mostra como estimar uma reta a partir dos dados. Em seguida, a Seção 3 apresenta o modelo probabilístico de regressão linear simples, enquanto a Seção 4 generaliza essa formulação para múltiplas variáveis explicativas. A Seção 5 reúne aplicações numéricas e computacionais; a Seção 6 sintetiza os principais conceitos; e a Seção 7 propõe atividades para consolidar o aprendizado. Os tópicos marcados com $\star$ constituem o núcleo conceitual da nota.

1 Covariância e Correlação

Antes de prever o valor de uma variável a partir de outra, precisamos responder a uma pergunta mais básica: *as variáveis estão relacionadas?* Se o número de horas de estudo e a nota final não tiverem qualquer associação, nenhum modelo de regressão produzirá previsões úteis. Covariância e correlação são os instrumentos que quantificam essa associação para variáveis quantitativas.

1.1 Variância e Covariância

Definições. Seja $\{x_1, \ldots, x_n\}$ uma amostra de tamanho n de uma variável X com média $\bar{x}$.

Variância amostral de X:

$$s_X^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Mede a dispersão unidimensional dos dados ao redor da média.

Covariância amostral entre X e Y:

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

Mede se os desvios das duas variáveis em relação às suas médias tendem a ocorrer no mesmo sentido ou em sentidos opostos.

O divisor $n-1$ aparece porque os desvios em relação às médias amostrais não podem variar todos livremente: depois de conhecidos $n-1$ deles, o último é determinado pela condição de que sua soma seja zero. Assim, dizemos que há $n-1$ graus de liberdade. Sob

amostragem aleatória, o uso de $n-1$ também corrige o viés que surgiria ao substituir as médias populacionais desconhecidas pelas médias calculadas na própria amostra.

Pergunta 1

Analise o produto $(x_i - \bar{x})(y_i - \bar{y})$ para um ponto (x_i, y_i) genérico.

(a) Em que situações esse produto é positivo? Negativo? Nulo?

(b) O que acontece com a soma $\sum(x_i - \bar{x})(y_i - \bar{y})$ quando a maior parte dos pontos estiver no 1.º e 3.º quadrantes em torno do ponto $(\bar{x}, \bar{y})$?

(c) Por que dividimos por $n-1$ em vez de n?

A chave para entender a covariância é o sinal de cada produto $(x_i - \bar{x})(y_i - \bar{y})$. A Figura 1 ilustra essa ideia usando duas linhas tracejadas: a reta vertical $X = \bar{x}$ e a reta horizontal $Y = \bar{y}$. Essas linhas dividem o plano em quatro regiões, de acordo com os sinais dos desvios em relação às médias. Quando um ponto está à direita de $\bar{x}$ e acima de $\bar{y}$, ou à esquerda de $\bar{x}$ e abaixo de $\bar{y}$, os dois desvios têm o mesmo sinal e o produto é positivo, contribuindo para uma covariância positiva. Quando um ponto está à esquerda de $\bar{x}$ e acima de $\bar{y}$, ou à direita de $\bar{x}$ e abaixo de $\bar{y}$, os desvios têm sinais opostos e o produto é negativo.

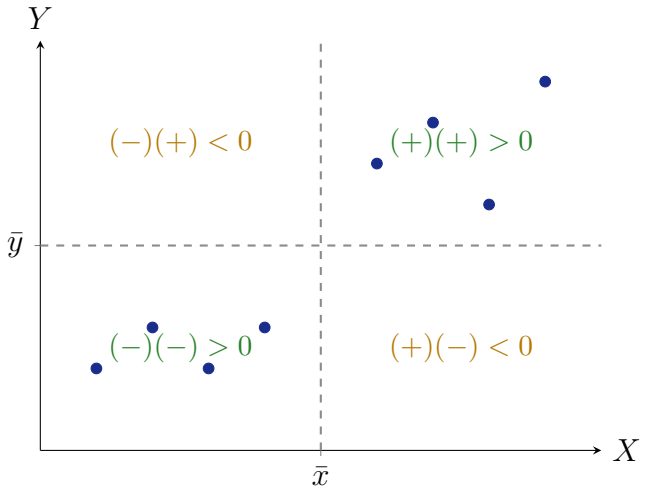


Figura 1: Sinal de $(x_i - \bar{x})(y_i - \bar{y})$ em cada região formada pelas linhas de referência $X = \bar{x}$ e $Y = \bar{y}$. Quando os pontos se concentram nas regiões superior direita e inferior esquerda, os desvios tendem a ter o mesmo sinal, contribuindo para uma covariância positiva. Quando se concentram nas regiões superior esquerda e inferior direita, os desvios tendem a ter sinais opostos, contribuindo para uma covariância negativa.

A covariância conserva as unidades das variáveis: se X for multiplicada por uma constante positiva c, s_{XY} também será multiplicada por c. Essa alteração de escala não modifica a posição relativa dos pontos nem o padrão de associação entre X e Y; modifica apenas o valor numérico usado para medi-lo.

Pergunta 2

Se convertermos a variável X de metros para centímetros (multiplicando por 100), como isso afeta s_{XY}? O relacionamento real entre X e Y mudou?

1.2 Coeficiente de Correlação de Pearson

A covariância tem, portanto, uma limitação prática importante: seu valor depende das unidades de medida de X e Y. Isso dificulta comparar a intensidade de associações entre estudos que usam escalas diferentes.

A solução é *normalizar* a covariância, dividindo pelos desvios-padrão de cada variável. Isso remove a dependência das unidades e confina o resultado ao intervalo $[-1, +1]$.

Coeficiente de Correlação de Pearson. O coeficiente de correlação de Pearson entre X e Y é:

$$r = \frac{s_{XY}}{s_X \cdot s_Y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Por construção, $r \in [-1, +1]$. O sinal indica a direção da associação; o valor absoluto indica a força.

A Figura 2 resume uma escala prática para interpretar o valor de r. Valores próximos de -1 indicam associação linear negativa forte, enquanto valores próximos de $+1$ indicam associação linear positiva forte. Valores próximos de zero sugerem ausência de associação linear, embora ainda possa existir uma relação não-linear entre as variáveis. Os limites entre "fraca", "intermediária" e "forte" não devem ser interpretados como universais: eles dependem do contexto substantivo, da área de aplicação e da variabilidade esperada nos dados.

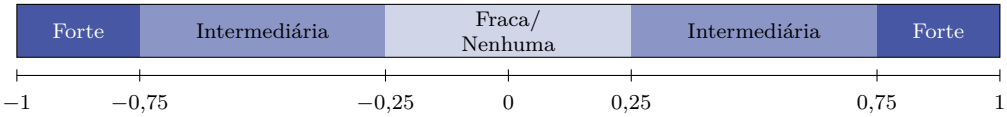


Figura 2: Escala de interpretação do coeficiente de correlação de Pearson r. Valores negativos indicam associação inversa; valores positivos, associação direta. A fronteira exata entre "fraca" e "intermediária" varia por domínio de aplicação.

Correlação não implica causalidade. Uma correlação alta entre X e Y significa apenas que as variáveis variam de forma associada na amostra observada. Não significa que X causa Y, nem que Y causa X. A associação pode ser espúria (devida a uma terceira variável confundidora), coincidencial, ou refletir uma relação de causa reversa. Para afirmar causalidade, são necessários delineamento experimental adequado ou métodos específicos de inferência causal.

1.3 Diagrama de Dispersão

O diagrama de dispersão (*scatter plot*) é a representação gráfica da associação entre duas variáveis quantitativas. Cada observação (x_i, y_i) é representada por um ponto no plano cartesiano, sem que os pontos sejam unidos por segmentos.

A Figura 3 ilustra três configurações típicas de diagramas de dispersão. No painel esquerdo, os pontos se distribuem próximos de uma reta crescente, caracterizando correlação positiva forte. No painel central, a tendência é decrescente, indicando correlação negativa forte. No painel direito, não há uma direção linear clara: os pontos aparecem espalhados sem formar uma tendência crescente ou decrescente, o que é compatível com um coeficiente de correlação próximo de zero.

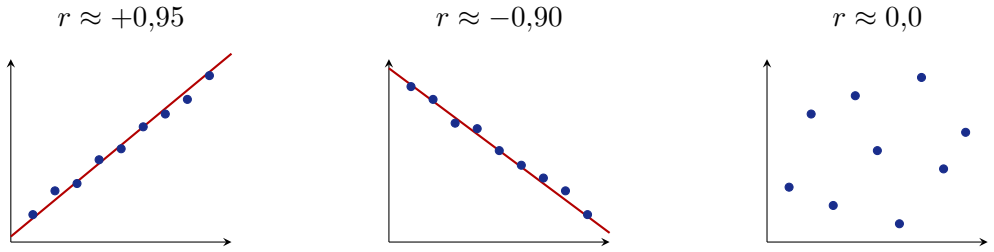


Figura 3: Três padrões típicos de diagrama de dispersão. Esquerda: associação positiva forte. Centro: associação negativa forte. Direita: ausência de associação linear.

A inspeção visual do diagrama deve *sempre* preceder o cálculo de r: o coeficiente captura apenas a componente linear da associação, e o gráfico pode revelar padrões não-lineares, outliers ou subgrupos que r sozinho não detecta.

1.4 O Quarteto de Anscombe

Francis Anscombe (1973) construiu quatro conjuntos de dados com exatamente os mesmos valores de r, $\bar{x}$, $\bar{y}$, s_X e s_Y, mas com padrões gráficos completamente distintos: um linear, um curvilíneo, um com outlier influente e um com ponto de alavanca. O quarteto é uma demonstração clássica de que resumos numéricos sozinhos podem ser enganosos. **Sempre construa o diagrama de dispersão antes de interpretar r.**

A Figura 4 mostra os quatro conjuntos do Quarteto de Anscombe. No primeiro painel, os pontos seguem aproximadamente uma tendência linear crescente, compatível com a interpretação usual de um coeficiente de correlação alto. No segundo, a relação é claramente curvilínea; no terceiro, um único outlier altera fortemente a percepção do padrão; e, no quarto, quase todos os pontos têm o mesmo valor de x, sendo a aparente associação linear sustentada por um único ponto de alavanca. O exemplo evidencia por que o cálculo de r deve ser acompanhado da inspeção visual do diagrama de dispersão.

1.5 Exemplo resolvido: Idade e Peso de Crianças

Uma amostra de 6 crianças fornece os seguintes dados de idade (em anos) e peso (em kg):

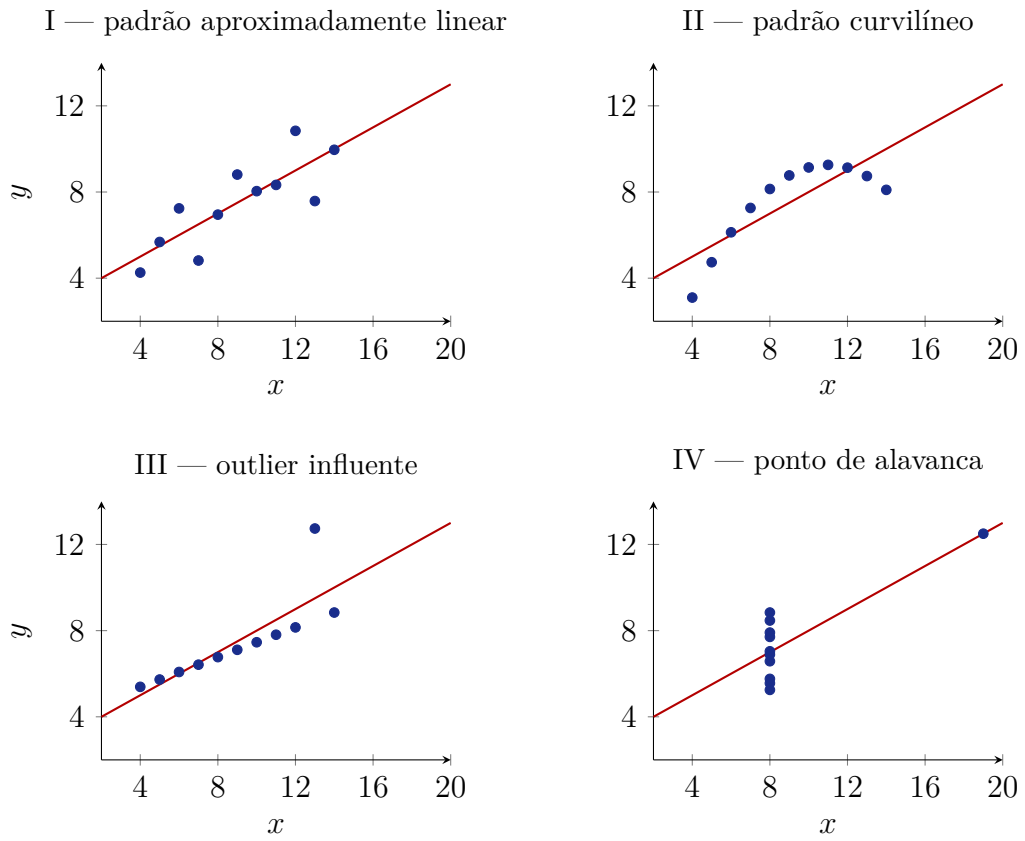


Figura 4: O Quarteto de Anscombe. Os quatro conjuntos de dados possuem os mesmos valores de correlação, médias, variâncias e a mesma reta de regressão linear ajustada, mas exibem padrões gráficos muito diferentes: no painel I, a relação é aproximadamente linear; no painel II, há curvatura; no painel III, um outlier influencia fortemente a análise; e no painel IV, um ponto de alavanca sustenta a aparente relação linear. A figura reforça que o diagrama de dispersão deve sempre ser inspecionado antes da interpretação de resumos numéricos.

id	**Idade** (x_i)	**Peso** (y_i)
1	7	12
2	6	8
3	8	12
4	5	10
5	6	11
6	9	13

Antes de calcular o coeficiente de correlação, devemos inspecionar o diagrama de dispersão. A Figura 5 mostra que os pontos apresentam uma tendência geral crescente: crianças mais velhas tendem a ter maior peso. Apesar disso, a associação não é perfeita, pois há variação de peso entre crianças com idades próximas ou iguais. O gráfico, portanto, sugere que faz sentido calcular uma medida de associação linear, como o coeficiente de correlação de Pearson.

Após a inspeção visual, podemos calcular o coeficiente de correlação. As médias são

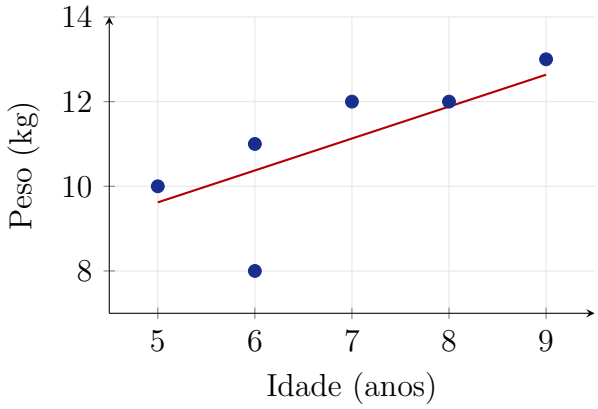


Figura 5: Diagrama de dispersão entre idade e peso das crianças. O padrão geral é crescente, sugerindo associação linear positiva, embora não perfeita.

$\bar{x} = 41/6 \approx 6{,}833$ e $\bar{y} = 66/6 = 11{,}0$.

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	0,167	1,0	0,028	1,0	0,167
2	−0,833	−3,0	0,694	9,0	2,500
3	1,167	1,0	1,361	1,0	1,167
4	−1,833	−1,0	3,361	1,0	1,833
5	−0,833	0,0	0,694	0,0	0,000
6	2,167	2,0	4,694	4,0	4,333
Σ			10,833	16,0	10,000

$$r = \frac{10{,}000}{\sqrt{10{,}833} \times \sqrt{16{,}0}} = \frac{10{,}000}{3{,}292 \times 4{,}000} \approx 0{,}759.$$

O valor $r \approx 0{,}759$ indica uma associação linear positiva de intensidade moderada a forte. Essa interpretação é compatível com o padrão observado na Figura 5: em geral, crianças mais velhas tendem a ser mais pesadas, mas os pontos não estão perfeitamente alinhados sobre uma reta.

1.6 Implementação em Python

O cálculo do coeficiente de correlação pode ser realizado diretamente em Python. A implementação a seguir usa os mesmos dados do exemplo anterior, com idade representada pela variável `x` e peso pela variável `y`. O código tem três objetivos didáticos: primeiro, calcular a covariância amostral e obter r a partir da definição; segundo, comparar esse resultado com a função `pearsonr` da biblioteca `scipy`; terceiro, construir o diagrama de dispersão, reforçando que a interpretação de r deve ser acompanhada da inspeção visual dos dados.

Listing 1: Cálculo do coeficiente de correlação de Pearson e construção do diagrama de dispersão em Python.

```python
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import pearsonr

# Dados: idade (x) e peso (y)
x = np.array([7, 6, 8, 5, 6, 9])
y = np.array([12, 8, 12, 10, 11, 13])

# Covariancia amostral entre x e y
cov_xy = np.cov(x, y, ddof=1)[0, 1]

# Desvios-padrao amostrais
sx = np.std(x, ddof=1)
sy = np.std(y, ddof=1)

# Correlacao calculada pela definicao
r_manual = cov_xy / (sx * sy)

# Correlacao via scipy
# pearsonr tambem retorna o p-valor do teste H0: rho = 0
r, p_valor = pearsonr(x, y)

print(f"Covariancia amostral = {cov_xy:.4f}")
print(f"r calculado manualmente = {r_manual:.4f}")
print(f"r via scipy = {r:.4f}")
print(f"p-valor = {p_valor:.4f}")

# Diagrama de dispersao
plt.figure(figsize=(5, 4))
plt.scatter(x, y, color='steelblue', zorder=3)
plt.xlabel("Idade (anos)")
plt.ylabel("Peso (kg)")
plt.title(f"Diagrama de dispersao (r = {r:.3f})")
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

A Listagem 1 mostra que o cálculo manual e a função `pearsonr` produzem o mesmo valor de r, como esperado. A diferença é que `pearsonr` também retorna um p-valor associado ao teste $H_0 : \rho = 0$, isto é, ao teste de ausência de correlação linear populacional. Neste ponto das notas, o foco principal não está ainda no teste de hipótese, mas na interpretação descritiva da associação. Por isso, o valor de r deve ser lido em conjunto com o diagrama de dispersão produzido pelo código: os pontos sugerem uma tendência crescente, embora não perfeitamente linear, compatível com uma correlação positiva moderada a forte.

2 O Método dos Mínimos Quadrados (OLS)

Na seção anterior, vimos que o coeficiente de correlação de Pearson permite avaliar a direção e a intensidade da associação linear entre duas variáveis quantitativas. Por exemplo,

um valor positivo e elevado de r indica que valores maiores de X tendem a estar associados a valores maiores de Y. Entretanto, a correlação não nos informa diretamente quanto Y tende a variar quando X aumenta uma unidade, nem fornece uma equação para estimar Y a partir de um valor conhecido de X.

2.1 Ideia central

Considere, por exemplo, um conjunto de observações que relaciona as horas de estudo de alunos (X) às notas obtidas em uma avaliação (Y). Um coeficiente de correlação positivo indica que alunos que estudam mais horas tendem a obter notas maiores. Contudo, essa informação não permite, por si só, estimar a nota de um aluno que estudou durante cinco horas. Para isso, precisamos descrever matematicamente como os valores de Y variam em função de X.

Uma possibilidade é representar essa relação por uma reta, especialmente quando o diagrama de dispersão sugere uma tendência aproximadamente linear. A equação dessa reta é

$$\hat{y} = b_0 + b_1 x,$$

em que $\hat{y}$ representa o valor ajustado de Y para um dado valor de x, enquanto b_0 e b_1 são os coeficientes que determinam a posição e a inclinação da reta.

O coeficiente b_0, denominado *intercepto*, corresponde ao valor ajustado de Y quando $x = 0$. Já o coeficiente b_1, denominado *inclinação*, indica quanto o valor ajustado de Y aumenta ou diminui quando X cresce uma unidade. Por exemplo, se $b_1 = 1{,}5$, a reta indica um aumento de 1,5 ponto na nota para cada hora adicional de estudo. Essa interpretação descreve uma associação entre as variáveis, mas não implica, por si só, uma relação de causa e efeito.

Assim, enquanto a correlação fornece uma medida da associação linear, a equação da reta permite descrever essa associação na escala original dos dados. Entretanto, ainda precisamos responder a uma questão fundamental: *como determinar os coeficientes b_0 e b_1 a partir das observações?*

Em geral, os pontos de um diagrama de dispersão não estão perfeitamente alinhados. Podemos, portanto, traçar diferentes retas para representar a tendência dos dados, cada uma passando mais perto de alguns pontos e mais longe de outros. Para escolher uma delas, precisamos estabelecer um critério objetivo que permita avaliar a qualidade do ajuste.

Portanto, a ideia central do OLS é comparar os valores observados de Y com aqueles fornecidos por cada reta candidata. Na próxima subseção, veremos como medir essas diferenças e utilizá-las para identificar a reta que melhor se ajusta aos dados segundo o critério dos mínimos quadrados.

2.2 Resíduos e a Função de Perda

Considere uma reta candidata, definida pela equação $\hat{y} = b_0 + b_1 x$. Para cada observação (x_i, y_i), podemos calcular o valor ajustado $\hat{y}_i = b_0 + b_1 x_i$ e compará-lo com o valor observado y_i. A diferença entre esses valores é denominada *resíduo*:

$$e_i = y_i - \hat{y}_i = y_i - (b_0 + b_1 x_i).$$

Geometricamente, o resíduo corresponde à distância vertical, com sinal, entre um ponto observado e a reta. Quando $e_i > 0$, o ponto está acima da reta; quando $e_i < 0$, está abaixo. Quanto menor a magnitude do resíduo, mais próximo o ponto está do valor fornecido pela reta.

Uma reta que representa bem os dados deve, em geral, produzir resíduos de pequena magnitude. Entretanto, precisamos considerar todas as observações, e não apenas um ponto isolado. Surge, então, a necessidade de definir uma medida que reúna os resíduos em um único valor e permita comparar diferentes retas.

Uma possibilidade seria somar diretamente os resíduos. Esse procedimento, porém, apresenta uma dificuldade: resíduos positivos e negativos podem se cancelar, produzindo uma soma pequena mesmo quando vários pontos estão distantes da reta. Para evitar esse cancelamento, podemos utilizar os quadrados dos resíduos.

O *método dos mínimos quadrados ordinários* (*Ordinary Least Squares*, OLS) adota justamente esse critério. Para uma reta com coeficientes b_0 e b_1, definimos a *soma dos quadrados dos resíduos* (SQE) por

$$\mathrm{SQE}(b_0, b_1) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} \left[y_i - (b_0 + b_1 x_i)\right]^2 .$$

Essa expressão é denominada *função de perda*, pois quantifica a discrepância total entre os valores observados e os valores ajustados pela reta. Cada escolha dos coeficientes b_0 e b_1 determina uma reta e, consequentemente, um valor para a SQE. Quanto menor esse valor, melhor é o ajuste segundo o critério quadrático.

A Figura 6 ilustra duas ideias importantes. No painel esquerdo, os segmentos verticais representam os resíduos associados a uma reta candidata. No painel direito, a função $L(e) = e^2$ mostra como cada resíduo contribui para a perda total. Por exemplo, um resíduo de magnitude 1 contribui com 1 para a SQE, enquanto um resíduo de magnitude 2 contribui com 4. Portanto, dobrar a magnitude de um resíduo quadruplica sua contribuição para a perda.

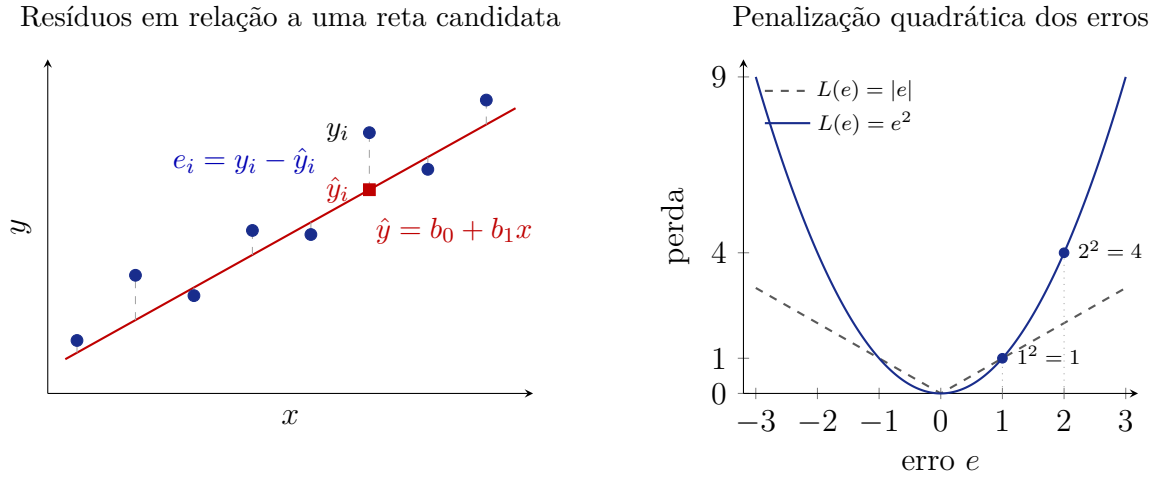


Figura 6: À esquerda, os segmentos verticais representam os resíduos em relação a uma reta candidata. À direita, a função de perda quadrática $L(e) = e^2$ mostra que resíduos maiores contribuem de forma desproporcionalmente maior para a soma dos quadrados dos resíduos. Para comparação, a linha tracejada representa a perda absoluta $L(e) = |e|$.

A figura também apresenta, para comparação, a função de perda absoluta $L(e) = |e|$.

Nesse caso, a penalização cresce proporcionalmente à magnitude do resíduo. As duas funções evitam o cancelamento entre erros positivos e negativos, mas atribuem pesos diferentes aos erros de maior magnitude.

A perda quadrática tem duas propriedades particularmente úteis para OLS. Ela penaliza de forma desproporcionalmente maior os resíduos de grande magnitude, embora isso também torne o ajuste mais sensível a valores atípicos. Além disso, é diferenciável em relação aos coeficientes da reta, o que permite localizar o mínimo da soma de perdas com derivadas. A perda absoluta também é um critério válido, mas conduz a um problema de otimização diferente.

Pergunta 3

A figura apresenta duas maneiras de penalizar os resíduos: a perda absoluta $L(e) = |e|$ e a perda quadrática $L(e) = e^2$.

1. Como a penalização muda quando a magnitude de um resíduo passa de 1 para 3, em cada função?
2. Qual das duas funções penaliza mais intensamente os resíduos de grande magnitude?
3. Que vantagem matemática a perda quadrática oferece para determinar os coeficientes da reta?

Essas propriedades explicam a escolha da perda quadrática no método OLS.

O método OLS consiste, portanto, em encontrar os valores de b_0 e b_1 que tornam a SQE a menor possível:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{b_0, b_1} \sum_{i=1}^{n} \left[y_i - (b_0 + b_1 x_i)\right]^2 .$$

Os valores $\hat{\beta}_0$ e $\hat{\beta}_1$ são os coeficientes estimados pelo método. Uma vez determinados, obtemos a *reta de mínimos quadrados*:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Resta descobrir como calcular esses coeficientes. Na próxima subseção, veremos que a minimização da SQE pode ser realizada por meio de derivadas, produzindo fórmulas explícitas para a inclinação e o intercepto da reta.

2.3 Derivação das Estimativas OLS

Na subseção anterior, definimos a soma dos quadrados dos resíduos (SQE) como uma medida da qualidade do ajuste de uma reta aos dados. O método OLS procura os coeficientes que minimizam essa função. Resta descobrir como calcular esses coeficientes.

Para uma reta candidata $\hat{y} = b_0 + b_1 x$, a função de perda é

$$\text{SQE}(b_0, b_1) = \sum_{i=1}^{n} \left[y_i - (b_0 + b_1 x_i)\right]^2 .$$

Observe que os valores x_i e y_i são conhecidos: eles correspondem às observações da amostra. As incógnitas são b_0 e b_1, pois diferentes escolhas desses coeficientes produzem diferentes retas e, consequentemente, diferentes valores para a SQE.

Como a SQE é uma função diferenciável dos dois coeficientes, podemos procurar seu mínimo calculando as derivadas parciais em relação a b_0 e b_1 e igualando-as a zero.

Passo 1: calcular as derivadas parciais. Derivando a SQE em relação ao intercepto b_0, obtemos

$$\frac{\partial \,\mathrm{SQE}}{\partial b_0} = -2\sum_{i=1}^{n}(y_i - b_0 - b_1 x_i).$$

De maneira semelhante, a derivada em relação à inclinação b_1 é

$$\frac{\partial \,\mathrm{SQE}}{\partial b_1} = -2\sum_{i=1}^{n} x_i(y_i - b_0 - b_1 x_i).$$

Igualando ambas as derivadas a zero e reorganizando os termos, chegamos ao sistema

$$\begin{aligned} nb_0 + b_1\sum_{i=1}^{n} x_i &= \sum_{i=1}^{n} y_i, \\ b_0\sum_{i=1}^{n} x_i + b_1\sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} x_i y_i. \end{aligned}$$

Essas expressões são conhecidas como *equações normais*. Elas estabelecem as condições que os coeficientes devem satisfazer para minimizar a SQE. Quando os valores de X não são todos iguais, o sistema possui uma solução única, que corresponde ao mínimo global da função de perda.

Passo 2: obter o intercepto em função da inclinação. Dividindo a primeira equação normal por n, temos

$$b_0 + b_1\frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

Reconhecendo as médias amostrais $\bar{x}$ e $\bar{y}$, obtemos

$$b_0 + b_1\bar{x} = \bar{y},$$

ou, equivalentemente,

$$b_0 = \bar{y} - b_1\bar{x}.$$

Essa expressão já revela uma propriedade importante: a reta estimada por OLS passa pelo ponto $(\bar{x}, \bar{y})$. Em outras palavras, quando substituímos $x = \bar{x}$ na equação da reta, o valor ajustado é exatamente $\bar{y}$.

Passo 3: obter a inclinação. Substituindo $b_0 = \bar{y} - b_1\bar{x}$ na segunda equação normal e reorganizando os termos, chegamos a

$$b_1 \left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^{\,2} \right) = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}.$$

Os termos entre parênteses podem ser escritos como somas de desvios em relação às médias:

$$\sum_{i=1}^{n} x_i^2 - n\bar{x}^{\,2} = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

e

$$\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}).$$

Portanto, a estimativa OLS da inclinação é

$$\boxed{\hat{\beta}_1 = \frac{\displaystyle\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\displaystyle\sum_{i=1}^{n} (x_i - \bar{x})^2}}$$

Uma vez calculada a inclinação, a estimativa do intercepto é obtida diretamente:

$$\boxed{\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}}$$

Assim, a reta de mínimos quadrados é dada por

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Essas fórmulas permitem determinar os coeficientes diretamente a partir das observações, sem precisar testar diferentes retas. Note também que a solução depende da variabilidade de X: se todos os valores de x_i forem iguais, o denominador da fórmula de $\hat{\beta}_1$ será zero, e não será possível determinar uma inclinação única.

Relação entre a inclinação e a correlação de Pearson. A fórmula da inclinação apresenta uma conexão direta com os conceitos estudados na seção anterior. Recordando que a covariância amostral e a variância amostral de X são, respectivamente,

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

e

$$s_X^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2,$$

podemos escrever

$$\hat{\beta}_1 = \frac{s_{XY}}{s_X^2}.$$

Como o coeficiente de correlação de Pearson é definido por $r = s_{XY}/(s_X s_Y)$, obtemos

$$\boxed{\hat{\beta}_1 = r\frac{s_Y}{s_X}}$$

Essa relação mostra que a inclinação da reta de regressão depende de dois elementos: a correlação entre as variáveis e a razão entre seus desvios padrões.

O coeficiente r determina o sinal da inclinação e expressa a intensidade da associação linear, enquanto o fator s_Y/s_X ajusta a inclinação às unidades de medida das variáveis. Por exemplo, se $r = 0{,}8$, $s_X = 2$ horas e $s_Y = 3$ pontos, teremos

$$\hat{\beta}_1 = 0{,}8 \cdot \frac{3}{2} = 1{,}2.$$

Nesse caso, a reta estimada indica um aumento de 1,2 ponto na nota para cada hora adicional de estudo. Observe que o coeficiente de correlação é adimensional, enquanto a inclinação é expressa em pontos por hora.

Essa relação também ajuda a compreender por que a regressão de Y sobre X não é equivalente à regressão de X sobre Y. Na primeira, minimizamos as diferenças verticais entre os valores observados e ajustados de Y; na segunda, minimizamos as diferenças na direção de X. Assim, inverter as variáveis altera o problema de otimização. Apenas no caso de associação linear perfeita ($|r| = 1$), com variabilidade em ambas as variáveis, as duas retas representam a mesma relação geométrica.

Pergunta 4

Considere duas variáveis quantitativas com correlação $r = 0{,}6$, desvios padrões $s_X = 4$ e $s_Y = 10$.

1. Qual é a inclinação da reta de regressão de Y sobre X?
2. Se medirmos X em uma unidade dez vezes menor, o valor de r muda? E o valor da inclinação?
3. O que aconteceria com a inclinação se a correlação fosse igual a zero?

3 Regressão Linear Simples

Na seção anterior, estudamos como o método dos mínimos quadrados ordinários (OLS) determina a reta que minimiza a soma dos quadrados dos resíduos. Para um conjunto de observações (x_i, y_i), essa reta é expressa por

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Os coeficientes $\hat{\beta}_0$ e $\hat{\beta}_1$ são calculados a partir da amostra e permitem descrever a tendência linear observada nos dados. Entretanto, o procedimento de minimização, por si só, não estabelece como essa relação varia de uma amostra para outra, nem permite quantificar a incerteza das estimativas.

Para avançar da descrição dos dados para a inferência estatística, precisamos de um modelo probabilístico. Esse modelo deverá representar não apenas a tendência linear entre as variáveis, mas também a variabilidade das observações em torno dessa tendência.

3.1 Modelo Probabilístico

Considere novamente o exemplo que relaciona as horas de estudo de alunos (X) às notas obtidas em uma avaliação (Y). Ainda que exista uma associação linear entre essas variáveis, dois alunos que estudam o mesmo número de horas podem obter notas diferentes. Isso ocorre porque a nota também depende de outros fatores, como conhecimento prévio, condições de realização da avaliação e características individuais.

O modelo de regressão linear simples representa essa situação por meio de duas componentes: uma componente sistemática, que descreve a relação linear entre as variáveis, e uma componente aleatória, que representa a variabilidade não explicada por essa relação.

Formalmente, para cada observação, escrevemos

$$\boxed{Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad i = 1, \ldots, n.}$$

Nessa expressão:

- x_i é o valor observado da variável explicativa X;
- Y_i é a variável aleatória que representa a resposta correspondente;
- β_0 e β_1 são parâmetros populacionais desconhecidos, denominados intercepto e inclinação, respectivamente;
- ε_i é o erro aleatório associado à i-ésima observação.

A componente $\beta_0 + \beta_1 x_i$ descreve a tendência sistemática da resposta. O erro aleatório ε_i representa o desvio da resposta em relação a essa tendência.

Assumindo que os erros têm média zero para cada valor de x_i, isto é, $E[\varepsilon_i \mid x_i] = 0$, obtemos

$$E[Y_i \mid x_i] = \beta_0 + \beta_1 x_i.$$

Essa expressão revela a interpretação central do modelo: *a reta populacional descreve o valor esperado de Y para cada valor de X*. Portanto, a regressão linear simples não pressupõe que todas as observações estejam sobre uma reta, mas que seus valores esperados sigam uma relação linear.

Nesse contexto, β_1 representa a variação no valor esperado de Y quando X aumenta uma unidade. Já β_0 representa o valor esperado de Y quando $X = 0$, desde que esse valor tenha significado no contexto estudado.

É importante observar que essa interpretação expressa uma associação estatística. A existência de uma inclinação diferente de zero não demonstra, por si só, que mudanças em X causam mudanças em Y.

3.2 Modelo Populacional e Reta Estimada

Agora podemos distinguir dois elementos que desempenham papéis diferentes na análise de regressão.

O *modelo populacional* descreve como as respostas são geradas:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

Os parâmetros β_0 e β_1 são desconhecidos. Eles caracterizam a relação linear que desejamos investigar na população.

A *reta estimada*, por outro lado, é calculada a partir dos dados amostrais pelo método OLS:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

Os coeficientes $\hat{\beta}_0$ e $\hat{\beta}_1$ são estimativas dos parâmetros populacionais. Consequentemente, $\hat{y}_i$ é uma estimativa do valor esperado da resposta para x_i.

Por exemplo, suponha que a reta estimada para a relação entre horas de estudo e notas seja

$$\hat{y} = 3 + 0{,}8x.$$

Para um aluno que estudou cinco horas, obtemos

$$\hat{y} = 3 + 0{,}8(5) = 7.$$

O resultado deve ser interpretado como uma estimativa da nota média dos alunos que estudam cinco horas, segundo o modelo. Isso não significa que todos esses alunos obterão nota 7, pois as notas individuais também apresentam variabilidade aleatória.

Além disso, como os coeficientes foram estimados a partir de uma amostra, existe incerteza sobre a própria reta. Se utilizássemos outra amostra, provavelmente obteríamos valores diferentes para $\hat{\beta}_0$ e $\hat{\beta}_1$.

Essa distinção será fundamental quando estudarmos a inferência em regressão linear: precisaremos considerar tanto a incerteza sobre os coeficientes estimados quanto a variabilidade das observações individuais.

3.3 Erros Aleatórios e Resíduos

A distinção entre modelo populacional e reta estimada também permite esclarecer a diferença entre **erro aleatório** e **resíduo**.

No modelo probabilístico, o erro aleatório representa o desvio da resposta em relação à reta populacional:

$$\varepsilon_i = Y_i - (\beta_0 + \beta_1 x_i).$$

Como os parâmetros populacionais são desconhecidos, não podemos calcular diretamente esses erros a partir dos dados.

Já o resíduo, apresentado na seção anterior, é a diferença entre o valor observado e o valor fornecido pela reta estimada:

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i).$$

Portanto, enquanto os erros aleatórios são componentes do modelo probabilístico, os resíduos são quantidades calculadas a partir da amostra.

Os resíduos fornecem informações sobre a variabilidade não explicada pela reta estimada. Por esse motivo, serão utilizados posteriormente para avaliar se as suposições do modelo são compatíveis com os dados.

3.4 Suposições do Modelo

Para realizar os procedimentos clássicos de inferência estatística em regressão linear, precisamos estabelecer algumas suposições sobre a relação entre as variáveis e o comportamento dos erros aleatórios.

Essas suposições são frequentemente resumidas pelo acrônimo **LINE**:

- **Linearidade (L):** o valor esperado da resposta é uma função linear da variável explicativa, isto é, $E[Y_i \mid x_i] = \beta_0 + \beta_1 x_i$. A suposição refere-se à relação média entre as variáveis, não à exigência de que todos os pontos estejam alinhados.
- **Independência (I):** os erros aleatórios $\varepsilon_1, \ldots, \varepsilon_n$ são mutuamente independentes. Essa suposição pode ser inadequada, por exemplo, quando as observações são coletadas sequencialmente no tempo ou pertencem a grupos com características compartilhadas.
- **Normalidade (N):** os erros aleatórios seguem uma distribuição normal com média zero. Essa suposição permite fundamentar as distribuições exatas utilizadas em testes de hipóteses e intervalos de confiança clássicos, especialmente em pequenas amostras.
- **Igualdade de variâncias (E):** os erros apresentam a mesma variância σ^2 para todos os valores da variável explicativa, isto é, $\mathrm{Var}(\varepsilon_i \mid x_i) = \sigma^2$. Essa propriedade é denominada *homocedasticidade*.

Em conjunto, essas suposições implicam que, para cada valor fixo de x_i, a resposta segue uma distribuição normal cuja média depende linearmente de x_i e cuja variância permanece constante:

$$\boxed{Y_i \mid x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2).}$$

Assim, para diferentes valores de X, temos distribuições de respostas com médias distintas, mas com a mesma dispersão. Geometricamente, podemos imaginar uma distribuição normal centrada em cada ponto da reta populacional, representando a variabilidade das respostas naquele valor de X.

É importante distinguir as suposições necessárias para ajustar a reta daquelas utilizadas para realizar inferência. O método OLS pode ser aplicado sem pressupor normalidade dos erros. A normalidade é uma condição adicional para determinados resultados inferenciais exatos, enquanto outras suposições, como a relação média linear e a independência dos erros, também desempenham papéis importantes na validade das conclusões.

As suposições do modelo não devem ser aceitas automaticamente. Sua plausibilidade depende do contexto de coleta dos dados e pode ser investigada por meio de ferramentas de diagnóstico, especialmente a análise dos resíduos.

Pergunta 5

Considere um modelo de regressão linear simples que relaciona horas de estudo (X) e notas de alunos (Y).

1. Se dois alunos estudarem o mesmo número de horas, o modelo exige que obtenham a mesma nota? Justifique.
2. Qual é a diferença entre o erro aleatório ε_i e o resíduo e_i?
3. Por que a normalidade dos erros não é necessária para calcular a reta OLS, mas é relevante para determinados procedimentos de inferência?

Até aqui, consideramos situações em que uma única variável explicativa é utilizada para descrever a resposta. Entretanto, muitos fenômenos dependem simultaneamente de diversos fatores. No exemplo das notas dos alunos, além das horas de estudo, outras variáveis, como frequência às aulas e conhecimento prévio, podem contribuir para explicar a variabilidade observada.

Na próxima seção, veremos como estender a regressão linear simples para incorporar várias variáveis explicativas em um mesmo modelo, mantendo a ideia central de uma relação linear e a estimação dos coeficientes pelo método dos mínimos quadrados.

4 Regressão Linear Múltipla

Na seção anterior, estudamos o modelo de regressão linear simples, no qual uma única variável explicativa X é utilizada para descrever o valor esperado de uma variável resposta Y. Entretanto, muitos fenômenos estão associados simultaneamente a diferentes fatores, de modo que uma única variável pode não ser suficiente para representar adequadamente a relação de interesse.

Considere, por exemplo, a relação entre as horas de estudo e as notas dos alunos. Embora as horas de estudo possam estar associadas ao desempenho, outros fatores, como a frequência às aulas e o conhecimento prévio, também podem contribuir para explicar as diferenças entre as notas. Se considerarmos apenas as horas de estudo, deixaremos de representar explicitamente essas outras fontes de variação.

A *regressão linear múltipla* estende a regressão simples para incorporar duas ou mais variáveis explicativas em um mesmo modelo. A ideia central permanece a mesma: descrever o valor esperado de Y por meio de uma função linear e estimar seus coeficientes a partir dos dados.

4.1 O Modelo de Regressão Linear Múltipla

Suponha que desejamos descrever a nota de um aluno (Y) utilizando duas variáveis explicativas: horas de estudo (X_1) e frequência às aulas (X_2). Em vez de utilizar uma reta que depende apenas de X_1, podemos representar o valor esperado da nota por

$$E[Y \mid X_1 = x_1, X_2 = x_2] = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

Nesse modelo, cada variável explicativa possui um coeficiente próprio. O parâmetro β_1 descreve a associação entre horas de estudo e a nota esperada quando a frequência

às aulas é mantida constante. De maneira semelhante, β_2 descreve a associação entre frequência e nota esperada para um mesmo número de horas de estudo.

Essa ideia pode ser generalizada para p variáveis explicativas. O *modelo probabilístico de regressão linear múltipla* é definido por

$$\boxed{Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \qquad i = 1, \ldots, n.}$$

Nessa expressão:

- Y_i é a variável aleatória que representa a resposta da i-ésima observação;
- x_{ij} é o valor da j-ésima variável explicativa para a i-ésima observação;
- β_0 é o intercepto populacional;
- $\beta_1, \ldots, \beta_p$ são os coeficientes populacionais associados às variáveis explicativas;
- ε_i é o erro aleatório associado à observação.

Assim como na regressão simples, assumimos que os erros aleatórios possuem média condicional zero. Consequentemente,

$$E[Y_i \mid x_{i1}, \ldots, x_{ip}] = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij}.$$

Portanto, a regressão múltipla continua modelando o *valor esperado da resposta*. A diferença é que esse valor passa a depender de uma combinação de várias variáveis explicativas.

Observe também que o termo *linear* se refere à maneira como os parâmetros aparecem na equação: cada coeficiente multiplica um termo conhecido e os resultados são somados. Embora o modelo apresentado utilize diretamente as variáveis $X_1, \ldots, X_p$, também é possível incorporar transformações dessas variáveis, como X_1^2, preservando a linearidade nos parâmetros.

4.2 Interpretação dos Coeficientes

A principal diferença conceitual entre regressão simples e múltipla está na interpretação dos coeficientes.

Na regressão simples, a inclinação β_1 representa a variação no valor esperado de Y quando X aumenta uma unidade. Na regressão múltipla, precisamos acrescentar uma condição: *a interpretação de cada coeficiente pressupõe que as demais variáveis explicativas sejam mantidas constantes.*

Para compreender essa distinção, considere o seguinte modelo estimado para as notas dos alunos:

$$\hat{y} = 2 + 0{,}6x_1 + 0{,}03x_2,$$

em que x_1 representa as horas de estudo e x_2 representa a frequência às aulas, medida em pontos percentuais.

A interpretação dos coeficientes é a seguinte:

- $\hat{\beta}_0 = 2$: quando as horas de estudo e a frequência são ambas iguais a zero, o modelo fornece uma nota ajustada de 2. Essa interpretação só tem utilidade prática se essa combinação de valores for pertinente ao contexto e à região dos dados observados.
- $\hat{\beta}_1 = 0{,}6$: para alunos com a mesma frequência às aulas, uma hora adicional de estudo está associada a um aumento de 0,6 ponto na nota esperada.
- $\hat{\beta}_2 = 0{,}03$: para alunos com o mesmo número de horas de estudo, um aumento de um ponto percentual na frequência está associado a um aumento de 0,03 ponto na nota esperada.

Por exemplo, para um aluno que estuda cinco horas e possui frequência de 80%, o valor ajustado é

$$\hat{y} = 2 + 0{,}6(5) + 0{,}03(80) = 7{,}4.$$

Se aumentarmos as horas de estudo de cinco para seis, mantendo a frequência em 80%, o valor ajustado passará para

$$\hat{y} = 2 + 0{,}6(6) + 0{,}03(80) = 8{,}0.$$

A diferença entre os dois valores é de 0,6 ponto, exatamente o coeficiente associado às horas de estudo.

Os coeficientes da regressão múltipla são frequentemente chamados de *coeficientes parciais*, pois cada um descreve a associação de uma variável com a resposta, condicionada aos valores das demais variáveis incluídas no modelo.

Associação marginal e associação parcial. Essa distinção ajuda a compreender por que um coeficiente pode mudar quando acrescentamos variáveis a um modelo.

Imagine que alunos com maior frequência às aulas também tendam a estudar mais horas. Nesse caso, horas de estudo e frequência estão associadas entre si. Se ajustarmos uma regressão simples utilizando apenas horas de estudo, seu coeficiente poderá refletir tanto a associação das horas de estudo com a nota quanto parte da associação relacionada à frequência, que não foi incluída no modelo.

Ao acrescentarmos a frequência como segunda variável explicativa, a interpretação do coeficiente das horas de estudo muda: agora ele representa a associação com a nota entre alunos com a mesma frequência. Por isso, seu valor pode diferir daquele obtido na regressão simples.

Em termos gerais, a associação observada entre X_j e Y sem considerar outros preditores é denominada *associação marginal*. Já a associação descrita pelo coeficiente β_j de um modelo múltiplo é uma *associação parcial*, condicionada às demais variáveis incluídas.

É importante destacar que manter outras variáveis constantes na interpretação do modelo não significa que elas tenham sido controladas experimentalmente. A regressão múltipla permite realizar um ajuste estatístico, mas não garante, por si só, uma interpretação causal dos coeficientes.

Pergunta 6

Considere o modelo estimado

$$\hat{y} = 2 + 0{,}6x_1 + 0{,}03x_2,$$

em que x_1 representa horas de estudo e x_2 representa frequência às aulas, em pontos percentuais.

1. Qual é a nota ajustada para um aluno que estuda quatro horas e possui frequência de 90%?
2. Se a frequência permanecer constante, qual será a mudança na nota ajustada quando as horas de estudo aumentarem de quatro para seis?
3. Por que não podemos concluir, apenas com esse modelo, que estudar uma hora adicional causa um aumento de 0,6 ponto na nota?

4.3 Estimação dos Coeficientes por OLS

Embora a regressão múltipla contenha mais coeficientes, não precisamos desenvolver um novo critério de estimação. O método dos mínimos quadrados ordinários continua aplicável: procuramos os coeficientes que minimizam a soma dos quadrados dos resíduos.

Para um conjunto de coeficientes candidatos $b_0, b_1, \ldots, b_p$, o valor ajustado da i-ésima observação é

$$\hat{y}_i = b_0 + b_1 x_{i1} + \cdots + b_p x_{ip}.$$

O resíduo correspondente é

$$e_i = y_i - \hat{y}_i = y_i - \left(b_0 + \sum_{j=1}^{p} b_j x_{ij} \right).$$

Consequentemente, a função de perda é

$$\mathrm{SQE}(b_0, \ldots, b_p) = \sum_{i=1}^{n} \left(y_i - b_0 - \sum_{j=1}^{p} b_j x_{ij} \right)^2.$$

O método OLS escolhe os coeficientes que minimizam essa expressão:

$$\boxed{(\hat{\beta}_0, \ldots, \hat{\beta}_p) = \underset{b_0,\ldots,b_p}{\arg\min}\, \mathrm{SQE}(b_0, \ldots, b_p).}$$

Portanto, o princípio de estimação é exatamente o mesmo estudado na regressão simples. A diferença é que agora precisamos determinar $p + 1$ coeficientes simultaneamente, em vez de apenas dois.

Na regressão simples, foi possível obter fórmulas explícitas para a inclinação e o intercepto utilizando somas, médias e covariâncias amostrais. Na regressão múltipla, podemos organizar todas as equações em uma representação matricial, que permite expressar a solução de maneira compacta.

4.4 Formulação Matricial

Considere n observações e p variáveis explicativas. Podemos reunir os valores da resposta em um vetor e os valores dos preditores em uma matriz:

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \qquad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix}.$$

Definimos também os vetores dos parâmetros e dos erros aleatórios:

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \qquad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Com essa notação, o modelo probabilístico pode ser escrito como

$$\boxed{\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.}$$

A matriz $\mathbf{X}$, denominada *matriz de projeto* (*design matrix*), possui n linhas e $p+1$ colunas. Cada linha corresponde a uma observação, enquanto cada coluna, exceto a primeira, corresponde a uma variável explicativa. A primeira coluna contém apenas valores iguais a 1, permitindo incorporar o intercepto ao produto matricial.

A formulação matricial não representa um modelo diferente. Ela apenas reúne, em uma única expressão, as n equações do modelo de regressão múltipla.

Para estimar os coeficientes, substituímos o vetor aleatório $\mathbf{Y}$ pelo vetor de valores observados $\mathbf{y}$ e consideramos um vetor de coeficientes candidatos $\mathbf{b}$. A função de perda pode então ser escrita como

$$\mathrm{SQE}(\mathbf{b}) = (\mathbf{y} - \mathbf{X}\mathbf{b})^\top (\mathbf{y} - \mathbf{X}\mathbf{b}).$$

Essa expressão é equivalente à soma dos quadrados dos resíduos apresentada anteriormente. O produto de um vetor por sua transposta corresponde, nesse caso, à soma dos quadrados de seus elementos.

Assim como fizemos na regressão simples, podemos minimizar a função de perda calculando suas derivadas. A diferença é que agora derivamos em relação a todos os componentes de $\mathbf{b}$. A condição de mínimo produz as *equações normais* na forma matricial:

$$\mathbf{X}^\top \mathbf{X}\, \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

Se a matriz $\mathbf{X}^\top\mathbf{X}$ for invertível, podemos isolar o vetor de coeficientes estimados:

$$\boxed{\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.}$$

Essa fórmula generaliza as expressões obtidas para o intercepto e a inclinação na regressão simples. Em ambos os casos, as estimativas são escolhidas para minimizar a soma dos quadrados dos resíduos.

Na prática, programas estatísticos costumam calcular os coeficientes utilizando métodos numéricos, como fatorações matriciais, que evitam calcular explicitamente a inversa de $\mathbf{X}^\top\mathbf{X}$.

Quando a solução é única? A expressão anterior exige que as colunas da matriz de projeto sejam linearmente independentes. Isso significa que nenhuma coluna pode ser representada exatamente como uma combinação linear das demais.

Por exemplo, se incluíssemos duas variáveis explicativas tais que $X_2 = 2X_1$ para todas as observações, seus valores carregariam a mesma informação. Nesse caso, não seria possível determinar separadamente coeficientes únicos para as duas variáveis utilizando OLS.

Essa situação é denominada *multicolinearidade perfeita*. Quando ela ocorre, a matriz $\mathbf{X}^\top\mathbf{X}$ não é invertível e a fórmula apresentada não pode ser utilizada para obter uma solução única.

Mesmo quando não existe dependência linear perfeita, preditores fortemente associados entre si podem dificultar a estimação precisa de seus coeficientes individuais. Esse fenômeno, chamado de *multicolinearidade*, será examinado posteriormente ao estudarmos as limitações e o diagnóstico dos modelos de regressão.

4.5 Da Construção do Modelo à Sua Avaliação

Vimos que a regressão múltipla amplia o modelo simples ao permitir que o valor esperado da resposta dependa de várias variáveis explicativas. Apesar dessa ampliação, os dois modelos compartilham a mesma estrutura probabilística básica e o mesmo princípio de estimação por mínimos quadrados.

A diferença está principalmente no número de coeficientes e em sua interpretação: na regressão múltipla, cada coeficiente descreve uma associação parcial, isto é, condicionada aos demais preditores incluídos no modelo.

Entretanto, obter uma equação ajustada não é suficiente para concluir que o modelo representa adequadamente os dados. Ainda precisamos responder a perguntas como: *quanto da variabilidade de Y é explicada pelo modelo? A inclusão de novos preditores realmente melhora o ajuste? Quanta incerteza existe sobre os coeficientes estimados?*

Essas perguntas são relevantes tanto para a regressão simples quanto para a múltipla. Por isso, nas próximas seções, estudaremos de maneira integrada os procedimentos de avaliação do ajuste, inferência estatística e diagnóstico dos modelos de regressão linear.

5 Exemplos Completos

Nos exemplos a seguir, adotamos $\alpha = 0{,}05$.

Como reportar um modelo de regressão. Um relatório completo deve conter: a equação ajustada; os erros padrão ou intervalos de confiança dos coeficientes; a significância de cada coeficiente (t e p-valor); R^2 (e R^2_{ajust} em modelos múltiplos); o resultado do teste F global; o erro padrão da regressão S; e uma interpretação substantiva no contexto do problema.

5.1 Exemplo 1: Horas de Estudo e Nota Final

Situação-problema. Um professor registrou o número de horas semanais de estudo (X) e a nota final (Y, de 0 a 100) de 9 alunos:

x_i	2	3	4	5	6	7	8	9	10
y_i	55	60	62	68	72	75	80	83	88

(1) Correlação. $\bar{x} = 6{,}0$, $\bar{y} = 71{,}44$. Calculando: $\sum(x_i - \bar{x})(y_i - \bar{y}) = 163{,}0$, $\sum(x_i - \bar{x})^2 = 60{,}0$, $\sum(y_i - \bar{y})^2 = 451{,}6$.

$$r = \frac{163{,}0}{\sqrt{60{,}0 \times 451{,}6}} = \frac{163{,}0}{164{,}5} \approx 0{,}991 \quad \text{(correlação direta muito forte)}$$

(2) Estimativas OLS.

$$\hat{\beta}_1 = \frac{163{,}0}{60{,}0} \approx 2{,}717 \qquad \hat{\beta}_0 = 71{,}44 - 2{,}717 \times 6{,}0 \approx 55{,}14$$

Equação ajustada: $\hat{y} = 55{,}14 + 2{,}717\,x$.

(3) Qualidade do ajuste. $R^2 = r^2 \approx 0{,}982$: o modelo explica 98,2% da variabilidade das notas.

$$\text{SSE} = \sum(y_i - \hat{y}_i)^2 \approx 8{,}1, \qquad S = \sqrt{8{,}1/(9-2)} \approx 1{,}075.$$

(4) Inferência sobre β_1.

$$\text{EP}(\hat{\beta}_1) = \frac{1{,}075}{\sqrt{60}} \approx 0{,}1388, \qquad t = \frac{2{,}717}{0{,}1388} \approx 19{,}57$$

p-valor ≈ 0 (com $t_{7;0{,}025} = 2{,}365$). Rejeitamos H_0: o número de horas de estudo tem efeito linear significativo sobre a nota.

(5) Interpretação. Para cada hora adicional de estudo por semana, a nota média esperada aumenta em aproximadamente 2,7 pontos. O intercepto 55,14 seria a nota prevista para um aluno que estuda zero horas — mas como $x = 0$ está fora do intervalo dos dados (2–10 horas), essa extrapolação não deve ser interpretada literalmente.

5.2 Exemplo 2: Regressão Múltipla — Tempo de Entrega

Situação-problema. Uma empresa de logística quer modelar o tempo de entrega (em horas) em função da distância percorrida (km) e do número de paradas intermediárias.

Entrega	**Distância (km)**	**Paradas**	**Tempo (h)**
1	100	1	3,2
2	150	2	5,1
3	200	1	4,8
4	200	3	7,0
5	250	2	6,5
6	300	3	8,2
7	300	1	6,0
8	350	4	10,1

(1) Modelo ajustado (via OLS).

$$\hat{y} = 0{,}215 + 0{,}0178\,(\text{distância}) + 1{,}612\,(\text{paradas})$$

(2) Interpretação dos coeficientes.

- $\hat{\beta}_1 = 0{,}0178$: mantido o número de paradas constante, cada km adicional de distância aumenta o tempo médio em 0,0178 horas (≈ 1 minuto).
- $\hat{\beta}_2 = 1{,}612$: mantida a distância constante, cada parada adicional aumenta o tempo médio em 1,612 horas.

(3) Qualidade. $R^2 = 0{,}978$, $R^2_{\text{ajust}} = 0{,}969$, $S = 0{,}37$ h.

(4) Teste F. $F(2,\, 5) = 110{,}4$, $p < 0{,}001$. O modelo é globalmente significativo.

(5) Testes t individuais. Ambos os coeficientes são significativos ($p < 0{,}01$): a distância e o número de paradas são preditores relevantes do tempo de entrega, controlando um pelo outro.

```
import numpy as np
import statsmodels.api as sm

distancia = np.array([100,150,200,200,250,300,300,350])
paradas   = np.array([1,2,1,3,2,3,1,4])
tempo     = np.array([3.2,5.1,4.8,7.0,6.5,8.2,6.0,10.1])

X = sm.add_constant(np.column_stack([distancia, paradas]))
resultado = sm.OLS(tempo, X).fit()
print(resultado.summary())
```

6 Resumo

Nesta nota, estudamos como a regressão linear permite descrever a relação entre uma variável resposta quantitativa e uma ou mais variáveis explicativas. O percurso começou com a investigação da associação entre variáveis, avançou para a estimação de uma reta pelo método dos mínimos quadrados e culminou na formulação dos modelos probabilísticos de regressão simples e múltipla.

As principais ideias desenvolvidas foram:

1. **Investigar a associação entre variáveis.** A covariância e o coeficiente de correlação de Pearson permitem avaliar a direção e a intensidade da associação linear entre duas variáveis quantitativas. O diagrama de dispersão complementa essas medidas ao revelar padrões que os resumos numéricos podem ocultar.
2. **Representar a associação por um modelo linear.** Quando existe uma tendência aproximadamente linear, podemos descrevê-la por uma equação que relaciona os valores da variável explicativa aos valores ajustados da resposta.

3. **Estimar os coeficientes por mínimos quadrados.** O método OLS determina os coeficientes que minimizam a soma dos quadrados dos resíduos, isto é, das diferenças entre os valores observados e os valores ajustados pelo modelo.

4. **Distinguir a reta estimada do modelo populacional.** A regressão linear probabilística representa a resposta como a combinação de uma componente sistemática e um erro aleatório. A reta estimada por OLS procura aproximar a relação média existente na população, mas seus coeficientes estão sujeitos à variabilidade amostral.

5. **Generalizar para múltiplas variáveis explicativas.** A regressão linear múltipla permite incorporar diferentes preditores em um mesmo modelo. Cada coeficiente descreve uma associação parcial com a resposta, condicionada aos demais preditores incluídos.

6. **Reconhecer as condições e limitações do modelo.** A interpretação dos resultados depende das suposições adotadas, da adequação da relação linear e do contexto dos dados. Além disso, uma associação estatística não implica, por si só, causalidade.

A tabela a seguir sintetiza os principais conceitos e expressões matemáticas apresentados na nota.

Conceito	**Síntese**
Covariância	Mede como os desvios de duas variáveis em relação às suas médias variam conjuntamente: $s_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$.
Correlação de Pearson	$r = \frac{s_{XY}}{s_X s_Y}$. É adimensional, varia de -1 a 1 e resume a direção e a intensidade da associação linear.
Reta ajustada	$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ na regressão simples. Fornece valores ajustados da resposta para diferentes valores de x.
Resíduo	$e_i = y_i - \hat{y}_i$. Representa a diferença entre o valor observado e o valor ajustado pelo modelo.
Critério OLS	Minimiza SQE $= \sum_{i=1}^{n} e_i^2$, penalizando quadraticamente as discrepâncias entre observações e valores ajustados.
Estimativas na regressão simples	$\hat{\beta}_1 = \frac{s_{XY}}{s_X^2} = r\frac{s_Y}{s_X}$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$.
Modelo probabilístico simples	$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. A reta populacional descreve o valor esperado de Y para cada valor de X.
Erros e resíduos	ε_i representa o desvio em relação à relação populacional; e_i é calculado em relação à reta estimada na amostra.
Suposições LINE	Linearidade da média condicional, independência, normalidade e igualdade de variâncias dos erros (homocedasticidade).
Modelo múltiplo	$Y_i = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} + \varepsilon_i$. Incorpora p variáveis explicativas.
Coeficientes parciais	Cada β_j descreve a variação no valor esperado de Y associada ao aumento de uma unidade em X_j, mantendo constantes os demais preditores.
Formulação matricial	$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, com estimativa OLS $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$, quando $\mathbf{X}$ possui posto completo de colunas.
Multicolinearidade	A dependência linear perfeita entre preditores impede a obtenção de coeficientes OLS únicos; associações muito fortes entre preditores podem dificultar sua estimação precisa.

Por fim, é importante distinguir a *construção de um modelo* de sua *avaliação estatística*. A obtenção dos coeficientes OLS não garante, por si só, que o modelo represente adequadamente os dados ou que suas estimativas sejam suficientemente precisas. Uma análise completa também pode envolver medidas de qualidade do ajuste, testes de hipóteses, intervalos de confiança, intervalos de predição e diagnóstico das suposições do modelo. Esses procedimentos complementam a fundamentação apresentada nesta nota e permitem avaliar a confiabilidade das conclusões obtidas.

7 Exercícios de Fixação

7.1 Exercício 1: Covariância e correlação

Uma pesquisadora coletou dados sobre temperatura média mensal (°C) e consumo de sorvete (em centenas de unidades) em uma cidade:

Temperatura (x)	15	18	22	25	28	32
Consumo (y)	12	18	24	28	35	42

(a) Calcule $\bar{x}$, $\bar{y}$, s_X, s_Y e s_{XY}.

(b) Calcule o coeficiente de correlação de Pearson e interprete.

(c) Construa o diagrama de dispersão e verifique se a linearidade parece razoável.

(d) Uma campanha de marketing aumentou o consumo de sorvete em 5 unidades em todos os meses. Como isso afeta r? Justifique sem recalcular.

7.2 Exercício 2: Derivação e cálculo das estimativas OLS

Usando os dados do exercício anterior:

(a) Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ manualmente.

(b) Escreva a equação da reta ajustada e interprete cada coeficiente.

(c) Verifique que a reta passa pelo ponto $(\bar{x}, \bar{y})$.

(d) Calcule os 6 resíduos $e_i = y_i - \hat{y}_i$ e verifique que $\sum e_i = 0$ e $\sum x_i e_i = 0$. (Essas são consequências algébricas das equações normais, não uma coincidência numérica.)

7.3 Exercício 3: Qualidade do ajuste e decomposição da variância

Continuando com os dados de temperatura e consumo de sorvete:

(a) Calcule SST, SSR, SSE e verifique que SST = SSR + SSE.

(b) Calcule R^2 de duas formas: (i) SSR/SST e (ii) r^2. Os valores devem coincidir.

(c) Calcule o erro padrão da regressão S.

(d) Interprete R^2 e S no contexto do problema.

7.4 Exercício 4: Inferência: testes e intervalos

Usando o modelo do exercício anterior:

(a) Calcule EP($\hat{\beta}_1$) e realize o teste $H_0 : \beta_1 = 0$ ao nível $\alpha = 0{,}05$.

(b) Construa um intervalo de confiança de 95% para β_1 e interprete.

(c) Para uma temperatura de $x^* = 20$°C, calcule o valor previsto $\hat{y}^*$, o IC de 95% para $E[Y \mid x^*]$ e o IP de 95% para uma nova observação. Explique a diferença entre os dois intervalos.

(d) Uma observação extra com temperatura 38°C não estava nos dados originais. Seria adequado usar o modelo para prever o consumo nessa temperatura? Justifique.

7.5 Exercício 5: Diagnóstico: identificar violações

Para cada conjunto de gráficos de resíduos descrito abaixo, identifique a suposição violada e sugira uma possível solução:

(a) O gráfico de resíduos vs. valores ajustados mostra uma curva em forma de "U".

(b) O gráfico de resíduos vs. valores ajustados mostra uma dispersão que cresce em forma de cone (funil), de esquerda para direita.

(c) O gráfico Normal Q-Q mostra que os pontos seguem a diagonal central mas se afastam nas caudas, sugerindo uma distribuição com caudas mais pesadas que a normal.

(d) O gráfico de resíduos vs. ordem de coleta mostra uma tendência crescente ao longo do tempo.

7.6 Exercício 6: Regressão Múltipla: preço de imóveis

Um conjunto de dados contém o preço de venda (em R$ mil), área útil (m²) e distância ao centro (km) de 12 imóveis. O ajuste OLS produziu:

$$\text{prêco} = 180{,}3 + 3{,}42 \times \text{area} - 8{,}75 \times \text{distancia}$$

com $R^2 = 0{,}88$, $R^2_{\text{ajust}} = 0{,}86$, $S = 25{,}3$ (R$ mil), $F(2, 9) = 33{,}0$ ($p < 0{,}001$).

Os p-valores dos testes t individuais foram: $p_{\text{area}} = 0{,}001$ e $p_{\text{distancia}} = 0{,}038$.

(a) Interprete os coeficientes de *area* e *distancia* no contexto do problema.

(b) Interprete R^2_{ajust} e S.

(c) Qual é a conclusão do teste F global?

(d) Ambos os preditores são individualmente significativos ao nível $\alpha = 0{,}05$?

(e) Um imóvel com 90 m² e 5 km do centro tem preço previsto de quanto? Quais informações adicionais você precisaria para construir um IP de 95%?

7.7 Exercício 7: Projeto computacional: regressão com dados reais

Utilize o conjunto de dados `tips` disponível na biblioteca `seaborn` (gorjeta em dólares, conta total, dia da semana e outras variáveis):

(a) Calcule a correlação entre `total_bill` e `tip` e construa o diagrama de dispersão.

(b) Ajuste a regressão simples de `tip` sobre `total_bill` usando `statsmodels`. Reporte a equação, R^2, S e a significância de $\hat{\beta}_1$.

(c) Construa os gráficos de diagnóstico de resíduos e avalie as suposições LINE.

(d) Ajuste um modelo múltiplo adicionando `size` (tamanho da mesa) como segundo preditor. Compare R^2_{ajust} e S com o modelo simples. A adição de `size` melhora o ajuste?

(e) Calcule o VIF dos dois preditores e verifique se multicolinearidade é um problema.

```
import seaborn as sns
tips = sns.load_dataset('tips')
print(tips.head())
```