

Regressão Linear

Notas de Aula

Prof. Eduardo Bezerra

Conteúdo

1	Covariância e Correlação	4
1.1	Motivação	4
1.2	Variância e Covariância	4
1.3	Coeficiente de Correlação de Pearson	5
1.4	Diagrama de Dispersão	6
1.5	O Quarteto de Anscombe	7
1.6	Exemplo resolvido: Idade e Peso de Crianças	7
1.7	Implementação em Python	9
2	O Método dos Mínimos Quadrados (OLS)	10
2.1	Da Correlação à Reta de Melhor Ajuste	10
2.2	Resíduos e a Função de Perda	11
2.3	Derivação das Estimativas OLS	11
3	Regressão Linear Simples	13
3.1	O Modelo Probabilístico	13
3.2	Interpretação dos Coeficientes	14
3.3	Decomposição da Variância e o Coeficiente R^2	14
3.4	Erro Padrão da Regressão	14
3.5	Inferência sobre os Coeficientes	15
3.6	Intervalo de Confiança vs. Intervalo de Predição	16
4	Diagnóstico do Modelo: Análise de Resíduos	16
4.1	Por que Analisar Resíduos?	16
5	Regressão Linear Múltipla	17
5.1	Motivação e Modelo	17
5.2	Formulação Matricial	17
5.3	Qualidade do Ajuste: R^2 Ajustado	18
5.4	Teste F Global	19
5.5	Multicolinearidade	21
5.6	Gráficos de Diagnóstico	21
5.6.1	Resíduos vs. valores ajustados	21
5.6.2	Gráfico QQ dos resíduos	22
5.6.3	Resíduos vs. preditores	23
5.6.4	Resíduos vs. ordem de coleta	23

6	Implementação em Python	25
6.1	Regressão Simples com <code>scipy</code> e <code>statsmodels</code>	25
6.2	Diagnóstico de Resíduos	26
6.3	Regressão Múltipla e VIF	26
7	Exemplos Completos	27
7.1	Exemplo 1: Horas de Estudo e Nota Final	27
7.2	Exemplo 2: Regressão Múltipla — Tempo de Entrega	28
8	Resumo	29
9	Exercícios de Fixação	31

Objetivos

Ao final da leitura, você deve ser capaz de:

Covariância e Correlação

- Calcular e interpretar a covariância entre duas variáveis quantitativas.
- Calcular o coeficiente de correlação de Pearson r e explicar por que ele é uma “normalização” da covariância.
- Interpretar o sinal e a magnitude de r , e construir e ler diagramas de dispersão.
- Explicar por que correlação não implica causalidade e por que um r alto não garante que o relacionamento é linear.

Método dos Mínimos Quadrados (OLS) ★

- Formular o problema de minimização dos quadrados dos resíduos.
- Derivar as expressões fechadas de $\hat{\beta}_0$ e $\hat{\beta}_1$ por meio das equações normais.
- Relacionar as estimativas OLS ao coeficiente de correlação e às variâncias amostrais.

Regressão Linear Simples ★

- Enunciar o modelo probabilístico de regressão simples e suas suposições (LINE).
- Interpretar os coeficientes $\hat{\beta}_0$ e $\hat{\beta}_1$ em termos do problema.
- Calcular e interpretar o coeficiente de determinação R^2 e o erro padrão da regressão S .
- Realizar o teste t para a significância de β_1 e construir intervalos de confiança para os coeficientes e para a média de Y .
- Distinguir intervalo de confiança para a média e intervalo de predição para uma nova observação.

Regressão Linear Múltipla ★

- Estender o modelo simples para múltiplos preditores e escrever o modelo na forma matricial.
- Interpretar os coeficientes parciais e distinguir R^2 de R^2_{ajustado} .
- Realizar o teste F global e os testes t individuais.
- Reconhecer o problema de multicolinearidade e suas consequências.

Diagnóstico do Modelo ★

- Verificar as suposições do modelo por meio de gráficos de resíduos.
- Identificar os padrões típicos de violação de cada suposição.

Roteiro de leitura

Estas notas estão organizadas nas seguintes partes. A Seção 1 apresenta covariância e correlação, ferramentas que servirão de base conceitual para toda a discussão subsequente. A Seção 2 descreve o método dos mínimos quadrados (OLS). A Seção 3 desenvolve a regressão linear simples, incluindo estimação, qualidade do ajuste e inferência. A Seção 4 estende o modelo para múltiplos preditores. A Seção 5 aborda o diagnóstico do modelo por meio de gráficos de resíduos. A Seção 6 reúne exemplos completos com implementação em Python. Os objetivos marcados com ★ são os mais centrais.

1 Covariância e Correlação

1.1 Motivação

Antes de prever o valor de uma variável a partir de outra, precisamos responder a uma pergunta mais básica: *as variáveis estão relacionadas?* Se o número de horas de estudo e a nota final não tiverem qualquer associação, nenhum modelo de regressão produzirá previsões úteis. Covariância e correlação são os instrumentos que quantificam essa associação para variáveis quantitativas.

1.2 Variância e Covariância

Definições

Seja $\{x_1, \dots, x_n\}$ uma amostra de tamanho n de uma variável X com média $\bar{x}$.

Variância amostral de X :

$$s_X^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Mede a dispersão unidimensional dos dados ao redor da média.

Covariância amostral entre X e Y :

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Mede se os desvios das duas variáveis em relação às suas médias tendem a ocorrer no mesmo sentido ou em sentidos opostos.

Pergunta 1

Análise o produto $(x_i - \bar{x})(y_i - \bar{y})$ para um ponto (x_i, y_i) genérico.

- (a) Em que situações esse produto é positivo? Negativo? Nulo?
- (b) O que acontece com a soma $\sum (x_i - \bar{x})(y_i - \bar{y})$ quando a maior parte dos pontos estiver no 1.º e 3.º quadrantes em torno do ponto $(\bar{x}, \bar{y})$?
- (c) Por que dividimos por $n-1$ em vez de n ?

A chave para entender a covariância é o sinal de cada produto $(x_i - \bar{x})(y_i - \bar{y})$. A Figura 1 ilustra essa ideia usando duas linhas tracejadas: a reta vertical $X = \bar{x}$ e a reta horizontal $Y = \bar{y}$. Essas linhas dividem o plano em quatro regiões, de acordo com os sinais dos desvios em relação às médias. Quando um ponto está à direita de $\bar{x}$ e acima de $\bar{y}$, ou à esquerda de $\bar{x}$ e abaixo de $\bar{y}$, os dois desvios têm o mesmo sinal e o produto é positivo, contribuindo para uma covariância positiva. Quando um ponto está à esquerda de $\bar{x}$ e acima de $\bar{y}$, ou à direita de $\bar{x}$ e abaixo de $\bar{y}$, os desvios têm sinais opostos e o produto é negativo.




Figura 1: Sinal de $(x_i - \bar{x})(y_i - \bar{y})$ em cada região formada pelas linhas de referência $X = \bar{x}$ e $Y = \bar{y}$. Quando os pontos se concentram nas regiões superior direita e inferior esquerda, os desvios tendem a ter o mesmo sinal, contribuindo para uma covariância positiva. Quando se concentram nas regiões superior esquerda e inferior direita, os desvios tendem a ter sinais opostos, contribuindo para uma covariância negativa.

Pergunta 2

Se convertermos a variável X de metros para centímetros (multiplicando por 100), como isso afeta s_{XY} ? O relacionamento real entre X e Y mudou?

1.3 Coeficiente de Correlação de Pearson

A covariância tem uma limitação prática importante: seu valor depende das unidades de medida de X e Y . Se medirmos a renda em reais em vez de dólares, a covariância aumentará por um fator de câmbio, mesmo que a relação entre as variáveis não tenha mudado. Isso torna comparações entre estudos quase impossíveis.

A solução é *normalizar* a covariância, dividindo pelos desvios-padrão de cada variável. Isso remove a dependência das unidades e confina o resultado ao intervalo $[-1, +1]$.

Coeficiente de Correlação de Pearson

O coeficiente de correlação de Pearson entre X e Y é:

$$r = \frac{s_{XY}}{s_X \cdot s_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Por construção, $r \in [-1, +1]$. O sinal indica a direção da associação; o valor absoluto indica a força.

A Figura 2 resume uma escala prática para interpretar o valor de r . Valores próximos de -1 indicam associação linear negativa forte, enquanto valores próximos de $+1$ indicam associação linear positiva forte. Valores próximos de zero sugerem ausência de associação linear, embora ainda possa existir uma relação não-linear entre as variáveis. Os limites entre “fraca”, “intermediária” e “forte” não devem ser interpretados como universais: eles dependem do contexto substantivo, da área de aplicação e da variabilidade esperada nos dados.




Figura 2: Escala de interpretação do coeficiente de correlação de Pearson r . Valores negativos indicam associação inversa; valores positivos, associação direta. A fronteira exata entre “fraca” e “intermediária” varia por domínio de aplicação.

Correlação não implica causalidade

Uma correlação alta entre X e Y significa apenas que as variáveis variam de forma associada na amostra observada. Não significa que X causa Y , nem que Y causa X . A associação pode ser espúria (devida a uma terceira variável confundidora), coincidental, ou refletir uma relação de causa reversa. Para afirmar causalidade, são necessários delineamento experimental adequado ou métodos específicos de inferência causal.

1.4 Diagrama de Dispersão

O diagrama de dispersão (*scatter plot*) é a representação gráfica da associação entre duas variáveis quantitativas. Cada observação (x_i, y_i) é representada por um ponto no plano cartesiano, sem que os pontos sejam unidos por segmentos.

A Figura 3 ilustra três configurações típicas de diagramas de dispersão. No painel esquerdo, os pontos se distribuem próximos de uma reta crescente, caracterizando correlação positiva forte. No painel central, a tendência é decrescente, indicando correlação negativa forte. No painel direito, não há uma direção linear clara: os pontos aparecem espalhados sem formar uma tendência crescente ou decrescente, o que é compatível com um coeficiente de correlação próximo de zero.




Figura 3: Três padrões típicos de diagrama de dispersão. Esquerda: associação positiva forte. Centro: associação negativa forte. Direita: ausência de associação linear.

A inspeção visual do diagrama deve *sempre* preceder o cálculo de r : o coeficiente captura apenas a componente linear da associação, e o gráfico pode revelar padrões não-lineares, outliers ou subgrupos que r sozinho não detecta.

1.5 O Quarteto de Anscombe

Francis Anscombe (1973) construiu quatro conjuntos de dados com exatamente os mesmos valores de r , $\bar{x}$, $\bar{y}$, s_X e s_Y , mas com padrões gráficos completamente distintos: um linear, um curvilíneo, um com outlier influente e um com ponto de alavanca. O quarteto é uma demonstração clássica de que resumos numéricos sozinhos podem ser enganosos. **Sempre construa o diagrama de dispersão antes de interpretar r .**

A Figura 4 mostra os quatro conjuntos do Quarteto de Anscombe. No primeiro painel, os pontos seguem aproximadamente uma tendência linear crescente, compatível com a interpretação usual de um coeficiente de correlação alto. No segundo, a relação é claramente curvilínea; no terceiro, um único outlier altera fortemente a percepção do padrão; e, no quarto, quase todos os pontos têm o mesmo valor de x , sendo a aparente associação linear sustentada por um único ponto de alavanca. O exemplo evidencia por que o cálculo de r deve ser acompanhado da inspeção visual do diagrama de dispersão.

1.6 Exemplo resolvido: Idade e Peso de Crianças

Uma amostra de 6 crianças fornece os seguintes dados de idade (em anos) e peso (em kg):

id	Idade (x_i)	Peso (y_i)
1	7	12
2	6	8
3	8	12
4	5	10
5	6	11
6	9	13

Antes de calcular o coeficiente de correlação, devemos inspecionar o diagrama de dispersão. A Figura 5 mostra que os pontos apresentam uma tendência geral crescente: crianças mais velhas tendem a ter maior peso. Apesar disso, a associação não é perfeita, pois há variação de peso entre crianças com idades próximas ou iguais. O gráfico, portanto,




Figura 4: O Quarteto de Anscombe. Os quatro conjuntos de dados possuem os mesmos valores de correlação, médias, variâncias e a mesma reta de regressão linear ajustada, mas exibem padrões gráficos muito diferentes: no painel I, a relação é aproximadamente linear; no painel II, há curvatura; no painel III, um outlier influencia fortemente a análise; e no painel IV, um ponto de alavanca sustenta a aparente relação linear. A figura reforça que o diagrama de dispersão deve sempre ser inspecionado antes da interpretação de resumos numéricos.

sugere que faz sentido calcular uma medida de associação linear, como o coeficiente de correlação de Pearson.

Após a inspeção visual, podemos calcular o coeficiente de correlação. As médias são $\bar{x} = 41/6 \approx 6,833$ e $\bar{y} = 66/6 = 11,0$.

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	0,167	1,0	0,028	1,0	0,167
2	-0,833	-3,0	0,694	9,0	2,500
3	1,167	1,0	1,361	1,0	1,167
4	-1,833	-1,0	3,361	1,0	1,833
5	-0,833	0,0	0,694	0,0	0,000
6	2,167	2,0	4,694	4,0	4,333
Σ			10,833	16,0	10,000




Figura 5: Diagrama de dispersão entre idade e peso das crianças. O padrão geral é crescente, sugerindo associação linear positiva, embora não perfeita.

$$r = \frac{10,000}{\sqrt{10,833} \times \sqrt{16,0}} = \frac{10,000}{3,292 \times 4,000} \approx 0,759.$$

O valor $r \approx 0,759$ indica uma associação linear positiva de intensidade moderada a forte. Essa interpretação é compatível com o padrão observado na Figura 5: em geral, crianças mais velhas tendem a ser mais pesadas, mas os pontos não estão perfeitamente alinhados sobre uma reta.

1.7 Implementação em Python

O cálculo do coeficiente de correlação pode ser realizado diretamente em Python. A implementação a seguir usa os mesmos dados do exemplo anterior, com idade representada pela variável x e peso pela variável y . O código tem três objetivos didáticos: primeiro, calcular a covariância amostral e obter r a partir da definição; segundo, comparar esse resultado com a função `pearsonr` da biblioteca `scipy`; terceiro, construir o diagrama de dispersão, reforçando que a interpretação de r deve ser acompanhada da inspeção visual dos dados.

Listing 1: Cálculo do coeficiente de correlação de Pearson e construção do diagrama de dispersão em Python.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import pearsonr

# Dados: idade (x) e peso (y)
x = np.array([7, 6, 8, 5, 6, 9])
y = np.array([12, 8, 12, 10, 11, 13])

# Covariância amostral entre x e y
cov_xy = np.cov(x, y, ddof=1)[0, 1]

# Desvios-padrão amostrais
sx = np.std(x, ddof=1)
sy = np.std(y, ddof=1)
```

```
# Correlacao calculada pela definicao
r_manual = cov_xy / (sx * sy)

# Correlacao via scipy
# pearsonr tambem retorna o p-valor do teste H0: rho = 0
r, p_valor = pearsonr(x, y)

print(f"Covariancia amostral = {cov_xy:.4f}")
print(f"r calculado manualmente = {r_manual:.4f}")
print(f"r via scipy = {r:.4f}")
print(f"p-valor = {p_valor:.4f}")

# Diagrama de dispersao
plt.figure(figsize=(5, 4))
plt.scatter(x, y, color='steelblue', zorder=3)
plt.xlabel("Idade (anos)")
plt.ylabel("Peso (kg)")
plt.title(f"Diagrama de dispersao (r = {r:.3f})")
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

A Listagem 1 mostra que o cálculo manual e a função `pearsonr` produzem o mesmo valor de r , como esperado. A diferença é que `pearsonr` também retorna um p -valor associado ao teste $H_0: \rho = 0$, isto é, ao teste de ausência de correlação linear populacional. Neste ponto das notas, o foco principal não está ainda no teste de hipótese, mas na interpretação descritiva da associação. Por isso, o valor de r deve ser lido em conjunto com o diagrama de dispersão produzido pelo código: os pontos sugerem uma tendência crescente, embora não perfeitamente linear, compatível com uma correlação positiva moderada a forte.

2 O Método dos Mínimos Quadrados (OLS)

2.1 Da Correlação à Reta de Melhor Ajuste

O coeficiente de correlação de Pearson resume a direção e a intensidade da associação linear entre duas variáveis quantitativas. Quando encontramos, por exemplo, um valor positivo e alto de r , concluímos que valores maiores de X tendem a estar associados a valores maiores de Y . No entanto, essa informação ainda é limitada: a correlação não nos diz qual valor de Y devemos esperar para um dado valor de X , nem quantifica diretamente a mudança média em Y quando X aumenta uma unidade.

Para avançar, precisamos substituir a pergunta “as variáveis estão associadas?” por uma pergunta mais operacional: *qual reta descreve melhor a tendência média dos dados?* Essa reta terá a forma

$$\hat{y} = b_0 + b_1x,$$

em que b_0 representa o intercepto e b_1 representa a inclinação. A inclinação é particularmente importante, pois expressa a variação esperada em Y para cada aumento de uma unidade em X . Assim, passamos de uma medida adimensional de associação, r , para uma equação capaz de produzir valores ajustados $\hat{y}$ na escala original da variável resposta.

Há, porém, infinitas retas que poderiam ser desenhadas sobre um diagrama de dispersão. Algumas passariam mais próximas de certos pontos, mas mais distantes de outros. Portanto, precisamos de um critério objetivo para decidir qual delas deve ser considerada a “melhor”. O método dos mínimos quadrados ordinários (*Ordinary Least Squares*, OLS) fornece esse critério: entre todas as retas possíveis, escolhemos aquela que minimiza a soma dos quadrados dos resíduos, isto é, das diferenças verticais entre os valores observados y_i e os valores ajustados $\hat{y}_i$.

Dessa forma, a regressão linear simples pode ser vista como uma continuação natural da análise de correlação. A correlação indica se há uma tendência linear; o OLS transforma essa tendência em uma reta estimada, permitindo interpretar inclinação, calcular previsões e, posteriormente, realizar inferência sobre os coeficientes do modelo.

2.2 Resíduos e a Função de Perda

Para qualquer reta candidata $\hat{y} = b_0 + b_1x$, definimos o *resíduo* da i -ésima observação como a diferença entre o valor observado e o valor ajustado:

$$e_i = y_i - \hat{y}_i = y_i - (b_0 + b_1x_i).$$

O resíduo mede o erro vertical de cada ponto em relação à reta. O OLS escolhe b_0 e b_1 de modo a minimizar a soma dos quadrados dos resíduos:

$$\text{SQE}(b_0, b_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1x_i)^2.$$

A Figura 6 sintetiza duas ideias centrais do método dos mínimos quadrados. No painel esquerdo, cada resíduo é a distância vertical entre um ponto observado e a reta candidata. No painel direito, a função de perda quadrática $L(e) = e^2$ mostra que erros maiores recebem penalização desproporcionalmente maior do que erros pequenos. Essa combinação (medir o erro por distâncias verticais e elevar essas distâncias ao quadrado) é a base do critério de mínimos quadrados.

Pergunta 3

Por que minimizamos a soma dos *quadrados* dos resíduos em vez da soma dos valores absolutos $\sum |e_i|$?

Pense em duas razões: uma algébrica (derivabilidade) e uma estatística (quais tipos de erros penalizamos mais).

Elevar ao quadrado tem duas consequências desejáveis: (1) erros positivos e negativos não se cancelam; (2) erros grandes recebem penalidade desproporcionalmente maior, tornando a reta sensível a desvios expressivos, o que é matematicamente tratável e, em muitos contextos, interpretável.

2.3 Derivação das Estimativas OLS

Para minimizar $\text{SQE}(b_0, b_1)$, igualamos as derivadas parciais a zero. Esse sistema de equações (chamado *equações normais*) possui solução fechada:




Figura 6: À esquerda, os resíduos são as distâncias verticais entre os pontos observados e a reta candidata. À direita, a função de perda quadrática $L(e) = e^2$ mostra que erros maiores recebem penalização mais intensa do que erros pequenos. Para comparação, a linha tracejada representa a perda absoluta $L(e) = |e|$.

Estimativas OLS para Regressão Simples

As estimativas de mínimos quadrados de β_0 e β_1 são:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{s_{XY}}{s_X^2} = r \cdot \frac{s_Y}{s_X}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

A reta de regressão *sempre* passa pelo ponto $(\bar{x}, \bar{y})$.

A derivação completa começa calculando $\partial \text{SQE} / \partial b_0 = 0$ e $\partial \text{SQE} / \partial b_1 = 0$, o que produz o sistema:

$$\begin{aligned} n b_0 + b_1 \sum x_i &= \sum y_i \\ b_0 \sum x_i + b_1 \sum x_i^2 &= \sum x_i y_i. \end{aligned}$$

Dividindo a primeira equação por n e isolando $b_0 = \bar{y} - b_1 \bar{x}$; substituindo na segunda e simplificando, obtemos $\hat{\beta}_1 = s_{XY} / s_X^2$.

Relação entre $\hat{\beta}_1$ e r

A fórmula $\hat{\beta}_1 = r \cdot (s_Y/s_X)$ revela uma conexão importante: a inclinação da reta de regressão é o produto da correlação pelo fator de escala s_Y/s_X . Se as unidades de X e Y fossem as mesmas e suas dispersões fossem iguais ($s_X = s_Y$), teríamos $\hat{\beta}_1 = r$ exatamente. Na prática, o fator de escala ajusta a inclinação às unidades do problema.

Isso também explica por que a reta de regressão de Y sobre X é *diferente* da reta de X sobre Y (exceto quando $|r| = 1$): cada uma minimiza os resíduos na direção de sua variável dependente.

3 Regressão Linear Simples

3.1 O Modelo Probabilístico

A reta OLS é apenas um estimador. Para fazer inferência (testes e intervalos de confiança), precisamos de um modelo probabilístico que descreva como os dados foram gerados.

Modelo de Regressão Linear Simples

O modelo assume que, para cada valor fixo de x_i , a variável resposta Y_i é gerada por:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

onde β_0 e β_1 são parâmetros populacionais desconhecidos e ε_i são os *erros aleatórios*.

As suposições do modelo são usualmente resumidas pelo acrônimo **LINE**:

- **Linearidade:** $E[Y_i | x_i] = \beta_0 + \beta_1 x_i$ (a relação média é linear).
- **Independência:** os erros $\varepsilon_1, \dots, \varepsilon_n$ são mutuamente independentes.
- **Normalidade:** $\varepsilon_i \sim N(0, \sigma^2)$ para todo i .
- **Equivariância (*homocedasticidade*):** $\text{Var}(\varepsilon_i) = \sigma^2$ é constante (não depende de x_i).

Modelo estimado vs. modelo populacional

É essencial distinguir dois níveis:

- **Modelo populacional:** $Y = \beta_0 + \beta_1 X + \varepsilon$, com parâmetros *verdadeiros* e desconhecidos β_0, β_1 .
- **Reta estimada:** $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, calculada a partir dos dados amostrais. Os valores ajustados $\hat{y}_i$ são estimativas de $E[Y | x_i]$, *não* previsões de observações individuais futuras (para isso, o intervalo de predição é mais adequado).

3.2 Interpretação dos Coeficientes

Como interpretar $\hat{\beta}_0$ e $\hat{\beta}_1$

- $\hat{\beta}_1$ (inclinação): para cada aumento de *uma unidade* em X , o valor médio previsto de Y aumenta (ou diminui, se negativo) em $\hat{\beta}_1$ unidades. É o coeficiente central da análise.
- $\hat{\beta}_0$ (intercepto): valor previsto de Y quando $X = 0$. Pode não ter interpretação substantiva quando $x = 0$ está fora do intervalo observado dos dados.

Cuidado com extrapolação

A reta de regressão é uma aproximação válida na região dos dados observados. Usá-la para prever Y fora do intervalo de X na amostra é *extrapolação*: não há garantia de que a linearidade se mantém, e os erros de previsão podem ser substanciais. Sempre informe o intervalo de X ao reportar um modelo.

3.3 Decomposição da Variância e o Coeficiente R^2

Para avaliar a qualidade do ajuste, separamos a variabilidade total de Y em duas componentes:

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SST (total)}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SSR (regressão)}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{SSE (erro)}}$$

Na expressão acima,

- **SST** (*Sum of Squares Total*) é a variabilidade total de Y ao redor de sua média;
- **SSR** (*Sum of Squares Regression*) é a variabilidade de Y explicada pela reta de regressão;
- **SSE** (*Sum of Squares Error*) é a variabilidade residual, não explicada pelo modelo.

A Figura 7 apresenta uma interpretação geométrica dessa decomposição para uma observação específica. O desvio total de y_i em relação à média $\bar{y}$ é separado em duas partes: a parcela explicada pelo modelo, $\hat{y}_i - \bar{y}$, e a parcela não explicada, isto é, o resíduo $y_i - \hat{y}_i$. A identidade visual mostrada na figura ajuda a entender por que, ao somar os quadrados desses desvios para todas as observações, obtemos a decomposição da variabilidade total em variabilidade explicada pela regressão e variabilidade residual.

3.4 Erro Padrão da Regressão

O parâmetro σ mede a dispersão dos erros ao redor da reta. Como σ é desconhecido, estimamos por:

$$S = \sqrt{\frac{\text{SSE}}{n-2}} = \sqrt{\text{QME}}$$




Figura 7: Decomposição do desvio de uma observação em relação à média. O desvio total $y_i - \bar{y}$ pode ser escrito como a soma da parcela explicada pela regressão, $\hat{y}_i - \bar{y}$, com o resíduo, $y_i - \hat{y}_i$. Ao elevar esses desvios ao quadrado e somar sobre todas as observações, obtém-se a decomposição $SST = SSR + SSE$.

O denominador $n - 2$ reflete que dois parâmetros (β_0 e β_1) foram estimados a partir dos dados. S tem a mesma unidade de Y e mede a “largura” típica da faixa de variação dos dados ao redor da reta.

3.5 Inferência sobre os Coeficientes

Sob as suposições LINE, as estimativas $\hat{\beta}_0$ e $\hat{\beta}_1$ são não-viesadas e seguem distribuição normal. O caso mais importante é o teste sobre β_1 : se $\beta_1 = 0$, X não tem poder preditivo linear sobre Y e o modelo não é útil.

Teste de Significância de β_1

Hipóteses: $H_0 : \beta_1 = 0$ vs. $H_a : \beta_1 \neq 0$

Erro padrão de $\hat{\beta}_1$:

$$EP(\hat{\beta}_1) = \frac{S}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Estatística de teste:

$$t = \frac{\hat{\beta}_1}{EP(\hat{\beta}_1)} \sim t_{n-2} \quad \text{sob } H_0$$

Decisão: rejeitar H_0 se $|t| > t_{\alpha/2, n-2}$ ou se $p\text{-valor} < \alpha$.

Intervalos de Confiança

Para β_1 :

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot \text{EP}(\hat{\beta}_1)$$

Para β_0 :

$$\hat{\beta}_0 \pm t_{\alpha/2, n-2} \cdot \text{EP}(\hat{\beta}_0), \quad \text{onde } \text{EP}(\hat{\beta}_0) = S \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2}}$$

3.6 Intervalo de Confiança vs. Intervalo de Predição

Uma das distinções mais importantes na prática da regressão é a diferença entre estimar a *média* de Y para um dado x^* e prever o valor de uma *nova observação individual* y^* .

Para um valor específico x^* :

IC para $E[Y | x^*]$ (estima a média populacional de Y):

$$\hat{y}^* \pm t_{\alpha/2, n-2} \cdot S \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum (x_i - \bar{x})^2}}$$

IP para y^* (prediz um valor individual futuro):

$$\hat{y}^* \pm t_{\alpha/2, n-2} \cdot S \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{\sum (x_i - \bar{x})^2}}$$

O IP é sempre mais largo que o IC: além da incerteza sobre a média, ele incorpora a variabilidade natural de observações individuais ao redor da média (representada pelo “+1” sob a raiz).

Pergunta 4

Tanto o IC quanto o IP ficam mais largos à medida que x^* se afasta de $\bar{x}$. Por que isso acontece geometricamente? O que isso implica sobre a confiabilidade das predições próximas vs. distantes do centro dos dados?

4 Diagnóstico do Modelo: Análise de Resíduos

4.1 Por que Analisar Resíduos?

As estimativas OLS são obtidas sem pressupor qualquer suposição sobre os erros: a reta minimizadora de SQE existe independentemente de normalidade, homocedasticidade ou independência. No entanto, a validade dos testes t , intervalos de confiança e predições depende de que as suposições LINE sejam razoavelmente satisfeitas. A análise dos resíduos é o principal instrumento para verificar isso.

Resíduos Padronizados

Os resíduos brutos $e_i = y_i - \hat{y}_i$ têm variâncias diferentes dependendo da posição de x_i . Uma forma mais comparável são os resíduos padronizados:

$$e_i^* = \frac{e_i}{S\sqrt{1 - h_{ii}}}$$

onde h_{ii} é o i -ésimo elemento diagonal da matriz chapéu (*hat matrix*). Sob as suposições do modelo, $e_i^* \approx N(0, 1)$, tornando mais fácil identificar outliers ($|e_i^*| > 3$).

5 Regressão Linear Múltipla

5.1 Motivação e Modelo

Na regressão simples, usamos um único preditor X para explicar Y . Na prática, a variável resposta quase sempre depende de múltiplos fatores: o preço de um imóvel depende de área, localização, número de quartos e idade da construção; a nota de um aluno pode depender de horas de estudo, horas de sono e nível de ansiedade. A regressão múltipla estende o modelo simples para acomodar p preditores simultaneamente.

Modelo de Regressão Linear Múltipla

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

com as mesmas suposições LINE do modelo simples (independência, normalidade e homocedasticidade dos erros).

Os coeficientes β_j ($j = 1, \dots, p$) são *coeficientes parciais*: β_j representa a mudança média em Y por unidade de aumento em X_j , *mantidos constantes* todos os demais preditores.

Interpretação parcial vs. marginal

Um erro comum é interpretar $\hat{\beta}_j$ como o efeito isolado de X_j . Na verdade, $\hat{\beta}_j$ representa o efeito de X_j sobre Y *condicionado* aos demais preditores no modelo. Se os preditores estiverem correlacionados entre si, o coeficiente de X_j na regressão múltipla pode diferir consideravelmente do coeficiente que seria obtido na regressão simples de Y sobre X_j isoladamente. Essa diferença reflete o controle estatístico das demais variáveis.

5.2 Formulação Matricial

Com n observações e p preditores, o modelo pode ser escrito compactamente na forma matricial:

Forma Matricial e Estimativa OLS

Defina:

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

O modelo é $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$.

A estimativa OLS que minimiza $\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2$ é:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

(desde que $\mathbf{X}^\top \mathbf{X}$ seja invertível, o que requer ausência de multicolinearidade perfeita).

A coluna de 1s na matriz $\mathbf{X}$ incorpora o intercepto β_0 . A derivação segue o mesmo princípio do caso simples: derivar $\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2$ em relação a $\boldsymbol{\beta}$, igualar a zero, e resolver para $\hat{\boldsymbol{\beta}}$.

5.3 Qualidade do Ajuste: R^2 Ajustado

Na regressão linear simples, o coeficiente de determinação R^2 mede a proporção da variabilidade de Y explicada pela reta ajustada. Na regressão múltipla, a interpretação básica permanece a mesma: R^2 indica a fração da variabilidade da resposta explicada pelo conjunto de preditores incluídos no modelo.

No entanto, há uma dificuldade importante: o R^2 ordinário nunca diminui quando adicionamos um novo preditor ao modelo. Mesmo que a nova variável seja irrelevante, isto é, mesmo que ela não tenha relação substantiva com Y , o modelo com mais preditores terá liberdade adicional para se ajustar aos dados amostrais. Com isso, a soma dos quadrados dos erros (SSE) tende a diminuir ou, no pior caso, permanecer igual. Como

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}},$$

qualquer redução em SSE aumenta artificialmente o R^2 . Assim, comparar modelos com diferentes números de preditores usando apenas o R^2 ordinário favorece modelos mais complexos, mesmo quando a melhora é pequena ou apenas acidental.

 R^2 Ajustado

O R^2 ajustado corrige parcialmente esse problema ao levar em conta o número de preditores do modelo:

$$R^2_{\text{ajust}} = 1 - \frac{\text{SSE}/(n - p - 1)}{\text{SST}/(n - 1)} = 1 - (1 - R^2) \cdot \frac{n - 1}{n - p - 1}.$$

Nessa expressão, n é o tamanho da amostra e p é o número de preditores, sem contar o intercepto. O termo $n - p - 1$ representa os graus de liberdade associados ao erro, pois foram estimados p coeficientes de inclinação e um intercepto.

A ideia central é comparar a variabilidade residual média do modelo com a variabilidade total média da resposta. Ao dividir a SSE por $n - p - 1$, o R^2_{ajust} penaliza modelos que usam muitos preditores sem reduzir suficientemente o erro. Portanto, ao adicionar uma nova variável, o R^2_{ajust} só aumenta se a redução em SSE compensar a perda de um grau de liberdade.

Isso torna o R^2_{ajust} mais apropriado do que o R^2 ordinário para comparar modelos com diferentes números de preditores. Se a inclusão de uma variável aumenta pouco o R^2 mas reduz o R^2_{ajust} , isso é um sinal de que a variável acrescentou complexidade sem melhorar substancialmente o ajuste. Por outro lado, se tanto o R^2 quanto o R^2_{ajust} aumentam, há evidência de que o novo preditor contribuiu para explicar a variabilidade de Y .

Cuidado na interpretação

Um R^2_{ajust} alto não garante que o modelo seja adequado. Ele não verifica linearidade, normalidade dos erros, homocedasticidade, independência ou ausência de observações influentes. Por isso, a comparação por R^2_{ajust} deve ser acompanhada da análise dos coeficientes, do conhecimento do problema e dos gráficos de diagnóstico.

Pergunta 5

Ao adicionar um novo preditor a um modelo de regressão múltipla, o R^2 aumentou de 0,72 para 0,73, mas o R^2_{ajust} caiu de 0,69 para 0,68. O que isso sugere sobre a contribuição desse novo preditor?

5.4 Teste F Global

Depois de ajustar um modelo de regressão múltipla, uma primeira pergunta natural é: *o conjunto de preditores, considerado como um todo, ajuda a explicar a variabilidade de Y ?* Essa pergunta é diferente de perguntar se um preditor específico é relevante. Antes de examinar os coeficientes individualmente, queremos saber se o modelo completo melhora a explicação de Y em comparação com um modelo sem preditores.

O modelo sem preditores é o chamado *modelo nulo*. Ele prevê sempre o mesmo valor para todas as observações:

$$\hat{y}_i = \bar{y}.$$

Nesse caso, nenhuma variável explicativa é usada; toda a variabilidade de Y é tratada como não explicada. Já o modelo de regressão múltipla usa os preditores $X_1, \dots, X_p$ para produzir valores ajustados $\hat{y}_i$. Se esses preditores forem úteis, esperamos que a soma dos quadrados dos erros diminua consideravelmente em relação ao modelo nulo.

É por isso que a ANOVA reaparece no contexto da regressão. Assim como na ANOVA estudada anteriormente, a ideia é decompor uma variabilidade total em componentes. Na regressão, escrevemos:

$$\text{SST} = \text{SSR} + \text{SSE},$$

em que SST mede a variabilidade total de Y em torno de $\bar{y}$, SSR mede a parte explicada pelo modelo de regressão, e SSE mede a parte que permanece nos resíduos. O teste F global compara a variabilidade explicada pelo modelo com a variabilidade residual média. Se a parcela explicada for grande em relação ao erro residual, temos evidência de que pelo menos um dos preditores possui associação linear com Y .

Teste F Global

Hipóteses:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

$$H_a : \text{pelo menos um } \beta_j \neq 0.$$

Sob H_0 , nenhum dos preditores contribui linearmente para explicar Y . Nesse caso, o modelo completo não deveria ser substancialmente melhor do que o modelo nulo, que usa apenas a média $\bar{y}$.

Tabela ANOVA da Regressão:

Fonte	SQ	GL	QM	F
Regressão	SSR	p	$\text{QMR} = \text{SSR}/p$	QMR/QME
Erro	SSE	$n - p - 1$	$\text{QME} = \text{SSE}/(n - p - 1)$	
Total	SST	$n - 1$		

Estatística de teste:

$$F = \frac{\text{QMR}}{\text{QME}} = \frac{\text{SSR}/p}{\text{SSE}/(n - p - 1)} \sim F_{p, n-p-1} \quad \text{sob } H_0.$$

Rejeitamos H_0 se $F > F_{\alpha, p, n-p-1}$ ou, equivalentemente, se o p -valor for menor que α .

A lógica do teste é a seguinte. O numerador, QMR, mede a variabilidade explicada pelo modelo por grau de liberdade associado aos preditores. O denominador, QME, mede a variabilidade residual média, isto é, a variabilidade que o modelo não conseguiu explicar. Portanto, um valor grande de F indica que a parte explicada pelo modelo é grande quando comparada ao ruído residual. Isso fornece evidência contra a hipótese de que todos os coeficientes de inclinação são nulos.

Teste F significativo não implica que todos os preditores são relevantes

Um p -valor global significativo indica que o modelo completo, considerado como conjunto, melhora a explicação de Y em relação ao modelo nulo. Isso significa que há evidência de que pelo menos um coeficiente β_j é diferente de zero.

No entanto, essa conclusão não implica que todos os preditores sejam individualmente relevantes. Alguns podem contribuir pouco, ter efeito redundante com outros ou perder significância na presença de variáveis correlacionadas. Para avaliar a contribuição individual de cada preditor, usamos os testes t :

$$t_j = \frac{\hat{\beta}_j}{\text{EP}(\hat{\beta}_j)} \sim t_{n-p-1}.$$

Assim, o teste F responde a uma pergunta global sobre o modelo; os testes t respondem a perguntas específicas sobre cada coeficiente.

5.5 Multicolinearidade

Por definição, *multicolinearidade* é a situação em que dois ou mais preditores são altamente correlacionados entre si. Nesse caso, $\mathbf{X}^T \mathbf{X}$ fica próxima de singular, as estimativas $\hat{\beta}_j$ tornam-se instáveis (pequenas mudanças nos dados produzem grandes mudanças nos coeficientes) e os erros padrão individuais ficam inflados, dificultando a detecção de efeitos parciais reais.

O *Fator de Inflação da Variância* (VIF) é a principal medida de multicolinearidade:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

onde R_j^2 é o coeficiente de determinação da regressão de X_j sobre todos os demais preditores. Um $\text{VIF}_j > 10$ é frequentemente usado como limiar de preocupação.

Sinais de multicolinearidade

- F global significativo, mas nenhum teste t individual significativo.
- Coeficientes com sinais contrários à correlação bivariada com Y .
- Grande instabilidade nos coeficientes ao adicionar ou remover preditores.
- $\text{VIF} > 10$ para algum preditor.

5.6 Gráficos de Diagnóstico

Depois de ajustar um modelo de regressão, é necessário verificar se as suposições do modelo são razoáveis. Essa verificação não deve depender apenas de medidas numéricas como R^2 , S ou p -valores. Um modelo pode apresentar bons indicadores globais e, ainda assim, violar suposições importantes. Por isso, a análise gráfica dos resíduos é uma etapa essencial do diagnóstico.

Os gráficos de diagnóstico procuram responder a perguntas diferentes: os resíduos parecem aleatórios? A variância dos erros é constante? A distribuição dos resíduos é aproximadamente normal? Há dependência temporal ou algum padrão associado à ordem de coleta? A seguir, discutimos quatro gráficos frequentemente usados em regressão linear.

5.6.1 Resíduos vs. valores ajustados

O gráfico de resíduos contra valores ajustados (e_i vs. $\hat{y}_i$) é geralmente o primeiro a ser examinado. Em um modelo adequado, espera-se que os resíduos se distribuam aleatoriamente ao redor de zero, sem formar tendência crescente, decrescente, curva ou padrão de dispersão sistemático.

Esse gráfico ajuda a avaliar principalmente duas suposições. A primeira é a linearidade: se houver uma estrutura curva nos resíduos, isso sugere que a relação entre X e Y talvez não seja bem representada por uma reta. A segunda é a homocedasticidade: se a dispersão dos resíduos aumenta ou diminui conforme $\hat{y}_i$ cresce, há evidência de variância não constante dos erros.

A Figura 8 ilustra dois padrões possíveis nesse gráfico. No painel esquerdo, os resíduos oscilam ao redor de zero sem estrutura aparente. No painel direito, a dispersão cresce com os valores ajustados, formando um padrão em funil, típico de heterocedasticidade.




Figura 8: Dois padrões possíveis no gráfico de resíduos versus valores ajustados. À esquerda, os resíduos se distribuem aleatoriamente ao redor de zero, sem estrutura aparente, o que é compatível com um modelo adequado. À direita, a dispersão cresce com $\hat{y}_i$, formando um padrão em funil, típico de heterocedasticidade.

5.6.2 Gráfico QQ dos resíduos

O gráfico QQ dos resíduos, ou Normal Q-Q plot, é usado para avaliar a suposição de normalidade dos erros. Ele compara os quantis empíricos dos resíduos com os quantis teóricos esperados caso os erros viessem de uma distribuição normal.

Se a normalidade for plausível, os pontos devem se alinhar aproximadamente ao longo de uma reta diagonal. Pequenas flutuações são esperadas, especialmente em amostras pequenas. No entanto, curvaturas sistemáticas, pontos muito afastados nas extremidades ou desvios acentuados nas caudas indicam que a distribuição dos resíduos pode ser assimétrica, possuir caudas pesadas ou conter outliers.

Esse gráfico é particularmente relevante para a validade aproximada dos testes t , testes F e intervalos de confiança em amostras pequenas. Em amostras maiores, os procedimentos inferenciais tendem a ser mais robustos, mas desvios severos de normalidade ainda devem ser investigados.

A Figura 9 ilustra dois padrões típicos no gráfico QQ dos resíduos. No painel esquerdo, os pontos acompanham aproximadamente a diagonal de referência, o que sugere compatibilidade com a suposição de normalidade. No painel direito, os pontos exibem desvio sistemático em relação à diagonal, sobretudo nas extremidades, indicando possível violação dessa suposição.




Figura 9: Dois padrões possíveis no gráfico QQ dos resíduos. À esquerda, os pontos ficam próximos da diagonal de referência, o que é compatível com a suposição de normalidade. À direita, há um desvio sistemático em relação à diagonal, especialmente nas caudas, sugerindo que a distribuição dos resíduos não é bem aproximada por uma normal.

5.6.3 Resíduos vs. preditores

O gráfico de resíduos contra cada preditor (e_i vs. x_i) permite verificar se há padrões associados a uma variável explicativa específica. Enquanto o gráfico de resíduos contra valores ajustados resume o comportamento global do modelo, os gráficos contra os preditores ajudam a localizar problemas em relação a uma variável particular.

Em um modelo adequado, os resíduos também devem parecer aleatórios quando vistos em função de cada preditor. Um padrão curvo pode sugerir que o efeito daquele preditor não é linear. Uma dispersão que aumenta ou diminui ao longo dos valores de x_i pode indicar heterocedasticidade associada a esse preditor. Agrupamentos ou pontos extremos também podem revelar subgrupos, outliers ou regiões dos dados em que o modelo ajusta pior.

Na regressão múltipla, esse diagnóstico é especialmente útil, pois um problema de não-linearidade pode estar ligado a apenas uma das variáveis explicativas, mesmo quando os indicadores globais do modelo parecem satisfatórios.

A Figura 10 ilustra dois padrões possíveis no gráfico de resíduos contra um preditor específico. No painel esquerdo, os resíduos se distribuem de forma aproximadamente aleatória ao redor de zero, o que é compatível com um modelo adequado em relação a esse preditor. No painel direito, a presença de curvatura sugere que o efeito de x_j sobre a resposta talvez não tenha sido bem representado por uma função linear.




Figura 10: Dois padrões possíveis no gráfico de resíduos versus um preditor específico x_j . À esquerda, os resíduos aparecem distribuídos aleatoriamente ao redor de zero, sem estrutura aparente, o que é compatível com um efeito linear adequadamente modelado. À direita, observa-se uma curvatura sistemática, sugerindo que a relação entre a resposta e o preditor x_j pode não ser linear.

5.6.4 Resíduos vs. ordem de coleta

Quando as observações têm uma ordem natural, como em dados coletados ao longo do tempo, também é importante construir o gráfico de resíduos contra a ordem de coleta. Esse gráfico ajuda a avaliar a suposição de independência dos erros.

Em um modelo adequado, não deve haver tendência temporal clara nos resíduos. Uma sequência longa de resíduos positivos seguida por uma sequência longa de resíduos negativos, uma tendência crescente ou decrescente, ou um padrão oscilatório sugerem autocorrelação. Isso significa que os erros não são independentes: o erro de uma observação pode estar relacionado ao erro de observações próximas na ordem de coleta.

A autocorrelação é comum em séries temporais e em dados observacionais organizados sequencialmente. Quando presente, ela pode comprometer os erros padrão, os testes

de hipótese e os intervalos de confiança, mesmo que a reta ajustada pareça razoável visualmente.

A Figura 11 ilustra dois padrões possíveis no gráfico de resíduos contra a ordem de coleta. No painel esquerdo, os resíduos aparecem distribuídos de forma aproximadamente aleatória ao redor de zero, sem tendência ou estrutura visível, o que é compatível com a suposição de independência. No painel direito, observa-se um padrão sistemático ao longo da sequência de coleta, sugerindo autocorrelação entre os erros.




Figura 11: Dois padrões possíveis no gráfico de resíduos versus ordem de coleta. À esquerda, os resíduos oscilam ao redor de zero sem padrão aparente, o que é compatível com independência. À direita, há uma estrutura sistemática ao longo da ordem de observação, sugerindo autocorrelação e, portanto, violação da suposição de independência dos erros.

Síntese: o que procurar nos gráficos de resíduos

Gráfico	Padrão problemático	O que isso sugere
e_i vs. $\hat{y}_i$	Curvatura sistemática	A relação média pode não ser linear; pode ser necessário transformar variáveis ou incluir termos não-lineares.
e_i vs. $\hat{y}_i$	Dispersão crescente ou decrescente	Possível heterocedasticidade; a variância dos erros pode não ser constante.
Normal Q-Q	Desvio sistemático da diagonal, especialmente nas caudas	Possível violação da normalidade dos erros; outliers ou caudas pesadas podem estar presentes.
e_i vs. preditor	Curvatura ou mudança de dispersão ao longo de x_j	O problema pode estar associado a um preditor específico; pode haver não-linearidade ou heterocedasticidade local.
e_i vs. ordem de coleta	Tendência, ciclos ou blocos de resíduos positivos/-negativos	Possível autocorrelação; a suposição de independência dos erros pode estar violada.

6 Implementação em Python

6.1 Regressão Simples com scipy e statsmodels

```
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt

# Dados: horas de estudo (x) e nota (y)
x = np.array([2, 3, 4, 5, 6, 7, 8, 9, 10])
y = np.array([55, 60, 62, 68, 72, 75, 80, 83, 88])

# OLS com statsmodels (inclui intercepto via add_constant)
X = sm.add_constant(x)
modelo = sm.OLS(y, X).fit()

print(modelo.summary())
# O summary() exibe: coeficientes, EP, t, p-valor, IC 95%,
# R2, R2 ajustado, estatística F e p-valor F.

# Previsão e intervalo de confiança / predição
x_novo = np.array([[1, 5.5]]) # intercepto + x*
ic = modelo.get_prediction(x_novo).summary_frame(alpha=0.05)
print(ic[['mean', 'mean_ci_lower', 'mean_ci_upper',
            'obs_ci_lower', 'obs_ci_upper']])

# Grafico
x_plot = np.linspace(x.min(), x.max(), 100)
y_pred = modelo.predict(sm.add_constant(x_plot))
pred_full = modelo.get_prediction(sm.add_constant(x_plot))
ic_full = pred_full.summary_frame(alpha=0.05)

plt.figure(figsize=(7, 5))
plt.scatter(x, y, color='steelblue', zorder=4, label='Dados')
plt.plot(x_plot, y_pred, 'r-', label='Reta ajustada')
plt.fill_between(x_plot,
                 ic_full['mean_ci_lower'], ic_full['mean_ci_upper'],
                 alpha=0.25, color='red', label='IC 95% (media)')
plt.fill_between(x_plot,
                 ic_full['obs_ci_lower'], ic_full['obs_ci_upper'],
                 alpha=0.10, color='blue', label='IP 95% (individual)')

plt.xlabel('Horas de estudo')
plt.ylabel('Nota')
plt.legend()
plt.tight_layout()
plt.show()
```

6.2 Diagnóstico de Resíduos

```
import scipy.stats as stats

residuos = modelo.resid
residuos_padronizados = modelo.get_influence().
    resid_studentized_internal
valores_ajustados = modelo.fittedvalues

fig, axes = plt.subplots(1, 2, figsize=(11, 4))

# Residuos vs. valores ajustados
axes[0].scatter(valores_ajustados, residuos, color='steelblue')
axes[0].axhline(0, color='red', linestyle='--', linewidth=1)
axes[0].set_xlabel('Valores ajustados')
axes[0].set_ylabel('Residuos')
axes[0].set_title('Residuos vs. Valores Ajustados')

# Normal Q-Q
stats.probplot(residuos, dist='norm', plot=axes[1])
axes[1].set_title('Normal Q-Q dos Residuos')

plt.tight_layout()
plt.show()
```

6.3 Regressão Múltipla e VIF

```
import pandas as pd
from statsmodels.stats.outliers_influence import
    variance_inflation_factor

# Dados simulados: preco de imovel
np.random.seed(42)
n = 100
area = np.random.uniform(40, 200, n)
quartos = np.random.randint(1, 5, n)
idade = np.random.uniform(1, 30, n)
preco = 150000 + 1200*area + 25000*quartos - 3000*idade \
    + np.random.normal(0, 20000, n)

df = pd.DataFrame({'preco': preco, 'area': area,
    'quartos': quartos, 'idade': idade})

X = sm.add_constant(df[['area', 'quartos', 'idade']])
modelo_mult = sm.OLS(df['preco'], X).fit()
print(modelo_mult.summary())

# VIF
vif_df = pd.DataFrame({
    'variavel': X.columns,
```

```
'VIF': [variance_inflation_factor(X.values, i)
        for i in range(X.shape[1])]
})
print(vif_df)
```

7 Exemplos Completos

Nos exemplos a seguir, adotamos $\alpha = 0,05$.

Como reportar um modelo de regressão

Um relatório completo deve conter: a equação ajustada; os erros padrão ou intervalos de confiança dos coeficientes; a significância de cada coeficiente (t e p -valor); R^2 (e R^2_{ajust} em modelos múltiplos); o resultado do teste F global; o erro padrão da regressão S ; e uma interpretação substantiva no contexto do problema.

7.1 Exemplo 1: Horas de Estudo e Nota Final

Situação-problema

Um professor registrou o número de horas semanais de estudo (X) e a nota final (Y , de 0 a 100) de 9 alunos:

x_i	2	3	4	5	6	7	8	9	10
y_i	55	60	62	68	72	75	80	83	88

(1) **Correlação.** $\bar{x} = 6,0$, $\bar{y} = 71,44$. Calculando: $\sum(x_i - \bar{x})(y_i - \bar{y}) = 163,0$, $\sum(x_i - \bar{x})^2 = 60,0$, $\sum(y_i - \bar{y})^2 = 451,6$.

$$r = \frac{163,0}{\sqrt{60,0 \times 451,6}} = \frac{163,0}{164,5} \approx 0,991 \quad (\text{correlação direta muito forte})$$

(2) **Estimativas OLS.**

$$\hat{\beta}_1 = \frac{163,0}{60,0} \approx 2,717 \quad \hat{\beta}_0 = 71,44 - 2,717 \times 6,0 \approx 55,14$$

Equação ajustada: $\hat{y} = 55,14 + 2,717x$.

(3) **Qualidade do ajuste.** $R^2 = r^2 \approx 0,982$: o modelo explica 98,2% da variabilidade das notas.

$$\text{SSE} = \sum(y_i - \hat{y}_i)^2 \approx 8,1, \quad S = \sqrt{8,1/(9-2)} \approx 1,075.$$

(4) Inferência sobre β_1 .

$$EP(\hat{\beta}_1) = \frac{1,075}{\sqrt{60}} \approx 0,1388, \quad t = \frac{2,717}{0,1388} \approx 19,57$$

p -valor ≈ 0 (com $t_{7,0,025} = 2,365$). Rejeitamos H_0 : o número de horas de estudo tem efeito linear significativo sobre a nota.

(5) Interpretação. Para cada hora adicional de estudo por semana, a nota média esperada aumenta em aproximadamente 2,7 pontos. O intercepto 55,14 seria a nota prevista para um aluno que estuda zero horas — mas como $x = 0$ está fora do intervalo dos dados (2–10 horas), essa extrapolação não deve ser interpretada literalmente.

7.2 Exemplo 2: Regressão Múltipla — Tempo de Entrega**Situação-problema**

Uma empresa de logística quer modelar o tempo de entrega (em horas) em função da distância percorrida (km) e do número de paradas intermediárias.

Entrega	Distância (km)	Paradas	Tempo (h)
1	100	1	3,2
2	150	2	5,1
3	200	1	4,8
4	200	3	7,0
5	250	2	6,5
6	300	3	8,2
7	300	1	6,0
8	350	4	10,1

(1) Modelo ajustado (via OLS).

$$\hat{y} = 0,215 + 0,0178(\text{distância}) + 1,612(\text{paradas})$$

(2) Interpretação dos coeficientes.

- $\hat{\beta}_1 = 0,0178$: mantido o número de paradas constante, cada km adicional de distância aumenta o tempo médio em 0,0178 horas (≈ 1 minuto).
- $\hat{\beta}_2 = 1,612$: mantida a distância constante, cada parada adicional aumenta o tempo médio em 1,612 horas.

(3) Qualidade. $R^2 = 0,978$, $R^2_{\text{ajust}} = 0,969$, $S = 0,37$ h.

(4) Teste F . $F(2, 5) = 110,4$, $p < 0,001$. O modelo é globalmente significativo.

(5) Testes t individuais. Ambos os coeficientes são significativos ($p < 0,01$): a distância e o número de paradas são preditores relevantes do tempo de entrega, controlando um pelo outro.

```
import numpy as np
import statsmodels.api as sm

distancia = np.array([100,150,200,200,250,300,300,350])
paradas   = np.array([1,2,1,3,2,3,1,4])
tempo     = np.array([3.2,5.1,4.8,7.0,6.5,8.2,6.0,10.1])

X = sm.add_constant(np.column_stack([distancia, paradas]))
resultado = sm.OLS(tempo, X).fit()
print(resultado.summary())
```

8 Resumo

A regressão linear é o modelo preditivo fundamental para variáveis quantitativas. O percurso completo de uma análise de regressão envolve:

1. Verificar visualmente a associação (diagrama de dispersão) e calcular r (regressão simples) antes de ajustar qualquer modelo.
2. Estimar os coeficientes por OLS e interpretar cada um no contexto do problema.
3. Avaliar a qualidade do ajuste via R^2 (ajustado em modelos múltiplos), S e a tabela ANOVA.
4. Diagnosticar as suposições do modelo pelos gráficos de resíduos.
5. Realizar inferência (testes t e F , intervalos de confiança e de predição).
6. Reportar resultados com precisão numérica e interpretação substantiva.

Síntese: Regressão Linear

Aspecto	Detalhe
Objetivo	Modelar $E[Y X]$ como função linear de preditores quantitativos
Estimação	OLS: minimiza $\sum e_i^2$; solução fechada para modelo simples; matricial para modelo múltiplo
Coef. simples	$\hat{\beta}_1 = s_{XY}/s_X^2 = r \cdot s_Y/s_X$; $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
Coef. múltipla	$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$
Suposições	LINE: linearidade, independência, normalidade, equivariância
Qualidade	$R^2 = \text{SSR}/\text{SST}$; R_{ajust}^2 (múltipla); $S = \sqrt{\text{QME}}$
Inf. sobre β_1	$t = \hat{\beta}_1/\text{EP}(\hat{\beta}_1) \sim t_{n-2}$ (simples); idem t_{n-p-1} (múltipla)
Teste global	$F = \text{QMR}/\text{QME} \sim F_{p, n-p-1}$; testa $H_0 : \beta_1 = \dots = \beta_p = 0$
IC vs. IP	IP mais largo: incorpora variabilidade individual além da incerteza na média
Diagnóstico	Resíduos vs. ajustados; Normal Q-Q; resíduos vs. preditores
Multicolinearidade	VIF > 10 indica problema; instabiliza $\hat{\beta}_j$ e infla EP
Limitações	Linearidade, extrapolação, outliers influentes, causalidade não inferida

9 Exercícios de Fixação

Exercício 1: Covariância e correlação

Uma pesquisadora coletou dados sobre temperatura média mensal ($^{\circ}\text{C}$) e consumo de sorvete (em centenas de unidades) em uma cidade:

Temperatura (x)	15	18	22	25	28	32
Consumo (y)	12	18	24	28	35	42

- (a) Calcule $\bar{x}$, $\bar{y}$, s_X , s_Y e s_{XY} .
- (b) Calcule o coeficiente de correlação de Pearson e interprete.
- (c) Construa o diagrama de dispersão e verifique se a linearidade parece razoável.
- (d) Uma campanha de marketing aumentou o consumo de sorvete em 5 unidades em todos os meses. Como isso afeta r ? Justifique sem recalcular.

Exercício 2: Derivação e cálculo das estimativas OLS

Usando os dados do exercício anterior:

- (a) Calcule $\hat{\beta}_1$ e $\hat{\beta}_0$ manualmente.
- (b) Escreva a equação da reta ajustada e interprete cada coeficiente.
- (c) Verifique que a reta passa pelo ponto $(\bar{x}, \bar{y})$.
- (d) Calcule os 6 resíduos $e_i = y_i - \hat{y}_i$ e verifique que $\sum e_i = 0$ e $\sum x_i e_i = 0$. (Essas são consequências algébricas das equações normais, não uma coincidência numérica.)

Exercício 3: Qualidade do ajuste e decomposição da variância

Continuando com os dados de temperatura e consumo de sorvete:

- (a) Calcule SST, SSR, SSE e verifique que $SST = SSR + SSE$.
- (b) Calcule R^2 de duas formas: (i) SSR/SST e (ii) r^2 . Os valores devem coincidir.
- (c) Calcule o erro padrão da regressão S .
- (d) Interprete R^2 e S no contexto do problema.

Exercício 4: Inferência: testes e intervalos

Usando o modelo do exercício anterior:

- (a) Calcule $EP(\hat{\beta}_1)$ e realize o teste $H_0 : \beta_1 = 0$ ao nível $\alpha = 0,05$.
- (b) Construa um intervalo de confiança de 95% para β_1 e interprete.
- (c) Para uma temperatura de $x^* = 20^\circ\text{C}$, calcule o valor previsto $\hat{y}^*$, o IC de 95% para $E[Y | x^*]$ e o IP de 95% para uma nova observação. Explique a diferença entre os dois intervalos.
- (d) Uma observação extra com temperatura 38°C não estava nos dados originais. Seria adequado usar o modelo para prever o consumo nessa temperatura? Justifique.

Exercício 5: Diagnóstico: identificar violações

Para cada conjunto de gráficos de resíduos descrito abaixo, identifique a suposição violada e sugira uma possível solução:

- (a) O gráfico de resíduos vs. valores ajustados mostra uma curva em forma de “U”.
- (b) O gráfico de resíduos vs. valores ajustados mostra uma dispersão que cresce em forma de cone (funil), de esquerda para direita.
- (c) O gráfico Normal Q-Q mostra que os pontos seguem a diagonal central mas se afastam nas caudas, sugerindo uma distribuição com caudas mais pesadas que a normal.
- (d) O gráfico de resíduos vs. ordem de coleta mostra uma tendência crescente ao longo do tempo.

Exercício 6: Regressão Múltipla: preço de imóveis

Um conjunto de dados contém o preço de venda (em R\$ mil), área útil (m²) e distância ao centro (km) de 12 imóveis. O ajuste OLS produziu:

$$\text{prêco} = 180,3 + 3,42 \times \text{area} - 8,75 \times \text{distancia}$$

com $R^2 = 0,88$, $R^2_{\text{ajust}} = 0,86$, $S = 25,3$ (R\$ mil), $F(2, 9) = 33,0$ ($p < 0,001$). Os p -valores dos testes t individuais foram: $p_{\text{area}} = 0,001$ e $p_{\text{distancia}} = 0,038$.

- (a) Interprete os coeficientes de *area* e *distancia* no contexto do problema.
- (b) Interprete R^2_{ajust} e S .
- (c) Qual é a conclusão do teste F global?
- (d) Ambos os preditores são individualmente significativos ao nível $\alpha = 0,05$?
- (e) Um imóvel com 90 m² e 5 km do centro tem preço previsto de quanto? Quais informações adicionais você precisaria para construir um IP de 95%?

Exercício 7: Projeto computacional: regressão com dados reais

Utilize o conjunto de dados `tips` disponível na biblioteca `seaborn` (gorjeta em dólares, conta total, dia da semana e outras variáveis):

- (a) Calcule a correlação entre `total_bill` e `tip` e construa o diagrama de dispersão.
- (b) Ajuste a regressão simples de `tip` sobre `total_bill` usando `statsmodels`. Reporte a equação, R^2 , S e a significância de $\hat{\beta}_1$.
- (c) Construa os gráficos de diagnóstico de resíduos e avalie as suposições LINE.
- (d) Ajuste um modelo múltiplo adicionando `size` (tamanho da mesa) como segundo preditor. Compare R^2_{ajust} e S com o modelo simples. A adição de `size` melhora o ajuste?
- (e) Calcule o VIF dos dois preditores e verifique se multicolinearidade é um problema.

```
import seaborn as sns
tips = sns.load_dataset('tips')
print(tips.head())
```