

Regressão Descontínua e Diferença-em-Diferenças

Notas de Aula

Prof. Eduardo Bezerra

Conteúdo

1	Da Regressão à Inferência Causal	3
1.1	Uma Pergunta que a Regressão Não Responde	3
1.2	A Linguagem Básica de uma Pergunta Causal	3
1.3	Associação, Identificação, Estimação e Inferência	5
1.4	O Problema Fundamental da Inferência Causal	5
1.5	Estratégias de Identificação Causal	6
2	Regressão Descontínua	7
2.1	Motivação: O Limiar como Experimento Natural	7
2.2	RDD Nítida: Definição Formal	8
2.3	A Suposição de Continuidade	10
2.4	Estimação por Regressão Linear Local	11
2.5	Escolha da Janela (<i>Bandwidth</i>)	13
2.6	Testes de Validade	14
2.6.1	Teste de Densidade de McCrary	15
2.6.2	Placebo de Covariáveis	15
2.6.3	Limiares Fictícios (<i>Placebo Cutoffs</i>)	15
2.7	Exemplo Completo	16
3	Diferença-em-Diferenças	22
3.1	Motivação	22
3.2	O Estimador DiD 2×2	22
3.3	Formulação por Regressão	23
3.4	A Suposição de Tendências Paralelas	24
3.5	Teste de Pré-Tendência	25
3.6	Exemplo Completo	26
4	Implementação em Python	31
4.1	Regressão Descontínua com <code>statsmodels</code>	31
4.2	Inspeção Visual da Densidade da Variável de Corte	33
4.3	Diferença-em-Diferenças com <code>statsmodels</code>	34
4.4	Teste de Pré-Tendência (Estudo de Evento)	35
5	Resumo Comparativo	36
6	Exercícios de Fixação	37

Objetivos

Ao final da leitura, você deve ser capaz de:

Fundamentos de Inferência Causal

- Enunciar o problema fundamental da inferência causal em termos de resultados potenciais.
- Distinguir associação estatística de efeito causal e explicar quando cada tipo de afirmação é legítimo.

Regressão Descontínua (RDD) ★

- Identificar situações em que um limiar de elegibilidade cria uma descontinuidade explorável.
- Enunciar a suposição de continuidade e explicar por que ela é a hipótese identificadora da RDD.
- Estimar o efeito causal por regressão linear local, escolher a janela (*bandwidth*) e interpretar o coeficiente $\hat{\tau}$.
- Distinguir RDD Nítida de RDD Difusa e relacionar a segunda a um estimador de variáveis instrumentais.
- Conduzir testes de validade (teste de densidade, placebo de covariáveis, limiares fictícios).

Diferença-em-Diferenças (DiD) ★

- Calcular o estimador DiD 2×2 e expressá-lo como coeficiente de interação em uma regressão.
- Enunciar a suposição de tendências paralelas, explicar por que ela não pode ser testada diretamente e avaliar sua plausibilidade com gráficos de pré-tendência.
- Estender o modelo de dois períodos para o estimador de efeitos fixos de dois lados (TWFE) com painel balanceado.
- Reconhecer os problemas de adoção escalonada e mencionar as correções modernas.

Roteiro de leitura

Estas notas estão organizadas em sete partes. A Seção 1 contextualiza os métodos no problema geral de inferência causal, servindo de ponte com as notas anteriores sobre regressão. A Seção 2 desenvolve a Regressão Descontínua (RDD). A Seção 3 desenvolve a Diferença-em-Diferenças (DiD). A Seção 4 reúne a implementação em Python de ambos os métodos. A Seção 5 apresenta exemplos completos. As Seções 6 e 7 trazem um resumo comparativo e exercícios de fixação.

Os objetivos marcados com ★ são os mais centrais e devem ser priorizados na leitura pré-aula. As subseções sobre RDD Difusa, seleção ótima de janela, TWFE com adoção escalonada e estudo de evento podem ser lidas como aprofundamento.

Antes da aula

Durante a leitura, procure responder a três perguntas centrais:

1. Qual é o contrafactual em RDD e em DiD?
2. Qual suposição torna esse contrafactual plausível em cada método?
3. Que evidência empírica enfraqueceria essa suposição?

Anote uma dúvida sobre RDD e uma dúvida sobre DiD para discussão em sala.

1 Da Regressão à Inferência Causal

1.1 Uma Pergunta que a Regressão Não Responde

Nas notas anteriores aprendemos que correlação não implica causalidade e que a regressão linear quantifica associações, mas não garante interpretação causal dos coeficientes. No entanto, perguntas causais são frequentemente as mais relevantes na prática:

- Uma bolsa de estudos *causa* melhora no desempenho acadêmico?
- Aumentar o salário mínimo *causa* redução no emprego?
- Um programa de vacinação *causa* queda na mortalidade?

Essas perguntas têm uma estrutura comum: queremos saber o que mudaria em um resultado se uma ação, política ou intervenção fosse aplicada. Essa ação é chamada, de forma genérica, de *tratamento*. O termo vem da estatística e da medicina, mas é usado de forma ampla: um tratamento pode ser receber uma bolsa, ser afetado por uma nova lei, participar de um curso, morar em uma região atendida por uma política pública ou cruzar um limiar de elegibilidade.

Responder a perguntas desse tipo exige mais do que ajustar uma reta. É preciso justificar que a diferença observada nos dados pode ser interpretada como consequência da intervenção, e não como resultado de outras diferenças entre os indivíduos, grupos ou períodos comparados.

1.2 A Linguagem Básica de uma Pergunta Causal

Antes de discutir métodos específicos, precisamos introduzir alguns termos básicos.

Unidade, tratamento, resultado e grupos

Em uma análise causal, começamos definindo:

- **Unidade:** o objeto individual da análise. Pode ser um aluno, uma escola, uma empresa, um município, um hospital ou um país.
- **Tratamento:** a intervenção, política, exposição ou condição cujo efeito queremos estudar. Por exemplo, receber uma bolsa de estudos, participar de um programa de capacitação ou estar sujeito a uma nova regra.
- **Resultado:** a variável que queremos explicar ou comparar. Por exemplo, nota final, salário, taxa de emprego, mortalidade ou número de internações.
- **Grupo tratado:** conjunto de unidades que receberam o tratamento.
- **Grupo controle:** conjunto de unidades que não receberam o tratamento e que será usado como referência de comparação.

Por exemplo, se queremos avaliar se uma bolsa de estudos melhora o desempenho acadêmico, as unidades podem ser os alunos, o tratamento é receber a bolsa, o resultado pode ser a nota final, o grupo tratado é formado pelos alunos que receberam a bolsa e o grupo controle é formado pelos alunos que não receberam.

A dificuldade é que comparar diretamente tratados e controles pode ser enganoso. Alunos que recebem bolsa podem já ser diferentes dos demais antes da bolsa: podem ter maior desempenho prévio, maior motivação, melhor apoio familiar ou critérios específicos de seleção. Nesse caso, uma diferença de notas entre os dois grupos pode refletir essas diferenças anteriores, e não necessariamente o efeito da bolsa.

O que é um efeito causal?

Dizer que um tratamento teve efeito causal significa comparar dois cenários para a mesma unidade:

- o resultado que a unidade teria se recebesse o tratamento;
- o resultado que a mesma unidade teria se não recebesse o tratamento.

A diferença entre esses dois cenários é o *efeito causal* do tratamento para aquela unidade. O problema é que, na prática, só observamos um dos dois cenários: um aluno recebe a bolsa ou não recebe; um município adota a política ou não adota; uma empresa é afetada pela regra ou não é afetada.

O cenário não observado é chamado de *contrafactual*: aquilo que teria acontecido com a mesma unidade sob a condição alternativa.

Essa é a razão pela qual inferência causal é difícil. A comparação ideal seria entre a mesma unidade com e sem tratamento, no mesmo momento e nas mesmas condições. Como isso é impossível, precisamos construir uma comparação plausível usando os dados disponíveis.

1.3 Associação, Identificação, Estimação e Inferência

Com a linguagem básica da inferência causal em mãos, podemos separar quatro tarefas diferentes envolvidas em uma análise causal. Essa separação evita uma confusão comum: achar que encontrar uma relação estatística entre duas variáveis já é suficiente para concluir que uma causa a outra.

Quatro verbos diferentes: associar, identificar, estimar e inferir

Em inferência causal, é útil separar quatro tarefas distintas:

- **Associar:** descrever, por meio da análise estatística dos dados, como duas variáveis se movem juntas. Por exemplo, podemos verificar se alunos que receberam bolsa têm, em média, notas maiores do que alunos que não receberam. Essa etapa descreve uma relação observada nos dados, mas ainda não permite concluir que a bolsa causou o aumento das notas.
- **Identificar:** justificar por que uma comparação feita nos dados pode ser interpretada como uma aproximação válida do contrafactual. Em outras palavras, identificar significa argumentar que o grupo controle, ou algum outro tipo de comparação disponível, representa de forma plausível o que teria acontecido com o grupo tratado se ele não tivesse recebido o tratamento. Essa justificativa vem do desenho do estudo e das suposições causais, não da regressão em si.
- **Estimar:** calcular numericamente o efeito de interesse a partir de uma amostra. Depois que uma estratégia de identificação foi definida, a estimação fornece um valor numérico para o efeito, como “a bolsa aumentou a nota média em 0,8 ponto”.
- **Inferir:** quantificar a incerteza associada à estimativa, usando erro padrão, intervalo de confiança ou teste de hipótese. Essa etapa responde a perguntas como: a estimativa é precisa? O efeito estimado é estatisticamente distinguível de zero?

A regressão linear contribui principalmente com as etapas de estimação e inferência. A identificação é um problema separado: ela depende de uma estratégia que torne plausível interpretar uma comparação observada nos dados como evidência de um efeito causal. RDD e DiD são, antes de tudo, estratégias de *identificação*.

1.4 O Problema Fundamental da Inferência Causal

O arcabouço moderno de causalidade foi desenvolvido por Rubin, Holland e outros a partir dos anos 1970 [Rubin, 1974]. Esse arcabouço formaliza o problema em termos de *resultados potenciais*.

Resultados Potenciais e o Efeito Causal Individual

Para cada unidade i , definimos dois resultados potenciais:

- $Y_i(1)$: resultado que i teria se recebesse o tratamento.
- $Y_i(0)$: resultado que i teria se não recebesse o tratamento.

O efeito causal individual é $\tau_i = Y_i(1) - Y_i(0)$.

O efeito médio do tratamento (ATE) é $\tau_{ATE} = E[\tau_i] = E[Y_i(1) - Y_i(0)]$.

O efeito médio sobre os tratados (ATT) é $\tau_{ATT} = E[\tau_i \mid D_i = 1]$, onde $D_i \in \{0, 1\}$ indica se i recebeu o tratamento.

O problema fundamental é que só observamos *um* dos dois resultados potenciais por unidade: se $D_i = 1$, observamos $Y_i(1)$; se $D_i = 0$, observamos $Y_i(0)$. O resultado não observado (i.e., o que teria acontecido sob a condição contrária) é chamado de *contrafactual* e nunca está nos dados.

Pergunta 1

Um programa de bolsas de estudo foi oferecido a um grupo de alunos. Uma aluna i participou ($D_i = 1$) e obteve nota 8,5 ($Y_i = 8,5$).

- O que representa $Y_i(0)$ nesse contexto? Por que não o observamos?
- Um colega argumenta: “Ela teria tirado 8,5 de qualquer forma, pois é esforçada.” Isso corresponde a qual valor de τ_i ?
- Por que a comparação simples entre médias de participantes e não-participantes pode superestimar ou subestimar τ_{ATT} ?

A comparação simples entre as médias observadas,

$$E[Y \mid D = 1] - E[Y \mid D = 0],$$

não isola, em geral, o efeito causal do tratamento. Essa diferença mistura duas componentes: o possível efeito do tratamento e as diferenças pré-existentes entre as unidades que receberam e as que não receberam o tratamento. No exemplo da bolsa de estudos, os alunos participantes podem já ter melhor desempenho anterior, maior motivação ou maior apoio familiar antes mesmo de receberem a bolsa. Nesse caso, parte da diferença observada nas notas não seria causada pela bolsa, mas pelo fato de que os grupos comparados já eram diferentes desde o início. Esse problema é chamado de *seleção*. A tarefa central dos métodos de inferência causal é justamente construir uma comparação na qual essa seleção seja eliminada, controlada ou tornada plausivelmente irrelevante.

1.5 Estratégias de Identificação Causal

A discussão anterior mostra que o principal desafio da inferência causal não é apenas calcular uma diferença de médias ou ajustar uma regressão. O desafio central é construir uma comparação que represente, de forma plausível, o contrafactual: isto é, o que teria acontecido com as unidades tratadas caso elas não tivessem recebido o tratamento.

O cenário ideal para resolver esse problema é o *experimento aleatório*, ou ensaio controlado randomizado (*randomized controlled trial*, RCT). Em um experimento desse tipo, o

tratamento é atribuído ao acaso. Como consequência, antes da intervenção, espera-se que o grupo tratado e o grupo controle sejam semelhantes tanto em características observáveis quanto em características não observáveis. Formalmente, a atribuição ao tratamento é independente dos resultados potenciais:

$$D_i \perp (Y_i(0), Y_i(1)).$$

Essa independência significa que saber se uma unidade recebeu ou não o tratamento não revela informação sistemática sobre os resultados que ela teria em cada cenário potencial. Por isso, em um experimento aleatório bem conduzido, a diferença média observada entre tratados e controles pode ser interpretada como efeito causal médio do tratamento.

Na prática, porém, experimentos aleatórios nem sempre são possíveis. Eles podem ser caros, demorados, inviáveis do ponto de vista operacional ou inadequados do ponto de vista ético. Não podemos, por exemplo, sortear arbitrariamente quais municípios receberão uma política pública essencial, quais trabalhadores estarão sujeitos a uma lei trabalhista ou quais pacientes deixarão de receber uma intervenção considerada necessária.

É nesse contexto que surgem os *métodos quasi-experimentais*. Eles não atribuem o tratamento ao acaso, mas exploram situações em que os próprios dados contêm alguma fonte de variação que se aproxima de uma atribuição experimental. Essa variação pode vir de uma regra institucional, de uma mudança de política ao longo do tempo ou de algum fator externo que afeta a probabilidade de receber o tratamento sem afetar diretamente o resultado de interesse.

A ideia comum a esses métodos é substituir o experimento ideal, que muitas vezes não pode ser realizado, por uma estratégia de comparação bem justificada. Cada método quasi-experimental propõe uma forma diferente de construir o contrafactual do grupo tratado.

Método	Como constrói a comparação	Estimando
Regressão Descontínua	Compara unidades próximas a um limiar institucional	Efeito local no limiar
Diferença-em-Diferenças	Compara mudanças ao longo do tempo entre grupo tratado e controle	ATT, sob tendências paralelas
Variáveis Instrumentais	Usa uma fonte externa de variação no tratamento	LATE dos cumpridores

Nas próximas seções, estudaremos duas dessas estratégias em detalhe. A Regressão Descontínua explora regras de elegibilidade baseadas em limiares, como notas de corte, margens eleitorais ou limites de renda. A Diferença-em-Diferenças explora mudanças ocorridas ao longo do tempo, comparando a trajetória de um grupo afetado por uma política com a trajetória de um grupo não afetado. Em ambos os casos, a pergunta central será a mesma: por que a comparação proposta pode ser interpretada como uma aproximação plausível do contrafactual?

2 Regressão Descontínua

2.1 Motivação: O Limiar como Experimento Natural

Na seção anterior, vimos que o desafio central da inferência causal é construir uma comparação plausível para o contrafactual: o que teria acontecido com as unidades tratadas se

elas não tivessem recebido o tratamento. A Regressão Descontínua parte de uma situação particular em que essa comparação pode surgir de forma bastante natural: quando uma regra institucional atribui tratamento com base em um limiar.

Muitas políticas públicas, decisões administrativas e regras de elegibilidade dependem de uma variável numérica. Essa variável é chamada de *variável de corte* (*running variable*), pois é ela que determina de que lado do limiar cada unidade ficará. Denotaremos essa variável por X e o limiar por c .

Alguns exemplos são:

- Bolsas de mérito: aluno recebe bolsa se $X_i \geq c$, onde X_i é sua nota e c é a nota de corte.
- Elegibilidade para programa social: família recebe o benefício se $X_i \leq c$, onde X_i é sua renda e c é o limite de renda.
- Eleições: candidato vence se $X_i \geq 50\%$, onde X_i é sua proporção de votos.
- Crédito: empréstimo é aprovado se $X_i \geq c$, onde X_i é o score de crédito e c é o limite mínimo exigido.

A intuição central da RDD é que unidades muito próximas ao limiar tendem a ser bastante semelhantes. Um aluno com nota 6,95 e outro com nota 7,05, por exemplo, provavelmente não são muito diferentes em termos de desempenho acadêmico, motivação ou preparo. No entanto, se o corte da bolsa é 7,0, apenas o segundo recebe o tratamento. Assim, na vizinhança imediata do limiar, pequenas diferenças em X podem gerar uma grande diferença na probabilidade de receber o tratamento.

É por isso que o limiar pode funcionar como um *experimento natural local*. As unidades logo abaixo do corte servem como aproximação do contrafactual das unidades logo acima: elas representam o que poderia ter acontecido com os tratados caso não tivessem cruzado o limiar. A comparação não é válida para unidades muito distantes do corte, mas pode ser plausível quando nos concentramos em uma janela suficientemente estreita ao redor de c .

Pergunta 2

Considere duas situações:

- (a) Um aluno que obteve nota 6,95 vs. um aluno com nota 7,05 (corte = 7,0 para bolsa). Por que é razoável tratá-los como comparáveis?
- (b) Um aluno com nota 4,0 vs. um aluno com nota 9,0. Por que essa comparação não é válida para estimar o efeito da bolsa?
- (c) Qual é a hipótese implícita que permite afirmar que alunos muito próximos ao limiar são comparáveis?

2.2 RDD Nítida: Definição Formal

A intuição apresentada na seção anterior pode agora ser escrita formalmente. Na *Regressão Descontínua Nítida* (*Sharp Regression Discontinuity Design*), a regra de elegibilidade

determina perfeitamente quem recebe o tratamento. Isto é, o tratamento depende apenas de a variável de corte X_i cruzar ou não o limiar c .

No caso em que o tratamento é atribuído às unidades com valores de X_i acima do limiar, escrevemos:

$$D_i = \mathbf{1}(X_i \geq c),$$

onde $D_i = 1$ indica que a unidade i recebeu o tratamento e $D_i = 0$ indica que não recebeu. Assim, todas as unidades com $X_i \geq c$ são tratadas, enquanto todas as unidades com $X_i < c$ permanecem no grupo controle. Por isso dizemos que a descontinuidade é *nítida*: a probabilidade de tratamento salta de 0 para 1 exatamente no ponto de corte.

O objetivo da RDD não é comparar todos os tratados com todos os controles. Unidades muito distantes do limiar podem ser bastante diferentes entre si. Por exemplo, em um programa de bolsas com nota de corte igual a 7,0, alunos com nota 9,5 provavelmente não são comparáveis a alunos com nota 4,0. A comparação relevante é local: unidades imediatamente acima do limiar são comparadas com unidades imediatamente abaixo dele.

Estimando da RDD Nítida

O efeito causal estimado pela RDD Nítida é o *efeito médio local do tratamento no limiar*. Ele é definido como o salto na média condicional do resultado quando a variável de corte cruza o ponto de corte:

$$\tau_{\text{RDD}} = \lim_{x \downarrow c} E[Y \mid X = x] - \lim_{x \uparrow c} E[Y \mid X = x].$$

O primeiro termo representa o valor esperado do resultado para unidades que se aproximam do limiar pelo lado tratado. O segundo termo representa o valor esperado do resultado para unidades que se aproximam do limiar pelo lado controle. A diferença entre esses dois limites laterais é interpretada como o efeito causal local do tratamento, desde que a suposição de continuidade, discutida na próxima seção, seja plausível.

Essa formulação explicita o papel do limiar como fonte de identificação. Se, na ausência do tratamento, o resultado esperado variasse suavemente com X , não haveria razão para observar um salto abrupto exatamente em c . Portanto, quando observamos uma descontinuidade em $E[Y \mid X = x]$ no ponto de corte, a RDD atribui esse salto ao tratamento, mas apenas sob a hipótese de que nenhuma outra mudança relevante ocorre no mesmo limiar.

RDD estima um efeito local, não um efeito médio populacional

O parâmetro τ_{RDD} não deve ser interpretado como o efeito médio do tratamento para toda a população. Ele descreve o efeito para unidades na vizinhança do limiar, isto é, para unidades cuja posição na variável de corte está muito próxima do ponto de corte.

Esse escopo local é uma limitação importante. Um programa de bolsas pode ter efeito diferente para alunos com nota 7,1 e para alunos com nota 9,5. A RDD identifica o efeito para os alunos próximos ao corte, mas não garante que o mesmo efeito se aplique a alunos distantes dele. Ao mesmo tempo, essa localidade é justamente a força do método: quanto mais nos concentramos em unidades próximas ao limiar, mais plausível se torna a comparação entre tratados e controles.

Essa interpretação causal, entretanto, ainda depende de uma hipótese importante: na ausência do tratamento, o resultado esperado deveria variar de forma contínua ao redor do limiar. Em outras palavras, o ponto de corte deve alterar o recebimento do tratamento, mas não deve coincidir com outras mudanças relevantes capazes de afetar o resultado. Essa é a suposição de continuidade, discutida a seguir.

2.3 A Suposição de Continuidade

A seção anterior mostrou que a RDD interpreta o salto em $E[Y \mid X = x]$ no limiar como efeito causal do tratamento. Mas essa interpretação não vem apenas da existência de uma regra de corte. Ela depende de uma hipótese central: na ausência do tratamento, unidades imediatamente abaixo e imediatamente acima do limiar teriam resultados esperados muito parecidos.

Em outras palavras, a RDD exige que o limiar c produza uma mudança abrupta no recebimento do tratamento, mas não produza, ao mesmo tempo, uma mudança abrupta em outros fatores que também afetam o resultado. Se tudo o mais varia suavemente ao redor de c , então um salto observado em Y exatamente no limiar pode ser atribuído ao tratamento.

Suposição de Continuidade

A hipótese identificadora da RDD é que, na ausência do tratamento, o resultado potencial sem tratamento variaria continuamente ao redor do limiar:

$$\lim_{x \rightarrow c^+} E[Y_i(0) \mid X_i = x] = \lim_{x \rightarrow c^-} E[Y_i(0) \mid X_i = x].$$

Em palavras: se o tratamento não existisse, a média do resultado não deveria apresentar um salto exatamente em c . A função poderia crescer, diminuir ou ter inclinação diferente em diferentes regiões, mas não deveria sofrer uma quebra abrupta no ponto de corte.

Assim, quando observamos uma descontinuidade em $E[Y \mid X = x]$ no limiar, a RDD interpreta essa descontinuidade como efeito do tratamento. Essa interpretação é plausível apenas se nenhuma outra característica relevante também mudar abruptamente em c .

Considere novamente o exemplo da bolsa com nota de corte igual a 7,0. A suposição de continuidade afirma que, na ausência da bolsa, alunos logo abaixo e logo acima do corte teriam desempenho esperado semelhante. Por exemplo, não esperamos que alunos com nota 6,95 sejam, em média, muito diferentes dos alunos com nota 7,05 em motivação, preparo anterior, apoio familiar ou outras características relevantes para o desempenho. A diferença importante entre esses dois grupos deve ser produzida pela regra de elegibilidade: os alunos logo acima do corte recebem a bolsa, enquanto os alunos logo abaixo não recebem. A ideia não é afirmar que os alunos dos dois lados do corte são idênticos. A ideia é que, em uma vizinhança muito pequena do limiar, não deve haver uma diferença sistemática entre eles que explique, por si só, um salto no resultado. Se um salto aparece exatamente no corte, e se nenhuma outra regra muda nesse ponto, a RDD atribui esse salto ao tratamento.

Essa hipótese também ajuda a entender por que a RDD é uma estratégia local. A comparação entre alunos com nota 6,95 e 7,05 pode ser plausível; a comparação entre

alunos com nota 4,0 e 9,5 provavelmente não é. Quanto mais longe do limiar, menos convincente se torna a ideia de que os grupos são comparáveis.

Quando a suposição de continuidade falha

A suposição de continuidade pode falhar quando o limiar altera mais do que apenas o tratamento de interesse. Alguns exemplos comuns são:

- **Outra política usa o mesmo limiar.** Se alunos com nota ≥ 7 recebem simultaneamente bolsa e acesso a um laboratório especial, o salto observado no desempenho pode refletir a bolsa, o laboratório ou a combinação dos dois efeitos.
- **Manipulação precisa da variável de corte.** Se alunos, professores ou gestores conseguem ajustar notas próximas ao corte para que alguns estudantes fiquem acima de 7,0, as unidades logo acima do limiar deixam de ser comparáveis às unidades logo abaixo. Nesse caso, estar acima do corte pode refletir uma escolha ou intervenção estratégica, e não apenas uma pequena diferença na nota.
- **Mudança abrupta na composição das unidades.** Se os alunos logo acima do corte pertencem sistematicamente a um perfil diferente dos alunos logo abaixo, por exemplo por causa de uma regra de arredondamento, seleção adicional ou triagem administrativa, a comparação local fica comprometida.
- **Comportamento antecipatório.** Se as unidades conhecem o limiar e mudam seu comportamento antes da medição da variável de corte, a comparação ao redor do corte pode deixar de representar uma situação quase-experimental.

Portanto, a validade de uma RDD não depende apenas de ajustar uma regressão dos dois lados do limiar. Depende, sobretudo, de defender que o ponto de corte gera uma descontinuidade no tratamento, mas não gera descontinuidades simultâneas em outros determinantes do resultado. Os testes de validade apresentados mais adiante ajudam a avaliar empiricamente essa hipótese.

2.4 Estimação por Regressão Linear Local

A definição formal da RDD envolve a comparação entre dois limites laterais: o valor esperado de Y quando X se aproxima do limiar pelo lado controle e o valor esperado de Y quando X se aproxima do limiar pelo lado tratado. Na prática, porém, não observamos diretamente esses limites. Observamos apenas unidades com valores de X próximos ao limiar, mas não o valor exato das funções condicionais em $x = c$.

Por isso, precisamos de um procedimento de estimação que use os dados ao redor do ponto de corte para aproximar o comportamento de $E[Y \mid X = x]$ dos dois lados do limiar. A abordagem padrão moderna é a *regressão linear local*: em vez de ajustar um modelo global usando toda a amostra, restringimos a análise a uma janela em torno do limiar e ajustamos uma reta de cada lado.

A ideia é simples. Dentro de uma vizinhança suficientemente pequena de c , espera-se que uma reta seja uma aproximação razoável para a relação entre X e Y em cada lado do

corte. O salto estimado entre essas duas retas no ponto $x = c$ é então interpretado como a estimativa do efeito local da RDD.

Regressão Linear Local para RDD

Dentro de uma janela $[c - h, c + h]$, ajusta-se o modelo:

$$Y_i = \beta_0 + \beta_1(X_i - c) + \tau D_i + \delta \cdot D_i(X_i - c) + \varepsilon_i,$$

onde $D_i = \mathbf{1}(X_i \geq c)$.

A variável $X_i - c$ é a variável de corte centralizada no limiar. Essa centralização é importante porque faz com que o ponto $X_i - c = 0$ corresponda exatamente ao ponto de corte.

Os termos do modelo têm a seguinte interpretação:

- β_0 : valor previsto para o grupo controle no limiar, isto é, o limite estimado pelo lado esquerdo.
- β_1 : inclinação da reta no lado controle ($X_i < c$).
- τ : parâmetro associado ao salto no limiar; sua estimativa, $\hat{\tau}_{\text{RDD}}$, é a estimativa do efeito local da RDD.
- δ : diferença entre a inclinação do lado tratado e a inclinação do lado controle.

Assim, $\hat{\tau}_{\text{RDD}}$ mede o salto estimado em $x = c$, e não uma diferença média entre todos os tratados e todos os controles.

A especificação acima é equivalente a ajustar duas retas separadas. Para unidades abaixo do limiar, isto é, com $D_i = 0$, o modelo se reduz a

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1(x - c).$$

Para unidades acima do limiar, isto é, com $D_i = 1$, o modelo se torna

$$\hat{y} = (\hat{\beta}_0 + \hat{\tau}) + (\hat{\beta}_1 + \hat{\delta})(x - c).$$

Portanto, $\hat{\tau}$ é a diferença entre os dois valores previstos no ponto de corte. Essa forma de escrever o modelo ajuda a visualizar por que a centralização em c é conveniente: quando $x = c$, todos os termos envolvendo $(x - c)$ desaparecem, restando apenas a diferença entre os interceptos locais.

A Figura 1 resume visualmente essa lógica. Os pontos representam unidades observadas nos dois lados do limiar. Em cada lado, ajusta-se uma reta local. O estimador da RDD é o salto entre os valores previstos por essas duas retas no ponto de corte. Observe que as retas não são usadas para comparar todos os tratados com todos os controles; elas servem para aproximar os dois limites laterais que aparecem na definição formal da RDD.




Figura 1: Exemplo de RDD Nítida. A variável de corte X é centralizada no limiar $c = 0$. Cada lado recebe uma reta ajustada separadamente. O estimador $\hat{\tau}_{\text{RDD}}$ é a diferença entre os valores previstos pelas duas retas no ponto de corte. A descontinuidade visual é sugestiva de um efeito local, mas sua interpretação causal depende da validade da suposição de continuidade.

Salto visual não basta

A Figura 1 ajuda a enxergar a lógica da RDD, mas um salto visual no gráfico não é prova automática de efeito causal. A interpretação causal depende de o limiar alterar apenas o tratamento de interesse. Se outra regra, outra política ou uma mudança de composição também ocorre no mesmo ponto de corte, o salto observado pode misturar vários efeitos.

Por isso, a evidência gráfica deve ser interpretada em conjunto com as suposições e verificações de validade da RDD. O gráfico mostra o padrão nos dados; a validade causal vem do argumento de identificação.

2.5 Escolha da Janela (*Bandwidth*)

Na regressão linear local, não usamos necessariamente todos os dados disponíveis. Usamos apenas as observações que estão dentro de uma janela ao redor do limiar c :

$$[c - h, c + h].$$

O parâmetro h é chamado de *bandwidth* ou largura da janela. Ele determina o quão perto do limiar uma unidade precisa estar para ser incluída na estimação.

A escolha de h é importante porque a RDD é um método local. A comparação causal é mais plausível quando usamos unidades próximas ao ponto de corte, pois elas tendem a ser mais comparáveis. Por outro lado, se a janela for estreita demais, restarão poucas observações para estimar as retas dos dois lados do limiar.

Assim, a escolha da janela envolve um compromisso:

- **Janela muito estreita:** usa apenas unidades muito próximas ao limiar. Isso torna a comparação mais plausível e reduz o risco de a relação entre X e Y ser mal

aproximada por uma reta. No entanto, como poucas observações são usadas, a estimativa pode ficar muito instável e com erro padrão alto.

- **Janela muito larga:** inclui mais observações e, portanto, tende a produzir estimativas mais precisas do ponto de vista estatístico. Porém, unidades mais distantes do limiar podem ser menos comparáveis, e uma reta pode deixar de ser uma boa aproximação para a relação entre X e Y em uma região mais ampla.

Em termos estatísticos, esse compromisso é descrito como um balanço entre *viés* e *variância*. Janelas estreitas tendem a reduzir o viés da aproximação local, mas aumentam a variância da estimativa. Janelas largas tendem a reduzir a variância, mas podem aumentar o viés caso a relação entre X e Y não seja aproximadamente linear em toda a janela.

Seleção da janela na prática

Na prática, a largura da janela não deve ser escolhida olhando para qual valor produz o resultado mais conveniente. O procedimento recomendado é usar critérios pré-especificados e reportar análises de robustez.

Um procedimento amplamente utilizado é o seletor de janela proposto por Calonico et al. [2014], frequentemente chamado de seletor CCT. A ideia é escolher uma janela que equilibre, de forma sistemática, o viés e a variância da estimativa. Esse procedimento é implementado no pacote `rdrobust`, disponível em R e Python, por meio de funções como `rdbwselect()`.

A fórmula matemática do seletor é complexa e não é o foco destas notas. O ponto essencial é entender que a janela deve ser escolhida por um critério transparente e replicável, não por tentativa e erro orientada pelo resultado.

Mesmo quando uma janela principal é selecionada por um procedimento automático, é boa prática verificar se a conclusão é robusta a escolhas razoáveis de h . Por exemplo, se h é a janela principal, podemos também reportar resultados usando $0,5h$ e $1,5h$. Se a estimativa muda drasticamente quando a janela é levemente alterada, isso sugere que a evidência empírica é sensível à escolha do bandwidth e deve ser interpretada com cautela.

Erro comum: escolher a janela olhando para o resultado

Um erro grave é testar várias janelas e escolher aquela que produz o menor p -valor, o maior efeito estimado ou o resultado mais alinhado à hipótese do pesquisador. Esse procedimento é uma forma de *p-hacking*: a escolha do método passa a depender do resultado que se deseja obter.

A seleção da janela deve ser definida antes da análise principal ou baseada em um critério automático e replicável, como o seletor CCT. A análise de múltiplas janelas deve ser usada para avaliar robustez, não para escolher a especificação mais favorável.

2.6 Testes de Validade

A validade de uma RDD repousa sobre suposições não testáveis diretamente. No entanto, um conjunto de testes empíricos pode revelar violações.

2.6.1 Teste de Densidade de McCrary

Se os agentes puderem manipular precisamente a variável de corte para ficarem logo acima (ou abaixo) do limiar, haverá um empilhamento anormal de observações em um lado. O teste de densidade de McCrary (2008) verifica se a densidade estimada de X é contínua em c : um salto na densidade é evidência de manipulação.




Figura 2: Teste de densidade de McCrary. Esquerda: densidade da variável de corte é contínua no limiar, o que é um sinal de ausência de manipulação. Direita: um salto na densidade logo acima de c sugere que agentes empilharam suas observações do lado tratado.

A Figura 2 ilustra o contraste entre uma distribuição válida e uma que sinaliza manipulação. No caso da esquerda, a densidade é suave ao cruzar o limiar; no caso da direita, há um acúmulo anormal de observações logo acima de c , sugerindo que agentes conseguiram posicionar-se estrategicamente do lado tratado.

2.6.2 Placebo de Covariáveis

Se a suposição de continuidade for válida, covariáveis *pré-determinadas* (sexo, raça, renda familiar, notas de anos anteriores) não devem apresentar descontinuidade em c : elas foram fixadas antes de o limiar ser relevante. Rodar a mesma regressão RDD com cada covariável como variável dependente e verificar que $\hat{\tau} \approx 0$ é um teste de placebo fundamental.

2.6.3 Limiares Fictícios (*Placebo Cutoffs*)

Estimativas RDD em valores $c' \neq c$ (onde não existe nenhum tratamento) devem retornar $\hat{\tau} \approx 0$. Se encontrarmos saltos significativos em limiares fictícios, a variável de corte pode exibir descontinuidades naturais na resposta que não têm origem no tratamento.

Checklist de Validade para RDD

1. Teste de densidade: a distribuição de X é contínua em c ?
2. Placebo de covariáveis: covariáveis pré-determinadas não exibem salto em c ?
3. Limiares fictícios: não há salto significativo em $c' \neq c$?
4. Robustez de janela: as estimativas são estáveis para múltiplos valores de h ?
5. Robustez de especificação: resultados semelhantes com e sem controles adicionais?

Se algum desses itens falhar, o pesquisador deve investigar a causa antes de reportar resultados causais.

Checkpoint de RDD: você entendeu se consegue explicar...

1. Por que a comparação precisa ser *local* ao limiar.
2. Por que manipulação da variável de corte ameaça a validade.
3. Por que a escolha da janela afeta o balanço entre viés e variância.
4. Por que a RDD Difusa leva a uma razão entre dois saltos.

Ponte entre RDD e Diferença-em-Diferenças

Na RDD, o contrafactual é construído *localmente no espaço*: unidades logo abaixo do limiar representam o que teria acontecido com unidades logo acima, caso não recebessem o tratamento. Em DiD, o contrafactual é construído *temporalmente*: a evolução do grupo controle representa o que teria acontecido com o grupo tratado na ausência da política.

Os dois métodos tentam resolver o mesmo problema fundamental (observar o contrafactual de cada unidade), mas exploram fontes diferentes de comparação. A pergunta central em ambos não é “qual método é mais sofisticado?”, mas sim: *qual comparação observável é uma boa aproximação do contrafactual?*

2.7 Exemplo Completo

Nesta seção, vamos aplicar a lógica da Regressão Descontínua a um exemplo completo. O objetivo é mostrar como a pergunta causal, a regra de elegibilidade, a estimação local e as verificações de validade aparecem juntas em uma análise.

Situação-problema

Uma universidade concede bolsas de permanência a alunos que obtiveram nota de ingresso maior ou igual a 70 no exame de seleção. A regra institucional é:

$$D_i = \begin{cases} 1, & \text{se } X_i \geq 70, \\ 0, & \text{se } X_i < 70, \end{cases}$$

onde X_i é a nota de ingresso do aluno i e D_i indica se ele recebeu a bolsa.

O pesquisador quer estimar o efeito da bolsa sobre a taxa de conclusão do curso. A variável de resultado é:

$$Y_i = \begin{cases} 1, & \text{se o aluno concluiu o curso,} \\ 0, & \text{caso contrário.} \end{cases}$$

A pergunta causal é:

Receber a bolsa aumenta a probabilidade de concluir o curso?

Observe que a pergunta não é apenas se alunos bolsistas concluem mais o curso do que alunos não bolsistas. Essa comparação simples poderia ser enganosa, pois alunos com notas muito altas provavelmente são diferentes de alunos com notas muito baixas. A RDD evita essa comparação ampla e concentra a análise apenas nos alunos próximos ao corte de 70 pontos. Neste exemplo, temos:

- *Unidade de análise*: aluno.
- *Variável de corte*: nota de ingresso, X_i .
- *Limiar*: $c = 70$.
- *Tratamento*: receber bolsa de permanência.
- *Resultado*: conclusão do curso.
- *Tipo de RDD*: RDD Nítida, pois a regra determina perfeitamente quem recebe a bolsa.
- *Estimando*: efeito causal local da bolsa para alunos com nota próxima de 70.

A ideia central é comparar alunos que ficaram ligeiramente abaixo e ligeiramente acima do corte. Por exemplo, alunos com nota 69,8 e 70,2 provavelmente são semelhantes em termos de preparo acadêmico medido pelo exame de ingresso. No entanto, pela regra da universidade, apenas o segundo grupo recebe a bolsa. Essa mudança abrupta na elegibilidade é a fonte de identificação da RDD.

1. Primeira descrição dos dados

Suponha que o pesquisador inicialmente restrinja a análise a uma janela de 8 pontos ao redor do corte, isto é, considere apenas alunos com nota entre 62 e 78. Os dados resumidos são:

	Controle $X \in [62, 70)$	Tratado $X \in [70, 78]$
Tamanho amostral	87	94
Taxa de conclusão média	0,61	0,74
Nota média de ingresso	66,3	73,8
% feminino	52%	54%
% renda baixa	38%	37%

A diferença bruta nas taxas médias de conclusão é:

$$0,74 - 0,61 = 0,13.$$

Uma leitura apressada diria que a bolsa aumenta a taxa de conclusão em 13 pontos percentuais. No entanto, essa comparação ainda não é a estimativa RDD principal. Ela compara todos os alunos dentro da janela, mas ignora que a taxa de conclusão pode variar gradualmente com a nota de ingresso. Mesmo dentro da janela $[62, 78]$, alunos com notas mais altas podem ter maior probabilidade de concluir o curso, independentemente da bolsa.

Por que a diferença bruta não é suficiente?

A diferença bruta entre os dois lados do corte mistura dois componentes:

1. o possível efeito da bolsa;
2. a diferença esperada de conclusão associada ao fato de os alunos do lado tratado terem, em média, notas de ingresso maiores.

Por isso, a RDD não se baseia apenas na diferença de médias dentro da janela. Ela estima o salto no ponto de corte, descontando a tendência local da relação entre nota de ingresso e conclusão.

2. Centralização da variável de corte

Antes de ajustar a regressão local, centralizamos a variável de corte no limiar:

$$X_i^* = X_i - 70.$$

Assim, alunos exatamente no ponto de corte têm $X_i^* = 0$; alunos abaixo do corte têm $X_i^* < 0$; e alunos acima do corte têm $X_i^* \geq 0$. Essa centralização facilita a interpretação da regressão. O coeficiente associado ao tratamento passa a representar diretamente o salto estimado no ponto de corte.

3. Modelo de regressão linear local

Dentro da janela $[62, 78]$, ajustamos o modelo:

$$Y_i = \beta_0 + \beta_1 X_i^* + \tau D_i + \delta D_i X_i^* + \varepsilon_i.$$

Nesse modelo:

- β_0 é a taxa de conclusão prevista para alunos do grupo controle exatamente no limiar;
- β_1 é a inclinação local da relação entre nota e conclusão abaixo do corte;
- τ é o salto estimado no ponto de corte;
- δ permite que a inclinação da reta seja diferente no lado tratado.

Suponha que a regressão estimada tenha produzido:

$$\hat{Y}_i = 0,62 + 0,008X_i^* + 0,11D_i - 0,003D_iX_i^*.$$

O erro padrão estimado para $\hat{\tau}$ foi 0,032.

4. Interpretando os coeficientes

Para alunos logo abaixo do corte, temos $D_i = 0$. Logo, a reta estimada do lado controle é:

$$\hat{Y}_i = 0,62 + 0,008X_i^*.$$

No ponto de corte, $X_i^* = 0$, então:

$$\hat{Y}_{\text{controle no corte}} = 0,62.$$

Para alunos logo acima do corte, temos $D_i = 1$. Substituindo no modelo:

$$\begin{aligned}\hat{Y}_i &= 0,62 + 0,008X_i^* + 0,11 - 0,003X_i^* \\ &= 0,73 + 0,005X_i^*.\end{aligned}$$

No ponto de corte, novamente $X_i^* = 0$, então:

$$\hat{Y}_{\text{tratado no corte}} = 0,73.$$

Portanto, o salto estimado no limiar é:

$$\hat{\tau}_{\text{RDD}} = 0,73 - 0,62 = 0,11.$$

Estimativa RDD

A estimativa RDD indica que, entre alunos próximos ao corte de 70 pontos, receber a bolsa está associado a um aumento estimado de 11 pontos percentuais na probabilidade de conclusão do curso.

Em termos substantivos: alunos que receberam bolsa por ficarem marginalmente acima do corte apresentaram uma taxa de conclusão estimada 11 pontos percentuais maior do que alunos comparáveis que ficaram marginalmente abaixo do corte.

5. Inferência estatística

A estimativa pontual é:

$$\hat{\tau}_{\text{RDD}} = 0,11.$$

Agora queremos avaliar se esse efeito estimado pode ser considerado estatisticamente diferente de zero. Para isso, formulamos a hipótese nula:

$$H_0 : \tau = 0,$$

isto é, a hipótese de que não há salto no resultado exatamente no ponto de corte.

Como em testes de hipóteses para coeficientes de regressão, comparamos a estimativa com seu erro padrão. A estatística de teste é:

$$t = \frac{\hat{\tau}_{\text{RDD}} - 0}{EP(\hat{\tau}_{\text{RDD}})}.$$

Com erro padrão igual a 0,032, obtemos:

$$t = \frac{0,11}{0,032} \approx 3,44.$$

Esse valor indica que a estimativa está cerca de 3,44 erros padrão acima de zero. Em termos intuitivos, se o verdadeiro efeito local fosse zero, seria pouco provável observar uma estimativa tão distante de zero apenas por flutuação amostral. Portanto, há evidência estatística contra a hipótese nula de ausência de efeito local.

Como regra prática, valores de $|t|$ maiores do que aproximadamente 2 costumam indicar significância estatística ao nível de 5%, em amostras moderadas ou grandes. Como $3,44 > 2$, a estimativa fornece evidência estatística de um salto positivo no limiar.

6. Checagens de validade

A estimativa acima só tem interpretação causal se a suposição de continuidade for plausível. Portanto, antes de concluir que a bolsa causou aumento na conclusão, o pesquisador deve verificar se há evidências de violações do desenho RDD.

Balanceamento de covariáveis. As covariáveis pré-determinadas parecem semelhantes nos dois lados do corte:

52% feminino no controle vs. 54% feminino no tratado,

38% renda baixa no controle vs. 37% renda baixa no tratado.

Essas diferenças são pequenas e não sugerem, por si só, uma mudança abrupta na composição dos alunos exatamente no corte. Em uma análise real, porém, seria recomendável estimar regressões RDD usando cada covariável como variável dependente. Se a regra de corte for plausivelmente quase-experimental, covariáveis pré-determinadas não devem apresentar saltos significativos em $c = 70$.

Densidade da variável de corte. Também é necessário verificar se há acúmulo anormal de alunos logo acima do corte. Por exemplo, se professores ou avaliadores pudessem ajustar notas de 69,8 para 70,0 com base em características dos alunos, a comparação local ficaria comprometida. Nesse caso, os alunos logo acima do corte não seriam apenas “ligeiramente melhores” em nota: poderiam ser alunos selecionados administrativamente para receber a bolsa.

Robustez à escolha da janela. A janela principal usada foi $h = 8$. Uma análise convincente deveria verificar se os resultados são semelhantes para outras janelas razoáveis, por exemplo:

$$h = 4, \quad h = 6, \quad h = 8, \quad h = 10.$$

Se a estimativa desaparece ou muda muito de sinal quando a janela é levemente alterada, a conclusão deve ser interpretada com cautela.

Checklist do exemplo RDD

Antes de interpretar $\hat{\tau}_{\text{RDD}} = 0,11$ como efeito causal, devemos perguntar:

1. A regra de elegibilidade é realmente baseada no corte $X = 70$?
2. Há evidência de manipulação da nota de ingresso ao redor do corte?
3. Covariáveis pré-determinadas são contínuas no limiar?
4. A estimativa é robusta a diferentes janelas?
5. Há outras políticas ou benefícios que também começam exatamente em $X = 70$?

7. Conclusão substantiva

Com base na regressão linear local, estimamos que a bolsa aumenta a probabilidade de conclusão em aproximadamente 11 pontos percentuais para alunos próximos ao corte de 70 pontos. O resultado é estatisticamente significativo e, pelas covariáveis resumidas, não há evidência inicial de grande desbalanceamento entre os lados do corte.

No entanto, a conclusão deve ser formulada com cuidado:

Entre alunos com nota de ingresso próxima a 70, receber a bolsa parece aumentar a taxa de conclusão do curso em cerca de 11 pontos percentuais.

Essa frase é mais correta do que afirmar simplesmente:

A bolsa aumenta a taxa de conclusão dos alunos da universidade em 11 pontos percentuais.

A segunda frase extrapola o efeito para todos os alunos, inclusive para aqueles muito distantes do corte. A RDD identifica um efeito local: ela é mais convincente justamente para os alunos cuja elegibilidade foi determinada por uma diferença mínima em torno do limiar.

Mensagem final do exemplo

A força da RDD está na comparação local. O método não pergunta se todos os bolsistas são melhores do que todos os não bolsistas. Ele pergunta se há um salto no resultado exatamente no ponto em que a regra muda o tratamento.

Neste exemplo, o salto estimado é de 11 pontos percentuais. A interpretação causal depende de defender que, na ausência da bolsa, a taxa de conclusão teria variado suavemente ao redor da nota 70.

3 Diferença-em-Diferenças

3.1 Motivação

Suponha que um estado adote uma nova política de saúde pública em 2018. Queremos saber se ela reduziu internações hospitalares. Não temos acesso a um experimento: todas as pessoas do estado foram expostas à política simultaneamente.

Duas comparações ingênuas falham:

- Antes vs. depois (no estado tratado): as internações podem ter caído por outras razões não relacionadas à política (sazonalidade, contexto econômico, tendência de longo prazo).
- Tratado vs. controle (após a política): o estado tratado pode ser sistematicamente diferente dos demais, mesmo sem a política.

O método de Diferença-em-Diferenças (DiD) combina as duas comparações: mede a *mudança ao longo do tempo* no grupo tratado e subtrai a *mudança ao longo do tempo* no grupo controle. Sob a suposição de tendências paralelas — discutida em detalhe adiante —, essa segunda mudança funciona como uma estimativa do que teria acontecido com o grupo tratado na ausência da política, eliminando simultaneamente tendências temporais comuns e diferenças de nível pré-existentes.

3.2 O Estimador DiD 2×2

O contexto mais simples tem dois grupos (tratado e controle) e dois períodos (antes e depois).

Estimador DiD 2×2

Defina $\bar{Y}_{g,t} = E[Y \mid G = g, T = t]$, onde $G \in \{0, 1\}$ indica o grupo e $T \in \{0, 1\}$ indica o período.

$$\hat{\delta}_{\text{DiD}} = \underbrace{(\bar{Y}_{1,1} - \bar{Y}_{1,0})}_{\text{variação temporal no grupo tratado}} - \underbrace{(\bar{Y}_{0,1} - \bar{Y}_{0,0})}_{\text{variação temporal no grupo controle}}$$

Equivalentemente:

$$\hat{\delta}_{\text{DiD}} = (\bar{Y}_{1,1} - \bar{Y}_{0,1}) - (\bar{Y}_{1,0} - \bar{Y}_{0,0})$$

A segunda forma mostra que DiD também pode ser lida como a *diferença de diferenças entre grupos*: a diferença tratado–controle após o tratamento, subtraída a diferença tratado–controle antes do tratamento.

A interpretação é direta: se o grupo controle tivesse mudado 3 unidades por razões externas ($\bar{Y}_{0,1} - \bar{Y}_{0,0} = 3$) e o tratado mudou 8 unidades ($\bar{Y}_{1,1} - \bar{Y}_{1,0} = 8$), então o DiD atribui $8 - 3 = 5$ unidades ao efeito do tratamento, após descontar a tendência comum.

A Figura 3 ilustra a lógica central do método. A linha tracejada é o contrafactual do grupo tratado: ela assume que, sem a política, o grupo tratado teria crescido no mesmo ritmo que o grupo controle. O estimador DiD mede a distância entre o resultado observado e esse contrafactual no período pós.




Figura 3: Ilustração do estimador DiD 2x2. O grupo controle aumenta 2 unidades (tendência comum). O grupo tratado aumenta 5 unidades. O DiD isola a diferença de 3 unidades como efeito causal do tratamento. A linha tracejada representa o contrafactual: o que teria acontecido com o grupo tratado na ausência do programa.

3.3 Formulação por Regressão

O estimador DiD tem uma representação natural como coeficiente de interação em uma regressão, o que o conecta diretamente ao material das notas anteriores.

DiD como Regressão com Interação

Para cada unidade i em cada período t :

$$Y_{it} = \alpha + \beta \cdot G_i + \gamma \cdot T_t + \delta \cdot (G_i \times T_t) + \varepsilon_{it}$$

onde $G_i \in \{0, 1\}$ é o indicador de grupo tratado e $T_t \in \{0, 1\}$ é o indicador de período pós-tratamento.

Os parâmetros têm a seguinte interpretação:

- $\alpha = \bar{Y}_{0,0}$: média do grupo controle no período pré.
- β : diferença de nível pré-existente entre grupos (pode ser não-nula).
- γ : tendência temporal comum (mudança no controle de pré para pós).
- $\delta = \hat{\delta}_{DiD}$: o estimador causal de interesse.

A equivalência com o estimador 2×2 é verificável diretamente:

$$\begin{aligned}\hat{\delta}_{DiD} &= (E[Y \mid G = 1, T = 1] - E[Y \mid G = 1, T = 0]) \\ &\quad - (E[Y \mid G = 0, T = 1] - E[Y \mid G = 0, T = 0]) \\ &= (\alpha + \beta + \gamma + \delta) - (\alpha + \beta) - (\alpha + \gamma) + \alpha \\ &= \delta.\end{aligned}$$

Dois grupos podem começar em níveis muito diferentes e ainda assim ser válidos para DiD, desde que a diferença entre eles fosse aproximadamente constante ao longo do tempo na ausência do tratamento. O parâmetro β captura exatamente essa diferença pré-existente.

A diferença de nível pré-existente não invalida o DiD

Um equívoco frequente é achar que o DiD requer que os dois grupos tenham médias iguais no período pré. Isso é falso: o parâmetro β captura exatamente essa diferença pré-existente e a regressão a “desconta” automaticamente. O que o DiD requer não é igualdade de *nível*, mas igualdade de *tendência*. Isso é a suposição de tendências paralelas, discutida a seguir.

3.4 A Suposição de Tendências Paralelas

A hipótese identificadora do DiD é a *suposição de tendências paralelas*:

Suposição de Tendências Paralelas

Na ausência de tratamento, a mudança esperada em Y de pré para pós seria a *mesma* nos dois grupos:

$$E[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1] = E[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0]$$

onde $Y_{it}(0)$ denota o resultado potencial da unidade i no período t na *ausência de tratamento*. Em palavras: o contrafactual do grupo tratado (o que teria acontecido sem o tratamento) teria seguido a mesma tendência que o grupo controle.

A suposição de tendências paralelas não é testável diretamente

Tendências paralelas afirmam algo sobre o contrafactual $Y_{it}(0)$ para os tratados no período pós, algo que, por definição, nunca observamos. Não é possível *provar* que a suposição é válida. O que podemos fazer é (i) argumentar substantivamente que o grupo controle é plausível e (ii) testar se as tendências eram paralelas em períodos *pré-tratamento*, como explicado abaixo.

A Figura 4 destaca que a validade do DiD depende da trajetória contrafactual, não da igualdade de níveis. No painel esquerdo, a diferença entre os grupos seria constante na ausência do tratamento; no painel direito, os grupos já seguiam trajetórias diferentes antes da intervenção, e o DiD incorretamente atribuiria parte dessa tendência divergente ao efeito do programa.




Figura 4: Esquerda: tendências paralelas no período pré-tratamento são satisfeitas; as linhas se movem em paralelo antes de $t = 0$. Direita: as tendências já divergiam antes do tratamento, violando a suposição. Nesse caso, o DiD atribuiria ao tratamento o que seria apenas uma continuação da tendência preexistente.

Pergunta 3

Pesquisadores querem estimar o efeito de um programa de vacinação implementado em um estado em 2020. Eles usam outro estado como controle.

- O estado tratado tinha uma taxa de mortalidade que vinha caindo mais rapidamente que a do estado controle *antes* de 2020. Por que isso ameaça a validade do DiD?
- Suponha que, ao mesmo tempo em que o estado tratado implementou a vacinação, ele também promoveu uma campanha de higiene. Como isso afeta a interpretação de $\hat{\delta}_{\text{DiD}}$?
- Um revisor sugere usar como controle estados que seriam “muito similares” ao tratado. Isso é sempre bom? Pode haver problemas com tal escolha?

3.5 Teste de Pré-Tendência

Com dados de múltiplos períodos pré-tratamento, é possível (e fortemente recomendado) testar se as tendências eram paralelas antes do tratamento.

Defina $\tau \in \{\dots, -2, -1, 0, 1, 2, \dots\}$ como o tempo relativo ao início do tratamento ($\tau = 0$). O modelo de estudo de evento é:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{\tau \neq -1} \beta_\tau \cdot \mathbf{1}[\text{unidade } i \text{ tratada, tempo relativo} = \tau] + \varepsilon_{it}$$

O período $\tau = -1$ (um período antes do tratamento) é a categoria de referência. Os coeficientes β_τ para $\tau < 0$ devem ser próximos de zero se as tendências eram paralelas. Um teste F conjunto de $H_0 : \beta_{-k} = \dots = \beta_{-2} = 0$ é o *teste de pré-tendência formal*.

Um teste de pré-tendência não-significativo não *prova* tendências paralelas; ele apenas não encontra evidência contra elas com o poder disponível. Em amostras pequenas, o teste pode ter baixo poder: ele pode deixar de detectar diferenças relevantes de tendência simplesmente porque há pouca informação no período pré-tratamento. O teste é necessário, mas não suficiente, para validar a suposição.

Checkpoint de DiD: você entendeu se consegue explicar...

1. Por que a comparação antes/depois, sozinha, não identifica efeito causal.
2. Por que a comparação tratado/controle, sozinha, também não identifica efeito causal.
3. O que representa a linha contrafactual no gráfico do DiD.
4. Por que tendências paralelas são uma suposição sobre algo que não observamos.

3.6 Exemplo Completo

Nesta seção, vamos aplicar a lógica de Diferença-em-Diferenças a um exemplo completo. O objetivo é mostrar como a comparação antes-depois é combinada com a comparação tratado-controle para construir uma estimativa causal.

Situação-problema

Um município ofereceu capacitação profissional a trabalhadores desempregados em 2019. Chamaremos esse município de **grupo tratado**. Um município vizinho, com características socioeconômicas semelhantes, não ofereceu o programa no mesmo período. Chamaremos esse município de **grupo controle**.

O pesquisador quer estimar o efeito do programa sobre os salários mensais médios dos trabalhadores. Os salários médios observados foram:

	2018 (antes)	2020 (depois)
Município tratado	R\$ 1.850	R\$ 2.310
Município controle	R\$ 1.920	R\$ 2.080

A pergunta causal é:

O programa de capacitação aumentou os salários médios dos trabalhadores desempregados no município tratado?

Como em qualquer pergunta causal, o desafio é construir um contrafactual. Gostaríamos de saber qual teria sido o salário médio no município tratado em 2020 caso o programa de capacitação não tivesse sido oferecido. Esse valor não é observado. O método DiD usa a evolução do município controle como aproximação para essa trajetória contrafactual. Como elementos do desenho DiD neste exemplo, temos:

- *Unidade de comparação*: município.
- *Grupo tratado*: município que ofereceu o programa de capacitação.
- *Grupo controle*: município vizinho que não ofereceu o programa.
- *Período pré-tratamento*: 2018.
- *Período pós-tratamento*: 2020.

- *Tratamento*: oferta do programa de capacitação em 2019.
- *Resultado*: salário mensal médio dos trabalhadores.
- *Estimando*: efeito médio do programa sobre o salário no município tratado, sob a suposição de tendências paralelas.

1. Por que comparações simples não bastam?

Antes de calcular o estimador DiD, é útil observar por que duas comparações mais simples seriam insuficientes.

Comparação antes–depois no município tratado. No município tratado, o salário médio aumentou de R\$ 1.850 para R\$ 2.310:

$$2310 - 1850 = 460.$$

Uma interpretação apressada diria que o programa aumentou os salários em R\$ 460. No entanto, essa conclusão ignora que os salários poderiam ter aumentado por outros motivos entre 2018 e 2020, como crescimento econômico, inflação salarial, mudanças setoriais ou políticas estaduais.

Comparação tratado–controle após o programa. Em 2020, o salário médio no município tratado foi R\$ 2.310, enquanto no controle foi R\$ 2.080:

$$2310 - 2080 = 230.$$

Essa comparação também não identifica o efeito causal, pois os municípios já podiam ter níveis salariais diferentes antes do programa. De fato, em 2018, o município tratado tinha salário médio menor do que o controle:

$$1850 - 1920 = -70.$$

Portanto, a diferença observada em 2020 mistura o possível efeito do programa com diferenças pré-existentes entre os municípios.

Por que precisamos do DiD?

A comparação antes–depois no grupo tratado confunde o efeito do programa com mudanças gerais ao longo do tempo. A comparação tratado–controle no período pós confunde o efeito do programa com diferenças pré-existentes entre os municípios. O DiD combina as duas comparações: ele mede quanto o município tratado mudou ao longo do tempo e desconta a mudança observada no município controle.

2. Cálculo do estimador DiD

O estimador Diferença-em-Diferenças é dado por:

$$\hat{\delta}_{\text{DiD}} = (\bar{Y}_{1,1} - \bar{Y}_{1,0}) - (\bar{Y}_{0,1} - \bar{Y}_{0,0}),$$

onde:

- $\bar{Y}_{1,0}$ é a média do grupo tratado antes do programa;

- $\bar{Y}_{1,1}$ é a média do grupo tratado depois do programa;
- $\bar{Y}_{0,0}$ é a média do grupo controle antes do programa;
- $\bar{Y}_{0,1}$ é a média do grupo controle depois do programa.

Substituindo os valores da tabela:

$$\begin{aligned}\hat{\delta}_{\text{DiD}} &= (2310 - 1850) - (2080 - 1920) \\ &= 460 - 160 \\ &= \mathbf{300}.\end{aligned}$$

Portanto, a estimativa DiD do efeito do programa é R\$ 300.

3. Construindo o contrafactual

O município controle teve aumento salarial de R\$ 160 entre 2018 e 2020:

$$2080 - 1920 = 160.$$

Sob a suposição de tendências paralelas, assumimos que, na ausência do programa, o município tratado teria seguido a mesma variação temporal do município controle. Como o salário médio do município tratado em 2018 era R\$ 1.850, seu salário contrafactual em 2020 seria:

$$1850 + 160 = 2010.$$

Esse valor, R\$ 2.010, representa o que estimamos que teria acontecido com o município tratado em 2020 se o programa não tivesse sido oferecido.

Mas o salário observado no município tratado em 2020 foi R\$ 2.310. Portanto, a diferença entre o observado e o contrafactual é:

$$2310 - 2010 = 300.$$

Esse é exatamente o estimador DiD.

Interpretação do estimador DiD

O município tratado teve aumento salarial de R\$ 460. O município controle teve aumento de R\$ 160 no mesmo período.

O DiD atribui ao programa apenas o aumento adicional do município tratado em relação ao controle:

$$460 - 160 = 300.$$

Assim, sob a suposição de tendências paralelas, estimamos que o programa de capacitação aumentou o salário mensal médio em R\$ 300.

4. Formulação por regressão

O mesmo resultado pode ser obtido por meio de uma regressão com interação. Definimos:

$$G_i = \begin{cases} 1, & \text{se a observação pertence ao município tratado,} \\ 0, & \text{se pertence ao município controle,} \end{cases}$$

e

$$T_t = \begin{cases} 1, & \text{se a observação é do período pós-tratamento,} \\ 0, & \text{se é do período pré-tratamento.} \end{cases}$$

O modelo DiD é:

$$Y_{it} = \alpha + \beta G_i + \gamma T_t + \delta(G_i \times T_t) + \varepsilon_{it}.$$

Neste exemplo, a equação estimada é:

$$\hat{Y}_{it} = 1920 - 70G_i + 160T_t + 300(G_i \times T_t).$$

Vamos interpretar cada coeficiente.

- $\hat{\alpha} = 1920$: salário médio do grupo controle antes do programa.
- $\hat{\beta} = -70$: diferença inicial entre tratado e controle. Antes do programa, o município tratado ganhava R\$ 70 a menos que o controle.
- $\hat{\gamma} = 160$: mudança temporal do grupo controle entre 2018 e 2020.
- $\hat{\delta} = 300$: estimativa DiD, isto é, aumento adicional do grupo tratado após o programa.

5. Verificando os quatro valores da tabela

A regressão reproduz exatamente as quatro médias observadas.

Controle antes: $G_i = 0, T_t = 0$.

$$\hat{Y} = 1920 - 70(0) + 160(0) + 300(0 \cdot 0) = 1920.$$

Tratado antes: $G_i = 1, T_t = 0$.

$$\hat{Y} = 1920 - 70(1) + 160(0) + 300(1 \cdot 0) = 1850.$$

Controle depois: $G_i = 0, T_t = 1$.

$$\hat{Y} = 1920 - 70(0) + 160(1) + 300(0 \cdot 1) = 2080.$$

Tratado depois: $G_i = 1, T_t = 1$.

$$\hat{Y} = 1920 - 70(1) + 160(1) + 300(1 \cdot 1) = 2310.$$

Portanto, o coeficiente da interação $G_i \times T_t$ coincide com o estimador DiD calculado diretamente pelas médias.

6. Onde entra a suposição de tendências paralelas?

A interpretação causal de $\hat{\delta}_{\text{DiD}} = 300$ depende da suposição de tendências paralelas. Neste exemplo, essa suposição afirma que, se o município tratado não tivesse oferecido o programa, seus salários teriam aumentado no mesmo ritmo observado no município controle.

Formalmente, a suposição é:

$$E[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1] = E[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0].$$

Em palavras: na ausência do programa, a mudança salarial esperada teria sido a mesma nos dois municípios.

O DiD não exige níveis iguais no pré-tratamento

Observe que os municípios não tinham o mesmo salário médio em 2018. O município tratado tinha salário médio de R\$ 1.850, enquanto o controle tinha salário médio de R\$ 1.920.

Isso não invalida o DiD. O método permite diferenças de nível entre os grupos. O que ele exige é que, na ausência do tratamento, os grupos tivessem seguido tendências semelhantes.

7. Checagens de validade

Com apenas dois grupos e dois períodos, não é possível testar empiricamente se as tendências eram paralelas antes do programa. Para isso, seria necessário observar os salários em vários anos anteriores a 2019, por exemplo de 2015 a 2018.

Se os dados anteriores fossem disponíveis, poderíamos verificar se os salários dos dois municípios evoluíam de forma aproximadamente paralela antes da capacitação. Por exemplo, seria tranquilizador observar algo como:

	2015	2016	2017	2018
Município tratado	1600	1680	1760	1850
Município controle	1670	1750	1840	1920

Nesse caso, os dois municípios apresentam trajetórias parecidas antes do programa, o que tornaria a suposição de tendências paralelas mais plausível.

Por outro lado, se o município tratado já estivesse crescendo mais rapidamente antes de 2019, por exemplo por causa da chegada de novas empresas ou de investimentos locais, a estimativa DiD poderia superestimar o efeito do programa.

Checklist do exemplo DiD

Antes de interpretar $\hat{\delta}_{\text{DiD}} = 300$ como efeito causal, devemos perguntar:

1. Os municípios tinham trajetórias salariais semelhantes antes de 2019?
2. Alguma outra política afetou apenas o município tratado no mesmo período?
3. O município controle permaneceu sem tratamento ou sem política semelhante?
4. Houve choques econômicos que afetaram diferentemente os dois municípios?
5. A composição dos trabalhadores mudou de forma diferente entre os municípios?

8. Conclusão substantiva

A estimativa DiD sugere que o programa de capacitação aumentou o salário mensal médio em R\$ 300 no município tratado, após descontar a variação salarial observada no município controle.

Uma conclusão cuidadosa seria:

Sob a suposição de tendências paralelas, o programa de capacitação está associado a um aumento estimado de R\$ 300 no salário mensal médio dos trabalhadores do município tratado.

Essa formulação é mais adequada do que afirmar simplesmente:

O programa aumentou os salários em R\$ 300.

A segunda frase omite a suposição necessária para a interpretação causal. O DiD não prova automaticamente que o programa causou o aumento; ele fornece uma estimativa causal plausível quando o grupo controle representa bem a trajetória contrafactual do grupo tratado.

Mensagem final do exemplo

A força do DiD está em transformar uma comparação antes-depois em uma comparação contrafactual. O município controle informa qual teria sido a tendência esperada no município tratado na ausência do programa.

Neste exemplo, o município tratado cresceu R\$ 460, mas R\$ 160 desse crescimento é interpretado como tendência comum. O aumento adicional de R\$ 300 é a estimativa DiD do efeito do programa.

4 Implementação em Python**4.1 Regressão Descontínua com statsmodels**

O código abaixo implementa a estimação manual por regressão linear local dentro de uma janela de tamanho fixo, usando `statsmodels`. Para seleção ótima de janela pelo critério de Calonico, Cattaneo e Titiunik (CCT), recomenda-se o pacote `rdrobust` (disponível em R e, com instalação adicional, em Python). Os princípios de interpretação são os mesmos.

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.formula.api as smf

np.random.seed(42)
n = 500
# Variavel de corte: nota de entrada (0 a 100), corte em 60
X = np.random.uniform(20, 100, n)
D = (X >= 60).astype(int) # RDD nitida: bolsa se nota >= 60

# Resultado potencial: media de desempenho futuro
# Efeito causal real da bolsa: 5 pontos
Y0 = 40 + 0.3 * X + np.random.normal(0, 5, n) # sem bolsa
Y1 = Y0 + 5 # com bolsa
Y = D * Y1 + (1 - D) * Y0 # observado

df = pd.DataFrame({'Y': Y, 'X': X, 'D': D})

#####
# Estimacao por regressao linear local
# Janela: +/- 10 pontos ao redor do limiar c = 60
#####
c, h = 60, 10
janela = df[(df['X'] >= c - h) & (df['X'] <= c + h)].copy()
janela['Xc'] = janela['X'] - c # centralizar
janela['DXc'] = janela['D'] * janela['Xc'] # interacao

modelo_rdd = smf.ols('Y ~ Xc + D + DXc', data=janela).fit()
print(modelo_rdd.summary())
# O coeficiente de D e a estimativa tau_RDD

tau_hat = modelo_rdd.params['D']
print(f"\ntau_RDD estimado: {tau_hat:.3f} (verdadeiro: 5.0)")
print(f"p-valor: {modelo_rdd.pvalues['D']:.4f}")
print(f"IC 95%: [{modelo_rdd.conf_int().loc['D',0]:.3f},
      "
      f"{modelo_rdd.conf_int().loc['D',1]:.3f}]",)

#####
# Grafico de dispersao com retas ajustadas
#####
fig, ax = plt.subplots(figsize=(8, 5))
# Pontos binned para visualizacao
bins = np.arange(20, 101, 4)
df['bin'] = pd.cut(df['X'], bins=bins, labels=bins[:-1]+2)
medias = df.groupby('bin', observed=True)['Y'].mean()
ax.scatter(medias.index.astype(float), medias.values,
          color='steelblue', zorder=4, label='Médias por intervalo
          ')

```



```

# Retas ajustadas nos dois lados
x_left = np.linspace(c - h, c, 100)
x_right = np.linspace(c, c + h, 100)
ax.plot(x_left,
        modelo_rdd.params['Intercept'] + modelo_rdd.params['Xc']*(
            x_left-c),
        'k-', lw=2, label='Reta ajustada (controle)')
ax.plot(x_right,
        (modelo_rdd.params['Intercept'] + tau_hat) +
        (modelo_rdd.params['Xc'] + modelo_rdd.params['DXc'])*(
            x_right-c),
        'b-', lw=2, label='Reta ajustada (tratado)')

ax.axvline(c, color='red', linestyle='--', alpha=0.7, label=f'
    Limiar c={c}')
ax.set_xlabel('Nota de entrada (variável de corte)')
ax.set_ylabel('Desempenho futuro')
ax.set_title(f'RDD Nítida |  $\hat{\tau}$  = {tau_hat:.2f} '
             f'(IC 95%: [{modelo_rdd.conf_int().loc["D",0]:.2f}, '
             f'{modelo_rdd.conf_int().loc["D",1]:.2f}])')
ax.legend()
plt.tight_layout()
plt.show()

```

4.2 Inspeção Visual da Densidade da Variável de Corte

O código abaixo produz uma inspeção visual inicial da distribuição da variável de corte em torno do limiar. Isso *não* substitui o teste formal de McCrary (2008): é apenas um passo exploratório para identificar desequilíbrios óbvios. Para análises formais, recomenda-se o pacote `rddensity` (disponível em R).

```

# Inspecao visual da densidade da variavel de corte
fig, ax = plt.subplots(figsize=(7, 4))
ax.hist(df[df['X'] < c]['X'], bins=20, alpha=0.6,
        color='gray', label='Controle (X < 60)')
ax.hist(df[df['X'] >= c]['X'], bins=20, alpha=0.6,
        color='steelblue', label='Tratado (X >= 60)')
ax.axvline(c, color='red', linestyle='--', label='Limiar c=60')
ax.set_xlabel('Variável de corte X')
ax.set_ylabel('Frequência')
ax.set_title('Inspeção Visual da Densidade (pré-teste informal)')
ax.legend()
plt.tight_layout()
plt.show()

# NOTA: este gráfico é apenas uma inspeção informal.
# Para o teste formal de densidade de McCrary, use rddensity em R
# ou uma implementação equivalente.

```

4.3 Diferença-em-Diferenças com statsmodels

```

import numpy as np
import pandas as pd
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt

np.random.seed(0)
n_unidades = 100 # 50 tratadas, 50 controle
n_periodos = 4 # periodos: -2, -1, 0 (tratamento), 1

# Simulacao de painel
dados = []
for i in range(n_unidades):
    tratado = int(i >= 50)
    efeito_fixo = np.random.normal(0, 2) # heterogeneidade individual
    for t in [-2, -1, 0, 1]:
        tendencia = 1.5 * t # tendencia comum
        # 0 tratamento começa em t=0; efeito causal real = 4
        tratamento_ativo = int(tratado == 1 and t >= 0)
        y = (10 + 3 * tratado # nivel base diferente
             + tendencia # tendencia comum
             + 4 * tratamento_ativo # efeito causal
             + efeito_fixo
             + np.random.normal(0, 1.5))
        dados.append({'id': i, 't': t, 'Y': y,
                     'tratado': tratado,
                     'pos': int(t >= 0),
                     'D': tratamento_ativo})

df = pd.DataFrame(dados)

#####
# Modelo DiD 2x2 (usando apenas t=-1 e t=1)
#####
df2x2 = df[df['t'].isin([-1, 1]).copy()]
modelo_did = smf.ols('Y ~ tratado + pos + tratado:pos',
                     data=df2x2).fit()
print(modelo_did.summary())
delta_did = modelo_did.params['tratado:pos']
print(f"\ndelta_DiD estimado: {delta_did:.3f} (verdadeiro: 4.0)")

#####
# TWFE com todos os periodos (efeitos fixos via dummies)
#####
df['id_str'] = df['id'].astype(str)
df['t_str'] = df['t'].astype(str)

modelo_twfe = smf.ols(
    'Y ~ D + C(id_str) + C(t_str)',

```

```

    data=df
).fit()

delta_twfe = modelo_twfe.params['D']
print(f"delta_TWFE estimado: {delta_twfe:.3f} (verdadeiro: 4.0)")

#####
# Grafico DiD
#####
medias = (df2x2.groupby(['tratado', 'pos'])['Y']
          .mean().reset_index())

fig, ax = plt.subplots(figsize=(6, 5))
for g, cor, rot in [(0, 'gray', 'Controle'), (1, 'steelblue', '
    Tratado')]:
    sub = medias[medias['tratado'] == g].sort_values('pos')
    ax.plot(sub['pos'], sub['Y'], 'o-', color=cor, lw=2, ms=8,
            label=rot)

# Contrafactual
y_pre_tratado = medias[(medias['tratado']==1)&(medias['pos']==0)][
    'Y'].values[0]
y_pre_controle = medias[(medias['tratado']==0)&(medias['pos']==0)][
    'Y'].values[0]
y_pos_controle = medias[(medias['tratado']==0)&(medias['pos']==1)][
    'Y'].values[0]
tendencia_comun = y_pos_controle - y_pre_controle
cf = y_pre_tratado + tendencia_comun

ax.plot([0, 1], [y_pre_tratado, cf], '--', color='steelblue',
        alpha=0.5, lw=2, label='Contrafactual')
ax.annotate('', xy=(1.05, medias[(medias['tratado']==1)&
    (medias['pos']==1)]['Y'].values
    [0]),
           xytext=(1.05, cf),
           arrowprops=dict(arrowstyle='<->', color='red', lw=2))
ax.set_xticks([0, 1])
ax.set_xticklabels(['Antes', 'Depois'])
ax.set_ylabel('Y médio')
ax.set_title(f'Diferença-em-Diferenças ( $\hat{\Delta}$ ) = {
    delta_did:.2f}')
ax.legend()
plt.tight_layout()
plt.show()

```

4.4 Teste de Pré-Tendência (Estudo de Evento)

```

# Estudo de evento: coeficientes por periodo relativo ao tratamento
# Referencia: t = -1 (exclui-se essa dummy)

```

```

df['t_dummy_m2'] = ((df['t'] == -2) & (df['tratado'] == 1)).astype(
    int)
df['t_dummy_0'] = ((df['t'] == 0) & (df['tratado'] == 1)).astype(
    int)
df['t_dummy_p1'] = ((df['t'] == 1) & (df['tratado'] == 1)).astype(
    int)

modelo_evento = smf.ols(
    'Y ~ t_dummy_m2 + t_dummy_0 + t_dummy_p1 + C(id_str) + C(t_str)',
    data=df
).fit()

coefs = modelo_evento.params[['t_dummy_m2', 't_dummy_0', 't_dummy_p1']]
cis = modelo_evento.conf_int().loc[['t_dummy_m2', 't_dummy_0', 't_dummy_p1']]

fig, ax = plt.subplots(figsize=(6, 4))
periodos_plot = [-2, 0, 1]
ax.errorbar(periodos_plot, coefs.values,
            yerr=[(coefs.values - cis[0].values),
                  (cis[1].values - coefs.values)],
            fmt='o', color='steelblue', capsize=5, ms=8)
ax.axhline(0, color='black', lw=0.8, linestyle='--')
ax.axvline(-0.5, color='red', linestyle=':', alpha=0.5,
            label='Inicio do tratamento')
ax.set_xticks([-2, -1, 0, 1])
ax.set_xticklabels(['-2 (pre)', '-1 (ref.)', '0 (trat.)', '+1 (pos)'])
ax.set_xlabel('Periodo relativo ao tratamento')
ax.set_ylabel('Coeficiente (relativo a t=-1)')
ax.set_title('Estudo de Evento: Teste de Pré-Tendência')
ax.legend()
plt.tight_layout()
plt.show()
# Coeficientes pre-tratamento proximos de zero indicam
# que as tendencias eram paralelas antes do tratamento.

```

5 Resumo Comparativo

Mensagem central

RDD e DiD são duas das ferramentas mais utilizadas para inferência causal com dados observacionais. A escolha entre elas depende da estrutura do problema: RDD é adequado quando o tratamento é determinado por uma regra de limiar; DiD é adequado quando o tratamento ocorre para um grupo em um momento específico. Ambos requerem suposições inspecionáveis (mas não completamente testáveis) e devem ser acompanhados de testes de validade rigorosos.

Síntese: RDD vs. DiD

Aspecto	Regressão (RDD)	Descontínua	Diferença-em-Diferenças (DiD)
Variação explorada	Descontinuidade em regra de limiar		Variação temporal + grupo
Suposição chave	Continuidade de $E[Y(0) X=x]$ em c ; sem manipulação		Tendências paralelas na ausência de tratamento
Estimando	LATE no limiar ($X \approx c$)		ATT (média dos tratados)
Escopo do efeito	Local: válido apenas próximo ao limiar		Mais geral: válido para todos os tratados (sob paralelas)
Testes de validade	Teste de densidade, placebo de covariáveis, limiares fictícios		Teste de pré-tendência, placebo de grupos/períodos
Estimação	Regressão linear local (OLS em janela h)		OLS com interação; TWFE com efeitos fixos
Extensão	Fuzzy RDD $\rightarrow$ IV/LATE dos cumpridores		TWFE com múltiplos períodos (com cautela)
Limitação central	Generalização externa restrita; requer limiar institucional		Tendências paralelas indetetável no pós-tratamento

6 Exercícios de Fixação

Exercício 1: Resultados Potenciais

Uma pesquisadora quer avaliar se participar de um bootcamp de programação (tratamento $D = 1$) aumenta o salário anual de jovens profissionais.

- Defina $Y_i(0)$ e $Y_i(1)$ formalmente nesse contexto.
- Para Lara (participou e tem salário de R\$ 72.000), qual resultado potencial é observado e qual é o contrafactual?
- O pesquisador compara a média salarial de participantes (R\$ 70.000) com a de não-participantes (R\$ 55.000) e conclui que o bootcamp aumenta o salário em R\$ 15.000. Quais fatores podem tornar essa estimativa enviesada? Em que direção?
- O bootcamp é gratuito, mas limitado a 100 vagas selecionadas por nota em um teste. Proposta de um pesquisador: usar a nota de corte como RDD. Identifique: (i) a variável de corte, (ii) o limiar, (iii) o grupo de tratamento, (iv) o estimando.

Exercício 2: Cálculo e Interpretação do Estimador RDD

Os dados abaixo são de um programa de transferência de renda que atende famílias com renda per capita inferior a R\$ 500 (limiar $c = 500$). A variável de resultado é o índice de frequência escolar das crianças (0–100).

Família	Renda per capita (x_i)	D_i	Frequência (y_i)
A	430	1	82
B	460	1	85
C	490	1	88
D	510	0	74
E	540	0	76
F	570	0	71

- Centralize a variável de renda: $x_i^* = x_i - 500$. Calcule x_i^* para cada família.
- Ajuste a regressão linear local $y_i = \beta_0 + \beta_1 x_i^* + \tau D_i + \delta D_i x_i^*$ manualmente. (*Dica:* com apenas 3 pontos de cada lado, você pode ajustar duas retas separadas e tomar a diferença dos interceptos.)
- Interprete $\hat{\tau}$ no contexto do problema.
- O programa foi criado como RDD Nítida, mas você descobre que algumas famílias com renda de R\$ 510 estão recebendo o benefício por engano administrativo. Isso transforma o design em RDD Difusa? Como isso afeta a estimação?

Exercício 3: Cálculo e Interpretação do Estimador DiD

Um estado implementou em 2022 uma política de isenção de IPVA para veículos elétricos. Os dados de emplacamentos mensais médios de veículos elétricos (em centenas) são:

	2021 (antes)	2023 (depois)
Estado com isenção (tratado)	3,2	8,7
Estado sem isenção (controle)	3,8	5,3

- Calcule $\hat{\delta}_{DiD}$ e interprete o resultado.
- Escreva a equação de regressão DiD ($Y = \alpha + \beta G + \gamma T + \delta G \cdot T$) com os valores numéricos de $\hat{\alpha}$, $\hat{\beta}$, $\hat{\gamma}$ e $\hat{\delta}$.
- Verifique que a equação reproduz corretamente os quatro valores da tabela.
- Um analista argumenta: “O estado tratado já estava crescendo mais rapidamente antes de 2022 por causa da chegada de montadoras de veículos elétricos na região.” Que suposição do DiD isso ameaça? Como você tentaria verificar empiricamente essa preocupação?
- Suponha que o estado vizinho (controle), ao ver o crescimento dos elétricos no estado tratado, também implementou uma política de incentivo menor em 2022. Como isso afetaria a interpretação do $\hat{\delta}_{DiD}$?

Exercício 4: Identificação de Violações de Suposições

Para cada cenário abaixo, identifique (i) o método aplicado (RDD ou DiD), (ii) a suposição violada e (iii) a direção esperada do viés.

- Uma RDD usa a nota de uma prova como variável de corte para ingresso em uma escola de elite. Descobriu-se que professores costumam arredondar notas de 6,8 e 6,9 para 7,0 quando o aluno “é esforçado”.
- Um DiD avalia o efeito de uma campanha de saúde em municípios de alta renda (tratados) vs. municípios de baixa renda (controles). No período pós, ocorreu uma crise econômica que afetou principalmente os municípios de baixa renda.
- Uma RDD usa a margem de vitória eleitoral de prefeitos como variável de corte para estudar o efeito de pertencer ao partido governante sobre o recebimento de emendas federais. O pesquisador usa todos os dados disponíveis (margem de -40% a $+40\%$), ajustando um polinômio de grau 5.
- Um DiD avalia a criação de um parque tecnológico em uma cidade. O grupo de controle é formado por cidades que se candidataram ao parque mas não foram selecionadas. Pesquisadores descobrem que as cidades selecionadas já tinham mais empresas de tecnologia e capital de risco antes do parque ser construído.

Exercício 5: Projeto Computacional: DiD com Dados de Paineis

O conjunto de dados de Card and Krueger [1994] é um dos estudos DiD mais citados da economia. Ele compara o emprego no setor de fast-food em New Jersey (tratado: aumento do salário mínimo em abril de 1992) e Pennsylvania (controle: sem aumento) antes e depois da mudança.

- (a) Baixe e explore o dataset disponibilizado pelo professor no repositório da disciplina. Identifique as variáveis de emprego (equivalente em tempo integral, *fte*), estado (*state*: 1 = NJ, 0 = PA) e período (*post*: 1 = depois, 0 = antes).
- (b) Calcule o estimador DiD 2×2 manualmente a partir das médias de emprego por grupo e período.
- (c) Ajuste a regressão DiD com interação ($Y = \alpha + \beta G + \gamma T + \delta G \cdot T$) usando *statsmodels*. Compare $\hat{\delta}$ com o valor calculado em (b).
- (d) Interprete $\hat{\delta}$: um aumento do salário mínimo reduziu o emprego?
- (e) O que Card & Krueger reportaram originalmente? Por que esse resultado foi controverso e que debate ele gerou sobre o efeito do salário mínimo?

```
# Ponto de partida
import pandas as pd
import statsmodels.formula.api as smf

# Substitua pelo caminho local do arquivo fornecido na
# disciplina.
# Colunas esperadas: state (1=NJ, 0=PA), post (1=depois, 0=
# antes),
# fte (full-time equivalent employment)
df = pd.read_csv("card_krueger_1994.csv")

# Calcule as medias por grupo e periodo
medias = df.groupby(['state', 'post'])['fte'].mean()
print(medias)

# Ajuste o modelo DiD
modelo = smf.ols('fte ~ state + post + state:post', data=df).
    fit()
print(modelo.summary())
```

Referências

Sebastian Calonico, Matias D. Cattaneo, and Rocio Titiunik. Robust nonparametric confidence intervals for regression-discontinuity designs. *Econometrica*, 82(6):2295–2326, 2014. doi: 10.3982/ECTA11757.

David Card and Alan B. Krueger. Minimum wages and employment: A case study of the

fast-food industry in new jersey and pennsylvania. *American Economic Review*, 84(4): 772–793, 1994.

Donald B. Rubin. Estimating causal effects of treatments in randomized and non-randomized studies. *Journal of Educational Psychology*, 66(5):688–701, 1974. doi: 10.1037/h0037350.